




Trí tuệ nhân tạo: Cách tiếp cận hiện đại

Nền tảng Nhận thức & Hành vi (Tài liệu chuẩn bị trước thêm môn học Học Máy)

Dựa trên giáo trình tiêu chuẩn của Stuart J. Russell & Peter Norvig.

Hành trình Nhập môn Trí tuệ Nhân tạo (AI): Từ Nền tảng đến Tác tử Thông minh

1. AI LÀ GÌ? 4 HƯỚNG TIẾP CẬN CỐT LÕI

ĐỊNH NGHĨA: HÀNH ĐỘNG GIỐNG CON NGƯỜI

Suy nghĩ/Hành động giống con người hoặc suy nghĩ/hành động hợp lý.



1. Thinking Humanly, 2. Acting Humanly, 3. Thinking Rationally, 4. Acting Rationally.

MÔ HÌNH CHUẨN (STANDARD MODEL)

Tập trung vào "Hành động hợp lý": Xây dựng tác tử thực hiện hành động đúng để đạt mục tiêu.




SUY NGHĨ HỢP LÝ & HÀNH ĐỘNG HỢP LÝ



PHÂN BIỆT AI VÀ ML

AI là lĩnh vực rộng lớn; ML là một nhánh con nghiên cứu khả năng tự cải thiện từ kinh nghiệm.

2. TÁC TỬ THÔNG MINH (INTELLIGENT AGENTS)



CÁC LOẠI HÌNH TÁC TỬ

- Từ tác tử phản xạ đơn giản
- Tác tử dựa trên mục tiêu
- Tác tử hữu dụng

3. NỀN TẢNG ĐA NGÀNH & ỨNG DỤNG THỰC TẾ




SO SÁNH: MÁY TÍNH vs. NÃO BỘ


	Máy tính (2019)	Não người
Đơn vị tính toán:	8 nhân CPU	10^{11} Neuron
Đơn vị lưu trữ:	10^{18} bytes RAM	10^{14} Khớp thần kinh
Thời gian chu kỳ:	10^{-2} giây	10^{-2} giây

THÀNH TỰU TIÊU BIỂU HIỆN NAY





Khung kiến trúc Tác tử & Môi trường



P - Hiệu suất (Performance)

An toàn, nhanh chóng, đúng luật, tối đa hóa lợi nhuận.



E - Môi trường (Environment)

Đường phố, xe cộ, người đi bộ, thời tiết.



A - Cơ cấu (Actuators)

Vô lăng, chân ga, phanh, xi-nhan.




S - Cảm biến (Sensors)


Camera, Radar, GPS, gia tốc kế.



Phân cấp Tác tử thông minh



Giải quyết vấn đề bằng Tìm kiếm & Lập kế hoạch



Tri thức và Lập luận Logic

Logic Mệnh đề (Propositional)


Cơ bản

- Dựa trên các sự kiện (Đúng/Sai).
- Trình bày thế giới một cách cứng nhắc.
- Thiếu khả năng tổng quát hóa.

Logic Bậc nhất (First-Order)


Uyển chuyển

- Trình bày thế giới qua Đối tượng, Thuộc tính, và Quan hệ.
- Sử dụng lượng từ ($\forall$, $\exists$).
- Sát với thực tế phức tạp.



Bản thể học (Ontology): Phương pháp AI sử dụng để phân loại mọi khái niệm trong thế giới thành các mạng lưới đối tượng, sự kiện, không gian và thời gian.

Quyết định dưới sự Bất định



Mạng Bayes (Bayesian Networks)



Chuyển từ suy luận chắc chắn sang biểu diễn tri thức dưới dạng xác suất. Cập nhật niềm tin liên tục khi có bằng chứng mới (Ví dụ: Chẩn đoán y khoa).


Quá trình Quyết định Markov (MDP)



Công cụ lập kế hoạch chuỗi hành động khi kết quả quả mang tính ngẫu nhiên (Stochastic). Mở đường cho việc đưa ra quyết định tuần tự tối ưu.


Điểm bùng phát: Từ Logic đến Học Máy

AI Cổ điển (Classical AI / Deduction)



Con người cung cấp tri thức cho máy móc.


Học Máy (Machine Learning / Induction)




Máy móc tự học từ dữ liệu để sinh ra tri thức.

Điểm bùng phát: Chuyển đổi từ Diễn dịch (Deduction) sang Quy nạp (Induction).

Kiến trúc Học Máy & Học Sâu



Ứng dụng & Hướng tới Tương lai



Hành trang Nhận thức đã hoàn thiện. Chào mừng các bạn chính thức bước vào kỷ nguyên của Học Máy (Machine Learning).

MÁY HỌC - 3 TÍN CHỈ

**Làm chủ thuật toán - Dẫn đầu
tương lai công nghệ.**

Giảng viên: TS. Trần Thành Thắng
Đơn vị: Đại học Đông Á
Khoa: Công nghệ Thông tin & AI



Mục Tiêu Cốt Lõi



Hiểu Sâu Khái Niệm

Nắm vững nền tảng toán học, tư duy cốt lõi và cơ chế hoạt động của các thuật toán Machine Learning và Deep Learning.



Xây Dựng Mô Hình


Tự tay lập trình, tối ưu hóa siêu tham số và tinh chỉnh các kiến trúc mạng nơ-ron phức tạp bằng TensorFlow và Keras.



Triển Khai Thực Tế

Đóng gói và đưa các sản phẩm AI lên môi trường thực tế (Scalable AI), sẵn sàng phục vụ hàng triệu người dùng.

Thang Điểm Đánh Giá Môn Học



50% - Dự Án Cuối Môn

Trọng tâm khóa học. Xây dựng một ứng dụng AI hoàn chỉnh (End-to-End) giải quyết bài toán kinh doanh hoặc kỹ thuật thực tế.

25% - Điểm Thường Xuyên

Bài tập Lab, bài tập về nhà và các thử thách lập trình (Coding tasks) hàng tuần.

15% - Điểm Giữa Kỳ

Kiểm tra kiến thức lý thuyết, đánh giá mức độ hiểu sâu về cấu trúc thuật toán.

10% - Chuyên Cần & Tương Tác

Tham gia thảo luận, phản biện và đóng góp tích cực tại lớp học.

Chặng 1 | Nền Tảng Machine Learning Cổ Điển

Chương 1 - 7: Chinh phục các thuật toán nền móng trước khi bước vào kỷ nguyên Học sâu.

Phân Loại & Hồi Quy

Khám phá Classification, Linear, Polynomial và Softmax Regression.

Máy Học Vector Hỗ Trợ (SVM)


Tối ưu hóa ranh giới quyết định tuyến tính và phi tuyến.

Cây Quyết Định

Trực quan hóa logic phân nhánh (Decision Trees).

Học Tập Hợp (Ensemble Learning)

Kết hợp sức mạnh thông qua Random Forests và Gradient.



Module 1 - Classical ML Foundations (Chapters 1-7: Classification, Linear/Polynomial/Softmax Regression, SVM, Decision Trees, and Ensemble Learning)

Nền tảng và Các khái niệm cốt lõi




Machine Learning là gì?

Khoa học lập trình máy tính để chúng có thể tự học hỏi từ dữ liệu mà không cần lập trình rõ ràng.

Hai nhiệm vụ Học có giám sát phổ biến



Phân loại
(dự đoán nhãn rời rạc)



Hồi quy
(dự đoán giá trị số liên tục)




Thách thức chính: Quá khớp (Overfitting)


Mô hình hoạt động tốt trên dữ liệu huấn luyện nhưng khái quát hóa kém trên dữ liệu mới.

Các Thuật toán Học máy Cổ điển

Hồi quy: Từ Tuyến tính đến Softmax



Tuyến tính
(Linear)



Đa thức
(Polynomial)






Dự đoán đa lớp
(Softmax)



Support Vector Machines (SVM)

Tìm kiếm "con đường" rộng nhất (biên lớn nhất) để phân tách các lớp dữ liệu một cách tối ưu.



Cây quyết định & Ensemble Learning

Cây quyết định rất linh hoạt; khi kết hợp lại (Ensemble) sẽ tạo ra các mô hình mạnh mẽ như Rừng ngẫu nhiên.

Bảng So sánh các Thuật toán

So sánh Nhanh các Thuật toán



Linear Regression

Mục tiêu chính: Dự đoán giá trị số.


Đặc điểm nổi bật: Tìm mối liên hệ tuyến tính giữa đặc trưng và mục tiêu.



SVM

Mục tiêu chính: Phân loại dữ liệu.

Đặc điểm nổi bật: Khớp "con đường" rộng nhất giữa các lớp; hỗ trợ kernel phi tuyến.



Decision Trees

Mục tiêu chính: Phân loại & Hồi quy.

Đặc điểm nổi bật: Cấu trúc phân nhánh dễ hiểu, cổ khá năng khớp các tập dữ liệu phức tạp.

Chặng 2 | Tiền Xử Lý Dữ Liệu & Học Không Giám Sát

Chương 8, 9, 13: Nghệ thuật khám phá cấu trúc ẩn giấu trong dữ liệu thô.



Giảm Chiều Dữ Liệu

Sử dụng PCA và t-SNE để loại bỏ nhiễu, tối ưu hóa đặc trưng và nén không gian.




Phân Cụm Dữ Liệu

Nhóm dữ liệu không nhãn bằng thuật toán K-Means và Gaussian Mixture Models (GMM).



Đường Ống Dữ Liệu


Xây dựng luồng xử lý tự động và nạp dữ liệu tốc độ cao với kiến trúc tf.data.



Module 2 - Preprocessing & Unsupervised Learning (Chapters 8, 9, 13: Dimensionality reduction like PCA/t-SNE, Clustering with K-Means/GMM, and tf.data preprocessing pipelines).


Giảm Chiều Dữ Liệu & Phân Cụm (Học không giám sát)

PCA vs. t-SNE




3D Gốc (Phức tạp)

PCA dùng để nén và tăng tốc huấn luyện




PCA
(Nén & Tăng tốc)



3D Gốc (Phức tạp)

t-SNE dùng để trực quan hóa dữ liệu phức tạp



t-SNE
(Trực quan hóa)

K-Means vs. Gaussian Mixtures (GMM)

Đặc điểm	K-Means	Gaussian Mixtures (GMM)
Bản chất	Phân cụm cứng (Hard Clustering)	Phân cụm mềm (Xác suất)
Hình dạng cụm	 Hình cầu	 Hình elip đa dạng
Ứng dụng chính	Phân đoạn nhóm dựa Phân đoạn khách hàng nhanh	Phát hiện bất thường & Ước tính lung & Ước tính mật độ

Động lực: Tăng tốc, Trực quan hóa & Nén



Giúp loại bỏ
nhiều



Hiểu rõ đặc trưng
quan trọng



Tiết kiệm không
gian lưu trữ

Xây dựng Pipeline Dữ liệu với tf.data


Chaining Transformations



list_files




interleave




map (Tiền xử lý)



batch




prefetch(1)



Model
Training
(GPU)

Kết nối các bước: list_files → interleave → map (tiền xử lý) → batch → prefetch

Tối ưu hiệu năng với Prefetching




Lợi ích của Tiền xử lý "On-the-fly"



Flexible
experiment

Dễ dàng thử nghiệm
logic mới



Áp dụng Data Augmentation mà
không tốn tài nguyên lưu trữ

Chặng 3 | Học Sâu & Chinh Phục TensorFlow

Chương 10 - 12: Kỹ nguyên của Neural Networks. Khai phá sức mạnh của framework hàng đầu thế giới.

Mạng Nơ-ron Nhân Tạo (ANNs)


Kiến trúc mạng sâu, các hàm kích hoạt, và kỹ thuật tinh chỉnh siêu tham số (DNN Tuning).

Tự Động Vi Phân (Autodiff)

Trái tim của quá trình huấn luyện mạng nơ-ron (Backpropagation).

Tùy Chỉnh Linh Hoạt

Phá vỡ ranh giới bằng việc tự xây dựng mô hình, hàm suy hao (loss functions) và các lớp đặc thù.




Module 3 - Deep Learning & TensorFlow

(Chapters 10-12: ANNs, DNN tuning, Custom models/layers, and Autodiff)

CHƯƠNG 10: KIẾN TRÚC MẠNG NƠ-RON & KERAS API

TỪ PERCEPTRON ĐẾN MLP



Mạng Perceptron đa lớp (MLP) là nền tảng giải quyết các bài toán phân loại và hồi quy phức tạp.

BA PHƯƠNG PHÁP XÂY DỰNG MÔ HÌNH KERAS



SEQUENTIAL API
(đơn giản)




FUNCTIONAL API
(linh hoạt)



SUBCLASSING API
(động)

Lựa chọn giữa Sequential API (đơn giản), Functional API (linh hoạt) hoặc Subclassing API (động).



SỨC MẠNH CỦA MẠNG NƠ-RON NHÂN TẠO (ANN)

Khả năng mở rộng cực cao để xử lý hàng tỷ hình ảnh hoặc giọng nói.

CHƯƠNG 11: TÍNH CHỈNH & TỐI ƯU HÓA DNN

GIẢI QUYẾT GRADIENT KHÔNG ỔN ĐỊNH



KHỞ TẠO TRONG SỐ (HE/GLOROT)

Sử dụng khởi tạo trong số (He/Glorot) và hàm kích hoạt (ReLU/Swish) để tránh gradient biến mất.

HÀM KÍCH HOẠT (RELU/SWISH)



TÍNH CHỈNH SIÊU THAM SỐ (HYPERPARAMETER TUNING)



Sử dụng Reras Tuner để tự động tìm kiếm tốc độ học (learning rate) và số neuron tối ưu.

CÔNG CỤ KIỂM SOÁT HUẤN LUYỆN



EARLY STOPPING

Áp dụng Early Stopping, Model Checkpoints và TensorBoard để theo dõi và dừng huấn luyện đúng lúc.



MODEL CHECKPOINTS



TENSORBOARD

CHƯƠNG 12: TÙY BIẾN CHUYÊN SÂU & AUTODIFF

TENSORFLOW: "NUMPY TRÊN STEROIDS"



TENSOR




MÁY CHỦ PHÂN TÁN


Tensors hỗ trợ tính toán song song trên GPU và phân tán trên nhiều máy chủ.



THÀNH PHẦN TÙY CHỈNH (CUSTOM COMPONENTS)



TỰ VIẾT CÁC LỚP (LAYERS)



HÀM MẤT MẶT (LOSS)



MÔ HÌNH (MODELS)

Tự viết các Lớp (Layers), Nền mất mặt (Loss) và hình ảnh (models) cho các yêu cầu đặc thù.

ĐẠO HÀM TỰ ĐỘNG (AUTODIFF)



GRADIENTTAPE

Sử dụng GradientTape để tự động tính toán gradient, giúp tối ưu hóa tham số mô hình hiệu quả.

SƠ SÁNH CÁC PHƯƠNG PHÁP TÍNH ĐẠO HÀM

PHƯƠNG PHÁP	ĐẶC ĐIỂM CHÍNH	ỨNG DỤNG
PHÂN TÍCH (ANALYSIS)	CHÍNH XÁC TUYỆT ĐỐI	KHOẢNG THỰC INHỮU VỚI MẢNG DỮ LIỆU PHỨC TẠP
FORWARD-MODE AUTODIFF	TÍNH THÂN TỪ ĐẦU VÀO ĐẾN ĐẦU RA	HIỆU QUẢ KHI CÓ ÍT BIẾN ĐẦU VÀO
REVERSE-MODE AUTODIFF (TENSORFLOW BẰNG)	TÍNH THÂN NGƯỢC TỪ ĐẦU RA	HIỆU QUẢ NHẤT CHO BẾNG LỢI NHẬP (NẾU THANG RẮC)

Chặng 4 | AI Nâng Cao & Mô Hình Sinh

Chương 14 - 18: Từ thị giác máy tính, ngôn ngữ tự nhiên đến việc tạo ra nội dung hoàn toàn mới.

Thị Giác Máy Tính:

Khai thác mạng tích chập (CNN) để phân tích hình ảnh.

Xử Lý Ngôn Ngữ Tự Nhiên:

Làm chủ dữ liệu chuỗi với Transformers và Attention.

Mô Hình Sinh:

Khám phá GANs, Autoencoders và Diffusion Models.



Học Tăng Cường:

Huấn luyện các tác tử AI tự ra quyết định trong môi trường biến động.


Module 4 - Advanced AI & Generative Models

(Chapters 14-18: Computer Vision/CNN, Sequence processing/RNN/Transformers, Generative models like GANs/Diffusion, and Reinforcement Learning).

Kiến Trúc Xử Lý Hình Ảnh và Chuỗi (CNN & RNN)

CNN: Tối ưu cho Thị giác Máy tính

CNN sử dụng trường tiếp nhận cục bộ và tái sử dụng trọng số để giảm tham số so với DNN.




Cấu trúc Phân cấp của CNN



RNN: Chuyên gia Dữ liệu Tuần tự

Có khả năng xử lý chuỗi độ dài tùy ý như văn bản, âm thanh và dự báo chuỗi thời gian.



Mô Hình Sinh và Cơ Chế Chú Ý (Generative & Transformers)


Transformer & Multi-Head Attention

Cơ chế Attention giúp mô hình xác định sự liên quan giữa các từ trong ngữ cảnh.



GANs: Trò chơi Đối đầu

Generator tạo ảnh giả để đánh lừa Discriminator, ứng dụng trong chỉnh sửa ảnh và tăng cường dữ liệu.




So sánh: GANs vs. Diffusion Models

Đặc điểm	GANs	Diffusion Models
Chất lượng ảnh	Thuyết phục	Rất cao/Vượt trội
Độ đa dạng	Dễ bị sụp đổ chế độ (Mode Collapse)	Rất đa dạng
Tốc độ tạo ảnh	Nhanh	Chậm (do quy trình khử nhiễu)

Học Tăng Cường (Reinforcement Learning - RL)


Học qua Thử sai và Phần thưởng

Agent thực hiện hành động trong môi trường để tối đa hóa tổng phần thưởng nhận được.



Sự cân bằng Explore vs. Exploit

Agent phải chọn giữa việc khám phá hành động mới và khai thác các hành động đã biết hiệu quả.



Bài toán Phân bổ Tín nhiệm

Khó khăn trong việc xác định hành động cụ thể nào dẫn đến phần thưởng cuối cùng bị trì hoãn.



Chặng 5 | Vận Hành Ở Quy Mô Lớn & MLOps


Chương 19: Đưa mô hình từ phòng Lab ra thế giới thực để phục vụ hàng triệu người dùng.

- ✓ **Môi Trường Đám Mây:** Huấn luyện mô hình phân tán trên nền tảng Google Vertex AI.
- ✓ **Cung Cấp API:** Đưa mô hình vào sản xuất và phục vụ thông qua TensorFlow Serving.
- ✓ **Tối Ưu Hóa Trọng Số:** Áp dụng lượng tử hóa sau huấn luyện (Post-training Quantization).
- ✓ **Triển Khai Đa Nền Tảng:** Vận hành trên thiết bị di động (TFLite) và trình duyệt web (TF.js).




Module 5 - Production Scaling & MLOps (Chapter 19: TF Serving, Vertex AI cloud training, post-training quantization, and TFLite/TF.js deployment).

Triển khai Quy mô lớn trên Máy chủ và Đám mây



SavedModel

Xuất mô hình sang định dạng SavedModel để TF Serving tự động theo dõi và cập nhật phiên bản



TensorFlow Serving (TF Serving)

Máy chủ hiệu suất cao (C++) hỗ trợ triển khai nhiều phiên bản mô hình và thử nghiệm A/B



Client (REST)

Phổ biến, dễ sử dụng, định dạng JSON (Dùng khi cần sự tương thích rộng rãi và tính đơn giản)



Client (gRPC)

Hiệu suất cao, nén dữ liệu tốt, dùng protocol buffers (Dùng khi cần độ trễ thấp nhất và thông lượng dữ liệu lớn)



Google Vertex AI & Cloud Training

Nền tảng đám mây quản lý dữ liệu, huấn luyện quy mô lớn (GPU/TPU) và tinh chỉnh siêu tham số tự động

Tối ưu hóa và Triển khai trên Thiết bị Di động & Web



32-bit float

4x
smaller size



8-bit integer


Post-training Quantization Lượng tử hóa sau huấn luyện

Chuyển đổi trọng số từ float 32-bit sang integer 8-bit giúp giảm 4 lần kích thước mô hình



TensorFlow Lite (TFLite)

Sử dụng FlatBuffers để nén mô hình, giảm độ trễ và tiết kiệm pin cho thiết bị nhúng



TensorFlow.js (TF.js) cho Trình duyệt

Chạy dự đoán trực tiếp trên trình duyệt web, bảo vệ quyền riêng tư và tận dụng WebGL

Đồ Án Cuối Môn | Kiến Tạo Ứng Dụng End-to-End

Hiện thực hóa kiến thức qua việc tự tay thiết kế và vận hành một sản phẩm AI hoàn chỉnh (Trọng số: 50%).

1. Mục Tiêu

Xác định bài toán kinh doanh hoặc nhu cầu thực tiễn cần AI can thiệp.

2. Dữ Liệu

Thu thập, làm sạch và áp dụng các kỹ thuật phân tích (EDA) trên tập dữ liệu.

3. Huấn Luyện

Thiết kế kiến trúc, thử nghiệm thuật toán toán và tinh chỉnh siêu tham số.

4. Triển Khai

Đóng gói mô hình thành Live API hoặc Web Service hoàn chỉnh cho người dùng.

Hệ Sinh Thái Công Nghệ


Làm chủ các công cụ tiêu chuẩn của ngành công nghiệp (Industry-Standard Tech Stack).

Tầng 4: Môi trường Cloud GPU tối ưu huấn luyện.

Tầng 3: Xây dựng và tinh chỉnh Neural Networks cốt lõi.

Tầng 2: Triển khai các thuật toán Machine Learning nền tảng.

Tầng 1: Xử lý mảng, ma trận, và trực quan hóa dữ liệu thô.



Tri Thức Cốt Lõi & Mở Rộng Tư Duy



Sách Giáo Trình

Tác giả: Aurélien Géron

Cuốn “kinh thánh” thực hành không thể thiếu, cung cấp tư duy giải quyết vấn đề sắc bén cho kỹ sư AI.



Kênh Nghe Nhìn

Lex Fridman Podcast

Các cuộc đối thoại chuyên sâu cùng các bộ óc vĩ đại nhất về trí tuệ nhân tạo, triết học và tương lai.

ML Street Talk (MLST)

Sân chơi học thuật mổ xẻ các đột phá nghiên cứu (papers) mới nhất trong ngành học máy.

TỪ CON SỐ 0 ĐẾN KỸ SƯ AI

Khóa học này không chỉ truyền đạt lý thuyết. Đây là lò luyện tạo ra những kỹ sư có khả năng kiến tạo tương lai. Hãy tham gia lớp học, kết nối cùng đồng đội, và xây dựng những giải pháp đột phá giải quyết các thách thức của thế giới thực.

“Tương lai không được dự đoán, tương lai do chính bạn lập trình.”

Khóa Học Này Mở Ra Chân Trời Nào?



Machine Learning Engineer

Xây dựng, đưa vào sản xuất và duy trì hiệu năng của các hệ thống thuật toán quy mô lớn tại các tập đoàn công nghệ.


Data Scientist

Nhà Khoa học Dữ liệu – những người kể chuyện bằng những con số, khai phá giá trị kinh doanh chiến lược từ tập dữ liệu khổng lồ.

AI Researcher / MLOps


Mở rộng ranh giới của AI, hoặc chuyên biệt hóa trong việc tự động hóa và tối ưu chu trình vòng đời của mô hình AI.

Hành Trang Cần Chuẩn Bị



Nền Tảng Toán Học

- **Đại Số Tuyến Tính:** Thao tác cơ bản với Ma trận và Vector.
- **Giải Tích Cơ Bản:** Nắm vững Đạo hàm và Tích phân phục vụ tối ưu hóa.



Kỹ Năng Lập Trình

- **Python Cơ Bản:** Thành thạo vòng lặp, hàm (functions), và cấu trúc dữ liệu.

Lưu ý: Sẽ có các tài liệu bổ trợ (Cheat-sheets) giúp bạn ôn tập và lấy lại gốc nhanh chóng ngay trong tuần đầu tiên!

Q & A

Bạn đã sẵn sàng để trở thành một kỹ sư AI?



Email: lienhe@donga.edu.vn



Văn phòng: Khoa Công nghệ Thông tin & AI



Kênh hỗ trợ sinh viên: Microsoft Teams



BỨC TRANH TỔNG QUAN VỀ HỌC MÁY

Chương 1 – Machine Learning

TS. Trần Thành Thắng
Đại học Đông Á
August 11, 2026

Nội dung Chương trình



1. Khái quát & Ứng dụng của Học máy



2. Phân loại Hệ thống Học máy



3. Thách thức, Kiểm thử & Xác thực

Bức Tranh Tổng Quan Về Machine Learning (Chương 1)

Tóm tắt nội dung nền tảng về Machine Learning (ML), từ việc hiểu ML là gì, tại sao cần sử dụng, phân loại các hệ thống ML đến quy trình thực hiện một dự án thực tế và các khái niệm đại số tuyến tính thiết yếu.

Lý Thuyết Nền Tảng & Phân Loại

Machine Learning Là Gì?



Khả năng học từ dữ liệu để cải thiện hiệu suất mà không cần lập trình cụ thể.

4 Cách Phân Loại Hệ Thống ML

Giám Sát

VS.

Không Giám Sát




Theo Giám Sát (Supervised)

Học có giám sát dùng dữ liệu có nhãn.



Học Tăng Cường (Reinforcement)

Học tăng cường, học từ tương tác và phản hồi.



Khả Năng Tổng Quát Hóa

Cách thức tổng quát hóa dữ liệu.



Tổng Quát (General Learning)


Hoặc cách thức tổng quát hóa dữ liệu.

Thực Hành & Thách Thức Cốt Lõi

Quy Trình Dự Án ML Điển Hình



Thu thập dữ liệu.



Chọn mô hình.



Huấn luyện tham số.




Đưa ra dự đoán.

Bài Toán Hồi Quy Tuyến Tính




Dự đoán mức độ hài lòng cuộc sống dựa trên chỉ số GDP đầu người.

Quá Khớp & Dưới Khớp



Quá Khớp

Quá phức tạp để học dữ liệu.



Dưới Khớp

Quá đơn giản để học dữ liệu.

Thách Thức Cốt Lõi & Giải Pháp

Loại Thách Thức	Ví Dụ Điển Hình	Giải Pháp
Dữ liệu kém	Dữ liệu không đại diện, nhiều	Thu thập thêm dữ liệu, làm sạch dữ liệu
Thuật toán kém (Poor Algo)	Quá khớp	Đơn giản hóa mô hình, chỉnh quy hóa
	Dưới khớp	Chọn mô hình mạnh hơn, kỹ thuật đặc trưng

Thách Thức Cốt Lõi & Giải Pháp

Loại Thách Thức	Ví Dụ Điển Hình	Giải Pháp
Dữ liệu kém	Dữ liệu không đại diện, nhiều	Thu thập thêm dữ liệu, làm sạch dữ liệu
Thuật toán kém	Quá khớp	Đơn giản hóa mô hình, chỉnh quy hóa
	Dưới khớp	Chọn mô hình mạnh hơn, kỹ thuật đặc trưng

Toán Học & Công Cụ (Bổ trợ)

Vectơ & Ma Trận: Xương Sống Của ML

Vectơ



Vectơ đại diện cho các quan sát.

Ma Trận

	1	2	3	4
1	1	2	3	4
2	2	3	4	5
3	1	2	3	5

Ma trận giúp xử lý nhiều dữ liệu cùng lúc.

Thư Viện Scikit-Learn & NumPy



Các công cụ mã nguồn mở tối ưu để huấn luyện mô hình.



Các công cụ mã nguồn mở tối ưu để tính toán.


Mục tiêu bài học



Hiểu rõ định nghĩa và tầm quan trọng của Học máy (Machine Learning).



Phân biệt các hệ thống Học máy (Có giám sát, Không giám sát, Bán giám sát, Học tăng cường).



Nắm bắt quy trình phát triển một dự án Học máy thực tế.



Nhận diện các thách thức chính (Overfitting, Underfitting, Chất lượng dữ liệu).

1 Khái quát & Ứng dụng của Học máy

Đặt vấn đề: Bức tranh tổng quan

Học máy không còn là khoa học viễn tưởng, nó hiện diện trong hàng tỷ thiết bị mỗi ngày.

Thập niên 1990



Ứng dụng phổ biến đầu tiên là Bộ lọc thư rác (Spam filter).

Ngày nay



Lời nhắc bằng giọng nói, dịch tự động, tìm kiếm hình ảnh, đề xuất sản phẩm...

Câu hỏi đặt ra: Một cỗ máy học hỏi điều gì và học như thế nào?

Học máy là gì?



Định nghĩa 1 (Arthur Samuel, 1959)

Học máy là lĩnh vực nghiên cứu cung cấp cho máy tính khả năng học hỏi mà không cần được lập trình rõ ràng.




Định nghĩa 2 (Tom Mitchell, 1997)

Một chương trình máy tính được cho là học từ kinh nghiệm **E** đối với một nhiệm vụ **T** và một thước đo hiệu suất **P**, nếu hiệu suất của nó trên **T**, được đo bằng **P**, cải thiện theo kinh nghiệm **E**.

Cách tiếp cận truyền thống vs. Học máy




Truyền thống: Lập trình viên viết các quy tắc (rules) thủ công. Nếu vấn đề phức tạp, danh sách quy tắc sẽ dài bất tận và khó bảo trì.




Hình 1-1. Cách tiếp cận truyền thống

Cách tiếp cận bằng Học máy



Học máy: Hệ thống tự động học các quy tắc từ dữ liệu (data) và đáp án (answers). Mã nguồn ngắn hơn, dễ bảo trì hơn và độ chính xác thường cao hơn rất nhiều.




Hình 1-2. Phương pháp học máy

Tại sao sử dụng học máy?



Tự động thích ứng

Khi dữ liệu thay đổi (ví dụ: spammer dùng từ lóng mới), mô hình học máy tự động cập nhật mà không cần lập trình lại.



Giải quyết bài toán phức tạp


Những bài toán không có thuật toán truyền thống tối ưu (VD: nhận diện giọng nói).



Khám phá tri thức (Data Mining)


Tìm ra những quy luật ẩn giấu trong lượng dữ liệu khổng lồ.

Tự động thích ứng với thay đổi



Hình 1-3. Tự động thích ứng với dữ liệu mới

Học máy giúp con người học hỏi



Hình 1-4. Khai phá dữ liệu giúp con người tìm ra quy luật mới

Ví dụ về các ứng dụng (1/2)



Phân tích hình ảnh sản phẩm: Tự động phân loại sản phẩm trong quy trình sản xuất (Phân loại ảnh - CNN).



Phát hiện khối u não: Trích xuất thông tin từ ảnh y tế (Phân đoạn ảnh - Semantic Segmentation).



Phân loại bài viết/tin tức: Phân loại tự động các bài báo theo chủ đề (NLP - Phân loại văn bản).

Ví dụ về các ứng dụng (2/2)



Đánh dấu nhận xét tiêu cực: Phân tích cảm xúc từ phản hồi khách hàng ở diễn đàn.



Dự báo doanh thu: Xây dựng mô hình dự báo tài chính dựa trên dữ liệu hiệu suất quá khứ (Hồi quy - Regression).



Phát hiện gian lận thẻ tín dụng: Tìm ra các giao dịch bất thường (Phát hiện bất thường - Anomaly Detection).

Phân loại Hệ thống Học máy



Tiêu chí phân loại hệ thống học máy

Có ba tiêu chí chính để phân loại:



Pillar 1

1. Sự giám sát của con người

- Học có giám sát
- Không giám sát
- Bán giám sát
- Học tăng cường



Pillar 2

2. Khả năng học tăng dần

- Học trực tuyến (Online)
- Học theo lô (Batch)



Pillar 3


3. Cách tổng quát hóa

- Học dựa trên thực thể (Instance-based)
- Học dựa trên mô hình (Model-based)



Học có giám sát (Supervised Learning)

Dữ liệu huấn luyện cung cấp cho thuật toán bao gồm các giải pháp mong muốn, được gọi là **nhãn (labels)**. Ví dụ điển hình: Bộ lọc thư rác (Spam filter).




Hình 1-5. Bộ dữ liệu có nhãn cho học có giám sát

Phân loại (Classification) vs Hồi quy (Regression)



Phân loại: Dự đoán danh mục/lớp (Rác/Không rác).


Hồi quy: Dự đoán một giá trị mục tiêu (giá xe hơi) dựa trên các tập đặc trưng (đã đi bao nhiêu km, nhãn hiệu...).




Hình 1-6. Bài toán hồi quy (Regression)

Học không giám sát (Unsupervised Learning)

Dữ liệu huấn luyện **không được gán nhãn**. Hệ thống cố gắng học mà không cần người hướng dẫn. Dùng để tìm kiếm cấu trúc ẩn trong dữ liệu.




Hình 1-7. Tập dữ liệu không gán nhãn



Phân cụm (Clustering)

Tự động nhóm dữ liệu thành các cụm có chung đặc điểm.


Ví dụ: Gom cụm khách hàng trên trang web thành các phân khúc để chạy chiến dịch quảng cáo mục tiêu.



Hình 1-8. Phân cụm (Clustering)

Giảm chiều dữ liệu (Dimensionality Reduction)

Đơn giản hóa dữ liệu mà không làm mất quá nhiều thông tin. **Trích xuất đặc trưng:** Kết hợp nhiều đặc trưng tương quan thành 1 đặc trưng mới.



Hình 1-9. Giảm chiều (từ 3D xuống 2D)

Phát hiện bất thường (Anomaly Detection) & Luật kết hợp




Phát hiện gian lận thẻ tín dụng, lỗi sản xuất, xóa ngoại lai trước khi huấn luyện mô hình.




Luật kết hợp (Association Rule):

Tìm kiếm mối liên hệ (VD: Khách mua bím thường mua thêm bia).



Minh họa: Bất thường & Luật kết hợp


Hình 1-10. Phát hiện bất thường



Hình 1-10. Phát hiện bất thường

Học bán giám sát (Semi-supervised Learning)

Dữ liệu bao gồm rất nhiều mẫu chưa gán nhãn, và chỉ có một số ít mẫu được gán nhãn. Phổ biến trong nhận diện ảnh (Google Photos). Thuật toán (như DBNs) gộp các đặc điểm chung trước khi cần con người định danh 1 người cụ thể.



Hình 1-11. Học bán giám sát




Học tự giám sát (Self-supervised Learning)

Tạo ra tập dữ liệu có nhãn từ dữ liệu hoàn toàn không nhãn.

Ví dụ: Che một phần hình ảnh và yêu cầu mô hình khôi phục phần bị che.


Thường được dùng để tạo ra một mô hình cơ sở, sau đó tinh chỉnh (fine-tune) cho tác vụ cụ thể.



Hình 1-12. Ví dụ học tự giám sát


Học tăng cường (Reinforcement Learning)

Hệ thống (Agent) quan sát môi trường, thực hiện hành động và nhận về phần thưởng/hình phạt. Nó phải tự học ra chính sách (Policy) tốt nhất để tối đa hóa phần thưởng. (Ví dụ: AlphaGo).



Hình 1-13. Cơ chế Học tăng cường

Học theo lô vs Học trực tuyến (Batch vs Online)




Học theo lô (Batch): Huấn luyện một lần với toàn bộ dữ liệu. Tốn thời gian, tài nguyên. Nếu có dữ liệu mới phải huấn luyện lại từ đầu.




Học trực tuyến (Online): Huấn luyện theo từng phần dữ liệu nhỏ (mini-batches). Phù hợp với luồng dữ liệu liên tục (Chứng khoán, Thời tiết).

Minh họa: Học trực tuyến



Hình 1-14. Học trực tuyến

Học với tập dữ liệu khổng lồ (Out-of-core)




Hình 1-15. Học với tập dữ liệu khổng lồ (Out-of-core)



Học dựa trên thực thể (Instance-based Learning)

Hệ thống học bằng cách **ghi nhớ** các ví dụ. Khi có mẫu mới, nó so sánh độ tương đồng (Ví dụ: tính số lượng từ giống nhau) với các mẫu đã biết để đưa ra quyết định.




Hình 1-16. Học dựa trên thực thể

Học dựa trên mô hình (Model-based Learning)

Xây dựng một **mô hình** từ các ví dụ, sau đó dùng mô hình đó để dự đoán.


Ví dụ: Tìm ra hàm tuyến tính $y = ax + b$ phản ánh mối quan hệ giữa "GDP bình quân đầu người" và "Mức độ hài lòng với cuộc sống".




Hình 1-17. Học dựa trên mô hình

Mô hình phù hợp nhất & Hàm chi phí

Bằng cách định nghĩa **hàm chi phí (Cost Function)** và tối thiểu hóa nó, hệ thống thống sẽ tìm ra tham số tốt nhất cho mô hình.



Hình 1-20. Mô hình tuyến tính phù hợp nhất



Các mô hình tuyến tính với tham số khác nhau

3. Thách thức, Kiểm thử & Xác thực

3. Thách thức, Kiểm thử & Xác thực

Những thách thức chính của học máy: Mô hình 'Dữ liệu tồi' (Bad Data) hoặc 'Thuật toán tồi' (Bad Algorithm):



Dữ liệu huấn luyện không đủ lớn.



Dữ liệu huấn luyện không đại diện.



Dữ liệu chất lượng kém (nhiều, ngoại lai).



Đặc trưng không liên quan (Garbage in, garbage out).



Khớp quá mức (Overfitting) dữ liệu huấn luyện.




Chưa khớp (Underfitting) dữ liệu huấn luyện.

Dữ liệu huấn luyện không đủ (Dữ liệu tồi)



Máy tính cần hàng nghìn, thậm chí hàng triệu ví dụ mới có thể học được các tác vụ phức tạp (nhận dạng hình ảnh, xử lý ngôn ngữ).

Hiệu quả dữ liệu đôi khi còn quan trọng hơn cả thuật toán tính vi.




Hình 1-19. Tầm quan trọng của khối lượng dữ liệu (Nghiên cứu của Microsoft)

Dữ liệu huấn luyện không đại diện



- Để dự đoán tốt, dữ liệu phải đại diện cho các trường hợp mới mà mô hình sẽ gặp.
- Nếu dữ liệu bị thiên lệch, mô hình sẽ sai lầm (Lỗi lấy mẫu - Sampling bias).



Hình 1-20. Lỗi dự báo nếu bỏ qua một số quốc gia khỏi tập huấn luyện

Dữ liệu chất lượng kém



Chất lượng kém:
Nhiều lỗi, ngoại lai (outliers), giá trị nhiều.



- Cần tốn thời gian làm sạch (Data Cleaning).



- Hầu hết các Data Scientist dành phần lớn thời gian cho việc làm sạch dữ liệu.

Đặc trưng không liên quan



Đặc trưng không liên quan: Thuật toán học máy chỉ tốt khi thông tin nạp vào là hữu ích (Garbage In, Garbage Out).



Kỹ thuật đặc trưng (Feature Engineering):


- Lựa chọn đặc trưng (Feature Selection).
- Trích xuất đặc trưng (Feature Extraction).
- Tạo đặc trưng mới.

Overfitting (Khớp quá mức)

- Mô hình hoạt động tuyệt vời trên tập huấn luyện nhưng dự đoán cực kém với dữ liệu mới.
- Xảy ra khi mô hình quá phức tạp so với lượng dữ liệu, hoặc dữ liệu quá nhiễu.



- **Khắc phục:** Đơn giản hóa mô hình, thêm dữ liệu, giảm nhiễu, hoặc Dừng sớm.




Hình 1-22. Khớp quá mức (Overfitting) với mô hình đa thức phức tạp

Điều chuẩn (Regularization)

- Phương pháp ràng buộc mô hình để làm nó đơn giản hơn và giảm rủi ro Overfitting.

 - Hình bên cho thấy hiệu quả của Regularization: mô hình bớt cong vẹo và ít phụ thuộc vào nhiễu hơn.




Hình 1-23. Hiệu ứng của việc điều chuẩn để giảm Overfitting

Underfitting (Chưa khớp)

- Mô hình quá đơn giản, không đủ khả năng học các cấu trúc ẩn bên trong dữ liệu (Ví dụ: dùng mô hình tuyến tính cho dữ liệu phi tuyến).



- **Khắc phục:** Chọn mô hình phức tạp hơn, cung cấp đặc trưng tốt hơn, hoặc nới lỏng các ràng buộc (giảm Regularization).




Hình 1-24. Underfitting - Đường dự đoán bị lệch khỏi xu thế thực

Kiểm thử và xác thực (Testing and Validating)



- Để biết mô hình có tốt không, không thể chỉ đánh giá trên tập huấn luyện (vì có thể bị Overfitting).



Chia dữ liệu: Thường chia thành 80% **Tập huấn luyện (Training Set)** và 20% **Tập kiểm thử (Test Set)**.



Lỗi tổng quát hóa (Generalization Error): Tỷ lệ lỗi trên tập kiểm thử đại diện cho khả năng ứng dụng thực tế.

Tinh chỉnh mô hình và Tập xác thực (Validation Set)




- Nếu bạn dùng Test Set để tinh chỉnh tham số (Hyperparameters), mô hình sẽ “học vẹt” Test Set -> Lỗi dự báo khi thực tế đưa vào vẫn cao.



- **Giải pháp:** Tách riêng một phần dữ liệu huấn luyện thành **Tập xác thực (Validation Set)**.



- **Cross-Validation:** Giúp tối đa hóa hiệu năng khi dữ liệu bị hạn chế.



Hình 1-25. Kỹ thuật Cross-Validation

Sự không khớp dữ liệu (Data Mismatch) & Tập train-dev




- Xảy ra khi dữ liệu huấn luyện dồi dào nhưng không đại diện hoàn toàn cho thực tế (Ví dụ: ảnh tải từ web vs ảnh chụp thực tế bằng di động).



- **Giải pháp:** Giữ lại một phần dữ liệu huấn luyện thành **Tập train-dev**.

- Giúp phân biệt rõ mô hình bị **Overfitting** hay bị **Data Mismatch**.



Hình 1-26. Sử dụng tập train-dev để đánh giá

Không có bữa trưa miễn phí (No Free Lunch)



- “Không có mô hình học máy nào luôn luôn tốt nhất cho mọi loại dữ liệu” (Định lý Wolpert, 1996).



- **Đơn giản hóa** có nghĩa là mô hình phải loại bỏ các chi tiết thừa thãi.



- Nếu bạn hoàn toàn không biết gì về dữ liệu, không có lý do gì để ưu tiên mô hình này hơn mô hình khác.




- Cần đưa ra một số **giả định hợp lý** và **thử nghiệm** nhiều mô hình khác nhau.

Tổng kết Chương 1



- Học máy là việc làm cho máy tính thực hiện công việc dựa trên kinh nghiệm từ dữ liệu.



- Bao gồm nhiều loại (Supervised, Unsupervised, Reinforcement, Batch, Online, Instance, Model).



- Phụ thuộc vào chất lượng & số lượng dữ liệu.



- Luôn phải cân bằng giữa Overfitting và Underfitting.



- Phải đánh giá nghiêm ngặt bằng tập Train/Validation/Test.