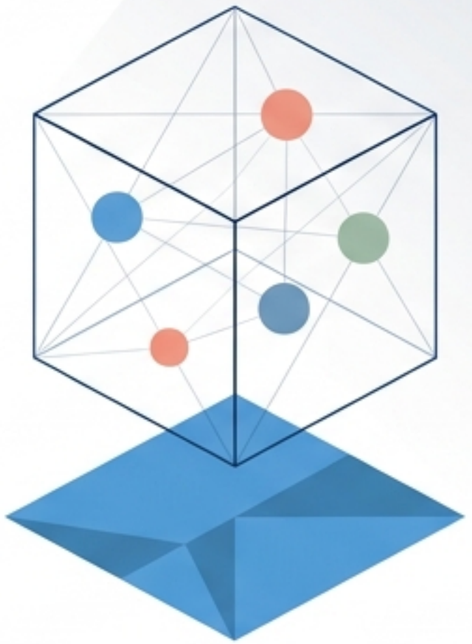


Chương 8: Giảm chiều dữ liệu (Dimensionality Reduction)

Mở khóa sức mạnh của dữ liệu bằng cách loại bỏ sự dư thừa.

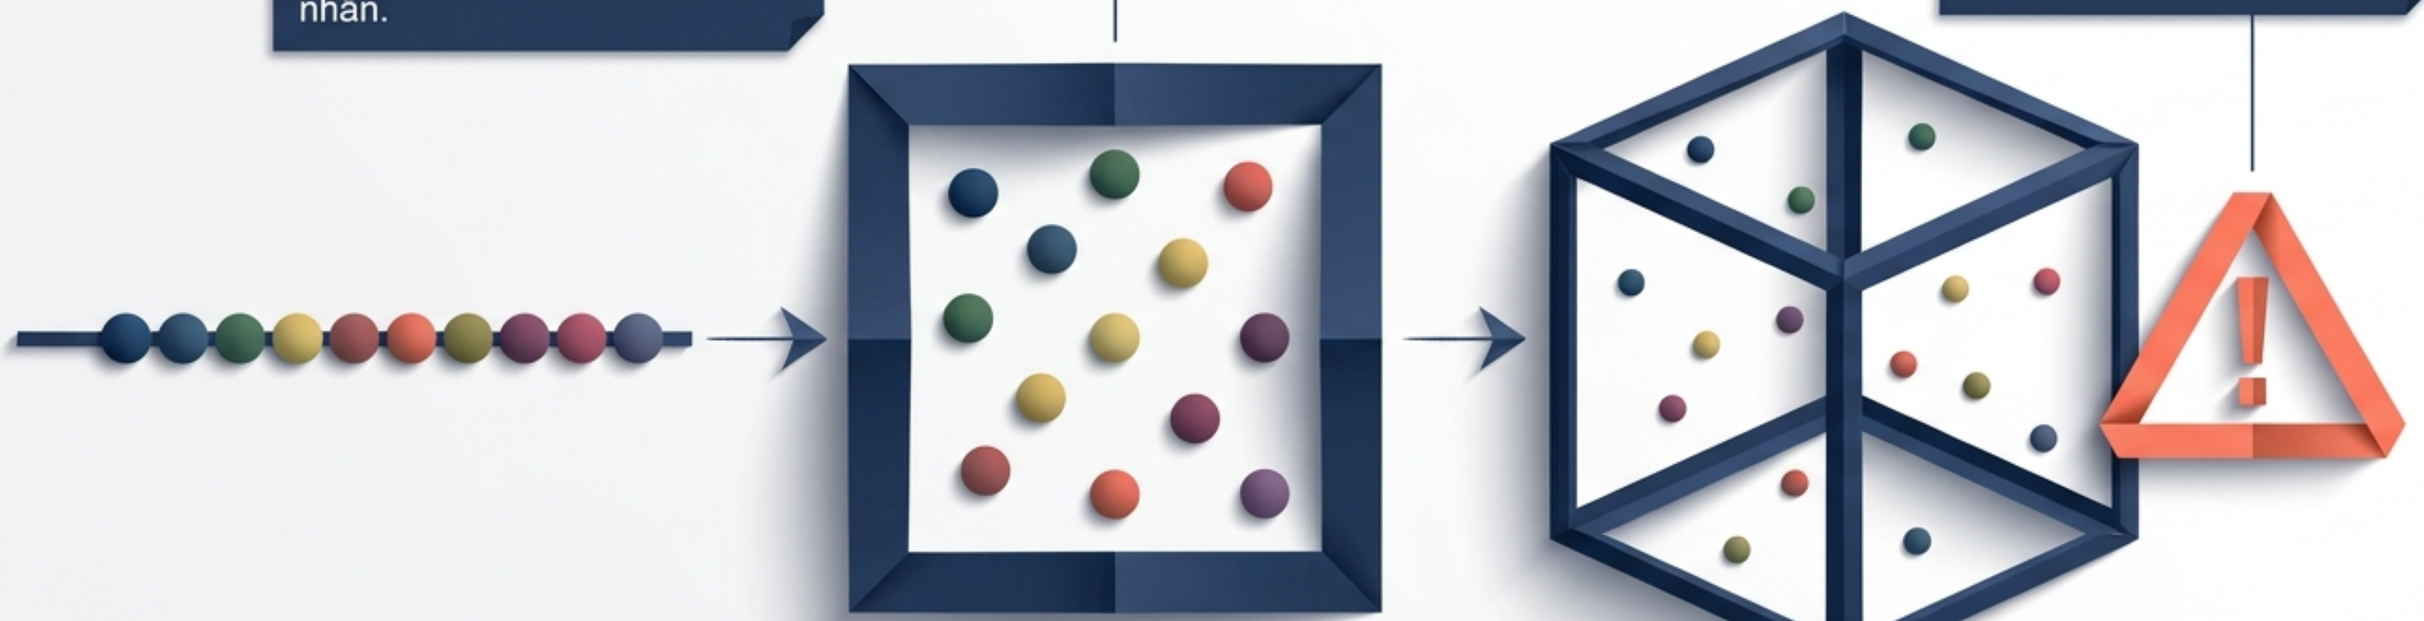
Giới thiệu bậc Đại học — Khái niệm, Thuật toán và Trực quan hóa hình học.

Gemini Notebook

Lời nguyền đa chiều làm tê liệt các mô hình học máy

Không gian thưa thớt: Hàng nghìn đặc trưng (như pixel ảnh) khiến các điểm dữ liệu cách xa nhau theo cấp số nhân.

Huấn luyện rùa bò: Khối lượng tính toán khổng lồ vắt kiệt tài nguyên và thời gian xử lý.



Nguy cơ Quá khớp (Overfitting): Do thưa thớt, mô hình dễ dàng học vẹt các nhiễu cục bộ thay vì tìm ra quy luật thực sự.

Gemini Notebook

Ba mục tiêu cốt lõi của kỹ thuật giảm chiều



Tăng tốc huấn luyện

Cắt bỏ triệt để các đặc trưng dư thừa và thông tin nhiễu không quan trọng để thuật toán chạy nhanh hơn.



Trực quan hóa dữ liệu

Kéo dữ liệu phức tạp về không gian 2D hoặc 3D để con người dễ dàng quan sát các mẫu và cụm bằng mắt thường.

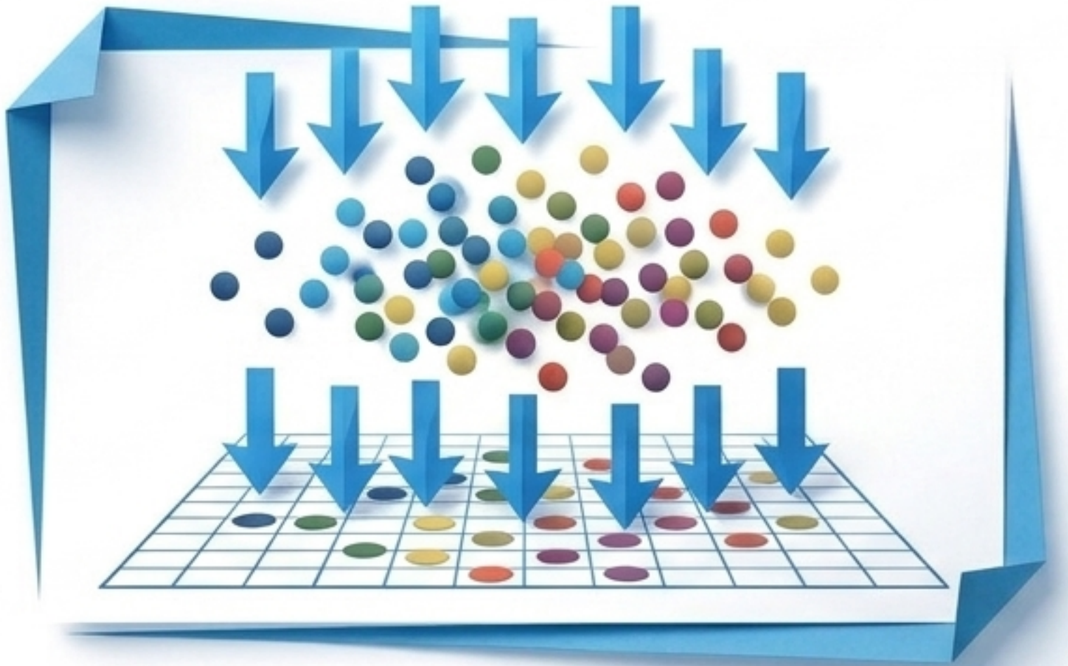


Nén dữ liệu

Tiết kiệm đáng kể dung lượng bộ nhớ lưu trữ mà vẫn bảo toàn phần lớn thông tin cốt lõi.

Gemini Notebook

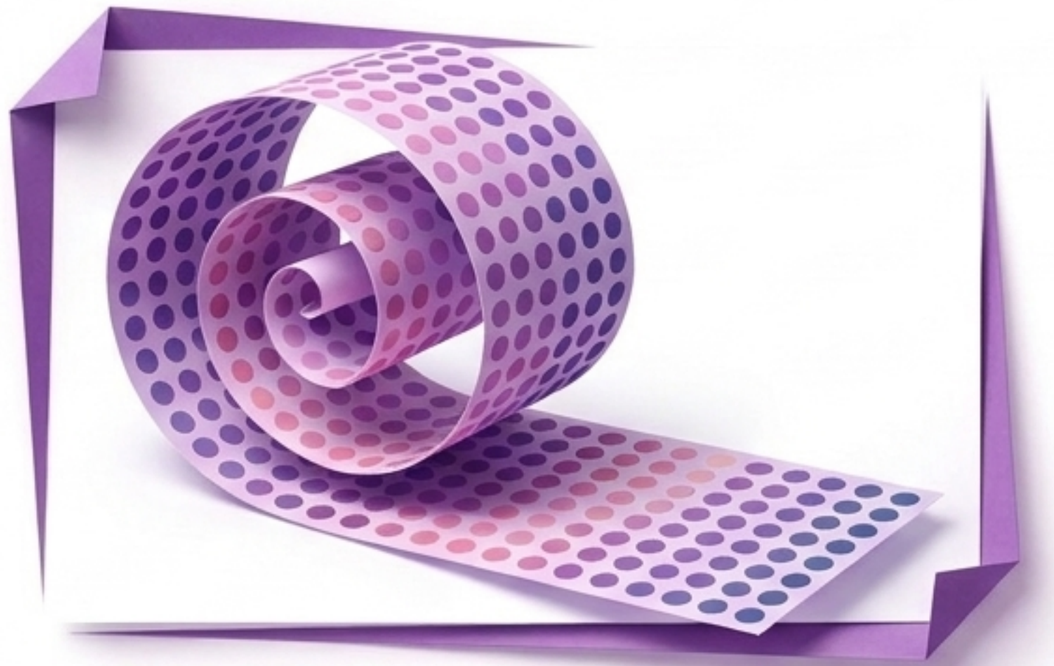
Hai trường phái tiếp cận cơ bản



Phép chiếu (Projection)

Chiếu vuông góc các điểm dữ liệu từ không gian cao xuống không gian con (subspace) thấp hơn.

Hạn chế: Thất bại hoàn toàn nếu dữ liệu bị vặn xoắn hoặc uốn cong phức tạp.



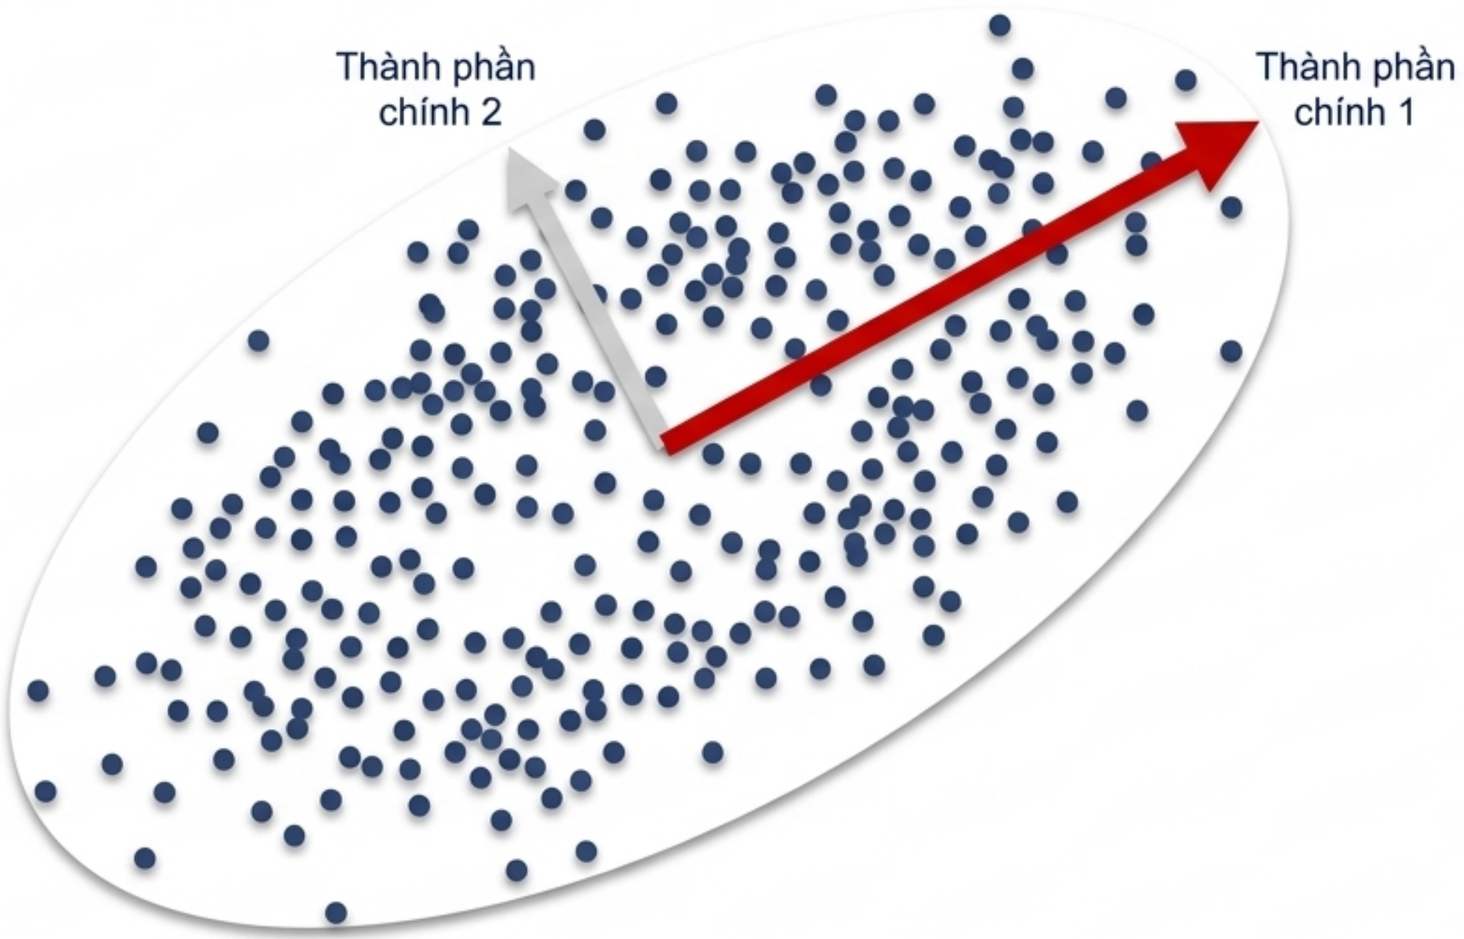
Học đa tạp (Manifold Learning)

Dựa trên Giả định đa tạp (Manifold Hypothesis).

Cơ chế: Dữ liệu chiều cao thực chất là một mặt phẳng chiều thấp bị uốn cong. Thuật toán tìm cách "mở cuộn" đa tạp này thay vì làm bẹp nó.

Gemini Notebook

Phân tích Thành phần chính (PCA): Trái tim của Phép chiếu



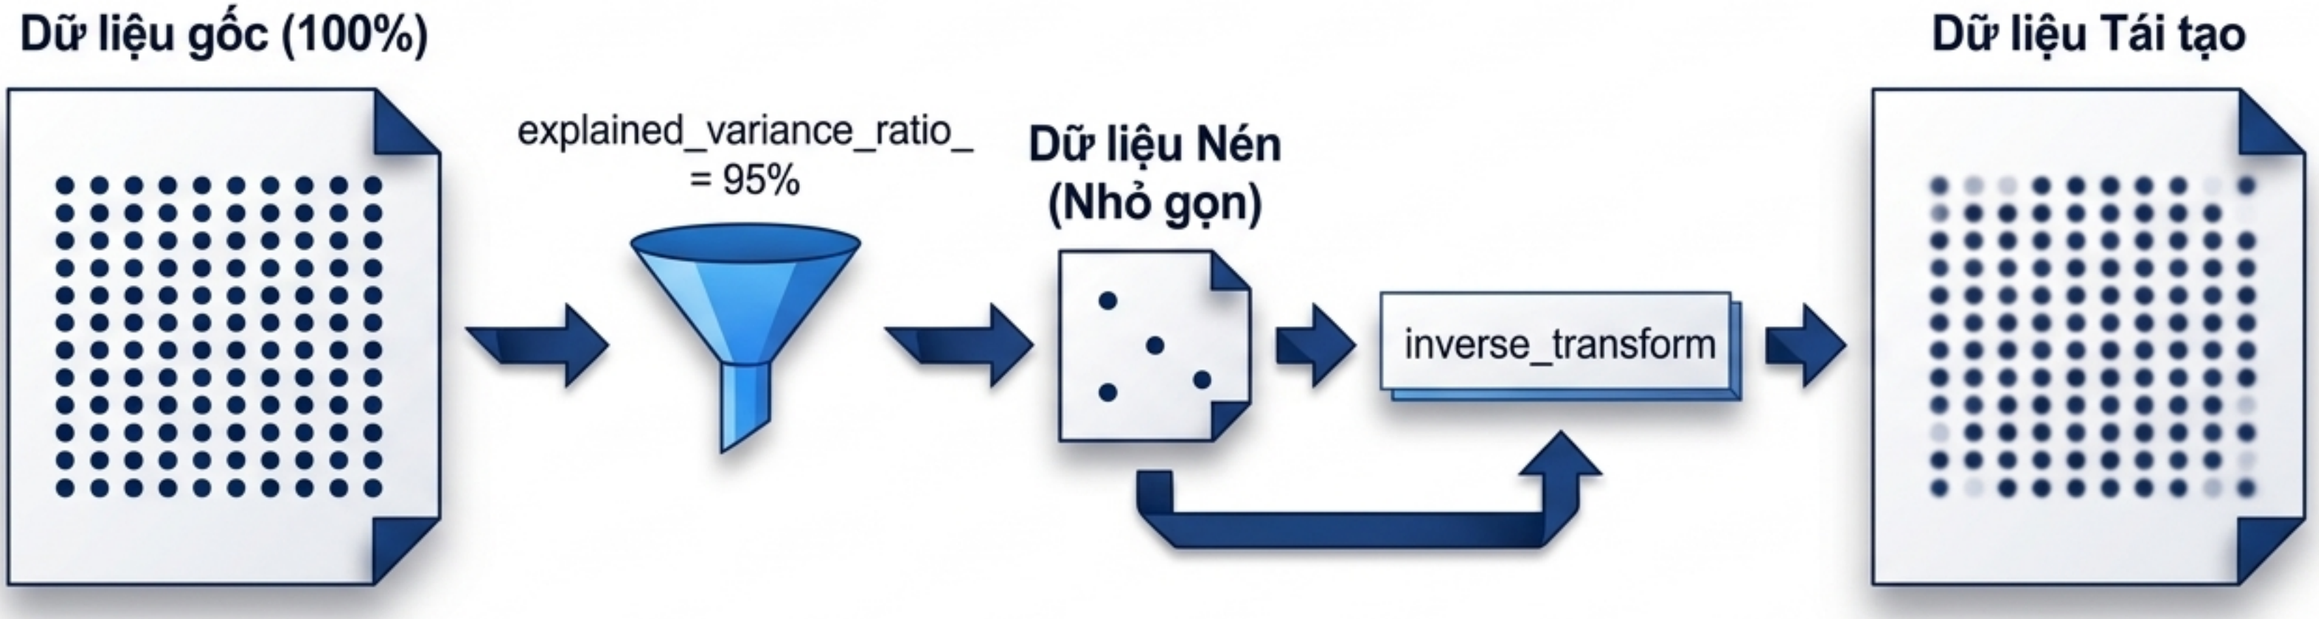
Bảo toàn phương sai tối đa:
Tìm siêu phẳng (hyperplane) mà khi chiếu dữ liệu xuống, sự phân tán của dữ liệu (phương sai) được giữ lại nhiều nhất.

Khoảng cách tối thiểu:
Tương đương với việc giảm thiểu khoảng cách bình phương trung bình từ điểm gốc tới mặt chiếu.

Vận hành dựa trên kỹ thuật Phân tách giá trị số ít (SVD) trên ma trận dữ liệu đã được căn giữa.

Gemini Notebook

PCA trong thực chiến: Nén và Khôi phục



Tỷ lệ phương sai giải thích

Sử dụng thuộc tính explained_variance_ratio_ để đo lượng thông tin mỗi thành phần nắm giữ. Không cần đoán số chiều; hãy chọn mức phương sai mục tiêu (ví dụ: giữ lại 95%).

Sai số tái tạo (Reconstruction Error)

Hàm inverse_transform cho phép khôi phục dữ liệu nén về không gian gốc. Khoảng cách giữa dữ liệu gốc và dữ liệu tái tái tạo chính là thước đo độ mất mát thông tin.

Gemini Notebook

Lựa chọn biến thể PCA theo bài toán phần cứng



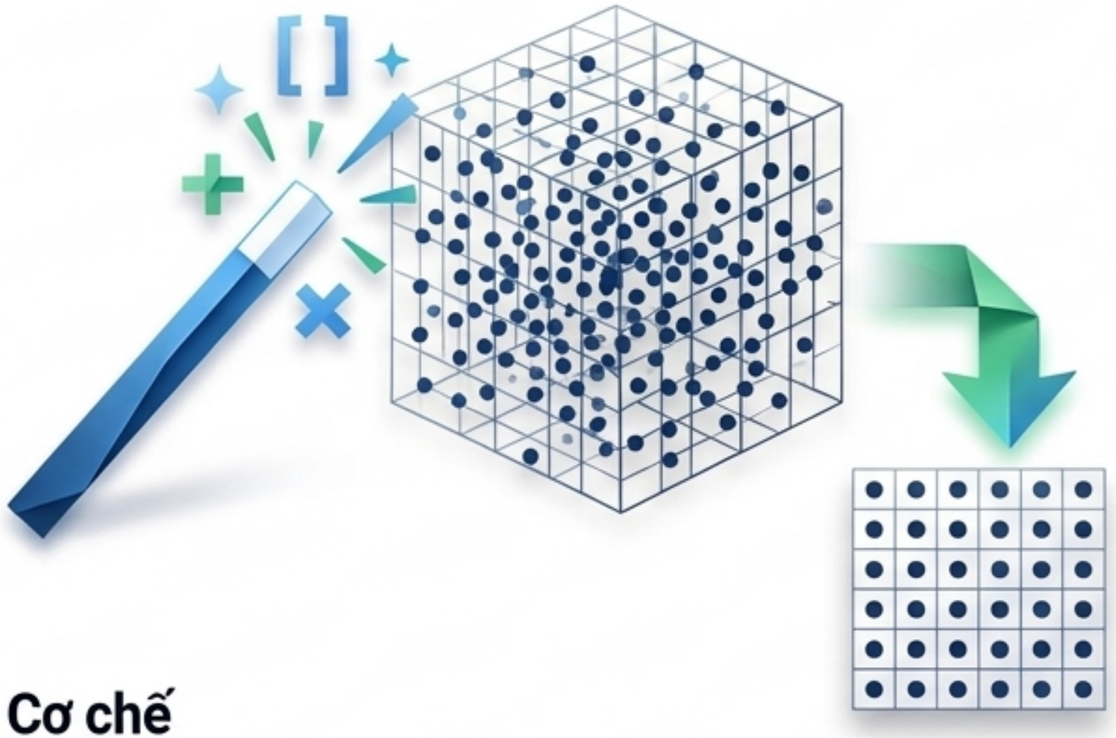




	Standard PCA	Randomized PCA	Incremental PCA (IPCA)
Use Case	Dữ liệu kích thước vừa và nhỏ. Vừa vặn trong bộ nhớ RAM.	Khi số chiều mục tiêu d nhỏ hơn rất nhiều so với số chiều ban đầu n ($d \ll n$).	"Big Data" khổng lồ không nằm gọn trong bộ nhớ RAM (Out-of-core).
Advantage /Math	Tính toán thuật toán SVD chính xác trên toàn bộ ma trận.	Dùng thuật toán ngẫu nhiên để xấp xỉ nhanh các thành phần chính. Tốc độ vượt trội.	Chia nhỏ dữ liệu thành các mini-batch. Kết hợp hoàn hảo với partial_fit hoặc np.memmap.

Gemini Notebook

Phép chiếu ngẫu nhiên: Giảm chiều không cần huấn luyện



Định lý Johnson-Lindenstrauss (JL)

Bảo chứng toán học: phép chiếu ngẫu nhiên vẫn bảo toàn khoảng cách giữa các điểm dữ liệu với xác suất rất cao.

Cơ chế

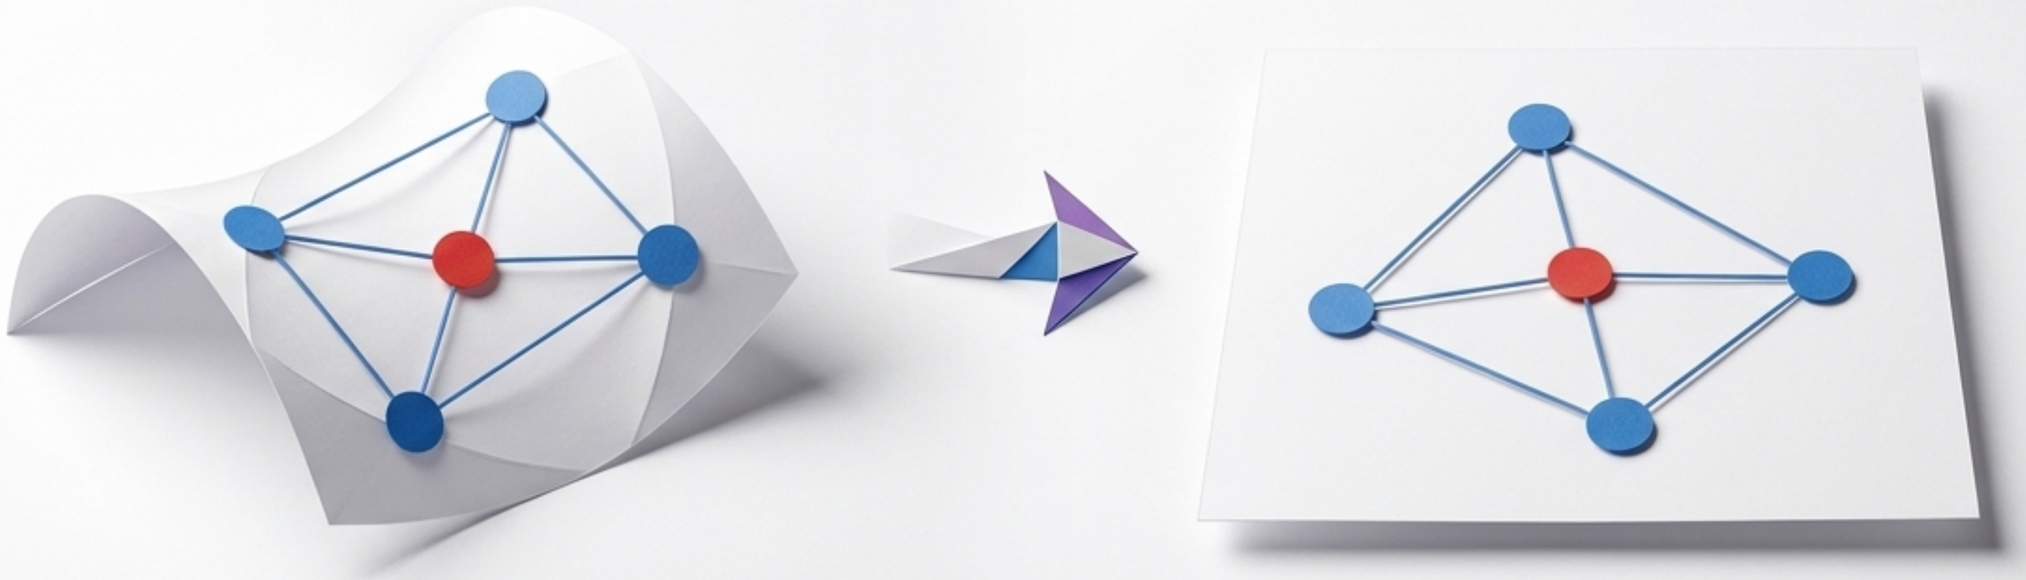
Khác với PCA, thuật toán chiếu dữ liệu xuống không gian chiều thấp bằng một ma trận tuyến tính ngẫu nhiên. Bỏ qua hoàn toàn bước huấn luyện (training phase).

Thực thi Scikit-Learn

Gaussian: Chiếu ngẫu nhiên tiêu chuẩn.
Sparse: Sử dụng ma trận thưa, giúp tiết kiệm bộ nhớ RAM tối đa và tính toán nhanh hơn nhiều lần.

Gemini Notebook

LLE (Nhúng tuyến tính cục bộ): Giải mã đa tạp xoắn xoắn



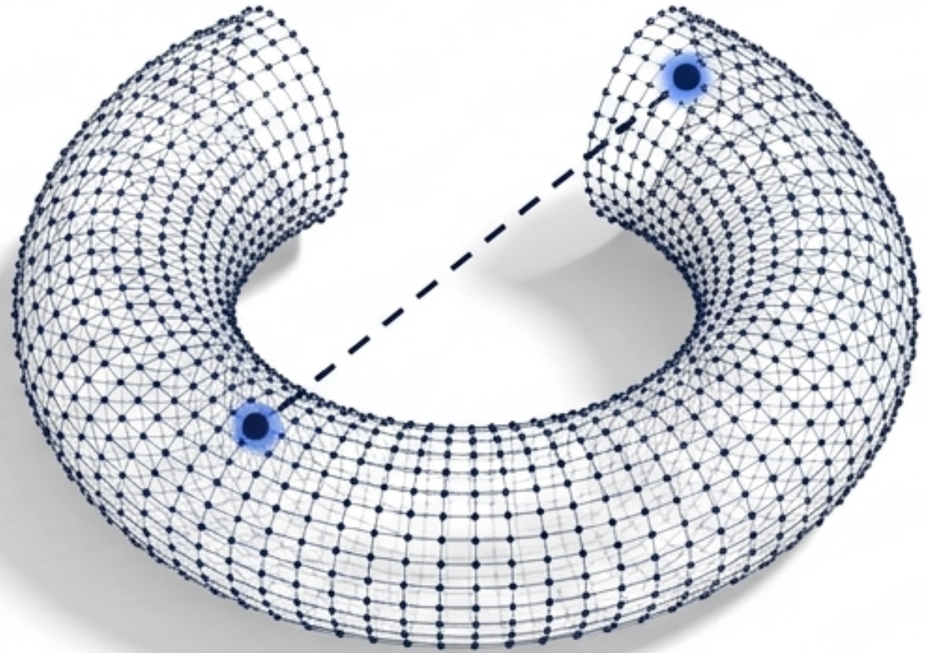
LLE là bậc thầy của Học đa tạp phi tuyến tính. Không dùng phép chiếu vuông góc, LLE tìm cách "mở cuộn" các cấu trúc cuộn xoắn.

1. **Đo lường cục bộ:** Tính toán mối quan hệ tuyến tính giữa mỗi điểm và k láng giềng gần nhất của nó.
2. **Ánh xạ:** Nhấc các điểm sang không gian d-chiều mới sao cho các mối quan hệ láng giềng cục bộ này được bảo toàn nguyên vẹn nhất có thể.

Hạn chế: Mở rộng rất kém đối với các tập dữ liệu cực lớn do độ phức tạp thuật toán cao.

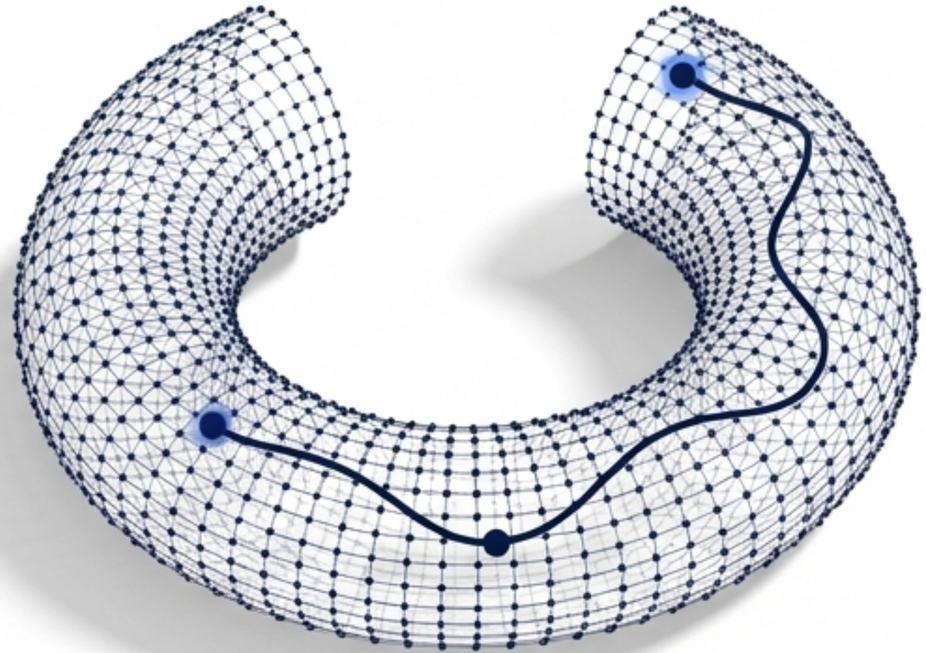
Gemini Notebook

Mở rộng không gian: Khoảng cách Vật lý vs. Khoảng cách Trắc địa



MDS (Multidimensional Scaling)

Mục tiêu: Cố gắng bảo toàn khoảng cách vật lý ban đầu (đường thẳng xuyên không gian) giữa các điểm dữ liệu khi chuyển sang không gian mới.



Isomap

Mục tiêu: Tạo ra một đồ thị láng giềng và bảo toàn khoảng cách trắc địa (geodesic distance). Đo lường quãng đường ngắn nhất đi dọc theo bề mặt của đa tạp dữ liệu.

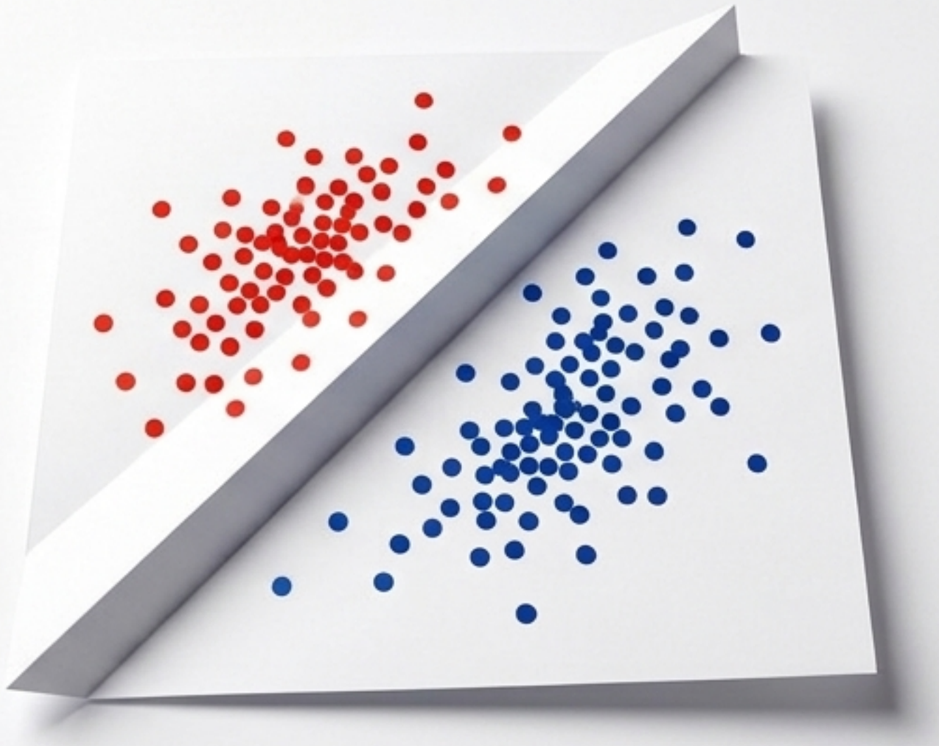
Gemini Notebook

Kỹ thuật chuyên biệt: Trực quan hóa và Phân loại



t-SNE (t-distributed Stochastic Neighbor Embedding)

- **Cơ chế:** Giữ các điểm tương đồng ở gần nhau, đồng thời đẩy lùi các điểm khác biệt ra xa.
- **Sức mạnh:** Thuật toán vô địch trong việc trực quan hóa các cụm dữ liệu phức tạp trong không gian 2D/3D.

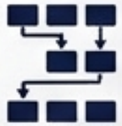
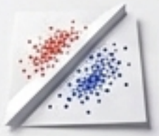


LDA (Linear Discriminant Analysis)

- **Cơ chế:** Khác với các thuật toán trên, LDA là kỹ thuật có giám sát (supervised).
- **Sức mạnh:** Tìm các trục không gian mới giúp phân biệt và chia cắt rõ ràng nhất giữa các lớp (classes) dữ liệu đã được dán nhãn.

Gemini Notebook

Tổng hợp: Ma trận lựa chọn thuật toán

Thuật toán	Đặc điểm	Ứng dụng lý tưởng
Standard / Random PCA 	Tuyến tính, tính toán cực nhanh.	Nén dữ liệu tổng quát, giảm nhiễu nền tảng. 
Incremental PCA (IPCA) 	Xử lý theo từng mini-batch.	Big Data khổng lồ vượt quá dung lượng RAM. 
Random Projection 	Không cần huấn luyện, dựa trên định lý JL.	Dữ liệu chiều cực lớn cần tốc độ xấp xỉ tức thì. 
LLE / Isomap 	Học đa tạp phi tuyến tính, bảo toàn láng giềng.	Dữ liệu bị vặn xoắn (Swiss roll), quy mô vừa và nhỏ. 
t-SNE 	Tách cụm phi tuyến tính cực mạnh.	Dành riêng cho trực quan hóa cụm dữ liệu 2D/3D. 
LDA 	Kỹ thuật giảm chiều có giám sát.	Tối ưu hóa không gian trước khi đưa vào mô hình phân loại. 

Gemini Notebook

Thử thách Thực hành: Sức mạnh của Code

Lý thuyết đã nắm vững. Giờ là lúc kiểm chứng trên dữ liệu thực tế!





Viết một đoạn mã Python ngắn để so sánh hiệu năng của PCA và t-SNE khi giảm chiều tập dữ liệu ảnh chữ số viết tay MNIST.

- Thuật toán nào vẽ ra các cụm số từ 0-9 tách biệt và rõ ràng hơn bằng mắt thường?
- Thuật toán nào chạy xong trong chớp mắt, và thuật toán nào bắt bạn phải chờ đợi?

Mở Jupyter Notebook của bạn và bắt đầu "mở cuộn" dữ liệu.

Gemini Notebook