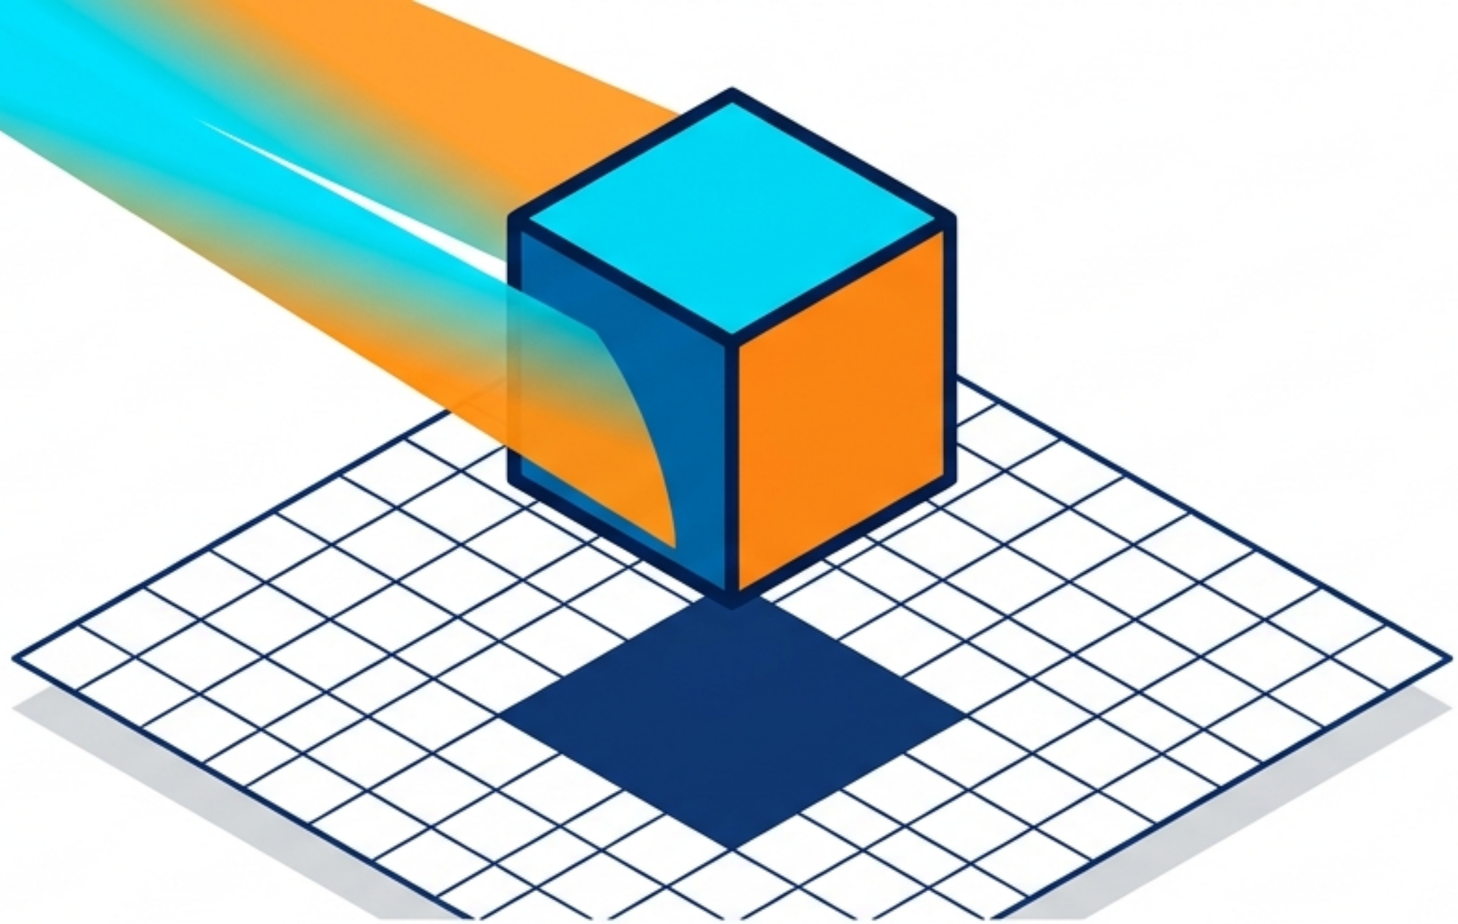


Phân Tích Thành Phần Chính (PCA) & Các Biến Thể

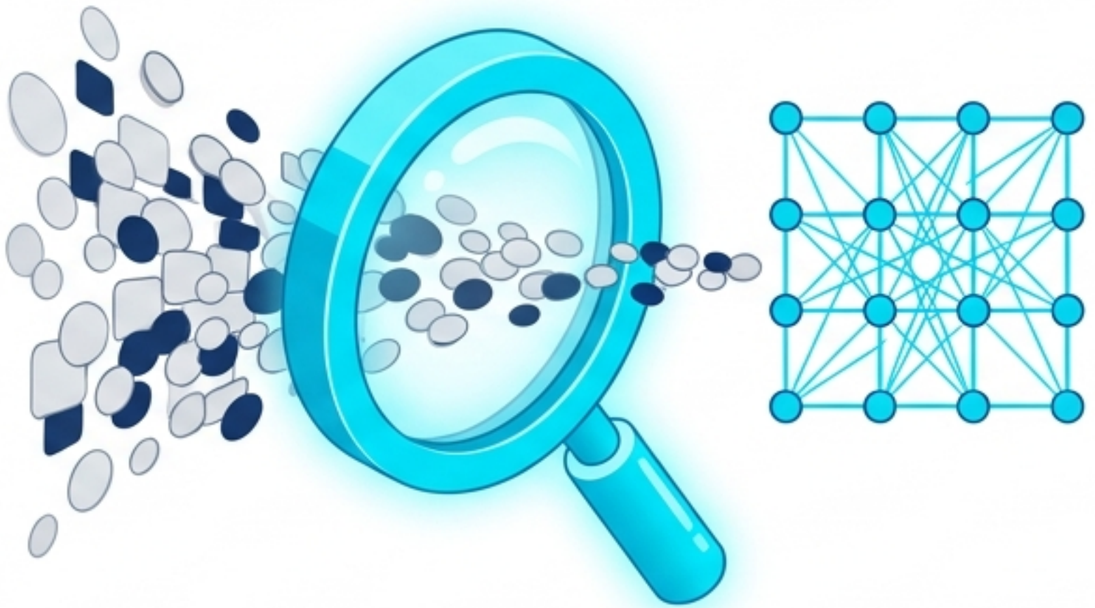
Làm chủ nghệ thuật giảm chiều dữ liệu và bảo toàn thông tin.

Tài liệu bài giảng đại học | Chương 8 - Phần 2

Gemini Notebook

Gánh nặng của dữ liệu đa chiều





Vấn đề: Các tập dữ liệu hiện đại có hàng ngàn đặc trưng (chiều). Điều này gây cạn kiệt bộ nhớ RAM và làm chậm quá trình huấn luyện mô hình học máy một cách nghiêm trọng.

Thách thức: Làm sao để nén dữ liệu, giảm thiểu không gian lưu trữ mà không làm mất đi bức tranh toàn cảnh và các thông tin quan trọng nhất?

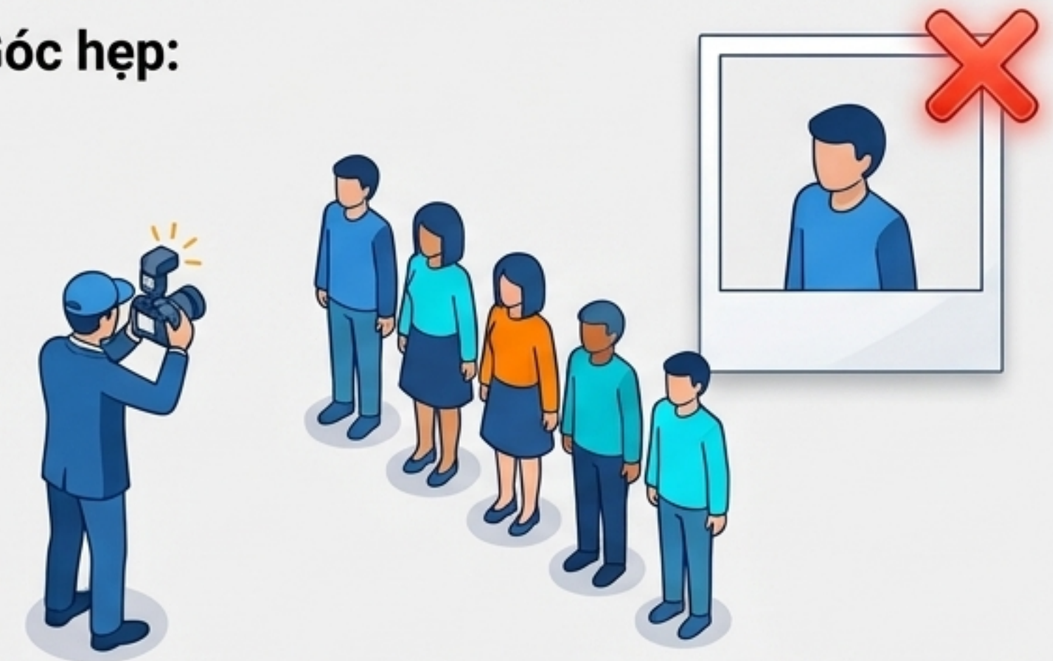
Giải pháp tối ưu chính là Phân tích thành phần chính (PCA).

Gemini Notebook

Trực giác về PCA: Đi tìm "Góc chụp" hoàn hảo

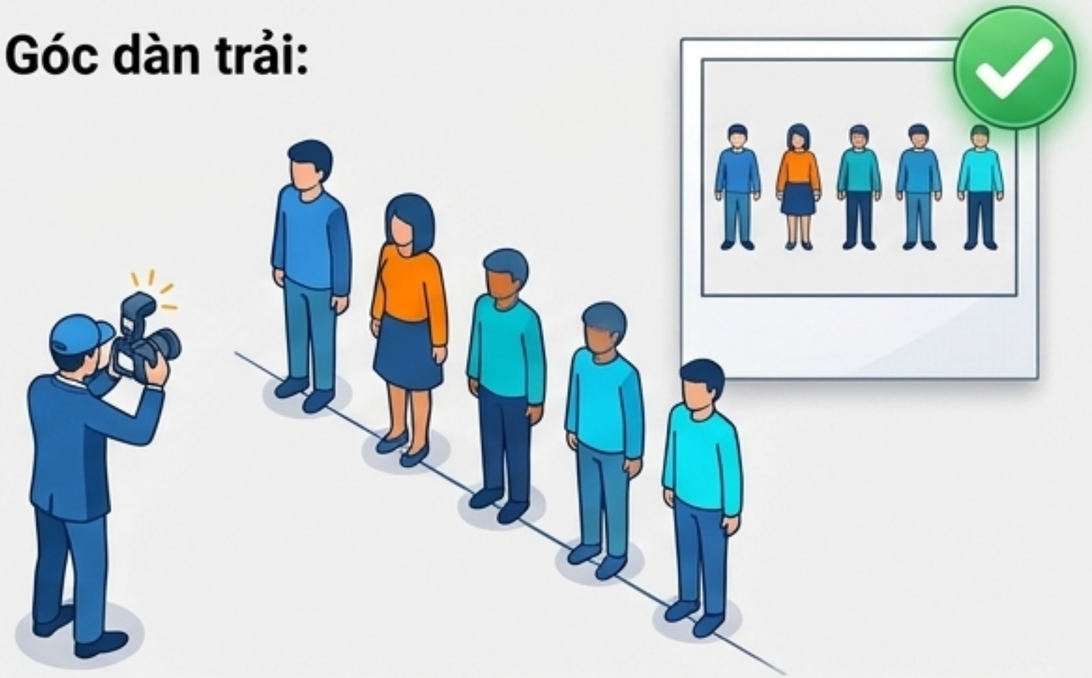
Bản chất của PCA giống như việc bạn chọn góc chụp ảnh cho một đám đông.

Góc hẹp:



Các điểm dữ liệu đè lên nhau. Thông tin bị mất.

Góc dàn trải:



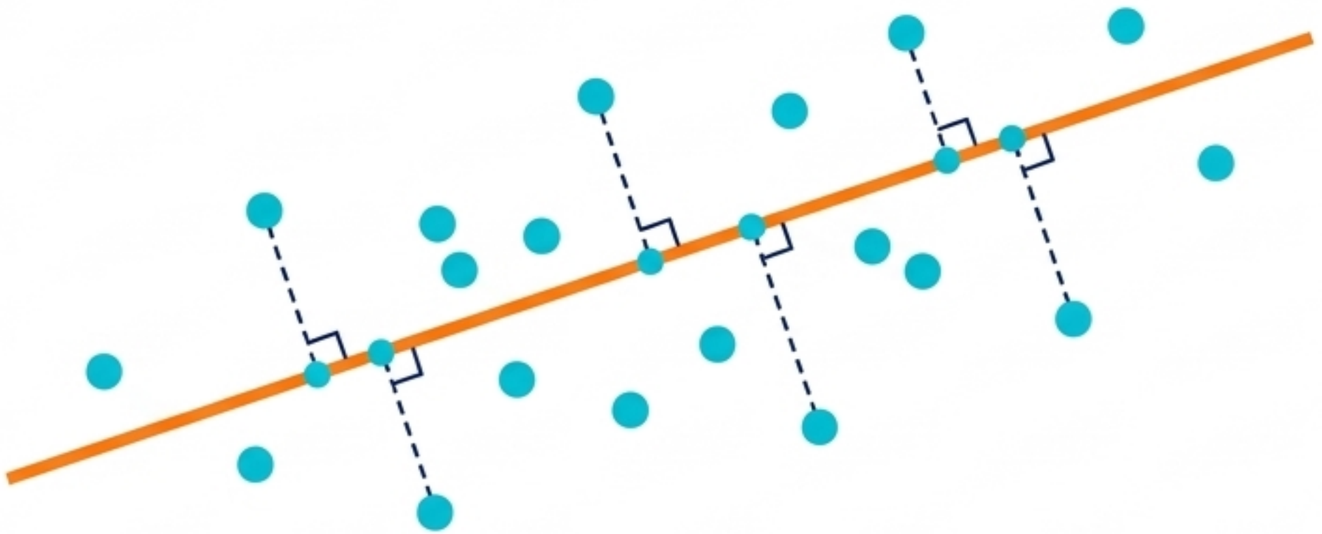
Tìm trục nhìn sao cho dữ liệu phân tán rộng nhất.

Nguyên lý cốt lõi: PCA luôn tìm đường/trục sao cho dữ liệu chiếu lên đó có độ dàn trải nhiều nhất (phương sai lớn nhất).

Gemini Notebook

Hai mặt của một nguyên lý hình học

Việc chọn trục bảo toàn phương sai thực chất là giải quyết bài toán tối ưu hình học. Hai nhận định sau là hoàn toàn tương đương:



1. Tối đa hóa phương sai

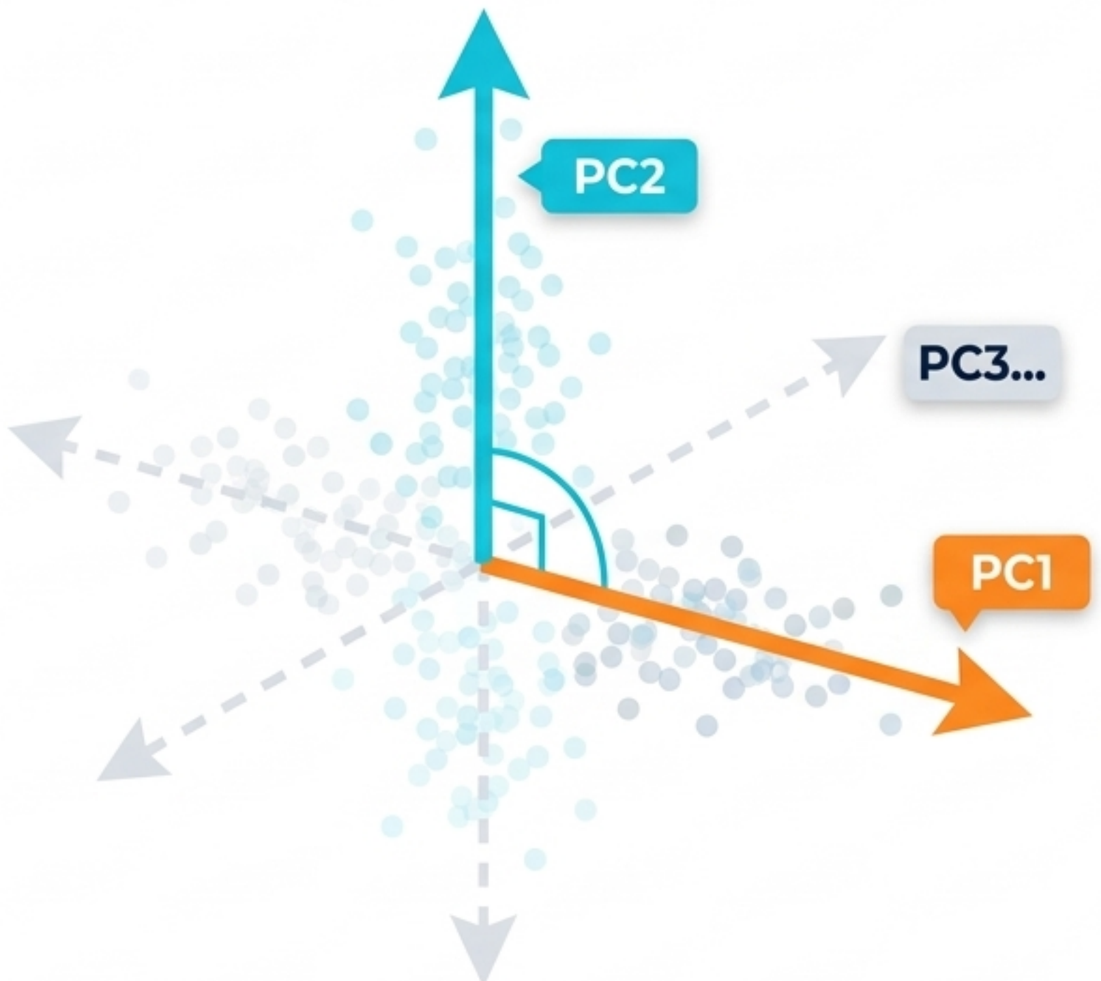
Khi chiếu các điểm dữ liệu lên trục (đường màu cam), khoảng cách giữa các điểm chiếu là lớn nhất.

2. Tối thiểu hóa sai số

Tổng khoảng cách bình phương (đường nét đứt) từ điểm gốc đến điểm chiếu của chúng trên trục là nhỏ nhất. (Sai số chiếu nhỏ nhất).

Gemini Notebook

Định nghĩa các Thành phần chính (Principal Components)



PC1 (Trục thứ nhất): Là trục chứa lượng phương sai (thông tin) lớn nhất của toàn bộ tập dữ liệu.

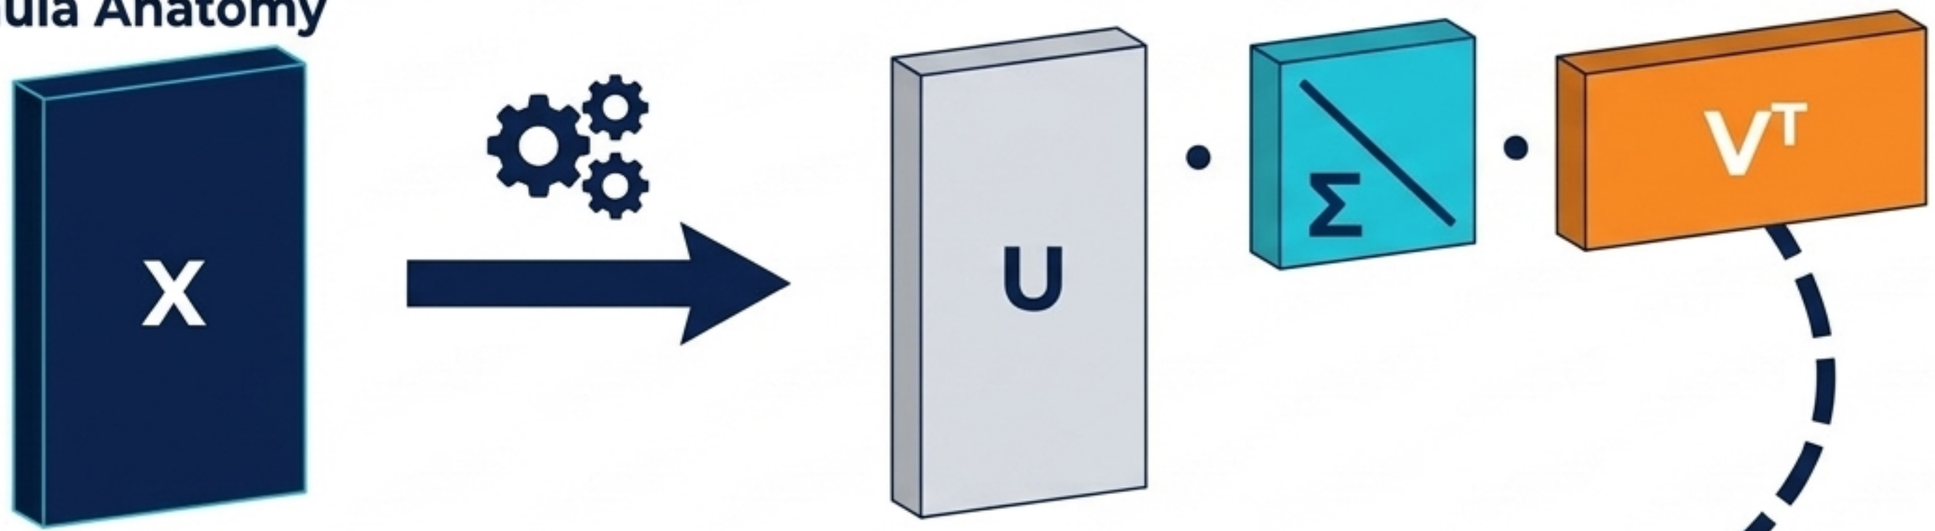
PC2 (Trục thứ hai): Bắt buộc phải trực giao (vuông góc) với PC1. Nó chứa phần lớn phương sai còn sót lại.

PC3... PCn: Quá trình tiếp tục tìm các trục vuông góc với các trục trước đó, cho đến khi số lượng trục bằng với số chiều ban đầu của dữ liệu.

Gemini Notebook

Nền tảng Toán học: Phân tách SVD

Formula Anatomy



1. Chuẩn hóa trung tâm (Mean-Centering)

Bắt buộc dời tâm dữ liệu về gốc tọa độ bằng phép tính: **X - X.mean(axis=0)**.

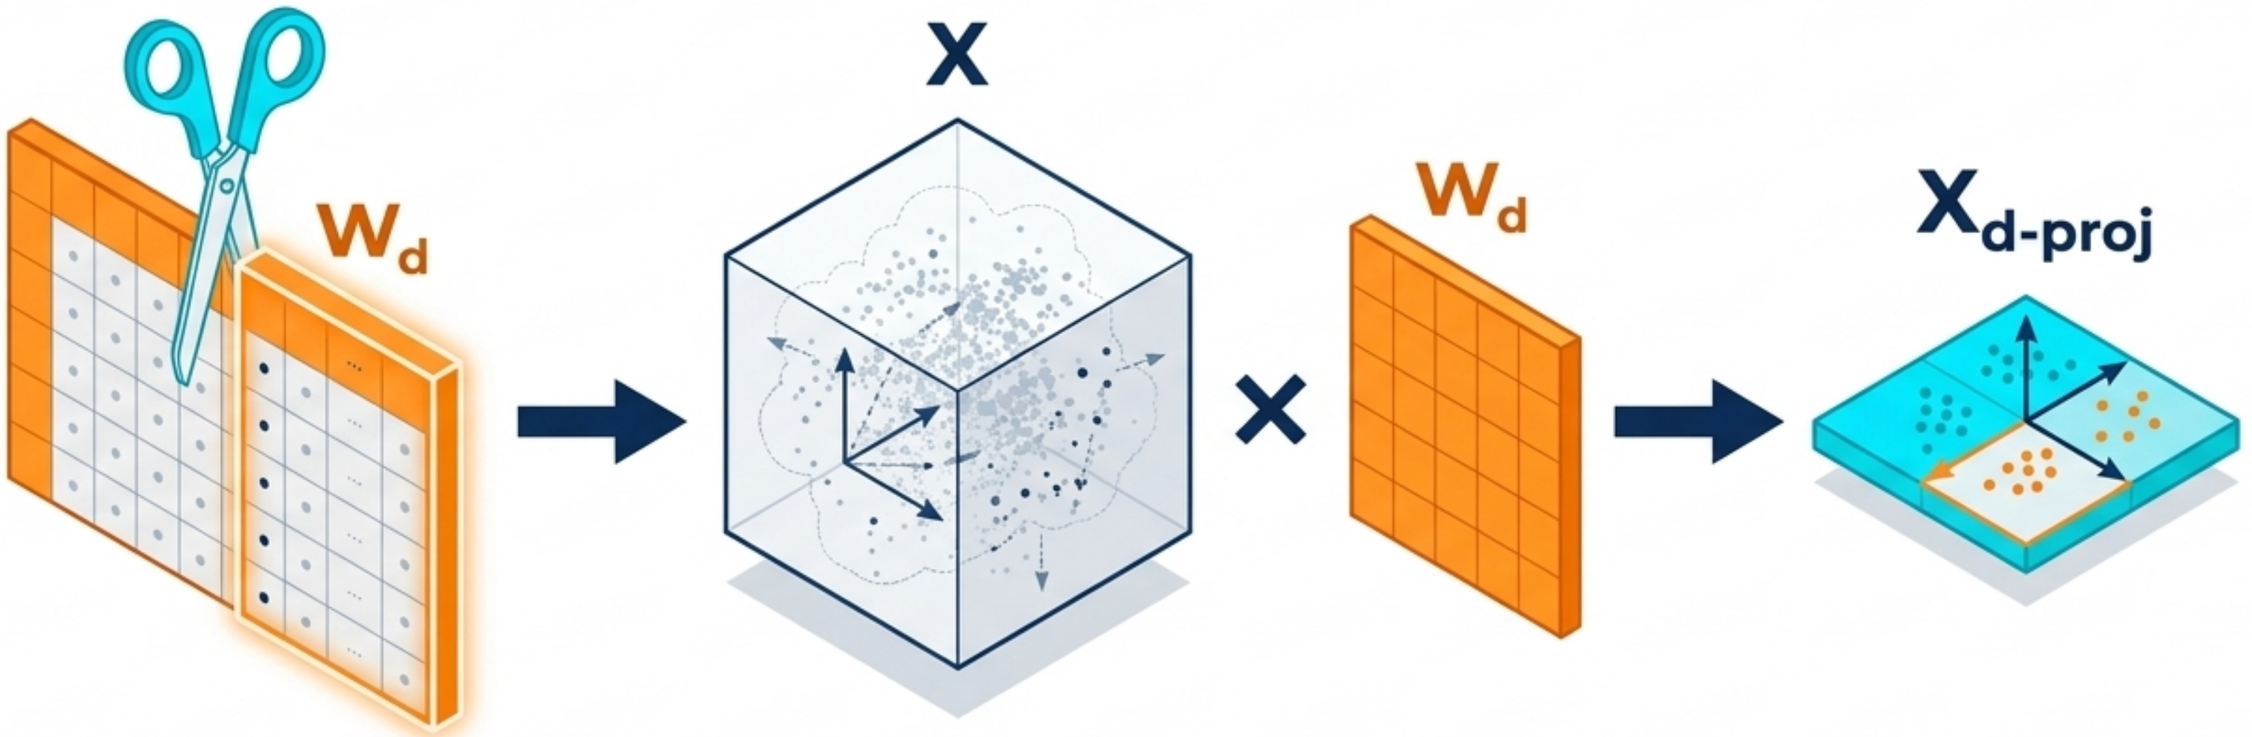
2. Phân tách SVD

Thuật toán SVD phân tách ma trận. Ma trận **VT** chứa tất cả các vector đơn vị định nghĩa nên các thành phần chính (PC).

Lưu ý: Lớp PCA của Scikit-Learn tự động xử lý toàn bộ bước chuẩn hóa và phân tách SVD này!

Gemini Notebook

Quá trình Hạ chiều (Phép chiếu)



1. Khi quyết định giảm xuống d chiều, trích xuất d cột đầu tiên của ma trận V để tạo thành ma trận trọng số W_d.

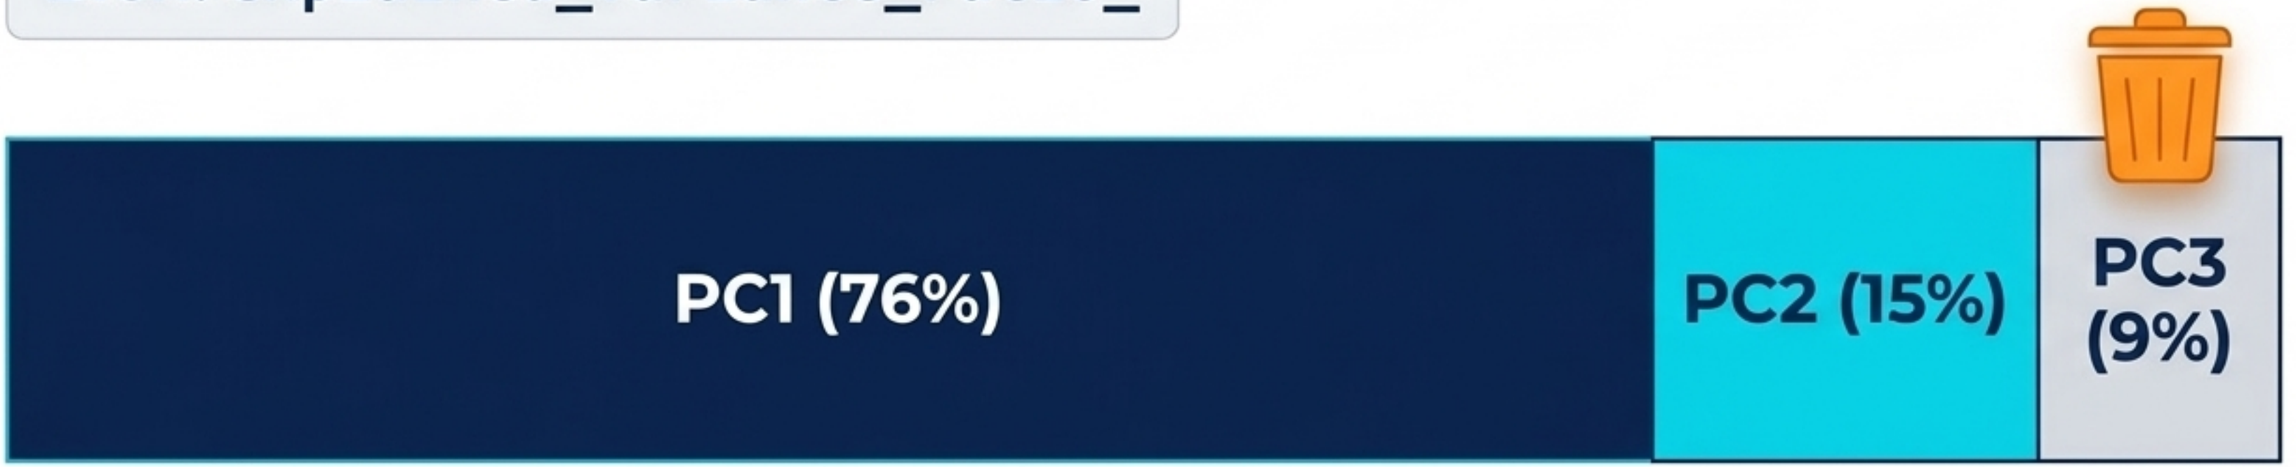
$$X_{d\text{-}proj} = X \cdot W_d$$

2. Kết quả là tập dữ liệu mới, mang lượng thông tin cốt lõi nhưng có kích thước nhỏ gọn hơn rất nhiều.

Gemini Notebook

Đo lường hiệu quả: Tỷ lệ phương sai giải thích

Biến: `explained_variance_ratio_`



Ý nghĩa:

Đo lường tỷ lệ phần trăm lượng thông tin (phương sai) mà mỗi thành phần chính đang nắm giữ.

Ví dụ minh họa:

Kết luận từ biểu đồ:

- PC1 + PC2 giữ tổng cộng 91% thông tin gốc.
- PC3 chỉ giữ 9% thông tin.
- Ta có thể yên tâm loại bỏ PC3 mà không làm sai lệch đáng kể cấu trúc dữ liệu.

Gemini Notebook

Chiến lược chọn số chiều (d) tối ưu

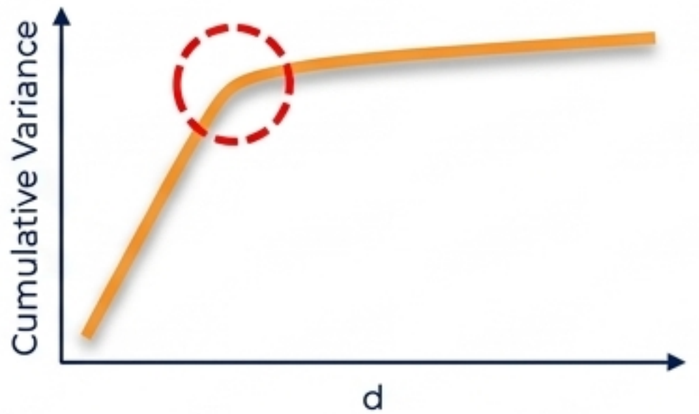


Cách 1: Khai báo tỷ lệ mục tiêu

Thay vì đoán mò số d, hãy truyền trực tiếp mức phương sai mong muốn vào Scikit-Learn.

```
PCA(n_components=0.95)
```

Hệ thống sẽ tự động tính toán số chiều tối thiểu cần thiết để giữ được 95% thông tin.



Cách 2: Tìm điểm uốn (Elbow point)

Vẽ biểu đồ phương sai tích lũy.

Chọn d tại Điểm uốn — vị trí mà đường cong bắt đầu đi ngang.

Thêm chiều sau điểm này không mang lại nhiều giá trị thông tin.

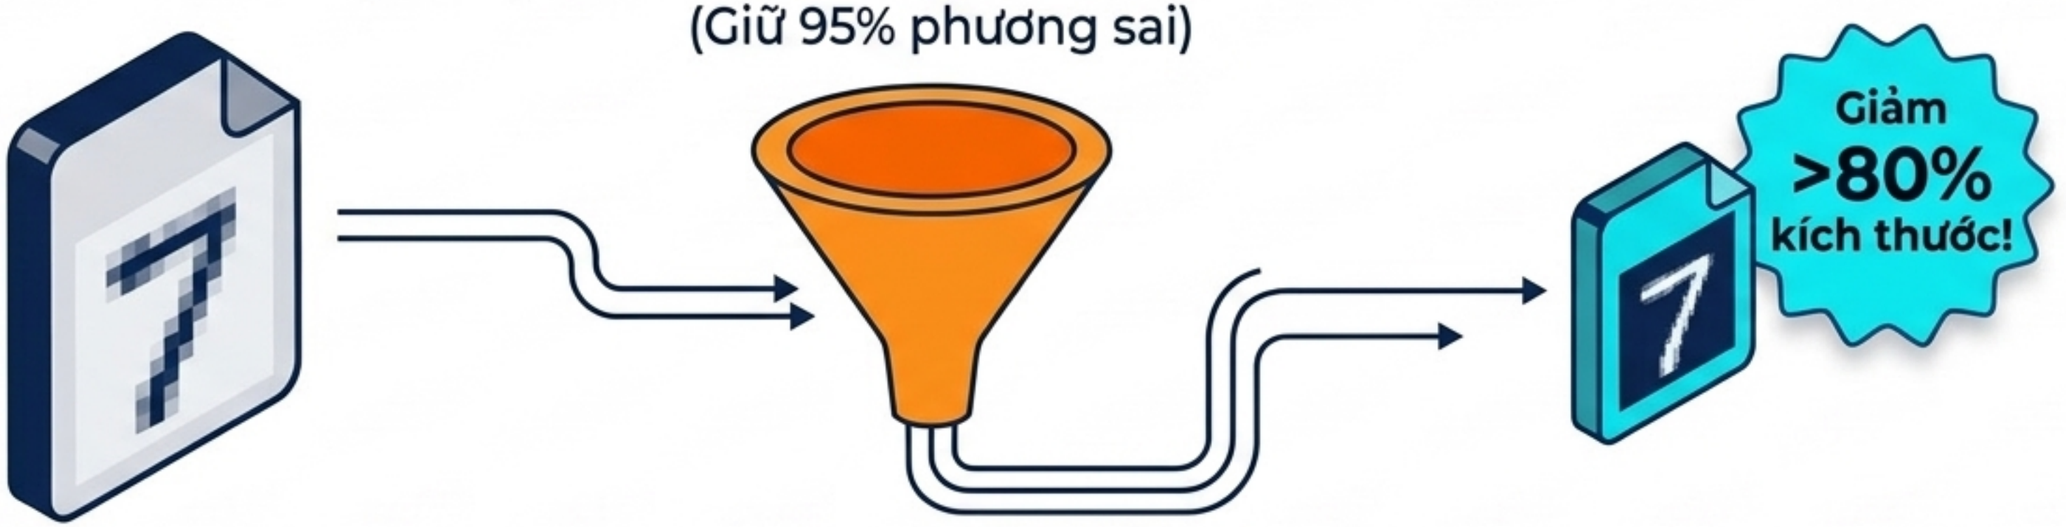
Gemini Notebook

Thực chứng: Sức mạnh nén ảnh MNIST

Bản gốc: 784 Chiều (Pixel)

PCA
(Giữ 95% phương sai)

Nén: 154 Chiều

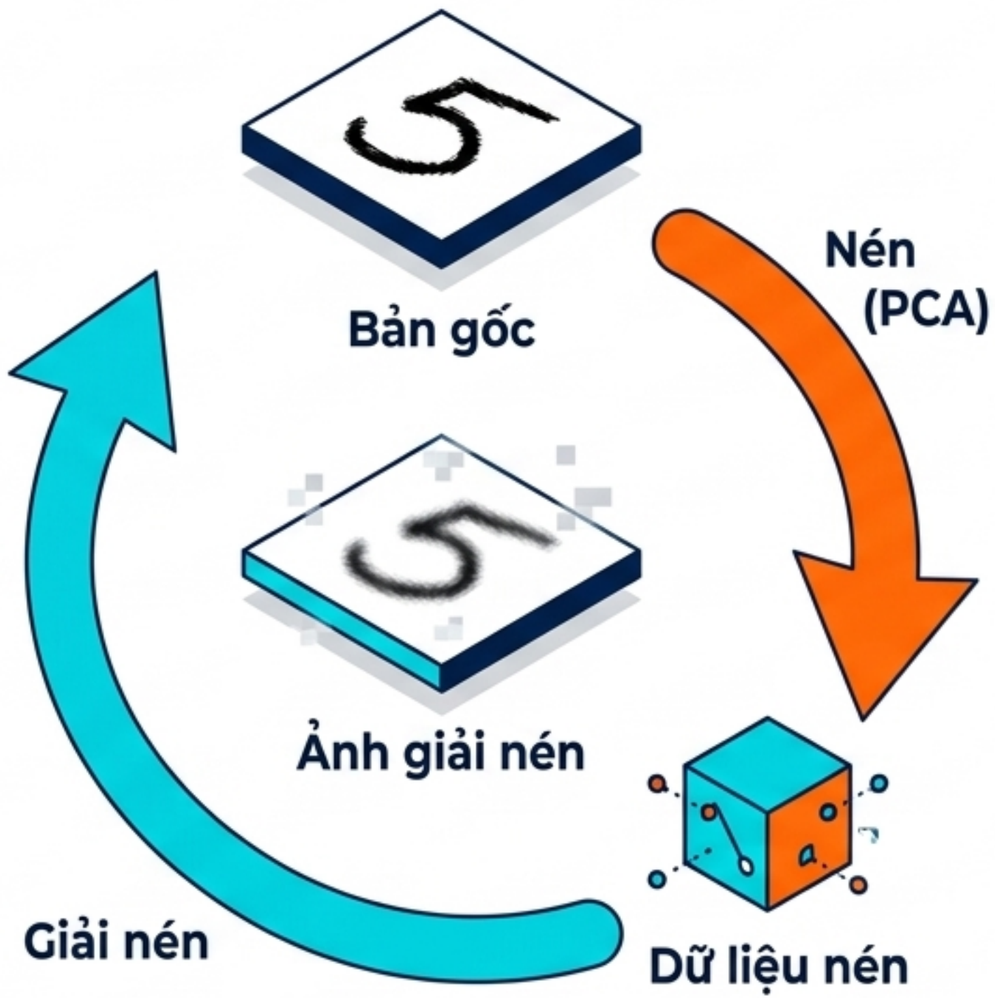


- Với tập ảnh chữ số viết tay MNIST, mỗi bức ảnh ban đầu có 784 pixel (tương đương 784 chiều).
- Áp dụng PCA để bảo toàn 95% phương sai, dữ liệu được rút gọn chỉ còn 154 chiều.

Kết quả: Kích thước dữ liệu giảm hơn **80%**. Điều này giải phóng dung lượng RAM khổng lồ và tăng tốc độ huấn luyện mô hình phân loại lên gấp nhiều lần.

Gemini Notebook

Giải nén dữ liệu & Sai số tái tạo



Giải nén: Dữ liệu có thể được đưa về số chiều gốc bằng lệnh pca.inverse_transform().

Công thức: $X_{recovered} = X_{d-proj} \cdot W_d^T$

Đánh đổi: Bản chất của quá trình là có mất mát. Vì ta đã chủ động bỏ đi 5% phương sai (thông tin nhiễu), hình ảnh giải nén sẽ mờ hơn đôi chút so với ảnh gốc.

Sai số tái tạo (Reconstruction Error):
Là khoảng cách bình phương trung bình giữa ảnh gốc và ảnh giải nén.

Gemini Notebook

Thách thức giới hạn: Khi PCA tiêu chuẩn thất bại

Thuật toán SVD tiêu chuẩn hoạt động hoàn hảo cho dữliệu vừa và nhỏ. Tuy nhiên, nó sẽ gặp **nút thắt cổ chai** khi đối mặt với:

Tính toán quá lâu



Tính toán quá lâu

Khi tập dữ liệu có số chiều gốc quá lớn, độ phức tạp tính toán SVD nguyên bản làm thời gian chạy kéo dài đến mức không thể chấp nhận.

Tràn bộ nhớ RAM (Out-of-core)



Tràn bộ nhớ RAM (Out-of-core)

Tập dữ liệu khổng lồ không thể nhét vừa vào bộ nhớ chính (RAM) để xử lý cùng một lúc.

Giải pháp: Sử dụng các biến thể tối ưu của PCA.

Gemini Notebook

Các biến thể khắc phục: Ma trận lựa chọn

	Cơ chế	Khi nào dùng?	Ưu điểm / Công cụ
 **Randomized PCA** svd_solver="randomized"	Dùng thuật toán ngẫu nhiên xấp xỉ nhanh d thành phần đầu tiên.	Dữ liệu nằm gọn trong RAM. Số chiều mục tiêu nhỏ hơn rất nhiều chiều gốc (d << n).	Tốc độ vượt trội, xử lý cực nhanh: O(m × d^2) + O(d^3).
 **Incremental PCA (IPCA)** IncrementalPCA	Chia nhỏ dữ liệu thành mini-batches, cập nhật dần qua hàm partial_fit().	Dữ liệu khổng lồ tràn RAM (Out-of-core) hoặc Học trực tuyến liên tục.	Vũ khí kết hợp: Dùng chung với np.memmap để tải từng phần dữ liệu từ ổ cứng.

Gemini Notebook

Tổng kết & Bước tiếp theo

Key Insights

Bản chất PCA



Tối đa hóa **phương sai**, tối thiểu hóa **sai số**.

Kiểm soát thông tin



Dùng **Tỷ lệ phương sai giải thích** để quyết định số chiều cần giữ.

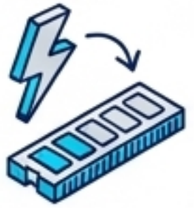


Đánh đổi



Nén tiết kiệm bộ nhớ **80%+, chấp nhận một mức sai số tái tạo nhỏ**.

Linh hoạt



Chọn **Randomized PCA** để tăng tốc, hoặc IPCA để vượt giới hạn RAM.

Đã sẵn sàng cho cấp độ tiếp theo?

Khám phá cách giảm chiều siêu tốc cho dữ liệu hàng chục nghìn chiều mà không cần luấn luyện trong **Phần 3:** Phép chiếu ngẫu nhiên (Random Projection).

Gemini Notebook