




2. Khám phá & Chuẩn bị Dữ liệu



Hình 2-9. Các loại thu nhập

Phân phối Thu nhập

Thu nhập trung bình là một thuộc tính rất quan trọng để dự đoán giá nhà.




Nếu lấy mẫu ngẫu nhiên thuần túy, ta có thể vô tình chọn phải một tập kiểm thử thiếu tính đại diện.

Lấy mẫu phân tầng (Stratified Sampling) so với Ngẫu nhiên



	Overall %	Stratified %	Random %	Strat. Error %	Rand. Error %
Income Category					
1	3.98	4.00	4.24	0.36	6.45
2	31.88	31.88	30.74	-0.02	-3.59
3	35.06	35.05	34.52	-0.01	-1.53
4	17.63	17.64	18.41	0.03	4.42
5	11.44	11.43	12.09	-0.08	5.63

Hình 2-10. Tỷ lệ phân loại thu nhập trong tổng thể so với mẫu ngẫu nhiên và phân tầng




Hình 2-11. Trực quan hóa dữ liệu địa lý

Trực quan hóa dữ liệu địa lý



Dữ liệu có thuộc tính kinh độ (longitude) và vĩ độ (latitude). Việc vẽ biểu đồ **phân tán** (scatter plot) sẽ giúp ta nhìn thấy mô hình phân bố của các khu dân cư.



Hình 2-12. Trực quan hóa tốt hơn để thấy khu vực mật độ cao


Phân tích mật độ địa lý



Bằng cách chỉnh thông số alpha, ta có thể nhìn thấy rõ ràng các khu vực tập trung đông dân cư.

Nổi bật lên khu vực Vùng Vịnh (Bay Area), Los Angeles và San Diego.

Giá nhà theo dân số & Vị trí



Hình 2-13. Giá nhà khu vực California (Màu: Giá nhà, Vòng tròn: Dân số)

Tìm kiếm các tương quan (Correlation)

Hệ số tương quan Pearson (r) chạy từ -1 đến +1.



Gần -1:

Tương quan âm mạnh.


Gần 0:

Không có tương quan tuyến tính.


Gần +1:

Tương quan dương mạnh (ví dụ: thu nhập tăng, giá nhà tăng).

Ma trận phân tán (Scatter Matrix)



Hình 2-14. Ma trận phân tán hiển thị tương quan giữa các đặc trưng



Hình 2-15. Thu nhập so với giá trị nhà

Thu nhập trung bình vs Giá nhà trung bình


Thu nhập trung bình là thuộc tính có tương quan mạnh nhất với giá nhà.

Anomaly Detected

Trên biểu đồ xuất hiện một số "đường ngang" (trần giá) ở mức \$500k, \$450k, và \$350k.

Có thể cần phải loại bỏ các điểm dữ liệu này để thuật toán không học những mô hình sai lệch này.

Phân phối và độ lệch chuẩn của dữ liệu



Hình 2-16. Độ lệch chuẩn của các tập dữ liệu khác nhau

Thử nghiệm với các kết hợp đặc trưng

Đôi khi, kết hợp các đặc trưng hiện có sẽ tạo ra đặc trưng mới ý nghĩa hơn.

Vấn đề:

Số lượng phòng trong một quận không hữu ích nếu không biết số hộ gia đình.

Giải pháp:

Thay vào đó, tạo đặc trưng Số phòng trên mỗi hộ.

Các kết hợp khác:

Số lượng phòng ngủ trên tổng số phòng.
Dân số trên mỗi hộ.





Chuẩn bị dữ liệu cho học máy

Làm sạch dữ liệu (Data Cleaning)

Các thuật toán học máy không thể hoạt động với các giá trị bị thiếu (Missing Values).



1. Loại bỏ các mẫu tương ứng (xóa hàng).



2. Loại bỏ toàn bộ thuộc tính đó (xóa cột).




3. Điền vào các giá trị bị thiếu bằng một giá trị nào đó (0, trung bình, trung vị...).



Sử dụng **SimpleImputer** của Scikit-Learn.

Xử lý các thuộc tính văn bản và phân loại

Hầu hết các thuật toán ML thích làm việc với con số. Cần chuyển đổi văn bản sang số.
Đặc trưng "ocean_proximity" là văn bản.



Phương pháp One-Hot Encoding:

Tạo một cột nhị phân cho mỗi danh mục.


Tránh việc thuật toán hiểu sai rằng danh mục "1" thì gần danh mục "2" hơn danh mục "4".

Co giãn Đặc trưng (Feature Scaling)

Các thuật toán hoạt động không tốt khi các đặc trưng có thang đo rất khác nhau (ví dụ: dân số từ vài nghìn, nhưng thu nhập chỉ từ 0 - 15).

Min-Max Scaling (Chuẩn hóa Normalization) (Chuẩn hóa Normalization)

Giá trị được chuyển về khoảng từ 0 đến 1.



Standardization (Chuẩn hóa Standardization) (chuẩn hóa Standardization)

Trừ đi giá trị trung bình và chia cho độ lệch chuẩn. Không bị ảnh hưởng nhiều bởi ngoại lai.
Không bị ảnh hưởng nhiều bởi ngoại lai.

