

Bí ẩn sức mạnh của Cây Quyết Định (Decision Tree)



Từ 4 cơ chế cốt lõi đến sự tiến hóa hoàn hảo mang tên Rừng Ngẫu Nhiên.

4 Trụ cột tạo nên sức mạnh xử lý dữ liệu phức tạp

Tại sao Cây quyết định nhị phân có thể dễ dàng phân tích các tập dữ liệu phi tuyến tính và đa chiều?



Phi tham số

Mức độ tự do cực cao, không bị gò bó bởi công thức.



Tương tác đặc trưng

Tự động học các quy luật kết hợp phức tạp qua từng phân tầng.



Chia để trị

Thuật toán CART cắt nhỏ không gian bằng các vạch vuông góc.



Không cần chuẩn hóa

Bỏ qua rào cản đo lường, xử lý mọi loại dữ liệu.


Sự tự do tuyệt đối: Mô hình Phi tham số

Tuyến tính / Có tham số



Bị gông còng. Các mô hình tuyến tính giả định dữ liệu phải là đường thẳng hoặc mặt phẳng. Cấu trúc bị khóa chặt bởi công thức cố định.

Cây quyết định / Phi tham số






Tự do phát triển. Không ấn định trước số lượng tham số. Tự động uốn lượn để bao trọn những hình dạng dữ liệu phi tuyến phức tạp nhất.

Chiến lược Chia để trị đệ quy (Thuật toán CART)



1 Câu hỏi Nhị phân

Tại mỗi nút, chỉ hỏi một điều kiện:
Đặc trưng $x_k \leq t_k$?



Cắt đôi không gian

Phép chia cắt dữ liệu thành 2 nửa
và lặp lại đệ quy trên từng nửa.

Lưới siêu khối (Hypercubes)

Ghép hàng trăm vạch cắt vuông góc
để phân tách hoàn toàn các nhóm
dữ liệu đan xen phức tạp.

Tự động học mối tương tác đặc trưng (Feature Interactions)



Mô hình truyền thống:

Kỹ sư dữ liệu phải tự tay tạo ra đặc trưng kết hợp (vd: $x1 * x2$).

Cây quyết định:

Tự động xây dựng các quy luật điều kiện phức tạp thông qua cấu trúc phân tầng rẽ nhánh.

Xử lý linh hoạt, không màng chuẩn hóa



Không nhạy cảm thang đo (Scale Invariant): Thuật toán chỉ quan tâm đến thứ tự xếp hạng để tìm ngưỡng t_k , hoàn toàn bỏ qua khoảng cách hay đơn vị đo.



Loại bỏ StandardScaler: Tiết kiệm hoàn toàn bước chuẩn hóa dữ liệu phức tạp.



Nuốt trọn mọi định dạng: Hoạt động hoàn hảo trên cả dữ liệu số (liên tục) lẫn dữ liệu phân loại (rời rạc).

Mặt tối của sự Xuất sắc: Bẫy Học Vẹt (Overfitting)

Khả năng tự do ôm sát dữ liệu biến thành tai họa. Nếu không giới hạn độ sâu, cây sẽ phân nhánh đến mức **mỗi nút lá chỉ chứa đúng 1 điểm dữ liệu**.



Ghi nhớ hoàn toàn nhiều. Lỗi huấn luyện bằng 0%, nhưng dự đoán **SAI BÉT** trên dữ liệu mới.

Giải pháp 1: Chính quy hóa (Regularization)

Giới hạn sự tự do vô kỉ luật để cây phát triển khỏe mạnh và tổng quát hóa tốt hơn.



max_depth
(Giới hạn độ sâu)

min_samples_leaf
(Số mẫu tối thiểu ở lá)

max_leaf_nodes
(Giới hạn nút lá)

Giải pháp 2: Sức mạnh Học tập hợp (Ensemble)

Từ sự đơn độc tiến đến **Rừng Ngẫu Nhiên (Random Forest) & Gradient Boosting**.



Ghép hàng trăm cây lại với nhau. Kết quả: Phát huy tối đa sức mạnh **khớp dữ liệu phức tạp** — **Triệt tiêu hoàn toàn** nỗi lo Quá khớp (Overfitting).

Cây quyết định đã chọn đường cắt tối ưu bằng cách nào?



Khám phá bí ẩn toán học của thuật toán CART và độ đo bất thuần (Impurity) ở bài học tiếp theo.