

VƯỢT RA KHỎI LÝ THUYẾT SÁCH GIÁO KHOA

Sự thật bị che giấu về đặc trưng trong Cây quyết định


Thuật toán Cây quyết định (Decision Tree) phức tạp và mạnh mẽ hơn rất nhiều so với những ví dụ 2 chiều kinh điển. Đã đến lúc nhìn vào cách mô hình thực sự vận hành trong không gian đa chiều.



Sách giáo khoa giới hạn góc nhìn của bạn để phục vụ thị giác




Các giáo trình thường chỉ sử dụng 2 đặc trưng (ví dụ: chiều dài và chiều rộng cánh hoa Iris).



Mục đích duy nhất là trực quan hóa trên đồ thị 2D. Mắt người cần mặt phẳng 2 chiều để dễ dàng nhìn thấy các đường ranh giới quyết định (Decision Boundaries) cắt vuông góc với trục tọa độ.

Trong thực tế, mô hình nuốt trọn hàng ngàn đặc trưng cùng lúc

Không hề có giới hạn 2 đặc trưng. Một tập dữ liệu thực tế mang theo khối lượng thông tin khổng lồ.



Ảnh MNIST: Xử lý đồng thời 784 pixel (784 đặc trưng).

Dữ liệu Nhà đất: Hàng chục thuộc tính phức tạp (diện tích, vị trí, số phòng, v.v.).

Quy luật “Kẻ được chọn” tại mỗi nút chia của thuật toán CART


Thuật toán CART (Scikit-Learn) có một nguyên tắc bất di bất dịch: Bất kể dữ liệu có bao nhiêu chiều, tại **MỖI NÚT CHIA**, nó chỉ tập trung vào một thứ duy nhất.




Chọn duy nhất 1 đặc trưng (k)



Chọn 1 ngưỡng giá trị (t_k) để xẻ dữ liệu làm 2 nhánh (Đúng / Sai).



Máy quét tìm kiếm ứng cử viên hoàn hảo nhất



Step 1

Quét toàn bộ: Thuật toán duyệt qua tất cả n đặc trưng đầu vào.

Step 2

Thử nghiệm: Với mỗi đặc trưng, nó liên tục thử nghiệm các ngưỡng cắt (t_k) khác nhau.

Step 3


Chấm điểm: Đo lường hiệu quả chia tách để tìm ra vị trí cắt tối ưu nhất tại thời điểm đó.

Mục tiêu tối thượng của mỗi nhát cắt là "Độ tinh khiết"

Đặc trưng được chọn là đặc trưng giúp giảm tối đa Độ không tinh khiết (Gini Impurity hoặc Entropy).



Độ không tinh khiết cao




Thuật toán luôn khát khao tạo ra các nhánh con ít lẫn lộn nhất (thuần khiết nhất). Đặc trưng nào làm tốt việc này nhất sẽ chiến thắng tại nút chia đó.



Thuần khiết

Số phận của các đặc trưng: Tái sử dụng và bị lãng quên



Xuất hiện nhiều lần: Một đặc trưng xuất xuất sắc có thể được cây dùng lại ở nhiều tầng/độ sâu khác nhau với các ngưỡng cắt khác nhau.



Không bao giờ được chọn: Không bắt buộc dùng hết mọi đặc trưng. Những đặc trưng kém quan trọng, không giúp giảm độ không tinh khiết sẽ bị bỏ qua hoàn toàn.

Nâng cấp lên Rừng ngẫu nhiên (Random Forest)

Sự thông thái của đám đông.



Thay vì một cây khổng lồ dễ bị học vẹt (overfitting), Random Forest huấn luyện cả một khu rừng gồm nhiều cây nhị phân. Nhưng để khu rừng thực sự mạnh, mỗi cái cây phải học cách nhìn nhận vấn đề theo một cách khác biệt.

Quy tắc góc nhìn hẹp: Bí quyết tạo nên sự đa dạng của khu rừng

Cây quyết định đơn lẻ



Xem xét toàn bộ n đặc trưng tại mỗi nút.

Một cây trong Rừng ngẫu nhiên



Chỉ chọn ngẫu nhiên một nhóm nhỏ đặc trưng
(mặc định lấy căn bậc hai của n đối với bài toán phân loại).

Việc 'che mắt' này ép mỗi cây nhị phân phải tập trung vào các góc nhìn đặc trưng khác nhau, tạo nên sự đa dạng và hạn chế tối đa hiện tượng quá khớp (overfitting).

Bản chất thực sự: Sự tập trung tuyệt đối trong không gian vô tận

Cây quyết định tiếp nhận toàn bộ số đặc trưng bạn đưa vào...



...nhưng tại mỗi bước quyết định (mỗi nút), nó gạt bỏ mọi nhiễu loạn để chọn ra 1 đặc trưng xuất sắc nhất tại thời điểm đó xẻ dữ liệu làm đôi!

Hành trình tiếp theo: Đo lường giá trị của từng đặc trưng



Dựa trên tần suất được chọn và hiệu quả phân chia (giảm độ không tinh khiết) xuyên suốt cái cây, Scikit-Learn có thể tính toán chính xác mức độ đóng góp của từng đặc trưng.

Bạn có muốn tìm hiểu cách thuật toán đo lường chỉ số Tầm quan trọng của đặc trưng (`feature_importances_`) trong bài học tiếp theo không?