



Minh họa: Biểu đồ phân tán & Mô hình phù hợp nhất



Hình 1-18. Biểu đồ phân tán (xu hướng)



Hình 1-20. Mô hình tuyến tính phù hợp nhất

- Bằng cách định nghĩa **hàm chi phí (Cost Function)** và tối thiểu hóa nó, hệ thống sẽ tìm ra tham số tốt nhất cho mô hình.

3. Thách thức, Kiểm thử & Xác thực


Những thách thức chính của học máy

Mô hình "Dữ liệu tồi" (Bad Data) hoặc "Thuật toán tồi" (Bad Algorithm):

- Dữ liệu huấn luyện không đủ lớn.
- Dữ liệu huấn luyện không đại diện.
- Dữ liệu chất lượng kém (nhiều, ngoại lai).
- Đặc trưng không liên quan (Garbage in, garbage out).
- Khớp quá mức (Overfitting) dữ liệu huấn luyện.
- Chưa khớp (Underfitting) dữ liệu huấn luyện.

Dữ liệu huấn luyện không đủ (Dữ liệu tồi)


- Máy tính cần hàng nghìn, thậm chí hàng triệu ví dụ mới có thể học được các tác vụ phức tạp (nhận dạng hình ảnh, xử lý ngôn ngữ).
- Hiệu quả dữ liệu đôi khi còn quan trọng hơn cả thuật toán tinh vi.



Hình 1-19. Tầm quan trọng của khối lượng dữ liệu (Nghiên cứu của Microsoft)

Dữ liệu huấn luyện không đại diện

- Để dự đoán tốt, dữ liệu phải đại diện cho các trường hợp mới mà mô hình sẽ gặp.
- Nếu dữ liệu bị thiên lệch, mô hình sẽ sai lầm (Lỗi lấy mẫu - Sampling bias).




Hình 1-20. Lỗi dự báo nếu bỏ qua một số quốc gia khỏi tập huấn luyện

- **Chất lượng kém:** Nhiều lỗi, ngoại lai (outliers), giá trị nhiễu. Cần tốn thời gian làm sạch (Data Cleaning).
- Hầu hết các Data Scientist dành phần lớn thời gian cho việc làm sạch dữ liệu.

- **Đặc trưng không liên quan:** Thuật toán học máy chỉ tốt khi thông tin nạp vào là hữu ích (Garbage In, Garbage Out).
- **Kỹ thuật đặc trưng (Feature Engineering):**
 - Lựa chọn đặc trưng (Feature Selection).
 - Trích xuất đặc trưng (Feature Extraction).
 - Tạo đặc trưng mới.

Overfitting (Khớp quá mức)


- Mô hình hoạt động tuyệt vời trên tập huấn luyện nhưng dự đoán cực kém với dữ liệu mới.
- Xảy ra khi mô hình quá phức tạp so với lượng dữ liệu, hoặc dữ liệu quá nhiễu.
- **Khắc phục:** Đơn giản hóa mô hình, thêm dữ liệu, giảm nhiễu, hoặc Dừng sớm.



Hình 1-22. Khớp quá mức (Overfitting) với mô hình đa thức phức tạp

Điều chuẩn (Regularization)


- Phương pháp ràng buộc mô hình để làm nó đơn giản hơn và giảm rủi ro Overfitting.
- Hình bên cho thấy hiệu quả của Regularization: mô hình bớt cong vẹo và ít phụ thuộc vào nhiễu hơn.



Hình 1-23. Hiệu ứng của việc điều chuẩn để giảm Overfitting

Underfitting (Chưa khớp)

- Mô hình quá đơn giản, không đủ khả năng học các cấu trúc ẩn bên trong dữ liệu (Ví dụ: dùng mô hình tuyến tính cho dữ liệu phi tuyến).
- **Khắc phục:** Chọn mô hình phức tạp hơn, cung cấp đặc trưng tốt hơn, hoặc nới lỏng các ràng buộc (giảm Regularization).



Hình 1-24. Underfitting - Đường dự đoán bị lệch khỏi xu thế thực

Kiểm thử và xác thực (Testing and Validating)

- Để biết mô hình có tốt không, không thể chỉ đánh giá trên tập huấn luyện (vì có thể bị Overfitting).
- **Chia dữ liệu:** Thường chia thành 80% **Tập huấn luyện (Training Set)** và 20% **Tập kiểm thử (Test Set)**.
- **Lỗi tổng quát hóa (Generalization Error):** Tỷ lệ lỗi trên tập kiểm thử đại diện cho khả năng ứng dụng thực tế.

Sự không khớp dữ liệu (Data Mismatch) & Tập train-dev

- Xảy ra khi dữ liệu huấn luyện dồi dào nhưng không đại diện hoàn toàn cho thực tế (Ví dụ: ảnh tải từ web vs ảnh chụp thực tế bằng di động).
- **Giải pháp:** Giữ lại một phần dữ liệu huấn luyện thành **Tập train-dev**.
- Giúp phân biệt rõ mô hình bị **Overfitting** hay bị **Data Mismatch**.



Hình 1-26. Sử dụng tập train-dev để đánh giá

Không có bữa trưa miễn phí (No Free Lunch)

- "Không có mô hình học máy nào luôn luôn tốt nhất cho mọi loại dữ liệu" (Định lý Wolpert, 1996).
- Nếu bạn hoàn toàn không biết gì về dữ liệu, không có lý do gì để ưu tiên mô hình này hơn mô hình khác.
- Đơn giản hóa có nghĩa là mô hình phải loại bỏ các chi tiết thừa thãi.
- Cần đưa ra một số giả định hợp lý và thử nghiệm nhiều mô hình khác nhau.

Tổng kết Chương 1

- Học máy là việc làm cho máy tính thực hiện công việc dựa trên kinh nghiệm từ dữ liệu.
- Bao gồm nhiều loại (Supervised, Unsupervised, Reinforcement, Batch, Online, Instance, Model).
- Phụ thuộc vào chất lượng & số lượng dữ liệu.
- Luôn phải cân bằng giữa Overfitting và Underfitting.
- Phải đánh giá nghiêm ngặt bằng tập Train/Validation/Test.