


Phân phối Thu nhập

- Thu nhập trung bình là một thuộc tính rất quan trọng để dự đoán giá nhà.
- Nếu lấy mẫu ngẫu nhiên thuần túy, ta có thể vô tình chọn phải một tập kiểm thử thiếu tính đại diện.



Hình 2-9. Các loại thu nhập

Lấy mẫu phân tầng (Stratified Sampling) so với Ngẫu nhiên


	Overall %	Stratified %	Random %	Strat. Error %	Rand. Error %
Income Category					
1	3.98	4.00	4.24	0.36	6.45
2	31.88	31.88	30.74	-0.02	-3.59
3	35.06	35.05	34.52	-0.01	-1.53
4	17.63	17.64	18.41	0.03	4.42
5	11.44	11.43	12.09	-0.08	5.63

Hình 2-10. Tỷ lệ phân loại thu nhập trong tổng thể so với mẫu ngẫu nhiên và phân tầng

2. Khám phá & Chuẩn bị Dữ liệu

Trực quan hóa dữ liệu địa lý


- Dữ liệu có thuộc tính kinh độ (longitude) và vĩ độ (latitude).
- Việc vẽ biểu đồ phân tán (scatter plot) sẽ giúp ta nhìn thấy mô hình phân bố của các khu dân cư.



Hình 2-11. Trực quan hóa dữ liệu địa lý


Phân tích mật độ địa lý

- Bằng cách chỉnh thông số α , ta có thể nhìn thấy rõ ràng các khu vực tập trung đông dân cư.
- Nổi bật lên khu vực Vùng Vịnh (Bay Area), Los Angeles và San Diego.



Hình 2-12. Trực quan hóa tốt hơn để thấy khu vực mật độ cao

Giá nhà theo dân số & Vị trí




Hình 2-13. Giá nhà khu vực California (Màu: Giá nhà, Vòng tròn: Dân số)

Tìm kiếm các tương quan (Correlation)

- Hệ số tương quan Pearson (r) chạy từ -1 đến +1.
- Gần +1: Tương quan dương mạnh (ví dụ: thu nhập tăng, giá nhà tăng).
- Gần -1: Tương quan âm mạnh.
- Gần 0: Không có tương quan tuyến tính.


Ma trận phân tán (Scatter Matrix)



Hình 2-14. Ma trận phân tán hiển thị tương quan giữa các đặc trưng


Thu nhập trung bình vs Giá nhà trung bình

- Thu nhập trung bình là thuộc tính có tương quan mạnh nhất với giá nhà.
- Trên biểu đồ xuất hiện một số "đường ngang" (trần giá) ở mức \$500k, \$450k, và \$350k.
- Có thể cần phải loại bỏ các điểm dữ liệu này để thuật toán không học những mô hình sai lệch này.



Hình 2-15. Thu nhập so với giá trị nhà

Phân phối và độ lệch chuẩn của dữ liệu



Hình 2-16. Độ lệch chuẩn của các tập dữ liệu khác nhau

Thử nghiệm với các kết hợp đặc trưng

- Đôi khi, kết hợp các đặc trưng hiện có sẽ tạo ra đặc trưng mới ý nghĩa hơn.
- **Ví dụ:**
 - Số lượng phòng trong một quận không hữu ích nếu không biết số hộ gia đình. Thay vào đó, tạo đặc trưng *Số phòng trên mỗi hộ*.
 - Số lượng phòng ngủ trên tổng số phòng.
 - Dân số trên mỗi hộ.

Chuẩn bị dữ liệu cho học máy

Làm sạch dữ liệu (Data Cleaning)

- Các thuật toán học máy không thể hoạt động với các giá trị bị thiếu (Missing Values).
- Có 3 lựa chọn để xử lý:
 - 1 Loại bỏ các mẫu tương ứng (xóa hàng).
 - 2 Loại bỏ toàn bộ thuộc tính đó (xóa cột).
 - 3 Điền vào các giá trị bị thiếu bằng một giá trị nào đó (0, trung bình, trung vị...).
- Sử dụng SimpleImputer của Scikit-Learn.

Xử lý các thuộc tính văn bản và phân loại

- Hầu hết các thuật toán ML thích làm việc với con số. Cần chuyển đổi văn bản sang số.
- Đặc trưng "ocean_proximity" là văn bản.
- Phương pháp **One-Hot Encoding**:
 - Tạo một cột nhị phân cho mỗi danh mục.
 - Tránh việc thuật toán hiểu sai rằng danh mục "1" thì gần danh mục "2" hơn danh mục "4".

Co giãn Đặc trưng (Feature Scaling)

- Các thuật toán hoạt động không tốt khi các đặc trưng có thang đo rất khác nhau (ví dụ: dân số từ vài nghìn, nhưng thu nhập chỉ từ 0 - 15).
- **Min-Max Scaling (Chuẩn hóa Normalization):** Giá trị được chuyển về khoảng từ 0 đến 1.
- **Standardization (Chuẩn hóa Standardization):** Trừ đi giá trị trung bình và chia cho độ lệch chuẩn. Không bị ảnh hưởng nhiều bởi ngoại lai.