

DỰ ÁN HỌC MÁY TỪ ĐẦU ĐẾN CUỐI

Chương 3 - Phân loại (Classification)

TS. Trần Thành Thắng

Đại học Đông Á

August 11, 2026

Nội dung Chương trình

1. Giới thiệu Phân loại, MNIST & Đánh giá Hiệu suất cơ bản
2. Sự đánh đổi Hiệu suất & Phân loại Đa lớp
3. Phân tích lỗi, Đa nhãn & Đa đầu ra

- Nắm vững khái niệm Phân loại (Classification) trong Học máy.
- Hiểu rõ và thực hành với bộ dữ liệu MNIST ("Hello World" của học máy).
- Đánh giá mô hình bằng các thước đo hiệu suất (Ma trận nhầm lẫn, Precision, Recall, F1-score, ROC AUC).
- Phân biệt và thực hiện Phân loại Đa lớp (Multiclass), Đa nhãn (Multilabel) và Đa đầu ra (Multioutput).
- Kỹ năng phân tích lỗi để cải thiện hiệu suất mô hình.


1. Giới thiệu Phân loại, MNIST & Đánh giá Hiệu suất cơ bản

Giới thiệu Bộ dữ liệu MNIST

- Các tác vụ học có giám sát phổ biến nhất là Hồi quy (Regression) và Phân loại (Classification).
- Chúng ta sẽ sử dụng bộ dữ liệu **MNIST**, gồm 70.000 hình ảnh nhỏ của các chữ số viết tay bởi học sinh và nhân viên Cục Thống kê Hoa Kỳ.
- MNIST được nghiên cứu nhiều đến mức nó được gọi là **"Hello World" của học máy**.
- Mục tiêu: Phân loại (nhận dạng) chữ số trong từng bức ảnh.

Hình ảnh chữ số MNIST

- Mỗi hình ảnh có kích thước 28x28 pixel, tương đương 784 đặc trưng (pixels).
- Mỗi pixel đại diện cho cường độ xám, từ 0 (trắng) đến 255 (đen).
- Trong ảnh là một ví dụ trực quan hóa một chữ số 5 từ bộ dữ liệu.



Hình 3-1. Ví dụ về hình ảnh MNIST

Sự đa dạng của chữ số MNIST

- Các chữ số được viết với nhiều phong cách, nét thanh, nét đậm khác nhau.
- Để minh họa độ phức tạp của bài toán phân loại, hình bên cạnh liệt kê một số chữ số mẫu từ tập dữ liệu.



Hình 3-2. Các chữ số từ bộ dữ liệu MNIST

Phân chia tập huấn luyện và tập kiểm thử

- **Nguyên tắc vàng:** Luôn tạo một tập kiểm thử (Test set) và tách biệt nó trước khi kiểm tra kỹ lưỡng dữ liệu.
- May mắn là tập dữ liệu MNIST tải từ OpenML đã được chia sẵn:
 - Tập huấn luyện (Train set): 60.000 hình ảnh đầu tiên.
 - Tập kiểm thử (Test set): 10.000 hình ảnh cuối cùng.
- Tập huấn luyện đã được xáo trộn (shuffled), đảm bảo các thuật toán học (đặc biệt là các thuật toán học tuần tự) không bị nhận nhiều trường hợp giống nhau liên tiếp.

Huấn luyện bộ phân loại nhị phân (Binary Classification)

Bài toán: Bộ phát hiện chữ số 5

- Hãy đơn giản hóa bài toán: Chúng ta chỉ cần phát hiện xem một chữ số có phải là "5" hay không.
- Đây là ví dụ về **Phân loại Nhị phân (Binary Classification)**: Phân biệt giữa 2 lớp (5 và không-phải-5).
- Mục tiêu (Label) mới: True (nếu là số 5), False (nếu là số khác).

Thuật toán Stochastic Gradient Descent (SGD)

- SGD (Xuống dốc ngẫu nhiên) là một thuật toán tối ưu rất hiệu quả để xử lý các tập dữ liệu lớn.
- SGD xử lý các trường hợp huấn luyện độc lập, từng trường hợp một (phù hợp với học trực tuyến - online learning).
- Lớp `SGDClassifier` trong Scikit-Learn giúp ta dễ dàng huấn luyện mô hình này.

Các thước đo hiệu suất

Đo độ chính xác bằng kiểm định chéo

- Giống như hồi quy, ta có thể dùng kiểm định chéo (Cross-Validation) để đánh giá mô hình phân loại.
- **Kết quả:** SGDClassifier đạt độ chính xác (Accuracy) trên 95% cho mọi fold!
- Nghe có vẻ tuyệt vời, nhưng hãy xem xét cẩn thận hơn.

Sự đánh lừa của Độ chính xác (Accuracy)

- Nếu ta tạo một "bộ phân loại ngốc nghếch" (Dummy Classifier) luôn đoán "không-phải-5", thì độ chính xác của nó cũng trên 90%!
- Tại sao? Vì chỉ có 10% chữ số trong tập dữ liệu là số 5.
- **Kết luận:** Độ chính xác (Accuracy) không phải là thước đo tốt cho các **tập dữ liệu bị lệch (skewed datasets)**.

Ma trận nhầm lẫn (Confusion Matrix)

- Ma trận nhầm lẫn (CM) là một cách tốt hơn nhiều để đánh giá hiệu suất.
- Ý tưởng chung: Đếm số lần các trường hợp của lớp A bị phân loại nhầm thành lớp B.
- Mỗi hàng là một lớp thực tế, mỗi cột là một lớp được dự đoán.