


Hiện tượng Quá khớp (Overfitting) với đa thức bậc cao

- Nếu thực hiện hồi quy đa thức bậc quá cao (Ví dụ: bậc 300), mô hình sẽ khớp dữ liệu huấn luyện cực kỳ tốt.
- Hình bên cho thấy đường uốn lượn dữ dội cố gắng đi qua mọi điểm.
- Tuy nhiên, đây là **Quá khớp nghiêm trọng**. Mô hình bậc 2 (Quadratic) mới là mô hình tổng quát hóa tốt nhất (Generalize) cho bộ dữ liệu này.
- Làm sao nhận biết mô hình đang quá khớp hay dưới khớp? Hãy sử dụng Đường cong học tập.




Hình 4-14. Hồi quy đa thức bậc cao (Overfitting)


Đánh giá mô hình bằng Đường cong học tập (Learning Curves)

- Đường cong học tập là các biểu đồ thể hiện lỗi trên tập Huấn luyện (Train) và tập Xác thực (Validation) của mô hình dưới dạng hàm của **kích thước tập huấn luyện**.
- **Dưới khớp (Underfitting)**: Cả hai đường đều đạt cao nguyên, lỗi cao và sát nhau (không cải thiện thêm dù cho dữ liệu).
- **Quá khớp (Overfitting)**: Lỗi trên tập huấn luyện thấp hơn nhiều, và có **khoảng cách (gap)** đáng kể giữa lỗi huấn luyện và lỗi xác thực (Mô hình hoạt động rất tốt trên tập huấn luyện nhưng kém trên dữ liệu mới).

Minh họa: Đường cong học tập (Dưới khớp và Quá khớp)



Hình 4-15. Dưới khớp (Đường cong sát nhau, lỗi cao)



Hình 4-16. Quá khớp (Khoảng cách rõ ràng giữa 2 đường cong)

Sự đánh đổi giữa Độ chệch (Bias) và Phương sai (Variance)

- Lỗi tổng quát hóa có thể phân rã thành ba loại lỗi:
- **Độ chệch (Bias):** Lỗi do các giả định sai của mô hình (Vd: giả định dữ liệu tuyến tính khi thực tế là phi tuyến). Độ chệch cao thường gây ra underfitting.
- **Phương sai (Variance):** Lỗi do mô hình quá nhạy cảm với biến động nhỏ trong tập huấn luyện. Một mô hình nhiều bậc tự do (bậc cao) có phương sai cao, gây ra overfitting.
- **Lỗi không thể giảm (Irreducible error):** Do độ nhiễu của bản thân dữ liệu. Chỉ có thể giảm bằng cách làm sạch dữ liệu.
- **Sự đánh đổi:** Tăng độ phức tạp mô hình $\rightarrow$ Tăng variance, giảm bias. Giảm độ phức tạp $\rightarrow$ Tăng bias, giảm variance.

Chính quy hóa (Regularization) Mô hình Tuyến tính

Hồi quy Ridge (Chuẩn hóa Tikhonov)


- Một cách tốt để giảm Overfitting là **chính quy hóa (ràng buộc)** mô hình. Đối với mô hình tuyến tính, điều này thường thực hiện bằng cách ràng buộc kích thước của các trọng số θ .
- **Hồi quy Ridge** thêm một số hạng phạt l_2 (chuẩn l_2) vào hàm chi phí MSE:

$$J(\theta) = MSE(\theta) + \alpha \frac{1}{2} \sum_{i=1}^n \theta_i^2 \quad (7)$$

- α kiểm soát mức độ chính quy hóa. Nếu $\alpha = 0$, nó là hồi quy tuyến tính bình thường. Nếu α lớn, tất cả trọng số θ sẽ gần về 0, tạo thành đường thẳng phẳng cắt qua trung bình dữ liệu.

Minh họa: Hồi quy Ridge

- **Bên trái:** Hồi quy Ridge áp dụng trên mô hình tuyến tính thông thường. α tăng làm cho đường dự đoán phẳng hơn, giảm độ chệch của cực đoan.
- **Bên phải:** Hồi quy Ridge áp dụng sau biến đổi PolynomialFeatures(degree=10). Dễ dàng thấy $\alpha = 0$ thì dao động cực mạnh, nhưng α lớn thì đường cong trở nên êm hơn nhiều, giảm overfitting đáng kể.



Hình 4-17. Hồi quy Ridge trên mô hình tuyến tính và đa thức


- **Hồi quy Lasso** (Least Absolute Shrinkage and Selection Operator Regression) tương tự Ridge nhưng sử dụng chuẩn l_1 làm số hạng phạt:

$$J(\boldsymbol{\theta}) = MSE(\boldsymbol{\theta}) + \alpha \sum_{i=1}^n |\theta_i| \quad (8)$$

- Điểm đặc biệt nhất của Lasso: Nó có xu hướng hoàn toàn loại bỏ (đặt trọng số bằng 0) đối với các đặc trưng ít quan trọng nhất.
- Do đó, Lasso tự động thực hiện **lựa chọn đặc trưng (feature selection)**, tạo ra một mô hình thưa (sparse model).

Minh họa: Hồi quy Lasso

- Hình bên minh họa Lasso trên dữ liệu tuyến tính (trái) và đa thức (phải).
- Với $\alpha = 1$, đối với mô hình đa thức, đường dự đoán gần như trở thành một đường thẳng bậc thấp, chứng tỏ các tham số bậc cao đã bị đưa về giá trị 0 hoàn toàn.




Hình 4-18. Hồi quy Lasso trên mô hình tuyến tính và đa thức

Điểm khác biệt giữa Lasso và Ridge trong không gian tham số

- Ridge (chuẩn l_2) khiến các trọng số giảm dần khi tiến tới gốc tọa độ, gradient trở nên nhỏ nên việc đi đến tối ưu hội tụ êm và không dao động. Các tham số không bao giờ bị loại bỏ hoàn toàn (không về 0).
- Lasso (chuẩn l_1) thì hàm chi phí giảm tuyến tính khi tiến tới các trục (trục θ_1, θ_2). Hạ gradient trên Lasso sẽ nhanh chóng khiến một tham số về 0 (như $\theta_2 = 0$), sau đó trượt trên trục θ_1 cho đến khi cả hai đạt cực tiểu.
- Kết quả: Lasso tạo ra mô hình thưa và loại bỏ đặc trưng.

Minh họa: Lasso vs Ridge trong Không gian tham số



Hình 4-19. Chính quy hóa Lasso (Trên) và Ridge (Dưới)

Hồi quy Elastic Net & Khi nào nên dùng?


- **Elastic Net** là sự kết hợp trung gian giữa Ridge và Lasso. Hàm phạt của nó kết hợp cả chuẩn l_1 và l_2 , được điều khiển bởi tỷ lệ trộn r .
- Khi $r = 0$, nó là Ridge; Khi $r = 1$, nó là Lasso.
- **Khi nào sử dụng loại nào?**
 - Luôn ưu tiên dùng một ít chính quy hóa. **Ridge là lựa chọn mặc định tốt.**
 - Nếu bạn nghi ngờ chỉ có một vài đặc trưng là hữu ích (Nhiều nhiều), dùng **Lasso hoặc Elastic Net** để loại bỏ các đặc trưng vô ích.
 - Nói chung, **Elastic Net được ưa chuộng hơn Lasso** vì Lasso có thể hoạt động thất thường khi số lượng đặc trưng lớn hơn số trường hợp, hoặc khi các đặc trưng có tương quan mạnh với nhau.

Dừng sớm (Early Stopping)

- Một cách rất khác (và đơn giản) để chính quy hóa các thuật toán học lặp (như GD) là dừng huấn luyện ngay khi Lỗi xác thực (Validation Error) đạt đến cực tiểu.
- Khi các epoch trôi qua, lỗi trên tập huấn luyện luôn giảm. Lỗi xác thực cũng giảm ban đầu, nhưng sau đó sẽ tăng ngược trở lại (Đó là lúc mô hình bắt đầu Overfitting).
- Chỉ cần dừng thuật toán ngay tại điểm lỗi xác thực chạm mức thấp nhất. Kỹ thuật này hiệu quả đến mức Geoffrey Hinton gọi nó là **"bữa trưa miễn phí tuyệt vời"**.

Minh họa: Chính quy hóa bằng Dừng sớm (Early Stopping)

- Mũi tên chỉ vào thời điểm tốt nhất để dừng huấn luyện.
- Các bước sau đó chỉ làm mô hình tệ hơn khi đối mặt với dữ liệu chưa từng thấy (Mặc dù lỗi RMSE trên tập huấn luyện vẫn đang giảm).



Hình 4-20. Early Stopping