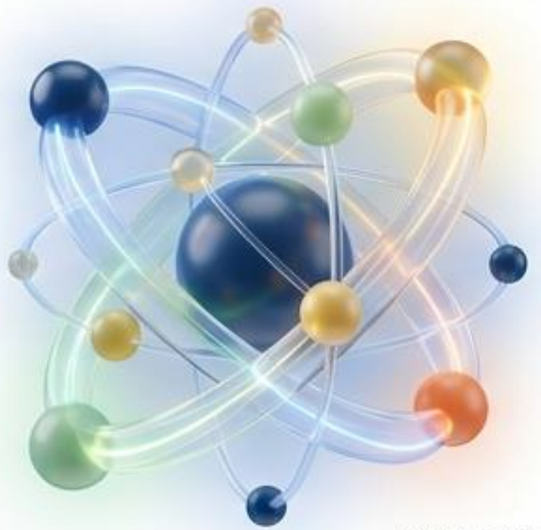
Học Máy (Machine Learning)

Chương 9: Các kỹ thuật Học không giám sát

Giảng viên: TS. Trần Thành Thắng
Đại học Đông Á
August 11, 2026



Gemini Notebook

Nội dung Chương trình

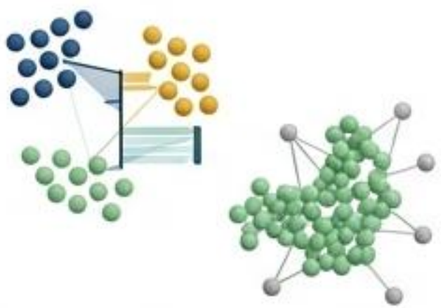
1

Giới thiệu Học không giám sát & K-Means



2

Điểm Silhouette, Ứng dụng K-Means & DBSCAN



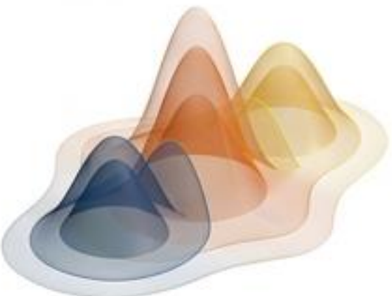
3

Mô hình Hỗn hợp Gaussian (GMM)



4

Mô hình Hỗn hợp Gaussian Bayes



Gemini Notebook

Giới thiệu Học không giám sát

Mặc dù đa số các ứng dụng học máy ngày nay dựa trên Học có giám sát, nhưng phần lớn dữ liệu trong thực tế là không được gắn nhãn. Chúng ta có các đặc trưng đầu vào X, nhưng không có nhãn y.

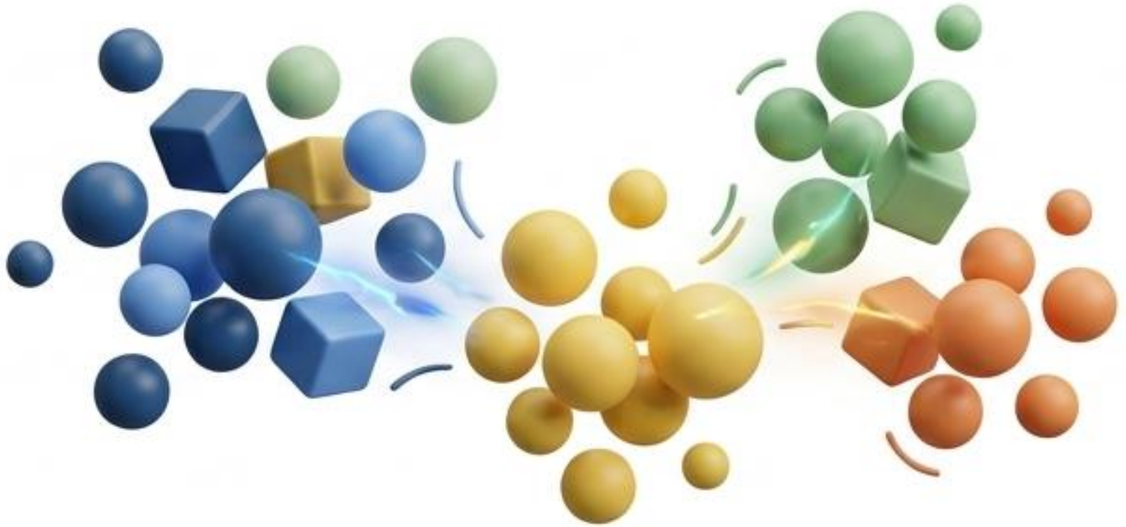
Tiềm năng của học không giám sát là vô cùng lớn nhưng chúng ta mới chỉ bắt đầu khai thác.

> Yann LeCun (Giám đốc AI của Meta):
> *”Nếu trí thông minh là một chiếc bánh, thì học không giám sát sẽ là chiếc bánh, học có giám sát sẽ là lớp kem trên bánh.”*



Gemini Notebook

Phân cụm (Clustering) là gì?



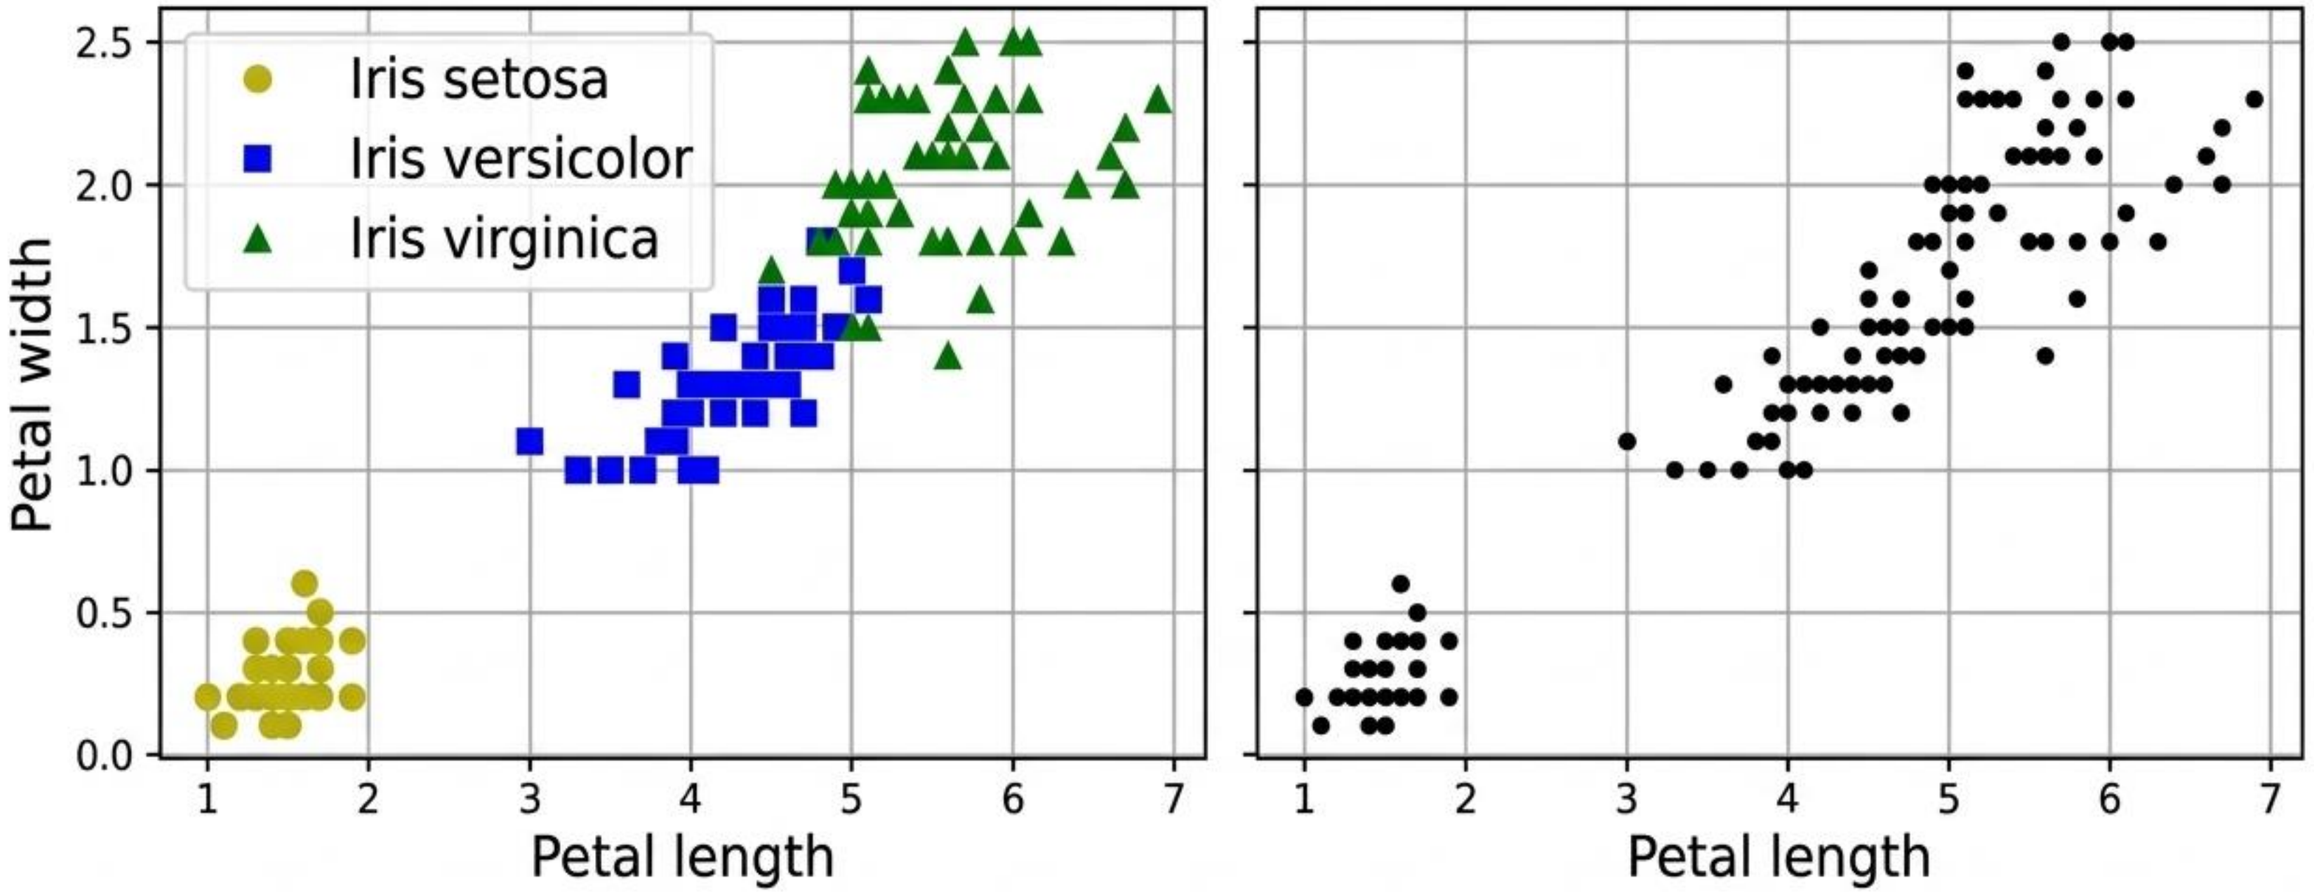
Phân cụm: Là tác vụ xác định các trường hợp tương tự nhau và gán chúng vào các "cụm" (clusters), hoặc các nhóm trường hợp tương tự.

Giống như phân loại, mỗi trường hợp được gán vào một nhóm. Nhưng khác biệt ở chỗ đây là tác vụ **không giám sát** (chúng ta không biết trước các nhóm là gì).

Thuật toán tự động tìm ra cấu trúc ẩn bên trong dữ liệu dựa trên sự tương đồng của các đặc trưng.

Gemini Notebook

Phân loại so với phân cụm



Hình 9-1. *Phân loại (trái) - đã có nhãn lớp, so với Phân cụm (phải) - không có nhãn*

Gemini Notebook

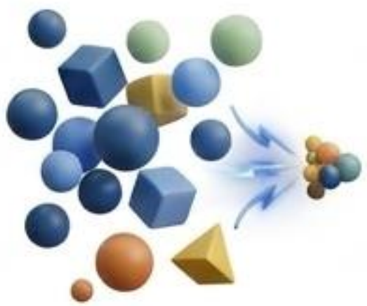
Ứng dụng của Phân cụm



Phân khúc khách hàng: Phân cụm khách hàng dựa trên lịch sử mua hàng, hoạt động trên trang web để điều chỉnh chiến dịch tiếp thị (Hệ thống đề xuất).



Phân tích dữ liệu: Phân cụm dữ liệu mới và phân tích từng cụm riêng biệt để hiểu sâu hơn.



Giảm chiều dữ liệu: Thay vì dùng đặc trưng gốc, dùng "khoảng cách tới tâm các cụm" làm đặc trưng mới.



Phân đoạn hình ảnh (Image Segmentation): Nhóm các điểm ảnh có màu sắc tương tự.

Gemini Notebook

Thuật toán K-Means

K-Means là một thuật toán phân cụm đơn giản, phổ biến và có khả năng phân cụm dữ liệu rất nhanh chóng, phân mảnh thành k cụm.

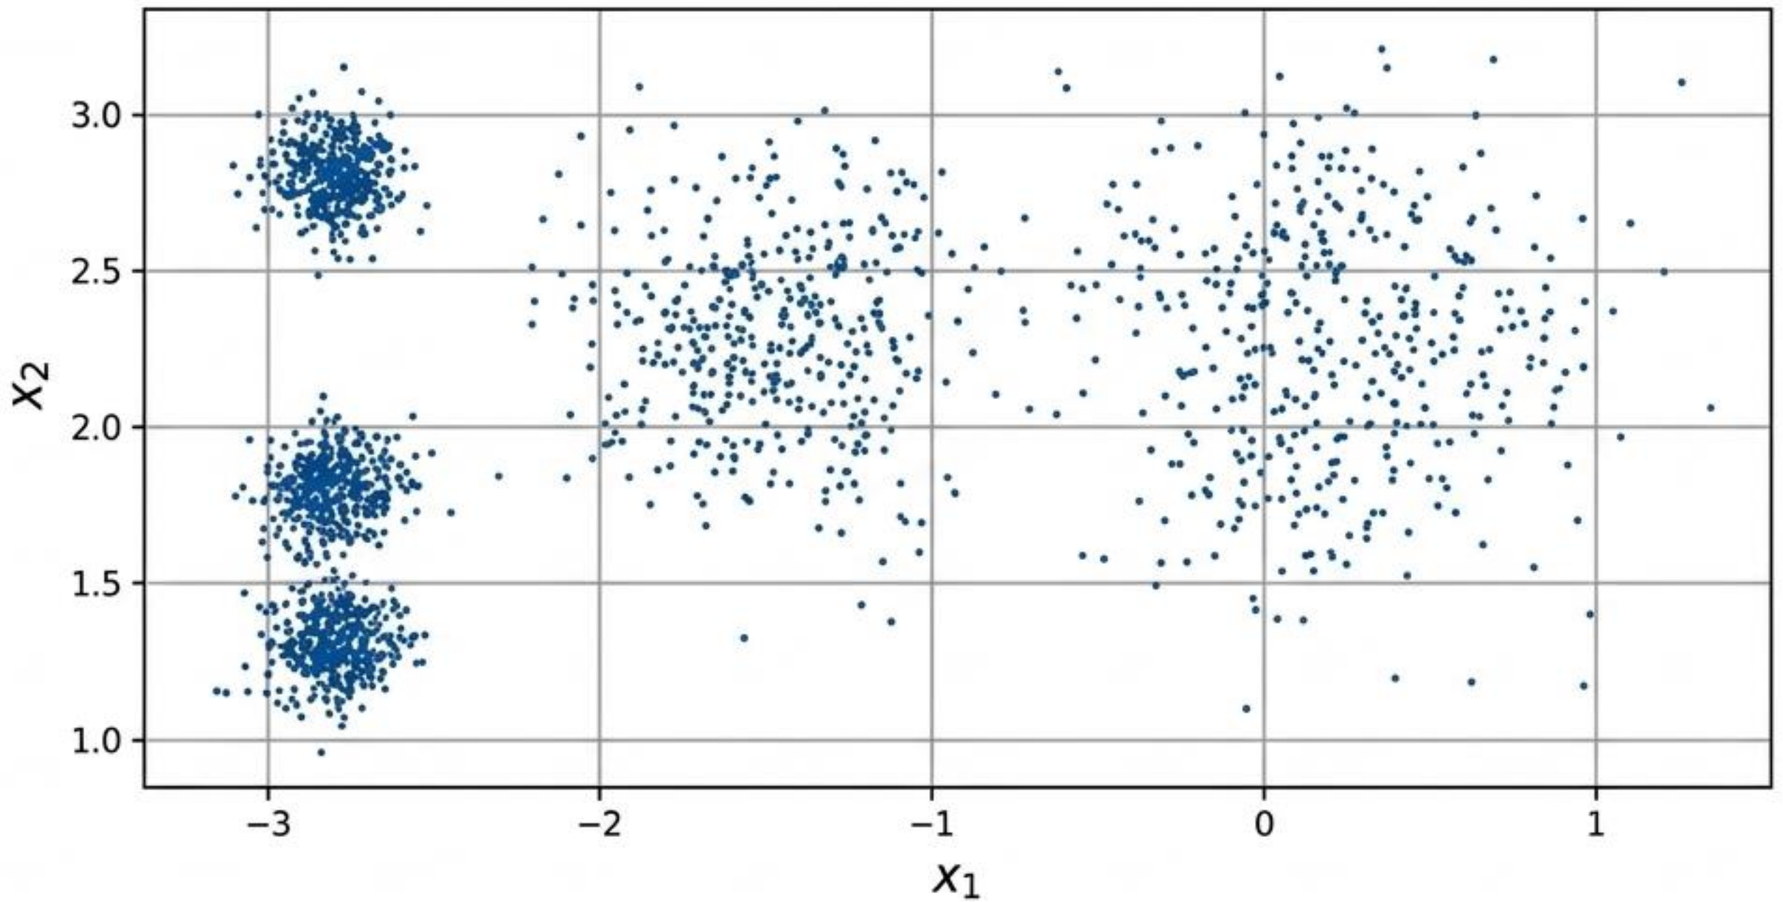
Được đề xuất đầu tiên vào năm 1957 bởi Stuart Lloyd tại Bell Labs.



Người dùng phải định nghĩa trước số lượng cụm (tham số k).

Gemini Notebook

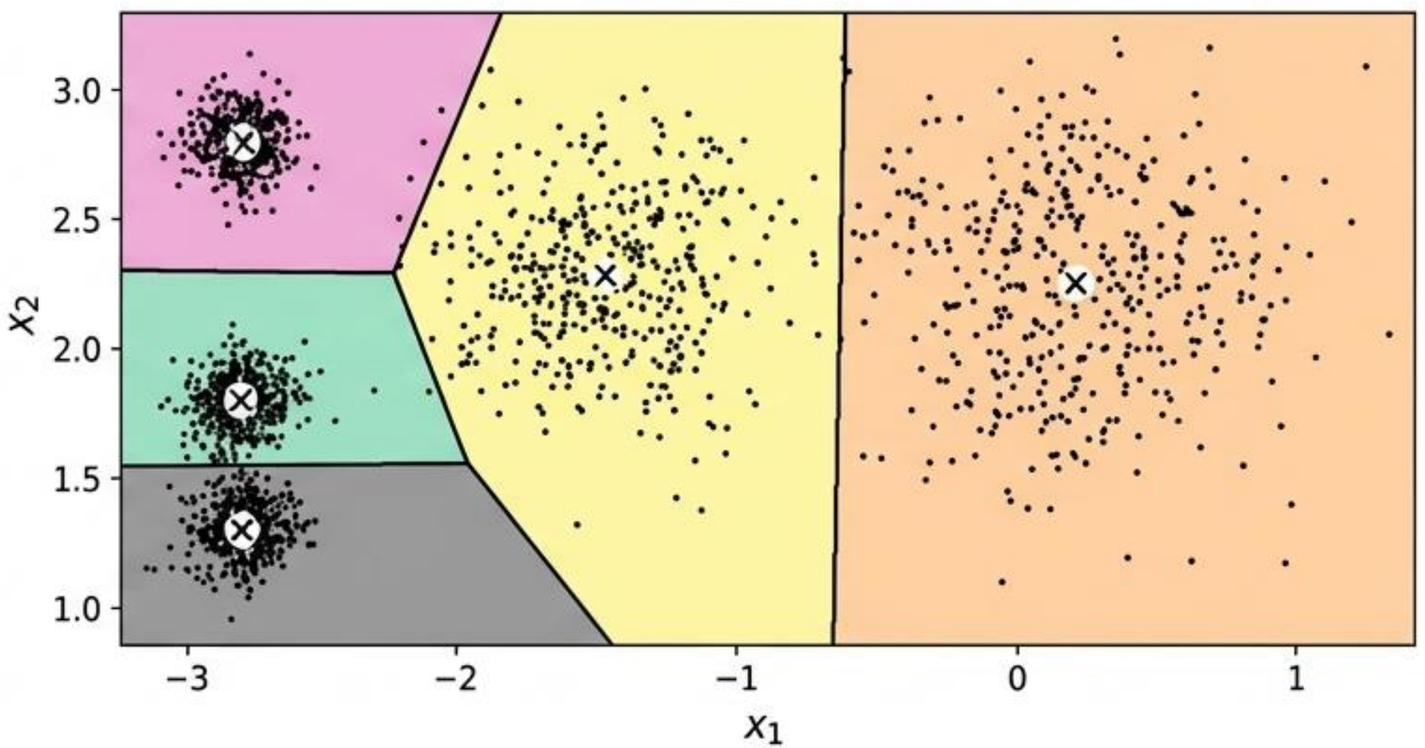
Tập dữ liệu chưa gán nhãn gồm 5 khối



Hình 9-2. Một tập dữ liệu không được gắn nhãn bao gồm 5 khối trường hợp rõ rệt

Gemini Notebook

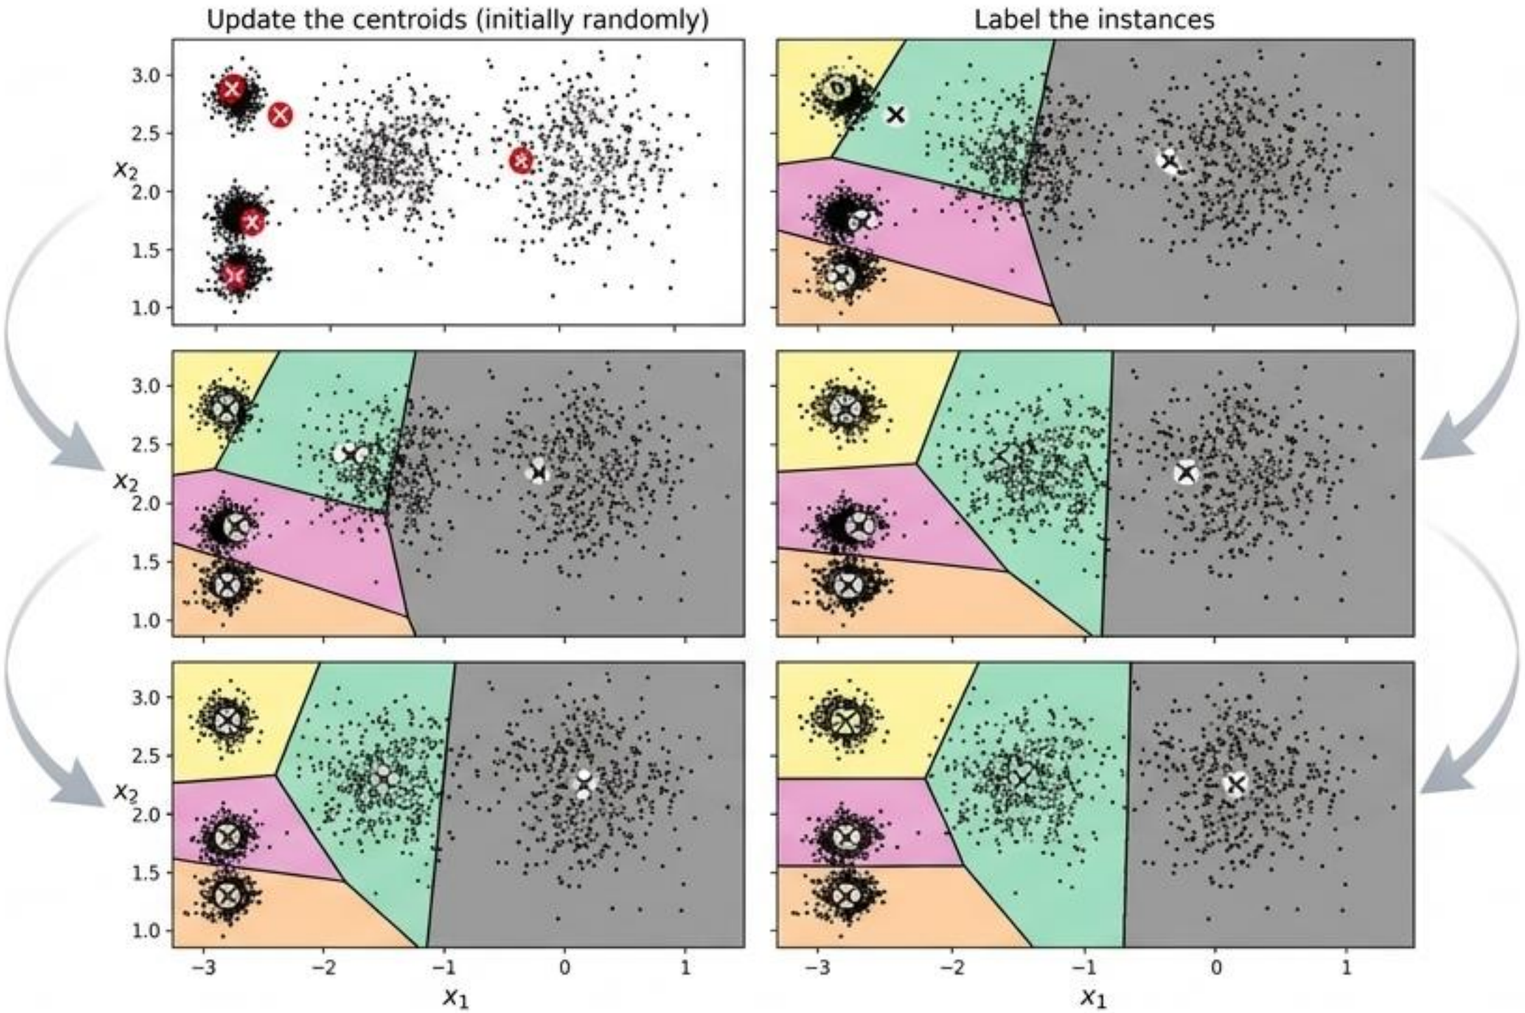
Phép phân vùng Voronoi của K-Means



Hình 9-3. K-Means chia không gian bằng phép phân vùng Voronoi (đường biên quyết định)

Gemini Notebook

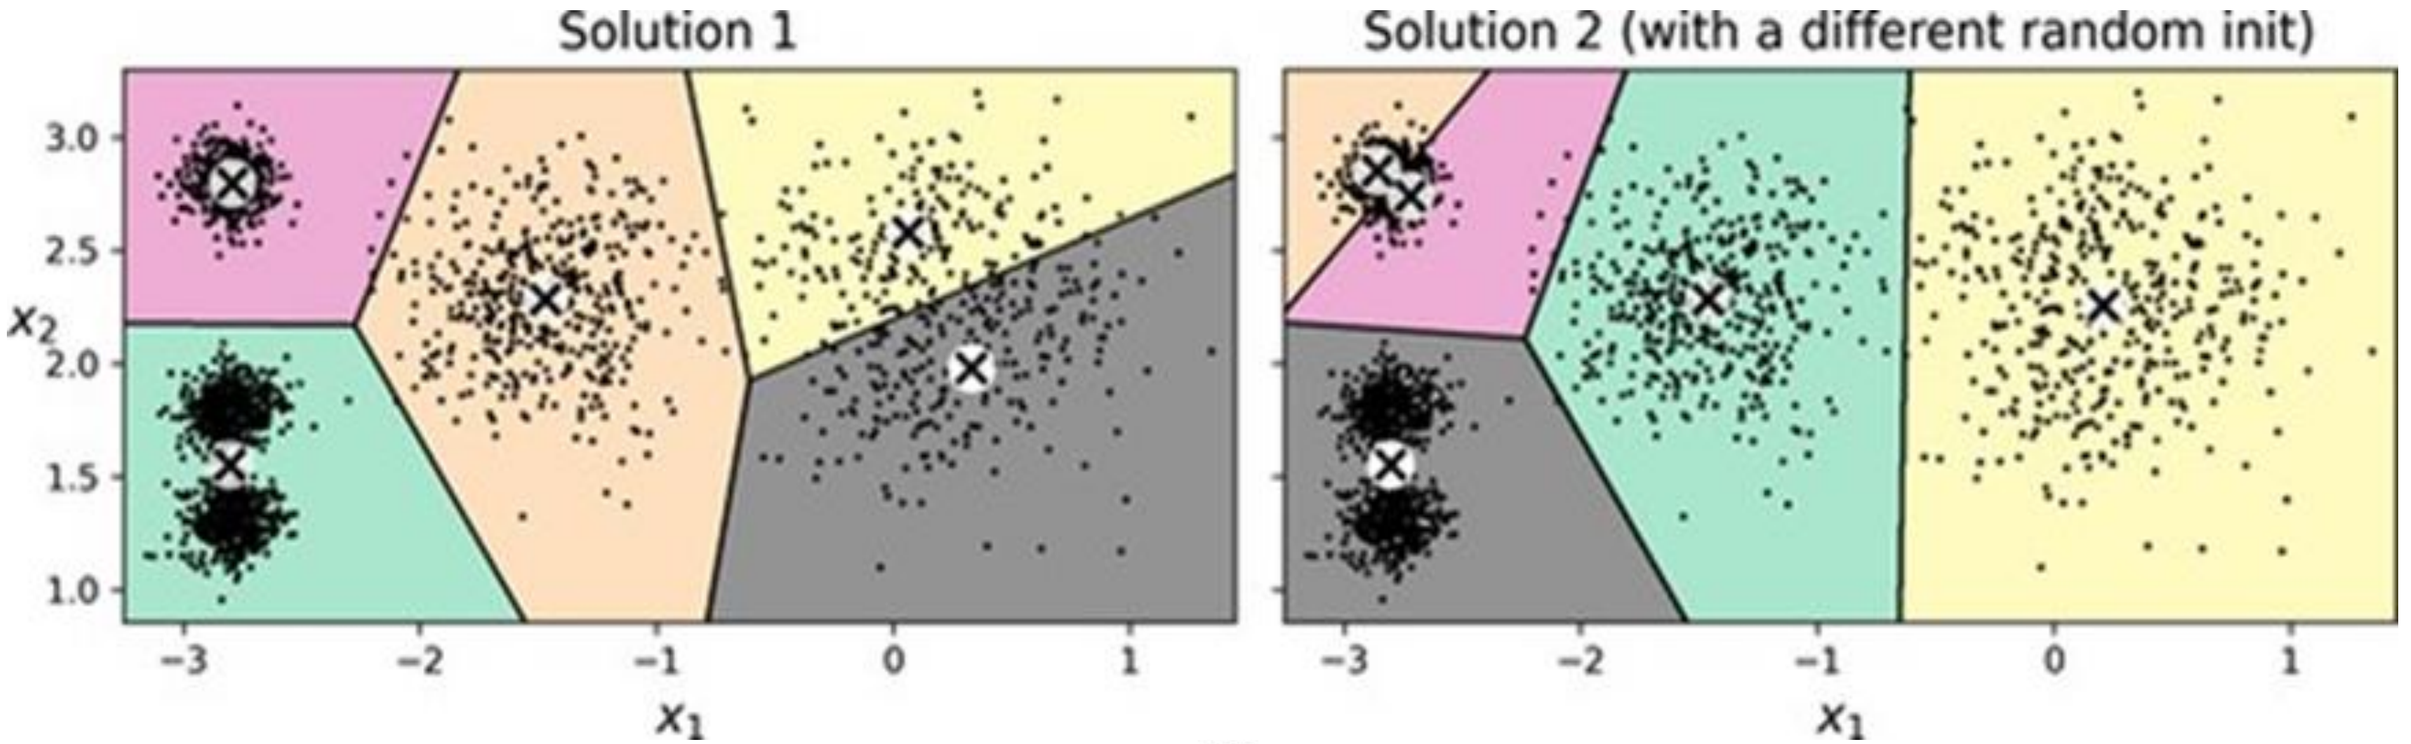
Cách thuật toán K-Means hoạt động



Hình 9-4. Khởi tạo ngẫu nhiên tâm cụm → Gán điểm cho cụm → Cập nhật tâm cụm → Lặp lại

Gemini Notebook

Vấn đề khởi tạo tâm cụm ngẫu nhiên



Hình 9-5. *K-Means có thể kẹt ở điểm tối ưu cục bộ nếu khởi tạo tâm cụm ngẫu nhiên không may mắn*

Gemini Notebook

Quán tính (Inertia) là gì?

Bài toán



Làm sao để biết một mô hình K-Means tốt hơn mô hình khác? (Do không có nhãn để tính độ chính xác).

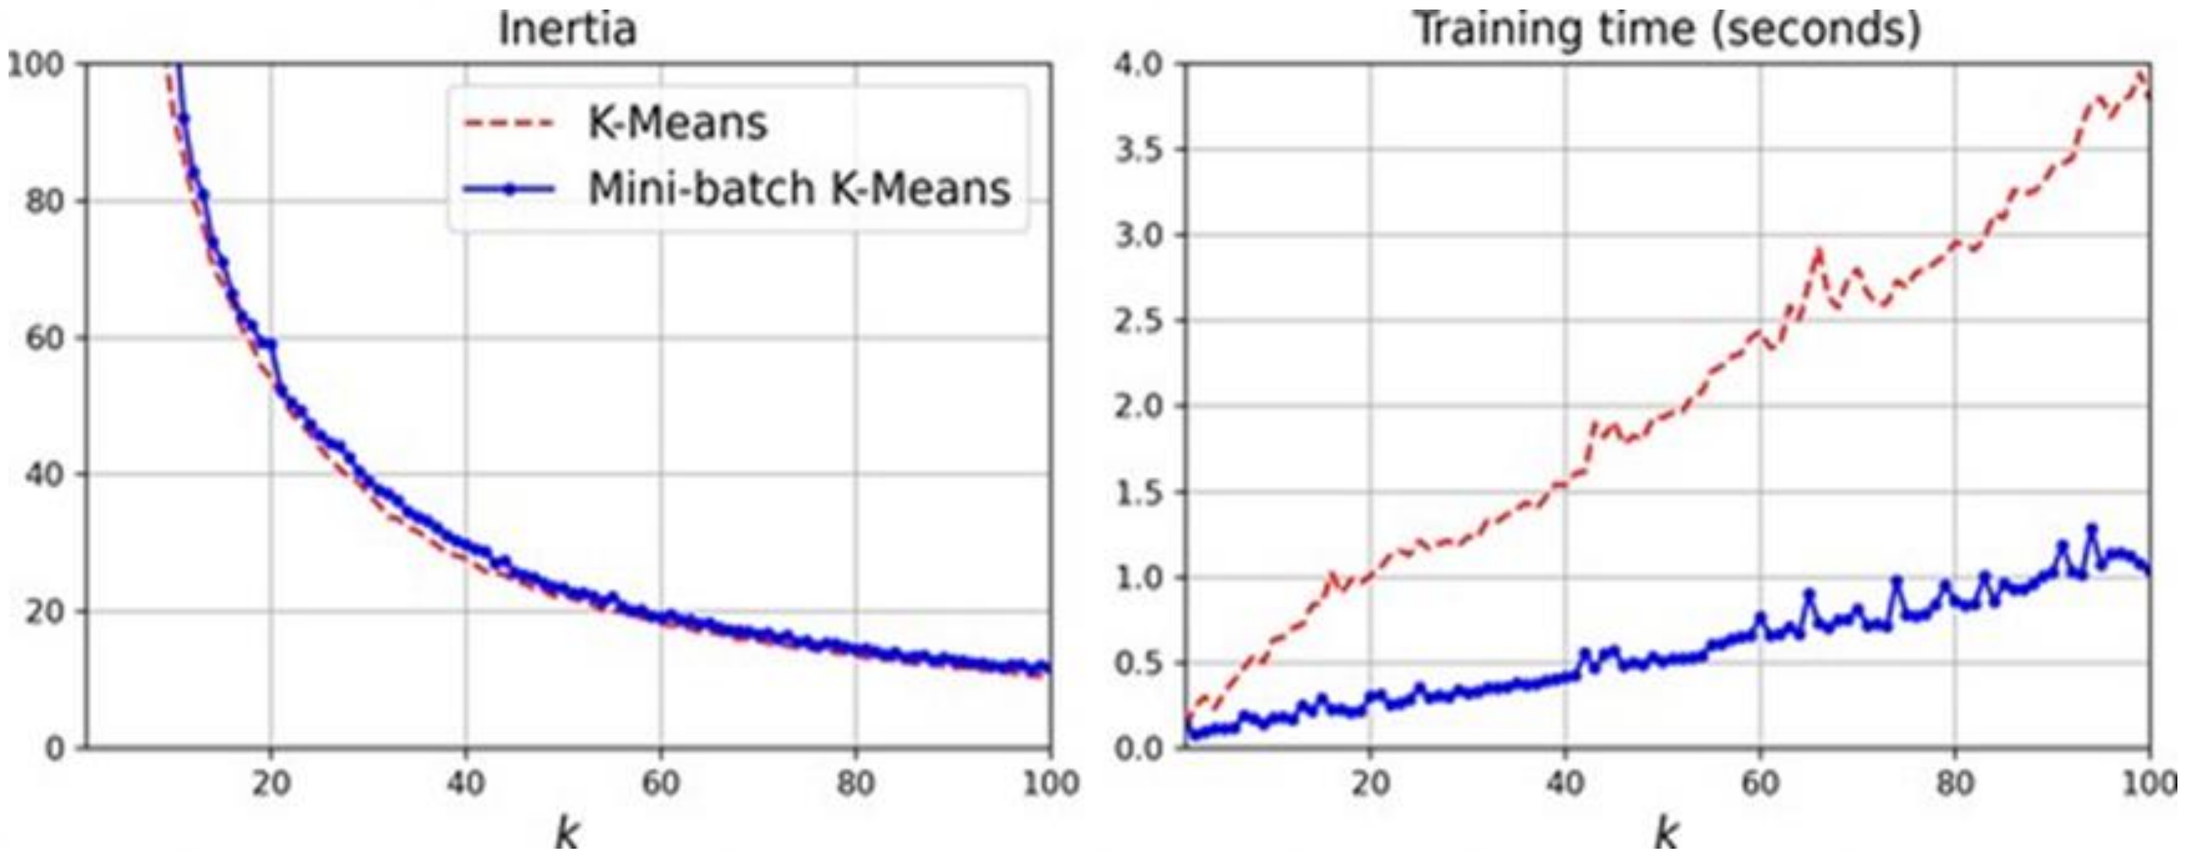
Dùng **Quán tính (Inertia):** Tổng khoảng cách bình phương từ mỗi điểm dữ liệu đến tâm cụm gần nhất của nó. Mục tiêu của K-Means chính là tối thiểu hóa Quán tính.

Giải pháp

K-Means++ (mặc định **trong** Scikit-Learn) dùng **thuật toán khởi tạo thông minh** để tránh bị **kẹt ở điểm tối ưu cục bộ.**

Gemini Notebook

Quán tính giảm theo các vòng lặp

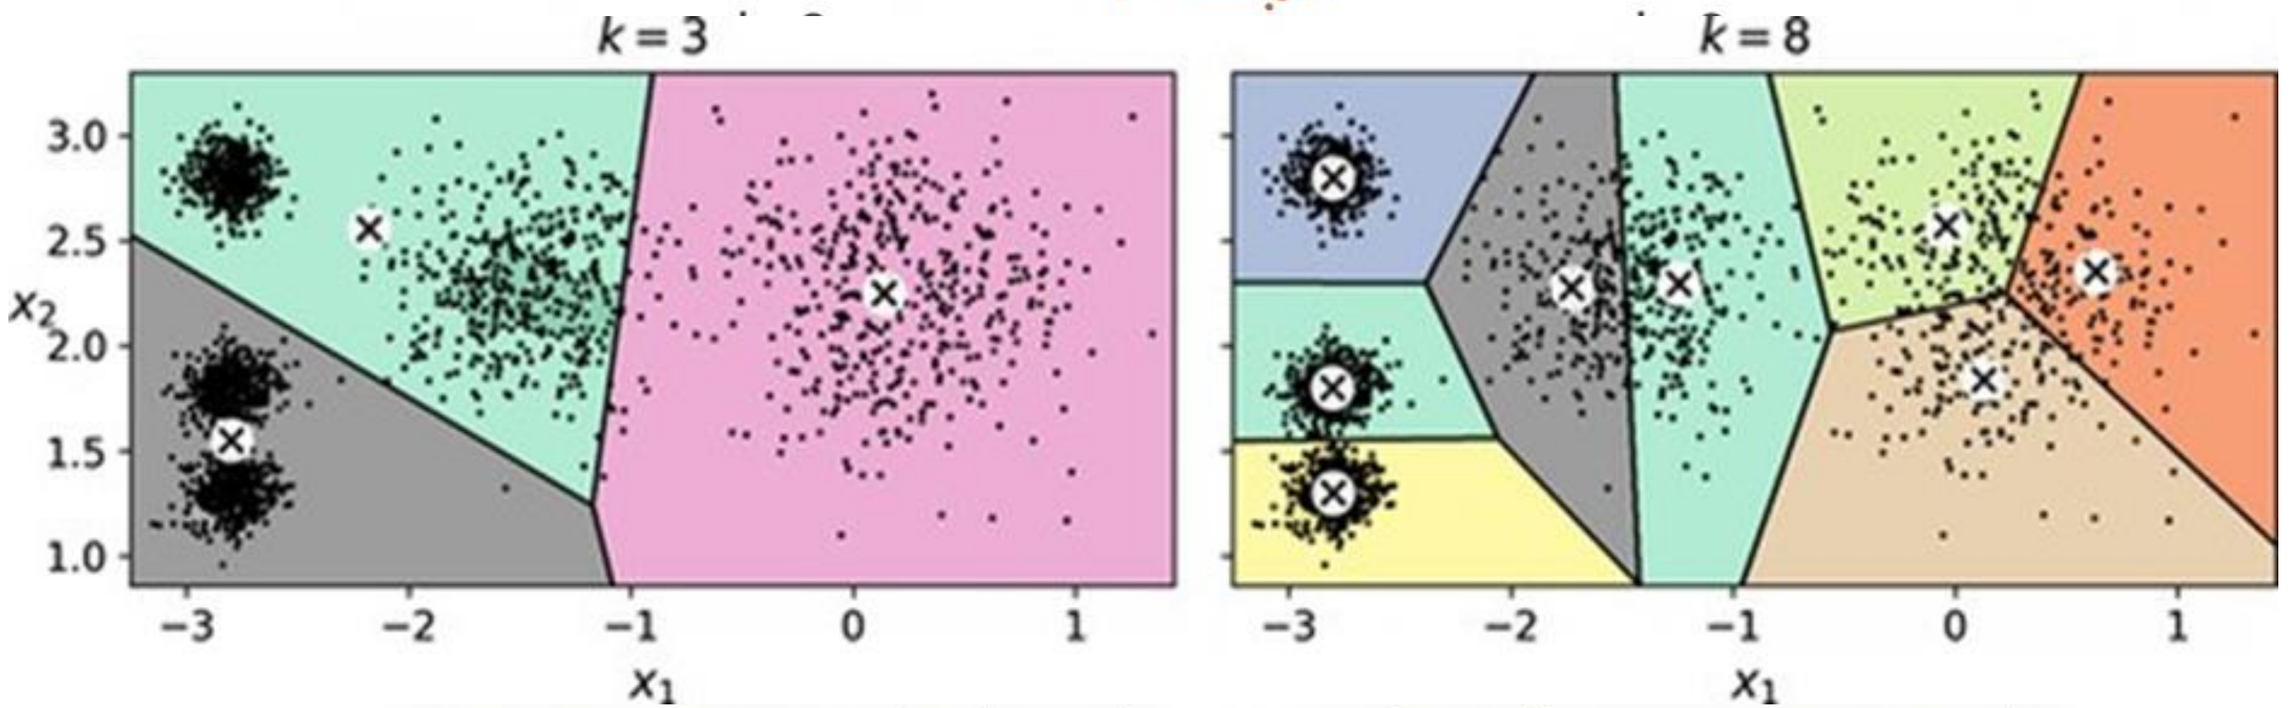


Hình 9-6. Quán tính giảm nhanh qua các bước lặp K-Means

Gemini Notebook

Hậu quả của việc chọn số lượng cụm (k) sai

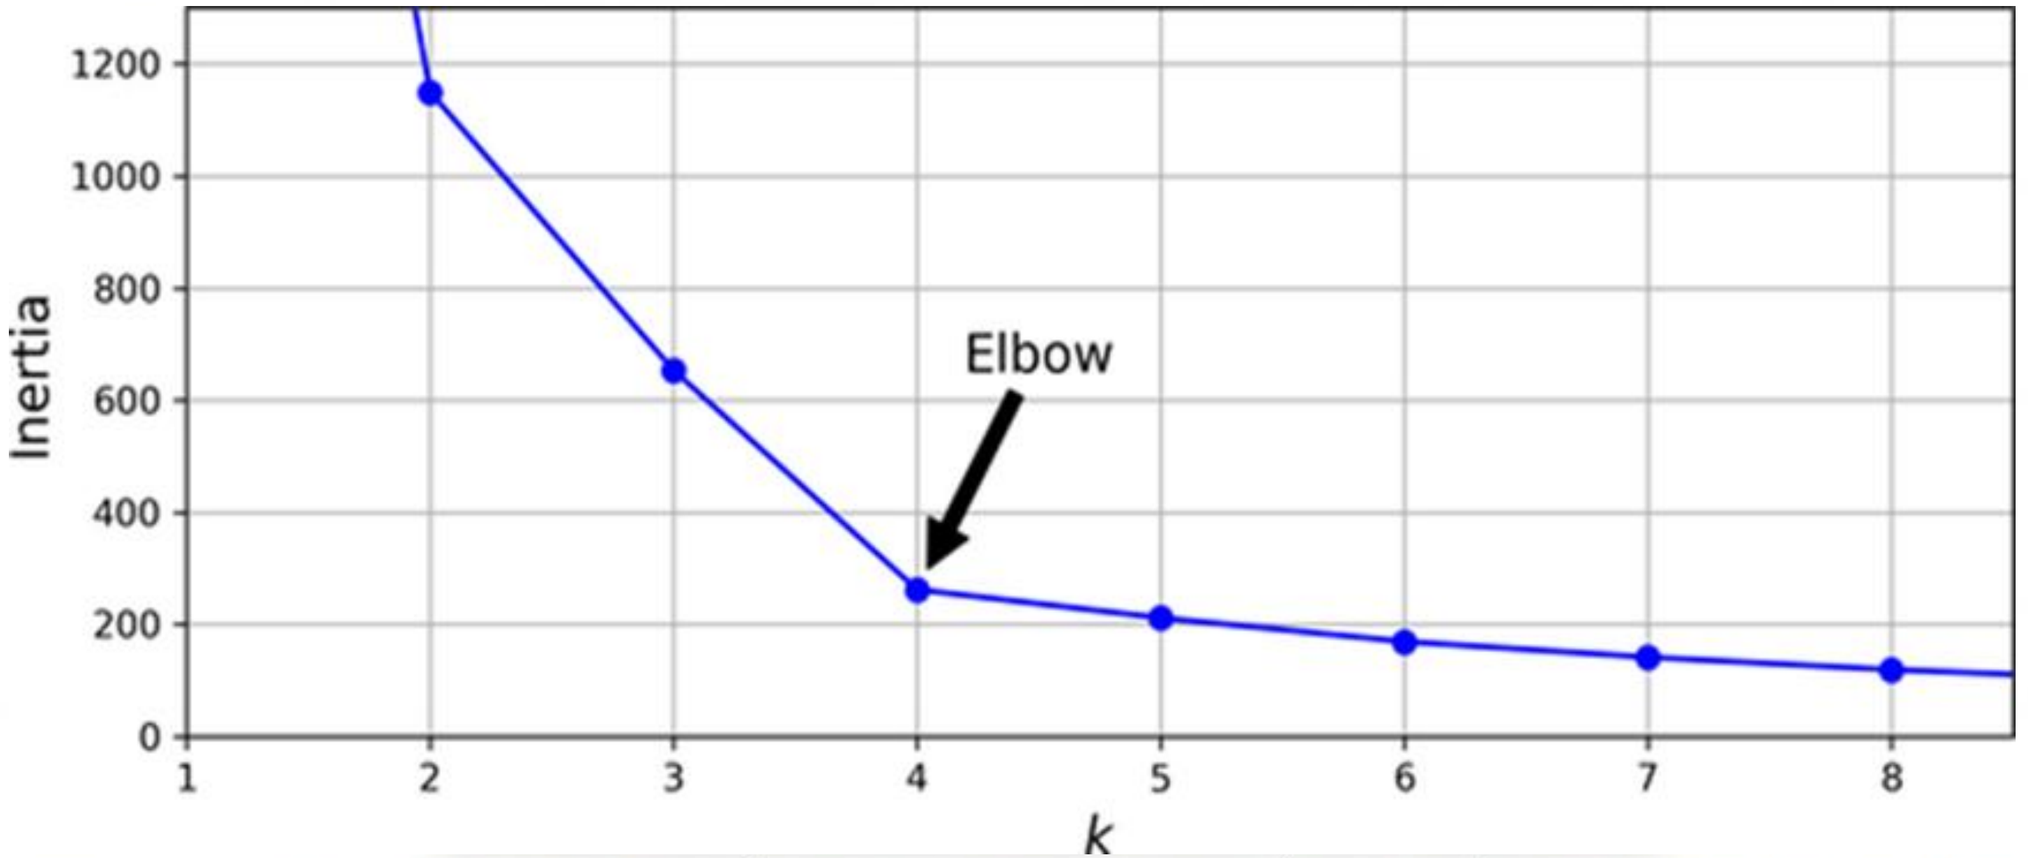




Hình 9-7. Chọn k=3 (thiếu cụm) hoặc k=8 (chia cắt quá mức cụm thực)

Gemini Notebook

Lựa chọn số cụm bằng phương pháp khuỷu tay (Elbow)



*Hình 9-8. Vẽ Quán tính theo số lượng cụm k. Chọn điểm "khuỷu tay" (**k* = 5** hoặc **k* = 4**)*

Gemini Notebook

Đánh giá chất lượng bằng điểm Silhouette

Phương pháp ”khuỷu tay” quá thô sơ. Đánh giá điểm Silhouette (Silhouette Score) chính xác hơn.



a: Khoảng cách trung bình đến các điểm trong cùng cụm.

$$s = \frac{(b-a)}{\max(a,b)}$$



b: Khoảng cách trung bình đến các điểm trong cụm gần nhất tiếp theo.

-1 Điểm có thể bị gán sai cụm.

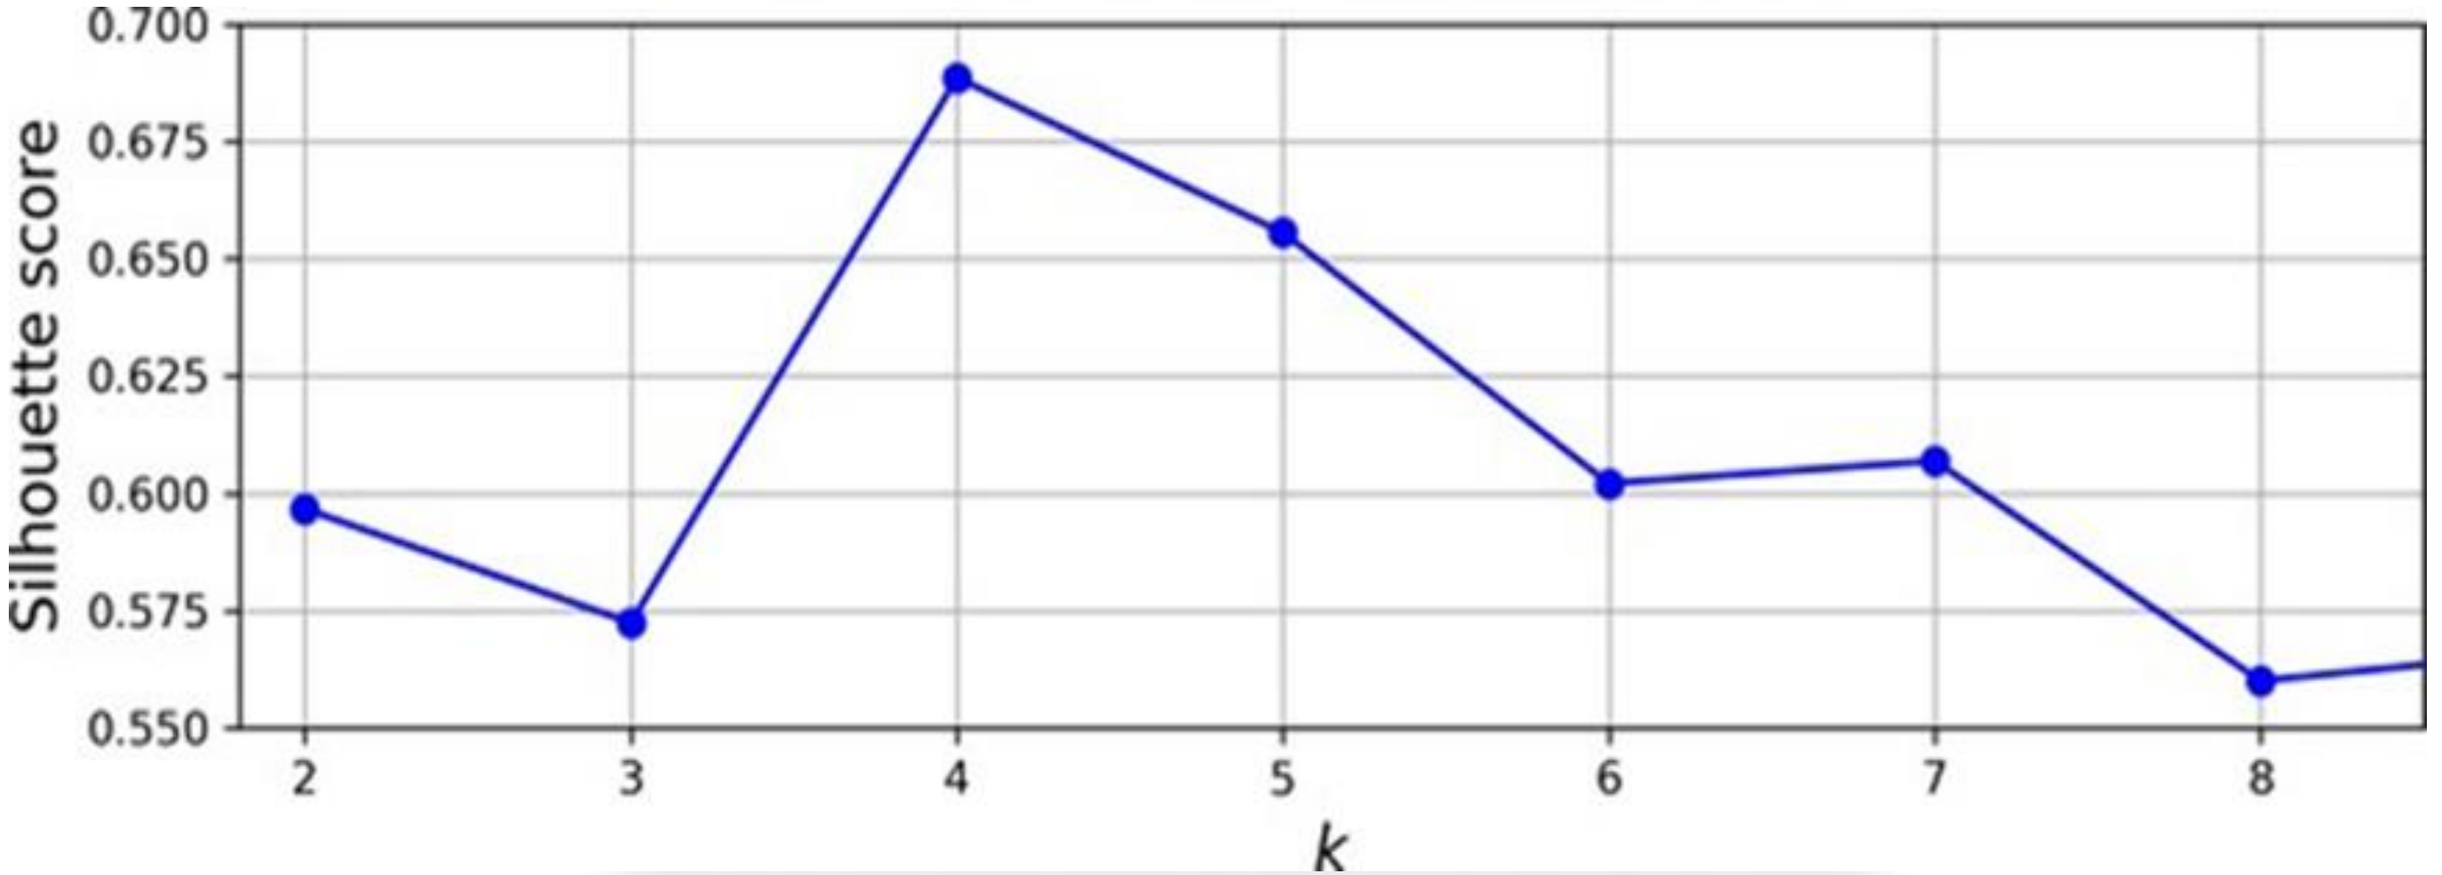
0 Điểm nằm ở rìa cụm.

+1 Điểm nằm sâu trong cụm.



Gemini Notebook

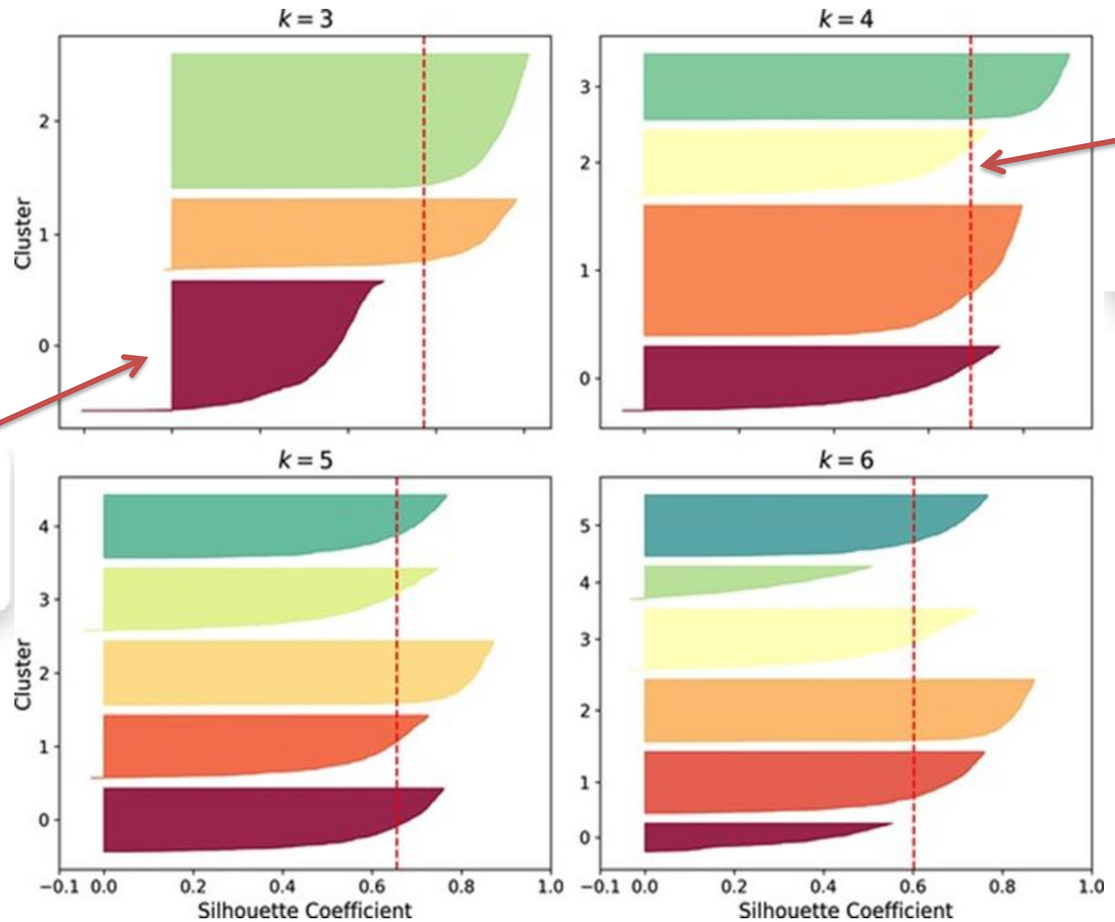
Biểu đồ điểm Silhouette theo k



Hình 9-9. Chọn số lượng cụm k tối ưu (đỉnh cao nhất, ví dụ k = 4 hoặc k = 5)

Gemini Notebook

Phân tích biểu đồ dao (Silhouette plots)



Hình 9-10. *Hình dao cho mỗi cụm. Dao càng rộng, cụm càng tốt. Ranh giới đỏ là điểm Silhouette trung bình.*

Gemini Notebook

Giới hạn của K-Means

Cần chạy thuật toán nhiều lần để tránh tối ưu cục bộ.

Phải chỉ định trước số cụm k.



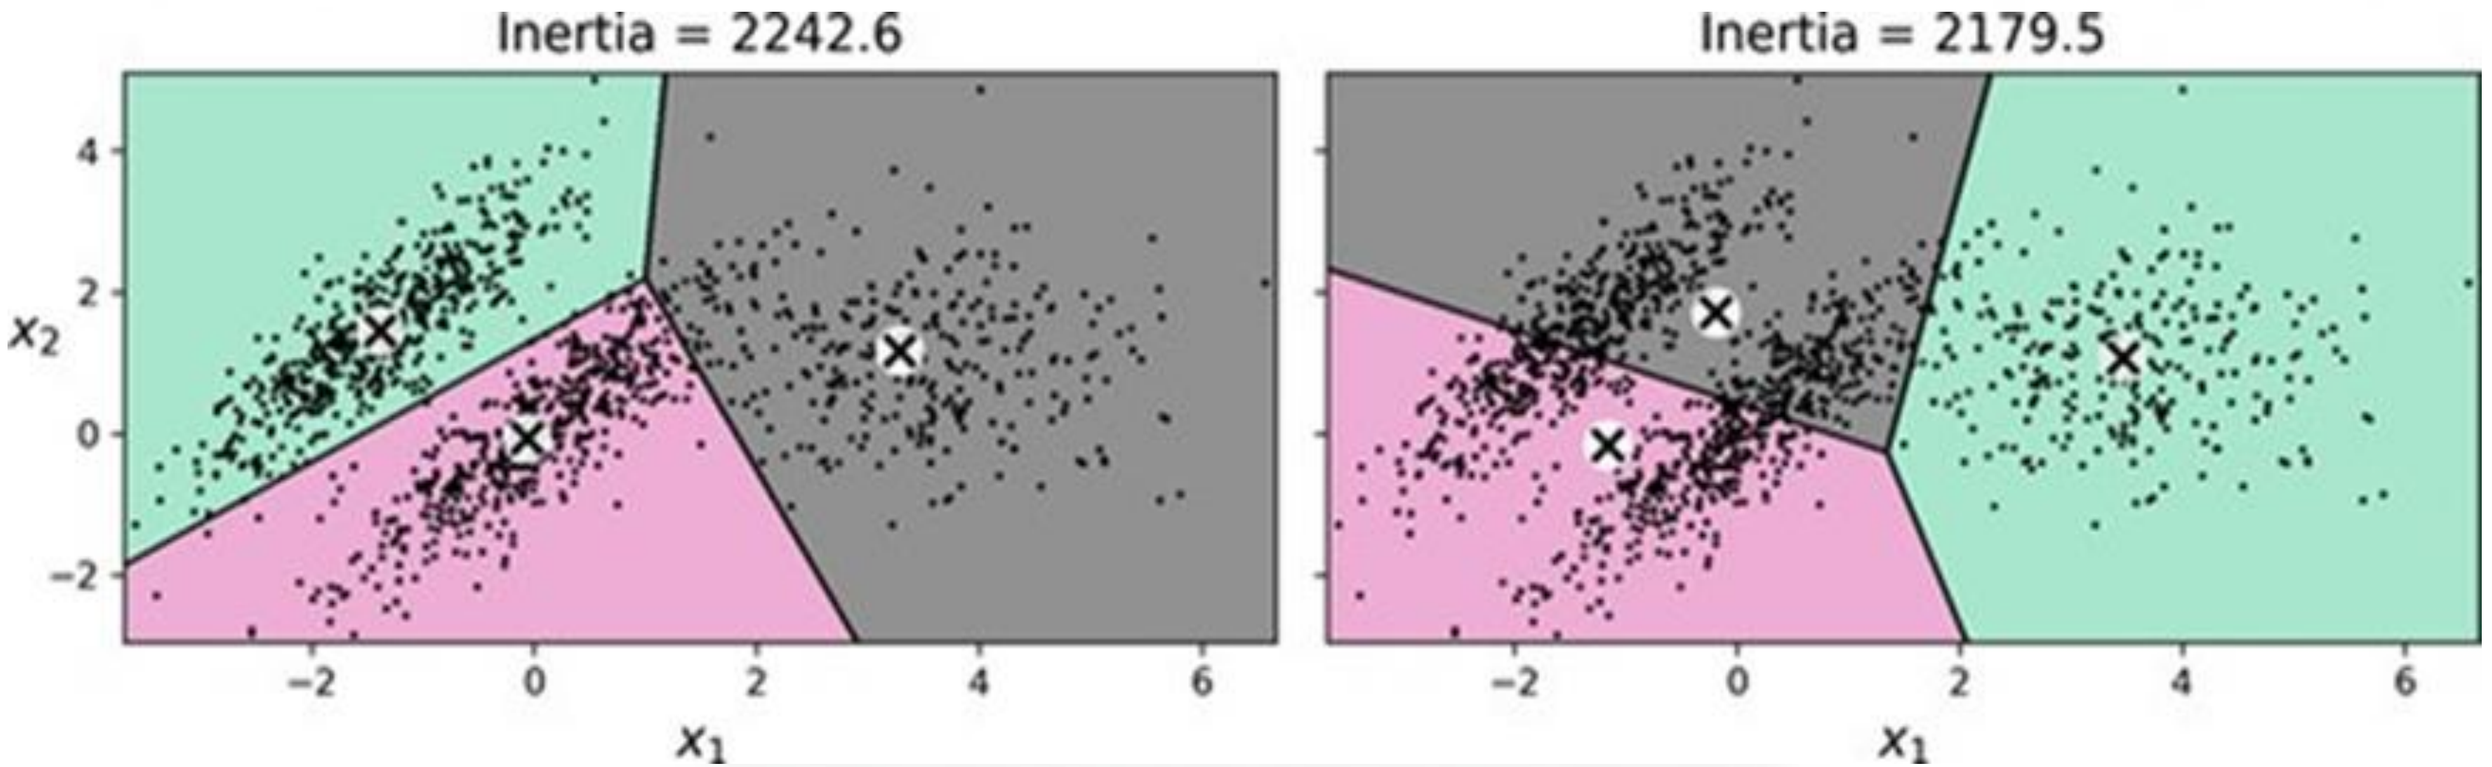
Nhược điểm lớn nhất: K-Means hoạt động rất kém khi các cụm có **kích thước khác nhau nhiều**, mật độ khác nhau, hoặc hình dạng không phải hình cầu (ví dụ: hình elip).



Lý do: K-Means chỉ quan tâm đến khoảng cách tới tâm cụm.

Gemini Notebook

K-Means gặp khó khăn với các cụm hình elip



Hình 9-11. K-Means phân cụm sai lầm khi cắt ngang khối hình elip tự nhiên

Gemini Notebook

Ứng dụng: Phân đoạn hình ảnh (Image Segmentation)

Phân đoạn hình ảnh: Chia hình ảnh thành nhiều phân đoạn. Ứng dụng phổ biến: Phân đoạn màu sắc.



Tập hợp các pixel của hình ảnh.



Nhóm các pixel có màu giống nhau vào cùng một cụm K-Means.



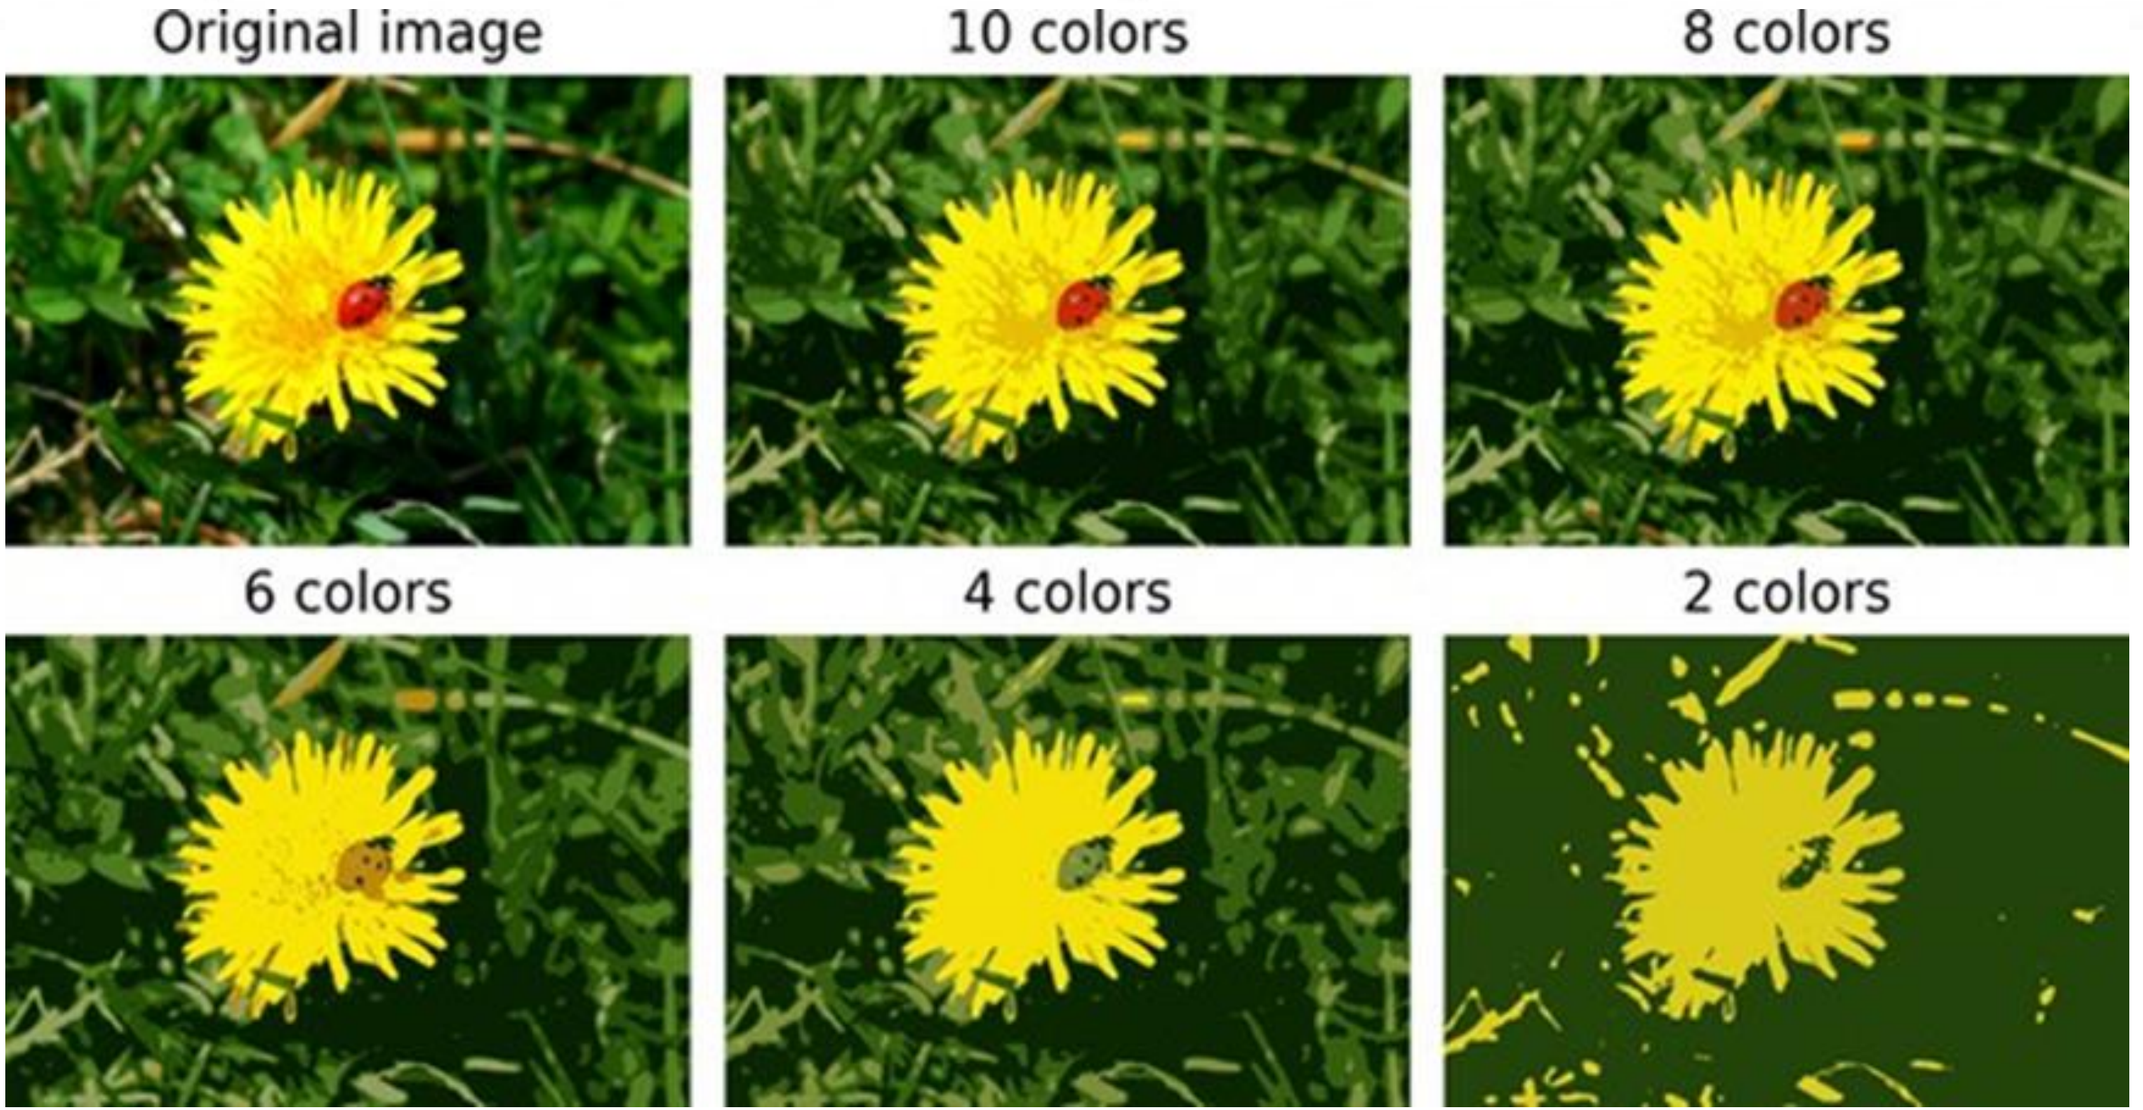
Thay thế giá trị màu của mọi pixel bằng màu của tâm cụm K-Means



giảm số lượng màu xuống k màu, tạo hiệu ứng ảnh như tranh vẽ (Posterization).

Gemini Notebook

Phân đoạn màu sắc hình ảnh bọ rùa

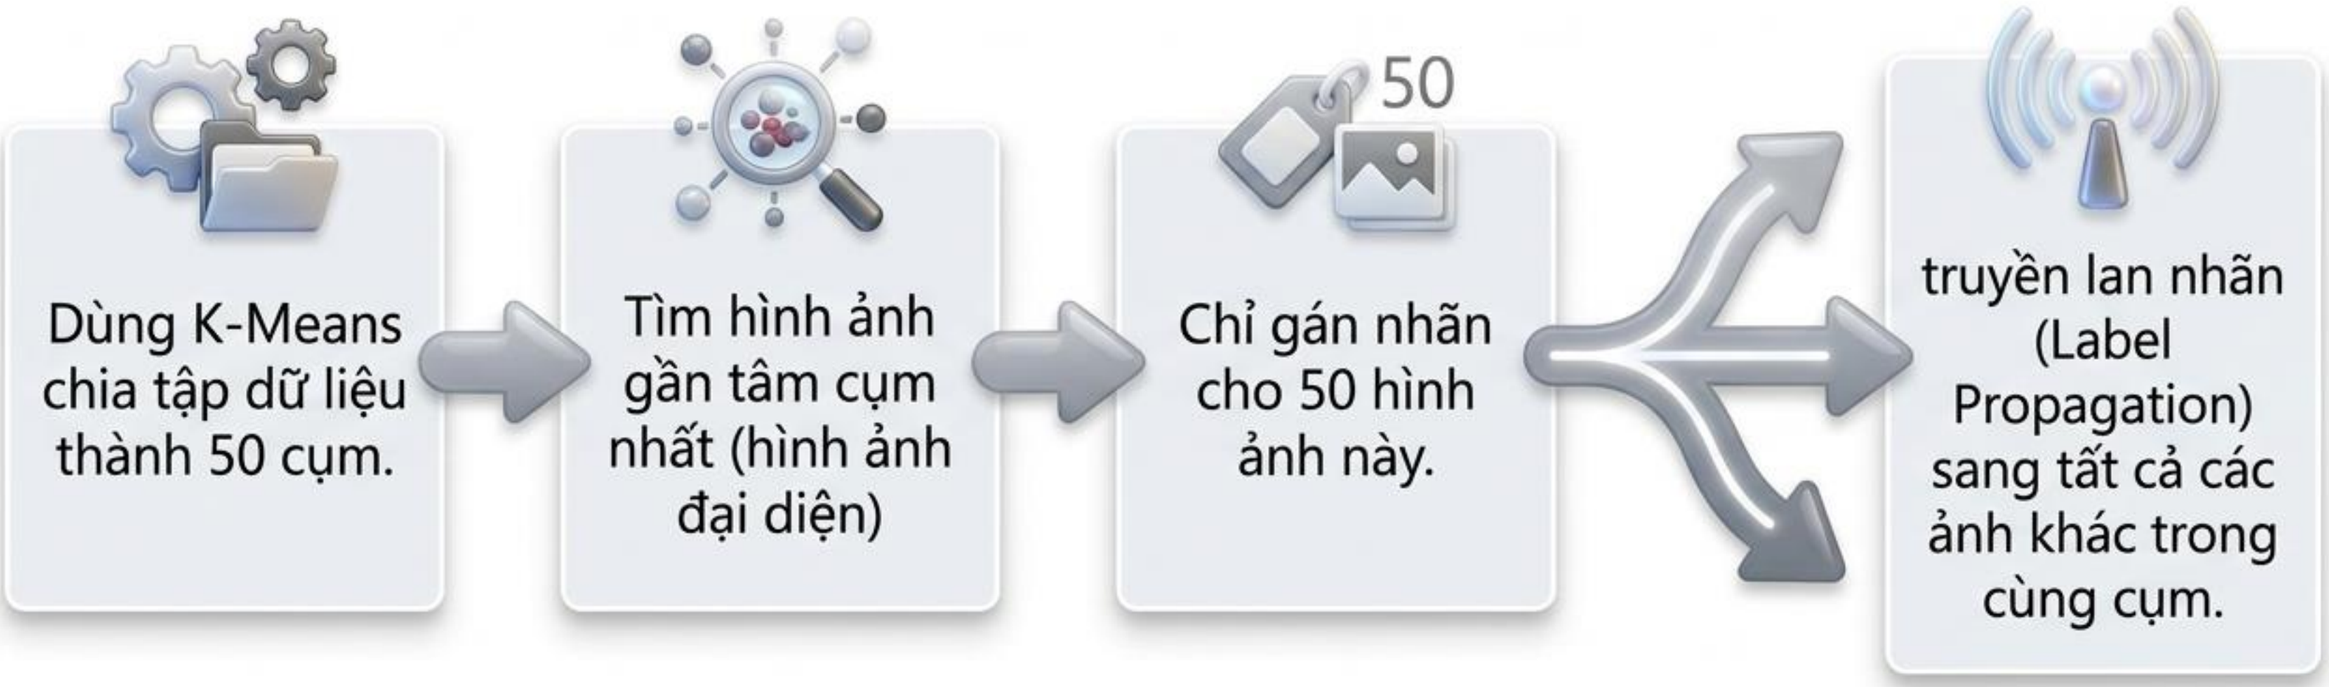


Hình 9-12. Phân đoạn hình ảnh sử dụng K-means với các số lượng cụm màu khác nhau (k = 10, 8, 6, 4, 2)

Gemini Notebook

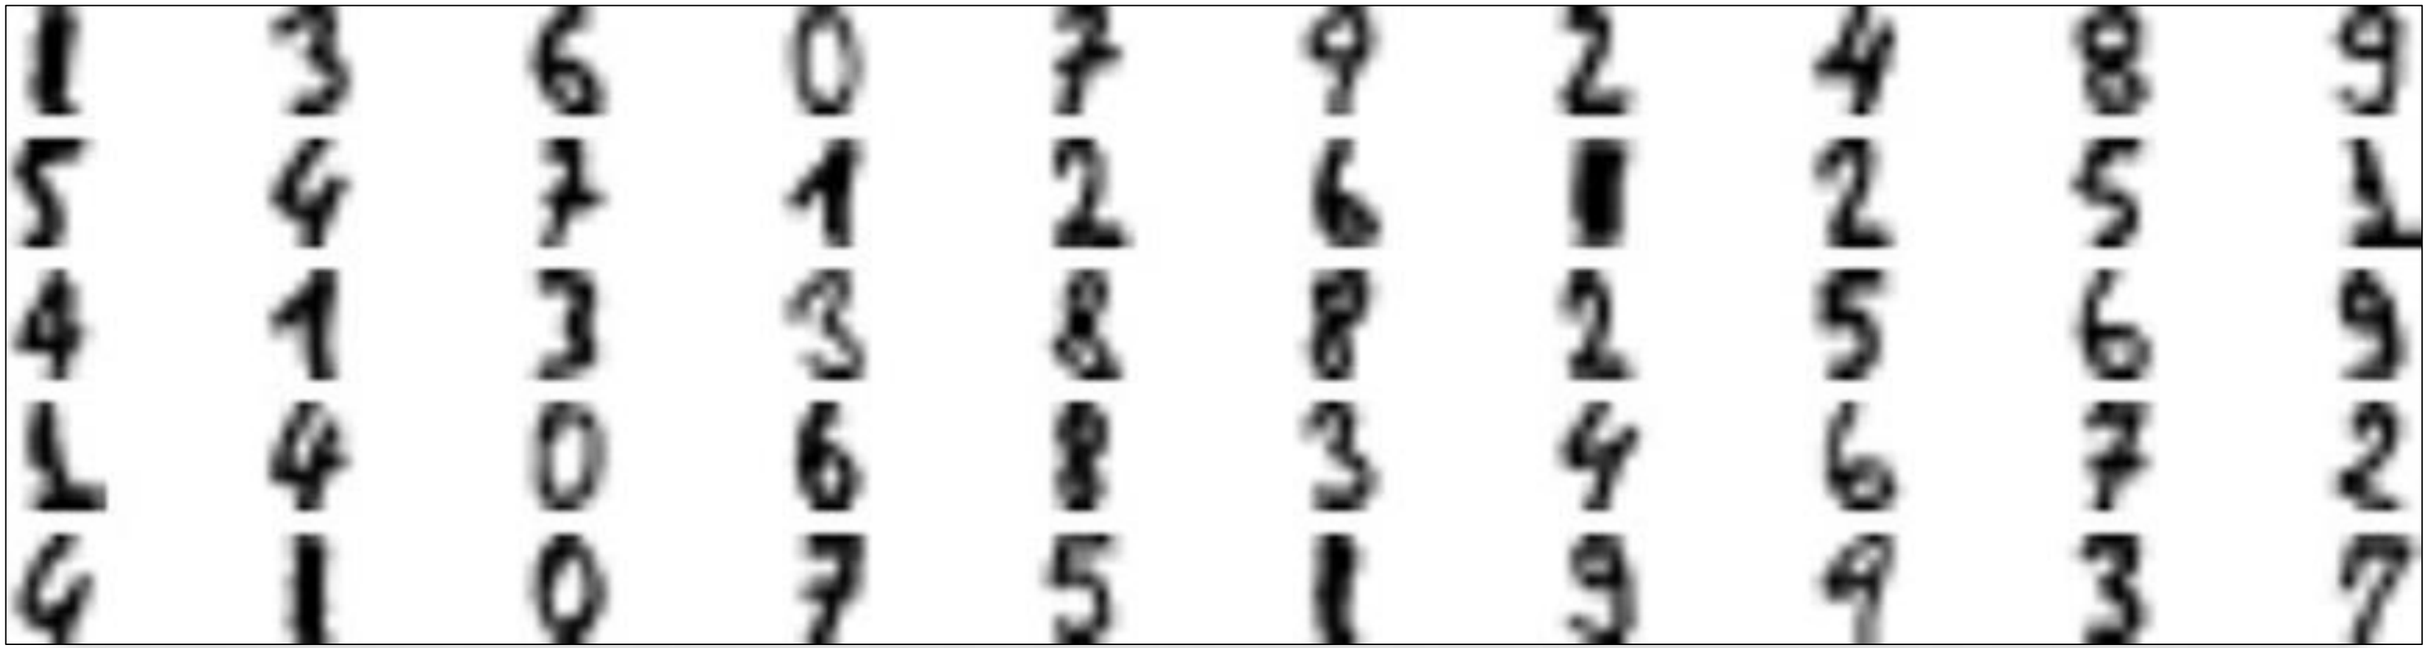
Ứng dụng: Tiền xử lý để học bán giám sát

Khi bạn có rất nhiều dữ liệu nhưng chỉ một phần rất nhỏ có nhãn (vd: chỉ gán nhãn được 50 tấm ảnh MNIST). Thay vì gán nhãn 50 ảnh ngẫu nhiên...



Gemini Notebook

Lấy 50 hình ảnh đại diện bằng K-Means

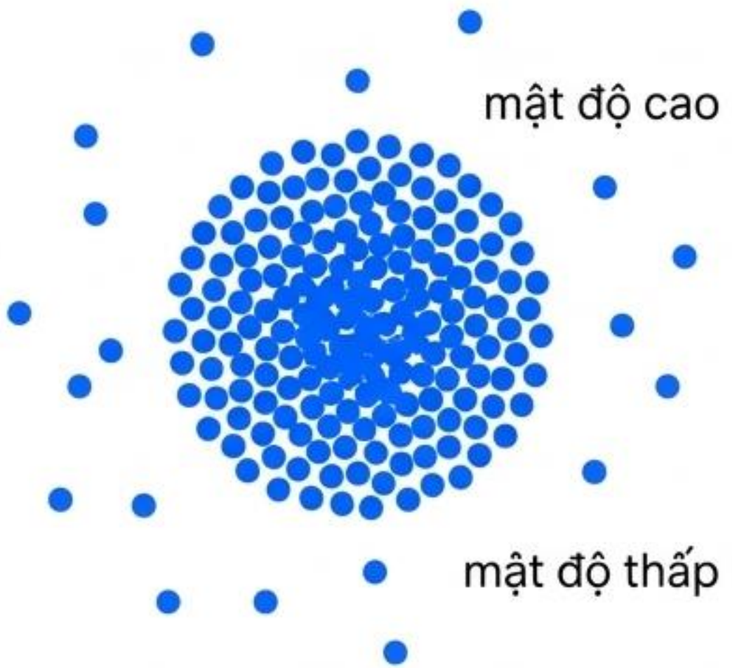


Hình 9-13. 50 hình ảnh chữ số đại diện (một hình ảnh cho mỗi cụm). Việc gán nhãn chúng mang lại ý nghĩa cao hơn chọn ngẫu nhiên.

Gemini Notebook

Thuật toán phân cụm DBSCAN

Density-Based Spatial Clustering of Clustering of Applications with Noise



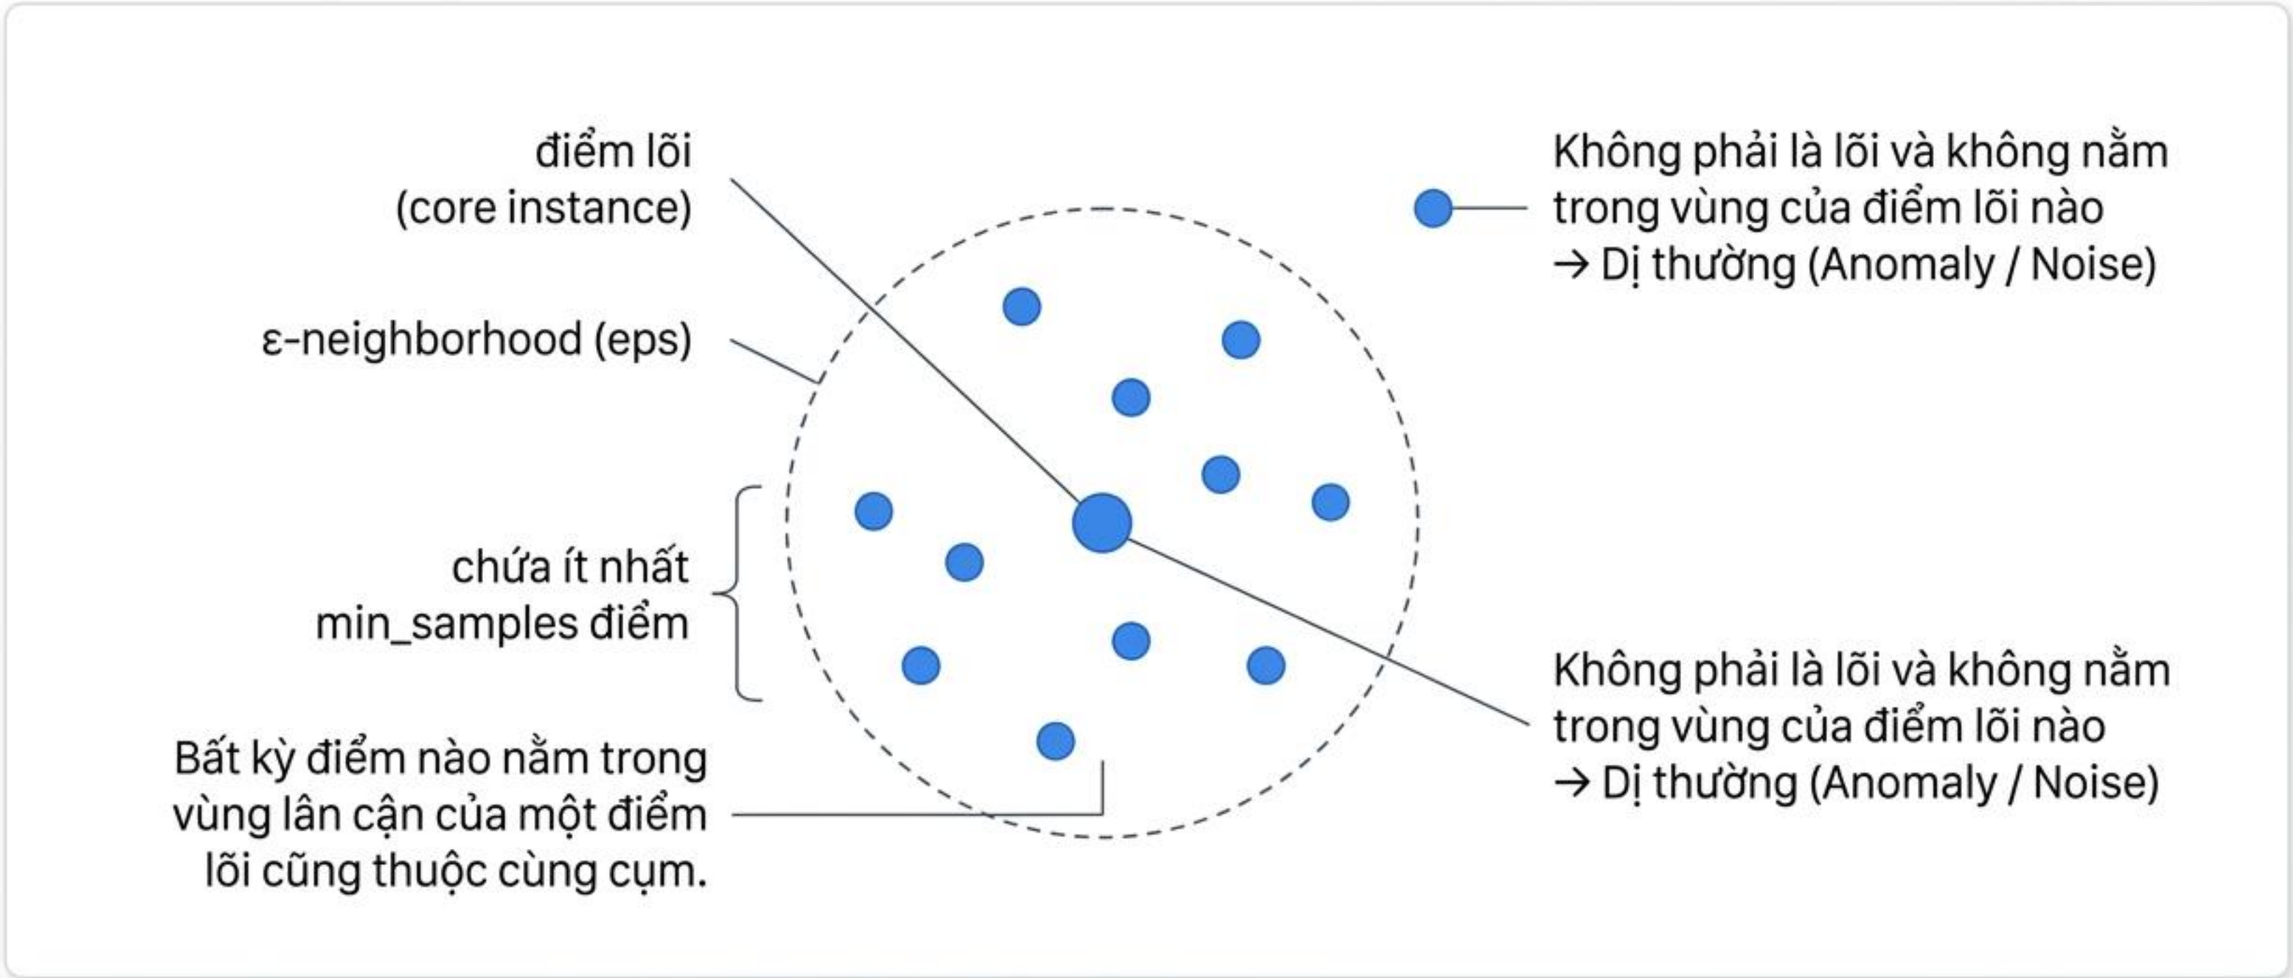
Dựa trên ý tưởng các cụm là các khu vực có mật độ cao phân tách bởi khu vực có mật độ thấp.

🔍 Xác định được các cụm có hình dạng tùy ý

✔ Có thể phát hiện điểm ngoại lai (nhiễu)

Gemini Notebook

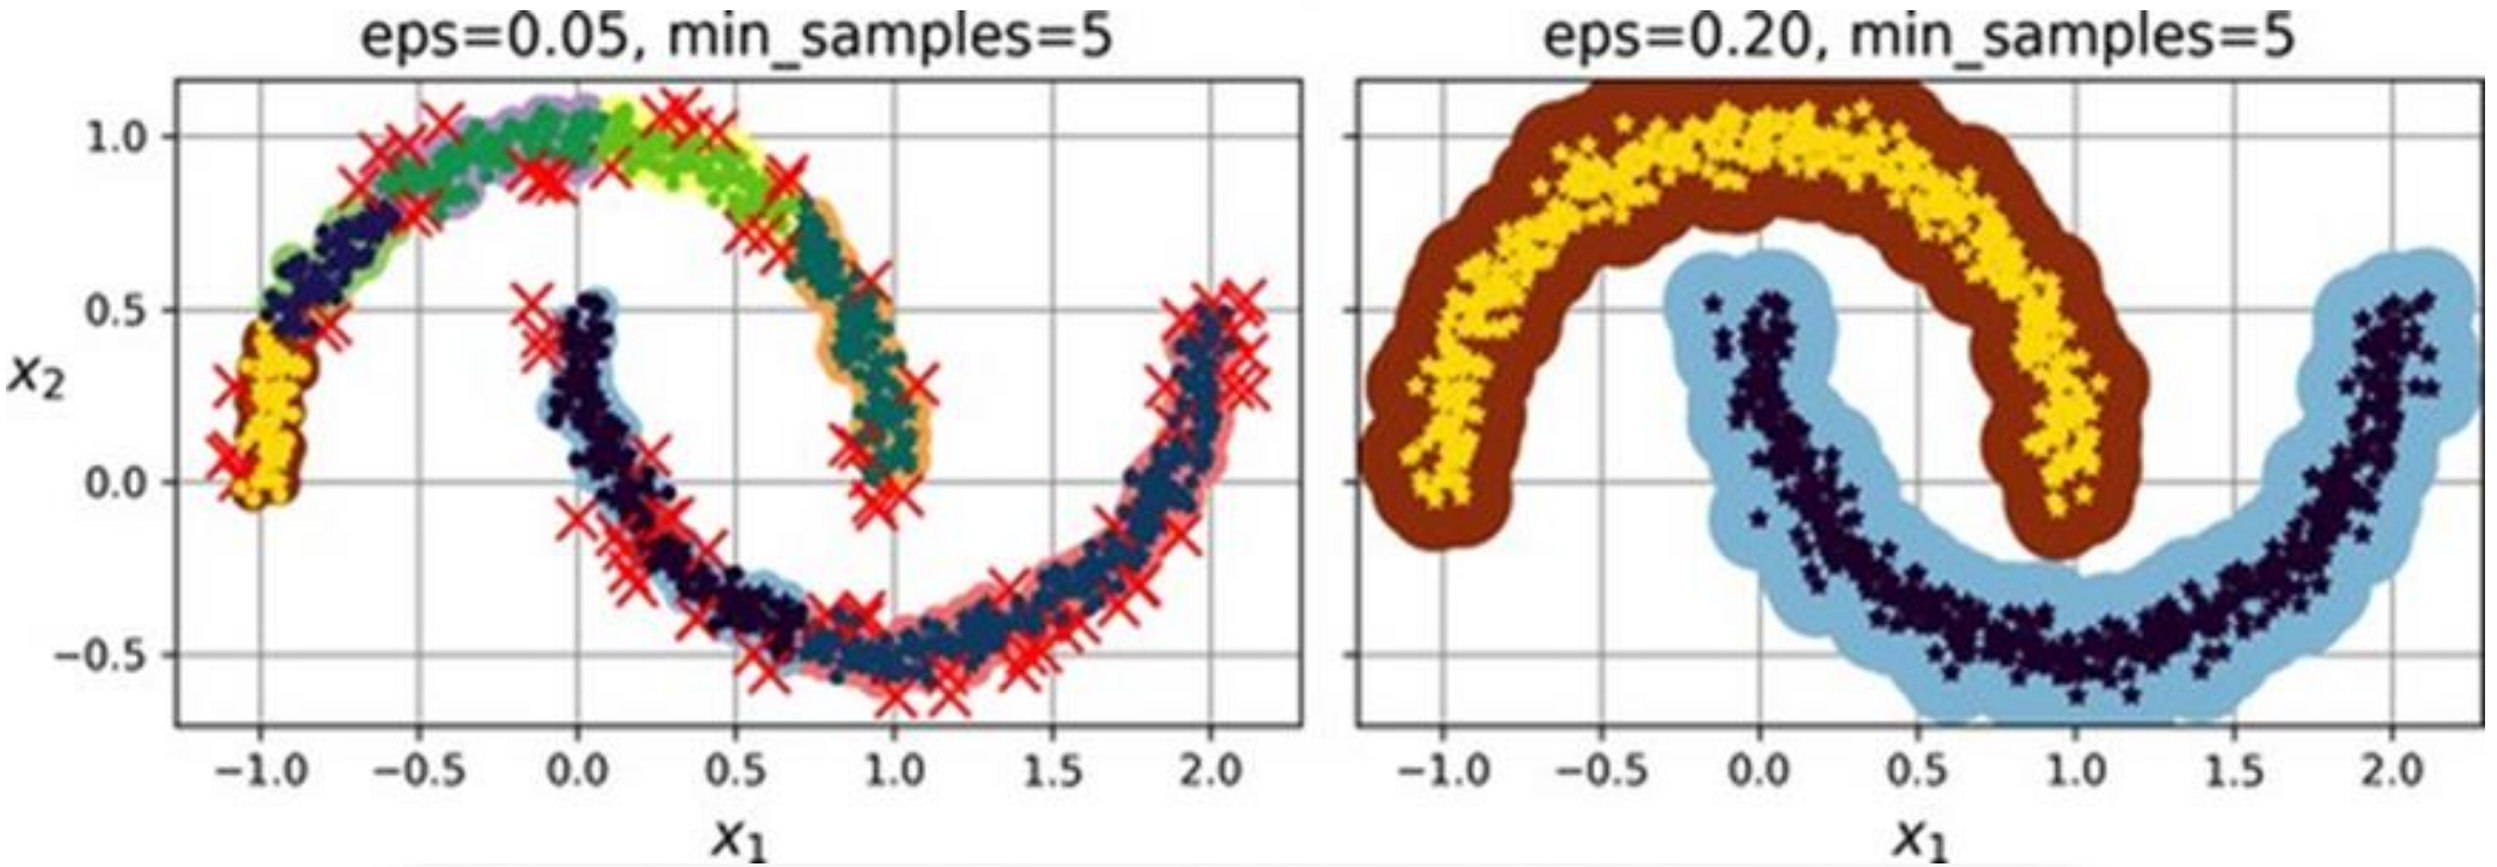
Cơ chế hoạt động của DBSCAN



(Các điểm lõi gần nhau kết hợp lại thành cụm lớn)

Gemini Notebook

DBSCAN với 2 bán kính vùng lân cận khác nhau



Hình 9-14. DBSCAN bắt được hình dạng "mặt trăng" cực tốt. eps nhỏ (trái) tạo nhiều cụm đứt gãy. eps lớn hơn (phải) tạo ra 2 cụm hoàn hảo.

Gemini Notebook

Ưu điểm và nhược điểm của DBSCAN

Ưu điểm:

- ✔ Không cần khai báo số cụm k trước.
- ✔ Kháng nhiễu cực tốt (tự phát hiện và loại bỏ điểm ngoại lai).
- ✔ Tìm được cụm có hình dạng hình học phức tạp (chữ U, hình vành khăn, mặt trăng...).

Nhược điểm:

- ✘ DBSCAN không có phương thức predict(), nó không thể tự gán cụm cho một trường hợp mới sinh ra.
- ✘ Kém hiệu quả nếu các cụm trong tập dữ liệu có mật độ khác biệt nhau quá lớn.

Gemini Notebook

Dự đoán với DBSCAN (Kết hợp KNN)

Vì DBSCAN không có predict(), ta có thể dùng thuật toán phân loại KNN để huấn luyện trên các lõi DBSCAN vừa tìm được.

```
from sklearn.neighbors import KNeighborsClassifier

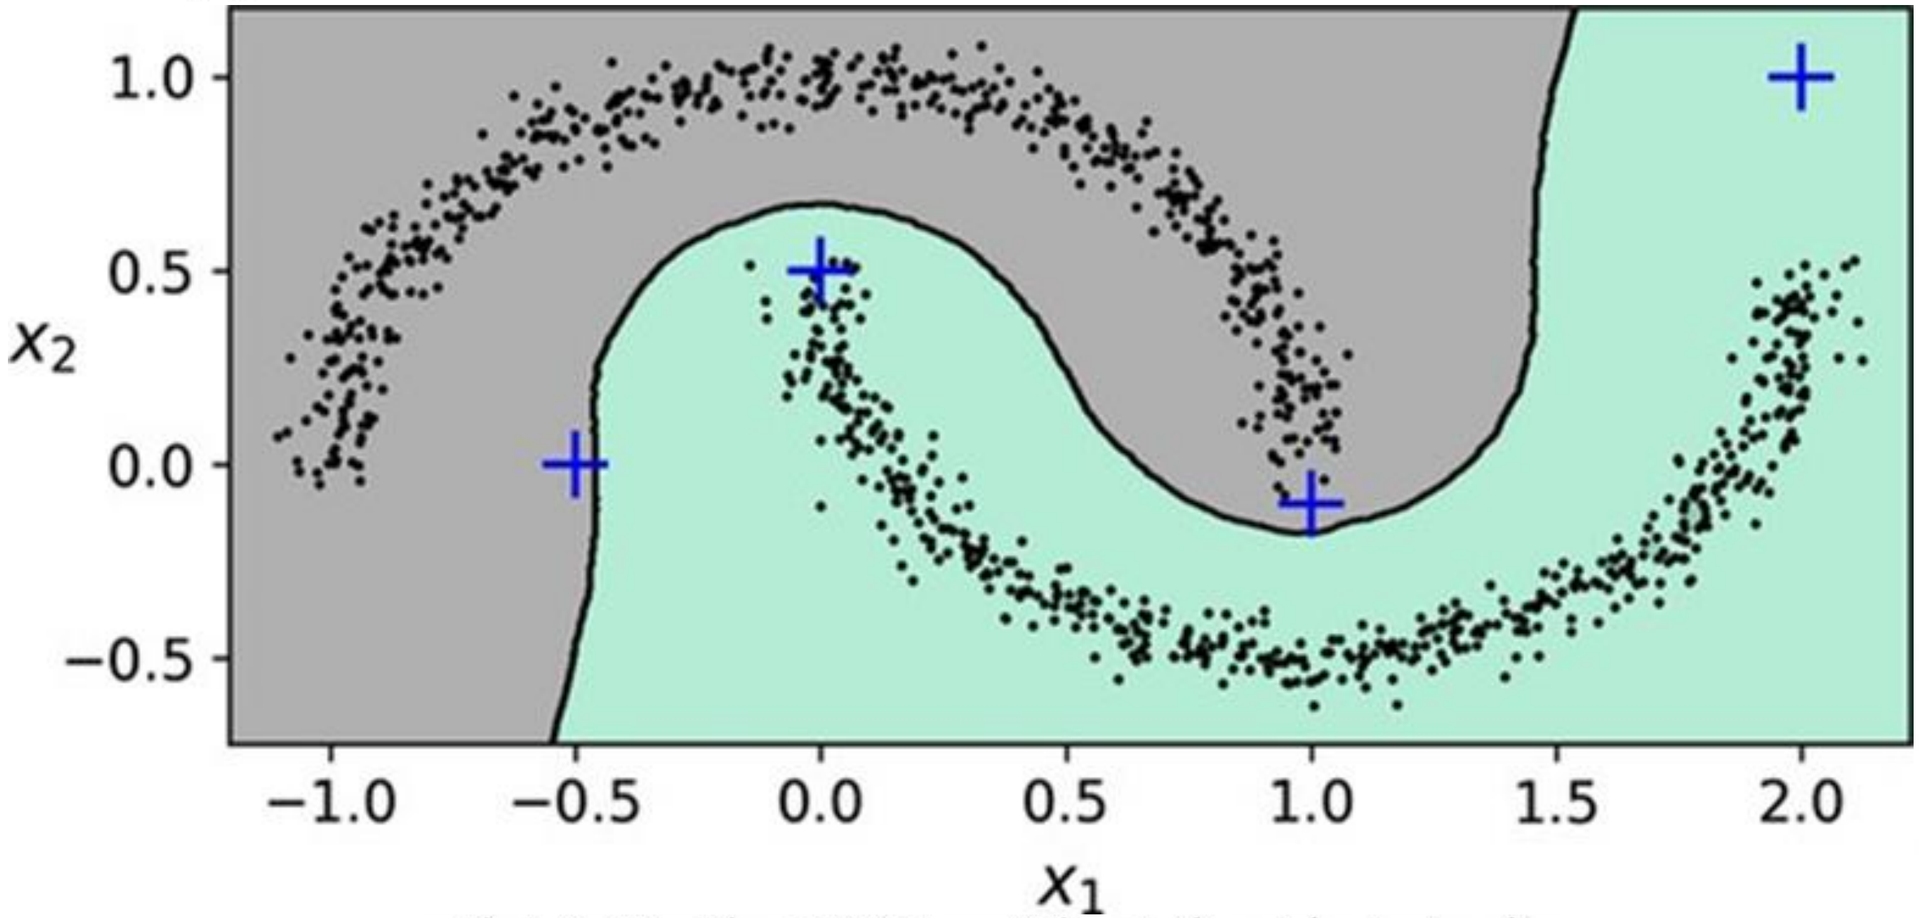
knn = KNeighborsClassifier(n_neighbors=50)
# dbscan.components_ chua cac diem loi
# dbscan.labels_ chua nhan cua cac diem do
knn.fit(dbscan.components_ , dbscan.labels_[dbscan.core_sample_indices_])

import numpy as np
X_new = np.array([[-0.5, 0], [0, 0.5], [1, -0.1], [2, 1]])
print(knn.predict(X_new))
# Output: [1 0 1 0]

```

Gemini Notebook

Đường biên quyết định của phân loại KNN trên tập DBSCAN



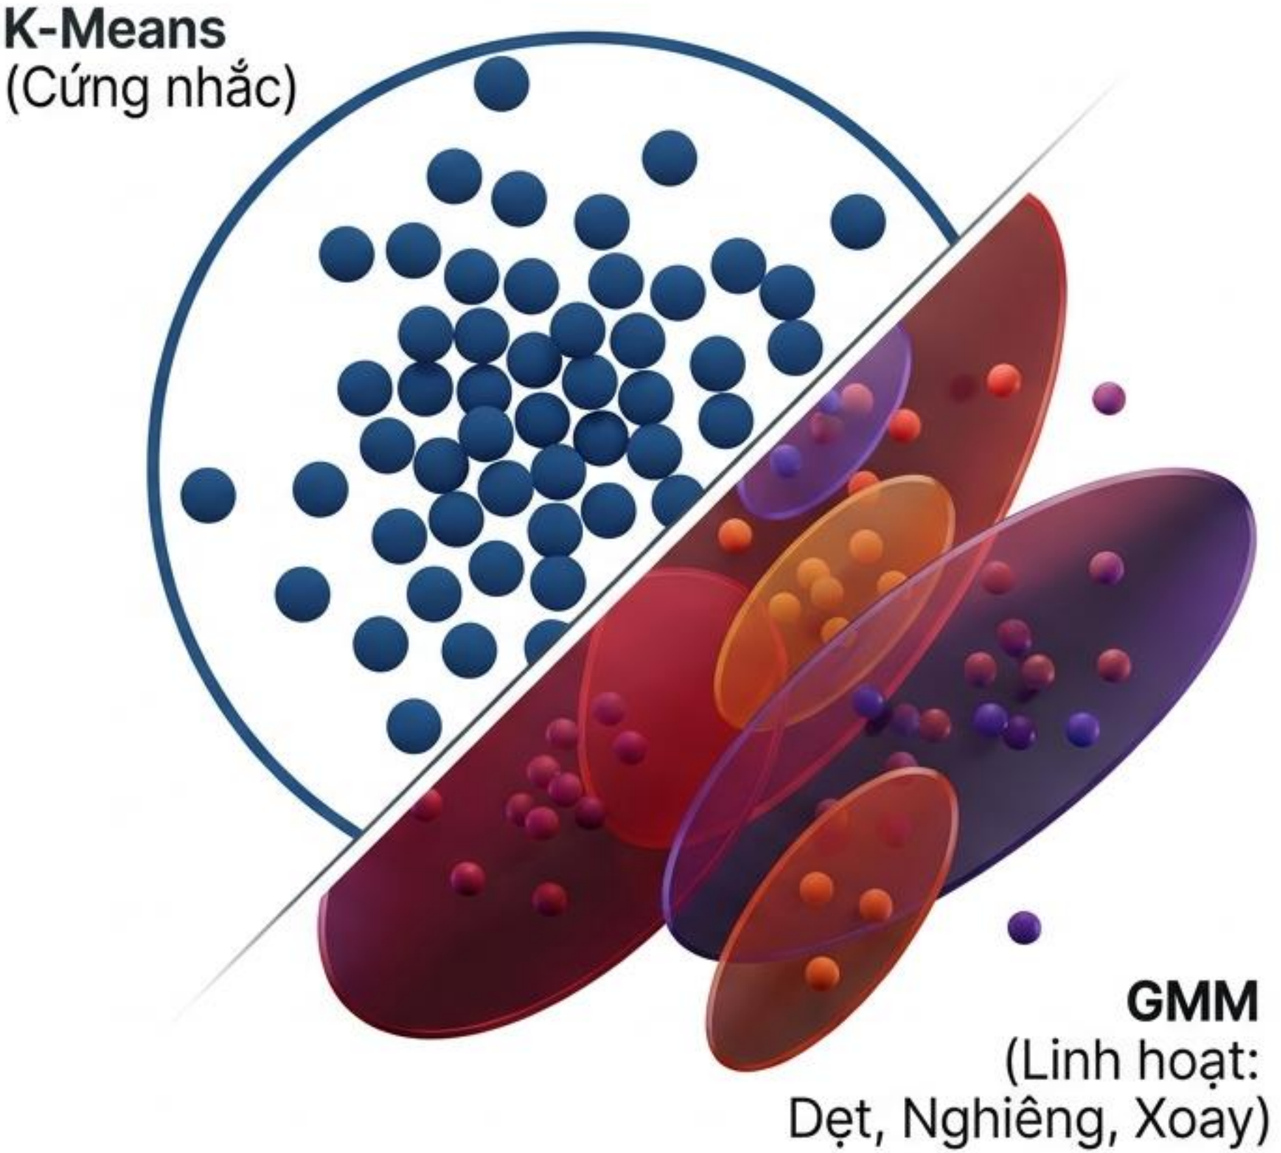
Hình 9-15. Dùng KNN tạo đường biên phân loại mới dựa trên các cụm đã tìm thấy bởi DBSCAN

Gemini Notebook

Mô hình Hỗn hợp Gaussian (GMM) là gì?

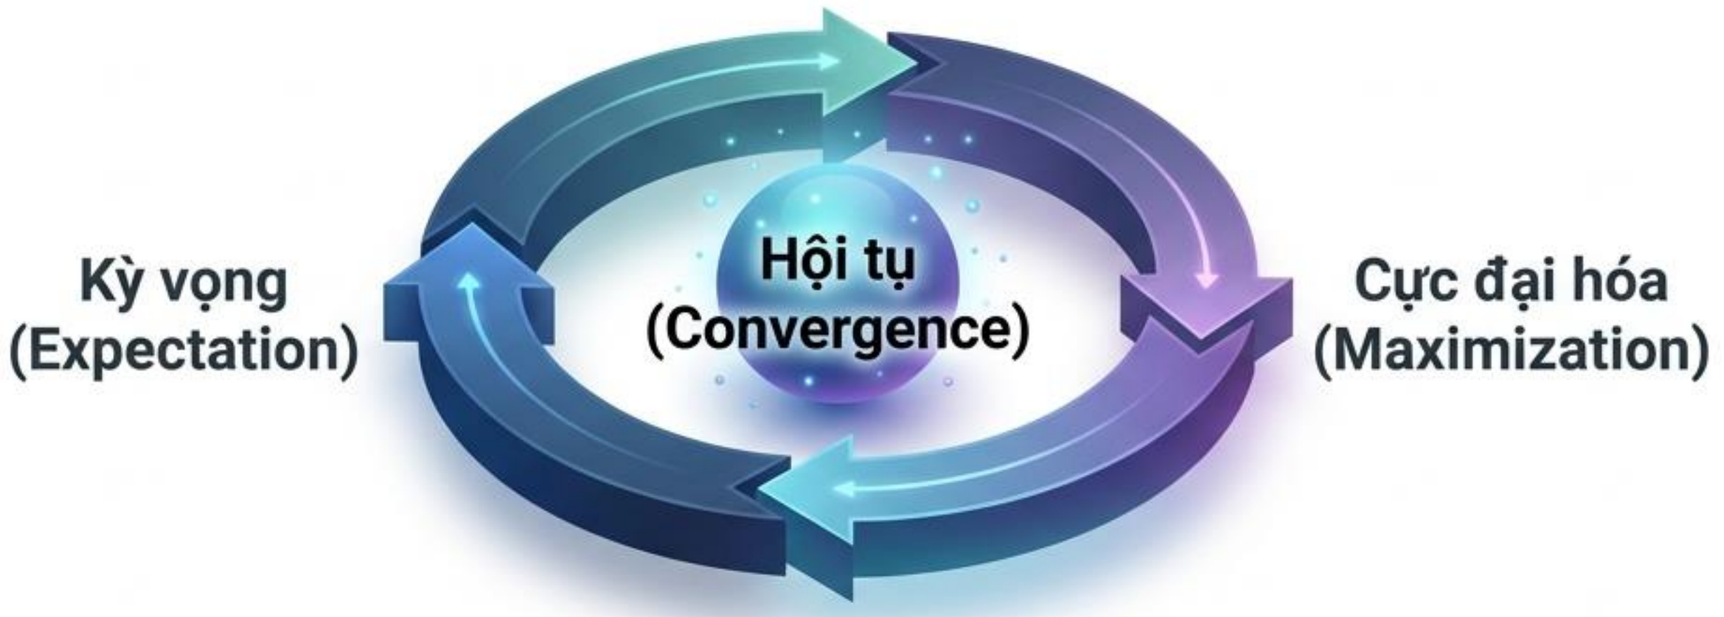
Gaussian Mixture Model (GMM): Là một mô hình xác suất giả định rằng tất cả các điểm dữ liệu được sinh ra từ một hỗn hợp (mixture) của một số hữu hạn các phân phối Gaussian (Phân phối chuẩn) với các tham số chưa biết.

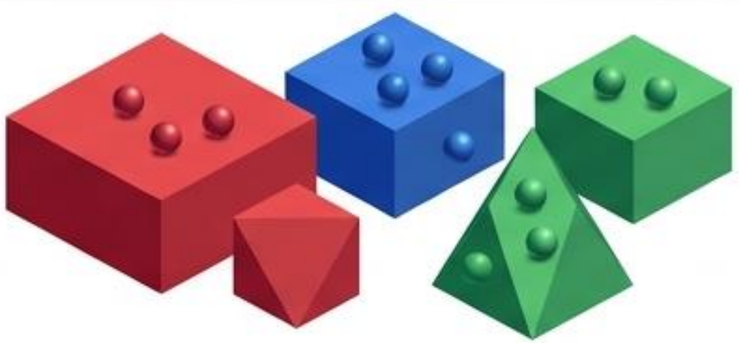
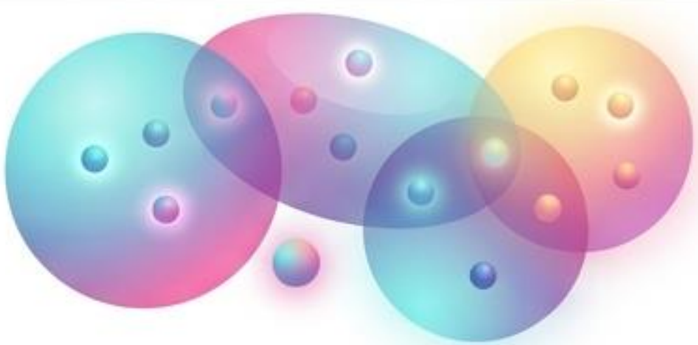
- **Khắc phục nhược điểm của K-Means, cực kỳ hiệu quả với các cụm hình elip.**



Gemini Notebook

Thuật toán Cực đại hóa Kỳ vọng (EM)

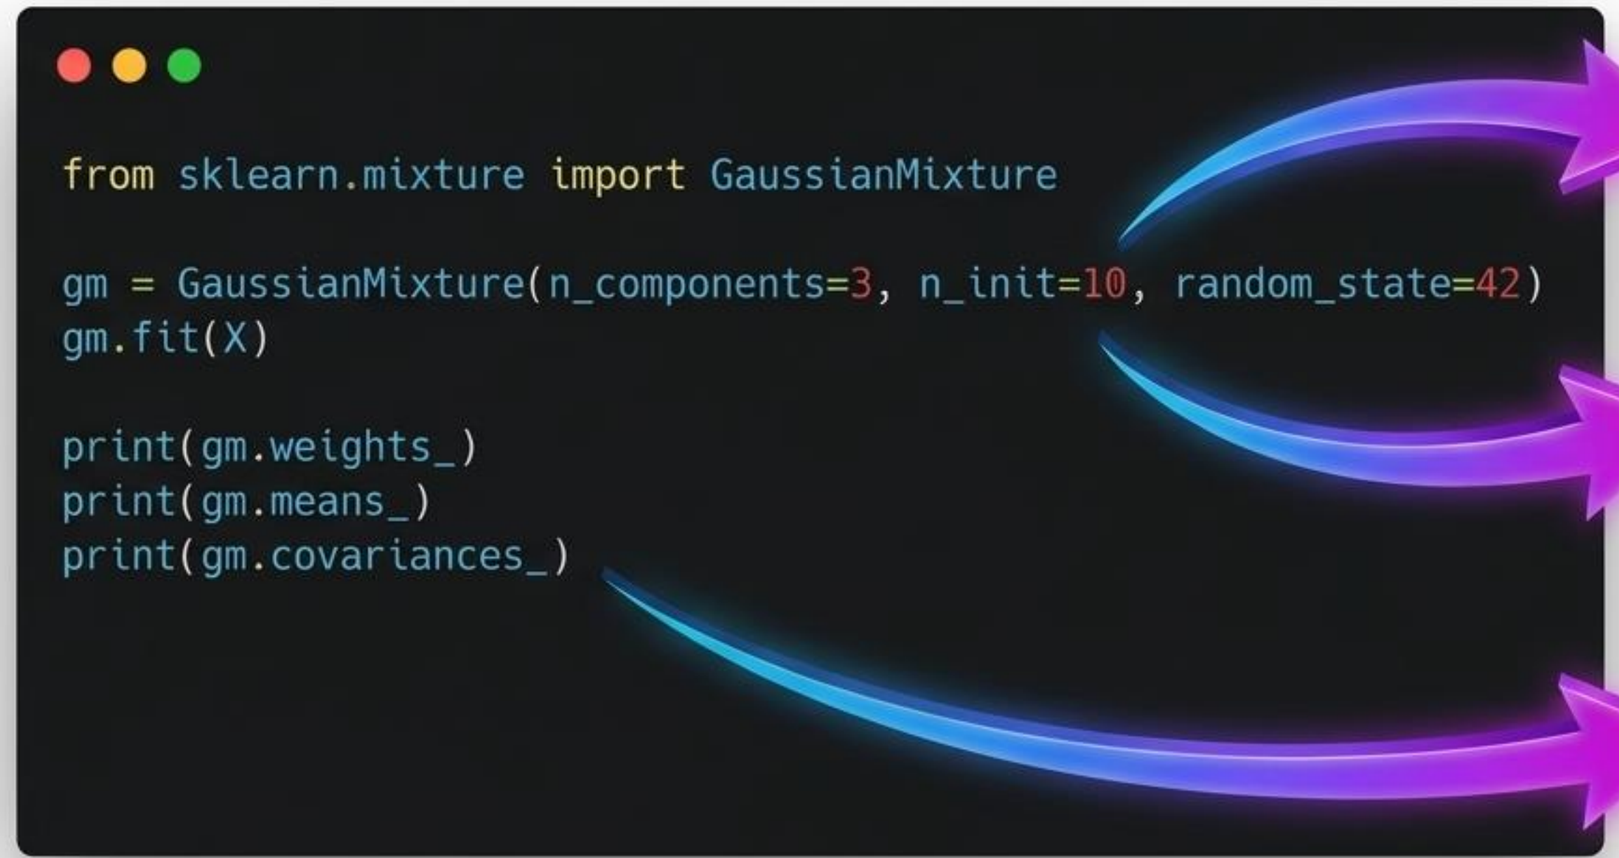


K-Means: Gán cứng (Hard)	GMM (EM): Gán mềm (Soft assignments)
	

Khác với K-Means, EM không chỉ tìm tâm cụm (trung bình **μ**), mà còn tìm kích thước, hình dạng, hướng (ma trận hiệp phương sai **Σ**) và xác suất tương đối (trọng số ϕ).

Gemini Notebook

Khởi tạo GMM trong Scikit-Learn



```python
from sklearn.mixture import GaussianMixture

gm = GaussianMixture(n_components=3, n_init=10, random_state=42)
gm.fit(X)

print(gm.weights_)
print(gm.means_)
print(gm.covariances_)
```

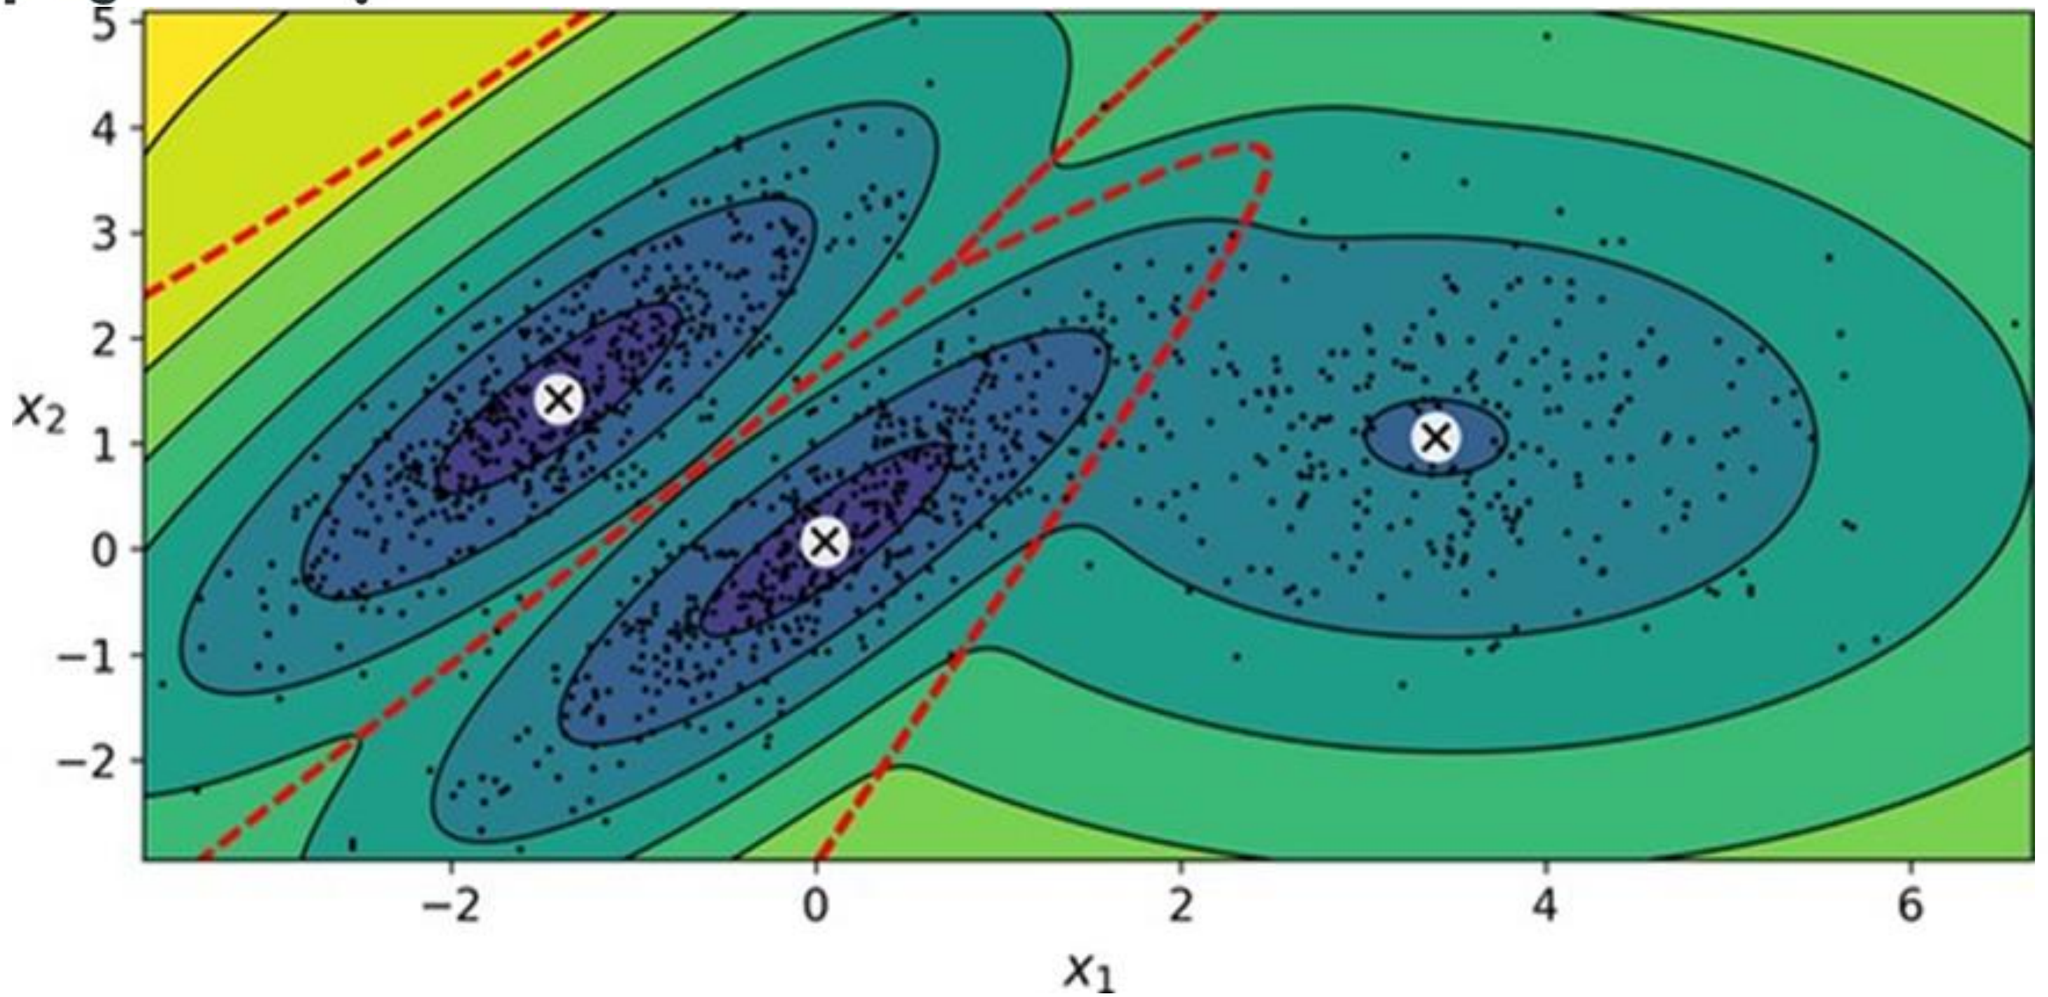
Số lượng cụm **k** (tương tự K-Means)

Chạy nhiều lần để tránh kẹt ở điểm tối ưu cục bộ → Giữ lại mô hình tốt nhất!

Trích xuất **trọng số (ϕ)**, **trung bình (μ)**, và **hiệp phương sai (Σ)**

Gemini Notebook

Các giá trị trung bình và đường biên quyết định của GMM



Hình 9-16. *GMM tìm ra các cụm hình elip bị kéo giãn và nghiêng cực kỳ chính xác*

Gemini Notebook

Hạn chế dạng ma trận hiệp phương sai

Dữ liệu lớn nhiều chiều làm ma trận hiệp phương sai bành trướng. Giải pháp: Hạn chế kiểu hình dạng bằng covariance_type.

full

Hình elip tự do hướng theo bất kỳ góc nào.



tied

Tất cả các cụm phải dùng chung kích thước, góc xoay, hình dáng.



spherical

Cụm phải là hình cầu hoàn hảo (nhưng bán kính có thể khác nhau).



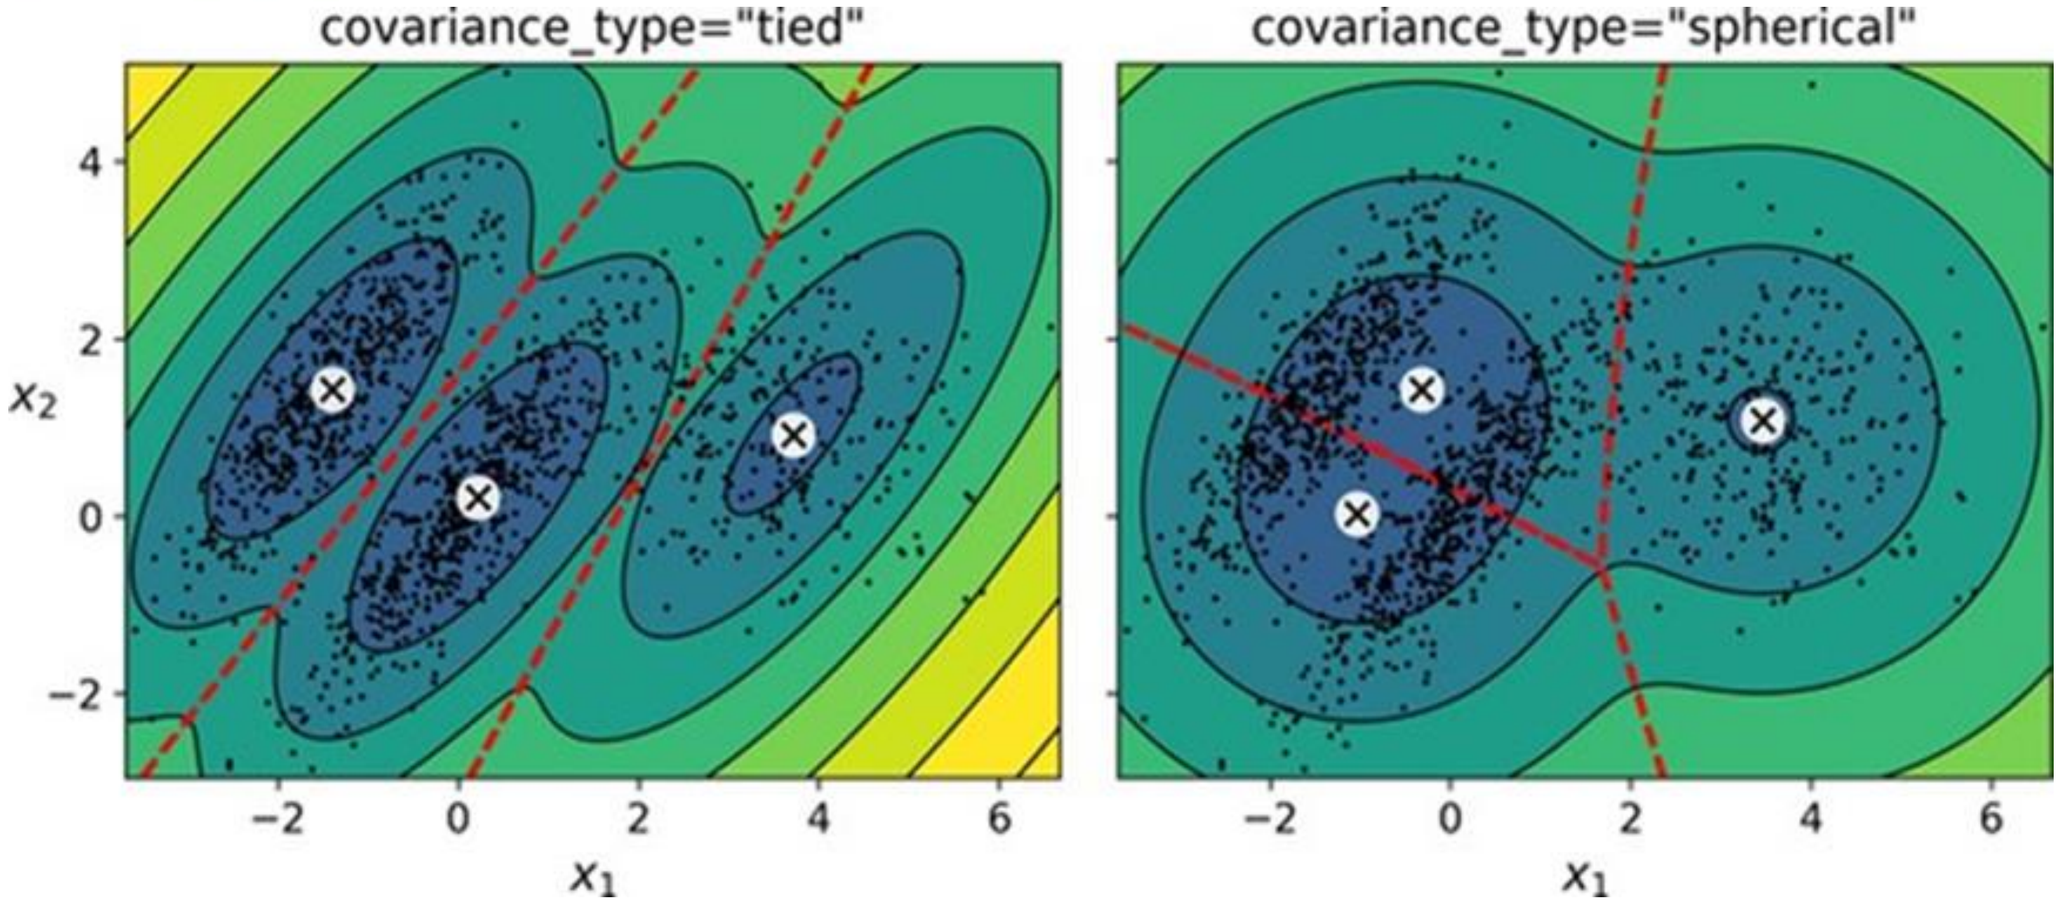
diag

Cụm hình elip nhưng trục phải song song với các trục tọa độ.



Gemini Notebook

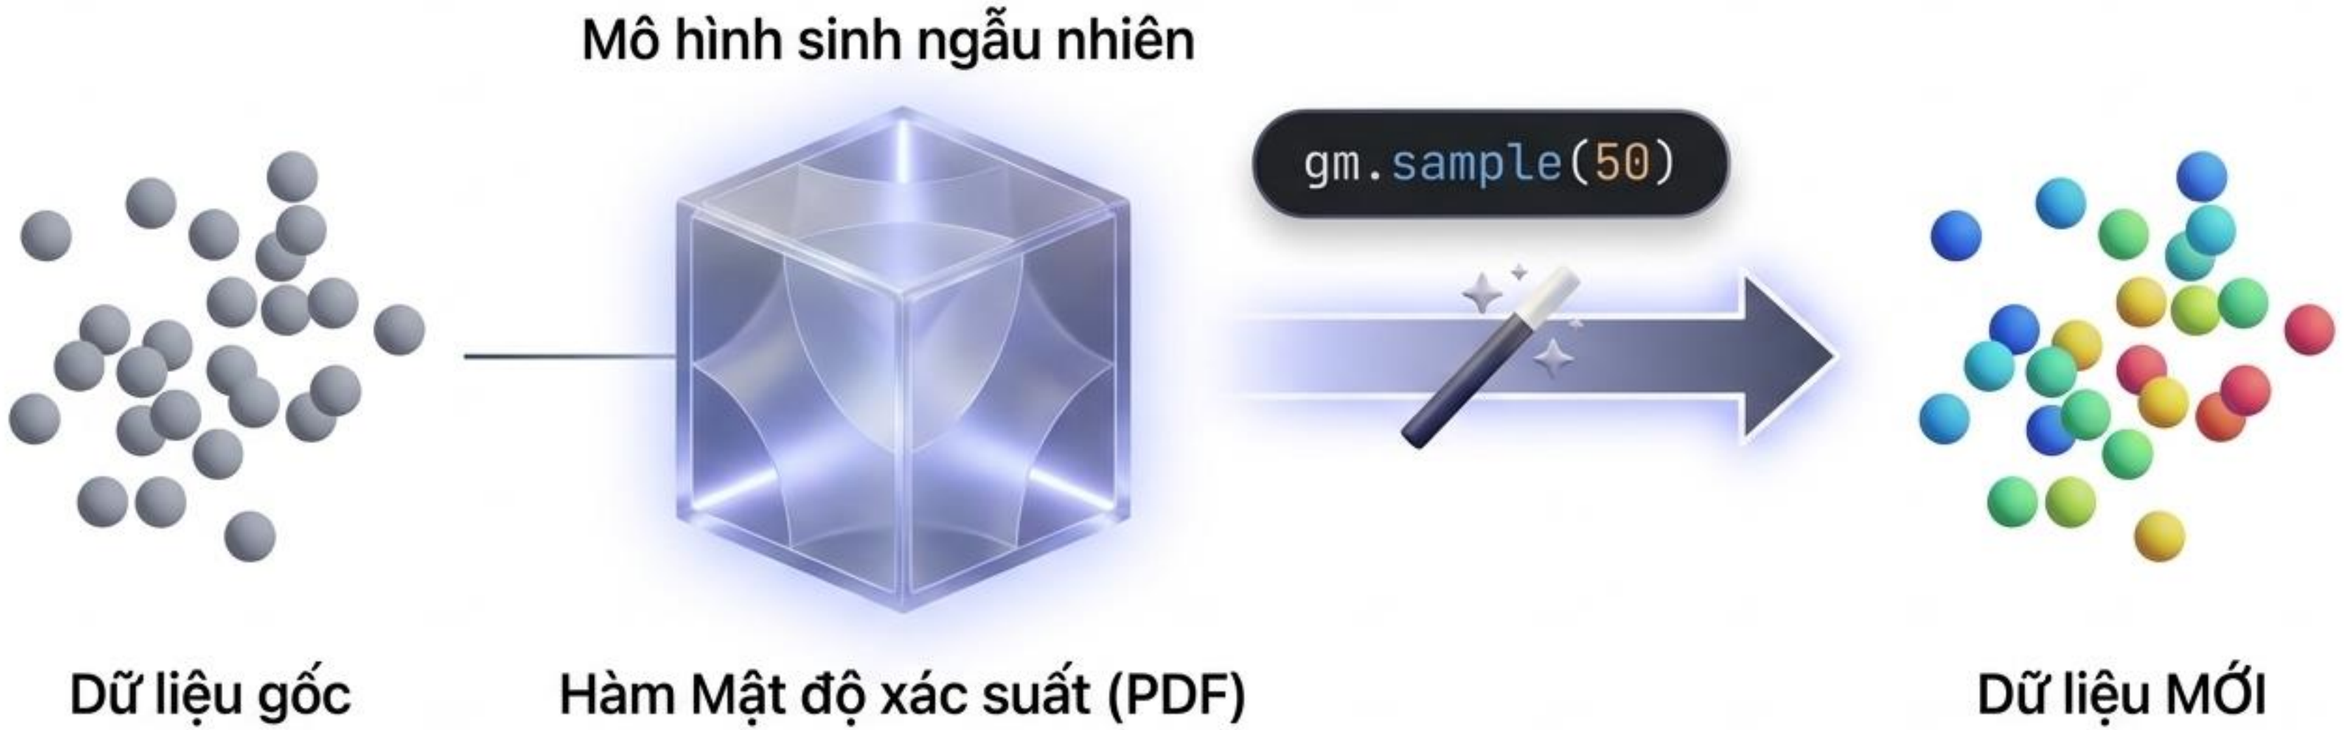
Trực quan hóa GMM với các cụm liên kết và hình cầu



Hình 9-17. Bên trái: tied (elip giống hệt nhau). Bên phải: spherical (hình cầu hoàn hảo)

Gemini Notebook

Ước tính mật độ sinh ngẫu nhiên (Generative process)

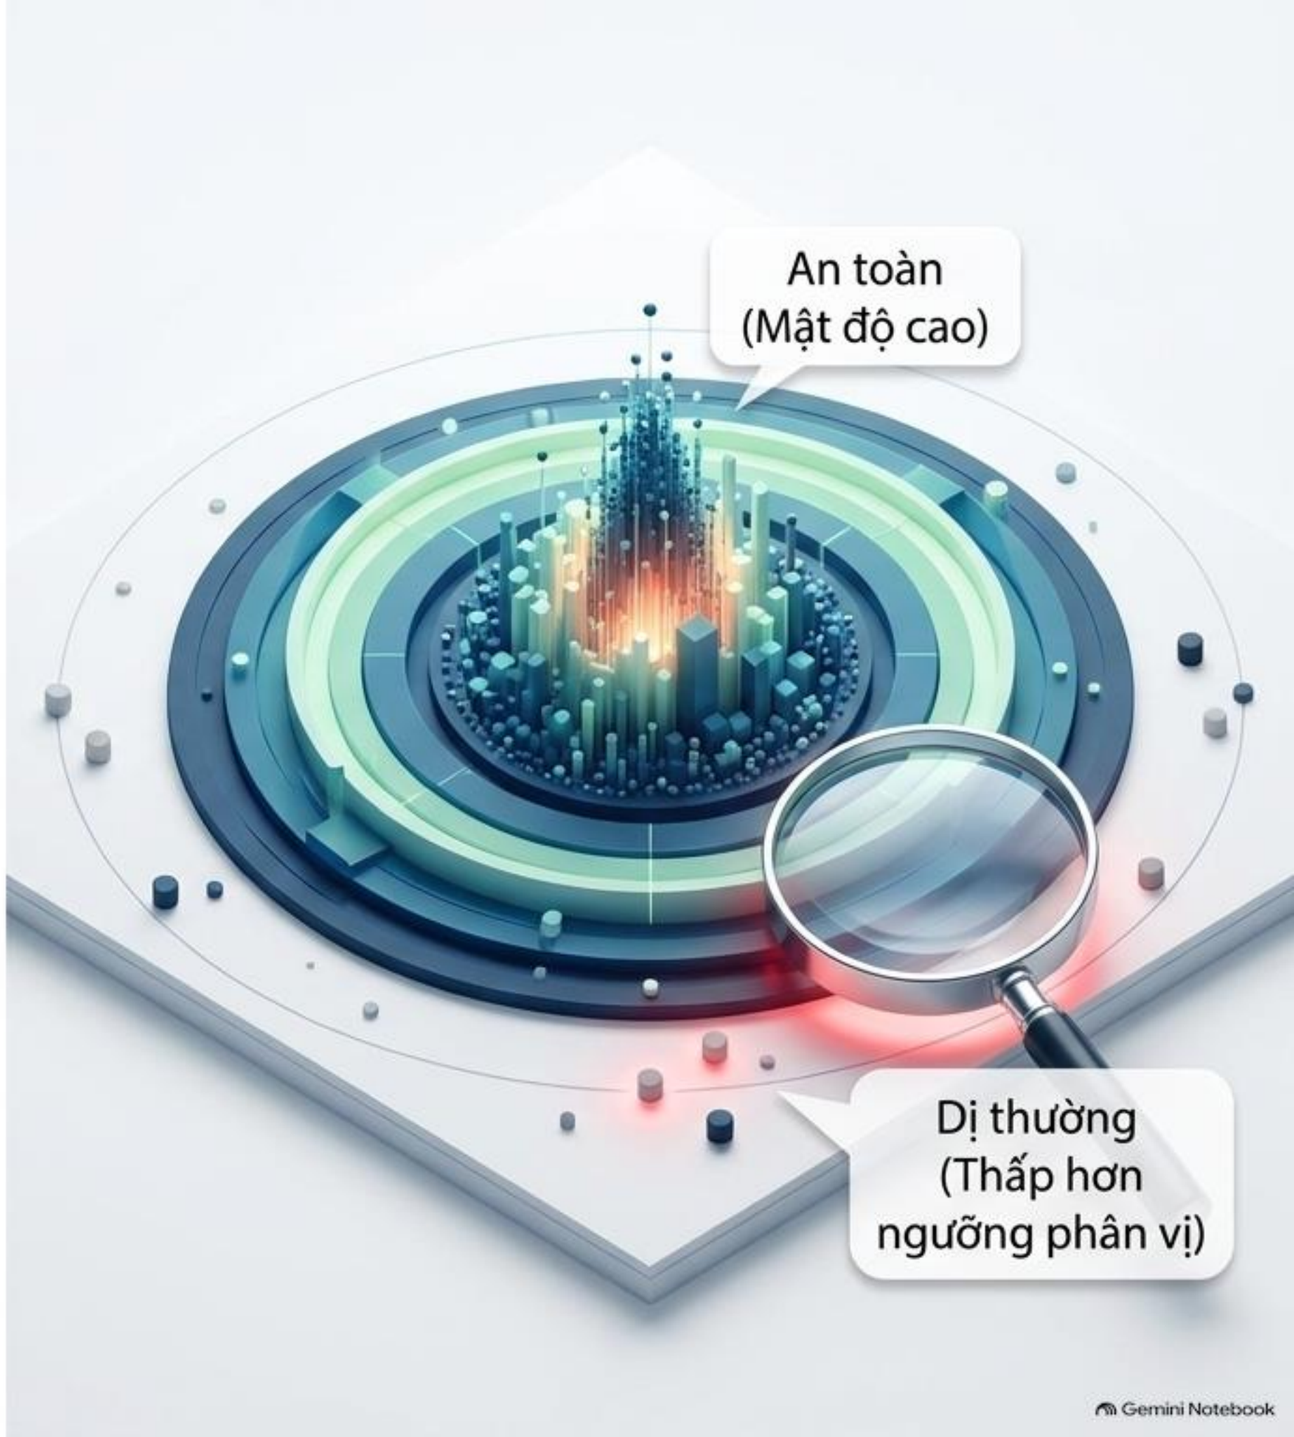


GMM không chỉ phân cụm, mà nó mô hình hóa hoàn toàn hàm PDF, cho phép sinh ra các điểm dữ liệu mới hoàn toàn tự nhiên trông giống phân phối gốc!

Gemini Notebook

Phát hiện dị thường (Anomaly Detection) bằng GMM

- Bằng cách ước lượng hàm PDF tổng quát, khu vực có mật độ cực thấp (low density) = Dị thường (Anomaly / Outlier).
- Dùng hàm gm.score_samples(X) để đánh giá mức độ mật độ (log-likelihood).



Cách tính ngưỡng mật độ phát hiện dị thường

Ví dụ: Lấy 4% điểm có mật độ thấp nhất làm dị thường.

Bước 1: Đánh giá mật độ. Trả về mật độ log (log PDF).

```
densities = gm.score_samples(X)
```

↓

Bước 2: Tìm ngưỡng. Xác định ranh giới phân vị 4%.

```
density_threshold = np.percentile(densities, 4)
```

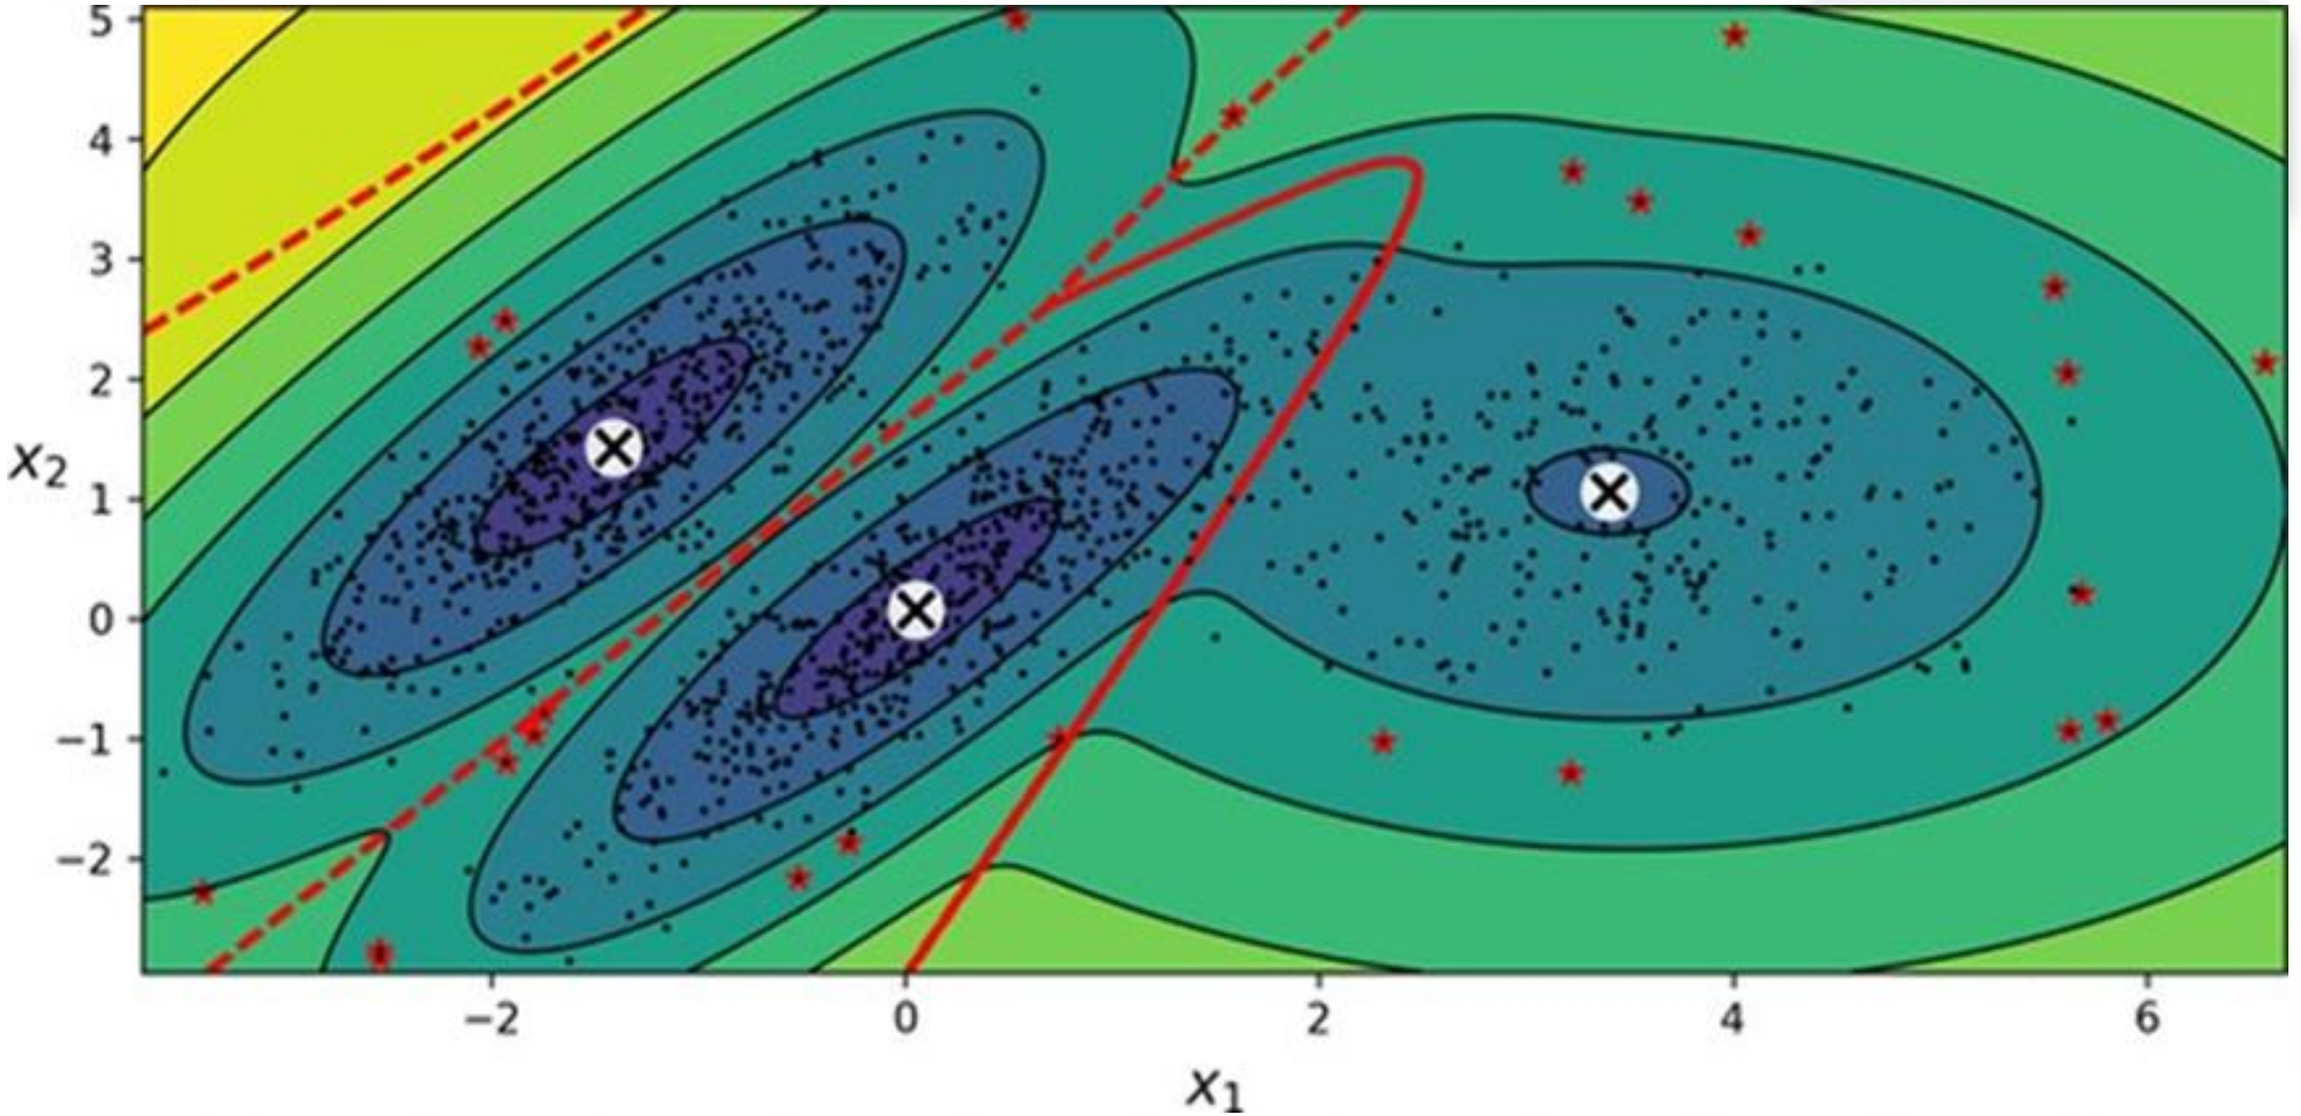
↓

Bước 3: Lọc Dị thường. Đánh dấu các điểm nằm dưới ngưỡng.

```
anomalies = X[densities < density_threshold]
```

Gemini Notebook

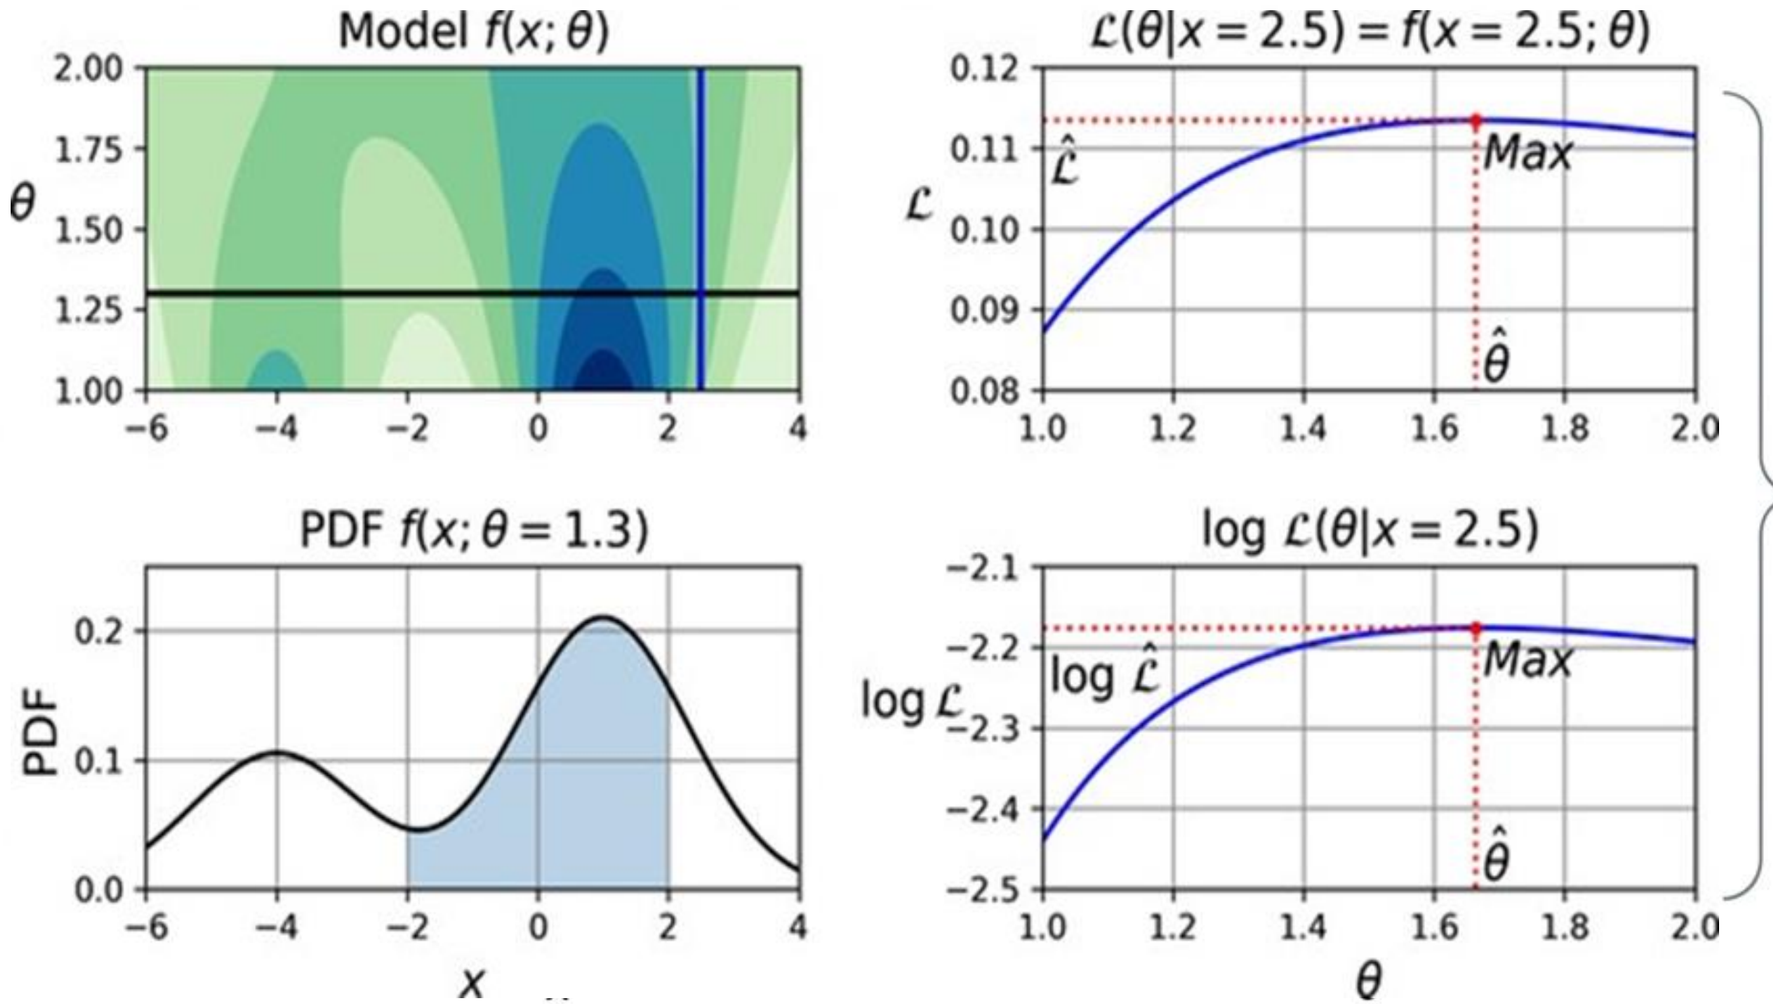
Trực quan hóa Phát hiện dị thường



Hình 9-18. Các ngôi sao màu đỏ là các điểm dị thường (Anomalies) nằm ở khu vực mật độ thấp

Gemini Notebook

Hàm tham số của mô hình



Mô hình tìm kiếm tham số bằng cách đạt cực đại hàm Likelihood (Max Likelihood).

Hình 9-19. Không gian hàm PDF của Mô hình hỗn hợp Gaussian từ một cụm đơn giản

Gemini Notebook

Lựa chọn số lượng cụm trong GMM

Problem



Quán tính (Inertia)

Silhouette Score

Không đáng tin cậy với GMM vì chúng thiên vị các cụm hình cầu (như K-Means).

Solution



Data Analysis

Structural Information

Sử dụng Tiêu chí Thông tin (Information Criteria):

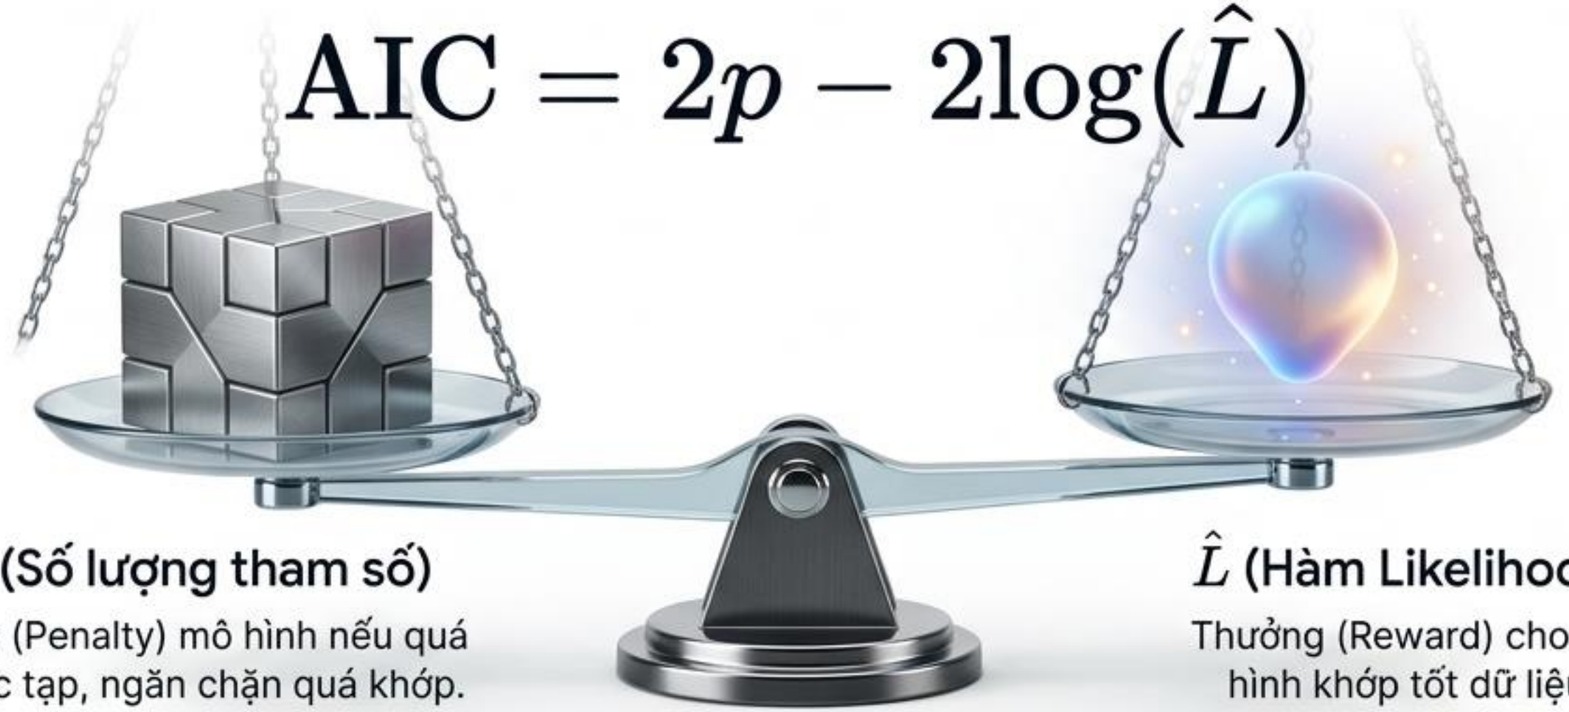
- **BIC** (Bayesian Information Criterion)
- **AIC** (Akaike Information Criterion)

Gemini Notebook

Công thức tính toán AIC và BIC

$$\mathrm{BIC} = \log(m)p - 2\log(\hat{L})$$

$$\mathrm{AIC} = 2p - 2\log(\hat{L})$$



p (Số lượng tham số)

Phạt (Penalty) mô hình nếu quá phức tạp, ngăn chặn quá khớp.

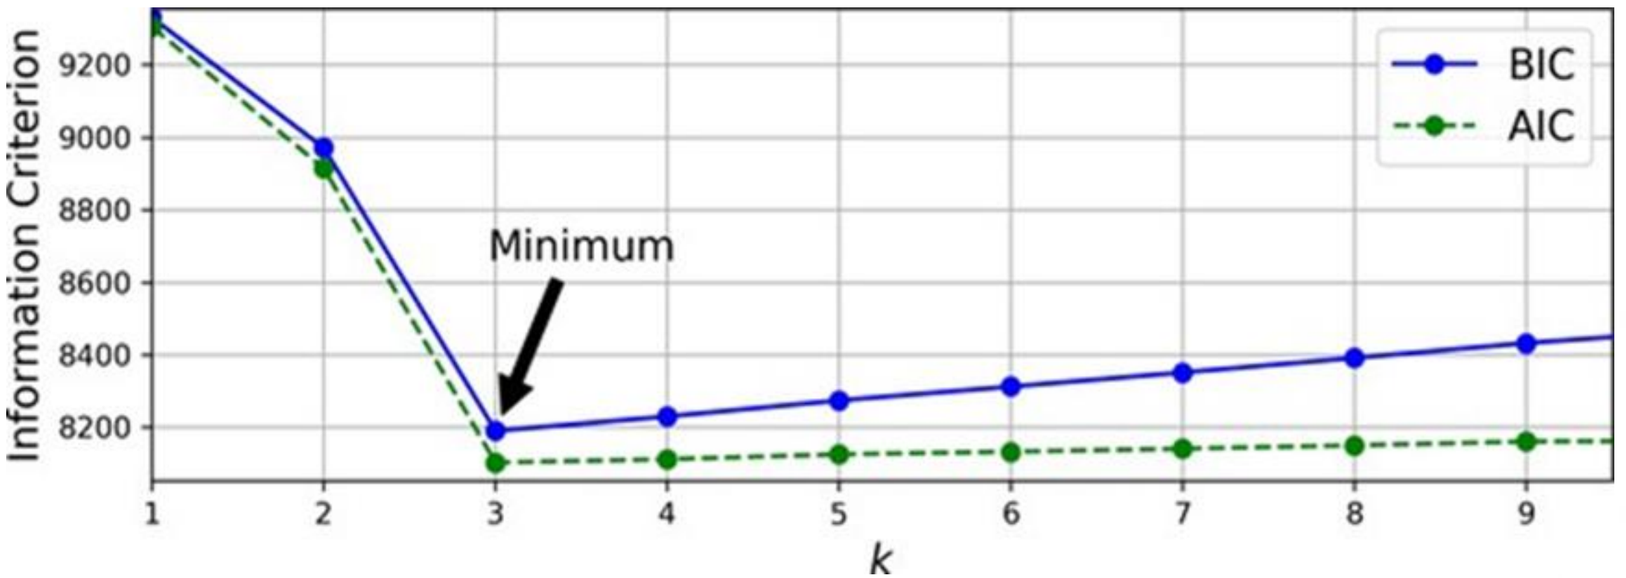
$\hat{L}$ (Hàm Likelihood)

Thưởng (Reward) cho mô hình khớp tốt dữ liệu.

Mô hình tốt nhất là mô hình có AIC/BIC thấp nhất. (m = số mẫu dữ liệu)

Gemini Notebook

Biểu đồ AIC và BIC cho các k khác nhau



BIC và AIC đạt giá trị cực tiểu rõ ràng tại k = 3.

Đây là số lượng cụm **tối ưu nhất** cho tập dữ liệu.

Gemini Notebook

Mô hình Hỗn hợp Gaussian Bayes (BGM)

Không cần thử thủ công k. BGM tự động khám phá số lượng cụm thực tế!



BGM tự động gán trọng số (weights) của các cụm không cần thiết bằng 0 hoặc xấp xỉ 0 → Tự động khám phá ra k thực tế!

Gemini Notebook

Sử dụng BGM bằng Scikit-Learn



```python
from sklearn.mixture import BayesianGaussianMixture

# Thiet lap k=10 du gia
bgm = BayesianGaussianMixture(n_components=10, n_init=10, random_state=42)
bgm.fit(X)

# Kiem tra trong so cac cum
np.round(bgm.weights_, 2)
# Output: array([0.4 , 0.21, 0.4 , 0. , 0.  , 0. , 0. , 0.  , 0. , 0. ])
```



Chỉ có 3 cụm đầu tiên có trọng số lớn hơn 0. BGM đã triệt tiêu 7 cụm dư thừa và tự nhận ra bài toán chỉ có 3 cụm.

Gemini Notebook

Tiên nghiệm Dirichlet (Dirichlet Prior)

BGM đạt được sự tự động này là nhờ áp dụng **phân phối Dirichlet** vào quá trình cập nhật Bayes. Thông qua tham số weight_concentration_prior, bạn có thể cho thuật toán biết niềm tin (Prior) của bạn:



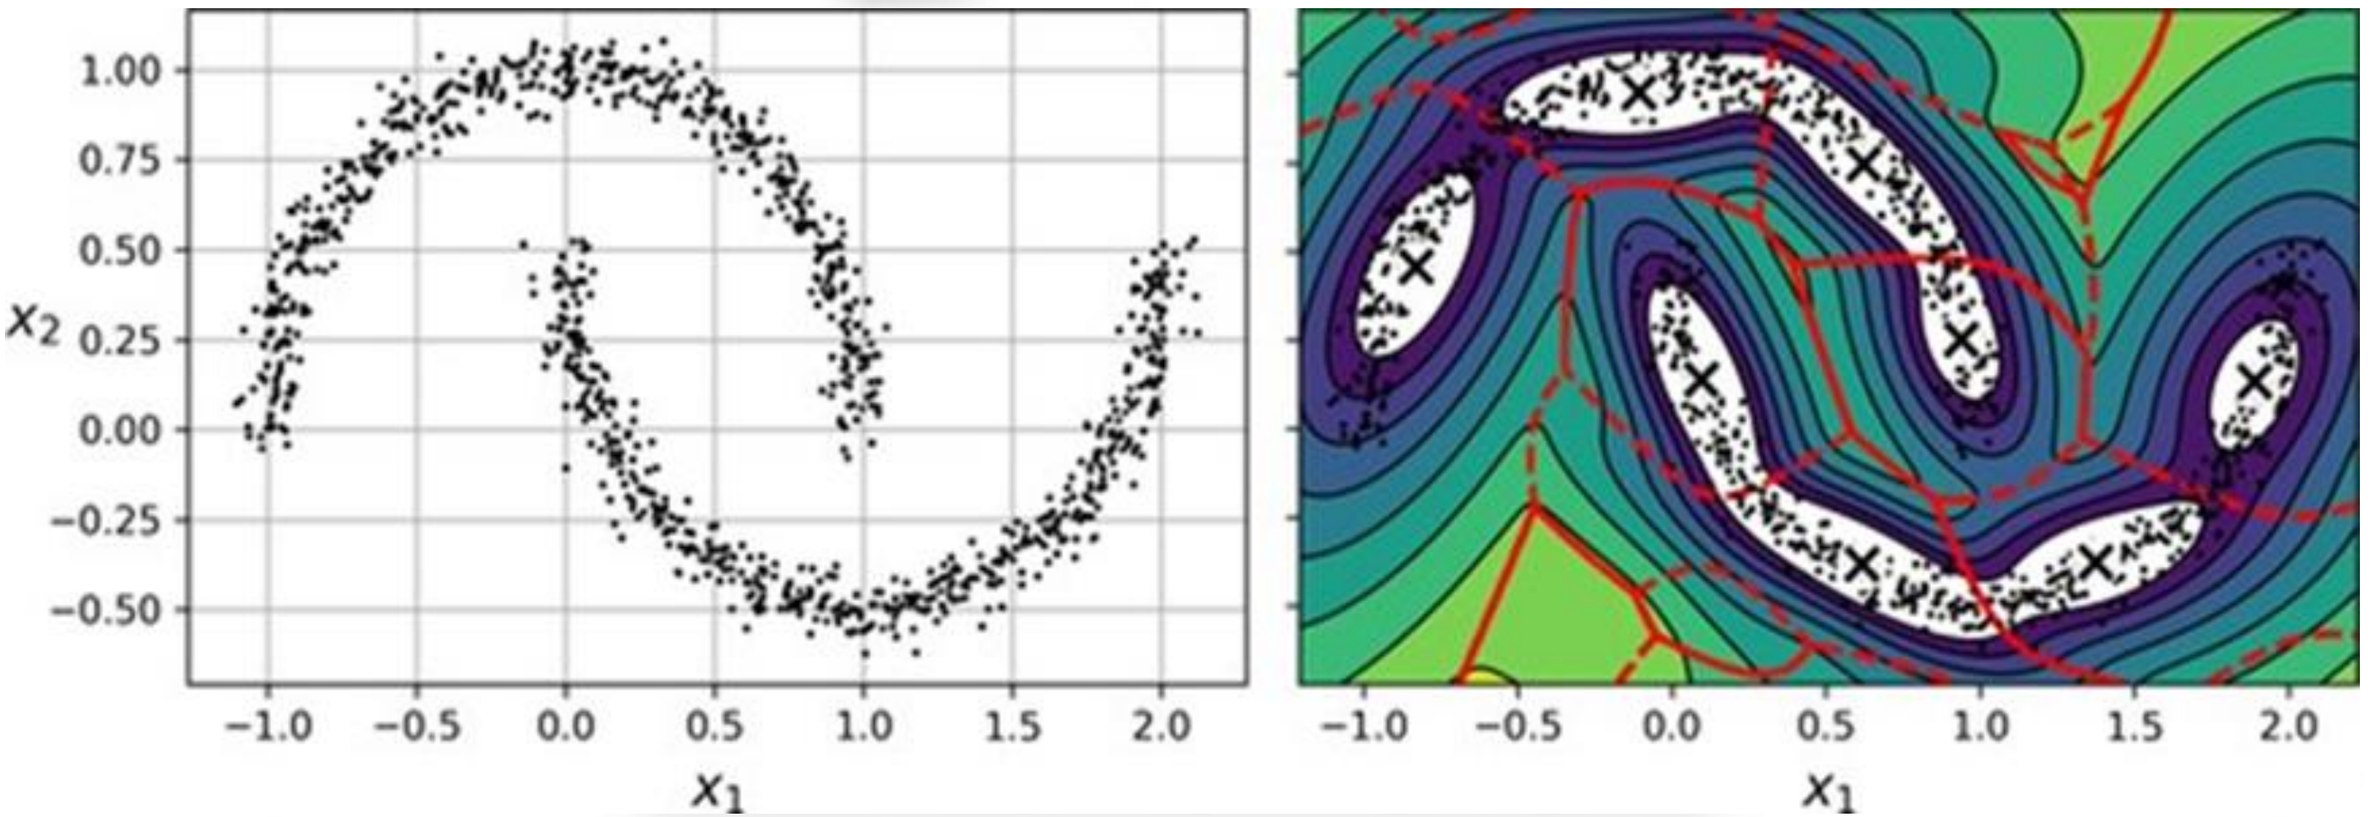
Nếu đặt bằng tỷ lệ nhỏ (mặc định 1/n_components), thuật toán sẽ mạnh tay loại bỏ cụm (tìm ít cụm).



Nếu đặt số lớn, thuật toán sẽ cố gắng giữ lại tất cả các cụm (như GMM thường).

Gemini Notebook

Lưu ý khi dùng BGM với dữ liệu hình dạng tùy ý ⚠️



Hình 9-21. *BGM phân cụm lỗi đối với tập dữ liệu Moons. GMM sinh ra các cục elip, nên một hình cong trăng khuyết sẽ bị nó chia làm nhiều cục elip nhỏ thay vì 1 cụm.*

Gemini Notebook

Các thuật toán phát hiện dị thường khác

Bên cạnh GMM, một số thuật toán chuyên biệt cho Phát hiện Dị thường (Anomaly Detection):



PCA (Phân tích thành phần chính): Sai số tái tạo (Reconstruction Error) của ngoại lệ thường cao hơn nhiều điểm bình thường.



Fast-MCD (Minimum Covariance Determinant): Rất giỏi trong việc dọn dẹp các **điểm nhiễu ngoại lai** trước khi chạy thuật toán học máy.



Isolation Forest: Chuyên gia phát hiện ngoại lệ trong tập dữ liệu không gian nhiều chiều.



LOF (Local Outlier Factor): Dựa trên sự khác biệt mật độ cục bộ.

Gemini Notebook

Tóm tắt Chương 9: K-Means & Ứng dụng



Học không giám sát **khai phá dữ liệu** chưa gắn nhãn, hứa hẹn mở ra **cuộc cách mạng AI.**



K-Means là ông vua tốc độ. Sử dụng quán tính, quy tắc khuỷu tay và điểm Silhouette để dò *k*. Thích ứng tốt nhất với cụm dạng cầu, kích thước đều.



Ứng dụng quan trọng
Rất tuyệt vời để Phân đoạn hình ảnh và Tiền xử lý cho việc Gán nhãn **Bán giám sát** (Semi-supervised).

Gemini Notebook

Tóm tắt Chương 9: DBSCAN & GMM



DBSCAN không quan tâm số cụm, dựa vào mật độ, có thể theo vết các cụm hình dạng phức tạp và kháng nhiễu tốt.



GMM (Hỗn hợp Gaussian) khắc phục nhược điểm về hình elip, rất mạnh trong **Phát hiện dị thường**.



BGM (Hỗn hợp Gaussian Bayes) giúp tự động hóa quá trình dò tìm số lượng cụm *k* nhờ tiêu chuẩn học máy thống kê.

Gemini Notebook



CẢM ƠN CÁC BẠN ĐÃ LẮNG NGHE!

Q & A

Gemini Notebook