




Machine Learning: Đánh Giá Mô Hình & Chính Quy Hóa

Chương 4 - Bài giảng giới thiệu bậc đại học



Hiện tượng Quá khớp (Overfitting) với đa thức bậc cao

- Thực hiện hồi quy đa thức bậc quá cao (Vd: bậc 300) khiến mô hình khớp dữ liệu huấn luyện cực kỳ tốt (đường uốn lượn dữ dội).
- Đây là **Quá khớp nghiêm trọng**. Mô hình bậc 2 (Quadratic) mới là mô hình **tổng quát hóa** (Generalize) tốt nhất.
- Câu hỏi đặt ra: Làm sao nhận biết mô hình đang quá khớp hay dưới khớp?
-> Sử dụng **Đường cong học tập**.



Hình 4-14. Hồi quy đa thức bậc cao (Overfitting)

Đánh giá mô hình bằng Đường cong học tập (Learning Curves)

Đường cong học tập thể hiện lỗi trên tập Huấn luyện (Train) và tập Xác thực (Validation) dưới dạng hàm của kích thước tập huấn luyện.




Dưới khớp (Underfitting): Cả hai đường đều đạt cao nguyên, lỗi cao và sát nhau. Việc thêm dữ liệu không mang lại sự cải thiện.



Quá khớp (Overfitting): Lỗi trên tập huấn luyện thấp hơn nhiều. Xuất hiện khoảng cách (gap) đáng kể giữa hai đường (Mô hình tốt trên tập huấn luyện nhưng kém trên dữ liệu mới).




Minh họa: Đường cong học tập (Dưới khớp)



Hình 4-15. Dưới khớp (Đường cong sát nhau, lỗi cao)



Minh họa: Đường cong học tập (Quá khớp)



Hình 4-16. Quá khớp (Khoảng cách rõ ràng giữa 2 đường cong)

Sự đánh đổi giữa Độ chệch (Bias) và Phương sai (Variance)



Độ chệch (Bias)

Lỗi do các giả định sai (Vd: giả định tuyến tính cho dữ liệu phi tuyến). Bias cao gây ra underfitting.



Phương sai (Variance)

Lỗi do mô hình quá nhạy cảm với biến động nhỏ. Bậc tự do cao $\rightarrow$ variance cao $\rightarrow$ overfitting.



Lỗi không thể giảm (Irreducible error)

Độ nhiễu của bản thân dữ liệu. Chỉ giảm được bằng cách làm sạch dữ liệu.

Sự đánh đổi: Tăng độ phức tạp $\rightarrow$ Tăng variance, giảm bias.
Giảm độ phức tạp $\rightarrow$ Tăng bias, giảm variance.



Chính quy hóa (Regularization): Hồi quy Ridge

Giảm **Overfitting** bằng cách chính quy hóa (ràng buộc) kích thước của các trọng số θ .


Hồi quy **Ridge** (Chuẩn hóa Tikhonov) thêm số hạng phạt **λ** vào hàm chi phí MSE:

$$J(\theta) = \text{MSE}(\theta) + \alpha \frac{1}{2} \sum_{i=1}^n \theta_i^2 \quad (7)$$

α kiểm soát mức độ chính quy hóa.

- $\alpha = 0$: Hồi quy tuyến tính bình thường.
- α lớn: Trọng số θ gần về 0, tạo đường thẳng phẳng cắt qua trung bình dữ liệu.

Minh họa: Hồi quy Ridge




Mô hình Tuyến tính: Áp dụng trên mô hình tuyến tính thông thường. Khi α tăng, đường dự đoán trở nên phẳng hơn, giúp giảm độ chệch của các giá trị cực đoan.



Mô hình Đa thức: Áp dụng sau biến đổi `PolynomialFeatures(degree=10)`. Nếu $\alpha = 0$, đường cong dao động cực mạnh. Khi α lớn, đường cong êm hơn nhiều, giảm overfitting đáng kể.

Hình 4-17. Hồi quy Ridge trên mô hình tuyến tính và đa thức



Chính quy hóa (Regularization): Hồi quy Lasso

Hồi quy Lasso (Least Absolute Shrinkage and Selection Operator) sử dụng chuẩn l1 làm số hạng phạt:


$$J(\theta) = \text{MSE}(\theta) + \alpha \sum_{i=1}^n |\theta_i| \quad (8)$$

Điểm đặc biệt nhất: Lasso có xu hướng **hoàn toàn loại bỏ** (đặt trọng số = 0) các đặc trưng ít quan trọng. Kết quả: **Tự động lựa chọn** đặc trưng (feature selection), tạo ra một **mô hình thưa** (sparse model).

Minh họa: Hồi quy Lasso



Dữ liệu tuyến tính: Lasso áp dụng hình phạt **chuẩn l1**, dẫn đến việc **giảm mạnh** các hệ số không quan trọng. **loại bỏ**.



Dữ liệu đa thức: Điểm đáng chú ý: Với $\alpha = 1$, đường dự đoán đa thức gần như trở thành một **đường thẳng bậc thấp**. Điều này chứng tỏ các tham số bậc cao đã bị đưa về **giá trị 0** hoàn toàn.

Hình 4-18. Hồi quy Lasso trên mô hình tuyến tính và đa thức

Điểm khác biệt giữa Lasso và Ridge trong không gian tham số



Ridge (Chuẩn l_2)


- **Trọng số giảm dần** khi tiến tới gốc tọa độ.
- **Gradient nhỏ dần** -> Tối ưu **hội tụ êm**, không dao động.
- Các tham số **không bao giờ bị loại bỏ hoàn toàn** (không về 0).



Lasso (Chuẩn l_1)

- **Hàm chi phí giảm tuyến tính** khi tiến tới các trục (θ_1, θ_2).
- **Hạ gradient** khiến một tham số nhanh chóng **về 0**, sau đó trượt trên trục còn lại.
- Kết quả: Tạo ra **mô hình thưa**, **loại bỏ đặc trưng**.

Minh họa: Lasso vs Ridge trong Không gian tham số



Hình 4-19. Chính quy hóa Lasso (Trên) và Ridge (Dưới)



Hồi quy **Elastic Net** & Khi nào nên dùng?

Elastic Net kết hợp cả chuẩn l_1 và l_2 (tỷ lệ trộn r). $r = 0 \rightarrow$ Ridge;
 $r = 1 \rightarrow$ Lasso.

Nguyên tắc lựa chọn (Luôn ưu tiên dùng một ít chính quy hóa):

- ✓ • **Ridge**: Lựa chọn mặc định tốt nhất.
- ✓ • **Lasso** hoặc **Elastic Net**: Dùng khi nghi ngờ chỉ có vài đặc trưng là hữu ích (giúp loại bỏ nhiều).
- ✓ • **Elastic Net** > **Lasso**: Elastic Net được ưa chuộng hơn vì Lasso có thể hoạt động thất thường khi số lượng đặc trưng lớn hơn số trường hợp, hoặc các đặc trưng có tương quan mạnh.




Dừng sớm (Early Stopping)

Dừng huấn luyện thuật toán học lặp (như Gradient Descent) ngay khi Lỗi xác thực (Validation Error) đạt đến cực tiểu.

Lỗi huấn luyện luôn giảm. Lỗi xác thực ban đầu giảm, nhưng sau đó tăng ngược trở lại (bắt đầu Overfitting). Điểm chạm đáy chính là mô hình tốt nhất.

🎁 Kỹ thuật này hiệu quả và đơn giản đến mức Geoffrey Hinton gọi nó là "bữa trưa miễn phí tuyệt vời".



Hình 4-20. Early Stopping (Mũi tên chỉ thời điểm tốt nhất. Các bước sau chỉ làm mô hình tệ hơn...)