




CHƯƠNG 4 | PHẦN 3

QUÁ KHỚP, ĐƯỜNG CONG HỌC TẬP & CHỈNH QUY HÓA (REGULARIZATION)

Đánh giá mô hình và các kỹ thuật chống Overfitting: Ridge, Lasso, Elastic Net & Early Stopping.

Hiện tượng Quá khớp (Overfitting) với đa thức bậc cao



Quá khớp nghiêm trọng. Mô hình bậc quá cao (bậc 300) dữ liệu huấn luyện cực kỳ tốt, tạo ra đường uốn lượn dữ dội cố gắng đi qua mọi điểm.

Tổng quát hóa (Generalize) tốt nhất. Mô hình bậc 2 (Quadratic) phù hợp nhất cho bộ dữ liệu này.

Hình 4-14. Hồi quy đa thức bậc cao (Overfitting)

Đánh giá mô hình bằng Đường cong học tập (Learning Curves)

Đường cong học tập là các biểu đồ thể hiện lỗi của mô hình dưới dạng hàm của kích thước tập huấn luyện.




Nó so sánh hai loại lỗi chính:

1. Lỗi trên tập **Huấn luyện** (Train) -
2. Lỗi trên tập **Xác thực** (Validation) -

Làm sao nhận biết mô hình đang quá khớp hay dưới khớp?
Hãy quan sát hình dạng của hai đường cong này.


Dưới khớp (Underfitting)



Cả hai đường đều đạt cao nguyên, **lỗi cao** và sát nhau. Lỗi **không cải thiện thêm** dù có cung cấp thêm dữ liệu huấn luyện.

Hình 4-15. Dưới khớp (Đường cong sát nhau, lỗi cao)

Quá khớp (Overfitting)



Lỗi trên tập huấn luyện thấp hơn nhiều, và có **khoảng cách (gap)** đáng kể giữa lỗi huấn luyện và lỗi xác thực.

Mô hình hoạt động rất tốt trên tập huấn luyện nhưng kém trên dữ liệu mới.

Hình 4-16. Quá khớp (Khoảng cách rõ ràng giữa 2 đường cong)

Phân rã Lỗi Tổng quát hóa

Lỗi tổng quát hóa có thể phân rã thành ba loại lỗi:



Độ chệch (Bias)

Lỗi do các giả định sai của mô hình (Vd: giả định dữ liệu tuyến tính khi thực tế là phi tuyến). Độ chệch cao thường gây ra underfitting.



Phương sai (Variance)

Lỗi do mô hình quá nhạy cảm với biến động nhỏ trong tập huấn luyện. Mô hình nhiều bậc tự do (bậc cao) có phương sai cao, gây ra overfitting.



Lỗi không thể giảm (Irreducible error)

Lỗi do độ nhiễu của bản thân dữ liệu. Chỉ có thể giảm bằng cách làm sạch dữ liệu.

Sự đánh đổi giữa Độ chệch và Phương sai



Chính quy hóa (Regularization) Mô hình Tuyến tính



Một cách tốt để giảm Overfitting là chính quy hóa (ràng buộc) mô hình.

Đối với mô hình tuyến tính, điều này thường thực hiện bằng cách ràng buộc kích thước của các trọng số θ .

Hồi quy Ridge (Chuẩn hóa Tikhonov)

$$J(\theta) = \text{MSE}(\theta) + \alpha \frac{1}{2} \sum \theta_i^2$$

Thêm số hạng phạt ℓ_2 vào hàm chi phí MSE.


α kiểm soát mức độ chính quy hóa.

Nếu $\alpha = 0$: Trở thành hồi quy tuyến tính bình thường.

Nếu α lớn: Tất cả trọng số θ sẽ gần về 0, tạo thành đường dự đoán phẳng hơn, giảm overfitting đáng kể (dao động cực mạnh biến mất, đường cong êm hơn).

Hồi quy Lasso (Least Absolute Shrinkage and Selection Operator)

$$J(\theta) = \text{MSE}(\theta) + \alpha \sum |\theta_i|$$




Tương tự Ridge nhưng sử dụng chuẩn l_1 làm số hạng phạt.

Lasso thay đổi hoàn toàn cách các trọng số bị giới hạn so với Ridge.

Điểm đặc biệt của Lasso: Lựa chọn đặc trưng


Nó có xu hướng hoàn toàn loại bỏ (đặt trọng số bằng 0) đối với các đặc trưng ít quan trọng nhất.



Do đó, Lasso tự động thực hiện lựa chọn đặc trưng (feature selection), tạo ra một mô hình thưa (sparse model).

(Dựa trên Hình 4-18. Các tham số bậc cao bị đưa về giá trị 0 hoàn toàn, biến đường đa thức thành đường thẳng bậc thấp).

Không gian tham số: Lasso vs. Ridge



Lasso (l_1): Chi phí giảm tuyến tính khi tiến tới các trục. Hạ gradient nhanh chóng khiến một tham số về 0 (ví dụ $\theta_2 = 0$), trượt trên trục θ_1 . Tạo ra mô hình thưa.

Ridge (l_2): Trọng số giảm dần khi tiến tới gốc tọa độ, gradient nhỏ đi giúp hội tụ êm, không dao động. Các tham số không bao giờ bị loại bỏ hoàn toàn (không về 0).

Hình 4-19. Chính quy hóa Lasso (Trên) và Ridge (Dưới)

Hồi quy Elastic Net & Lựa chọn Mô hình

Elastic Net kết hợp cả chuẩn L_1 và L_2 , điều khiển bởi tỷ lệ trộn r ($r=0 \rightarrow$ Ridge; $r=1 \rightarrow$ Lasso). Luôn ưu tiên dùng một ít chính quy hóa.

Mặc định

Ridge là lựa chọn mặc định tốt.


Nhiều nhiều, ít đặc trưng hữu ích

Dùng Lasso hoặc Elastic Net để loại bỏ đặc trưng vô ích.

Khi số lượng đặc trưng lớn

Elastic Net được ưa chuộng hơn Lasso vì Lasso hoạt động thất thường khi số đặc trưng lớn hơn số trường hợp, hoặc các đặc trưng có tương quan mạnh.

Dừng sớm (Early Stopping)



Hình 4-20. Early Stopping



Kỹ thuật này đơn giản và hiệu quả đến mức **Geoffrey Hinton** gọi nó là “**bữa trưa miễn phí tuyệt vời**”.

Các bước huấn luyện thêm sau điểm này chỉ làm mô hình tệ hơn.