



Học Máy Kết Hợp (Ensemble Learning)

Giải mã Sức mạnh của Bộ phân loại Bỏ phiếu (Voting Classifier) - Chương 7

Hiệu Suất Cơ Sở: Các “Chuyên Gia” Độc Lập

Độ chính xác (Accuracy) trên tập kiểm tra make_moons:



Bứt Phá Giới Hạn Với "Bỏ Phiếu" (Voting Classifier)

Tại sao sự kết hợp lại cho kết quả (0.912 / 0.920) cao hơn bất kỳ phép đo của mô hình riêng lẻ nào?

Bỏ phiếu cứng
(Hard Voting): **91.2%**




Bỏ phiếu mềm
(Soft Voting): **92.0%**




86.4%

89.6%


Nguyên Lý 1: "Mỗi Người Một Thế Mạnh"



Logistic Regression.
Cố gắng chia dữ liệu bằng một đường thẳng.



Random Forest. Chia dữ liệu bằng các đường cắt vuông góc (dạng bậc thang).



SVC.
Phân tách bằng các đường cong trơn.


Vì cách "nhìn" dữ liệu khác nhau theo nguyên lý toán học, chúng hiếm khi cùng đoán sai tại một mẫu dữ liệu!

Nguyên Lý 2: Đa Số Đề Thiểu Số (Bỏ Phiếu Cứng)


Bước 1: Một mẫu dữ liệu khó đi qua 3 mô hình.




Bước 2: Các dự đoán độc lập.



LR đoán Sai
(Lớp 0)



RF đoán Đúng
(Lớp 1)




SVC đoán Đúng
(Lớp 1)



Bước 3: 2 phiếu Lớp 1 > 1 phiếu Lớp 0.
Hai mô hình đúng đã "gánh" và sửa lỗi cho mô hình sai.
Độ chính xác đạt **91.2%.**

Nguyên Lý 3: Tận Dụng Độ Tin Cây (Bỏ Phiếu Mềm)



Rất chắc chắn: Dự đoán 99% là Lớp 1.
Ý kiến có trọng lượng vượt trội.

Phân vân: Chỉ đoán 51% là Lớp 0.
Ý kiến có trọng lượng thấp.

Thay vì đếm 1 phiếu thô (Đúng/Sai), Bỏ phiếu mềm tính trung bình xác suất %. Nhờ tận dụng độ tự tin, kết quả đạt đỉnh **92.0%**.

Tóm Lại: Sức Mạnh Của Tập Thể



Thuật toán đa dạng + Bỏ phiếu
(Cứng/Mềm) = Bứt phá giới hạn
hiệu suất.



Bạn có muốn xem ví dụ tính toán số
liệu cụ thể của **Bỏ phiếu mềm** hay
tìm hiểu về phương pháp
Bagging/Pasting trong **Chương 7**
không?

Đi đến Chương 7