

Học Máy (Machine Learning)

Chương 7: Học tổ hợp và Rừng ngẫu nhiên

Giảng viên: TS. Trần Thành Thắng

Đại học Đông Á

August 5, 2026





Nội dung Chương trình

- 1 Học tổ hợp (Ensemble Learning)
- 2 Bộ phân loại biểu quyết
- 3 Túi hóa (Bagging) và Dán nhãn (Pasting)
- 4 Rừng ngẫu nhiên (Random Forests)
- 5 Tăng cường (Boosting)
- 6 Phân lớp xếp chồng (Stacking)
- 7 Tổng kết Chương 7

Giới thiệu Học tổ hợp

Định nghĩa: Một phương pháp kết hợp các dự đoán của một nhóm các bộ dự đoán (bộ phân loại hoặc bộ hồi quy) để đạt được kết quả dự đoán tốt hơn so với bất kỳ bộ dự đoán riêng lẻ nào.



Một tập hợp (ensemble): Một nhóm các bộ dự đoán.



Học tổ hợp (ensemble learning): Phương pháp học sử dụng nhóm dự đoán này.




Phương pháp tổ hợp (ensemble method): Thuật toán sử dụng kỹ thuật này.

Sự khôn ngoan của đám đông



Giả sử bạn đặt một câu hỏi phức tạp cho hàng nghìn người ngẫu nhiên, sau đó tổng hợp câu trả lời của họ. Trong nhiều trường hợp, câu trả lời tổng hợp này tốt hơn câu trả lời của một chuyên gia.

→ **Sự khôn ngoan của đám đông.**



Ví dụ: Huấn luyện một nhóm các bộ phân loại cây quyết định trên các tập con ngẫu nhiên khác nhau của tập huấn luyện.




→ **Rừng ngẫu nhiên (Random Forest).**

Lưu ý: Thường được áp dụng gần cuối một dự án Machine Learning để đẩy tối đa độ chính xác của hệ thống.

Bộ phân loại biểu quyết (Voting Classifiers)



Khởi tạo: Bắt đầu bằng việc huấn luyện một vài bộ phân loại độc lập trên cùng một tập huấn luyện.



Đa dạng: Mỗi bộ phân loại có thể thuộc các loại khác nhau: SVM, Logistic Regression, Random Forest, K-Nearest Neighbors... (Mỗi bộ phân loại đạt độ chính xác riêng lẻ, ví dụ khoảng 80%.)

Kỹ thuật: Tổng hợp các dự đoán của tất cả các bộ phân loại và đưa ra dự đoán tập hợp.

Huấn luyện các bộ phân loại đa dạng



Hình 7-1. Huấn luyện các bộ phân loại đa dạng

Bộ phân loại bỏ phiếu cứng (Hard Voting)




Bỏ phiếu cứng (Hard voting): Dự đoán của tập hợp là lớp nhận được nhiều phiếu bầu đa số nhất từ các bộ phân loại riêng lẻ. Mặc dù đơn giản, bộ phân loại bỏ phiếu cứng thường đạt được độ chính xác cao hơn bộ phân loại tốt nhất trong tập hợp.



Bộ học yếu vs Bộ học mạnh: Ngay cả khi mỗi bộ phân loại chỉ là một bộ học yếu (weak learner - chỉ tốt hơn đoán ngẫu nhiên một chút), tập hợp vẫn có thể trở thành một bộ học mạnh (strong learner) nếu có đủ số lượng bộ học đa dạng.

Dự đoán bỏ phiếu cứng



Dự đoán bỏ phiếu cứng

Nguyên lý đằng sau bộ phân loại biểu quyết

Làm sao để các bộ học yếu kết hợp lại thành bộ học mạnh?



Phép tương tự: Tung đồng xu. Tung một đồng xu hơi lệch (51% sấp, 49% ngửa).



1.000 lần: Tỷ lệ mặt sấp sẽ tiến gần **51%**. Xác suất để đa số (trên 500 lần) là mặt sấp lên đến **~ 75%**.




10.000 lần: Xác suất đạt đa số mặt sấp tăng lên **> 97%**.



Đây là ứng dụng của **Luật số lớn (Law of Large Numbers)**.

Luật số lớn

Hình 7-3. Luật số lớn - Tỷ lệ mặt sấp khi số lần tung tăng



Lưu ý quan trọng:

Tập hợp chỉ hoạt động hoàn hảo khi các bộ phận loại hoàn toàn độc lập, mắc lỗi không tương quan.

Do cùng dùng một tập dữ liệu, chúng thường tương quan → làm giảm độ chính xác tập hợp so với kỳ vọng lý thuyết.

Mã nguồn: Bộ phân loại bỏ phiếu cứng (Phần 1)

Sử dụng **VotingClassifier** trong Scikit-Learn trên tập dữ liệu **moons**:



```
1 from sklearn.datasets import make_moons
2 from sklearn.ensemble import RandomForestClassifier , VotingClassifier
3 from sklearn.linear_model import LogisticRegression
4 from sklearn.model_selection import train_test_split
5 from sklearn.svm import SVC
6
7 X, y = make_moons(n_samples=500, noise=0.30, random_state=42)
8 X_train, X_test, y_train, y_test = train_test_split(X, y, random_state=42)
```

Mã nguồn: Bộ phân loại bỏ phiếu cứng (Phần 2)

Định nghĩa và huấn luyện tập hợp:

```
1 voting_clf = VotingClassifier(  
2     estimators=[  
3         ('lr', LogisticRegression(random_state=42)),  
4         ('rf', RandomForestClassifier(random_state=42)),  
5         ('svc', SVC(random_state=42))  
6     ]  
7 )  
8 voting_clf.fit(X_train, y_train)  
9  
10 # Kiểm tra kết quả:  
11 voting_clf.score(X_test, y_test) # Output: 0.912
```




Kết quả: Độ chính xác 91.2%, cao hơn độ chính xác của Logistic (86.4%), Random Forest (89.6%) và SVC (89.6%).

Bỏ phiếu mềm (Soft Voting)

Nếu tất cả các bộ phân loại có khả năng ước tính xác suất lớp (có phương thức `predict_proba()`), tập hợp có thể đưa ra dự đoán dựa trên trung bình xác suất của từng lớp trên tất cả các bộ phân loại.

Bỏ phiếu mềm (Soft voting): Chọn lớp có xác suất trung bình cao nhất.

Ưu điểm: Thường đạt hiệu suất cao hơn bỏ phiếu cứng vì nó ưu tiên các phiếu bầu có độ tin cậy cao.



Mã nguồn: Bỏ phiếu mềm


Đặt siêu tham số **voting="soft"** và đảm bảo các mô hình (như SVC) có tính xác suất (**probability=True**):

```
1 voting_clf.voting = "soft"
2 voting_clf.named_estimators["svc"].probability = True
3 voting_clf.fit(X_train, y_train)
4 voting_clf.score(X_test, y_test)
5 # Output: 0.92
```



Kết quả: Độ chính xác tăng lên 92% chỉ nhờ sử dụng bỏ phiếu mềm.

Túi hóa (Bagging) và Dán nhãn (Pasting)




Thay vì dùng nhiều thuật toán khác nhau, một cách tiếp cận khác là sử dụng cùng một thuật toán cho mỗi bộ dữ liệu huấn luyện trên các tập con ngẫu nhiên khác nhau của tập huấn luyện.



Túi hóa (Bagging - Bootstrap Aggregating)

Lấy mẫu ngẫu nhiên có hoàn lại (có thay thế). Một mẫu có thể được chọn nhiều lần cho cùng một bộ dữ liệu đoán.



Dán nhãn (Pasting)

Lấy mẫu ngẫu nhiên không hoàn lại (không thay thế). Một mẫu chỉ được chọn nhiều nhất một lần cho mỗi bộ dữ liệu đoán.