

Học Máy (Machine Learning)

Chương 7: Học tổ hợp và Rừng ngẫu nhiên

Giảng viên: TS. Trần Thành Thắng

Đại học Đông Á

August 5, 2026

Nội dung Chương trình

- 1 Học tổ hợp (Ensemble Learning)
- 2 Bộ phân loại biểu quyết
- 3 Túi hóa (Bagging) và Dán nhãn (Pasting)
- 4 Rừng ngẫu nhiên (Random Forests)
- 5 Tăng cường (Boosting)
- 6 Phân lớp xếp chồng (Stacking)
- 7 Tổng kết Chương 7

- **Định nghĩa:** Một phương pháp kết hợp các dự đoán của một nhóm các bộ dự đoán (bộ phân loại hoặc bộ hồi quy) để đạt được kết quả dự đoán tốt hơn so với bất kỳ bộ dự đoán riêng lẻ nào.
- Một nhóm các bộ dự đoán được gọi là **một tập hợp (ensemble)**.
- Phương pháp học này được gọi là **học tổ hợp (ensemble learning)**.
- Thuật toán sử dụng kỹ thuật này gọi là **phương pháp tổ hợp (ensemble method)**.


Sự khôn ngoan của đám đông

- Giả sử bạn đặt một câu hỏi phức tạp cho hàng nghìn người ngẫu nhiên, sau đó tổng hợp câu trả lời của họ.
- Trong nhiều trường hợp, câu trả lời tổng hợp này tốt hơn câu trả lời của một chuyên gia → **Sự khôn ngoan của đám đông**.
- **Ví dụ:** Huấn luyện một nhóm các bộ phân loại cây quyết định trên các tập con ngẫu nhiên khác nhau của tập huấn luyện → **Rừng ngẫu nhiên (Random Forest)**.
- Thường được áp dụng gần cuối một dự án Machine Learning để đẩy tối đa độ chính xác của hệ thống.

Bộ phân loại biểu quyết (Voting Classifiers)

- Bắt đầu bằng việc huấn luyện một vài bộ phân loại độc lập trên cùng một tập huấn luyện.
- Mỗi bộ phân loại có thể thuộc các loại khác nhau: SVM, Logistic Regression, Random Forest, K-Nearest Neighbors...
- Mỗi bộ phân loại đạt độ chính xác riêng lẻ, ví dụ khoảng 80%.
- Kỹ thuật: Tổng hợp các dự đoán của tất cả các bộ phân loại và đưa ra dự đoán tập hợp.

Huấn luyện các bộ phân loại đa dạng




Hình 7-1. Huấn luyện các bộ phân loại đa dạng

Bộ phân loại bỏ phiếu cứng (Hard Voting)

- **Bỏ phiếu cứng (Hard voting):** Dự đoán của tập hợp là lớp nhận được nhiều phiếu bầu đa số nhất từ các bộ phân loại riêng lẻ.
- Mặc dù đơn giản, bộ phân loại bỏ phiếu cứng thường đạt được độ chính xác cao hơn bộ phân loại tốt nhất trong tập hợp.
- Ngay cả khi mỗi bộ phân loại chỉ là một **bộ học yếu** (weak learner - chỉ tốt hơn đoán ngẫu nhiên một chút), tập hợp vẫn có thể trở thành một **bộ học mạnh** (strong learner) nếu có đủ số lượng bộ học đa dạng.


Dự đoán bỏ phiếu cứng



Nguyên lý đằng sau bộ phân loại biểu quyết

- Làm sao để các bộ học yếu kết hợp lại thành bộ học mạnh?
- **Phép tương tự:** Tung một đồng xu hơi lệch (51% sấp, 49% ngửa).
- Nếu tung 1.000 lần, tỷ lệ mặt sấp sẽ tiến gần 51%. Xác suất để đa số (trên 500 lần) là mặt sấp lên đến $\sim 75\%$.
- Tung 10.000 lần, xác suất đạt đa số mặt sấp tăng lên $> 97\%$.
- Đây là ứng dụng của **Luật số lớn (Law of Large Numbers)**.

Luật số lớn



Hình 7-3. Luật số lớn - Tỷ lệ mặt sấp khi số lần tung tăng

- *Lưu ý:* Tập hợp chỉ hoạt động hoàn hảo khi các bộ phân loại **hoàn toàn độc lập**, mắc lỗi không tương quan. Do cùng dùng một tập dữ liệu, chúng thường tương quan → làm giảm độ chính xác tập hợp so với kỳ vọng lý thuyết.

Mã nguồn: Bộ phân loại bỏ phiếu cứng (Phần 1)

Sử dụng VotingClassifier trong Scikit-Learn trên tập dữ liệu moons:

```
1 from sklearn.datasets import make_moons
2 from sklearn.ensemble import RandomForestClassifier, VotingClassifier
3 from sklearn.linear_model import LogisticRegression
4 from sklearn.model_selection import train_test_split
5 from sklearn.svm import SVC
6
7 X, y = make_moons(n_samples=500, noise=0.30, random_state=42)
8 X_train, X_test, y_train, y_test = train_test_split(X, y, random_state=42)
9
```

Mã nguồn: Bộ phân loại bỏ phiếu cứng (Phần 2)

Định nghĩa và huấn luyện tập hợp:

```
1 voting_clf = VotingClassifier(  
2     estimators=[  
3         ('lr', LogisticRegression(random_state=42)),  
4         ('rf', RandomForestClassifier(random_state=42)),  
5         ('svc', SVC(random_state=42))  
6     ]  
7 )  
8 voting_clf.fit(X_train, y_train)  
9  
10 # Kiểm tra kết quả:  
11 voting_clf.score(X_test, y_test) # Output: 0.912  
12
```

- Độ chính xác 91.2%, cao hơn độ chính xác của Logistic (86.4%), Random Forest (89.6%) và SVC (89.6%).

Bỏ phiếu mềm (Soft Voting)

- Nếu tất cả các bộ phân loại có khả năng ước tính xác suất lớp (có phương thức `predict_proba()`), tập hợp có thể đưa ra dự đoán dựa trên **trung bình xác suất** của từng lớp trên tất cả các bộ phân loại.
- **Bỏ phiếu mềm (Soft voting):** Chọn lớp có xác suất trung bình cao nhất.
- Thường đạt hiệu suất cao hơn bỏ phiếu cứng vì nó ưu tiên các phiếu bầu có độ tin cậy cao.

Mã nguồn: Bỏ phiếu mềm

Đặt siêu tham số `voting="soft"` và đảm bảo các mô hình (như SVC) có tính xác suất (`probability=True`):

```
1 voting_clf.voting = "soft"
2 voting_clf.named_estimators["svc"].probability = True
3 voting_clf.fit(X_train, y_train)
4 voting_clf.score(X_test, y_test)
5 # Output: 0.92
6
```

- Độ chính xác tăng lên 92% chỉ nhờ sử dụng bỏ phiếu mềm.

Túi hóa (Bagging) và Dán nhãn (Pasting)

- Thay vì dùng nhiều thuật toán khác nhau, một cách tiếp cận khác là sử dụng **cùng một thuật toán** cho mỗi bộ dữ liệu huấn luyện trên các **tập con ngẫu nhiên khác nhau** của tập huấn luyện.
- **Túi hóa (Bagging - Bootstrap Aggregating):** Lấy mẫu ngẫu nhiên *có hoàn lại* (có thay thế). Một mẫu có thể được chọn nhiều lần cho cùng một bộ dữ liệu huấn luyện.
- **Dán nhãn (Pasting):** Lấy mẫu ngẫu nhiên *không hoàn lại* (không thay thế). Một mẫu chỉ được chọn nhiều nhất một lần cho mỗi bộ dữ liệu huấn luyện.