


# Học Máy (Machine Learning)

## Chương 8: Giảm chiều dữ liệu (Dimensionality Reduction)

Giảng viên: TS. Trần Thành Thắng

Đại học Đông Á

August 5, 2026



# Nội dung Chương trình



**Khái quát về Giảm chiều dữ liệu**



**Phân tích thành phần chính (PCA)**



**Phép chiếu ngẫu nhiên & LLE**



# Giới thiệu Giảm chiều dữ liệu

## Lời nguyền của số chiều (The curse of dimensionality)

- Hàng nghìn/triệu đặc trưng (features) cho mỗi trường hợp huấn luyện.
- Làm quá trình huấn luyện cực kỳ chậm.
- Khó tìm ra giải pháp tốt.



## Kỹ thuật Giảm chiều (Dimensionality Reduction)


- Biến bài toán phức tạp thành có thể giải quyết được.
- Loại bỏ các đặc trưng không quan trọng hoặc dư thừa.

Lợi ích 1: Tăng tốc quá trình huấn luyện

# Giảm số lượng đặc trưng giúp thuật toán chạy nhanh hơn đáng kể, tốn ít bộ nhớ hơn.



Ví dụ: Ảnh MNIST




- Các pixel ở đường biên **hầu như luôn trắng** -> Có thể loại bỏ hoàn toàn không mất thông tin hữu ích.
- Hai pixel lân cận tương quan cao -> Có thể hợp nhất (vd: lấy trung bình) để giảm dữ liệu.




# Lợi ích 2: Trực quan hóa dữ liệu

Rất khó để vẽ đồ thị > 3 chiều.



**Giảm xuống 2 hoặc 3 chiều:** Vẽ biểu đồ trực quan, dễ dàng quan sát và phát hiện các mẫu (clusters).



Trực quan hóa là điều cần thiết để truyền đạt kết luận cho những người ra quyết định.



# Lời nguyên của số chiều: Trực giác thất bại

Không gian 2D

**0.4%**

Cơ hội một điểm ngẫu nhiên nằm cách đường biên dưới 0.001 trong hình vuông 1x1.

Không gian 10.000D


**> 99.9999999%**

Xác suất tương ứng trong một siêu hình lập phương 10.000 chiều.

**Kết luận:** Hầu hết các điểm trong một không gian có chiều cao đều nằm rất gần đường biên.



# Hình ảnh: Lối nguyên số chiều



Hình 8-1. Điểm, đoạn thẳng, hình vuông, hình lập phương và tesseract (siêu hình lập



# Sự khác biệt khoảng cách trong không gian chiều cao

**Bậc 1 (2D):**  
Hình vuông đơn vị ->  
Khoảng cách trung  
bình  $\approx 0.52$

**Bậc 2 (3D):**  
Hình lập phương đơn vị  
-> Khoảng cách trung  
bình  $\approx 0.66$

**Bậc 3 (1,000,000D):**  
Siêu hình lập phương ->  
Khoảng cách trung bình  $\approx 408.25$

Có rất nhiều không gian trong các chiều cao, dẫn đến dữ liệu vô cùng thưa thớt (sparse).

# Nguy cơ quá khớp do thưa thớt




**Tóm lại: Tập huấn luyện càng có nhiều chiều, rủi ro quá khớp càng tăng cao.**



# Các cách tiếp cận chính để giảm chiều


*Thay vì cố gắng thu thập dữ liệu bằng số nguyên tử vũ trụ (để đủ độ dày đặc), chúng ta dùng các thuật toán giảm chiều:*

# 1



**Phép chiếu  
(Projection)**

# 2



**Học đa tạp  
(Manifold Learning)**

# Cách tiếp cận 1: Phép chiếu (Projection)

## Thực tế phân bố dữ liệu


- Các trường hợp huấn luyện không được phân bố đều đặn (uniform) trên tất cả các chiều.
- Nhiều đặc trưng gần như không đổi.
- Các đặc trưng khác tương quan mạnh với nhau.

## Khái niệm Không gian con (Subspace)

Kết quả: Mọi trường hợp huấn luyện thường nằm gọn trong (hoặc rất gần) một **không gian con** có số chiều thấp hơn nhiều so với với không gian gốc.




# Hình ảnh minh họa Phép chiếu 1



Tập dữ liệu 3D gần không gian con 2D

Hình 8-2. Một tập dữ liệu 3D nằm gần một không gian con 2D (mặt phẳng)

# Hình ảnh minh họa Phép chiếu 2



Tập dữ liệu 2D mới sau phép chiếu

Hình 8-3. Bằng cách chiếu vuông góc các điểm lên mặt phẳng, ta thu được tập dữ liệu 2D mới



# Cách tiếp cận 2: Học đa tạp (Manifold Learning)


Phép chiếu không phải lúc nào cũng là cách tiếp cận tốt nhất.



**Trong nhiều trường hợp, không gian con có thể bị xoắn và uốn cong.**

Ví dụ điển hình: Tập dữ liệu Swiss roll.

# Hình ảnh minh họa Học đa tạp



Tập dữ liệu Swiss roll

Hình 8-4. Tập dữ liệu Swiss roll (như một tờ giấy bị cuộn lại trong không gian 3D)