

Học Máy (Machine Learning)

Chương 8: Giảm chiều dữ liệu (Dimensionality Reduction)

Giảng viên: TS. Trần Thành Thắng

Đại học Đông Á

August 5, 2026

Nội dung Chương trình

- 1 Khái quát về Giảm chiều dữ liệu
- 2 Phân tích thành phần chính (PCA)
- 3 Phép chiếu ngẫu nhiên & LLE

Giới thiệu Giảm chiều dữ liệu

- Trong thực tế, nhiều bài toán học máy liên quan đến hàng nghìn hoặc hàng triệu đặc trưng (features) cho mỗi trường hợp huấn luyện.
- Việc này không chỉ làm quá trình huấn luyện cực kỳ chậm mà còn làm cho việc tìm ra một giải pháp tốt trở nên khó khăn hơn.
- Vấn đề này thường được gọi là **lời nguyền của số chiều** (the curse of dimensionality).
- Kỹ thuật giảm chiều (Dimensionality Reduction) giúp biến bài toán phức tạp thành bài toán có thể giải quyết được bằng cách loại bỏ các đặc trưng không quan trọng hoặc dư thừa.

Lợi ích 1: Tăng tốc quá trình huấn luyện

- Giảm số lượng đặc trưng giúp thuật toán học máy chạy nhanh hơn đáng kể, tốn ít bộ nhớ hơn.
- **Ví dụ (Ảnh MNIST):** Các pixel ở đường biên hình ảnh hầu như luôn trắng.
- Ta có thể loại bỏ hoàn toàn các pixel này khỏi tập huấn luyện mà không làm mất nhiều thông tin hữu ích cho tác vụ phân loại chữ số.
- Hai pixel lân cận thường có tương quan cao, có thể hợp nhất chúng (ví dụ: lấy trung bình) để giảm dữ liệu.


Lợi ích 2: Trực quan hóa dữ liệu

- Trực quan hóa là điều cần thiết để truyền đạt kết luận của nhà khoa học dữ liệu cho những người ra quyết định.
- Rất khó để vẽ một đồ thị có hơn 3 chiều.
- Giảm số lượng chiều xuống còn 2 hoặc 3 giúp vẽ biểu đồ trực quan, giúp con người dễ dàng quan sát và phát hiện các mẫu (chẳng hạn như các cụm/clusters).

Lời nguyên của số chiều

- Chúng ta quen sống trong không gian 3D, do đó trực giác thường thất bại khi hình dung không gian có chiều cao (ví dụ: 1.000 chiều).
- Trong không gian chiều cao, nhiều thứ hoạt động rất khác.
- Một điểm ngẫu nhiên trong hình vuông 1×1 (2D) chỉ có 0.4% cơ hội nằm cách đường biên dưới 0.001.
- Trong một siêu hình lập phương 10.000 chiều, xác suất này $> 99.999999\%$.
- **Kết luận:** Hầu hết các điểm trong một không gian có chiều cao đều nằm *rất gần đường biên*.

Hình ảnh: Lời nguyên số chiều



Hình 8-1. Điểm, đoạn thẳng, hình vuông, hình lập phương và tesseract (siêu hình lập

Sự khác biệt khoảng cách trong không gian chiều cao

- Nếu chọn hai điểm ngẫu nhiên trong một hình vuông 2D đơn vị, khoảng cách trung bình là ≈ 0.52 .
- Trong hình lập phương 3D đơn vị, khoảng cách trung bình là ≈ 0.66 .
- Trong một siêu hình lập phương đơn vị 1.000.000 chiều, khoảng cách trung bình là ≈ 408.25 .
- Có rất nhiều không gian trong các chiều cao, dẫn đến dữ liệu vô cùng thưa thớt (sparse).

Nguy cơ quá khớp do thừa thớt

- Tập dữ liệu có chiều cao $\rightarrow$ hầu hết các trường hợp huấn luyện cách rất xa nhau.
- Một trường hợp mới (test instance) có thể sẽ cách xa bất kỳ trường hợp huấn luyện nào đã biết.
- Dự đoán sẽ kém tin cậy hơn nhiều vì phải dựa trên các phép *ngoại suy* (*extrapolation*) lớn.
- **Tóm lại:** Tập huấn luyện càng có nhiều chiều, nguy cơ **quá khớp (overfitting)** càng lớn.

Các cách tiếp cận chính để giảm chiều


Thay vì cố gắng thu thập dữ liệu bằng số nguyên tử vũ trụ (để đủ độ dày đặc), chúng ta dùng các thuật toán giảm chiều:

- 1 **Phép chiếu (Projection)**
- 2 **Học đa tạp (Manifold Learning)**

Cách tiếp cận 1: Phép chiếu (Projection)


- Trong hầu hết các bài toán thực tế, các trường hợp huấn luyện không được phân bố đều đặn (uniform) trên tất cả các chiều.
- Nhiều đặc trưng gần như không đổi, trong khi các đặc trưng khác tương quan mạnh.
- Kết quả là, mọi trường hợp huấn luyện thường nằm gọn trong (hoặc rất gần) một **không gian con (subspace) có số chiều thấp hơn nhiều** so với không gian gốc.

Tập dữ liệu 3D gần không gian con 2D



Hình 8-2. Một tập dữ liệu 3D nằm gần một không gian con 2D (mặt phẳng)

Tập dữ liệu 2D mới sau phép chiếu




Hình 8-3. Bằng cách chiếu vuông góc các điểm lên mặt phẳng, ta thu được tập dữ liệu 2D mới

Cách tiếp cận 2: Học đa tạp (Manifold Learning)

- Phép chiếu không phải lúc nào cũng là cách tiếp cận tốt nhất.
- Trong nhiều trường hợp, không gian con có thể bị **xoắn và uốn cong**.
- Ví dụ điển hình: Tập dữ liệu **Swiss roll**.

Tập dữ liệu Swiss roll



Hình 8-4. Tập dữ liệu Swiss roll (như một tờ giấy bị cuộn lại trong không gian 3D)