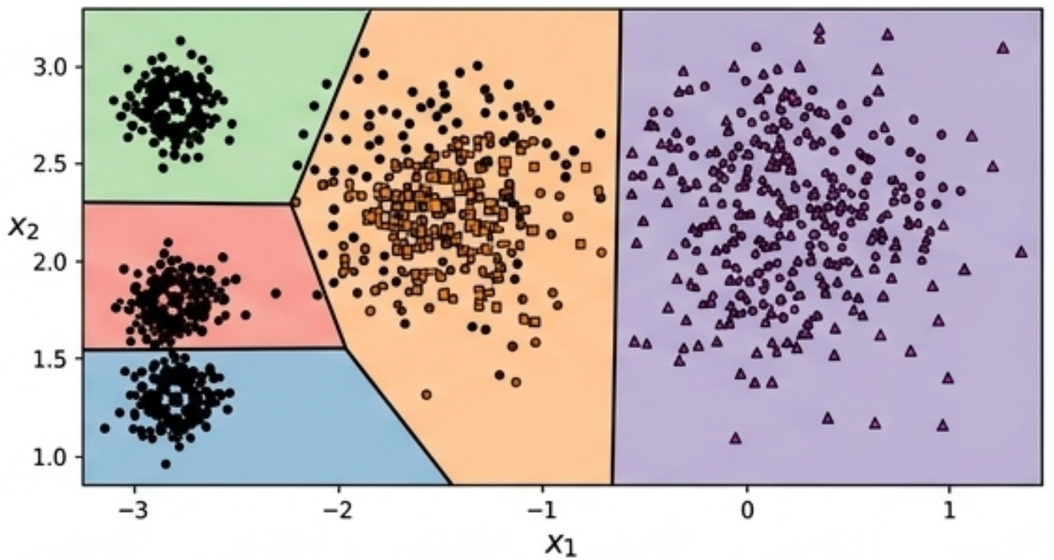


Thuật toán K-Means: Khám phá Dữ liệu Không giám sát

Nền tảng cốt lõi, tốc độ và cách thuật toán tự học từ dữ liệu chưa gán nhãn.

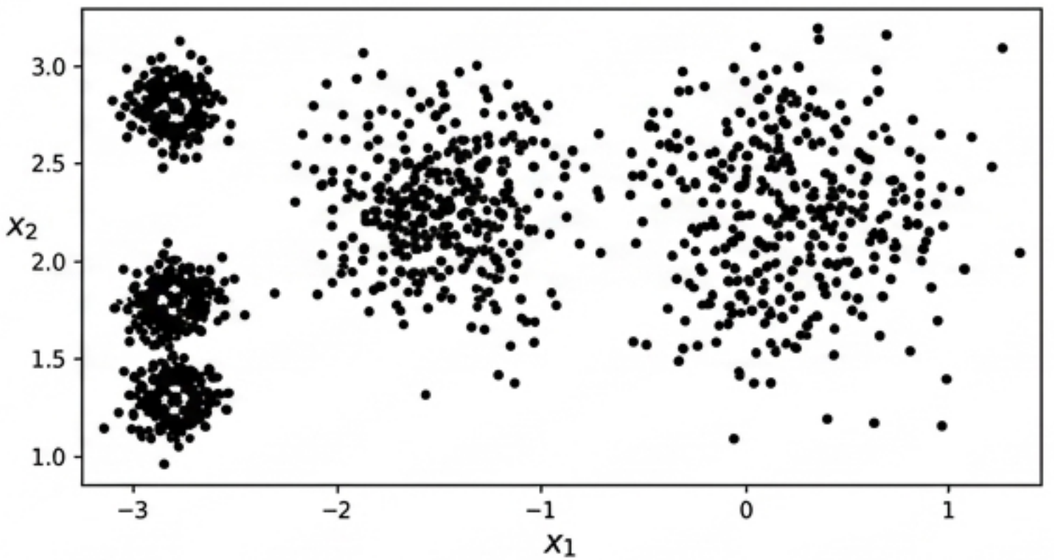
Gemini Notebook

Bối cảnh: Phân loại vs. Phân cụm



Có nhãn (Supervised)

Đã biết trước danh mục (ví dụ: các giống hoa Iris). Thuật toán học cách **phân loại** dữ liệu mới.



Không nhãn (Unsupervised)

Máy học đối mặt với dữ liệu trắng. Thuật toán phải tự tìm ra sự tương đồng và **gom cụm** mà không cần con người chỉ dẫn.

Làm thế nào máy tính có thể tự nhìn ra 3 nhóm hoa?

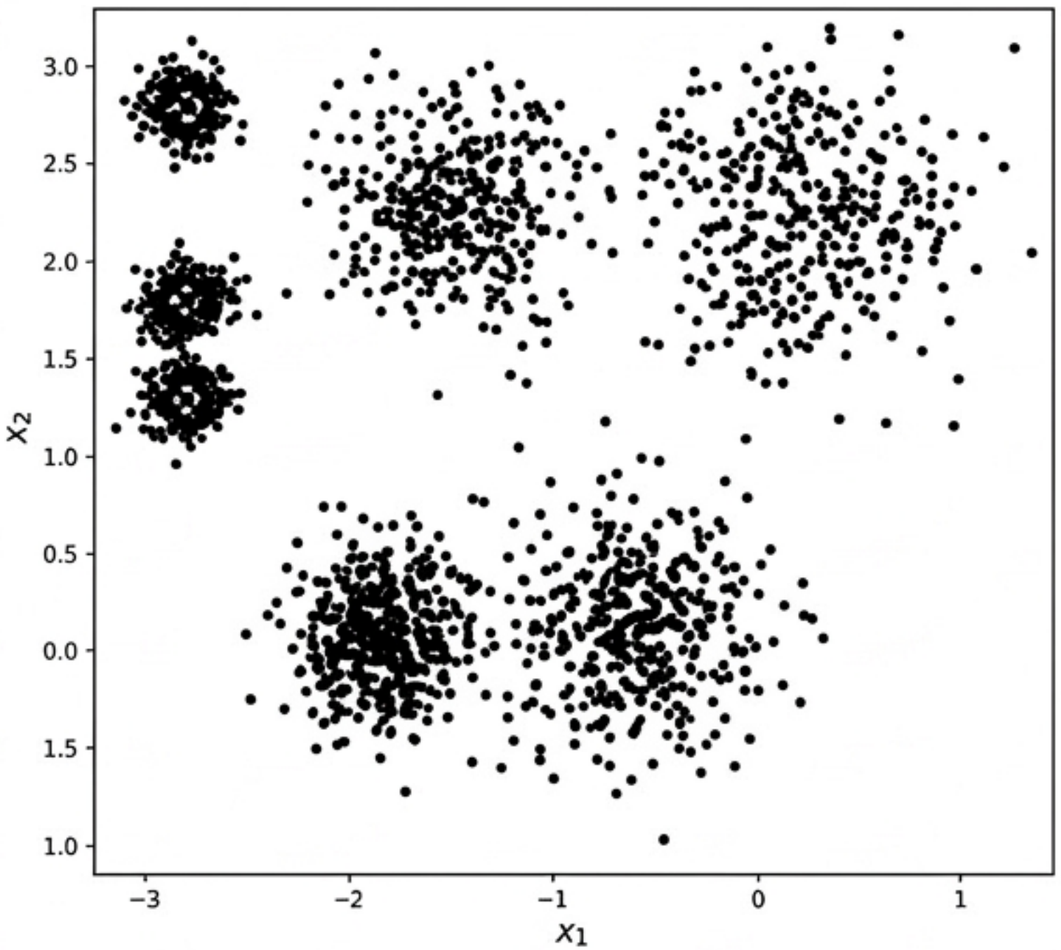
Gemini Notebook

K-Means là gì?

Định nghĩa: Thuật toán **Lloyd-Forgy** (K-Means) là kỹ thuật phân cụm nhanh và phổ biến nhất.

Mục tiêu cốt lõi: Phân chia m điểm dữ liệu thành k cụm (clusters) được chọn trước.

Thuật toán tìm cách **giảm thiểu tổng khoảng cách bình phương** từ mỗi điểm dữ liệu đến **tâm cụm (centroid)** gần nhất của nó.



Gemini Notebook

Giải phẫu vòng lặp K-Means

Bước 1: Khởi tạo

Chọn ngẫu nhiên vị trí cho k tâm cụm ban đầu.

Bước 2: Gán nhãn (Hard Clustering)

Đo khoảng cách và gán mỗi điểm dữ liệu vào tâm cụm gần nhất.

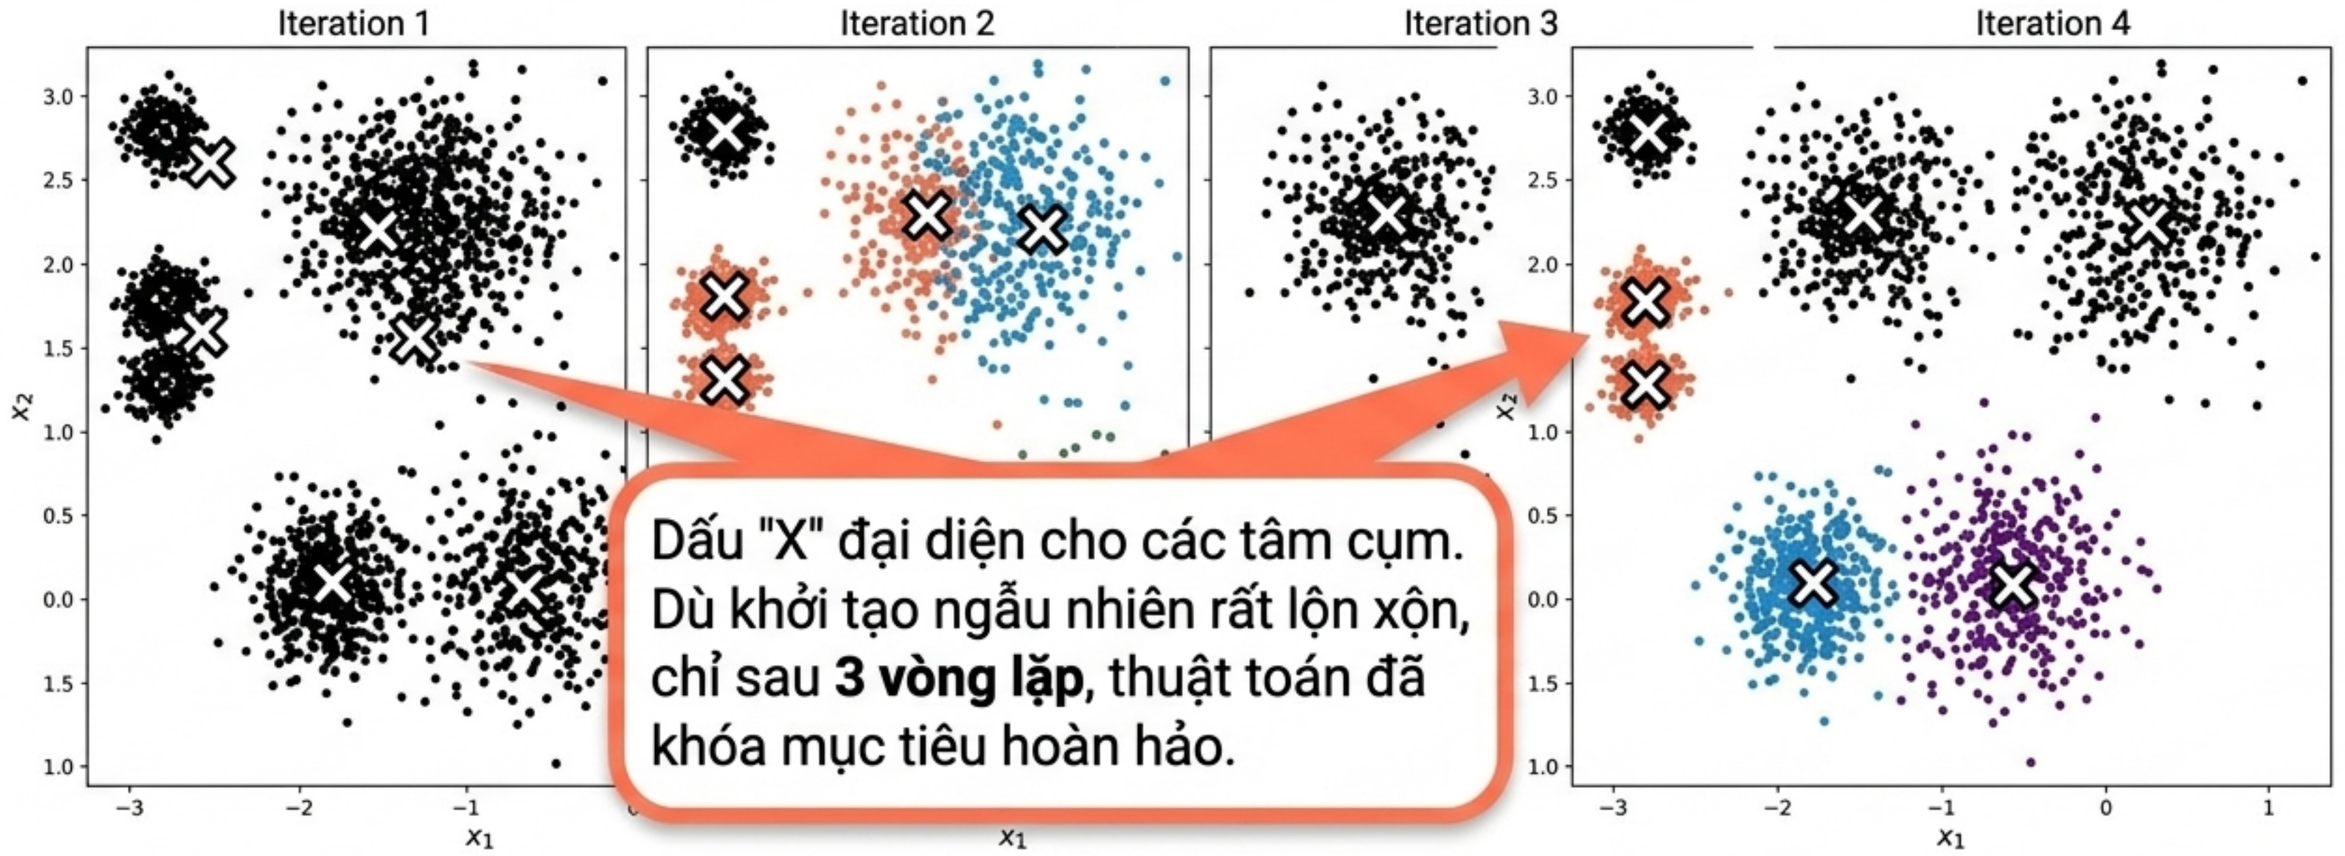
Bước 3: Cập nhật Tâm

Tính **giá trị trung bình** tọa độ các điểm trong cụm để tạo vị trí tâm mới.



Gemini Notebook

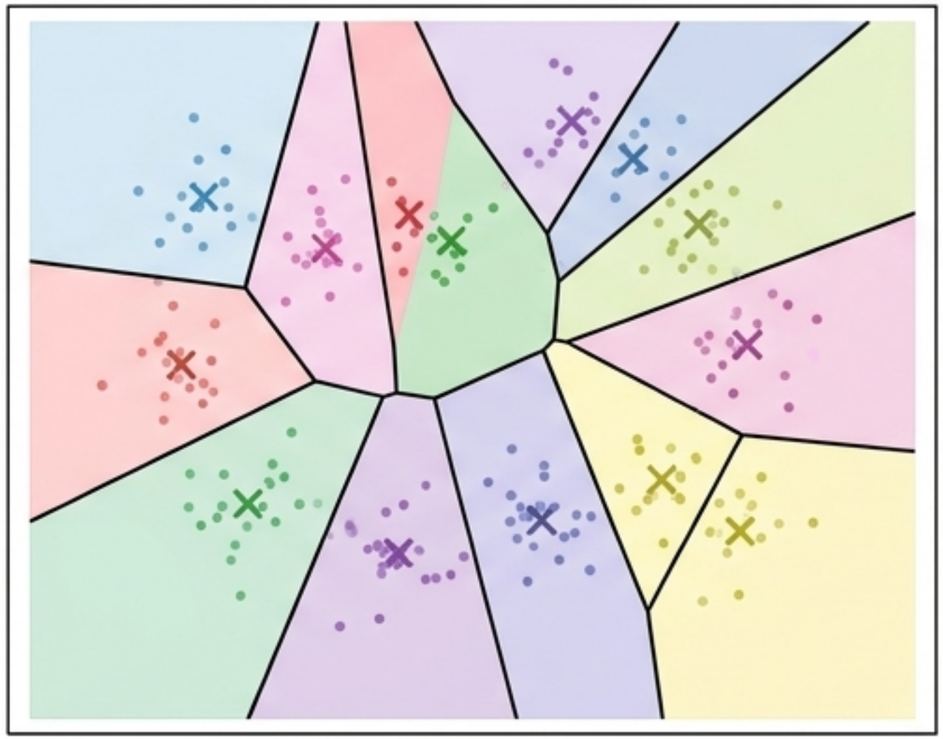
Trực quan hóa **Sự hội tụ**



Tính tất yếu: Thuật toán **chắc chắn hội tụ** vì khoảng cách trung bình luôn giảm dần (không bao giờ tăng) ở mỗi bước.

Gemini Notebook

Ranh giới Quyết định & Phân cụm Mềm



Phân cụm Cứng (Hard Clustering)

Gán dứt khoát 1 điểm vào duy nhất 1 cụm. Tạo ra biểu đồ phân vùng Voronoi (như hình trên).

Phân cụm Mềm (Soft Clustering)

Thay vì gán cứng, đo **khoảng cách từ 1 điểm đến tất cả** các tâm cụm. Giúp tạo ra một bộ đặc trưng mới, đóng vai trò như một kỹ thuật **giảm chiều dữ liệu phi tuyến tính**.

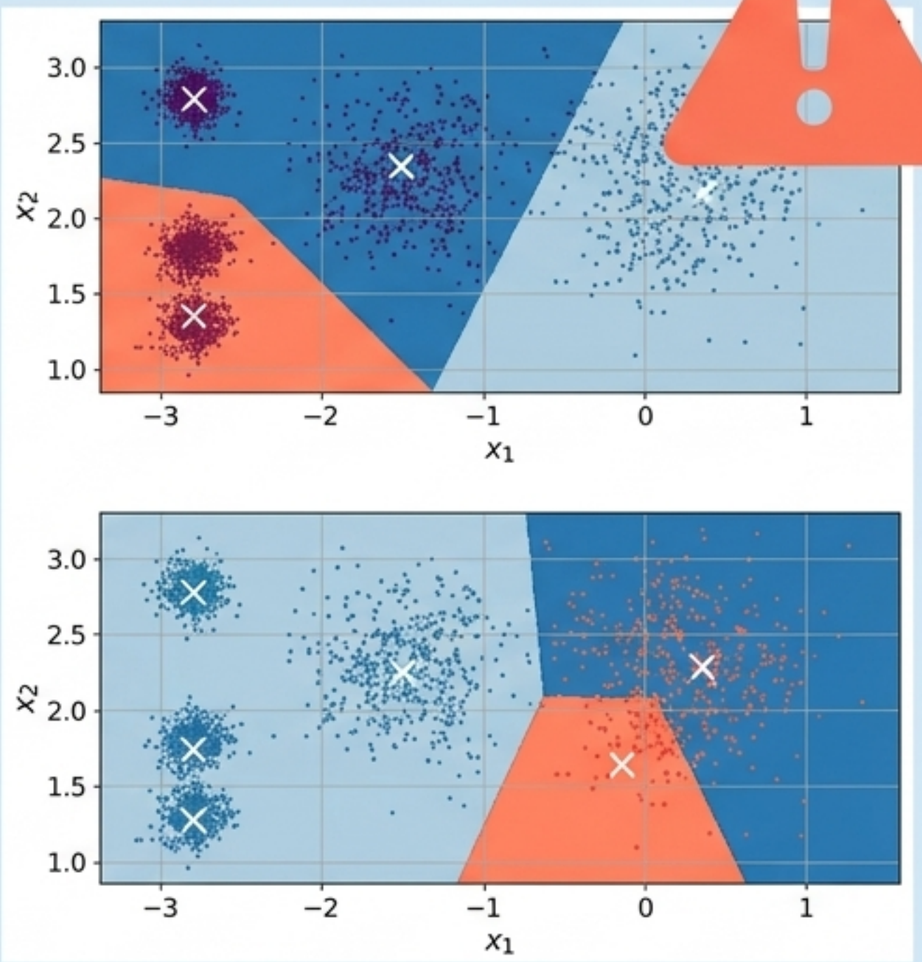
Gemini Notebook

Rủi ro Khởi tạo & Điểm Quán tính (Inertia)

Vấn đề: Khởi tạo ngẫu nhiên sai lầm có thể khiến K-Means kẹt ở **cực tiểu cục bộ** (kết quả phân cụm sai lệch).

Thước đo - Quán tính (Inertia): Tổng bình phương khoảng cách từ các điểm đến tâm cụm của chúng. Quán tính càng thấp, mô hình càng tốt.

Giải pháp Scikit-Learn: Tự động chạy thuật toán 10 lần (n_init=10) với các điểm khởi tạo khác nhau và chọn mô hình có Inertia thấp nhất.



Gemini Notebook

Ma trận Nâng cấp: Tốc độ và Sự chính xác



K-Means++

(Khởi tạo thông minh)

Thuật toán ép các tâm cụm ban đầu nằm **càng xa nhau càng tốt** bằng xác suất phân phối. Triệt tiêu gần như hoàn toàn rủi ro **kẹt ở cực tiểu cục bộ**.



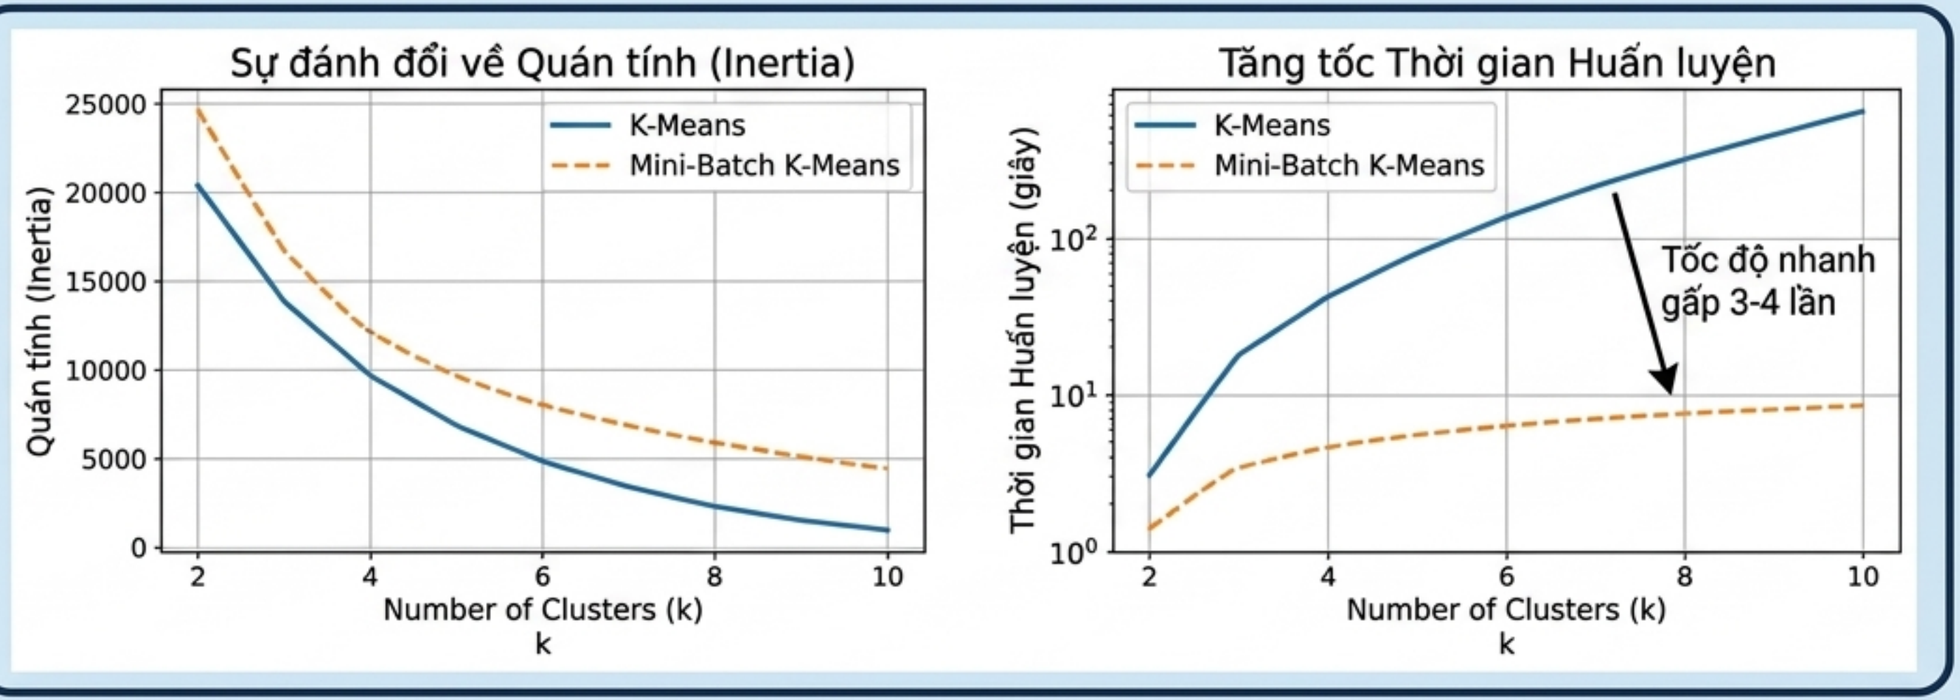
Elkan K-Means

(Tăng tốc toán học)

Khai thác **bất đẳng thức tam giác** ($AC \leq AB + BC$) để bỏ qua các phép tính khoảng cách thừa. Tăng tốc độ thuật toán đáng kể trên dữ liệu lớn.

Gemini Notebook

Mini-Batch K-Means cho Dữ liệu Khổng lồ



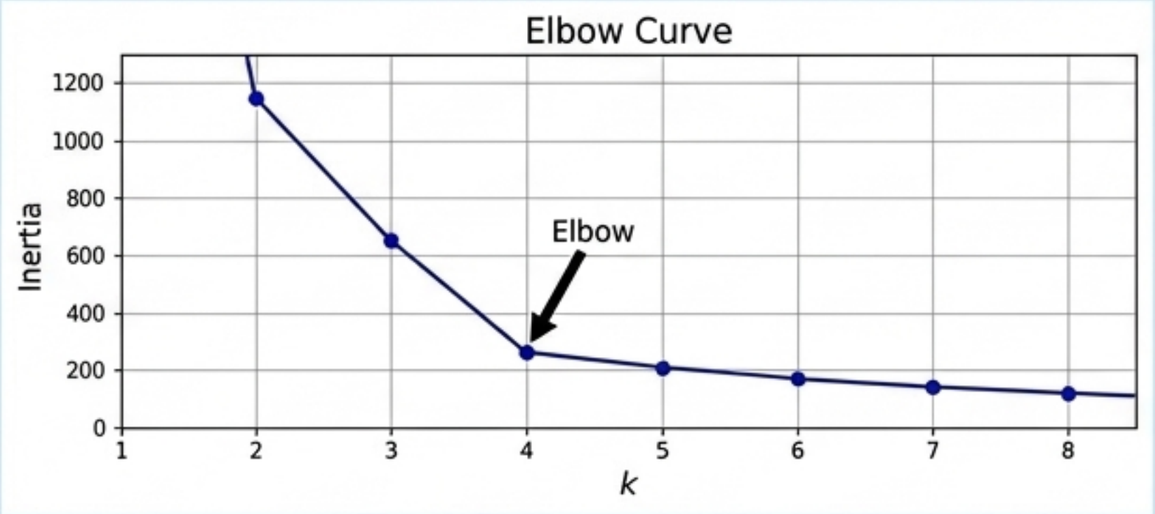
Cơ chế: Xử lý các tập dữ liệu không vừa bộ nhớ (RAM) bằng cách cập nhật tâm cụm từng chút một qua các **lô nhỏ (mini-batches)**.

Sự đánh đổi (Trade-off): Điểm Quán tính (Inertia) tăng lên một chút (độ chính xác giảm nhẹ), nhưng **Tốc độ huấn luyện nhanh gấp 3-4 lần** so với K-Means truyền thống.

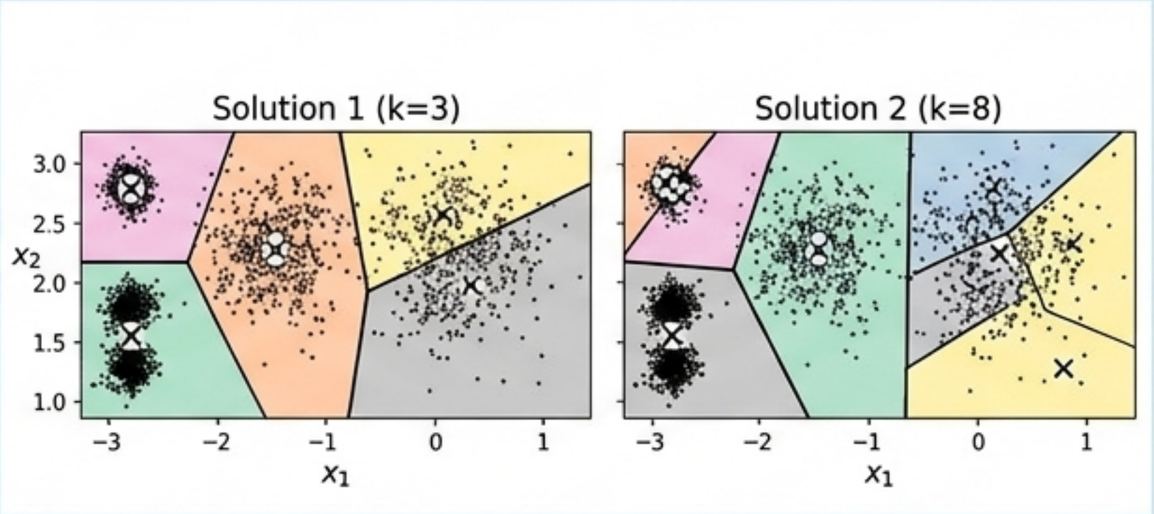
Gemini Notebook

Vấn đề nan giải: Chọn số lượng cụm (k)

Nghịch lý: Không thể chọn k dựa vào Inertia nhỏ nhất, vì khi k tăng, Inertia **luôn luôn giảm**.



Quy tắc Cùi chỏ (Elbow Rule): Vẽ đồ thị Inertia theo k. Tìm **điểm uốn (elbow)** nơi quán tính ngừng giảm đột ngột.



Trực quan, nhưng đôi khi thô sơ.

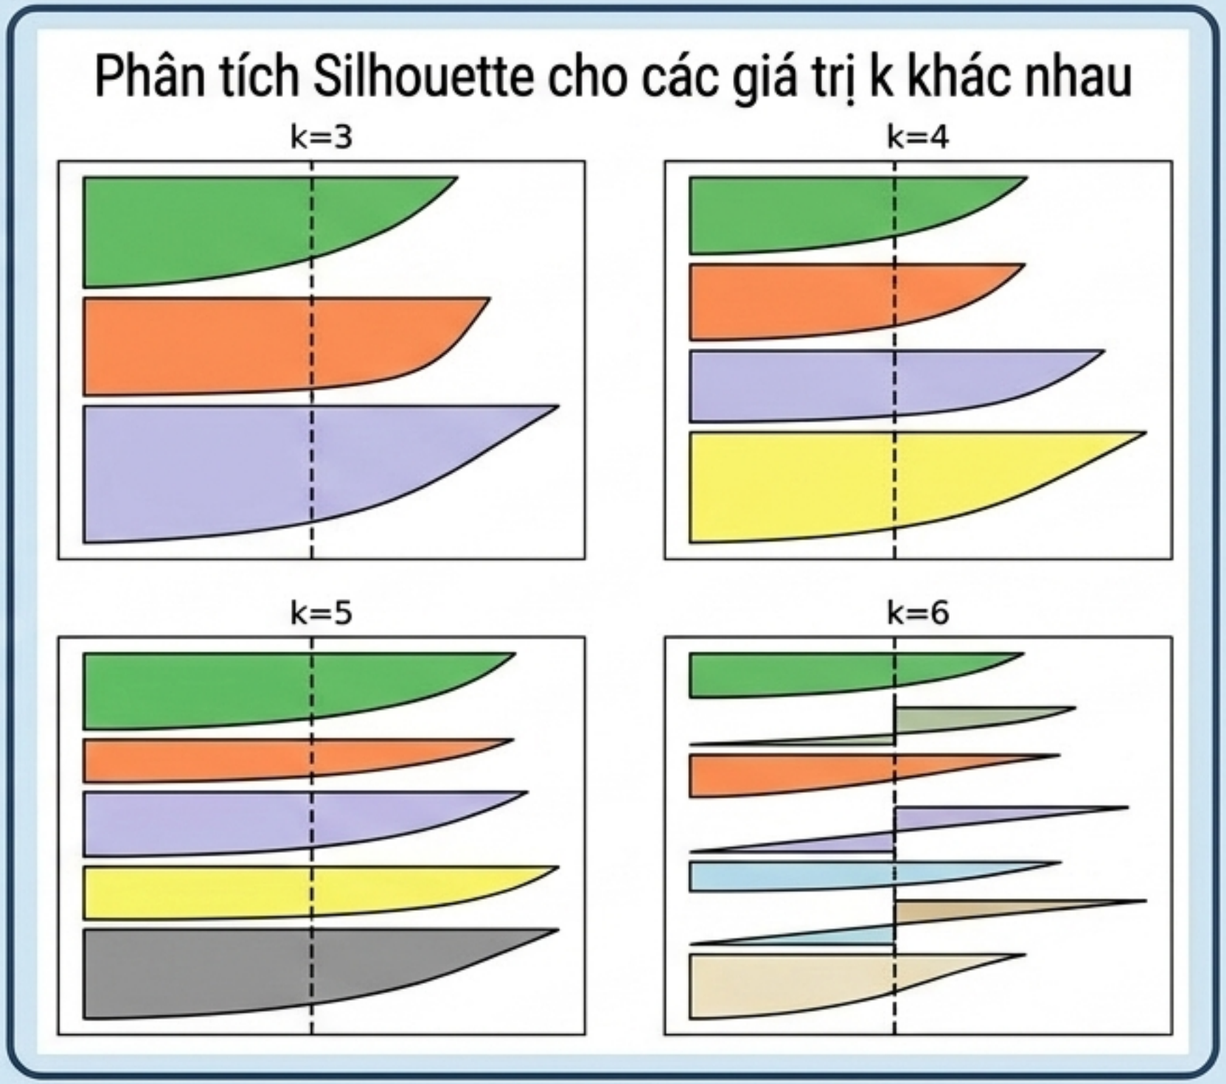
Gemini Notebook

Góc nhìn sâu sắc: Điểm số Hình bóng (Silhouette Score)

Cơ chế: Hệ số (b - a) / max(a, b).
Giá trị nằm từ -1 đến +1.

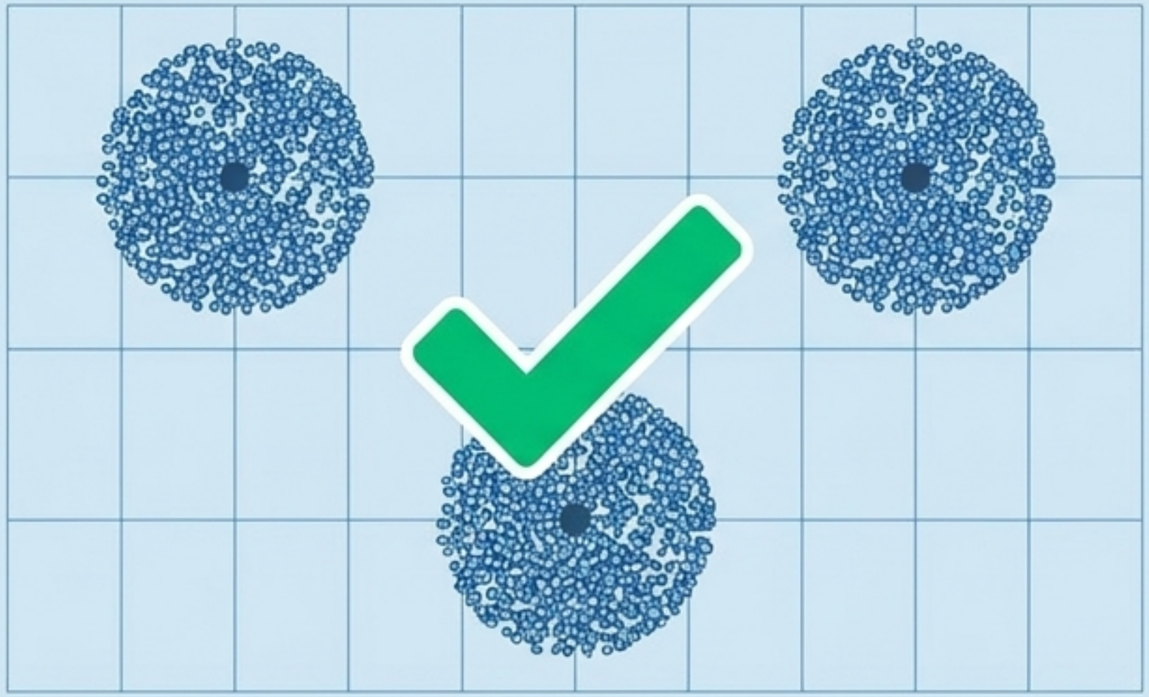
Thang đo: Gần +1: Điểm nằm sâu an toàn trong cụm.
Gần 0: Nằm chênh vênh ở ranh giới.

Đánh giá biểu đồ: k lý tưởng khi tất cả các cụm (hình lưỡi dao) đều vượt qua vạch đứt gạch (điểm trung bình) và có độ dày, kích thước tương đồng nhau. Trên biểu đồ, **k=5** là tối ưu nhất.

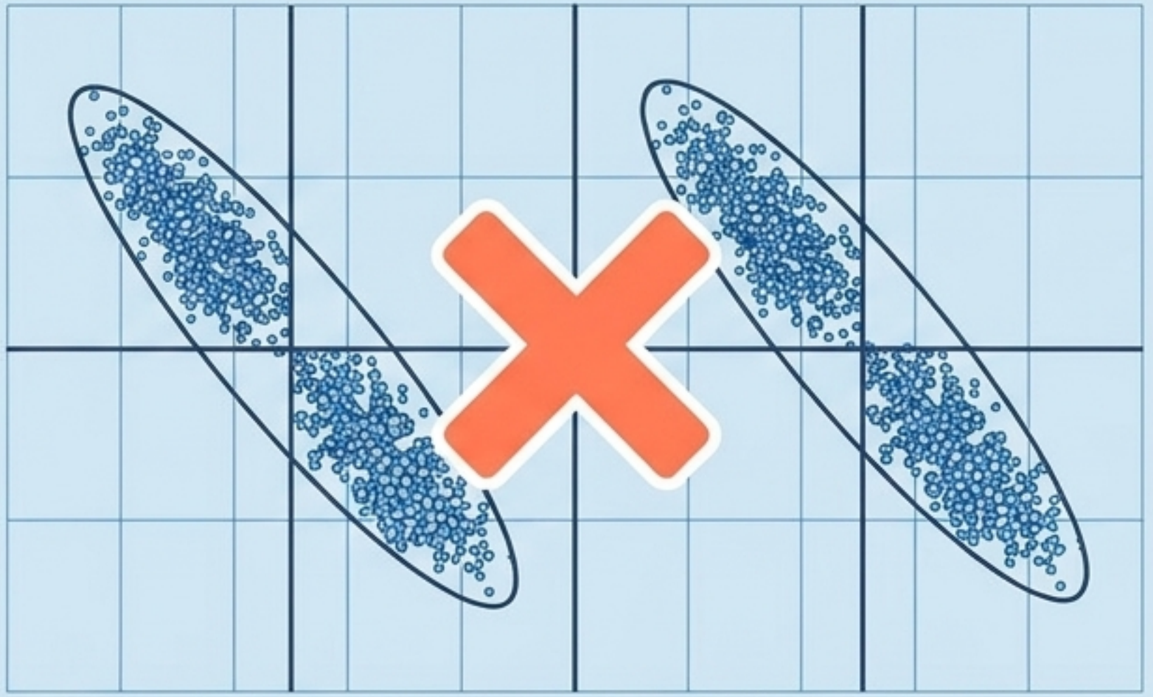


Gemini Notebook

Giới hạn: Khi nào K-Means thất bại?



Bản chất: K-Means sử dụng khoảng cách Euclide tĩnh, do đó nó mặc định ưu tiên các cụm có hình cầu và kích thước đồng đều.



Điểm mù: Thuật toán sẽ **thất bại thảm hại** với các cụm dữ liệu kéo dài (elongated), hình elip nghiêng, hoặc có mật độ chênh lệch quá lớn. (Giải pháp thay thế: Mô hình Hỗn hợp Gaussian - GMM).

Gemini Notebook

Ứng dụng Thực tiễn 1: Phân đoạn Hình ảnh





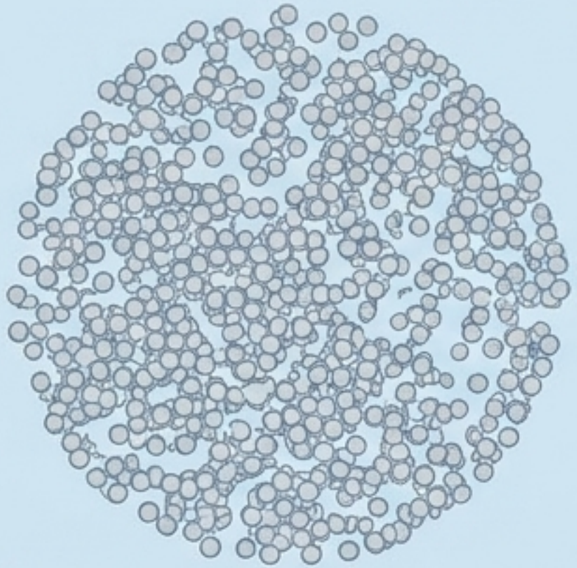


Mục đích: Giảm lượng màu sắc trong một bức ảnh bằng cách gom nhóm các pixel có màu sắc (RGB) tương tự nhau vào chung một cụm.

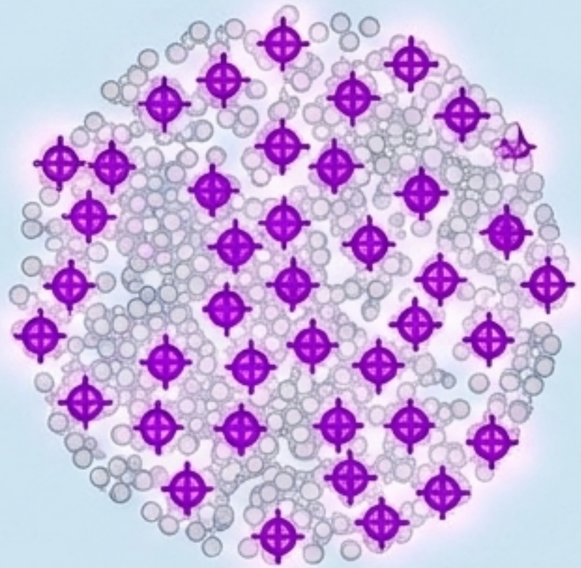
Kết quả: Thay thế màu gốc bằng màu trung bình của cụm. Kỹ thuật này cực kỳ hữu ích trong **nén ảnh** hoặc **phát hiện viền đối tượng** trong thị giác máy tính.

Gemini Notebook

Ứng dụng Thực tiễn 2: Học Bán giám sát



Chi phí gán nhãn thủ công rất đắt đỏ.



K-Means gom thành 50 cụm. Lấy 50 điểm ngay tại tâm cụm đại diện.



Lan truyền Nhãn (Label Propagation) cho toàn bộ dữ liệu.

Kết quả: Tăng vọt độ chính xác của AI với chi phí gán nhãn cực thấp.

Gemini Notebook

Tổng kết Hành trình K-Means

Tốc độ & Cốt lõi

Thuật toán nhanh, mạnh mẽ, đóng vai trò nền tảng và tiên phong trong các bài toán Học không giám sát.

Khởi tạo Thông minh

Luôn sử dụng **K-Means++** và thông số n_init để tránh rủi ro thuật toán kẹt ở cực tiểu cục bộ.



Đo lường & Đánh giá

Quy tắc Cùi chỏ thì nhanh, nhưng **Silhouette Score** mới đem lại cái nhìn sắu sắc và chính xác nhất về số lượng cụm k.

Cẩn trọng Hình học

Nhớ rõ nhược điểm với dữ liệu phi hình cầu hoặc khác biệt mật độ. Ứng dụng xuất sắc trong phân đoạn ảnh và học bán giám sát.

Gemini Notebook