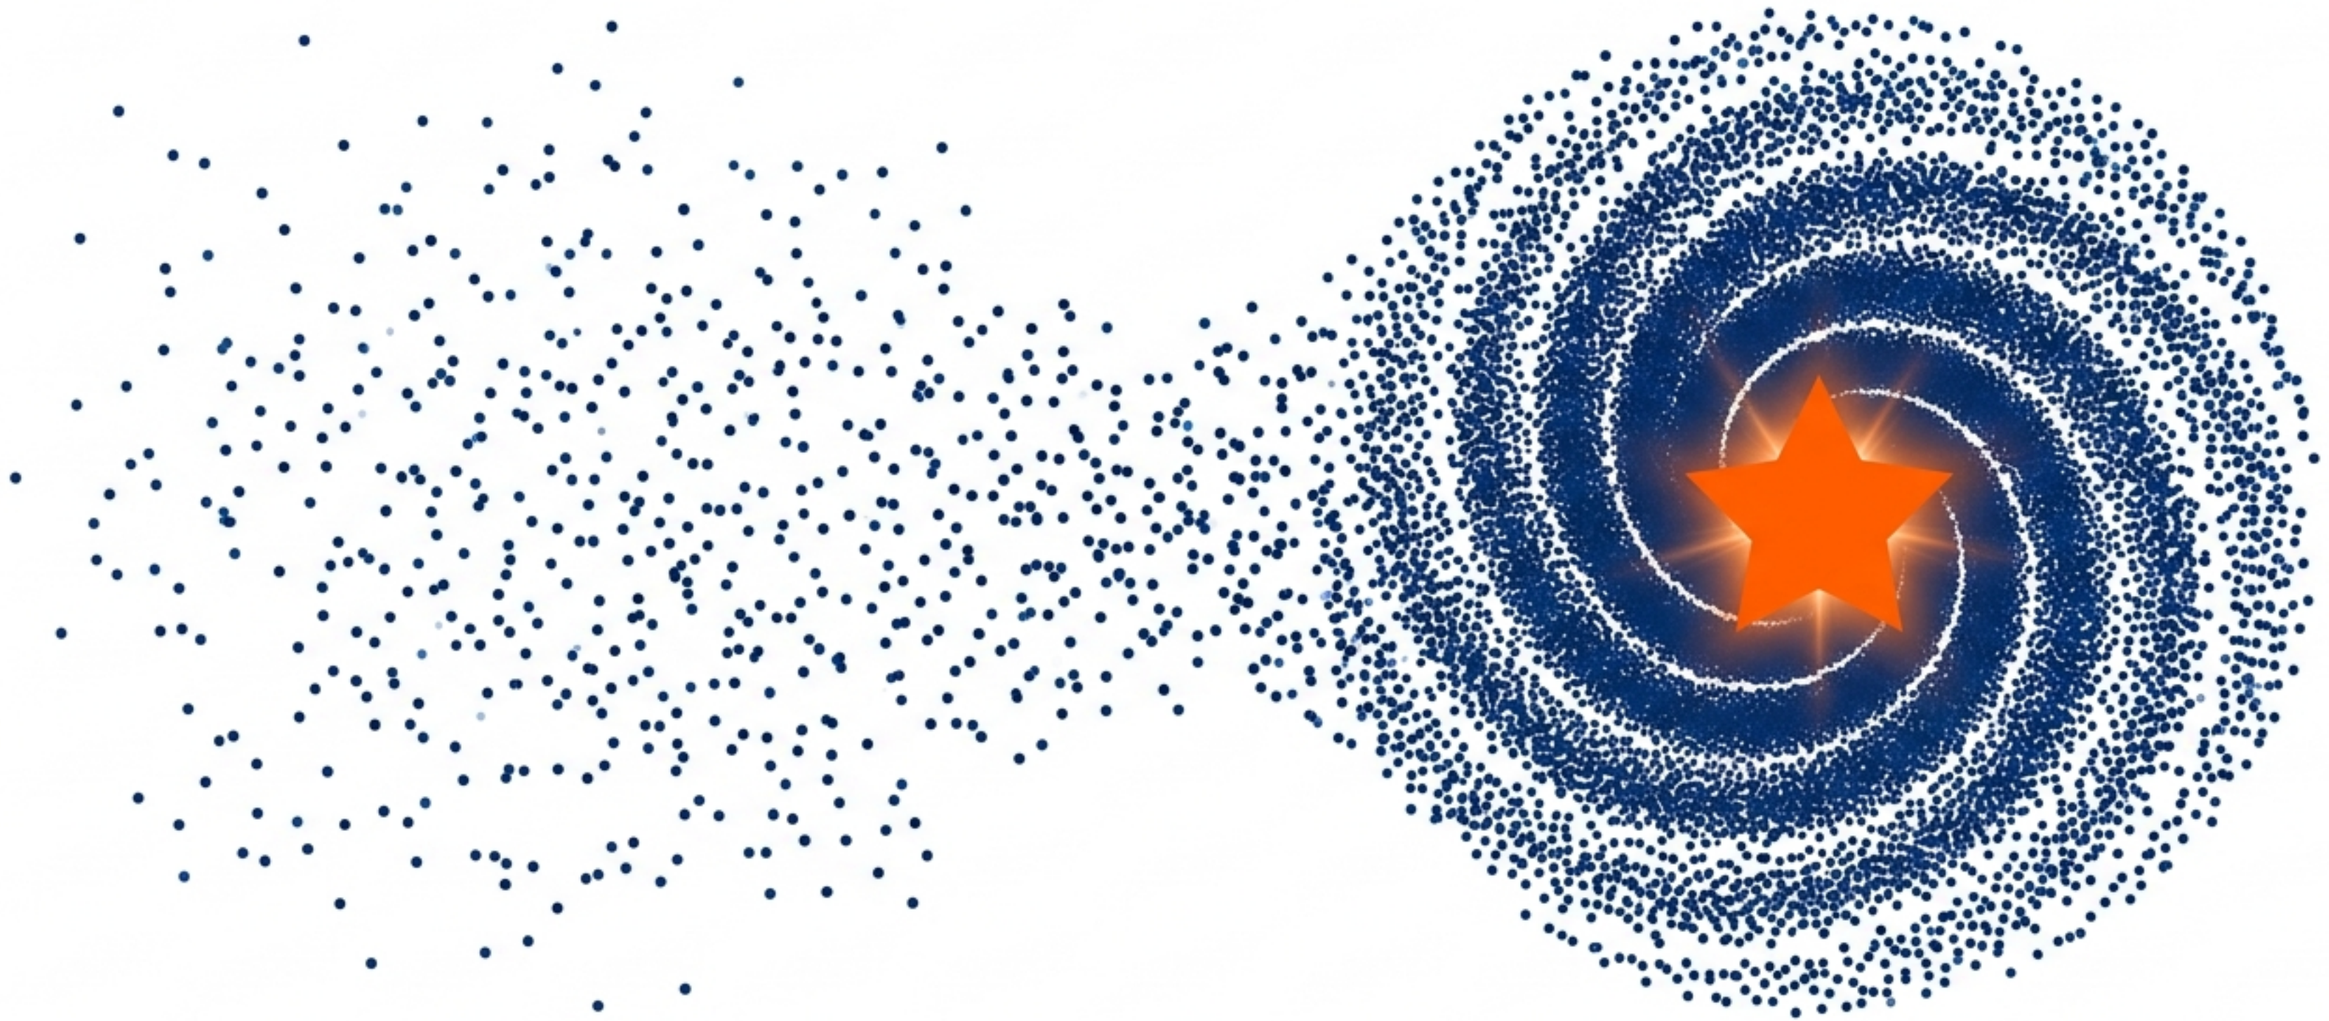
Tối Ưu Hóa Ngân Sách Gán Nhãn Bằng Học Bán Giám Sát



[UNIVERSITY_LOGO]

Gemini Notebook

Nghịch lý của Dữ liệu: Hàng ngàn ảnh gốc nhưng chỉ đủ ngân sách cho 50 nhãn

Ngân sách gán nhãn thủ công: **50 ảnh**

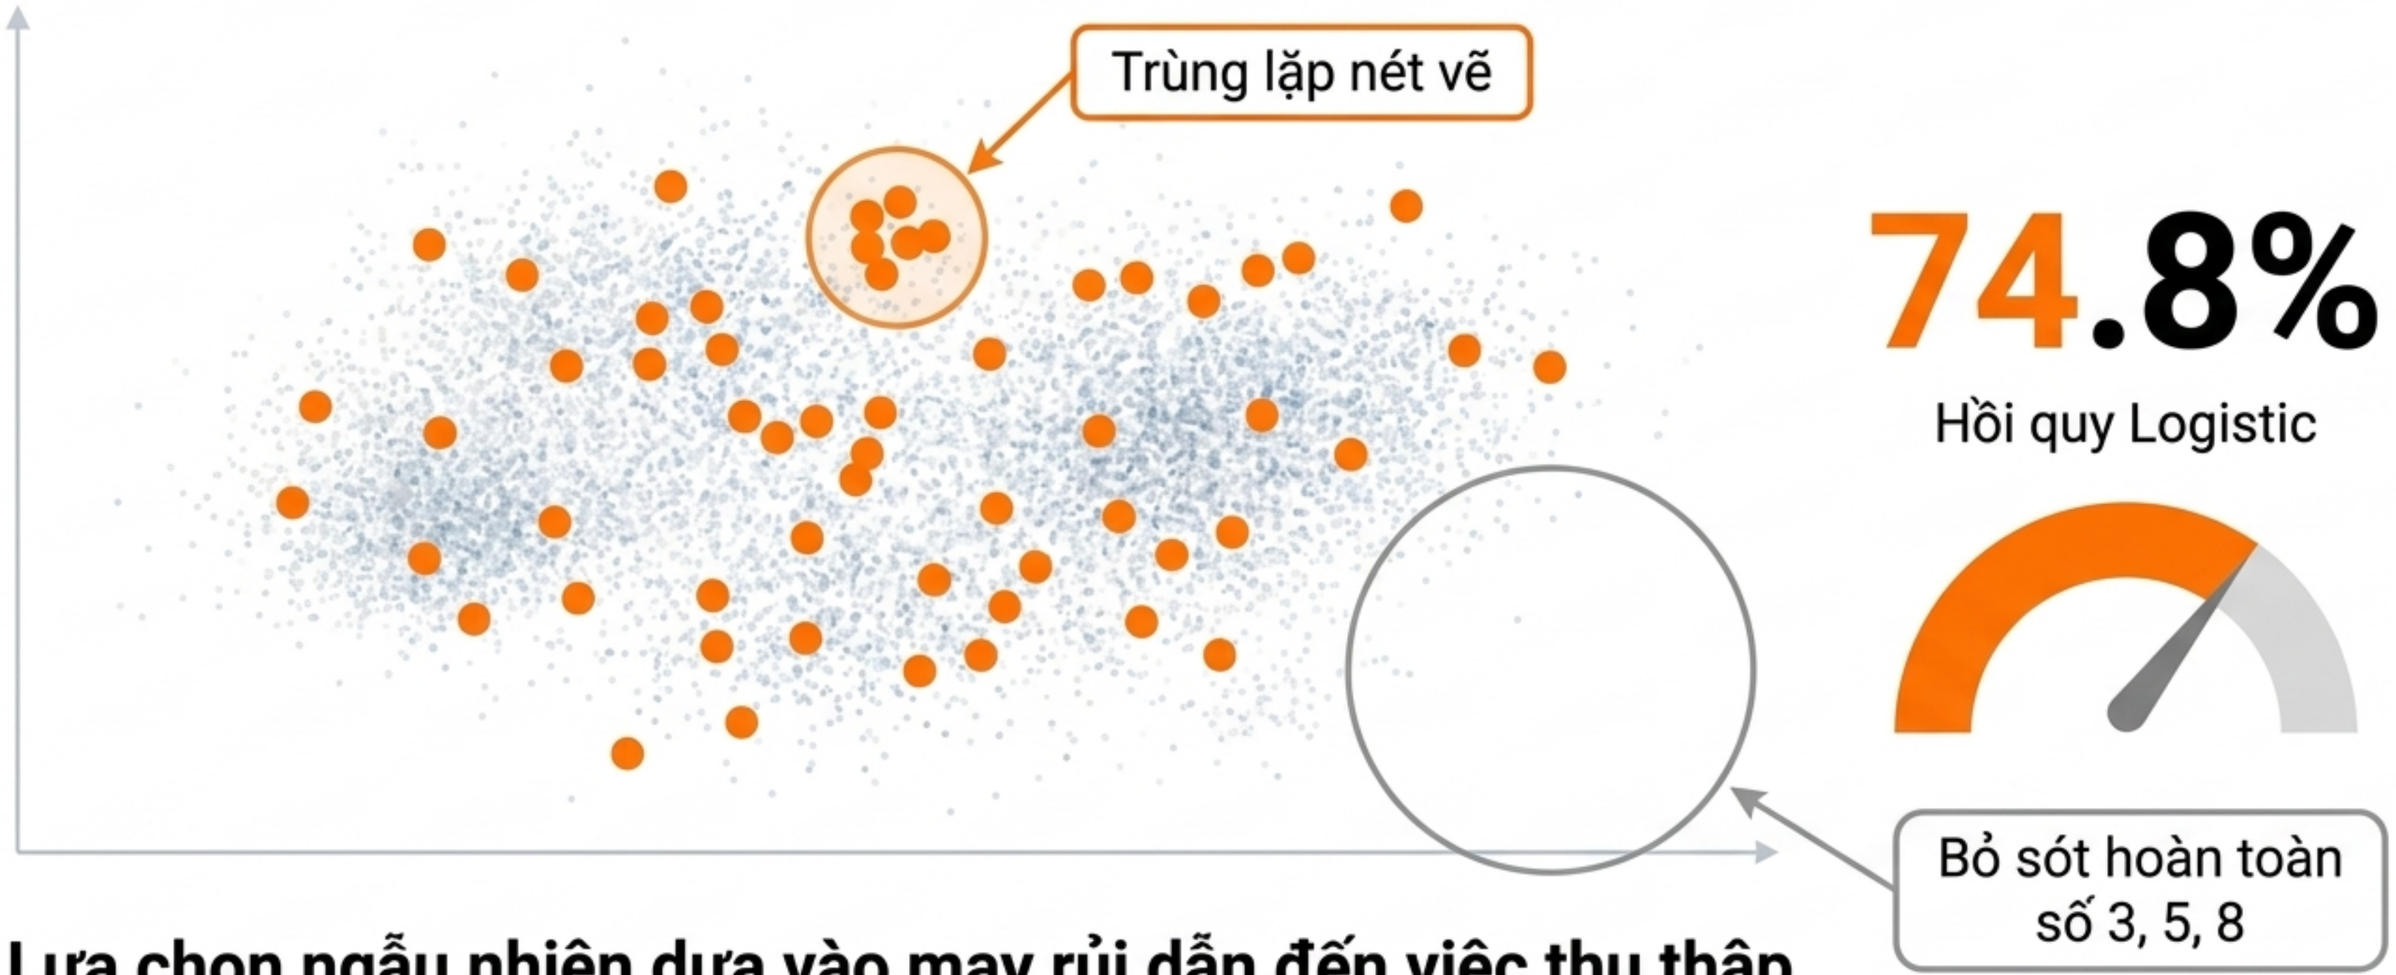
Dữ liệu chưa dán nhãn (Tập MNIST)



Dữ liệu thô luôn sẵn có, nhưng việc thuê chuyên gia dán nhãn thủ công lại cực kỳ tốn kém. Làm sao sao để khai thác tối đa giá trị từ giới hạn 50 tấm ảnh?

Gemini Notebook

Rủi ro của việc chọn mẫu ngẫu nhiên



Lựa chọn ngẫu nhiên dựa vào may rủi dẫn đến việc thu thập dữ liệu bị trùng lặp và bỏ sót các biến thể quan trọng.

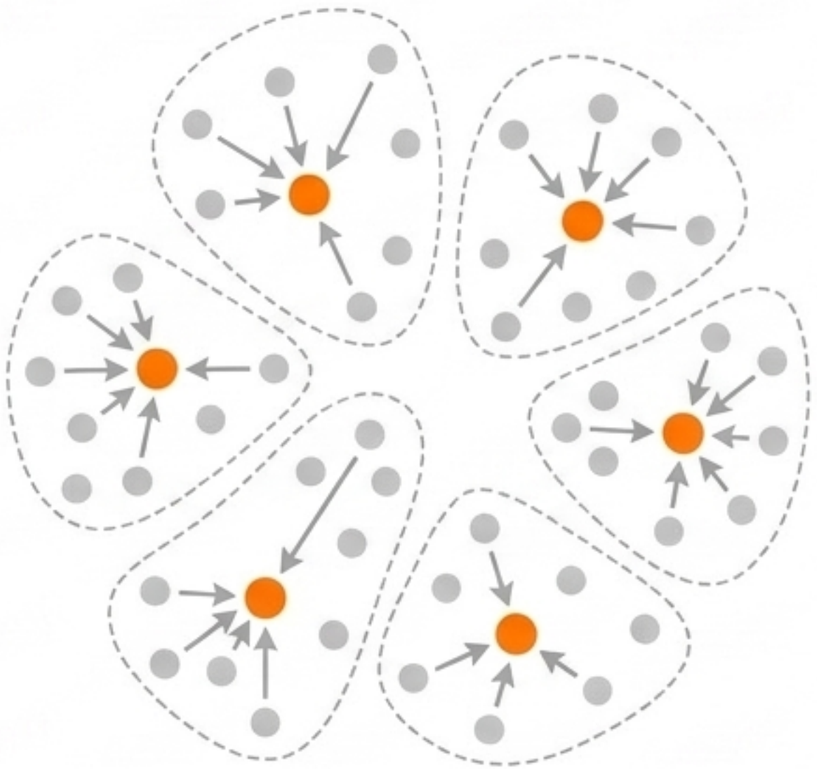
Gemini Notebook

Nguyên lý giải quyết: Bầu cử đại biểu thay vì bốc thăm

Thay vì chọn bốc thăm ngẫu nhiên, ta nhóm dữ liệu thành các cụm có tính chất giống nhau và chọn ra đại diện ưu tú nhất từ mỗi cụm.



Chọn Ngẫu Nhiên



Chọn Đại Diện (Centroid)

Gemini Notebook

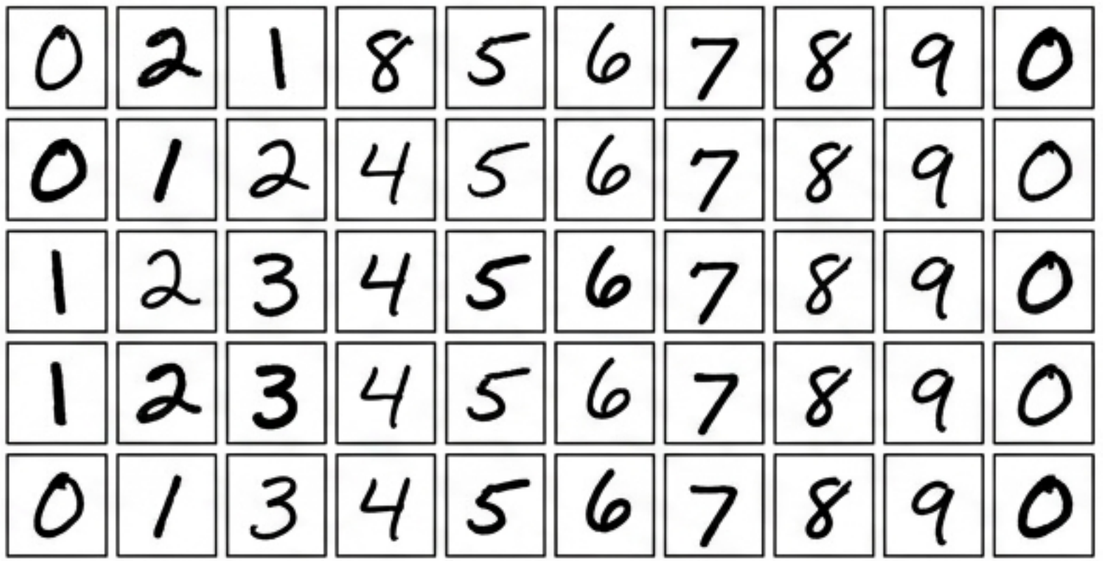
K-Means đảm bảo Độ bao phủ (Coverage) tuyệt đối

Thuật toán ép dữ liệu phân bổ vào 50 cụm khác biệt. Việc lấy đại diện từ mỗi cụm giúp mô hình học được mọi phong cách viết và biến thể nét chữ mà không bị bỏ sót.

Ngẫu nhiên (Random)

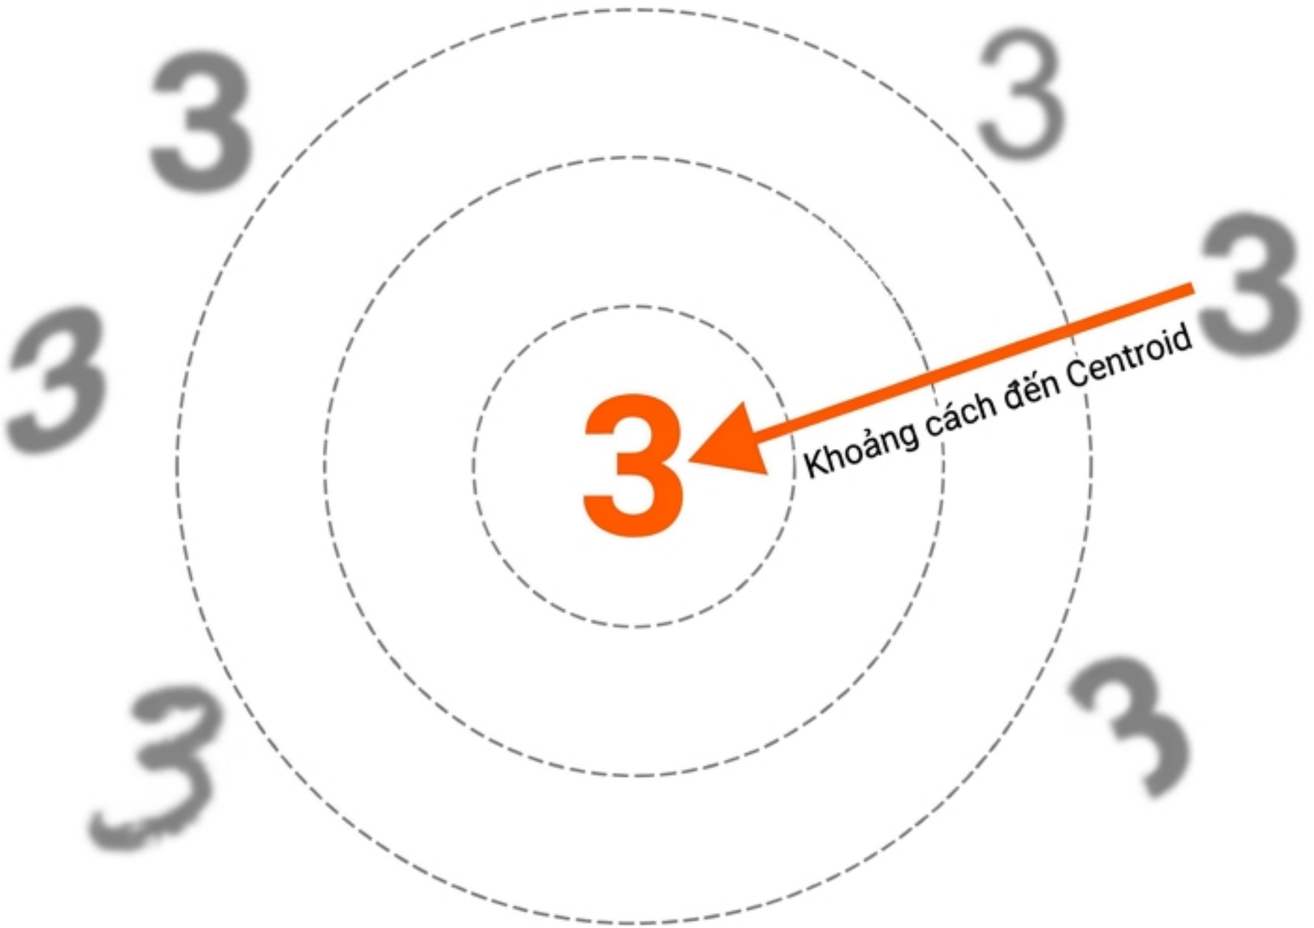


K-Means (k=50)



Gemini Notebook

Tìm kiếm những mẫu dữ liệu chuẩn mực nhất (Typicality)



Tấm ảnh nằm gần tâm cụm nhất mang đặc trưng tiêu biểu cho toàn bộ nhóm.
Lựa chọn này giúp mô hình tránh phải học từ những dữ liệu nhiễu hoặc méo mó.

Gemini Notebook

Đường ống Dữ liệu Học Bán Giám Sát (Semi-Supervised Pipeline)



Phân cụm

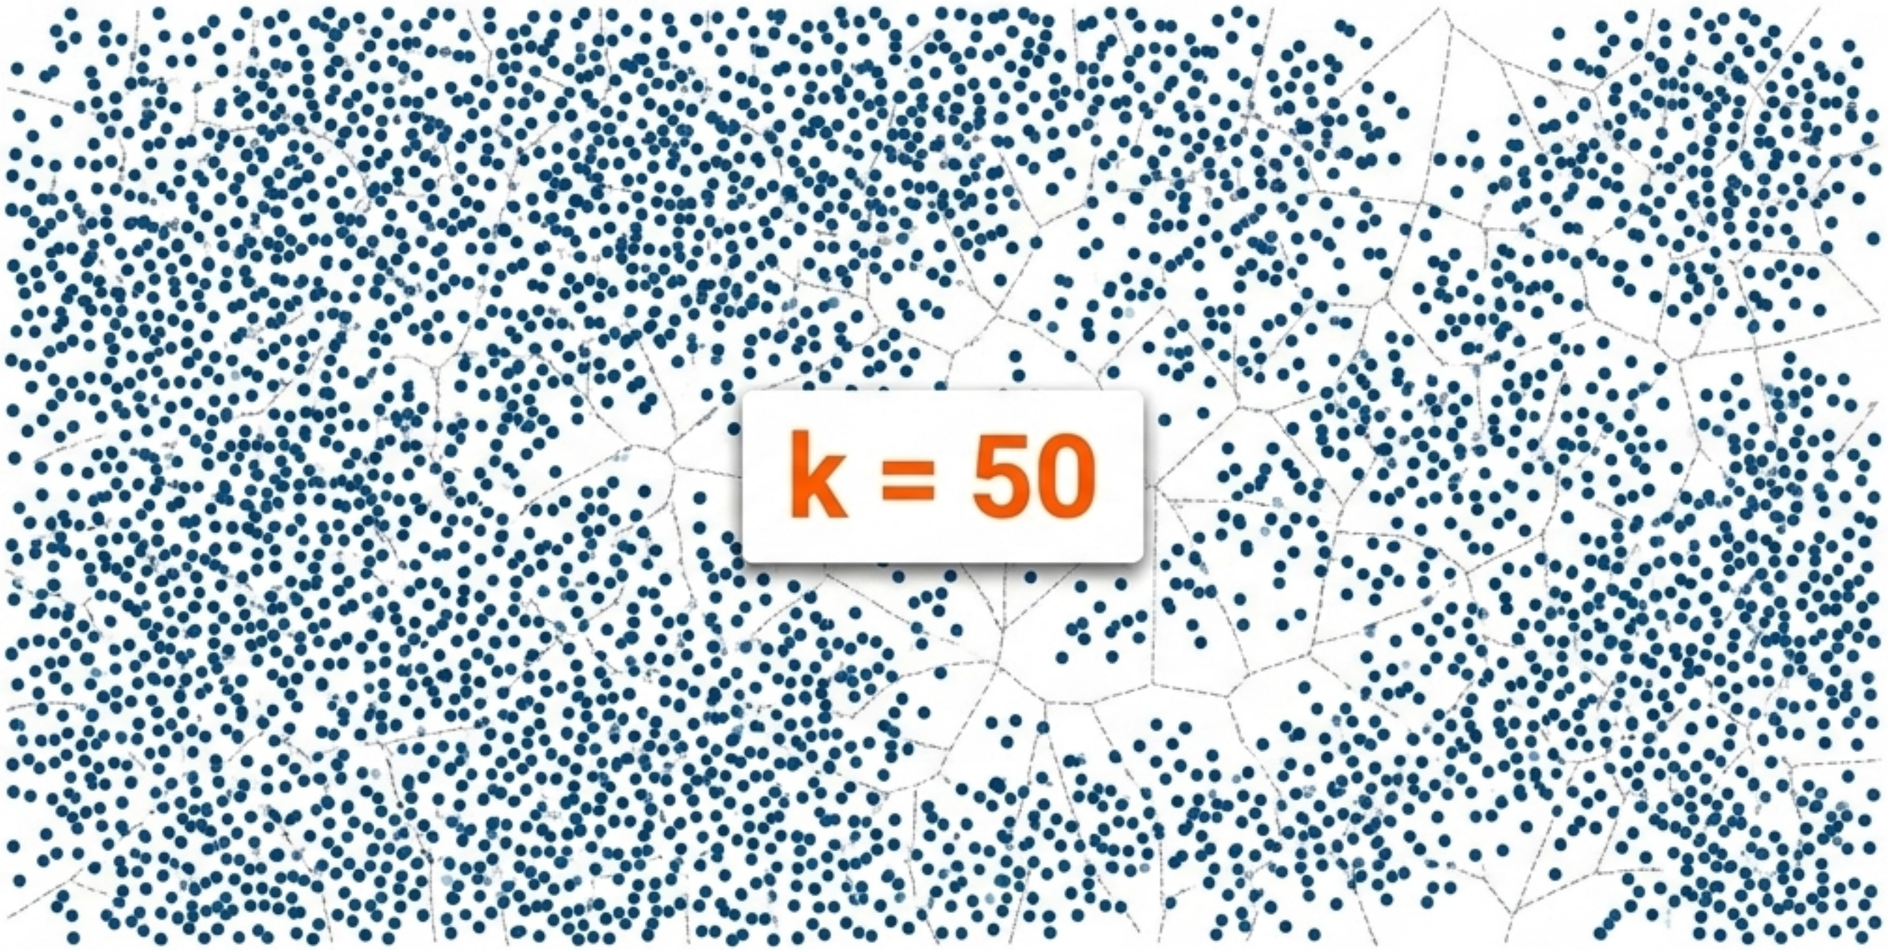
Chọn tâm

Gán nhãn

Huấn luyện

Gemini Notebook

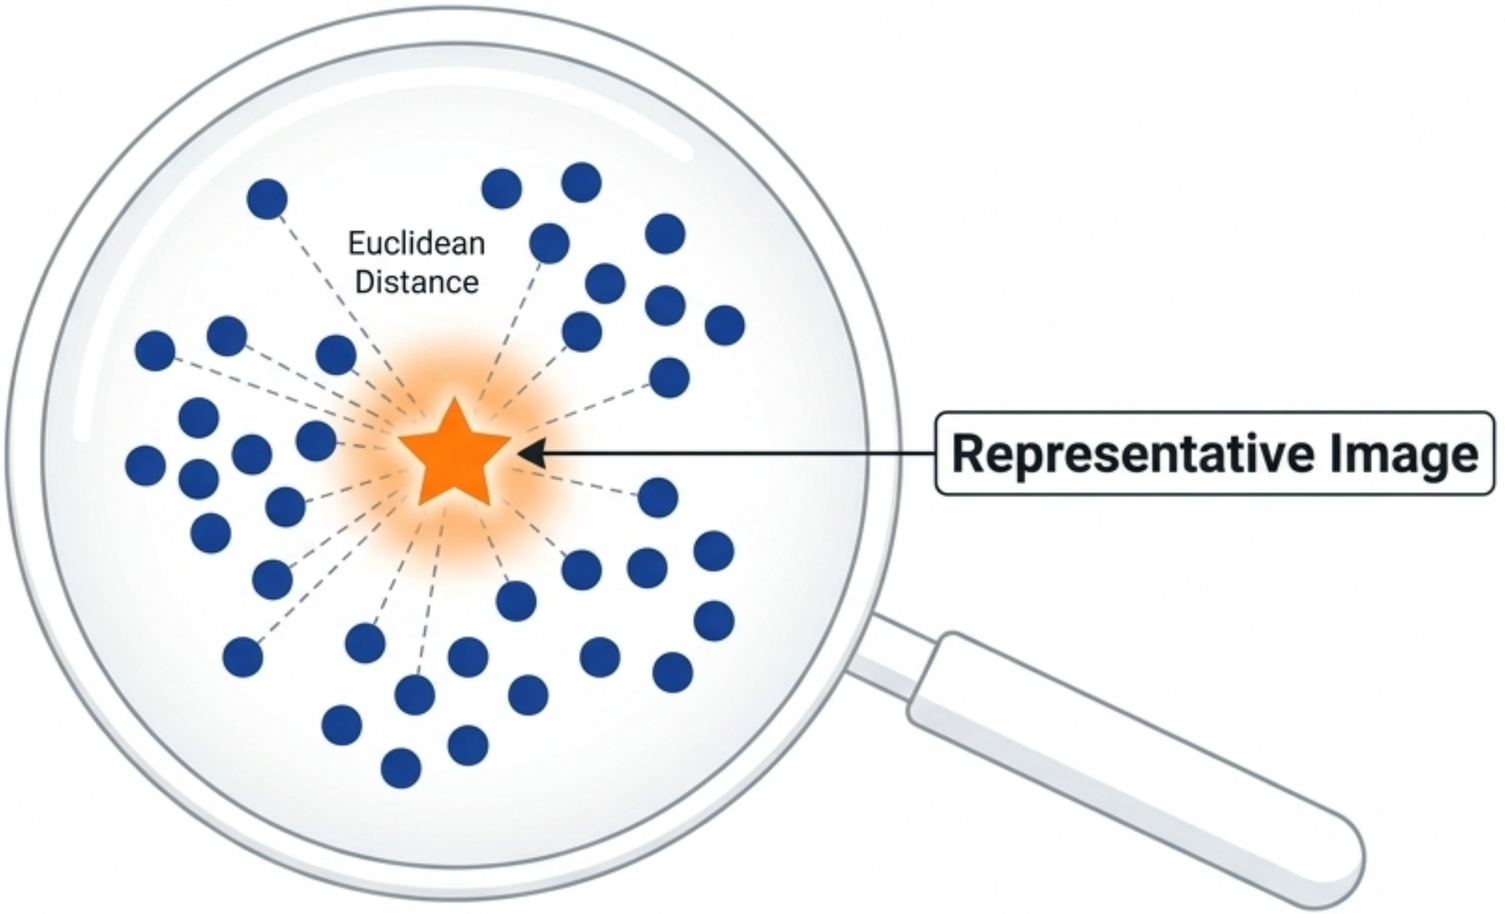
Bước 1: Phân cụm dữ liệu chưa gán nhãn



Chạy thuật toán K-Means trên toàn bộ tập dữ liệu huấn luyện để tự động tìm ra 50 nhóm có nét vẽ tương đồng, hoàn toàn không cần biết nhãn trước.

Gemini Notebook

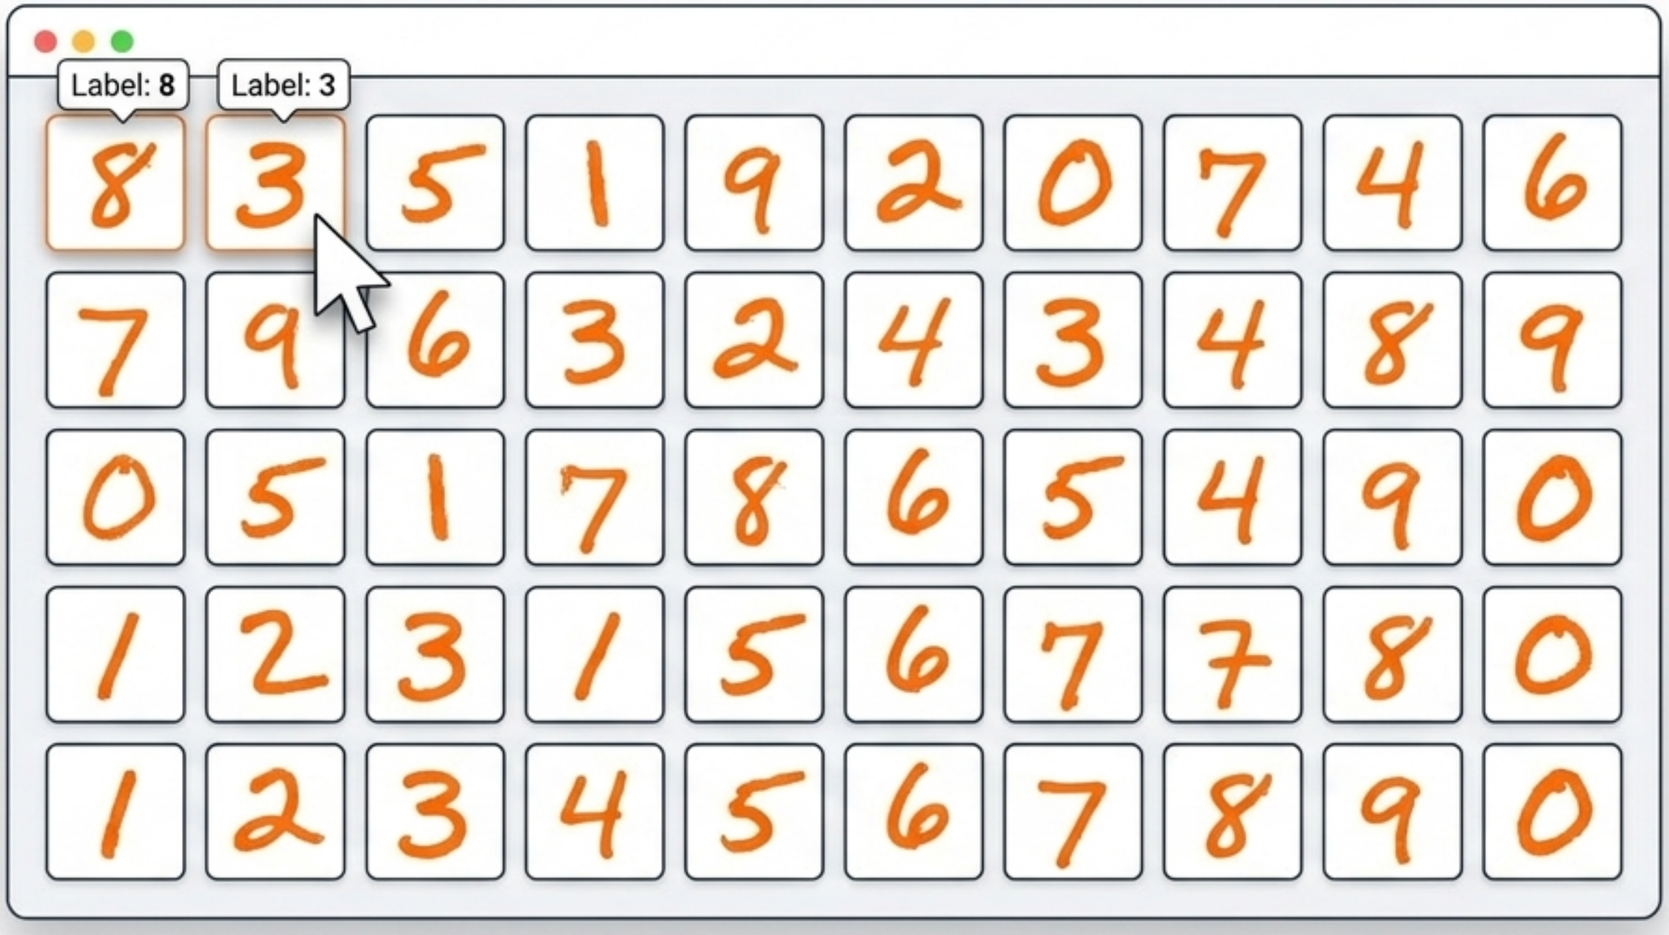
Bước 2: Trích xuất 50 hình ảnh đại diện



Đo lường khoảng cách từ mọi điểm đến tâm cụm (centroid). Trích xuất bức ảnh có khoảng cách ngắn nhất để làm đại diện duy nhất cho nhóm.

Gemini Notebook

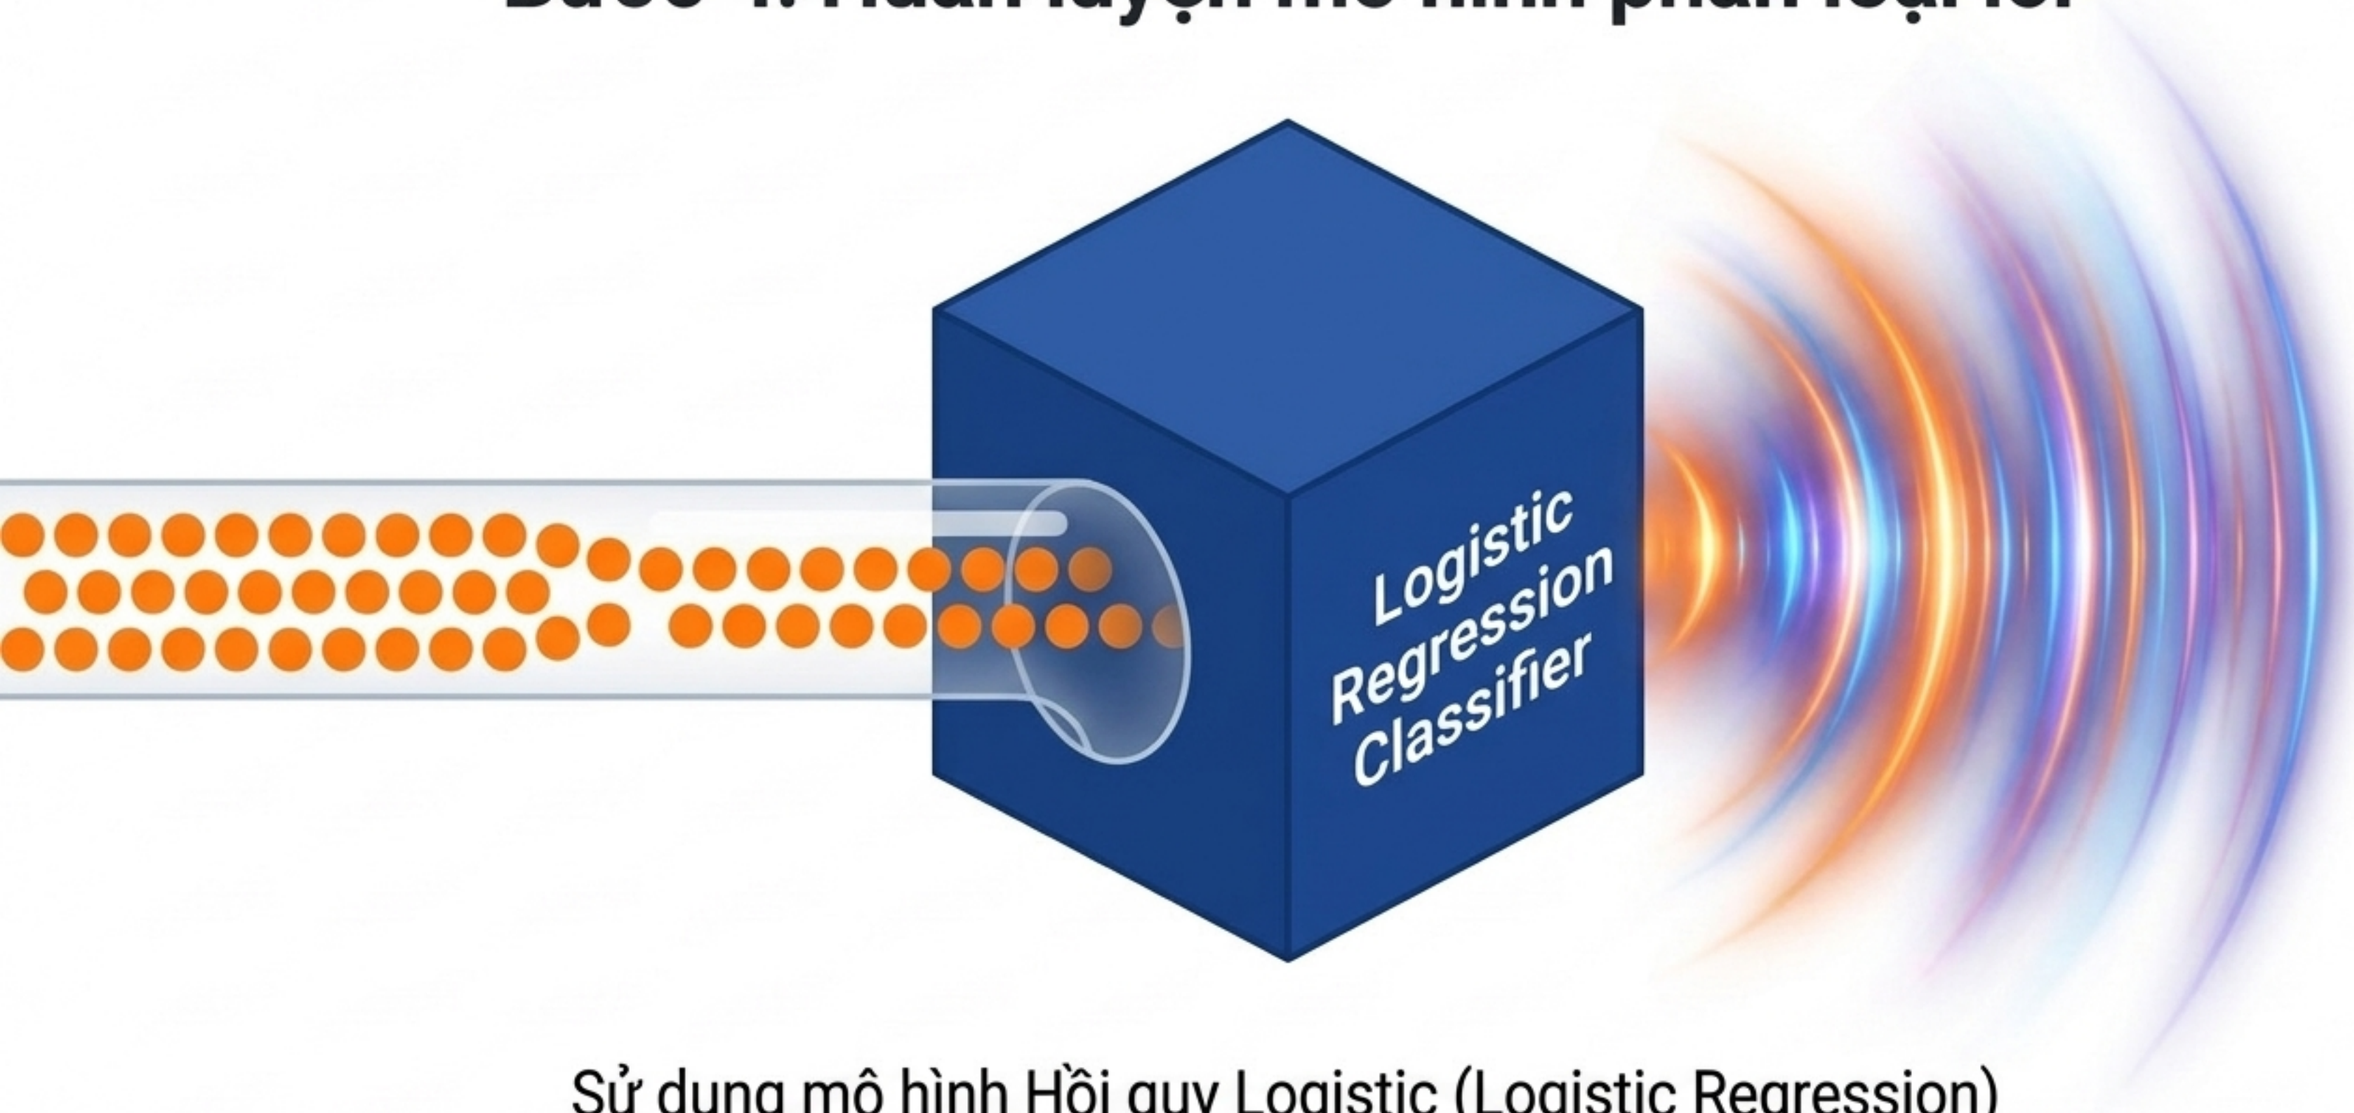
Bước 3: Gán nhãn thủ công với độ chính xác cao



Chuyên gia con người can thiệp: chỉ cần quan sát và dán nhãn cho đúng 50 bức ảnh đại diện này. Khối lượng công việc giảm đi hàng ngàn lần nhưng chất lượng dữ liệu được đảm bảo tuyệt đối.

Gemini Notebook

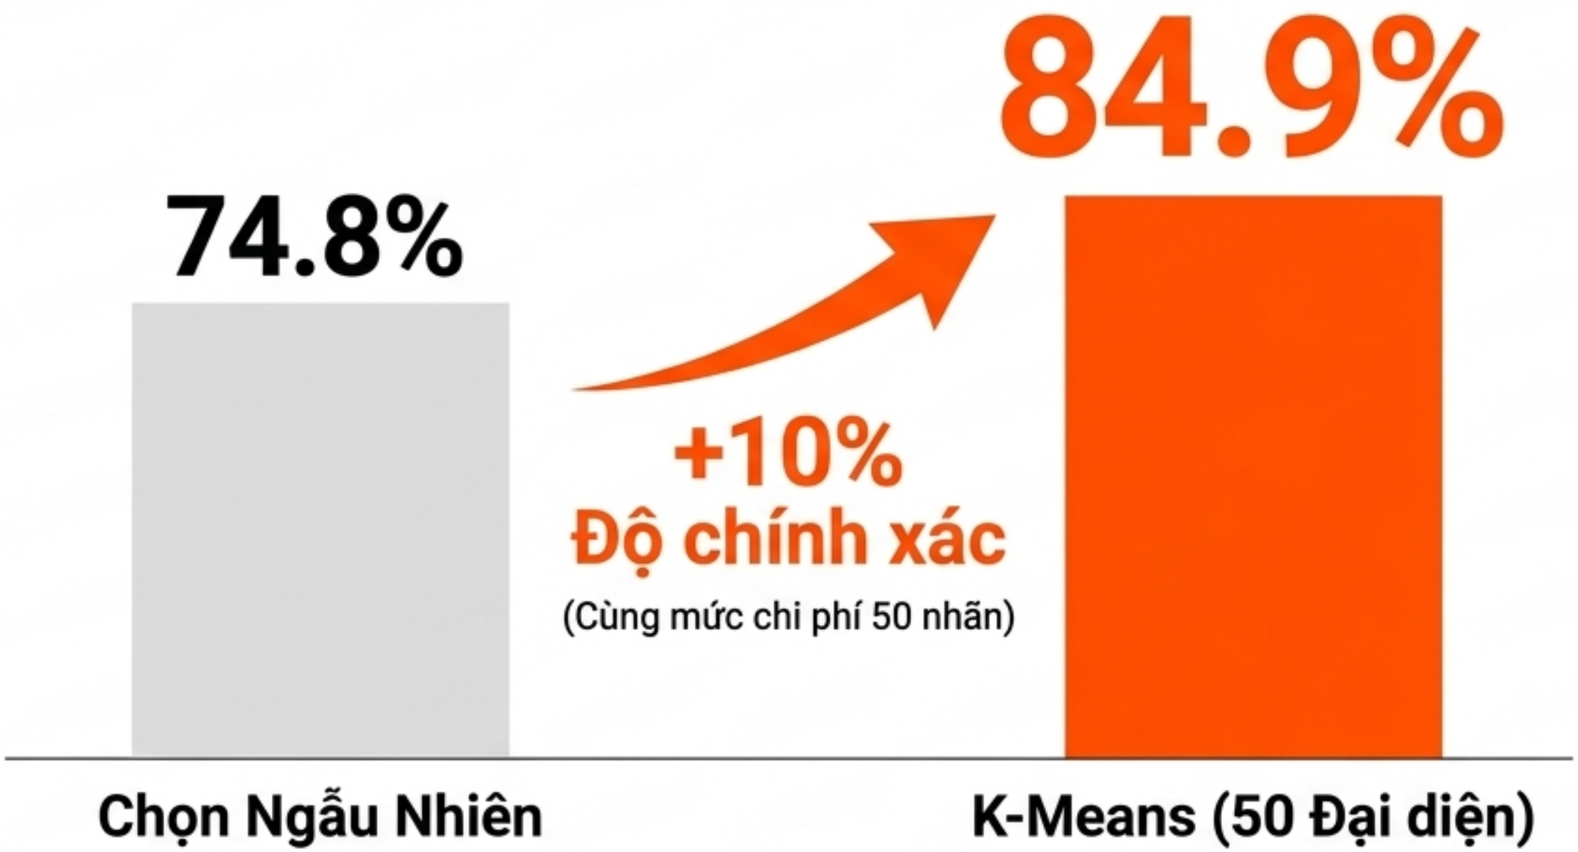
Bước 4: Huấn luyện mô hình phân loại lõi



Sử dụng mô hình Hồi quy Logistic (Logistic Regression) để học các đặc trưng chỉ từ 50 mẫu chuẩn mực này.

Gemini Notebook

Sự đột phá từ trí tuệ của Thuật toán



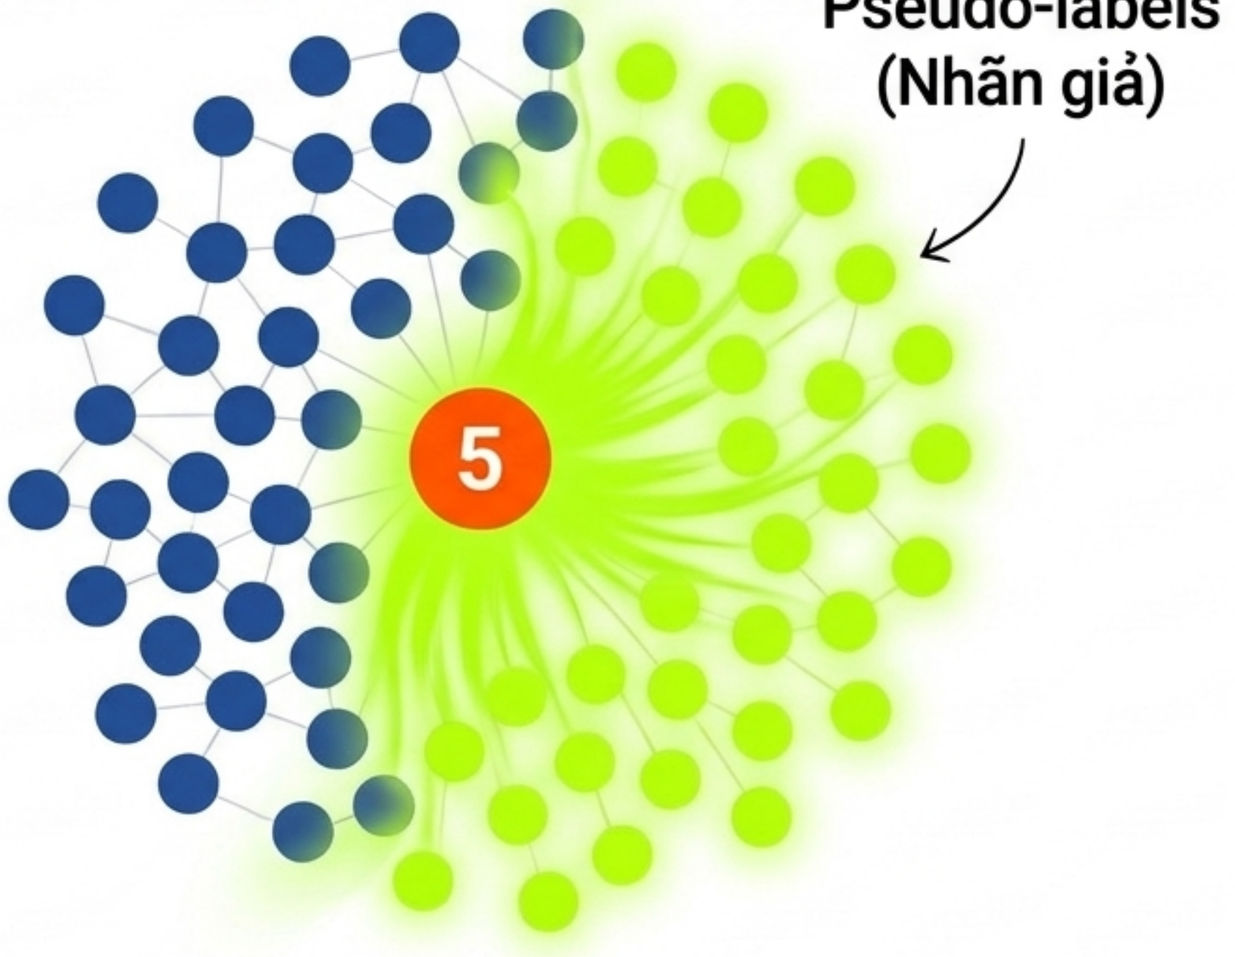
Việc kết hợp thuật toán học không giám sát để chọn lọc dữ liệu giúp mô hình phân loại nhảy vọt về hiệu suất.

Gemini Notebook

Mở rộng Giới hạn: Kỹ thuật Lan truyền nhãn (Label Propagation)

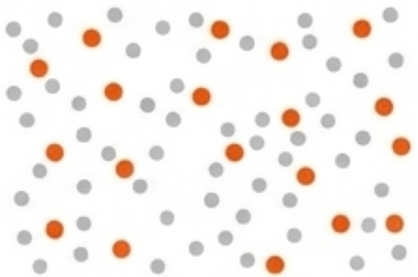
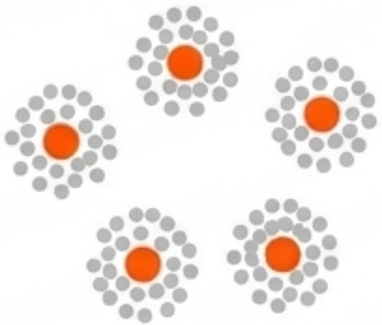
(Label Propagation)

Nếu ảnh đại diện ở tâm là số 5, thuật toán sẽ tự động gán nhãn 5 cho toàn bộ các ảnh khác nằm cùng trong cụm đó.
Từ 50 nhãn gốc, ta tạo ra hàng ngàn nhãn mới hoàn toàn miễn phí.



Gemini Notebook

3 Cấp độ Tối ưu hóa Dữ liệu trong Học Máy

Chọn ngẫu nhiên	K-Means (50 đại diện)	Label Propagation (Lan truyền nhãn)
		
74.8%	84.9%	~89.4%
Chọn ngẫu nhiên	K-Means (50 đại diện)	Label Propagation (Lan truyền nhãn)

Quá trình chuyển hóa từ làm việc chăm chỉ (thủ công) sang làm việc thông minh (tận dụng kiến trúc dữ liệu) giúp bứt phá giới hạn hiệu năng.

Gemini Notebook

Chuyển hóa Ý tưởng thành Mã nguồn



Tư duy thuật toán đã sẵn sàng. Hãy ứng dụng thư viện Scikit-Learn trong Python để tự mình triển khai bước trích xuất đại diện và lan truyền nhãn ngay hôm nay.

Gemini Notebook