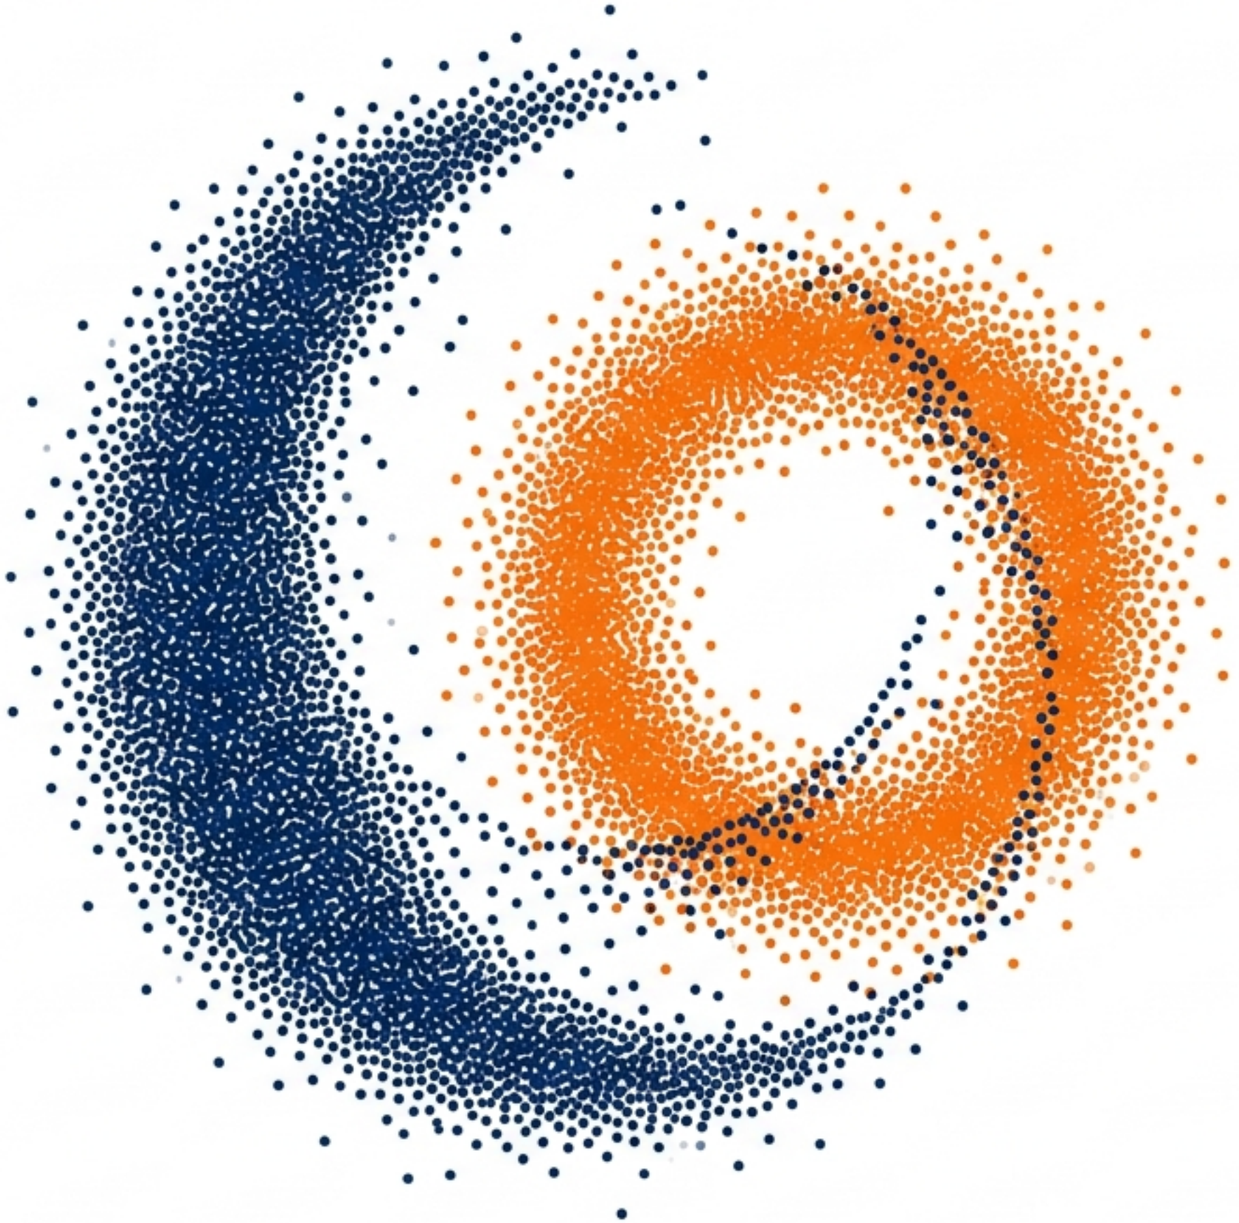
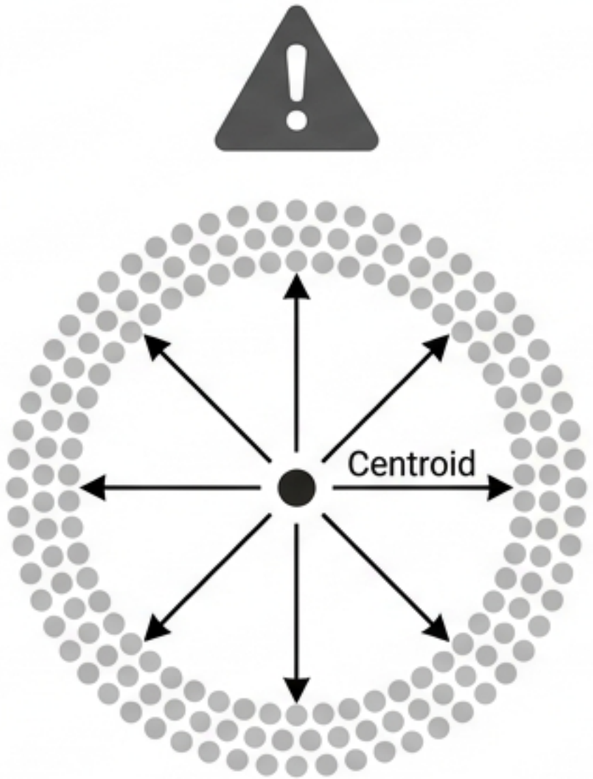
Thuật toán DBSCAN: Phân cụm Không gian dựa trên Mật độ

Hiểu bản chất, cơ chế lan truyền và ứng dụng linh hoạt trong Machine Learning để xử lý các hình dạng dữ liệu phức tạp.



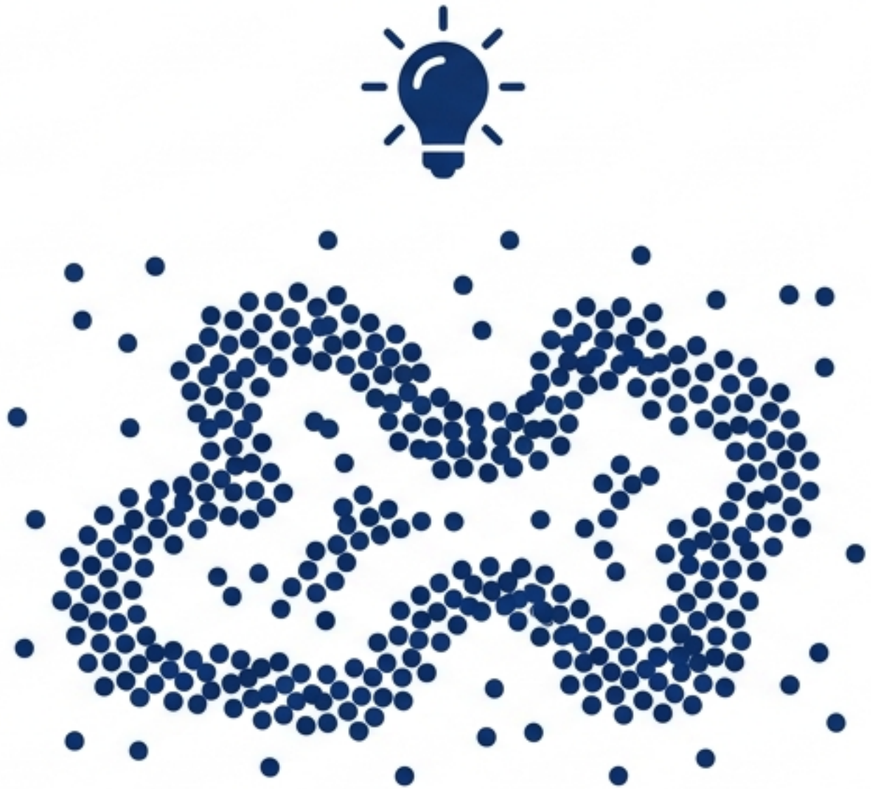
Gemini Notebook

Tại sao K-Means không phải lúc nào cũng là giải pháp tối ưu?



Thuật toán dựa trên khoảng cách đến tâm (centroid).

Chỉ hoạt động tốt với các cụm có hình cầu và kích thước tương đồng. Bất lực trước các hình dáng phức tạp.



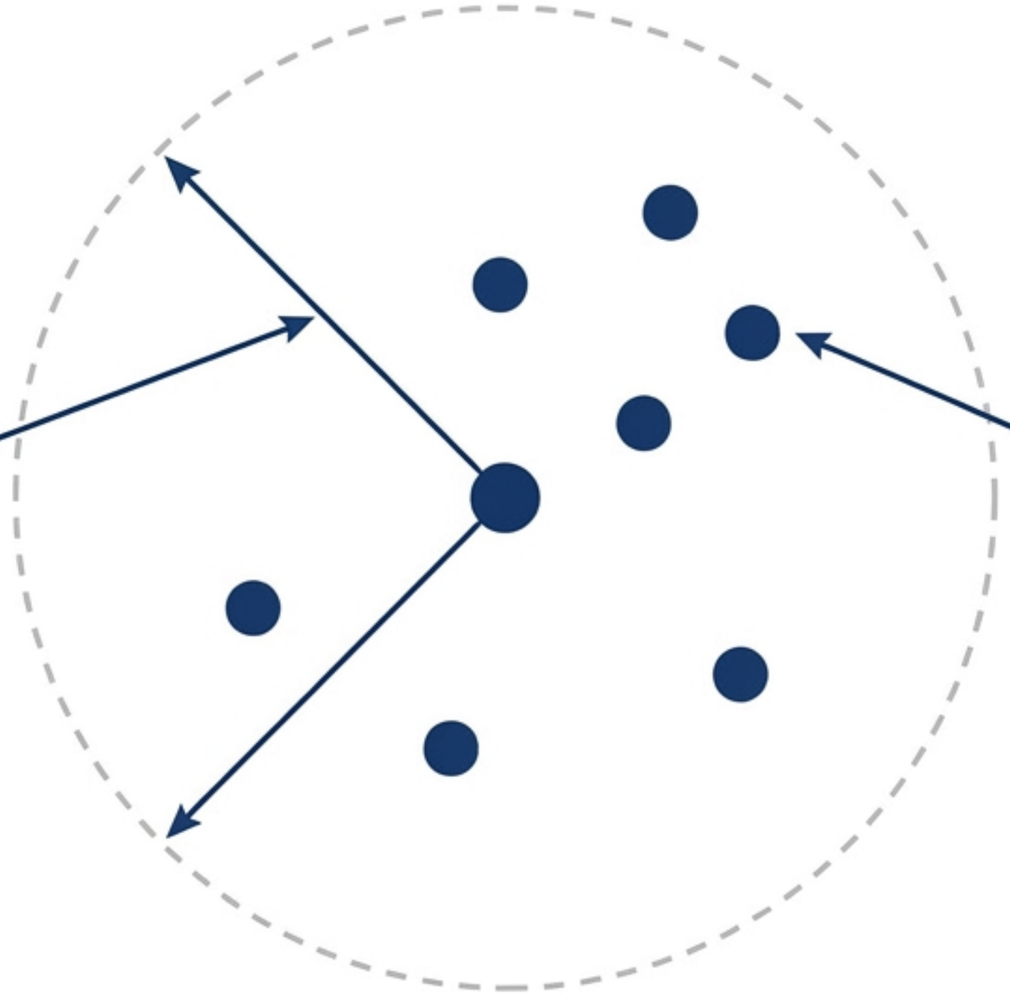
Tiếp cận theo mật độ cục bộ.

Định nghĩa cụm là các vùng liên tục có mật độ cao. Dễ dàng nhận diện cụm với hình dáng bất kỳ và tự động loại bỏ nhiễu.

Gemini Notebook

Hai siêu tham số định hình mọi cụm dữ liệu

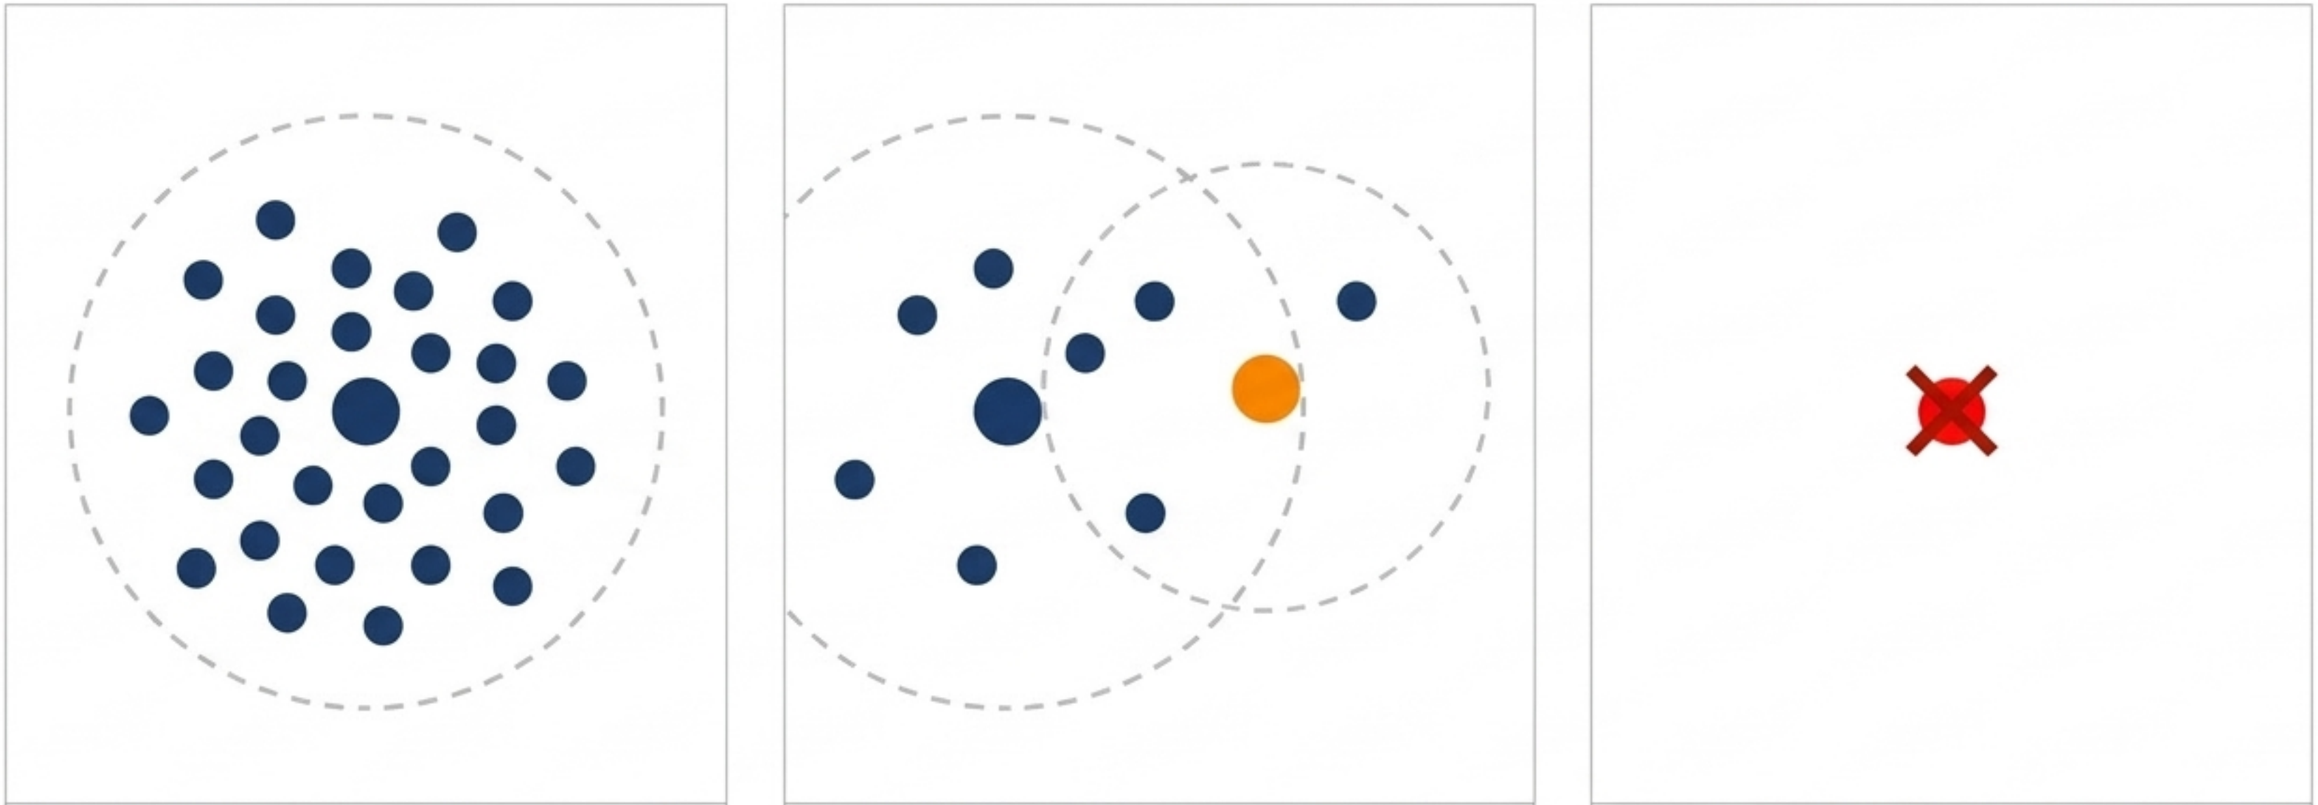
Bán kính epsilon (ε - eps): Kích thước giới hạn của "vùng lân cận" xung quanh một điểm.



min_samples: Số lượng điểm tối thiểu (bao gồm cả tâm) phải có trong vùng ε để vùng đó đạt chuẩn mật độ dày đặc.

Gemini Notebook

Giải phẫu ba loại điểm trong không gian DBSCAN



Trường hợp lõi (Core)

Chứa ≥ min_samples điểm trong vùng lân cận.
Nằm ở trung tâm vùng dày đặc.

Trường hợp biên (Border)

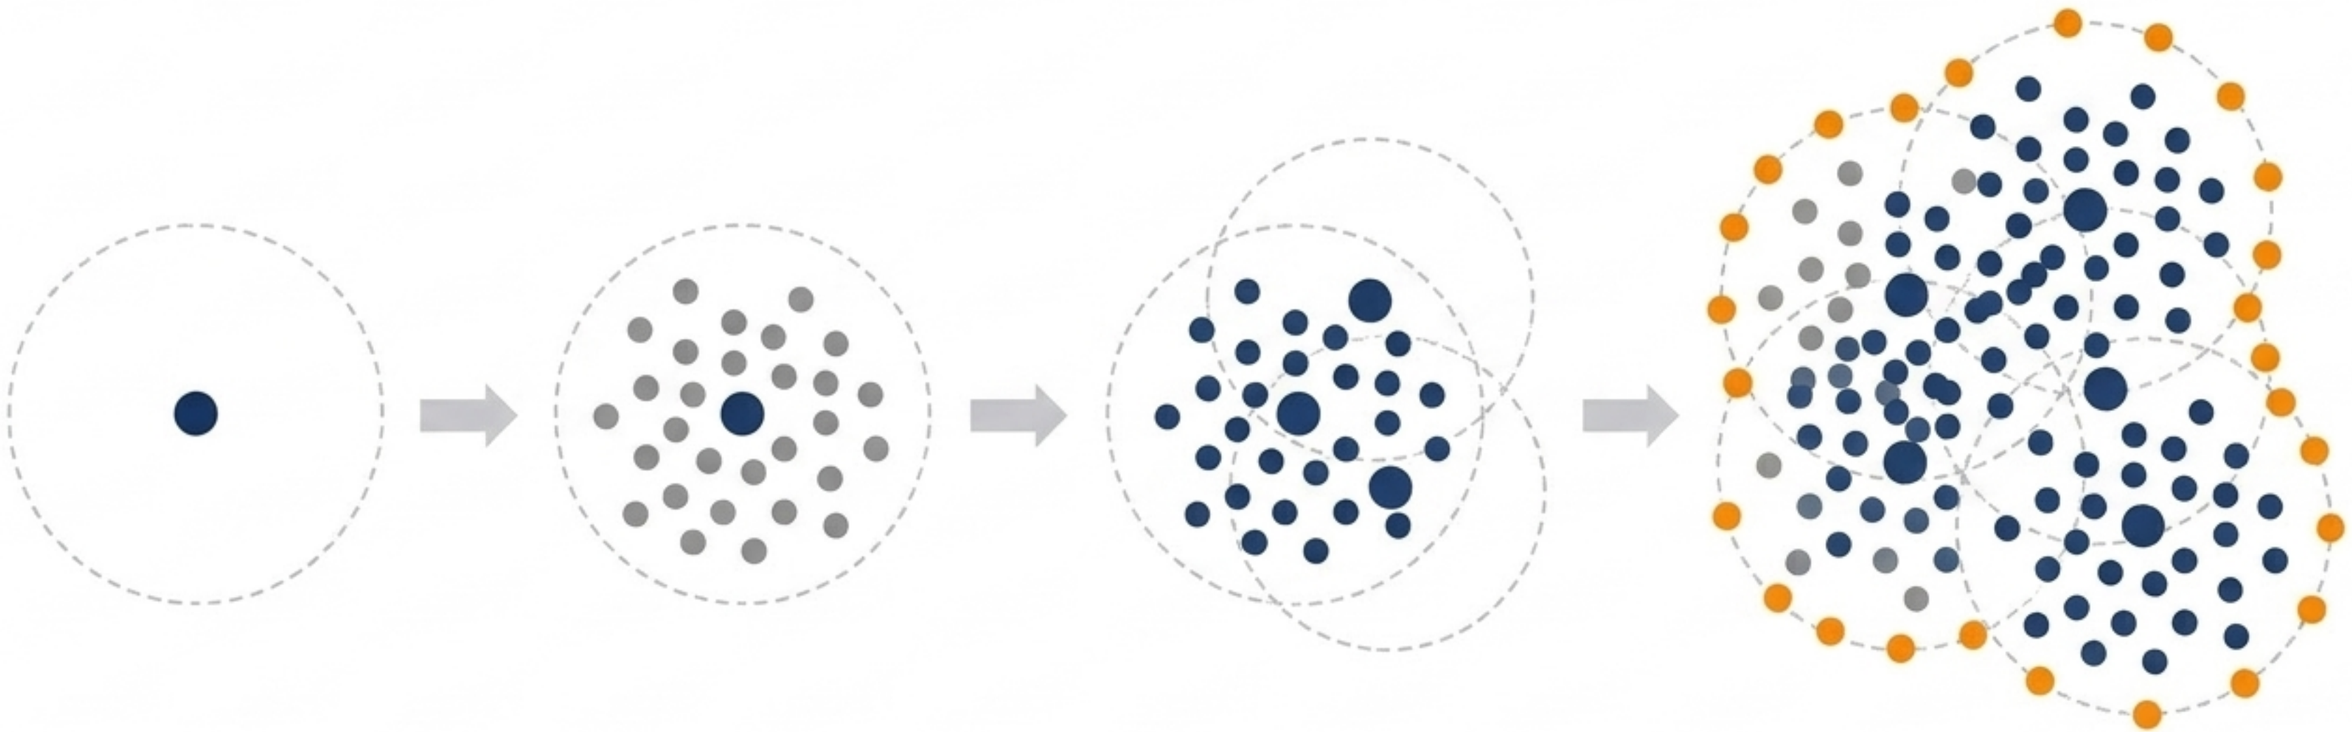
Chứa < min_samples điểm, nhưng lọt thỏm vào vùng lân cận của một Điểm Lõi.

Điểm nhiễu / Dị thường (Noise/Anomaly)

Gắn nhãn -1. Không thuộc vùng lân cận của bất kỳ Điểm Lõi nào.

Gemini Notebook

Hiệu ứng lan truyền định hình cụm hoàn chỉnh



Thuật toán bắt đầu từ một Điểm lõi bất kỳ.

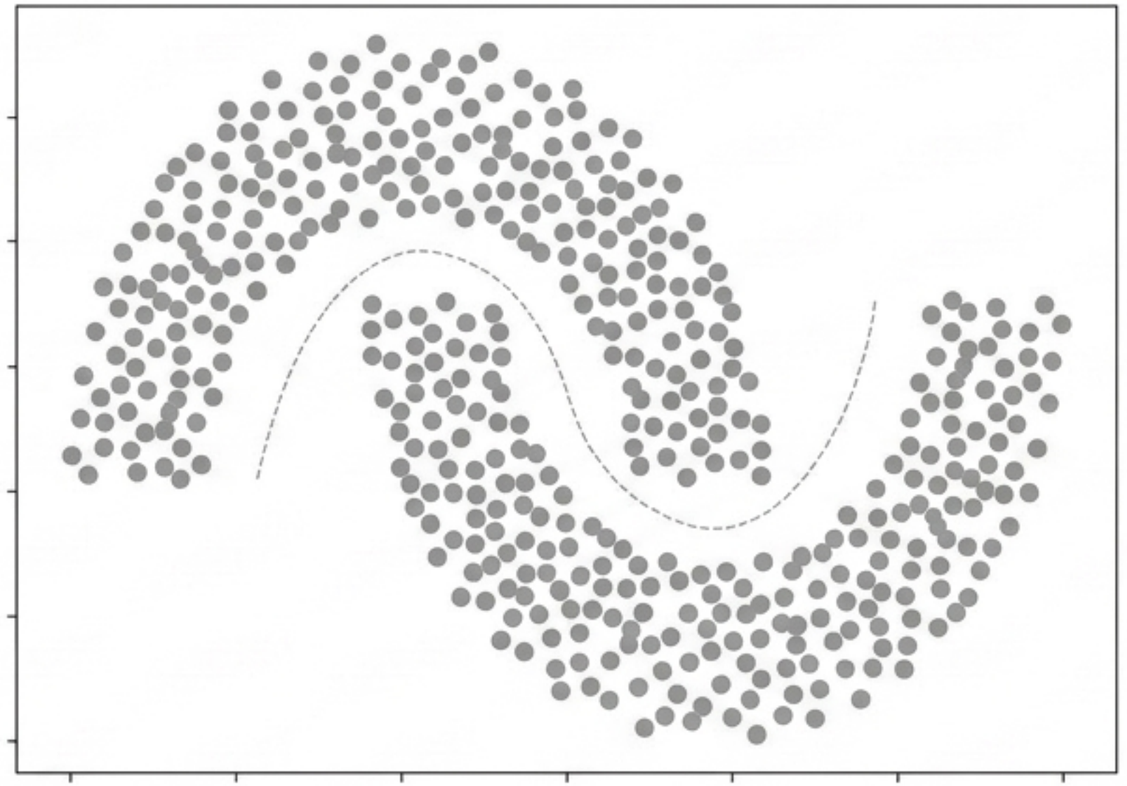
Gom toàn bộ điểm trong vùng lân cận ε của nó vào một cụm.

Nếu trong vùng lân cận có các Điểm lõi khác, tiếp tục lan rộng và gộp vùng lân cận của chúng lại.

Tạo thành một chuỗi liên kết chặt chẽ các điểm lõi và điểm biên, tạo nên hình dáng cụm cuối cùng.

Gemini Notebook

Thử thách thực chiến: Tập dữ liệu "Moons"

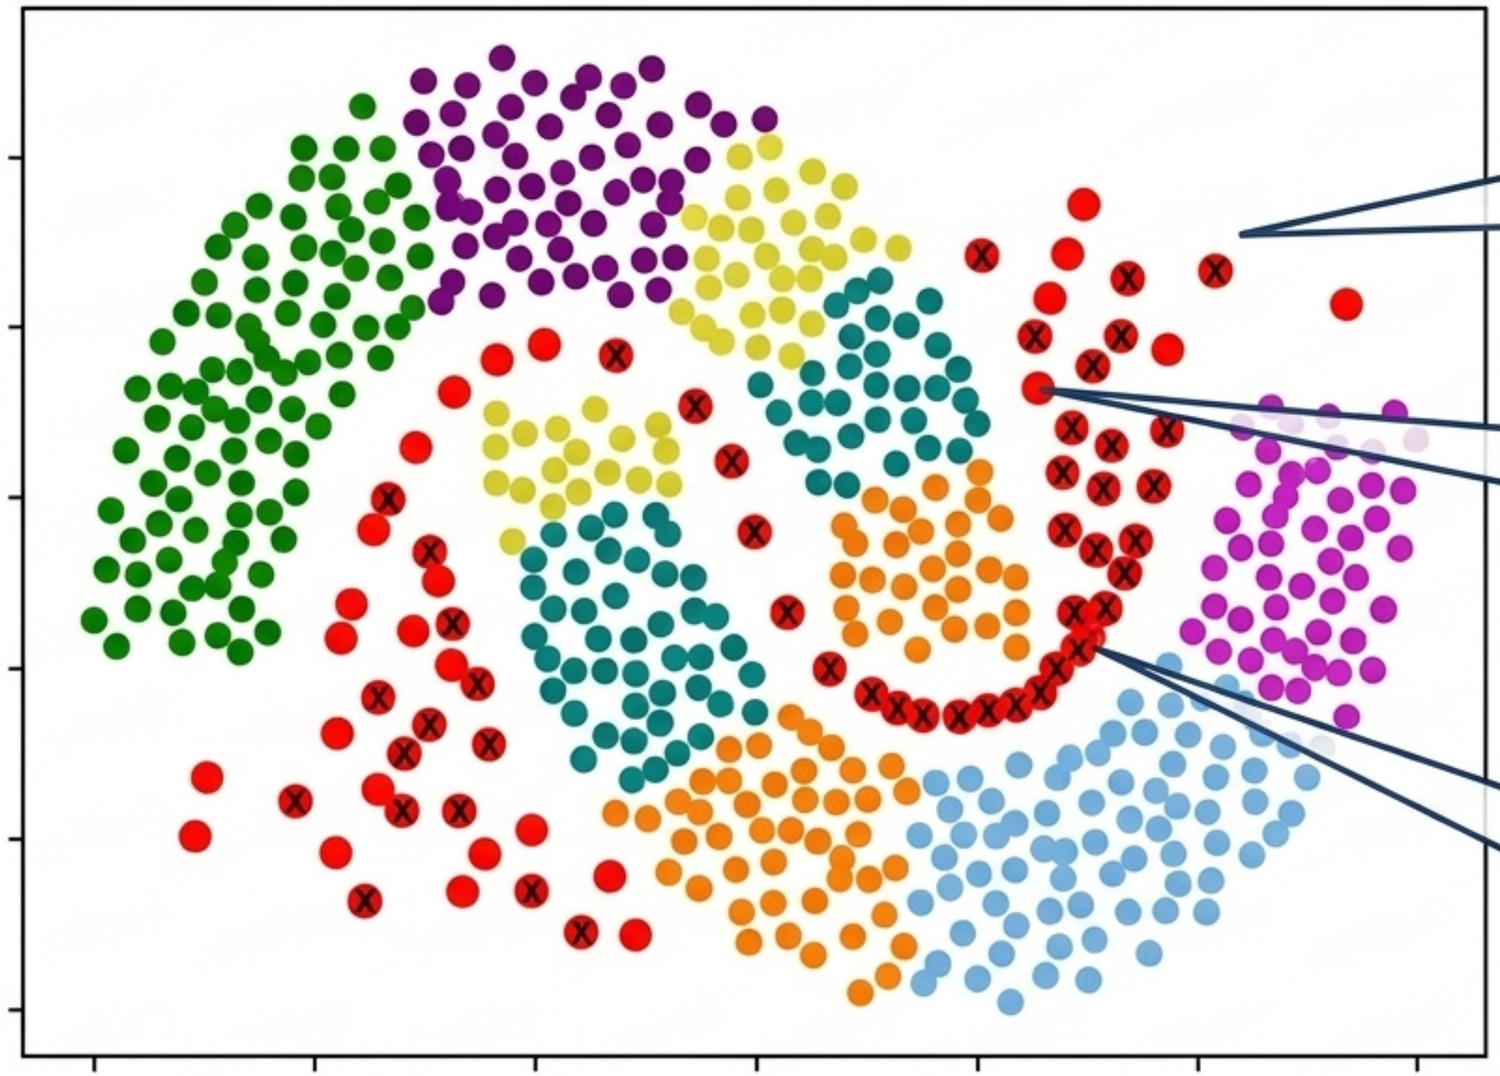


Bối cảnh: 2 dải dữ liệu hình mặt trăng khuyết lồng vào nhau.
K-Means chắc chắn sẽ thất bại do cố gắng tìm tâm hình cầu.

Làm sao để thuật toán tự động men theo đường cong của dữ liệu để tách hoàn hảo 2 cụm này?

Gemini Notebook

Hậu quả khi thuật toán quá “khắt khe”



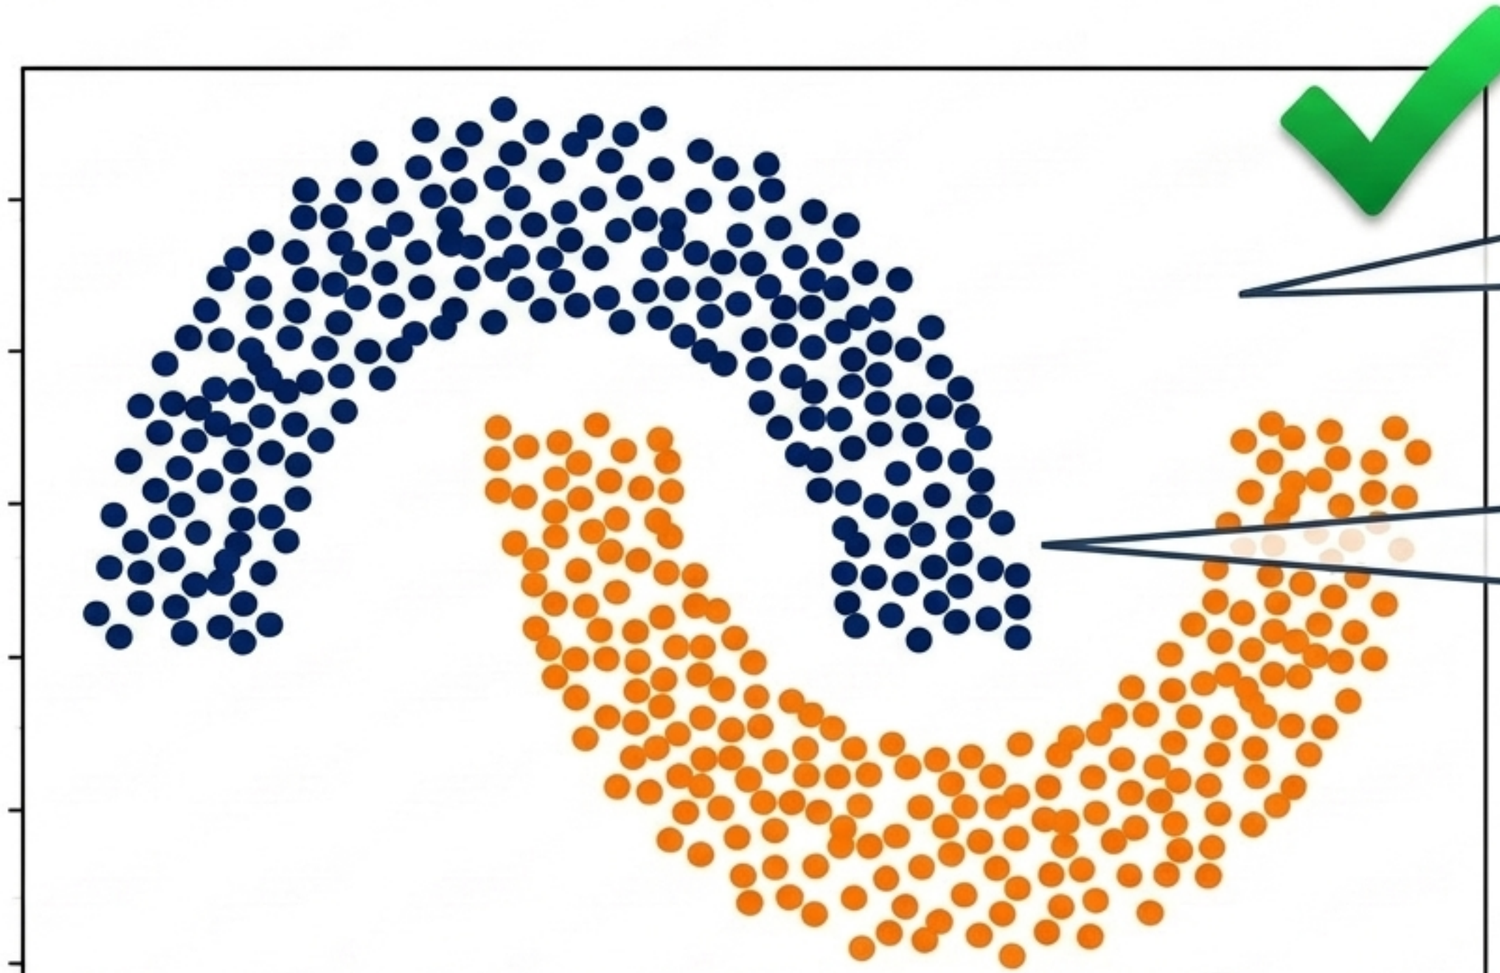
Cấu hình: eps = 0.05, min_samples = 5. Bán kính vùng lân cận quá nhỏ.

Hiện tượng phân mảnh: 2 dải dữ liệu lân liên tục bị xé nát thành 7 cụm nhỏ lắt nhắt.

Tỷ lệ nhiễu ảo cao: Hàng loạt điểm bị đánh dấu “x” đỏ (Dị thường / nhãn -1) oan uổng vì thuật toán không với tới.

Gemini Notebook

Nhận diện hoàn hảo nhờ tối ưu vùng lân cận



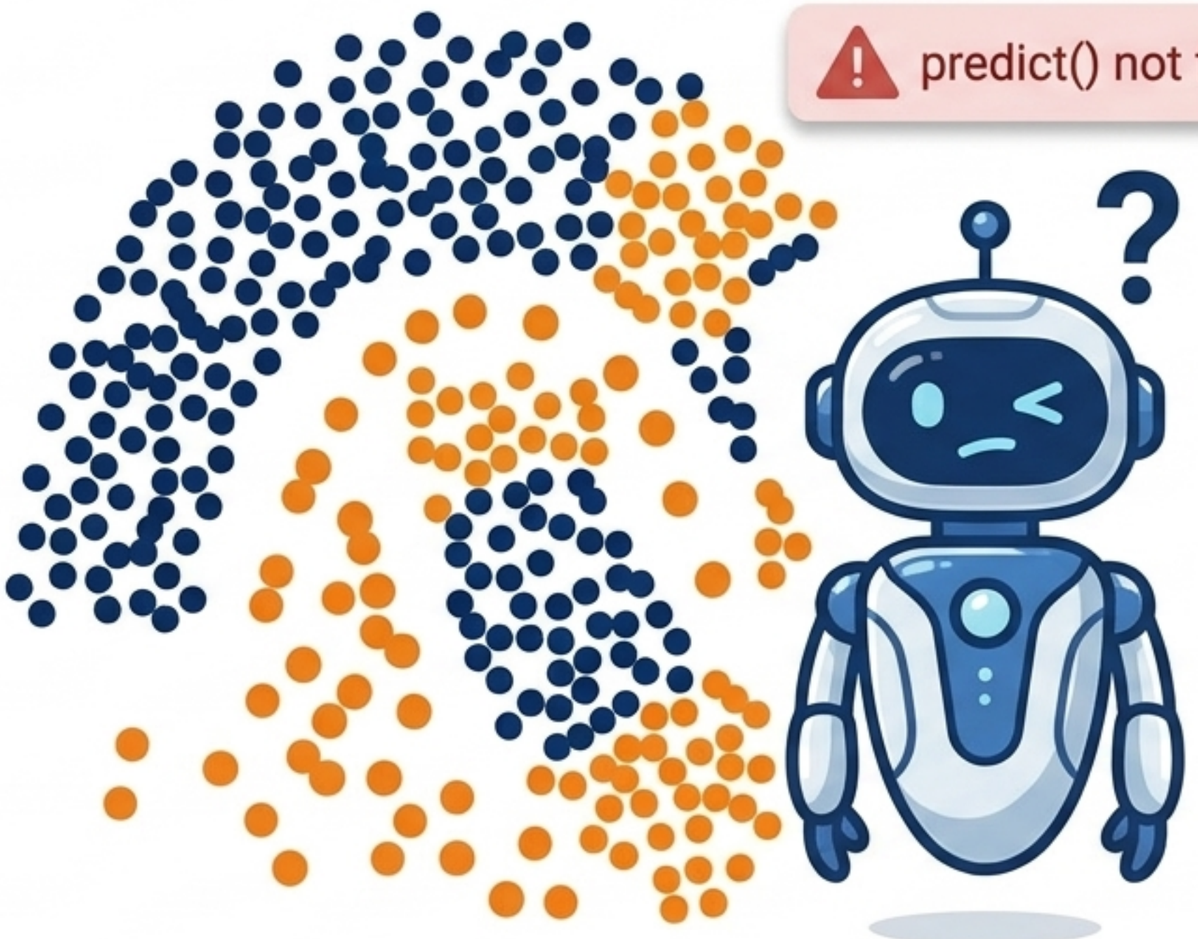
Cấu hình: eps = 0.20, min_samples = 5. Bán kính mở rộng hợp lý.

Kết quả: DBSCAN nhận diện chính xác hoàn hảo 2 cụm hình mặt trăng mượt mà, không hề đứt đoạn.

Thuật toán **tự động** tìm ra **đường bao** của dữ liệu và loại bỏ hoàn toàn điểm nhiễu mà không cần báo trước số cụm k.

Gemini Notebook

Bài toán hóc búa với điểm dữ liệu mới



- Lớp DBSCAN trong Scikit-Learn không có phương thức predict(), nó chỉ có fit_predict().

?

- Điều này có nghĩa thuật toán không tự động gán nhãn **không gán nhãn** cho một điểm dữ liệu hoàn toàn mới khi hệ thống đi vào hoạt động thực tế (**production**). **Giải pháp là gì?**

Gemini Notebook

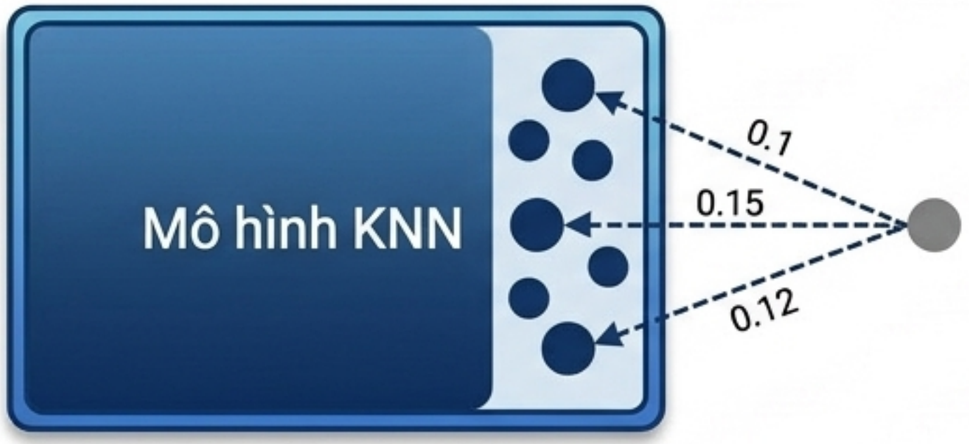
Tích hợp K-Nearest Neighbors (KNN) để dự đoán

Step 1



Mô hình KNN

Step 2

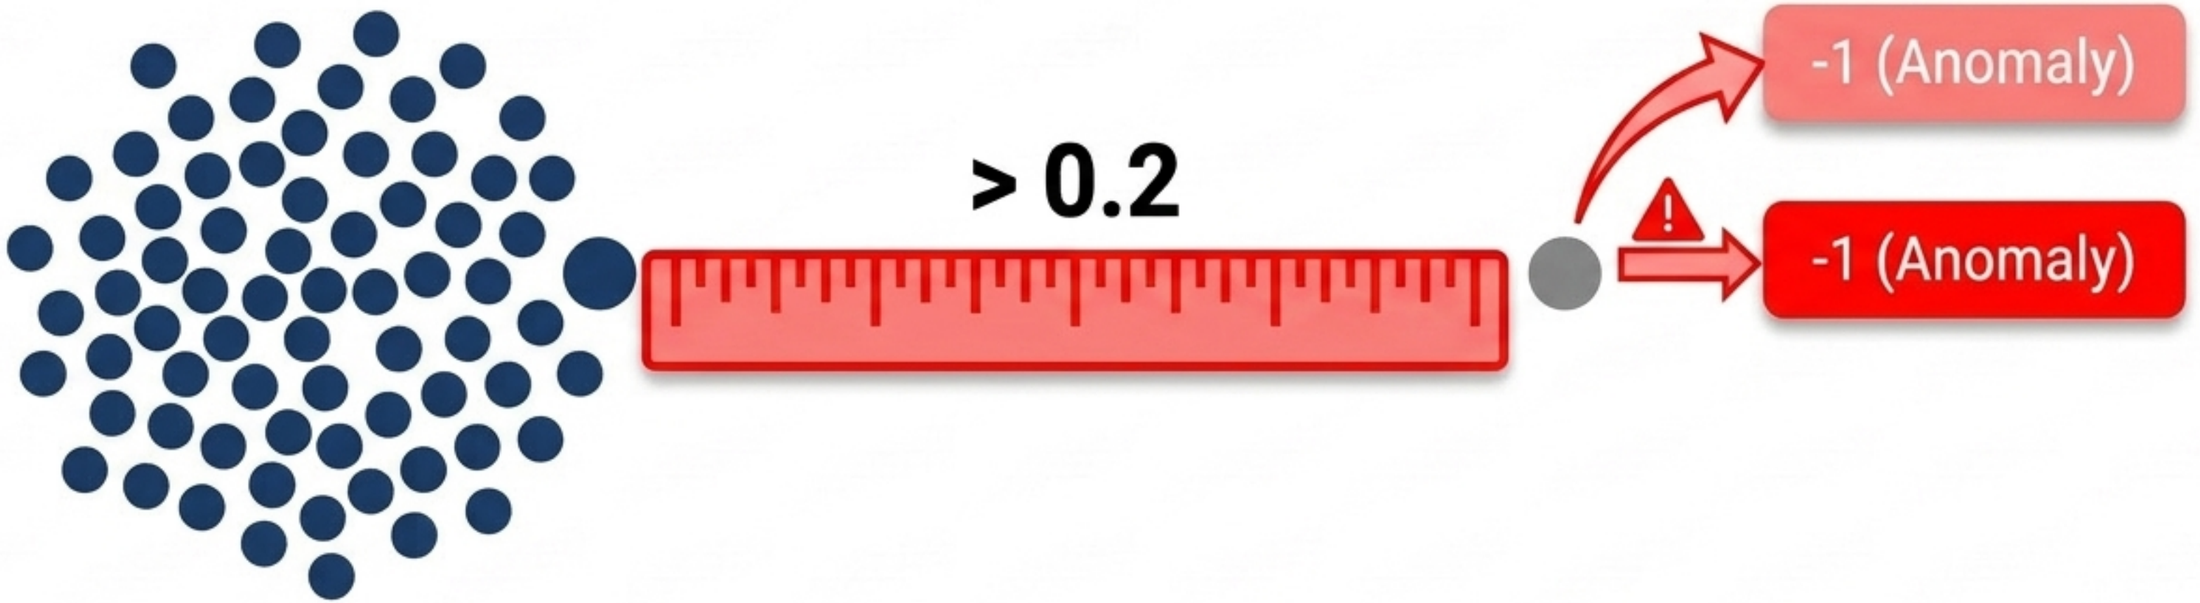


Bước 1 (Huấn luyện)
Trích xuất tập hợp các Điểm Lõi và nhãn cụm của chúng để làm dữ liệu huấn luyện cho bộ phân loại KNN.

Bước 2 (Dự đoán)
Khi điểm mới xuất hiện, KNN tìm kiếm láng giềng điểm lõi gần nhất để dự đoán cụm có khả năng cao nhất.

Gemini Notebook

Cơ chế bảo vệ mô hình trước các điểm dị thường



Tránh việc KNN mù quáng gán nhãn cho mọi điểm.

Tính khoảng cách từ điểm mới đến điểm lõi gần nhất. Nếu khoảng cách vượt quá ngưỡng an toàn (ví dụ: > 0.2), hệ thống tực động ép buộc gán nhãn **Dị thường** (-1) thay vì nhét nó vào một cụm.

Gemini Notebook

Đánh giá tổng quan năng lực của DBSCAN



- Không cần khai báo trước số cụm k.
- Bắt trọn các cụm có hình dạng hình học bất kỳ.
- Mạnh mẽ, tự động cô lập điểm ngoại lệ và nhiễu.
- Tinh gọn với chỉ 2 siêu tham số (eps & min_samples).



- Thất bại nếu mật độ giữa các cụm chênh lệch quá lớn.
- Độ phức tạp $O(m^2 \cdot n)$: Tính toán rất **chậm chạp** trên các tập dữ liệu khổng lồ.

Gemini Notebook

Chinh phục không gian dữ liệu bất định

DBSCAN đã cung cấp lăng kính đầu tiên về phân cụm theo mật độ. Để tiếp tục xử lý các hình dạng dữ liệu phức tạp mà không bị kẹt bởi nhược điểm tốc độ, hành trình tiếp theo gọi tên:



Thuật toán nào sẽ tối ưu hơn về tốc độ tính toán cho tập dữ liệu lớn của bạn?

Gemini Notebook