Đánh giá chất lượng bằng điểm Silhouette

Phương pháp ”khuỷu tay” quá thô sơ. Đánh giá điểm Silhouette (Silhouette Score) chính xác hơn.



a: Khoảng cách trung bình đến các điểm trong cùng cụm.

$$s = \frac{(b-a)}{\max(a,b)}$$



b: Khoảng cách trung bình đến các điểm trong cụm gần nhất tiếp theo.

-1 Điểm có thể bị gán sai cụm.

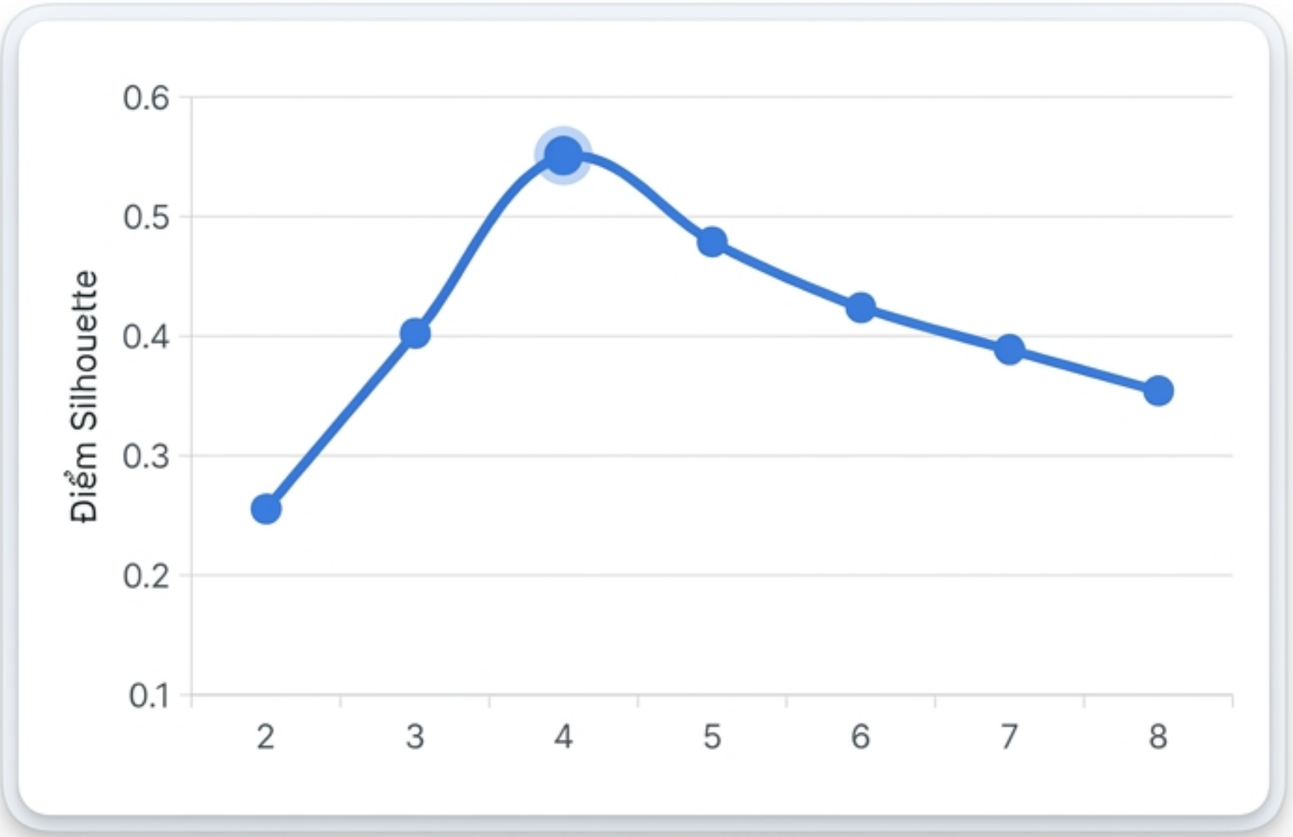
0 Điểm nằm ở rìa cụm.

+1 Điểm nằm sâu trong cụm.



Gemini Notebook

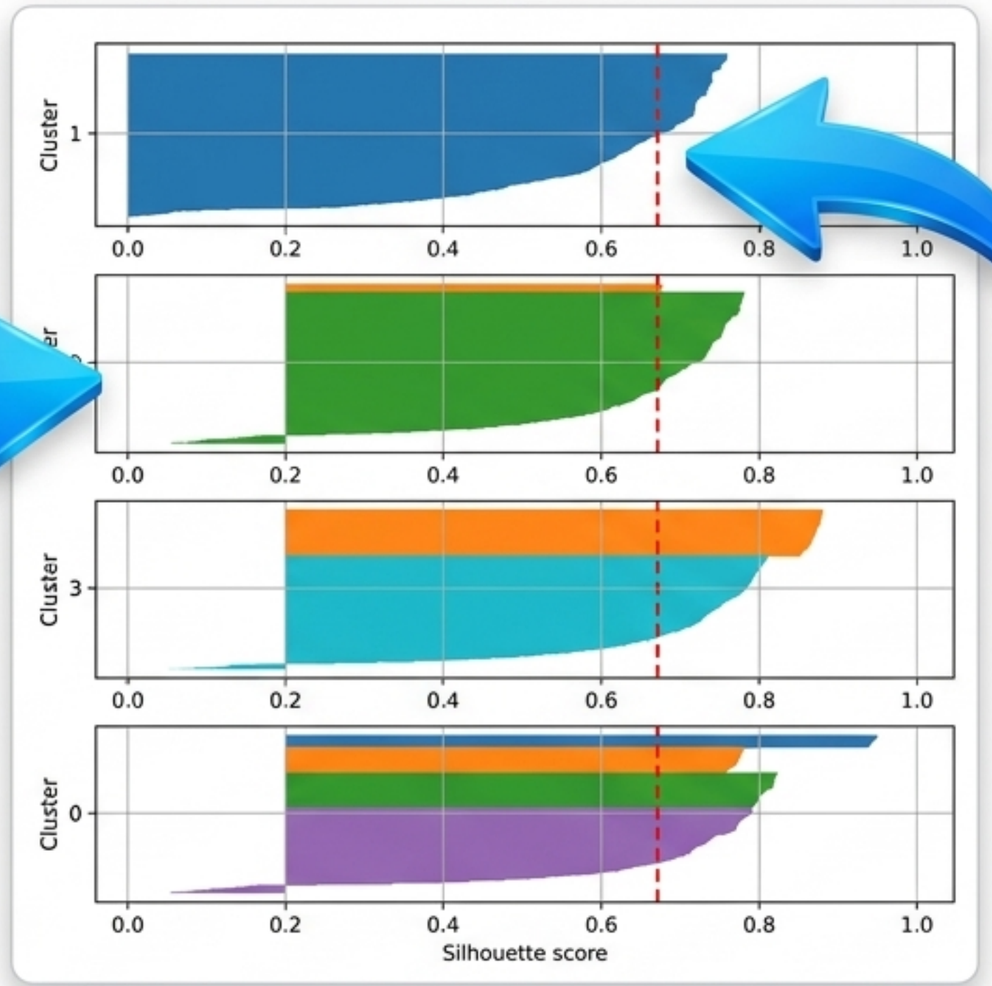
Biểu đồ điểm Silhouette theo k



Hình 9-9. Chọn số lượng cụm k tối ưu (đỉnh cao nhất, ví dụ k = 4 hoặc k = 5)

Gemini Notebook

Phân tích biểu đồ dao (Silhouette plots)



Ranh giới đỏ là điểm Silhouette trung bình.

Dao càng rộng, cụm càng tốt.

Hình 9-10. *Hình dao cho mỗi cụm. Dao càng rộng, cụm càng tốt. Ranh giới đỏ là điểm Silhouette trung bình.*

Gemini Notebook

Giới hạn của K-Means

Cần chạy thuật toán nhiều lần để tránh tối ưu cục bộ.

Phải chỉ định trước số cụm k.



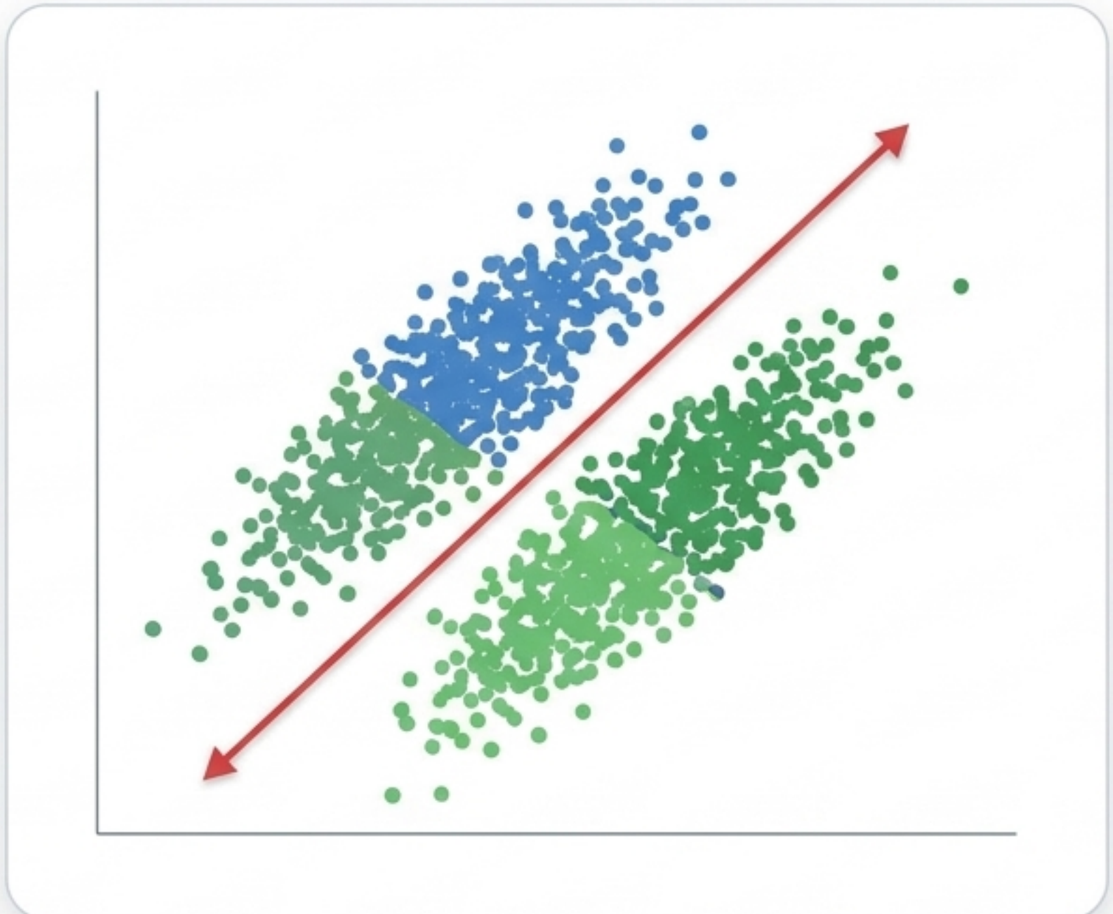
Nhược điểm lớn nhất: K-Means hoạt động rất kém khi các cụm có **kích thước khác nhau nhiều**, mật độ khác nhau, hoặc hình dạng không phải hình cầu (ví dụ: hình elip).



Lý do: K-Means chỉ quan tâm đến khoảng cách tới tâm cụm.

Gemini Notebook

K-Means gặp khó khăn với các cụm hình elip



Hình 9-11. K-Means phân cụm sai lầm khi cắt ngang khối hình elip tự nhiên

Gemini Notebook

Ứng dụng: Phân đoạn hình ảnh (Image Segmentation)

Phân đoạn hình ảnh: Chia hình ảnh thành nhiều phân đoạn. Ứng dụng phổ biến: Phân đoạn màu sắc.



Tập hợp các pixel của hình ảnh.



Nhóm các pixel có màu giống nhau vào cùng một cụm K-Means.



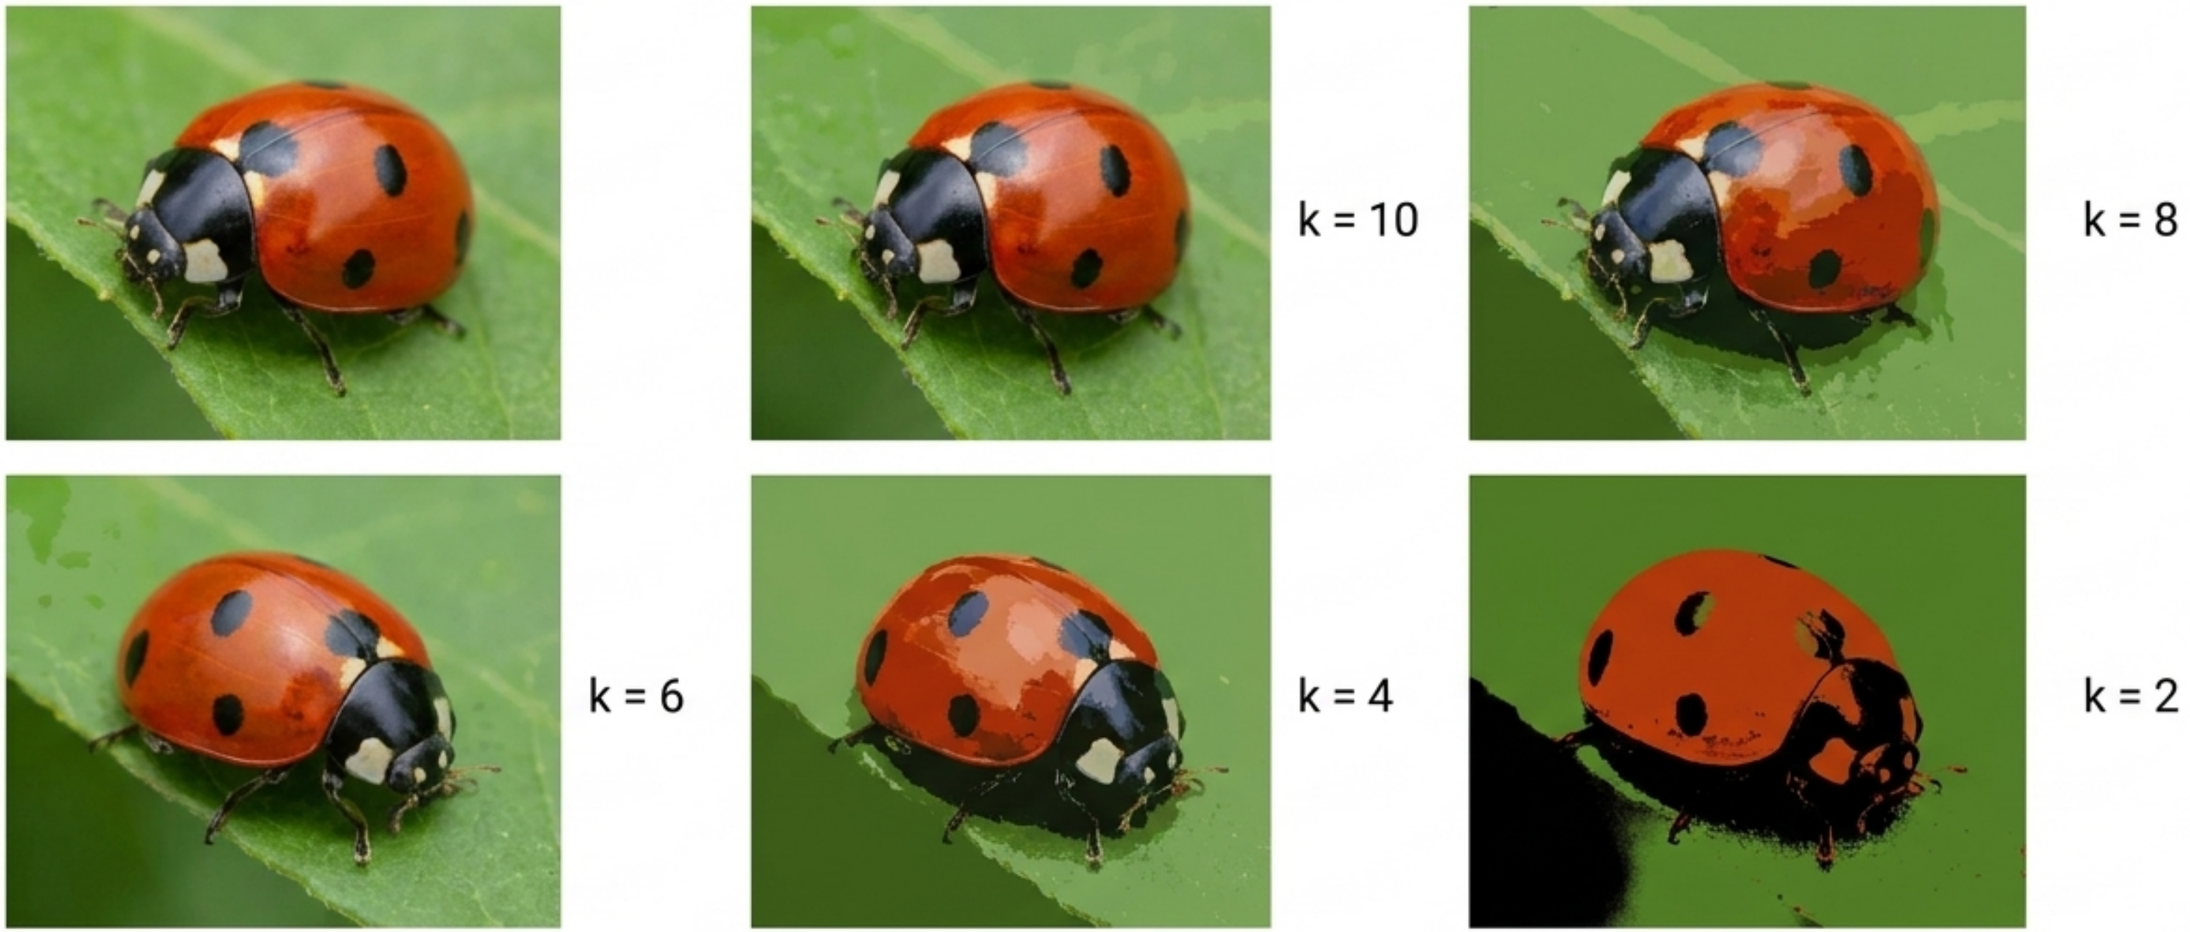
Thay thế giá trị màu của mọi pixel bằng màu của tâm cụm K-Means



giảm số lượng màu xuống k màu, tạo hiệu ứng ảnh như tranh vẽ (Posterization).

Gemini Notebook

Phân đoạn màu sắc hình ảnh bọ rùa

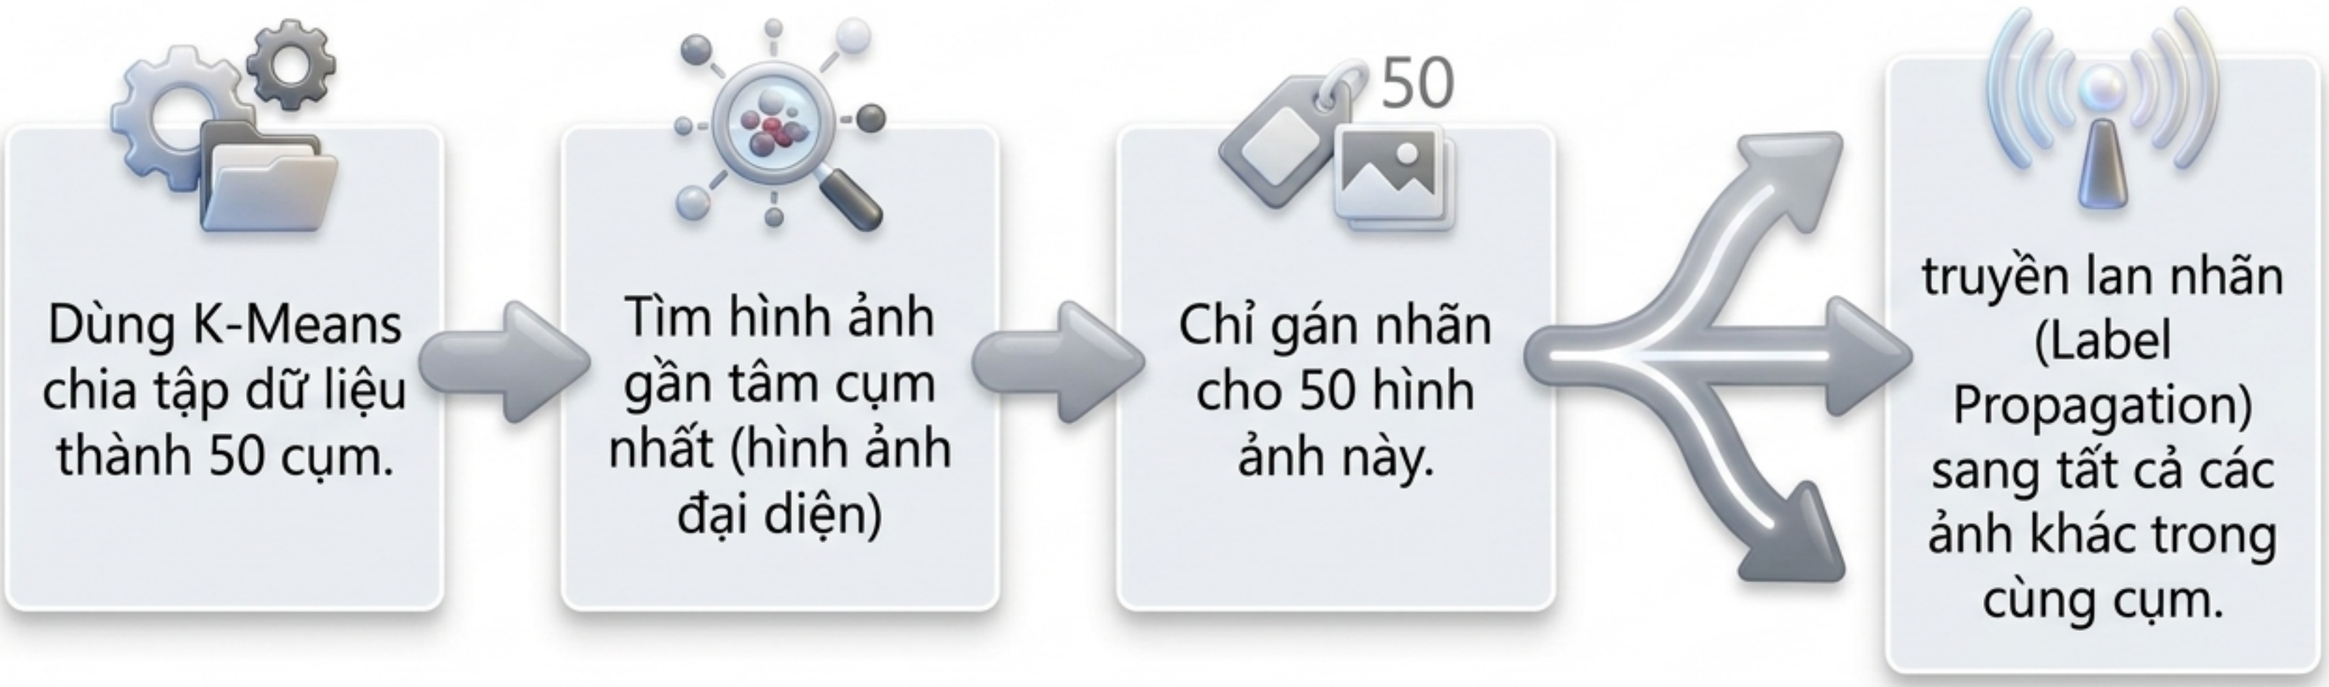


Hình 9-12. Phân đoạn hình ảnh sử dụng K-means với các số lượng cụm màu khác nhau (k = 10, 8, 6, 4, 2)

Gemini Notebook

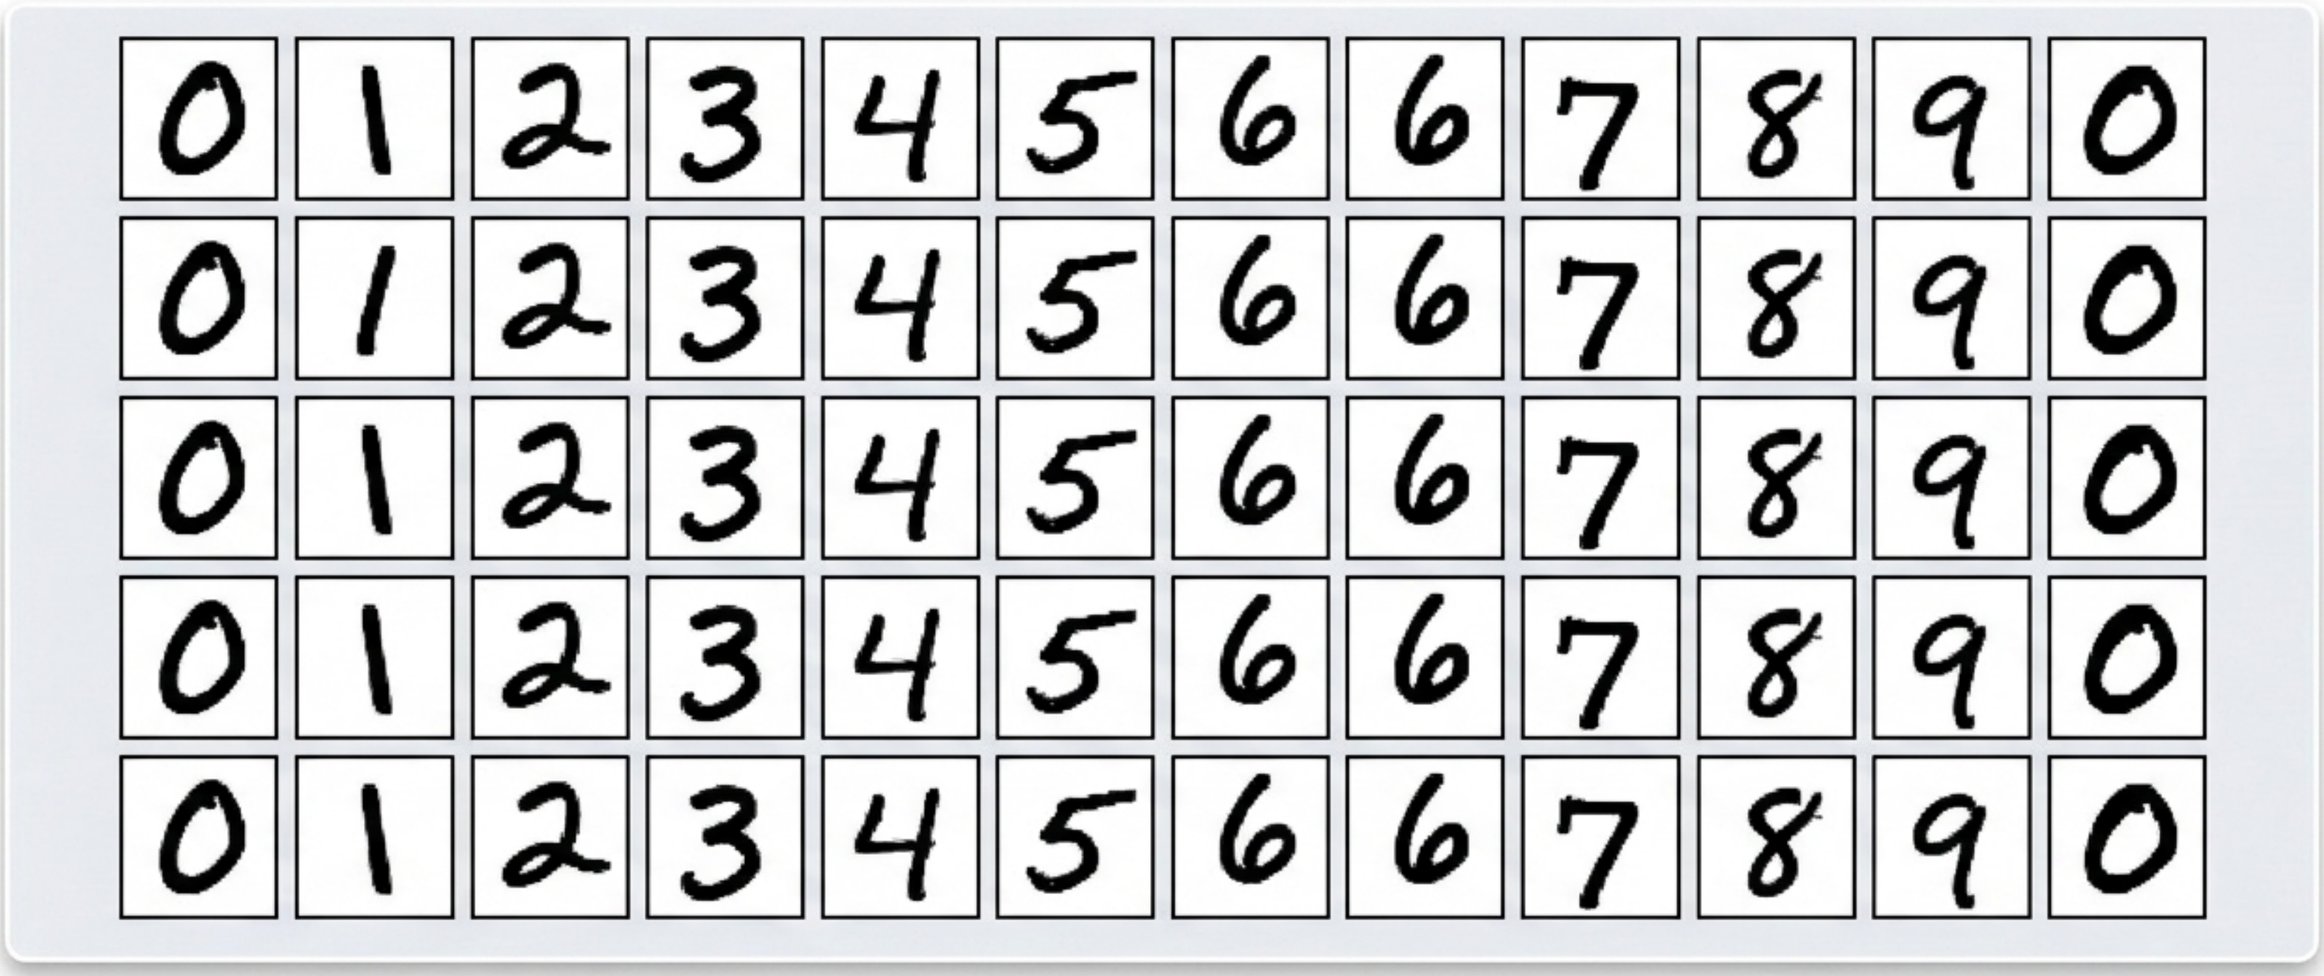
Ứng dụng: Tiền xử lý để học bán giám sát

Khi bạn có rất nhiều dữ liệu nhưng chỉ một phần rất nhỏ có nhãn (vd: chỉ gán nhãn được 50 tấm ảnh MNIST). Thay vì gán nhãn 50 ảnh ngẫu nhiên...



Gemini Notebook

Lấy 50 hình ảnh đại diện bằng K-Means

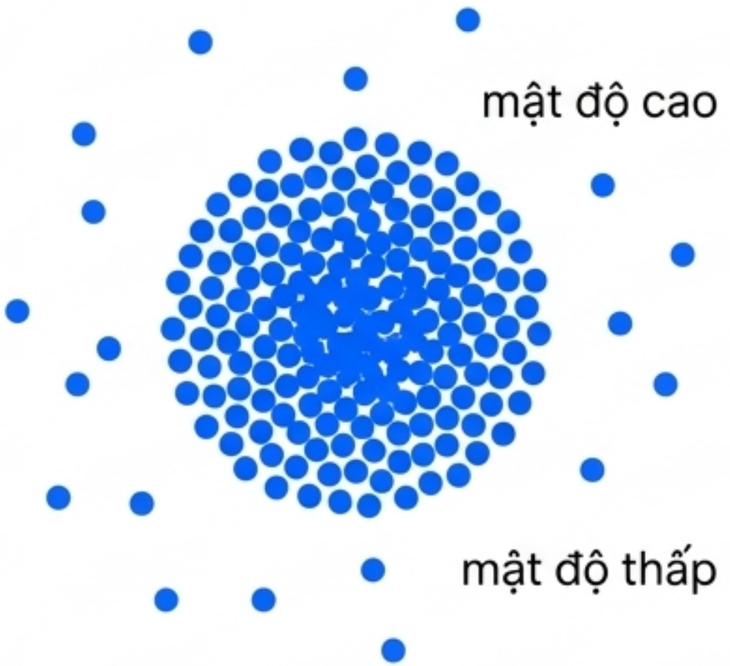


Hình 9-13. 50 hình ảnh chữ số đại diện (một hình ảnh cho mỗi cụm). Việc gán nhãn chúng mang lại ý nghĩa cao hơn chọn ngẫu nhiên.

Gemini Notebook

Thuật toán phân cụm DBSCAN

Density-**B**ased **S**patial **C**lustering of **C**lustering of **A**pplications with **N**oise



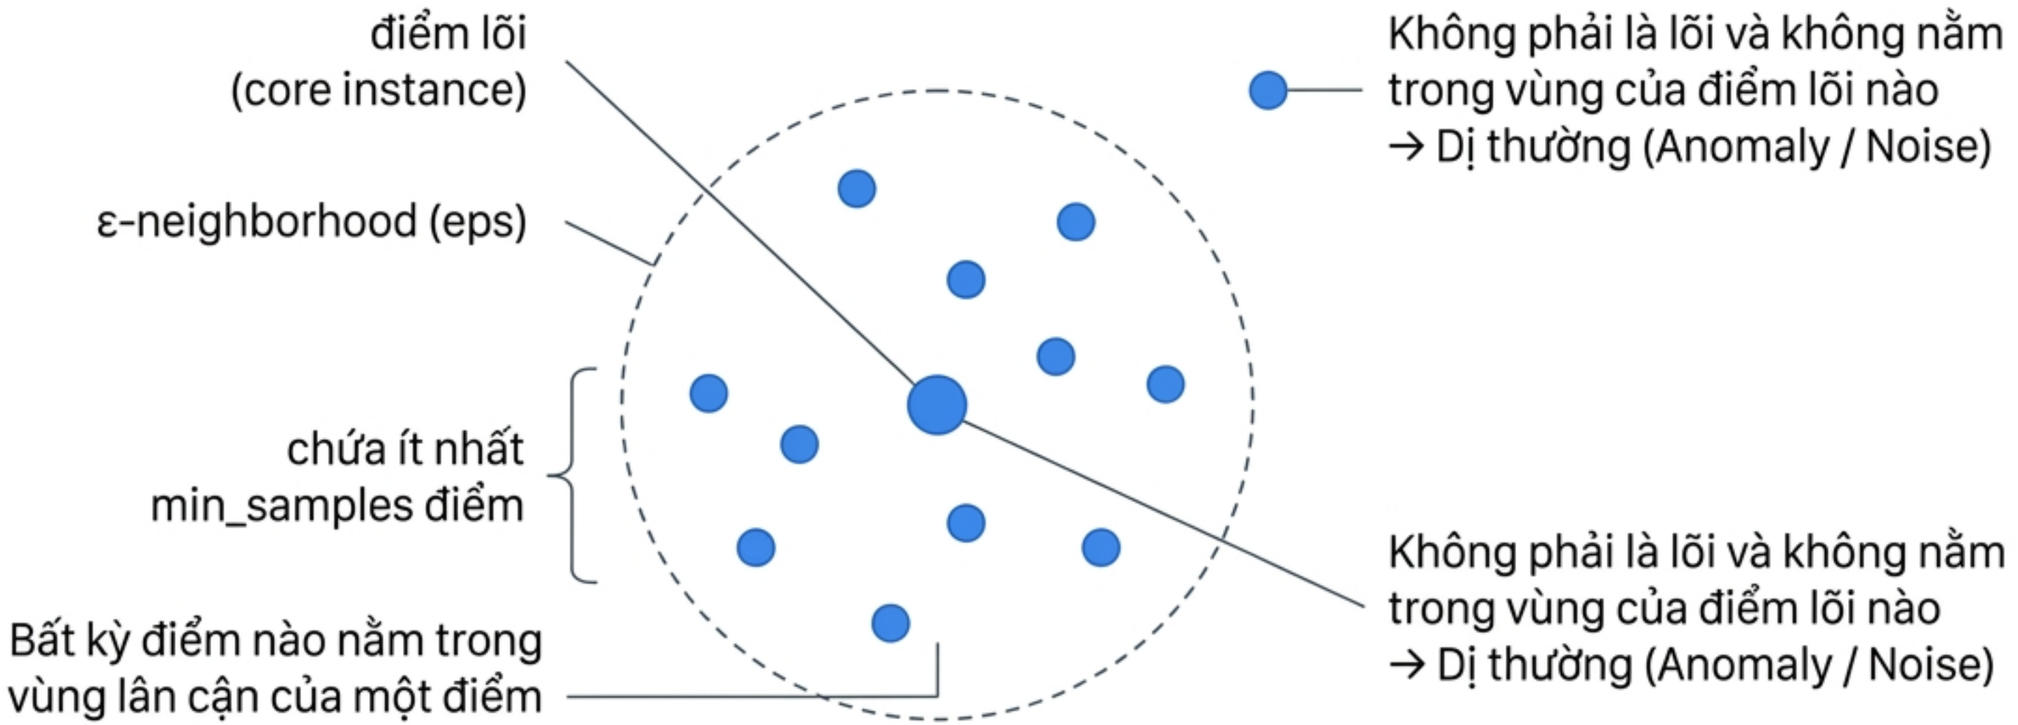
Dựa trên ý tưởng các cụm là các khu vực có mật độ cao phân tách bởi khu vực có mật độ thấp.

🔍 Xác định được các cụm có hình dạng tùy ý

✔ Có thể phát hiện điểm ngoại lai (nhiễu)

Gemini Notebook

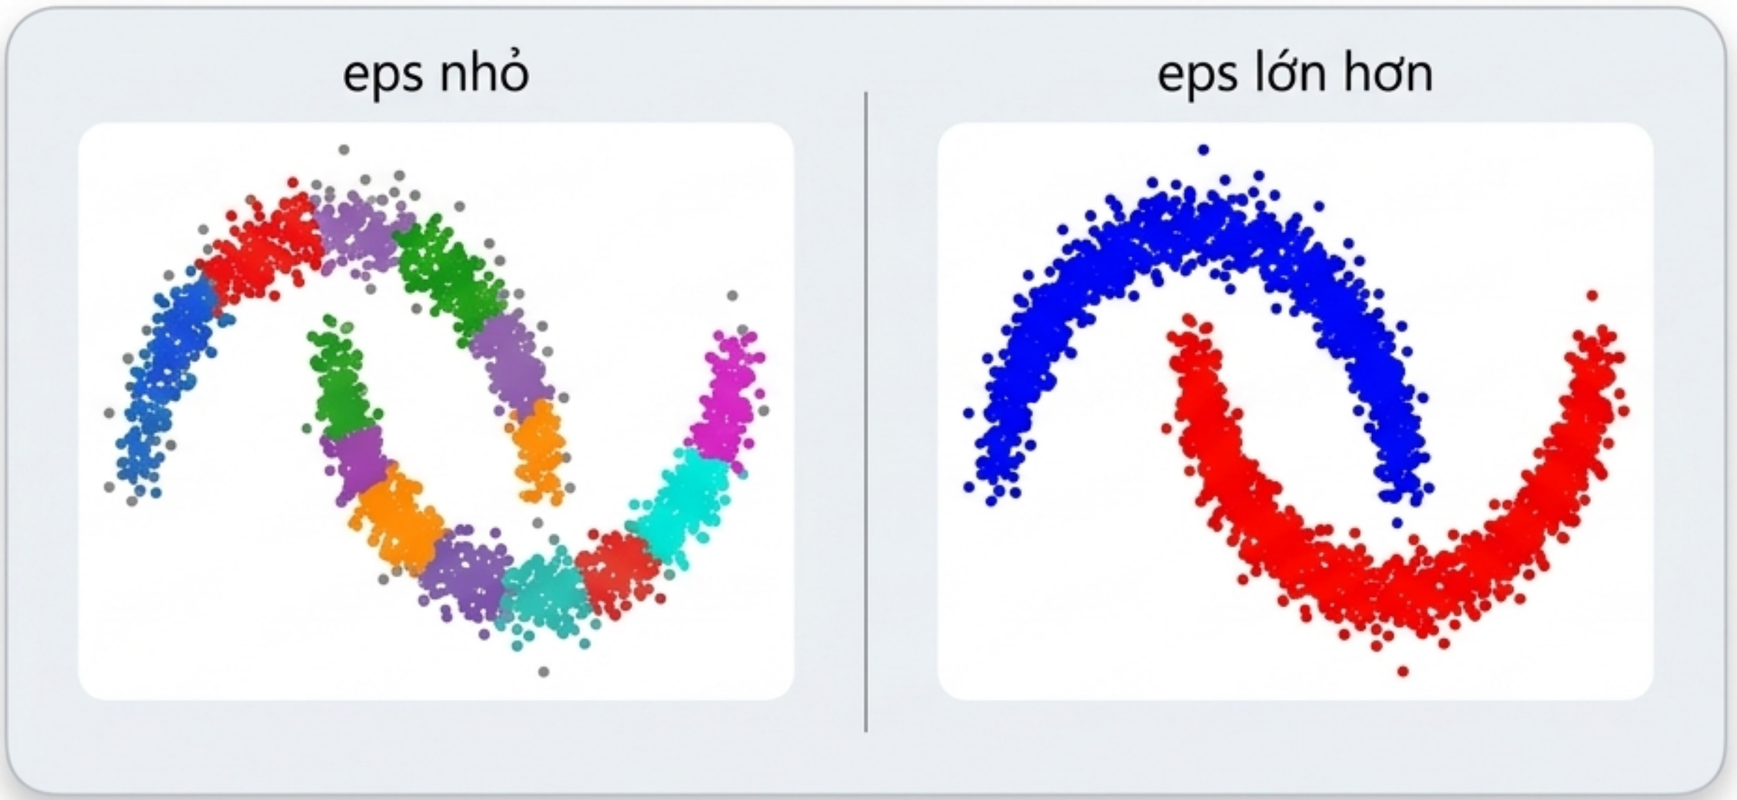
Cơ chế hoạt động của DBSCAN



(Các điểm lõi gần nhau kết hợp lại thành cụm lớn)

Gemini Notebook

DBSCAN với 2 bán kính vùng lân cận khác nhau



Hình 9-14. DBSCAN bắt được hình dạng "mặt trăng" cực tốt. eps nhỏ (trái) tạo nhiều cụm đứt gãy. eps lớn hơn (phải) tạo ra 2 cụm hoàn hảo.

Gemini Notebook

Ưu điểm và nhược điểm của DBSCAN

Ưu điểm:

- ✔ Không cần khai báo số cụm k trước.
- ✔ Kháng nhiễu cực tốt (tự phát hiện và loại bỏ điểm ngoại lai).
- ✔ Tìm được cụm có hình dạng hình học phức tạp (chữ U, hình vành khăn, mặt trăng...).

Nhược điểm:

- ✘ DBSCAN không có phương thức predict(), nó không thể tự gán cụm cho một trường hợp mới sinh ra.
- ✘ Kém hiệu quả nếu các cụm trong tập dữ liệu có mật độ khác biệt nhau quá lớn.

Gemini Notebook

Dự đoán với DBSCAN (Kết hợp KNN)

Vì DBSCAN không có predict(), ta có thể dùng thuật toán phân loại KNN để huấn luyện trên các lõi DBSCAN vừa tìm được.

```python
from sklearn.neighbors import KNeighborsClassifier

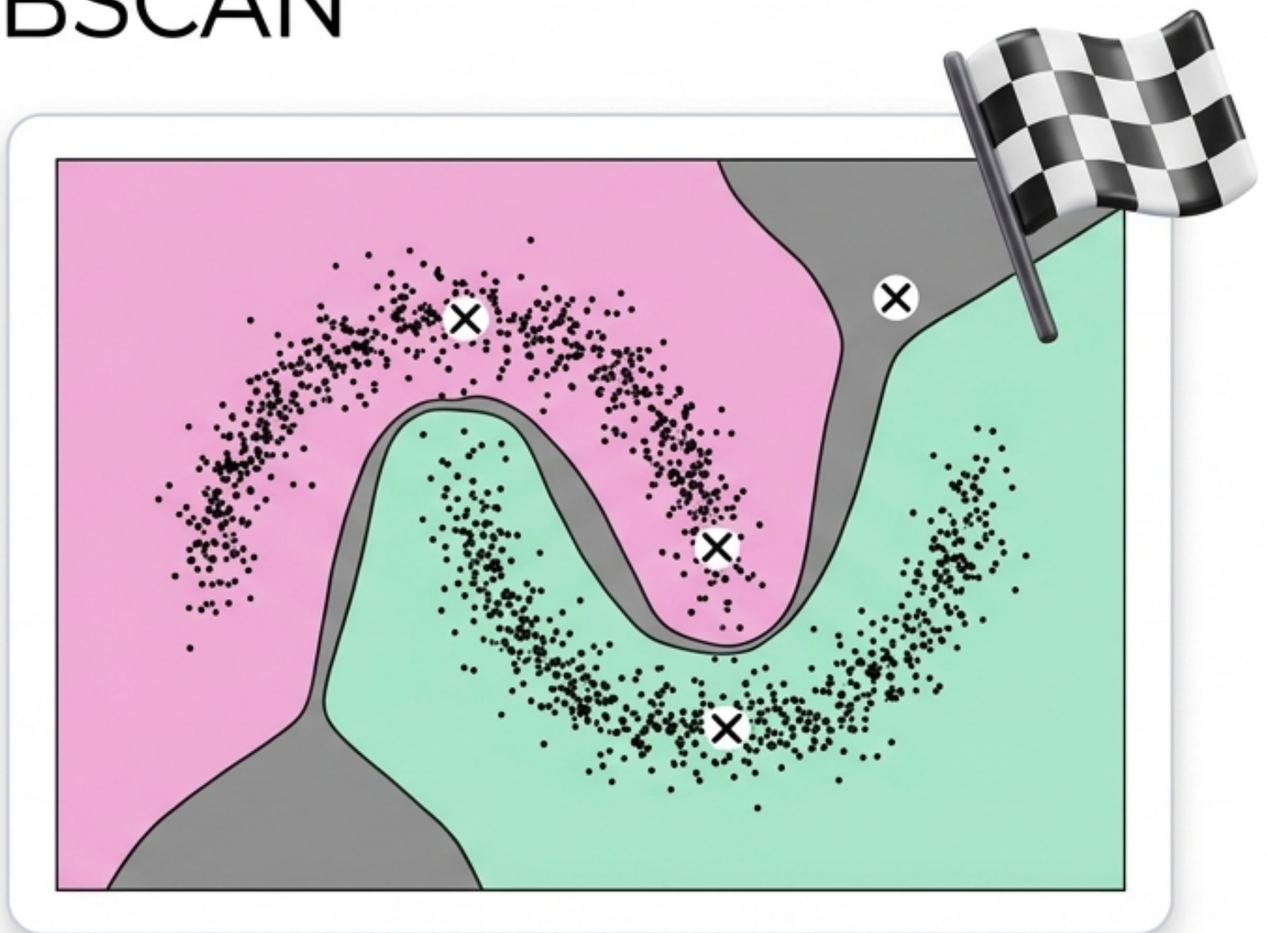
knn = KNeighborsClassifier(n_neighbors=50)
# dbscan.components_ chua cac diem loi
# dbscan.labels_ chua nhan cua cac diem do
knn.fit(dbscan.components_ , dbscan.labels_[dbscan.core_sample_indices_])

import numpy as np
X_new = np.array([[-0.5, 0], [0, 0.5], [1, -0.1], [2, 1]])
print(knn.predict(X_new))
# Output: [1 0 1 0]

```

Gemini Notebook

Đường biên quyết định của phân loại KNN trên tập DBSCAN



Hình 9-15. Dùng KNN tạo đường biên phân loại mới dựa trên các cụm đã tìm thấy bởi DBSCAN

Gemini Notebook