Mô hình Hỗn hợp Gaussian (GMM) là gì?

- **Gaussian Mixture Model (GMM):** Là một mô hình xác suất giả định rằng tất cả các điểm dữ liệu được sinh ra từ một *hỗn hợp (mixture)* của một số hữu hạn các phân phối Gaussian (Phân phối chuẩn) với các tham số chưa biết.
- Nó đại diện cho các cụm có hình dạng **hình elip** (có thể dẹt, nghiêng, xoay) với nhiều kích thước khác nhau.
- GMM là một kỹ thuật tuyệt vời để khắc phục nhược điểm của K-Means với các cụm hình elip.

Thuật toán Cực đại hóa Kỳ vọng (EM)

- Để khớp GMM với tập dữ liệu, người ta dùng thuật toán **Expectation-Maximization (EM)**.
- Có nhiều điểm tương đồng với K-Means: khởi tạo ngẫu nhiên tâm và lặp lại cho đến khi hội tụ.
- EM không chỉ tìm tâm cụm (trung bình μ), mà còn tìm cả kích thước, hình dạng, và hướng của chúng (ma trận hiệp phương sai Σ), cũng như xác suất tương đối của chúng (trọng số ϕ).
- Khác K-Means (gán cứng), EM thực hiện **gán mềm (soft assignments)**: tính *xác suất* một điểm thuộc về mỗi cụm.

Khởi tạo GMM trong Scikit-Learn

Giống K-Means, bạn phải cung cấp số lượng cụm k (biến `n_components`):

```
from sklearn.mixture import GaussianMixture

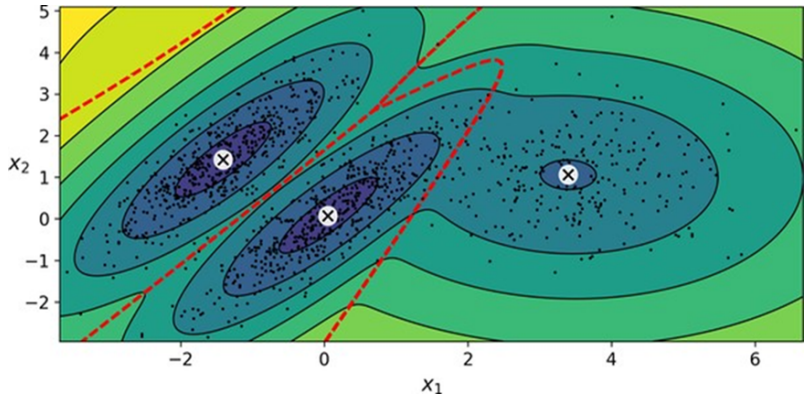
gm = GaussianMixture(n_components=3, n_init=10, random_state=42)
gm.fit(X)

print(gm.weights_)
print(gm.means_)
print(gm.covariances_)

```

Thuật toán EM rất dễ kẹt ở điểm tối ưu cục bộ, nên ta chạy nhiều lần (`n_init=10`) và giữ lại mô hình tốt nhất.

Các giá trị trung bình và đường biên quyết định của GMM



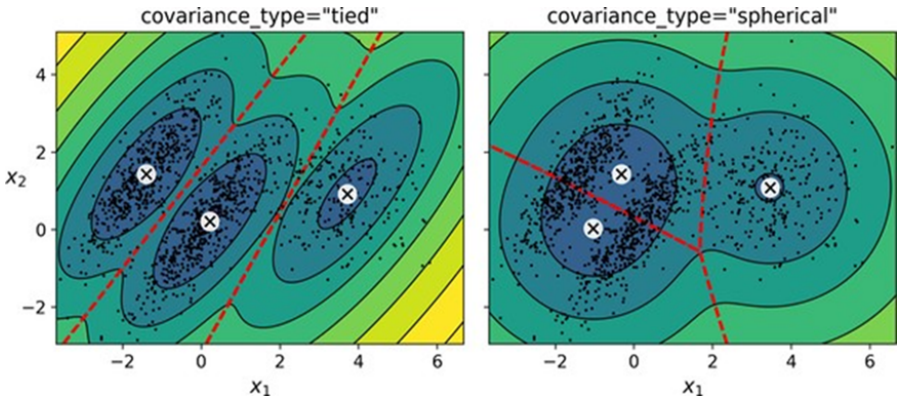
Hình 9-16. GMM tìm ra các cụm hình elip bị kéo giãn và nghiêng cực kỳ chính xác

Hạn chế dạng ma trận hiệp phương sai

Nếu tập dữ liệu lớn với nhiều chiều, GMM cực kỳ khó huấn luyện vì ma trận hiệp phương sai bành trướng. Có thể hạn chế kiểu hình dạng bằng `covariance_type`:

- `"full"` (mặc định): Hình elip tự do hướng theo bất kỳ góc nào.
- `"tied"`: Tất cả các cụm phải dùng chung kích thước, góc xoay, hình dáng.
- `"spherical"`: Cụm phải là hình cầu hoàn hảo (tương tự K-Means, nhưng bán kính có thể khác nhau).
- `"diag"`: Cụm hình elip nhưng trục phải song song với các trục tọa độ.

GMM với các cụm liên kết (tied) và hình cầu (spherical)



Hình 9-17. Bên trái: tied (elip giống hệt nhau). Bên phải: spherical (hình cầu hoàn hảo)

Ước tính mật độ sinh ngẫu nhiên (Generative process)

- GMM là một **Mô hình sinh ngẫu nhiên (Generative model)**.
- Nó không chỉ phân cụm, mà nó mô hình hóa hoàn toàn hàm Mật độ xác suất (PDF) của hệ thống.
- Do đó, bạn có thể sinh ra (generate) các điểm dữ liệu **mới** hoàn toàn tự nhiên trông giống như phân phối gốc bằng hàm `gm.sample(50)`.

Phát hiện dị thường (Anomaly Detection) bằng GMM

- Bằng cách ước lượng hàm PDF tổng quát, bất kỳ điểm dữ liệu nào nằm trong khu vực có **mật độ cực thấp** (low density) đều bị tình nghi là Dị thường (Anomaly / Outlier).
- Dùng hàm `gm.score_samples(X)` để đánh giá mức độ mật độ (log-likelihood) tại điểm đó.
- Nếu mật độ thấp hơn một ngưỡng phân vị, ta đánh dấu điểm đó là dị thường.

Cách tính ngưỡng mật độ phát hiện dị thường

Ví dụ, ta quyết định 4% số điểm có mật độ thấp nhất là dị thường:

```
import numpy as np

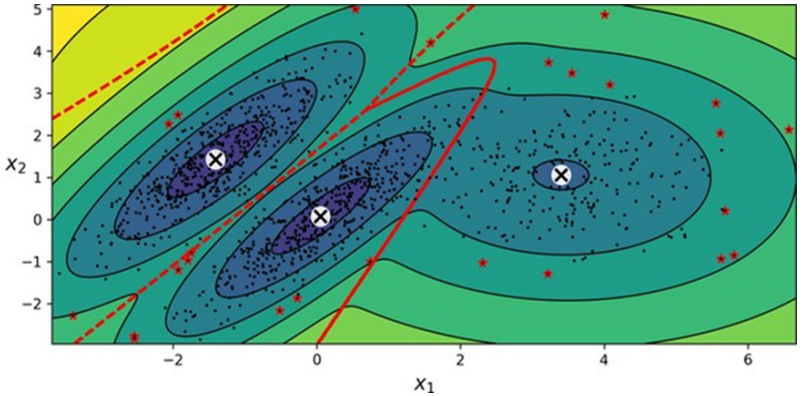
# score_samples tra ve mat do log (log PDF)
densities = gm.score_samples(X)

# Tim nguong mat do tuong ung voi percentile thu 4
density_threshold = np.percentile(densities, 4)

# Danh dau cac diem nam duoi nguong do la Di thuong (anomalies)
anomalies = X[densities < density_threshold]

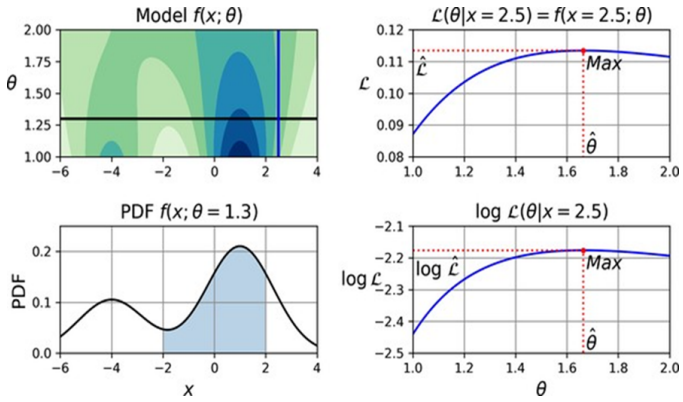
```

Phát hiện dị thường sử dụng GMM



Hình 9-18. Các ngôi sao màu đỏ là các điểm dị thường (Anomalies) nằm ở khu vực mật độ thấp

Hàm tham số của mô hình



Hình 9-19. Không gian hàm PDF của Mô hình hỗn hợp Gaussian từ một cụm đơn giản

Lựa chọn số lượng cụm trong GMM

- Với K-Means ta dùng Quán tính hay Silhouette Score.
- Tuy nhiên, các số liệu này không đáng tin cậy với GMM (chúng thiên vị các cụm hình cầu).
- Với GMM, ta dùng các **Tiêu chí Thông tin (Information Criteria)**: **BIC** (Bayesian Information Criterion) hoặc **AIC** (Akaike Information Criterion).

Công thức tính toán AIC và BIC

- Cả BIC và AIC phạt (penalty) mô hình nếu có quá nhiều tham số phải học (ngăn chặn quá khớp), và thưởng cho mô hình khớp tốt dữ liệu.
- Mô hình tốt nhất là mô hình có AIC/BIC **thấp nhất**.

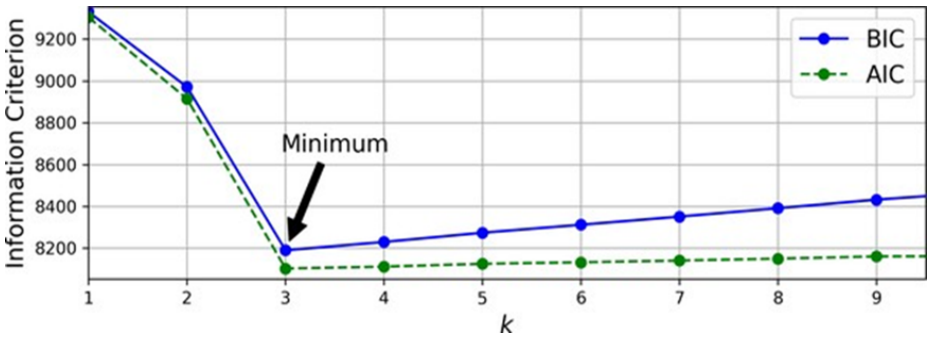
$$BIC = \log(m)p - 2\log(\hat{L})$$

$$AIC = 2p - 2\log(\hat{L})$$

Trong đó:

- m là số mẫu dữ liệu, p là số lượng tham số trong mô hình GMM.
- $\hat{L}$ là hàm giá trị khả năng cực đại (Likelihood) của mô hình.

Biểu đồ AIC và BIC cho các k khác nhau



Hình 9-20. BIC và AIC đạt giá trị cực tiểu rõ ràng tại $k = 3$. Đây là số lượng cụm tối ưu nhất.

Mô hình Hỗn hợp Gaussian Bayes (BGM)

- Khá vất vả khi phải chạy thử thủ công một loạt các k để đo BIC/AIC.
- Thay vì vậy, **Mô hình Hỗn hợp Gaussian Bayes (Bayesian Gaussian Mixture)** ra đời.
- Bạn khởi tạo nó với một số lượng cụm *k* **dư dả** (vd: lớn hơn thực tế bạn nghĩ).
- Thuật toán sẽ tự động gán trọng số (weights) của các cụm không cần thiết bằng 0 hoặc xấp xỉ 0.
- $\rightarrow$ BGM tự động khám phá ra số lượng cụm *k* thực tế!