

Học Máy (Machine Learning)

Chương 9: Các kỹ thuật Học không giám sát

Giảng viên: TS. Trần Thành Thắng

Đại học Đông Á

August 11, 2026

Nội dung Chương trình

- 1 Giới thiệu Học không giám sát & K-Means
- 2 Điểm Silhouette, Ứng dụng K-Means & DBSCAN
- 3 Mô hình Hỗn hợp Gaussian (GMM)
- 4 Mô hình Hỗn hợp Gaussian Bayes


Giới thiệu Học không giám sát

- Mặc dù đa số các ứng dụng học máy ngày nay dựa trên Học có giám sát, nhưng phần lớn dữ liệu trong thực tế là **không được gán nhãn**.
- Chúng ta có các đặc trưng đầu vào X , nhưng không có nhãn y .
- Yann LeCun (Giám đốc AI của Meta): "Nếu trí thông minh là một chiếc bánh, thì học không giám sát sẽ là chiếc bánh, học có giám sát sẽ là lớp kem trên bánh."
- Tiềm năng của học không giám sát là vô cùng lớn nhưng chúng ta mới chỉ bắt đầu khai thác.

Phân cụm (Clustering) là gì?

- **Phân cụm:** Là tác vụ xác định các trường hợp tương tự nhau và gán chúng vào các "cụm" (clusters), hoặc các nhóm trường hợp tương tự.
- Giống như phân loại, mỗi trường hợp được gán vào một nhóm. Nhưng khác biệt ở chỗ đây là tác vụ *không giám sát* (chúng ta không biết trước các nhóm là gì).
- Thuật toán tự động tìm ra cấu trúc ẩn bên trong dữ liệu dựa trên sự tương đồng của các đặc trưng.

Phân loại so với phân cụm



Hình 9-1. Phân loại (trái) - đã có nhãn lớp, so với Phân cụm (phải) - không có nhãn


Ứng dụng của Phân cụm

- **Phân khúc khách hàng:** Phân cụm khách hàng dựa trên lịch sử mua hàng, hoạt động trên trang web để điều chỉnh chiến dịch tiếp thị (Hệ thống đề xuất).
- **Phân tích dữ liệu:** Phân cụm dữ liệu mới và phân tích từng cụm riêng biệt để hiểu sâu hơn.
- **Giảm chiều dữ liệu:** Thay vì dùng đặc trưng gốc, dùng "khoảng cách tới tâm các cụm" làm đặc trưng mới.
- **Phân đoạn hình ảnh (Image Segmentation):** Nhóm các điểm ảnh có màu sắc tương tự.

Thuật toán K-Means


- K-Means là một thuật toán phân cụm đơn giản, phổ biến và có khả năng phân cụm dữ liệu rất nhanh chóng, phân mảnh thành k cụm.
- Được đề xuất đầu tiên vào năm 1957 bởi Stuart Lloyd tại Bell Labs.
- Người dùng phải định nghĩa trước số lượng cụm (tham số k).

Tập dữ liệu chưa gán nhãn gồm 5 khối




Hình 9-2. Một tập dữ liệu không được gán nhãn bao gồm 5 khối trường hợp rõ rệt

Phép phân vùng Voronoi của K-Means




Hình 9-3. K-Means chia không gian bằng phép phân vùng Voronoi (đường biên quyết định)

Cách thuật toán K-Means hoạt động



Hình 9-4. Khởi tạo ngẫu nhiên tâm cụm → Gán điểm cho cụm → Cập nhật tâm cụm → Lặp lại

Vấn đề khởi tạo tâm cụm ngẫu nhiên




Hình 9-5. K-Means có thể kẹt ở điểm tối ưu cục bộ nếu khởi tạo tâm cụm ngẫu nhiên không may mắn

Quán tính (Inertia) là gì?


- Làm sao để biết một mô hình K-Means tốt hơn mô hình khác? (Do không có nhãn để tính độ chính xác).
- Dùng **Quán tính (Inertia)**: Tổng khoảng cách bình phương từ mỗi điểm dữ liệu đến tâm cụm gần nhất của nó.
- Mục tiêu của K-Means chính là tối thiểu hóa Quán tính.
- K-Means++ (mặc định trong Scikit-Learn) dùng thuật toán khởi tạo thông minh để tránh bị kẹt ở điểm tối ưu cục bộ.

Quán tính giảm theo các vòng lặp




Hình 9-6. Quán tính giảm nhanh qua các bước lặp K-Means

Hậu quả của việc chọn số lượng cụm (k) sai



Hình 9-7. Chọn $k=3$ (thiếu cụm) hoặc $k=8$ (chia cắt quá mức cụm thực)

Lựa chọn số cụm bằng phương pháp khuỷu tay (Elbow)




Hình 9-8. Vẽ Quán tính theo số lượng cụm k . Chọn điểm "khuỷu tay" ($k = 5$ hoặc $k = 4$)

Đánh giá chất lượng bằng điểm Silhouette


- Phương pháp "khuỷu tay" quá thô sơ. Đánh giá **điểm Silhouette (Silhouette Score)** chính xác hơn.
- Điểm Silhouette của mỗi điểm dữ liệu: $s = \frac{b-a}{\max(a,b)}$
 - a : Khoảng cách trung bình đến các điểm trong cùng cụm.
 - b : Khoảng cách trung bình đến các điểm trong cụm gần nhất tiếp theo.
- Giá trị dao động từ -1 đến +1.
- Gần +1: Điểm nằm sâu trong cụm.
- Gần 0: Điểm nằm ở rìa cụm.
- Gần -1: Điểm có thể bị gán sai cụm.

Biểu đồ điểm Silhouette theo k



Hình 9-9. Chọn số lượng cụm k tối ưu (đỉnh cao nhất, ví dụ $k = 4$ hoặc $k = 5$)

Phân tích biểu đồ dao (Silhouette plots)




Hình 9-10. Hình dao cho mỗi cụm. Dao càng rộng, cụm càng tốt. Ranh giới đỏ là điểm Silhouette trung bình.

Giới hạn của K-Means

- Cần chạy thuật toán nhiều lần để tránh tối ưu cục bộ.
- Phải chỉ định trước số cụm k .
- **Nhược điểm lớn nhất:** K-Means hoạt động rất kém khi các cụm có kích thước khác nhau nhiều, mật độ khác nhau, hoặc hình dạng không phải hình cầu (ví dụ: hình elip).
- Lý do: K-Means chỉ quan tâm đến **khoảng cách** tới tâm cụm.

K-Means gặp khó khăn với các cụm hình elip



Hình 9-11. K-Means phân cụm sai lầm khi cắt ngang khối hình elip tự nhiên

Ứng dụng: Phân đoạn hình ảnh (Image Segmentation)

- Phân đoạn hình ảnh: Chia hình ảnh thành nhiều phân đoạn.
- Ứng dụng phổ biến: **Phân đoạn màu sắc**. Nhóm các pixel có màu giống nhau vào cùng một cụm K-Means.
- Thay thế giá trị màu của mọi pixel bằng màu của tâm cụm K-Means, ta có thể giảm số lượng màu xuống k màu, tạo hiệu ứng ảnh như tranh vẽ (Posterization).

Phân đoạn màu sắc hình ảnh bộ rùa




Hình 9-12. Phân đoạn hình ảnh sử dụng K-means với các số lượng cụm màu khác nhau ($k = 10, 8, 6, 4, 2$)

Ứng dụng: Tiền xử lý để học bán giám sát

- Khi bạn có rất nhiều dữ liệu nhưng chỉ một phần rất nhỏ có nhãn (vd: chỉ gán nhãn được 50 tấm ảnh MNIST).
- Thay vì gán nhãn 50 ảnh ngẫu nhiên, ta dùng K-Means chia tập dữ liệu thành 50 cụm.
- Sau đó, tìm hình ảnh **gần tâm cụm nhất** (hình ảnh đại diện) và chỉ gán nhãn cho 50 hình ảnh này.
- Cuối cùng, có thể **truyền lan nhãn** (Label Propagation) sang tất cả các ảnh khác trong cùng cụm.

Lấy 50 hình ảnh đại diện bằng K-Means




Hình 9-13. 50 hình ảnh chữ số đại diện (một hình ảnh cho mỗi cụm). Việc gán nhãn chúng mang lại ý nghĩa cao hơn chọn ngẫu nhiên.

- **DBSCAN (Density-Based Spatial Clustering of Applications with Noise):** Dựa trên ý tưởng các cụm là các khu vực có **mật độ cao** phân tách bởi khu vực có **mật độ thấp**.
- Không giống K-Means, DBSCAN xác định được các cụm có **hình dạng tùy ý** và có thể phát hiện điểm ngoại lai (nhiều).

Cơ chế hoạt động của DBSCAN

- Nhìn vào bán kính khoảng cách ε (**eps**) xung quanh mỗi điểm dữ liệu. Khu vực này gọi là *ε -neighborhood*.
- Nếu khu vực này có chứa ít nhất **min_samples** điểm, điểm đó được coi là một **điểm lõi (core instance)**.
- Bất kỳ điểm nào nằm trong vùng lân cận của một điểm lõi cũng thuộc cùng cụm. (Các điểm lõi gần nhau kết hợp lại thành cụm lớn).
- Nếu điểm không phải là lõi và không nằm trong vùng của điểm lõi nào $\rightarrow$ Nó bị coi là Dị thường (Anomaly / Noise).

DBSCAN với 2 bán kính vùng lân cận khác nhau



Hình 9-14. DBSCAN bắt được hình dạng "mặt trăng" cực tốt. ϵ nhỏ (trái) tạo nhiều cụm đứt gãy. ϵ lớn hơn (phải) tạo ra 2 cụm hoàn hảo.

Ưu điểm và nhược điểm của DBSCAN

- **Ưu điểm:**

- Không cần khai báo số cụm k trước.
- Kháng nhiễu cực tốt (tự phát hiện và loại bỏ điểm ngoại lai).
- Tìm được cụm có hình dạng hình học phức tạp (chữ U, hình vành khăn, mặt trăng...).

- **Nhược điểm:**


- DBSCAN **không có** phương thức `predict()`, nó không thể tự gán cụm cho một trường hợp mới sinh ra.
- Kém hiệu quả nếu các cụm trong tập dữ liệu có **mật độ khác biệt nhau quá lớn**.

Dự đoán với DBSCAN (Kết hợp KNN)

Vì DBSCAN không có `predict()`, ta có thể dùng thuật toán phân loại KNN để huấn luyện trên các lỗi DBSCAN vừa tìm được.

```
1 from sklearn.neighbors import KNeighborsClassifier
2
3 knn = KNeighborsClassifier(n_neighbors=50)
4 # dbscan.components_ chưa các điểm lõi
5 # dbscan.labels_ chưa nhãn của các điểm do
6 knn.fit(dbscan.components_, dbscan.labels_[dbscan.core_sample_indices_])
7
8 import numpy as np
9 X_new = np.array([[-0.5, 0], [0, 0.5], [1, -0.1], [2, 1]])
10 print(knn.predict(X_new))
11 # Output: [1 0 1 0]
12
```

Đường biên quyết định của phân loại KNN trên tập DBSCAN



Hình 9-15. Dùng KNN tạo đường biên phân loại mới dựa trên các cụm đã tìm thấy bởi DBSCAN

Mô hình Hỗn hợp Gaussian (GMM) là gì?

- **Gaussian Mixture Model (GMM):** Là một mô hình xác suất giả định rằng tất cả các điểm dữ liệu được sinh ra từ một *hỗn hợp (mixture)* của một số hữu hạn các phân phối Gaussian (Phân phối chuẩn) với các tham số chưa biết.
- Nó đại diện cho các cụm có hình dạng **hình elip** (có thể dẹt, nghiêng, xoay) với nhiều kích thước khác nhau.
- GMM là một kỹ thuật tuyệt vời để khắc phục nhược điểm của K-Means với các cụm hình elip.

Thuật toán Cực đại hóa Kỳ vọng (EM)

- Để khớp GMM với tập dữ liệu, người ta dùng thuật toán **Expectation-Maximization (EM)**.
- Có nhiều điểm tương đồng với K-Means: khởi tạo ngẫu nhiên tâm và lặp lại cho đến khi hội tụ.
- EM không chỉ tìm tâm cụm (trung bình μ), mà còn tìm cả kích thước, hình dạng, và hướng của chúng (ma trận hiệp phương sai Σ), cũng như xác suất tương đối của chúng (trọng số ϕ).
- Khác K-Means (gán cứng), EM thực hiện **gán mềm (soft assignments)**: tính *xác suất* một điểm thuộc về mỗi cụm.


Khởi tạo GMM trong Scikit-Learn

Giống K-Means, bạn phải cung cấp số lượng cụm k (biến `n_components`):

```
1 from sklearn.mixture import GaussianMixture
2
3 gm = GaussianMixture(n_components=3, n_init=10, random_state=42)
4 gm.fit(X)
5
6 print(gm.weights_)
7 print(gm.means_)
8 print(gm.covariances_)
9
```

Thuật toán EM rất dễ kẹt ở điểm tối ưu cục bộ, nên ta chạy nhiều lần (`n_init=10`) và giữ lại mô hình tốt nhất.

Các giá trị trung bình và đường biên quyết định của GMM




Hình 9-16. GMM tìm ra các cụm hình elip bị kéo giãn và nghiêng cực kỳ chính xác

Hạn chế dạng ma trận hiệp phương sai

Nếu tập dữ liệu lớn với nhiều chiều, GMM cực kỳ khó huấn luyện vì ma trận hiệp phương sai bùng nổ. Có thể hạn chế kiểu hình dạng bằng `covariance_type`:

- "full" (mặc định): Hình elip tự do hướng theo bất kỳ góc nào.
- "tied": Tất cả các cụm phải dùng chung kích thước, góc xoay, hình dáng.
- "spherical": Cụm phải là hình cầu hoàn hảo (tương tự K-Means, nhưng bán kính có thể khác nhau).
- "diag": Cụm hình elip nhưng trục phải song song với các trục tọa độ.

GMM với các cụm liên kết (tied) và hình cầu (spherical)



Hình 9-17. Bên trái: tied (elip giống hệt nhau). Bên phải: spherical (hình cầu hoàn hảo)

Ước tính mật độ sinh ngẫu nhiên (Generative process)

- GMM là một **Mô hình sinh ngẫu nhiên (Generative model)**.
- Nó không chỉ phân cụm, mà nó mô hình hóa hoàn toàn hàm Mật độ xác suất (PDF) của hệ thống.
- Do đó, bạn có thể sinh ra (generate) các điểm dữ liệu **mới** hoàn toàn tự nhiên trông giống như phân phối gốc bằng hàm `gm.sample(50)`.

Phát hiện dị thường (Anomaly Detection) bằng GMM


- Bằng cách ước lượng hàm PDF tổng quát, bất kỳ điểm dữ liệu nào nằm trong khu vực có **mật độ cực thấp** (low density) đều bị tình nghi là Dị thường (Anomaly / Outlier).
- Dùng hàm `gm.score_samples(X)` để đánh giá mức độ mật độ (log-likelihood) tại điểm đó.
- Nếu mật độ thấp hơn một ngưỡng phân vị, ta đánh dấu điểm đó là dị thường.

Cách tính ngưỡng mật độ phát hiện dị thường

Ví dụ, ta quyết định 4% số điểm có mật độ thấp nhất là dị thường:


```
1 import numpy as np
2
3 # score_samples tra về mật độ log (log PDF)
4 densities = gm.score_samples(X)
5
6 # Tìm ngưỡng mật độ tương ứng với percentile thứ 4
7 density_threshold = np.percentile(densities, 4)
8
9 # Đánh dấu các điểm nằm dưới ngưỡng đó là Dị thường (anomalies)
10 anomalies = X[densities < density_threshold]
11
```

Phát hiện dị thường sử dụng GMM



Hình 9-18. Các ngôi sao màu đỏ là các điểm dị thường (Anomalies) nằm ở khu vực mật độ thấp

Hàm tham số của mô hình



Hình 9-19. Không gian hàm PDF của Mô hình hỗn hợp Gaussian từ một cụm đơn giản

Lựa chọn số lượng cụm trong GMM

- Với K-Means ta dùng Quán tính hay Silhouette Score.
- Tuy nhiên, các số liệu này không đáng tin cậy với GMM (chúng thiên vị các cụm hình cầu).
- Với GMM, ta dùng các **Tiêu chí Thông tin (Information Criteria)**: **BIC** (Bayesian Information Criterion) hoặc **AIC** (Akaike Information Criterion).

Công thức tính toán AIC và BIC

- Cả BIC và AIC phạt (penalty) mô hình nếu có quá nhiều tham số phải học (ngăn chặn quá khớp), và thưởng cho mô hình khớp tốt dữ liệu.
- Mô hình tốt nhất là mô hình có AIC/BIC **thấp nhất**.


$$BIC = \log(m)p - 2\log(\hat{L})$$

$$AIC = 2p - 2\log(\hat{L})$$

Trong đó:

- m là số mẫu dữ liệu, p là số lượng tham số trong mô hình GMM.
- $\hat{L}$ là hàm giá trị khả năng cực đại (Likelihood) của mô hình.

Biểu đồ AIC và BIC cho các k khác nhau



Hình 9-20. BIC và AIC đạt giá trị cực tiểu rõ ràng tại $k = 3$. Đây là số lượng cụm tối ưu nhất.

Mô hình Hỗn hợp Gaussian Bayes (BGM)

- Khá vất vả khi phải chạy thử thử công một loạt các k để đo BIC/AIC.
- Thay vì vậy, **Mô hình Hỗn hợp Gaussian Bayes (Bayesian Gaussian Mixture)** ra đời.
- Bạn khởi tạo nó với một số lượng cụm k **dư dả** (vd: lớn hơn thực tế bạn nghĩ).
- Thuật toán sẽ tự động gán trọng số (weights) của các cụm không cần thiết bằng 0 hoặc xấp xỉ 0.
- → BGM tự động khám phá ra số lượng cụm k thực tế!

Sử dụng BGM bằng Scikit-Learn


```
1 from sklearn.mixture import BayesianGaussianMixture
2
3 # Thiet lap k=10 du gia
4 bgm = BayesianGaussianMixture(n_components=10, n_init=10, random_state=42)
5 bgm.fit(X)
6
7 # Kiem tra trong so cac cum
8 np.round(bgm.weights_, 2)
9 # Output: array([0.4 , 0.21, 0.4 , 0. , 0. , 0. , 0. , 0. , 0. , 0. ])
10
```

- Chỉ có 3 cụm đầu tiên có trọng số lớn hơn 0. BGM đã triệt tiêu 7 cụm dư thừa và tự nhận ra bài toán chỉ có 3 cụm.

Tiên nghiệm Dirichlet (Dirichlet Prior)

- BGM đạt được sự tự động này là nhờ áp dụng **phân phối Dirichlet** vào quá trình cập nhật Bayes.
- Thông qua tham số `weight_concentration_prior`, bạn có thể cho thuật toán biết niềm tin (Prior) của bạn:
 - Nếu đặt bằng tỷ lệ nhỏ (mặc định $1/n_{\text{components}}$), thuật toán sẽ mạnh tay loại bỏ cụm (tìm ít cụm).
 - Nếu đặt số lớn, thuật toán sẽ cố gắng giữ lại tất cả các cụm (như GMM thường).

Lưu ý khi dùng BGM với dữ liệu hình dạng tùy ý



Hình 9-21. BGM phân cụm lỗi đối với tập dữ liệu Moons. GMM sinh ra các cực elip, nên một hình cong trăng khuyết sẽ bị nó chia làm nhiều cực elip nhỏ thay vì 1 cụm.

Các thuật toán phát hiện dị thường khác

Bên cạnh GMM, một số thuật toán chuyên biệt cho Phát hiện Dị thường (Anomaly Detection):

- **PCA (Phân tích thành phần chính):** Sai số tái tạo (Reconstruction Error) của ngoại lệ thường cao hơn nhiều điểm bình thường.
- **Fast-MCD (Minimum Covariance Determinant):** Rất giỏi trong việc dọn dẹp các điểm nhiễu ngoại lai trước khi chạy thuật toán học máy.
- **Isolation Forest:** Chuyên gia phát hiện ngoại lệ trong tập dữ liệu không gian nhiều chiều.
- **LOF (Local Outlier Factor):** Dựa trên sự khác biệt mật độ cục bộ.

Tóm tắt Chương 9: K-Means & Ứng dụng

- Học không giám sát khai phá dữ liệu chưa gán nhãn, hứa hẹn mở ra cuộc cách mạng AI.
- **K-Means** là ông vua tốc độ. Sử dụng quán tính, quy tắc khuỷu tay và điểm Silhouette để dò k . Thích ứng tốt nhất với cụm dạng cầu, kích thước đều.
- **Ứng dụng quan trọng:** Rất tuyệt vời để Phân đoạn hình ảnh và Tiền xử lý cho việc Gán nhãn Bán giám sát (Semi-supervised).

Tóm tắt Chương 9: DBSCAN & GMM

- **DBSCAN** không quan tâm số cụm, dựa vào mật độ, có thể theo vết các cụm hình dạng phức tạp và kháng nhiễu tốt.
- **GMM (Hỗn hợp Gaussian)** khắc phục nhược điểm về hình elip, rất mạnh trong **Phát hiện dị thường**.
- **BGM (Hỗn hợp Gaussian Bayes)** giúp tự động hóa quá trình dò tìm số lượng cụm k nhờ tiêu chuẩn học máy thống kê.

CẢM ƠN CÁC BẠN ĐÃ LẮNG NGHE!

Q & A