

Chương 14: Thị giác Máy tính Chuyên sâu sử dụng Mạng Nơ-ron Tích chập (CNN)

Giảng viên: [Tên Giảng Viên]
Đại Học Đông Á
Ngày 11 tháng 8 năm 2026

Gemini Notebook

Nội dung Chương 14



1. Vỏ Não Thị Giác và Nguồn Gốc CNN



2. Các thành phần của CNN (Tích chập & Gộp)



3. Kiến trúc CNN Tiêu Biểu (Lịch sử & Hiện đại)



4. Định Vị Đối Tượng (Object Localization)



5. Phát hiện Đối Tượng (Object Detection)



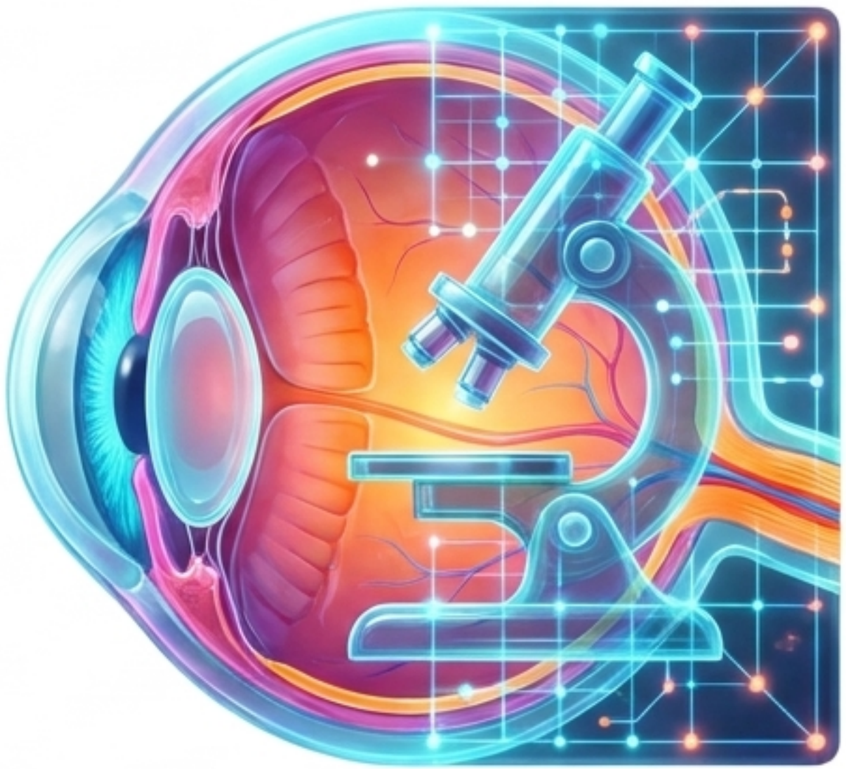
6. Phân đoạn Ngữ nghĩa (Semantic Segmentation)



Tổng Kết

Gemini Notebook

Khởi nguồn của Thị giác Máy tính



Năm 1959, David Hubel và Torsten Wiesel thực hiện một thí nghiệm kinh điển trên mèo, phát hiện ra cấu trúc của vỏ não thị giác (Visual Cortex).

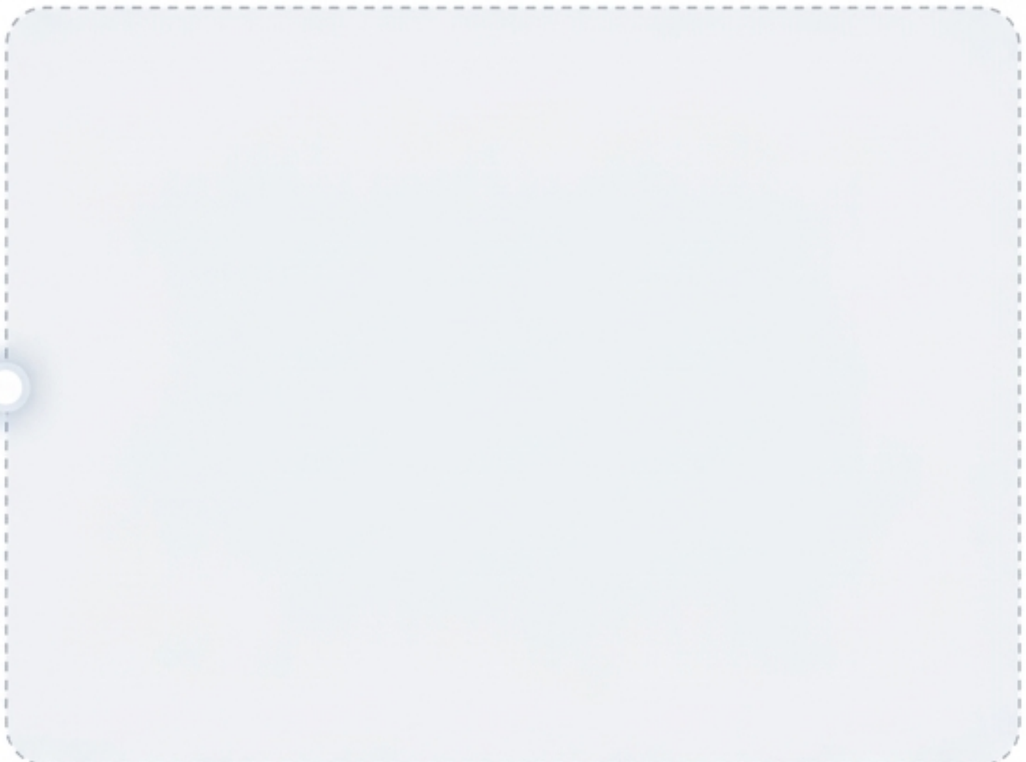
Họ phát hiện rằng các nơ-ron trong vỏ não thị giác có một trường tiếp nhận cục bộ (local receptive field). Một số nơ-ron chỉ phản ứng với các đường ngang, một số nơ-ron khác phản ứng với đường dọc hoặc đường chéo.

Các nơ-ron này được sắp xếp theo cấu trúc phân cấp: Nơ-ron cấp thấp nhận diện các đường nét đơn giản, nơ-ron cấp cao kết hợp chúng để nhận diện hình dạng phức tạp hơn.

Gemini Notebook

Trường tiếp nhận cục bộ (Local Receptive Fields)

Kiến trúc này đã truyền cảm hứng cho Mạng Nơ-ron Tích chập (CNN). Hình 14-1 cho thấy thay vì kết nối với mọi pixel (như MLP), mỗi nơ-ron lớp tích chập thứ nhất chỉ kết nối với một vùng hình chữ nhật nhỏ của hình ảnh đầu vào. Nơ-ron ở lớp thứ hai lại kết nối với một vùng nhỏ của lớp thứ nhất, cứ như vậy tạo ra mạng phân cấp.

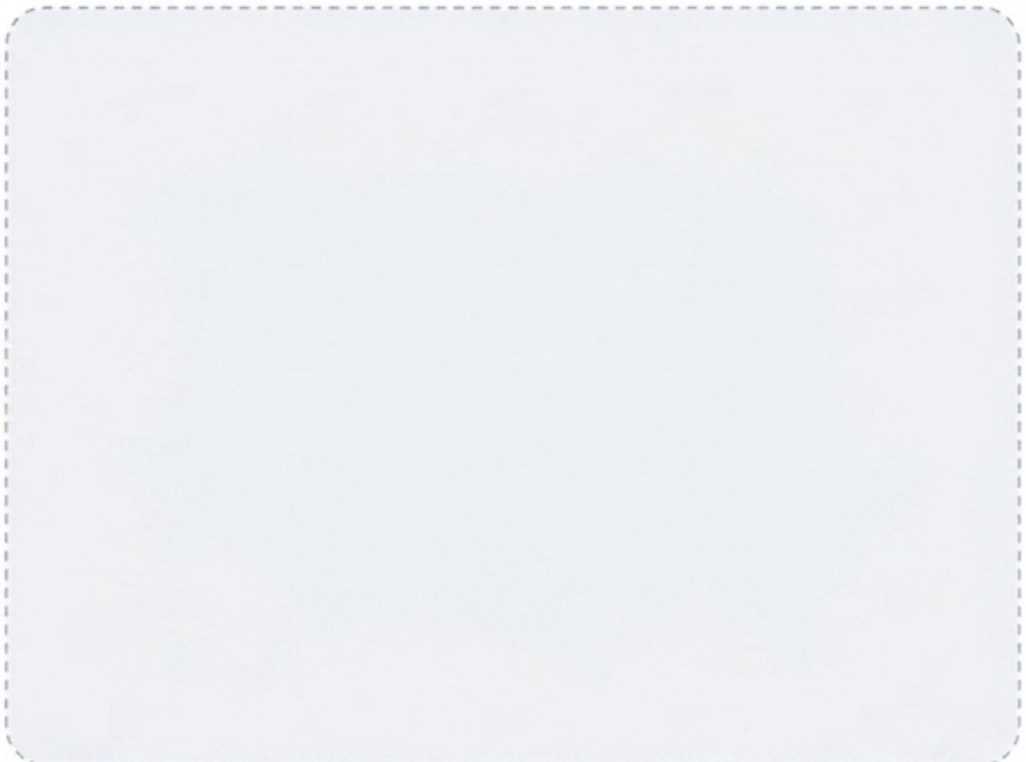


Hình 14-1: Kiến trúc phân cấp của CNN

Gemini Notebook

Lớp Tích chập (Convolutional Layer)

Lớp Tích chập là khối xây dựng cốt lõi của CNN. Một nơ-ron ở vị trí (i, j) của một lớp nhất định được kết nối với đầu ra của các nơ-ron ở lớp trước trong vùng từ hàng i đến $i + f_h - 1$, cột j đến $j + f_w - 1$.
Hình 14-2 minh họa sự kết nối giữa các lớp.



Hình 14-2: Kết nối cục bộ giữa 2 lớp CNN

Gemini Notebook

Đệm (Padding)



Nếu tiếp tục áp dụng tích chập, ảnh sẽ nhỏ dần đi sau mỗi lớp. Để giữ nguyên kích thước, ta dùng kĩ thuật **Zero Padding** (đệm thêm các số 0 xung quanh ảnh).

Hình 14-3 (trái): Hình đầu vào 5x5. Hình 14-3 (phải): Hình 5x5 được thêm đệm p = 1 thành 7x7. Tích chập bằng kernel 3× 3 sẽ trả về đúng ma trận đầu ra 5× 5.



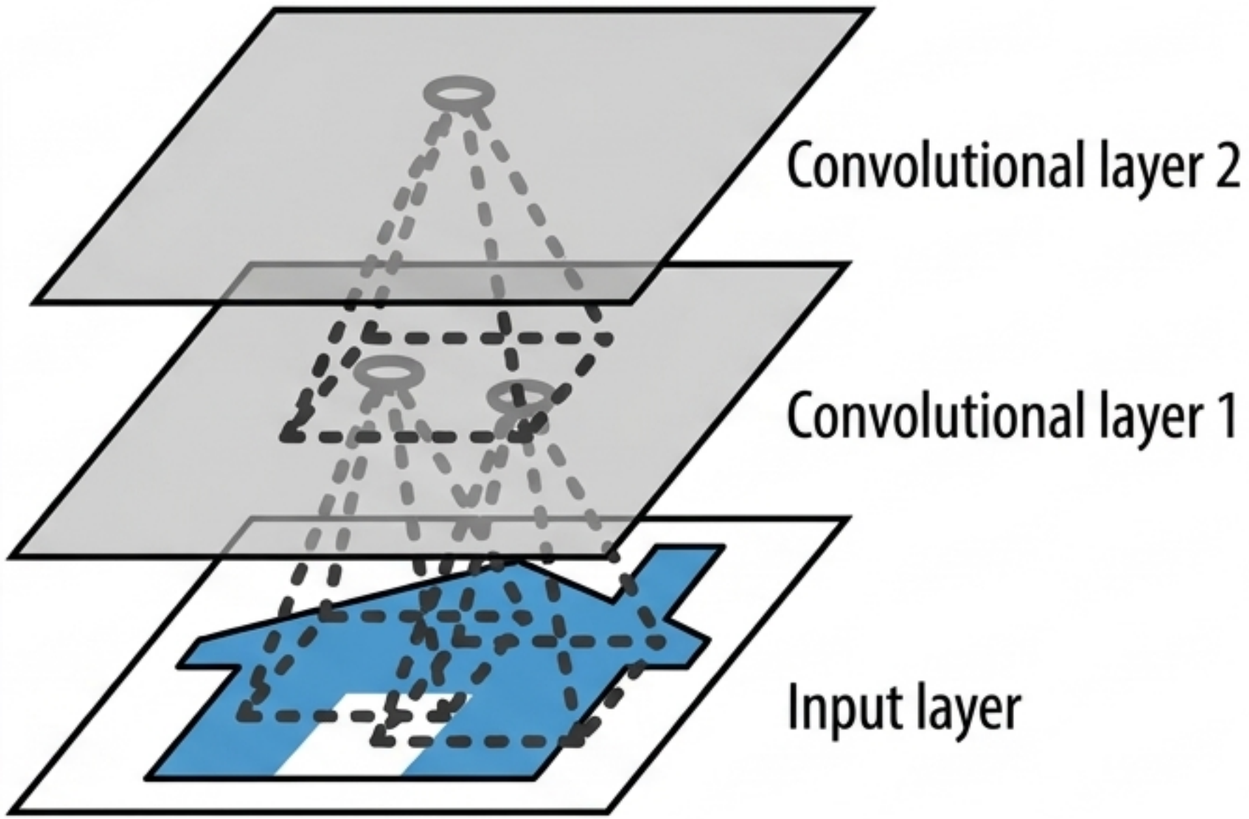
Hình 14-3: Kết nối với Padding

Gemini Notebook

Bước nhảy (Strides)



Nếu muốn giảm kích thước ảnh đầu ra một cách nhanh chóng, chúng ta sử dụng Stride (Bước nhảy) > 1.
Hình 14-4 cho thấy trường tiếp nhận di chuyển 2 ô mỗi lần (s = 2).
Kết quả: Một hình ảnh gốc 5x5 áp dụng kernel 3x3 với padding=1 và stride=2 sẽ cho ra bản đồ đặc trưng có kích thước chỉ còn 3× 3.



Hình 14-4: Lớp tích chập với bước nhảy Stride=2

Gemini Notebook

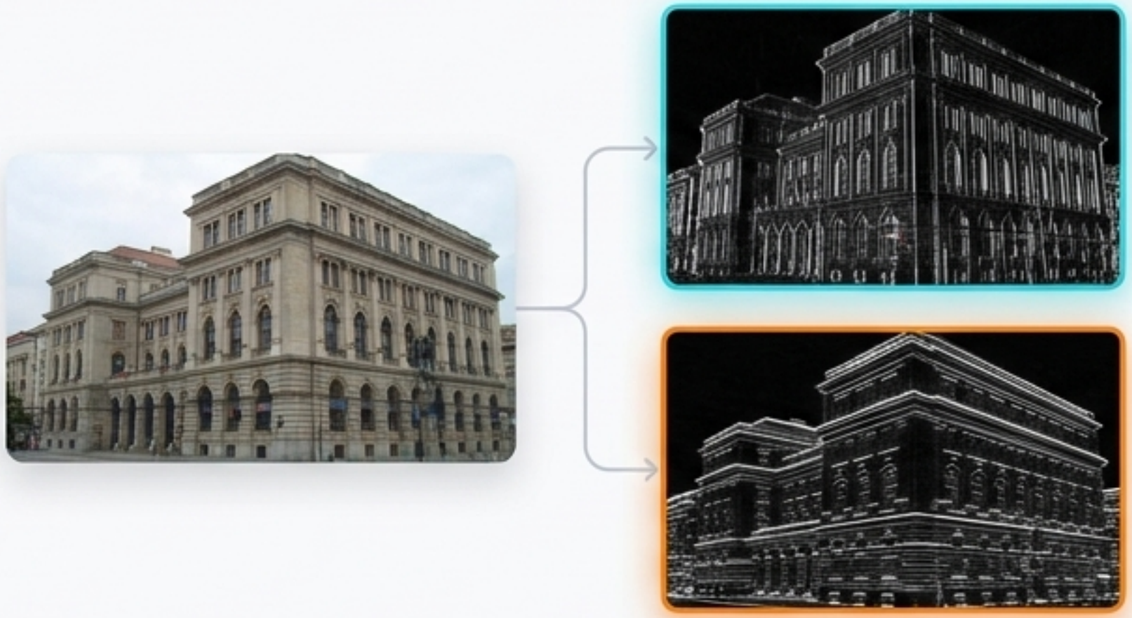
Bộ lọc (Filters / Kernels)



Bộ lọc dọc (Vertical filter): Nhấn mạnh các đường nét thẳng đứng.



Bộ lọc ngang (Horizontal filter): Nhấn mạnh các đường nét nằm ngang.



Hình 14-5: Áp dụng các bộ lọc khác nhau lên ảnh

Trọng số của một nơ-ron có thể biểu diễn dưới dạng ma trận kích thước nhỏ, gọi là Filter. Hình 14-5 minh họa hai bộ lọc cổ điển:

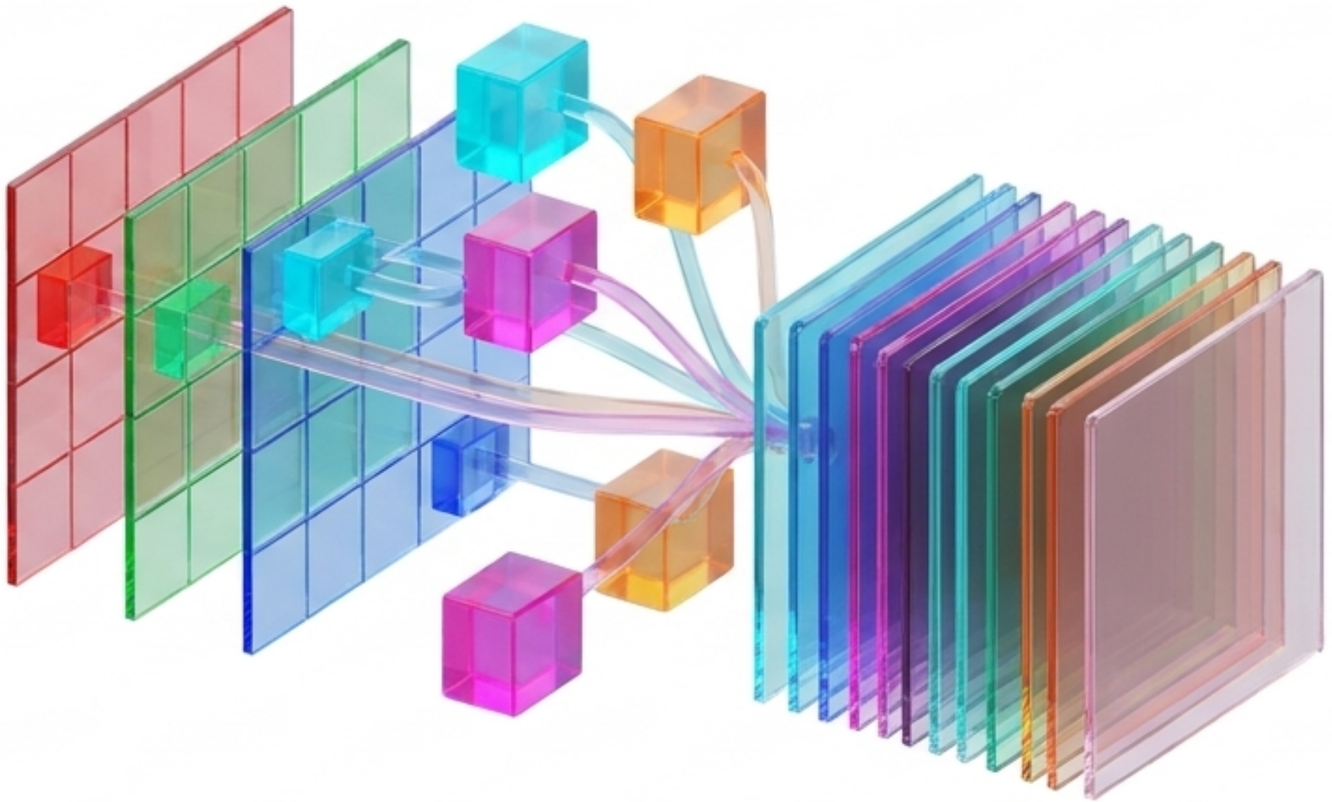
Trong CNN, ta **không tự định nghĩa filter**, mạng nơ-ron sẽ tự học các giá trị bộ lọc tốt nhất cho tác vụ.

Gemini Notebook

Nhiều Bản đồ Đặc trưng (Feature Maps)

Trong thực tế, một lớp tích chập sẽ có nhiều bộ lọc (ví dụ: 64 bộ lọc). Mỗi bộ lọc sinh ra một Bản đồ đặc trưng (Feature map) 2D.

Hình 14-6 mô phỏng quá trình đầu vào 3 kênh (RGB) quét qua nhiều bộ lọc để sinh ra một khối dữ liệu 3D đầu ra (Số kênh bằng số bộ lọc).



Hình 14-6: Đầu vào đa kênh và Đầu ra đa kênh

Gemini Notebook

Padding: ”Valid” vs ”Same”

Keras hỗ trợ 2 tham số phổ biến:



padding=“same”

Có padding. Đảm bảo kích thước ảnh ra bằng ảnh vào nếu stride=1 (bên trái Hình 14-7).



padding=“valid”

KHÔNG dùng padding. Bộ lọc có thể vượt ra ngoài biên, làm ảnh bị thu nhỏ lại nhanh chóng (bên phải Hình 14-7).

PLACEHOLDER FOR IMAGE

Hình 14-7: Cài đặt Padding SAME và VALID

Gemini Notebook

Code: Xây dựng Lớp Conv2D trong Keras

Để thêm một lớp Tích chập (Convolution) vào mạng:

```
from tensorflow import keras

model = keras.models.Sequential([
    keras.layers.Conv2D(filters=64, kernel_size=7, activation="relu",
                        padding="same", input_shape=[28, 28, 1])
])
```



filters=64: Mạng sẽ tự học 64 bộ lọc khác nhau.



kernel_size=7: Kích thước bộ lọc là 7× 7. Lớp này đòi hỏi rất nhiều phép tính bộ nhớ, nhưng số lượng tham số (weights) lại rất ít (do có cơ chế chia sẻ trọng số).

Gemini Notebook

Công thức Tính Kích Thước Đầu Ra (Output Dimension)

Kích thước của Bản đồ đặc trưng đầu ra (Feature Map) sau một lớp tích chập được tính bằng công thức:

O: Kích thước không gian đầu ra (Output dimension).

I: Kích thước không gian đầu vào (Input dimension).

$$O = \left\lfloor \frac{I - F + 2P}{S} \right\rfloor + 1$$

F: Kích thước trường tiếp nhận của nơ-ron (Filter size/Receptive field).

P: Lượng đệm (Zero Padding) được thêm vào mỗi phía.

S: Bước nhảy (Stride).

Nếu padding="same", kích thước đầu ra $O = \lceil I/S \rceil$.

Gemini Notebook

Lớp Gộp (Pooling Layer)

Sau vài lớp Tích chập, số kênh tăng rất nhiều (vd: 256, 512). Cần phải giảm không gian (chiều rộng và chiều cao) để tiết kiệm tài nguyên.

Lớp Gộp (Pooling Layer) ra đời để làm giảm khối lượng dữ liệu (Downsampling).

Hình ảnh 14-8 (nếu có) thường mô tả ý tưởng chung của Downsampling.



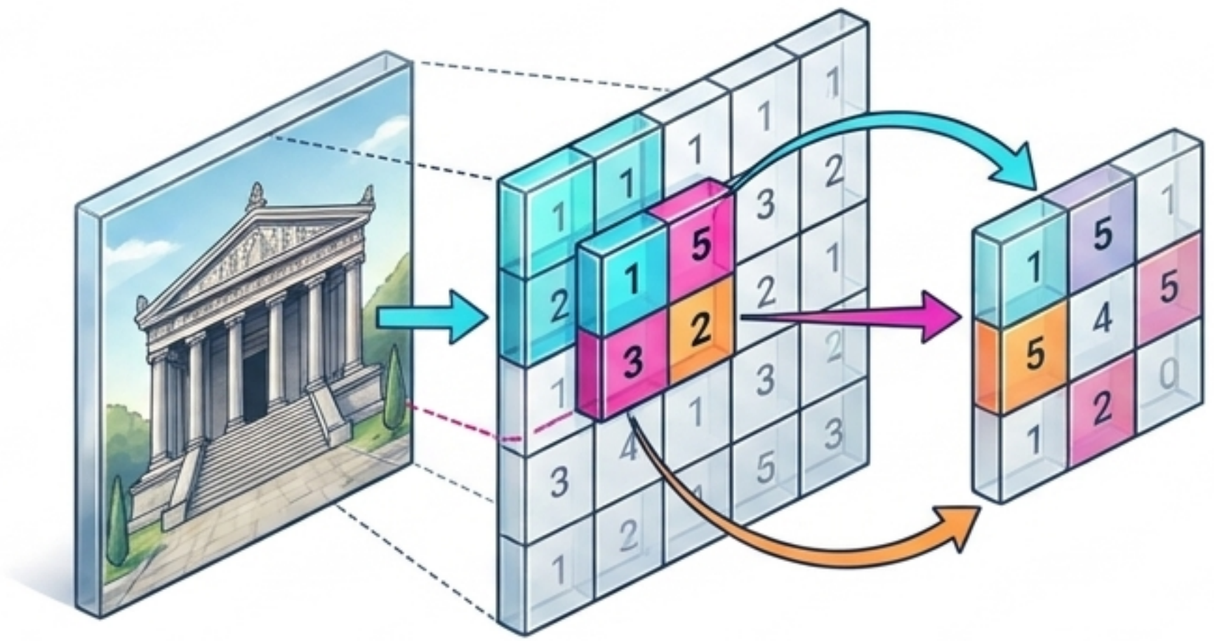
Hình 14-8: Ý tưởng của Pooling

Gemini Notebook

Max Pooling (Gộp Cực Đại)

Phổ biến nhất là Max Pooling. Hình 14-9 cho thấy kernel 2×2, stride=2. Quét qua vùng 2×2, nó chọn ra phần tử có giá trị lớn nhất (ví dụ: max của **[1, 5, 3, 2]** là **5**).

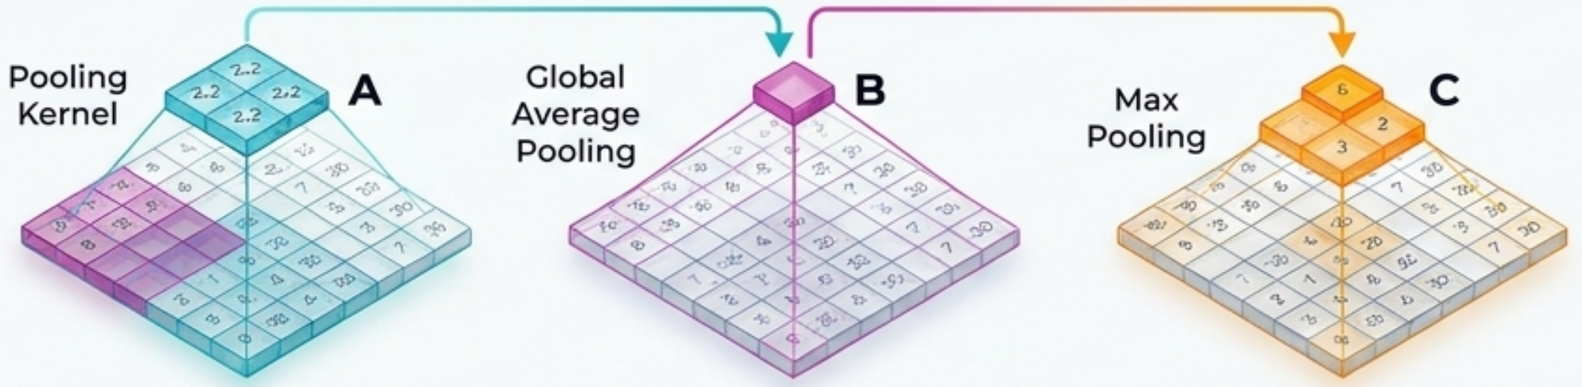
Lợi ích: Chọn ra các đặc trưng nổi bật nhất, và mang lại tính chất bất biến đối với dịch chuyển nhỏ (Translation Invariance).



Hình 14-9: Lớp gộp cực đại (Max Pooling Layer)

Gemini Notebook

Lớp Gộp Trung Bình & Gộp Toàn Cục



Hình 14-10: Các phương pháp Pooling khác

Average Pooling (Gộp Trung bình):
Thay vì lấy giá trị max, nó tính trung bình tất cả các giá trị trong trường tiếp nhận. Nó từng phổ biến ở LeNet-5, nhưng nay ít dùng hơn Max Pooling vì Max Pooling bảo toàn đường nét mạnh mẽ hơn.

Global Average Pooling (GAP):
Lấy trung bình toàn bộ một Bản đồ đặc trưng (kích thước n x n thu gọn thành 1 con số duy nhất). Rất hay dùng ở lớp cuối cùng trước Softmax, giúp giảm lượng tham số khổng lồ (Hình 14-10).

Gemini Notebook