

Câu 1: Bạn sẽ định nghĩa học máy như thế nào?

Là lĩnh vực nghiên cứu nhằm giúp máy tính có khả năng học mà không cần lập trình một cách tường minh (Arthur Samuel, 1959). Một chương trình máy tính được cho là học từ kinh nghiệm E với tác vụ T và phép đo chất lượng P nào đó, nếu chất lượng của tác vụ T, được đo bởi P, cải thiện theo kinh nghiệm E” (Tom Mitchell).

Câu 2: Bạn có thể kể tên bốn loại ứng dụng mà nó tỏa sáng không?

Giọng nói (Alexa, Google Assistant, Siri).

NLP (Sentiment Analysis).

Xử lý ảnh (nhận diện số, chữ viết; tô màu ảnh trắng đen).

Các hệ thống học máy nói chung (có hình minh họa các kiểu hệ thống).

Câu 3: Tập huấn luyện có nhãn là gì?

Là tập dữ liệu huấn luyện đã được gán nhãn (ví dụ: tập huấn luyện đã được gán nhãn cho tác vụ phân loại thư rác). Mỗi mẫu có cặp (input, outcome/nhãn).

Câu 4: Hai tác vụ có giám sát phổ biến nhất là gì?

Phân loại (classification) – ví dụ Logistic Regression, SVM, Cây quyết định...

Hồi quy (regression) – ví dụ Hồi quy Tuyến tính.

Câu 5: Bạn có thể kể tên bốn tác vụ không giám sát phổ biến không?

Phân cụm (Clustering): K-Means, Hierarchical Cluster Analysis (HCA).

Phát hiện bất thường và tính mới (Anomaly detection and novelty detection): One-class SVM, Isolation Forest.

Trực quan hóa và giảm chiều (Visualization & Dimensionality reduction): PCA, Kernel PCA.

Học luật kết hợp (Association rule): Apriori, Eclat.

Câu 6: Bạn sẽ sử dụng loại thuật toán nào để cho phép một robot đi trên nhiều địa hình không xác định khác nhau?

Học củng cố (Reinforcement Learning) – hệ thống tự xác định hành vi dựa trên hoàn cảnh để đạt lợi ích cao nhất (maximizing the performance).

Câu 7: Bạn sẽ sử dụng loại thuật toán nào để phân khúc khách hàng của mình thành nhiều nhóm?

Phân cụm (Clustering) – thuộc học không giám sát (K-Means hoặc HCA).

Câu 8: Bạn sẽ coi vấn đề phát hiện thư rác là một vấn đề học có giám sát hay một vấn đề học không giám sát?

Học có giám sát (Supervised Learning) – Ví dụ “tập huấn luyện đã được gán nhãn cho tác vụ phân loại thư rác”.

Câu 9: Hệ thống học trực tuyến là gì?

Theo kiến thức chuẩn (vẫn phù hợp với tổng quan học máy): hệ thống học dần dần bằng cách nhận dữ liệu theo từng mẫu hoặc mini-batch nhỏ và cập nhật mô hình liên tục.

Câu 10: Học ngoài lõi (out-of-core learning) là gì?

Đây là kỹ thuật học khi dữ liệu quá lớn không vừa bộ nhớ: tải từng phần, huấn luyện, lặp lại cho đến hết dữ liệu (thường dùng online learning).

Câu 11: Loại thuật toán nào dựa vào một thước đo tương tự để đưa ra dự đoán?

k-Điểm Gần nhất (k-Nearest Neighbors)

Câu 12: Sự khác biệt giữa tham số mô hình và siêu tham số mô hình là gì?

Tham số mô hình: được học từ dữ liệu trong quá trình huấn luyện.

Siêu tham số: được thiết lập trước khi huấn luyện (không học từ dữ liệu).

Câu 13: Các thuật toán dựa trên mô hình tìm kiếm điều gì? Chiến lược phổ biến nhất mà chúng sử dụng để thành công là gì? Chúng đưa ra dự đoán như thế nào?

Tìm kiếm giá trị tối ưu của các tham số mô hình. Chiến lược phổ biến: tối thiểu hóa hàm chi phí (cost function). Dự đoán bằng cách dùng mô hình với tham số đã tối ưu trên dữ liệu mới.

Câu 14: Bạn có thể kể tên bốn trong số những thách thức chính trong học máy không?

Không đủ dữ liệu huấn luyện.

Dữ liệu không đại diện.

Dữ liệu chất lượng kém.

Đặc trưng không liên quan (hoặc overfitting / underfitting).

Câu 15: Nếu mô hình của bạn hoạt động tốt trên dữ liệu huấn luyện nhưng tổng quát hóa kém cho các trường hợp mới, điều gì đang xảy ra? Bạn có thể kể tên ba giải pháp khả thi không?

Đang xảy ra overfitting (quá khớp).

Ba giải pháp phổ biến: Thu thập thêm dữ liệu, đơn giản hóa mô hình, thêm regularization / giảm nhiễu.

Câu 16: Tập kiểm thử là gì, và tại sao bạn muốn sử dụng nó?

Là phần dữ liệu giữ lại, không dùng để huấn luyện, nhằm ước lượng khả năng tổng quát hóa của mô hình trên dữ liệu mới.

Câu 17: Mục đích của tập xác thực là gì?

Dùng để chọn mô hình và tinh chỉnh siêu tham số, tránh làm “ô nhiễm” tập kiểm thử.

Câu 18: Tập train-dev là gì, khi nào bạn cần nó, và bạn sử dụng nó như thế nào?

Là phần dữ liệu lấy từ tập huấn luyện nhưng giữ riêng. Cần khi phân bố dữ liệu huấn luyện khác với validation/test (data mismatch). Dùng để phân biệt lỗi do overfitting hay do sự khác biệt phân bố.

Câu 19: Điều gì có thể sai nếu bạn điều chỉnh siêu tham số bằng cách sử dụng tập kiểm thử?

Mô hình sẽ overfitting trên tập kiểm thử -> ước lượng lỗi tổng quát hóa trở nên quá lạc quan, không phản ánh đúng hiệu suất thực tế.