DỰ ÁN HỌC MÁY TỪ ĐẦU ĐẾN CUỐI

Chương 2 - End-to-End Machine Learning Project

TS. Trần Thành Thắng

Đại học Đông Á

August 5, 2026

Gemini Notebook

Nội dung Chương trình

1. Giới thiệu Dự án & Khởi tạo Dữ liệu
2. Khám phá & Chuẩn bị Dữ liệu
3. Chọn, Huấn luyện, Tinh chỉnh & Triển khai

Gemini Notebook

Mục tiêu bài học

- Hiểu rõ toàn bộ quy trình phát triển một dự án học máy thực tế từ khi bắt đầu đến khi triển khai.
- Thực hành các kỹ thuật chuẩn bị, làm sạch, và biến đổi dữ liệu.
- Trực quan hóa dữ liệu để tìm ra các mẫu (patterns) và tương quan.
- Xây dựng pipeline dữ liệu chuẩn.
- Đánh giá, tinh chỉnh và lựa chọn mô hình học máy tốt nhất.

Gemini Notebook

1. Giới thiệu Dự án & Khởi tạo Dữ liệu

Gemini Notebook

Làm việc với dữ liệu thực

Học máy tốt nhất là thực hành trên dữ liệu thực. Trong chương này, chúng ta sử dụng tập dữ liệu **Nhà ở California (California Housing Prices).**

Mục tiêu: Dự đoán giá nhà trung bình tại một khu vực bất kỳ ở California dựa trên các đặc trưng như dân số, thu nhập trung bình, v.v.

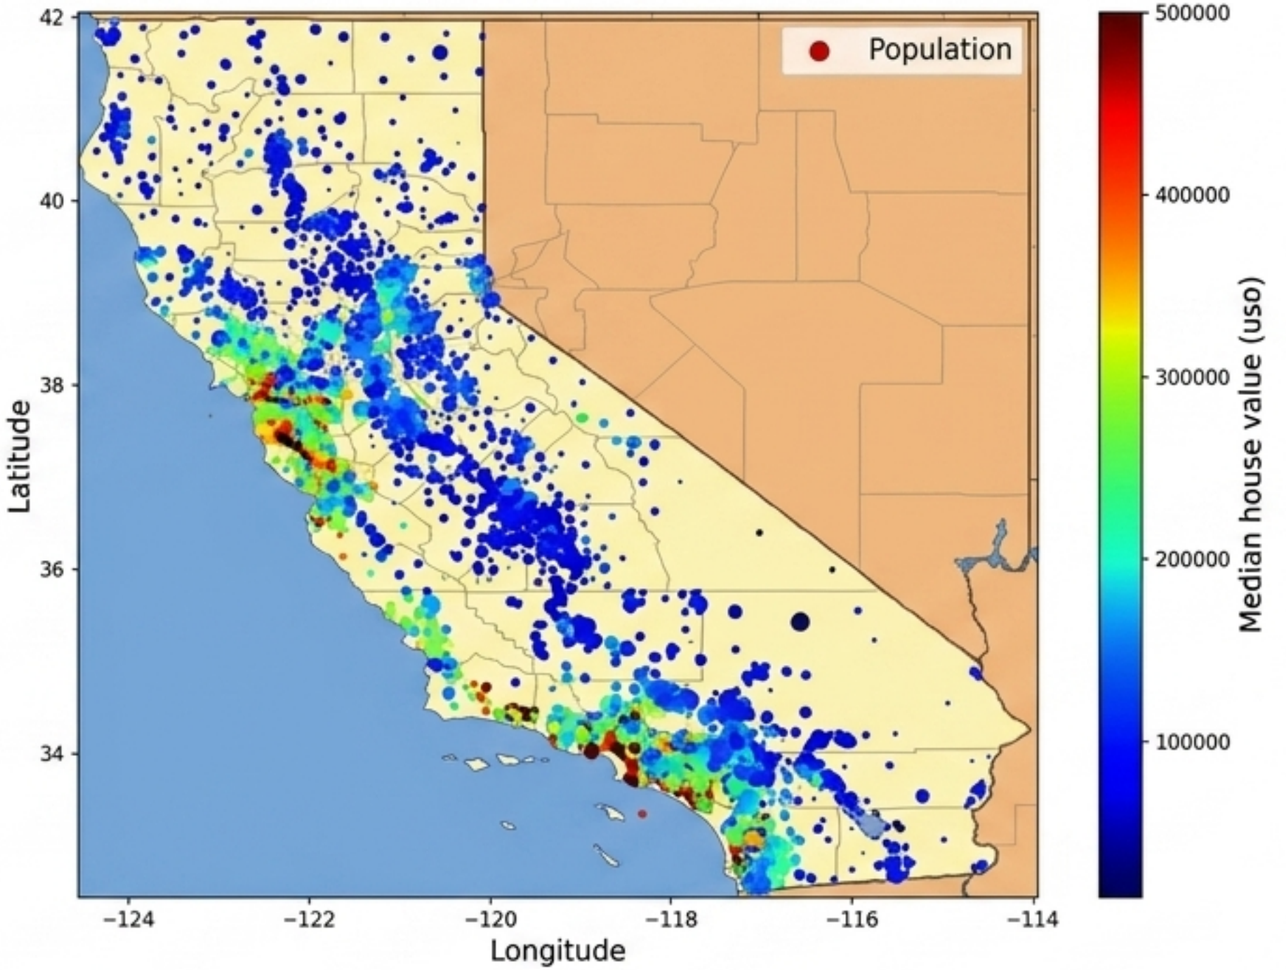

Hình 2-1. Giá nhà California

Gemini Notebook

Nhìn vào bức tranh lớn: Xác định vấn đề

Trước khi phân tích, cần hiểu mục đích kinh doanh là gì? Mô hình này sẽ được sử dụng như thế nào? Việc hiểu mục đích sẽ giúp quyết định: Thuật toán nào? Thước đo hiệu suất nào? Mức độ đầu tư công sức?

Bài toán của chúng ta: Hệ thống nhận dữ liệu khu vực và dự đoán giá nhà. Đầu ra này sẽ được đưa vào một hệ thống máy học khác để quyết định có nên đầu tư vào khu vực đó hay không.

Gemini Notebook

Pipeline hệ thống học máy

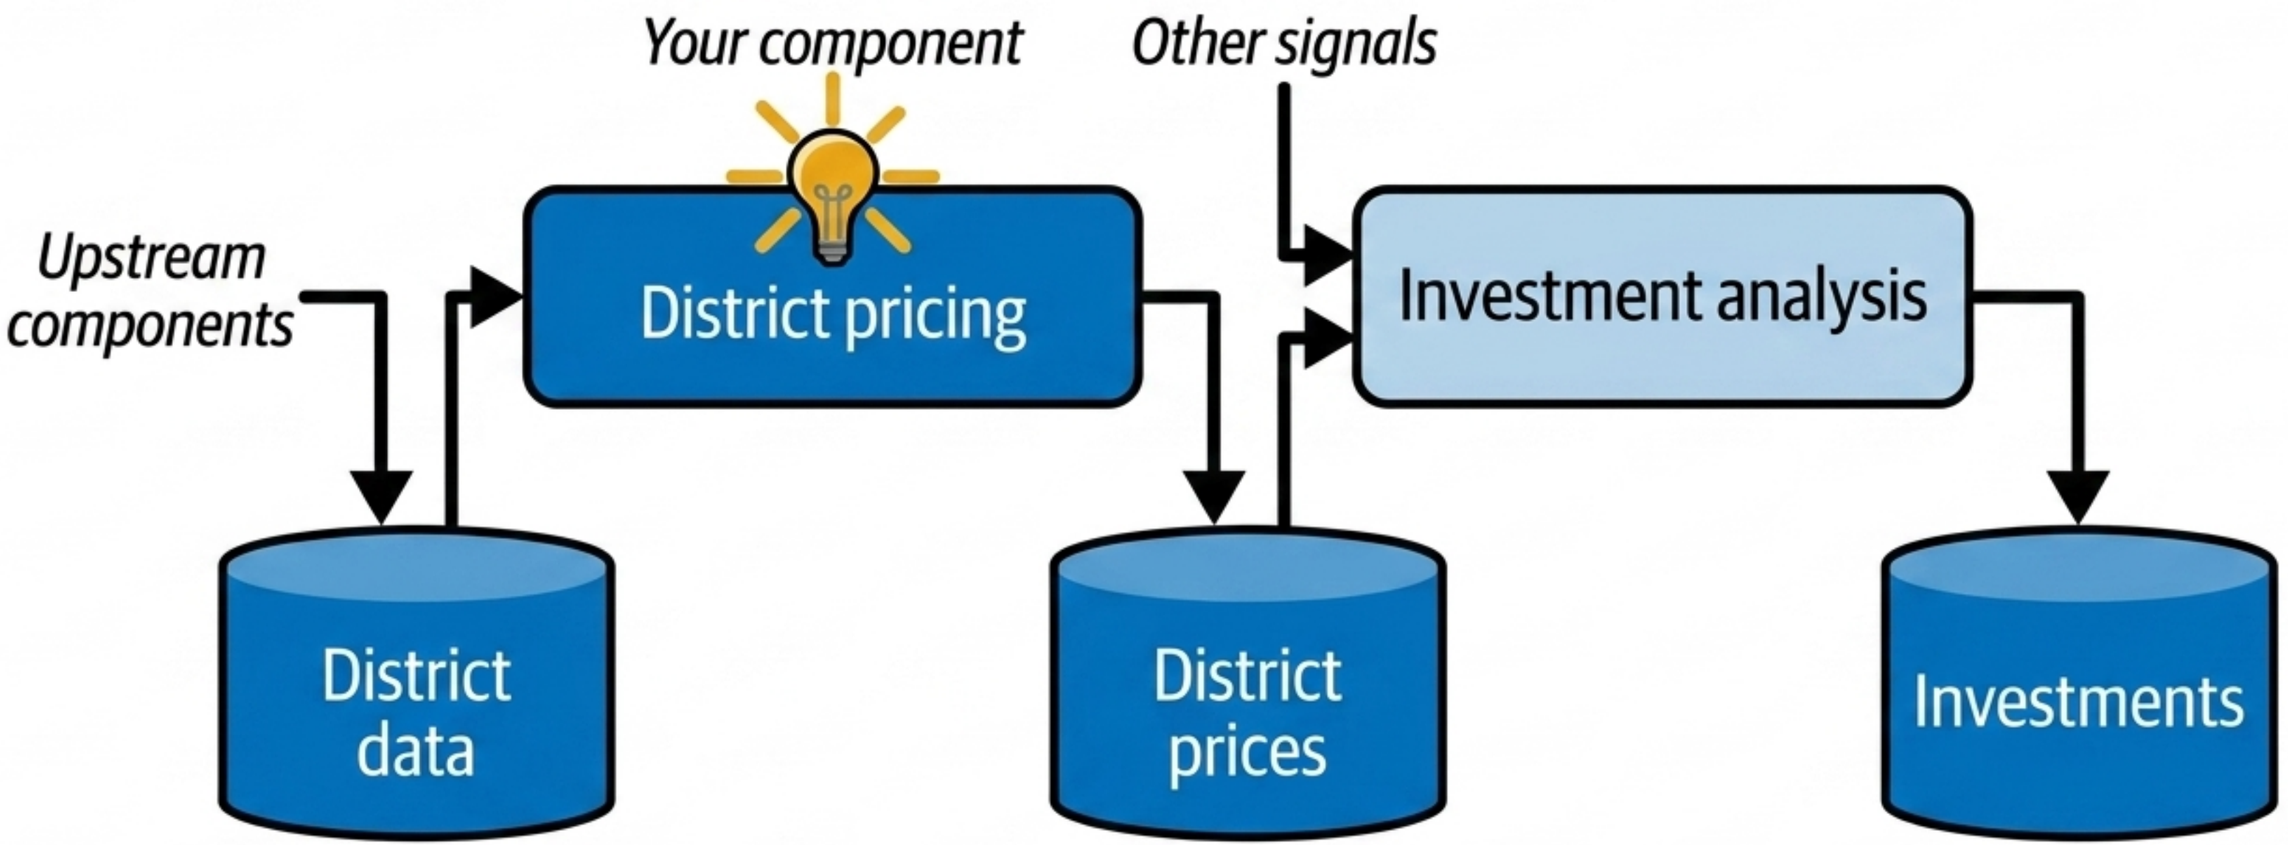

Hình 2-2. Một pipeline máy học cho đầu tư bất động sản

Gemini Notebook

Chọn một Thước đo Hiệu suất

Vì đây là bài toán hồi quy (Regression), chúng ta sử dụng **Căn bậc hai Sai số Toàn phương Trung bình (RMSE - Root Mean Square Error).**

RMSE cho biết sai số dự đoán điển hình. Càng nhỏ càng tốt.

Công thức 2-1. Sai số toàn phương trung bình (RMSE):

$$\mathrm{RMSE} = \sqrt{\frac{1}{m}\sum_{i=1}^{m}(h(x^{(i)}) - y^{(i)})^2}$$

Nếu dữ liệu có nhiều ngoại lai (outliers), ta có thể sử dụng **Sai số Tuyệt đối Trung bình (MAE - Mean Absolute Error).**

Công thức 2-2. Sai số tuyệt đối trung bình (MAE):

$$\mathrm{MAE} = \frac{1}{m}\sum_{i=1}^{m}|h(x^{(i)}) - y^{(i)}|$$

Gemini Notebook

Kiểm tra các Giả định

Luôn liệt kê và xác minh các giả định đã đặt ra.

Ví dụ: Hệ thống hạ nguồn có thực sự cần dự đoán giá trị cụ thể, hay chỉ cần các hạng mục (rẻ, trung bình, đắt)?

↓

Nếu họ chỉ cần hạng mục, thì chúng ta nên cấu trúc nó thành bài toán Phân loại (Classification) thay vì Hồi quy.

Gemini Notebook

Lấy Dữ liệu & Môi trường làm việc

Gemini Notebook

Môi trường Google Colab

Chúng ta sẽ sử dụng **Google Colab** - một môi trường Jupyter Notebook miễn phí trên đám mây.

Không cần cài đặt phần mềm phức tạp trên máy tính cá nhân.

Cung cấp GPU/TPU miễn phí để huấn luyện mô hình.

Gemini Notebook

Minh họa: Môi trường Google Colab

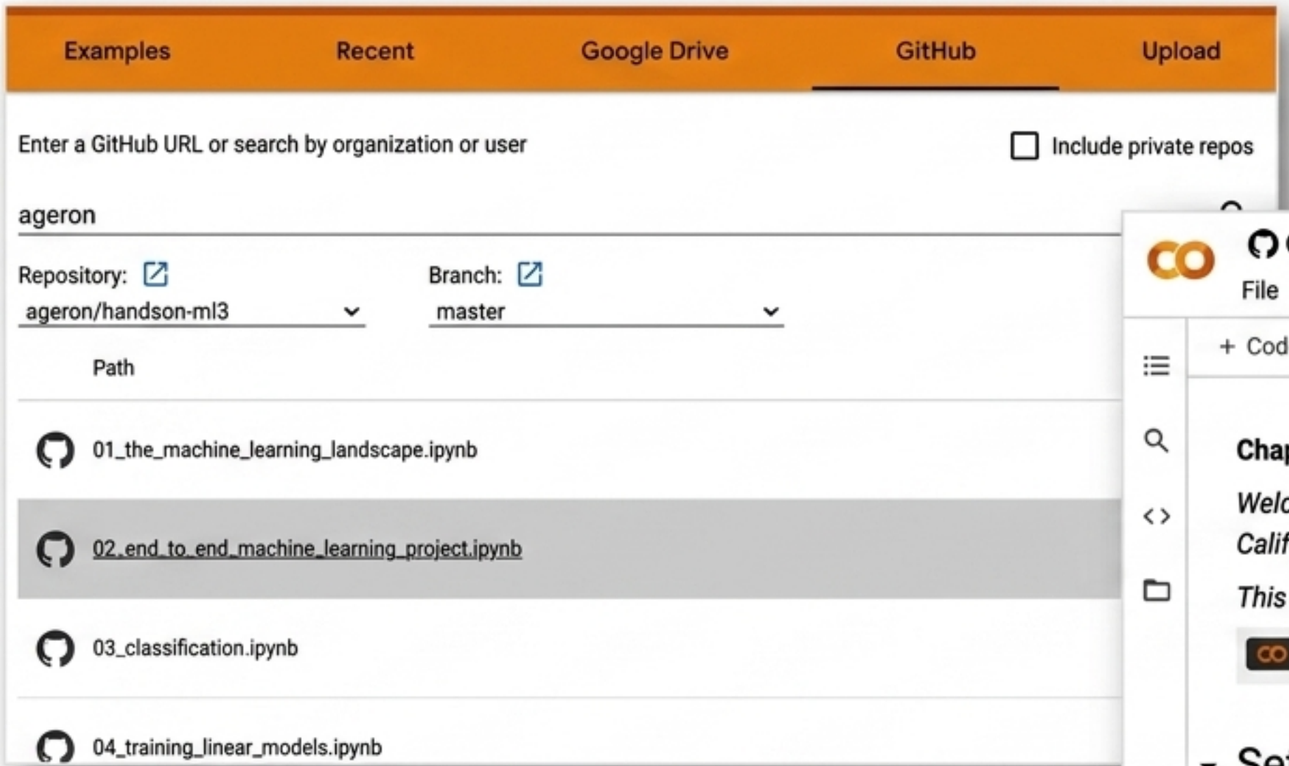

Hình 2-3. Giao diện Google Colab

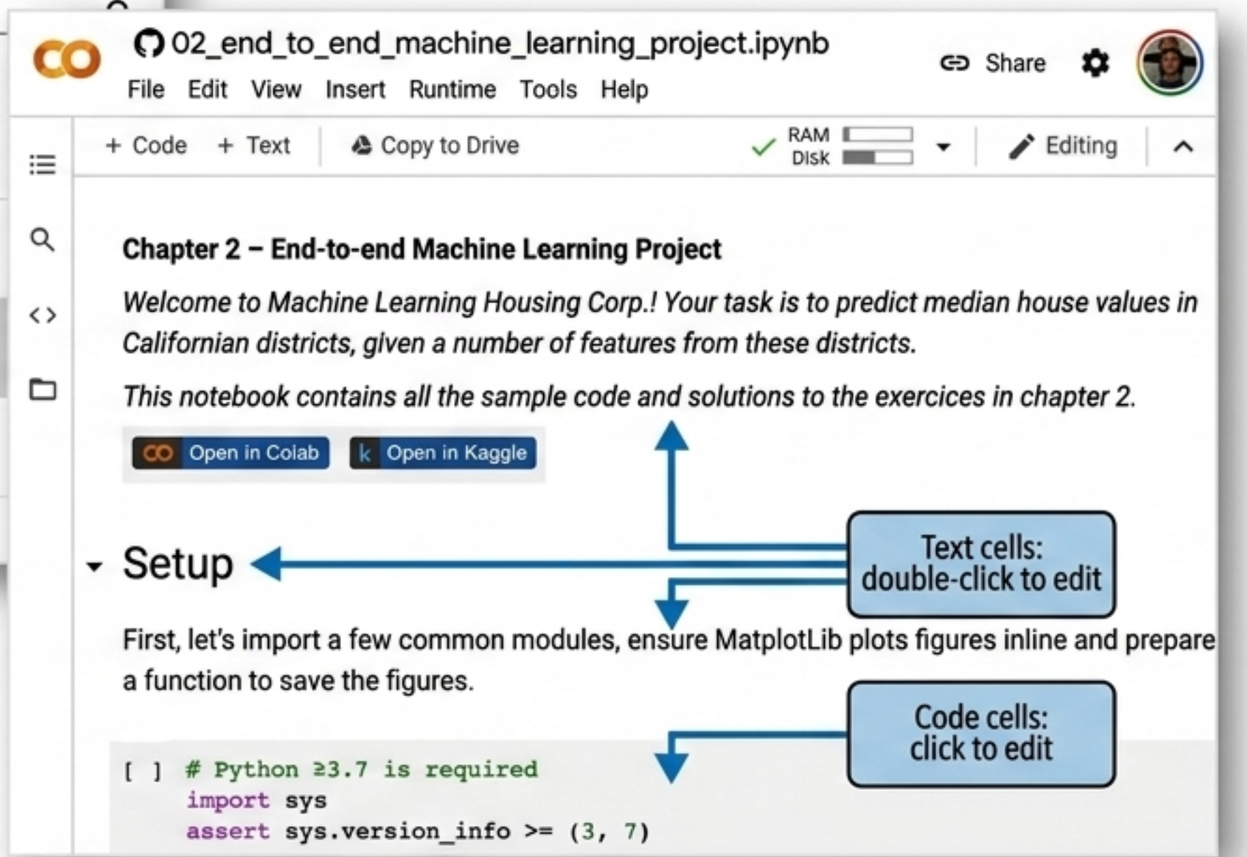

Hình 2-4. Chạy code trên Colab

Gemini Notebook

Tải và Xem dữ liệu

	longitude	latitude	housing_median_age	median_income	ocean_proximity	median_house_value
0	-122.23	37.88	41.0	8.3252	NEAR BAY	452600.0
1	-122.22	37.86	21.0	8.3014	NEAR BAY	358500.0
2	-122.24	37.85	52.0	7.2574	NEAR BAY	352100.0
3	-122.25	37.85	52.0	5.6431	NEAR BAY	341300.0
4	-122.25	37.85	52.0	3.8462	NEAR BAY	342200.0

Hình 2-6. Năm hàng đầu tiên trong tập dữ liệu

Gemini Notebook

Xem tóm tắt dữ liệu

```
housing.describe()
```

	longitude	latitude	housing_median_age	total_rooms	total_bedrooms	population	households	median_income	median_house_value
count	20640.000000	20640.000000	20640.000000	20640.000000	20433.000000	20640.000000	20640.000000	10.000000	20640.000000
mean	-119.569704	35.631861	28.639486	2635.763081	537.870553	537.870553	296.273322	2.539946	206855.816909
std	2.003532	2.135952	12.585558	2181.615522	421.385070	421.385070	292.376477	0.331326	115395.615874
min	-124.350000	32.540000	1.000000	2.000000	1.000000	1.000000	0.000000	0.000000	14999.000000
25%	-118.490000	34.260000	18.000000	1447.750000	296.000000	435.000000	100.000000	4.500000	179700.000000
75%	-118.010000	37.710000	37.000000	3148.000000	647.000000	647.000000	100.000000	7.500000	264725.000000
max	-114.310000	41.950000	52.000000	39320.000000	645.000000	6445.000000	3400.000000	52.000000	500001.000000

Hình 2-7. *Tóm tắt của từng thuộc tính số*

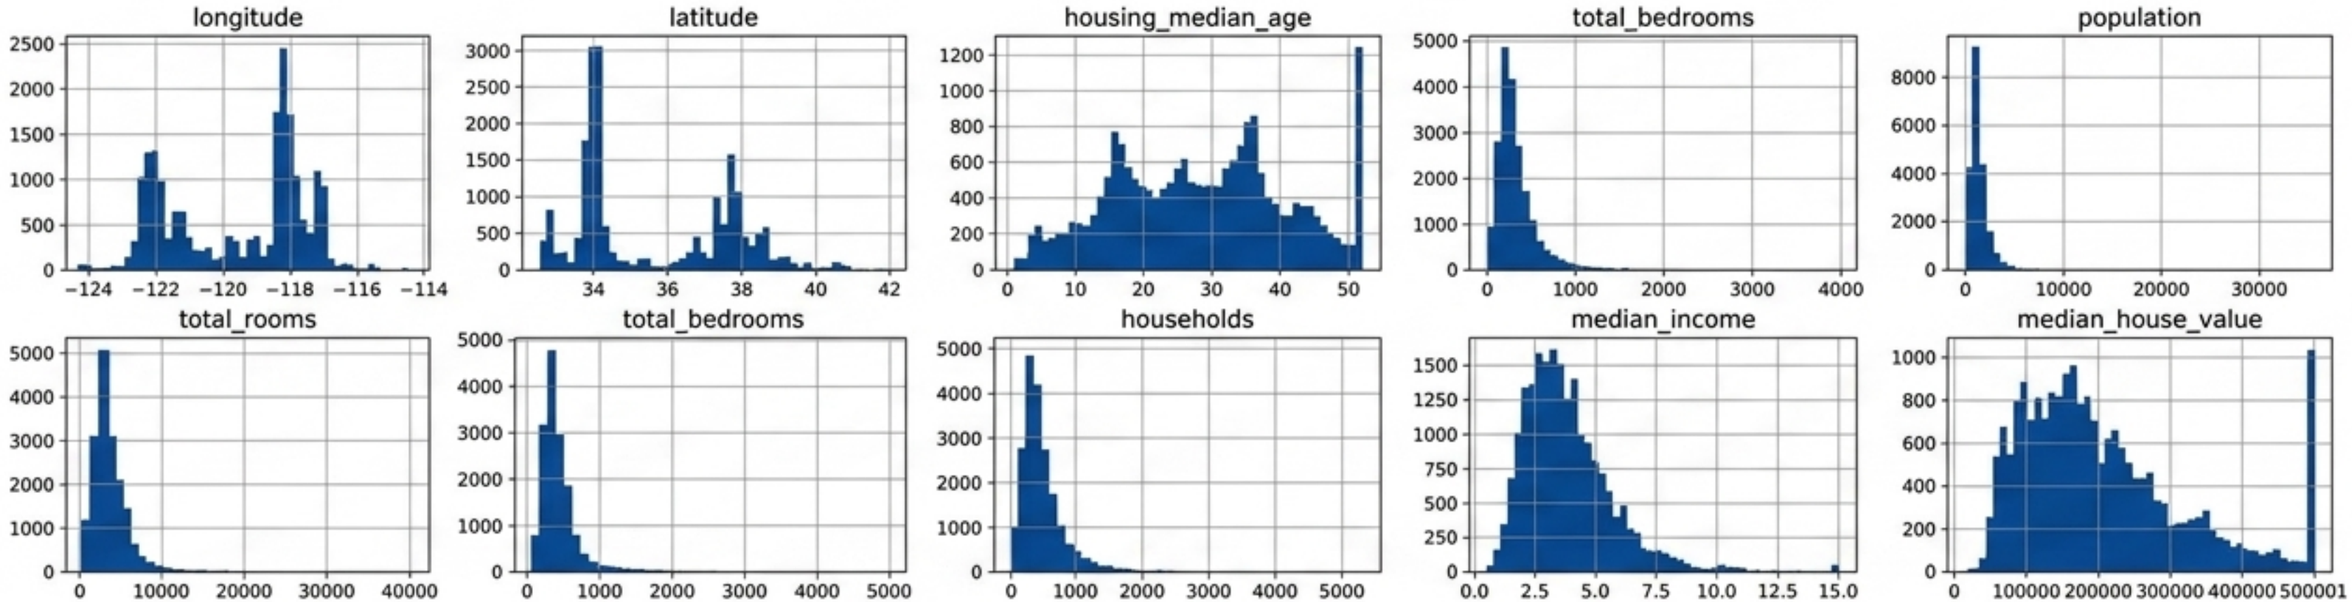

Hình 2-8. *Biểu đồ tần suất (Histogram)*

Gemini Notebook

Tạo tập kiểm thử (Test set): Tại sao cần thiết?

Chúng ta phải tách một phần dữ liệu (khoảng 20%) ngay lập tức và **không bao giờ nhìn vào nó.**

Lý do: Tránh ***thiên kiến rình mò dữ liệu (Data Snooping Bias).***

Nếu chọn thuật toán dựa trên toàn bộ dữ liệu, mô hình có thể Overfit trên tập đó nhưng dự đoán kém trong thực tế.

Gemini Notebook

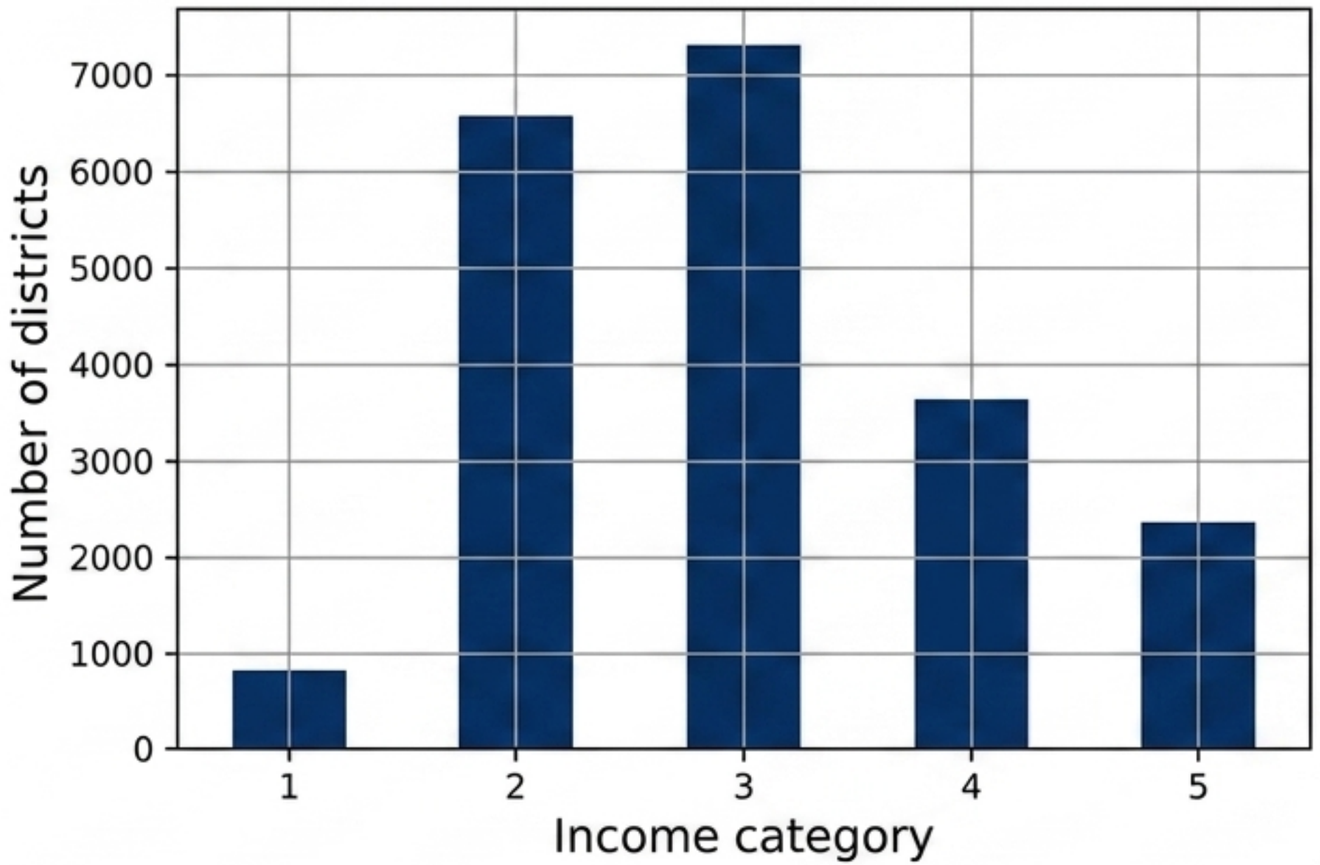

Hình 2-9. Các loại thu nhập

Phân phối Thu nhập

Thu nhập trung bình là một thuộc tính rất quan trọng để dự đoán giá nhà.

Nếu lấy mẫu ngẫu nhiên thuần túy, ta có thể vô tình chọn phải một tập kiểm thử thiếu tính đại diện.

Gemini Notebook

Lấy mẫu phân tầng (Stratified Sampling) so với Ngẫu nhiên

Income Category	Overall %	Stratified %	Random %	Strat. Error %	Rand. Error %
1	3.98	4.00	4.24	0.36	6.45
2	31.88	31.88	30.74	-0.02	-3.59
3	35.06	35.05	34.52	-0.01	-1.53
4	17.63	17.64	18.41	0.03	4.42
5	11.44	11.43	12.09	-0.08	5.63

Hình 2-10. Tỷ lệ phân loại thu nhập trong tổng thể so với mẫu ngẫu nhiên và phân tầng

Gemini Notebook

2. Khám phá & Chuẩn bị Dữ liệu

Gemini Notebook

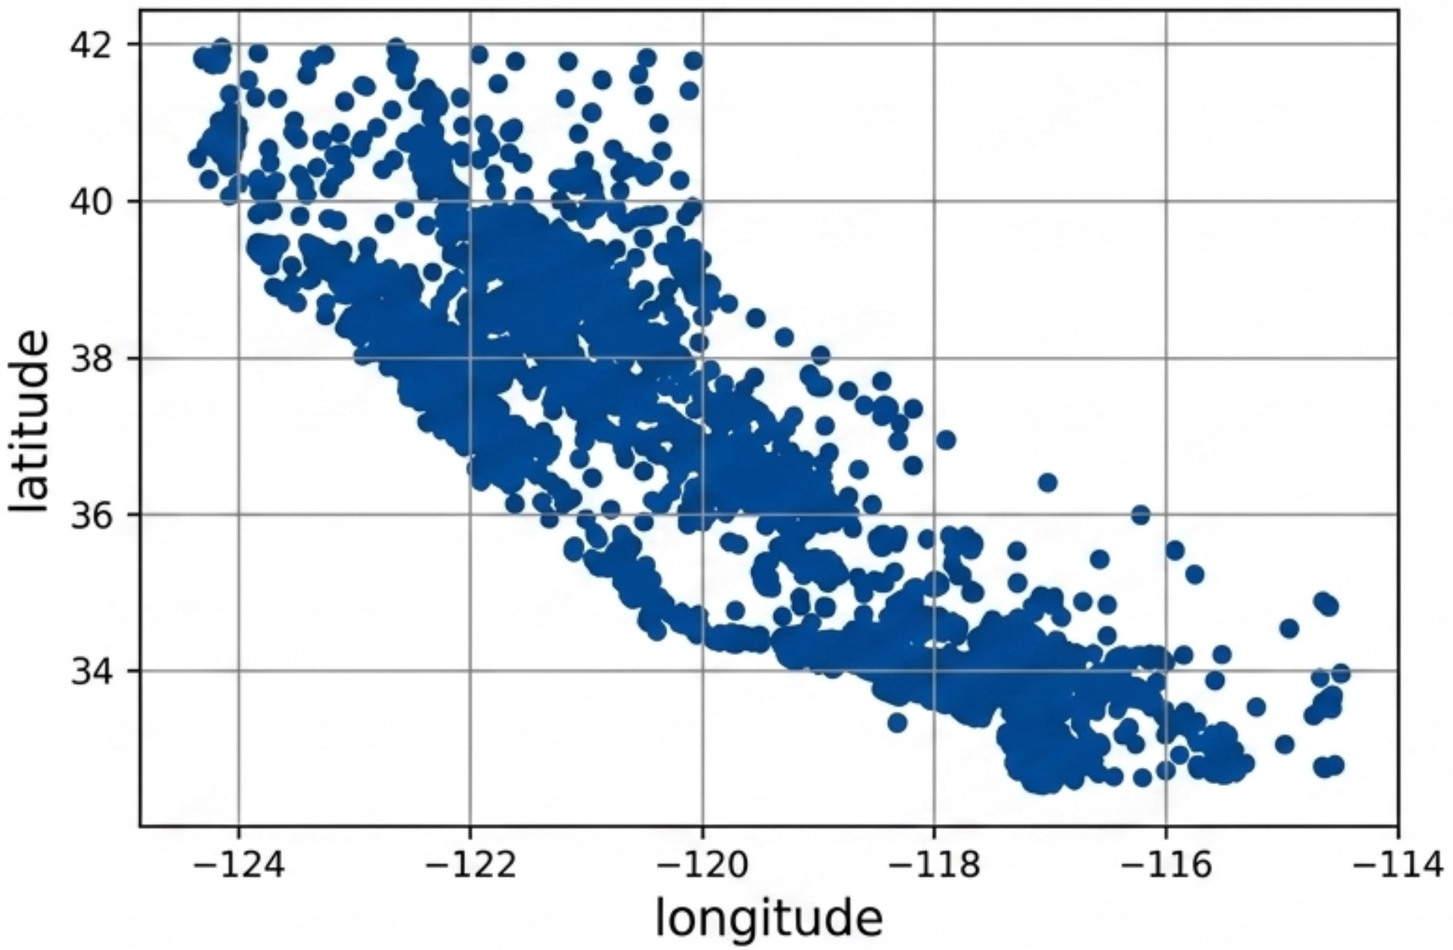

Hình 2-11. Trực quan hóa dữ liệu địa lý

Trực quan hóa dữ liệu địa lý

Dữ liệu có thuộc tính kinh độ (longitude) và vĩ độ (latitude). Việc vẽ biểu đồ **phân tán** (scatter plot) sẽ giúp ta nhìn thấy mô hình phân bố của các khu dân cư.

Gemini Notebook

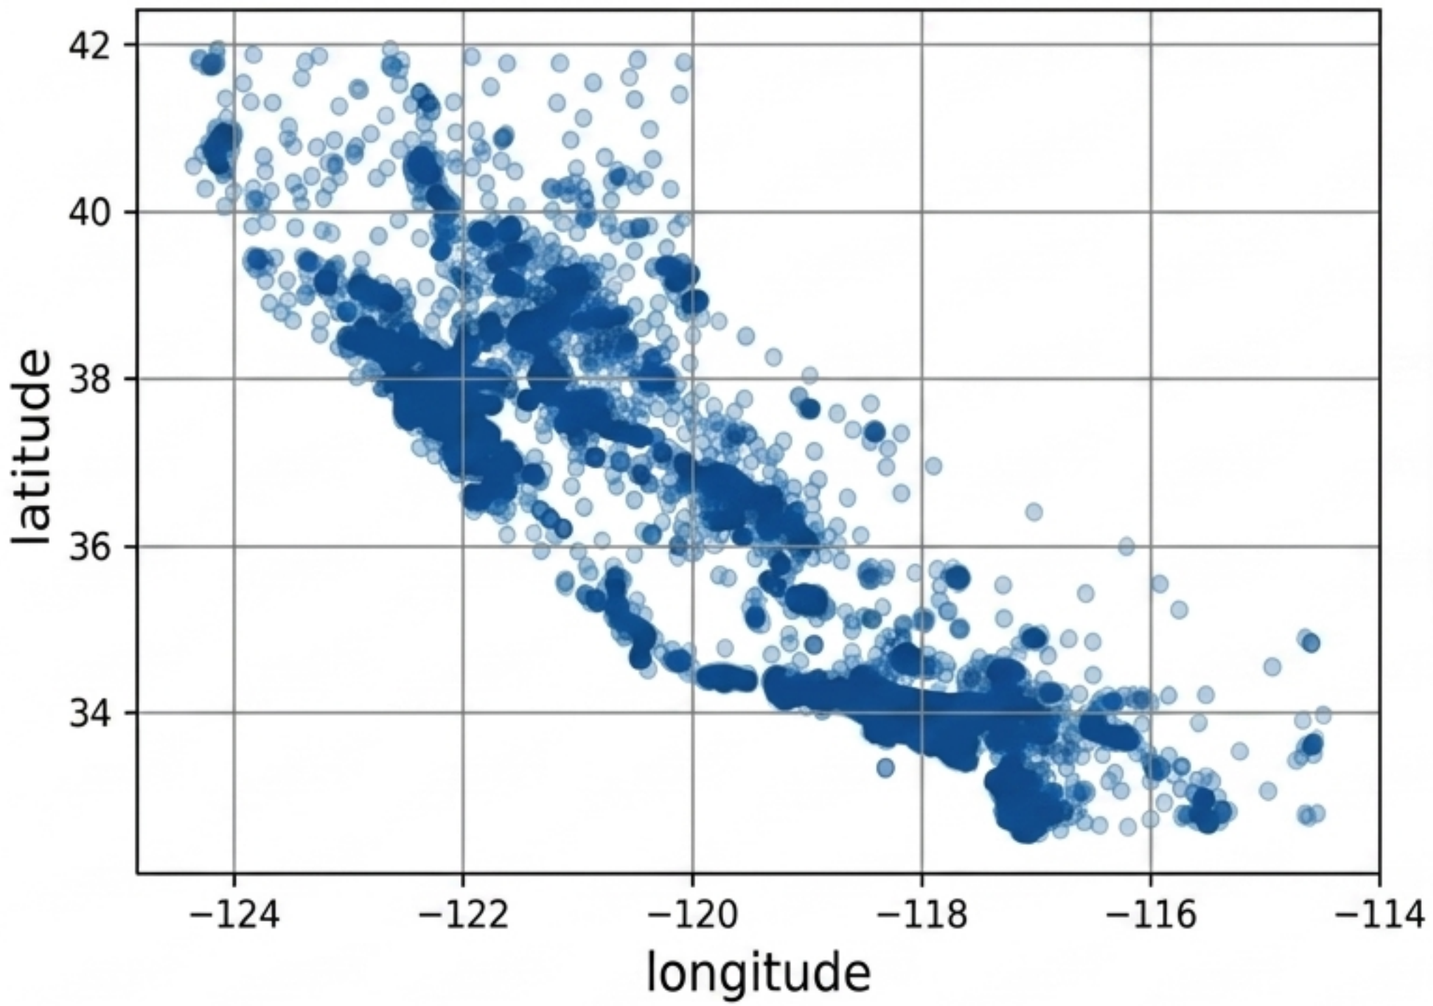

Hình 2-12. Trực quan hóa tốt hơn để thấy khu vực mật độ cao

Phân tích mật độ địa lý

Bằng cách chỉnh thông số alpha, ta có thể nhìn thấy rõ ràng các khu vực tập trung đông dân cư.

Nổi bật lên khu vực **Vùng Vịnh (Bay Area)**, **Los Angeles** và **San Diego.**

Gemini Notebook

Giá nhà theo dân số & Vị trí

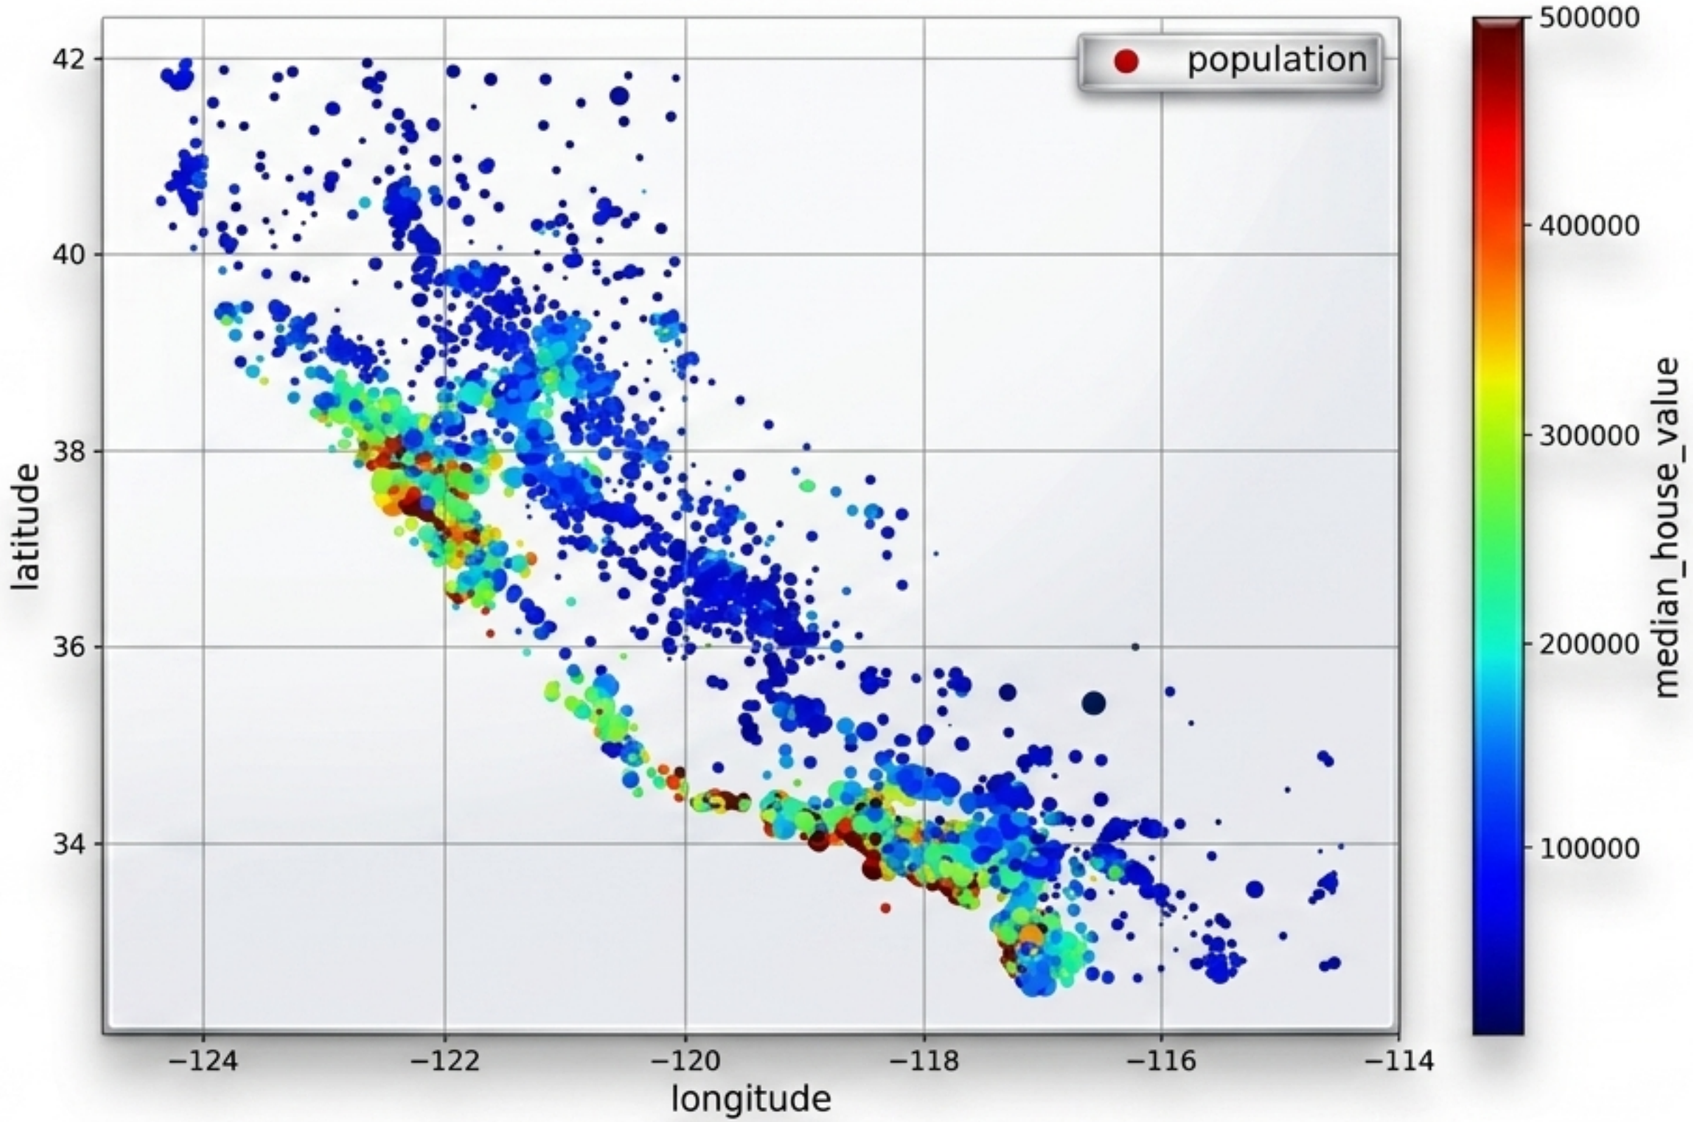

Hình 2-13. Giá nhà khu vực California (Màu: Giá nhà, Vòng tròn: Dân số)

Gemini Notebook

Tìm kiếm các tương quan (Correlation)

Hệ số tương quan Pearson (r) chạy từ -1 đến +1.

Gần -1:
Tương quan âm mạnh.

Gần 0:
Không có tương quan tuyến tính.

Gần +1:
Tương quan dương mạnh (ví dụ: thu nhập tăng, giá nhà tăng).

Gemini Notebook

Ma trận phân tán (Scatter Matrix)

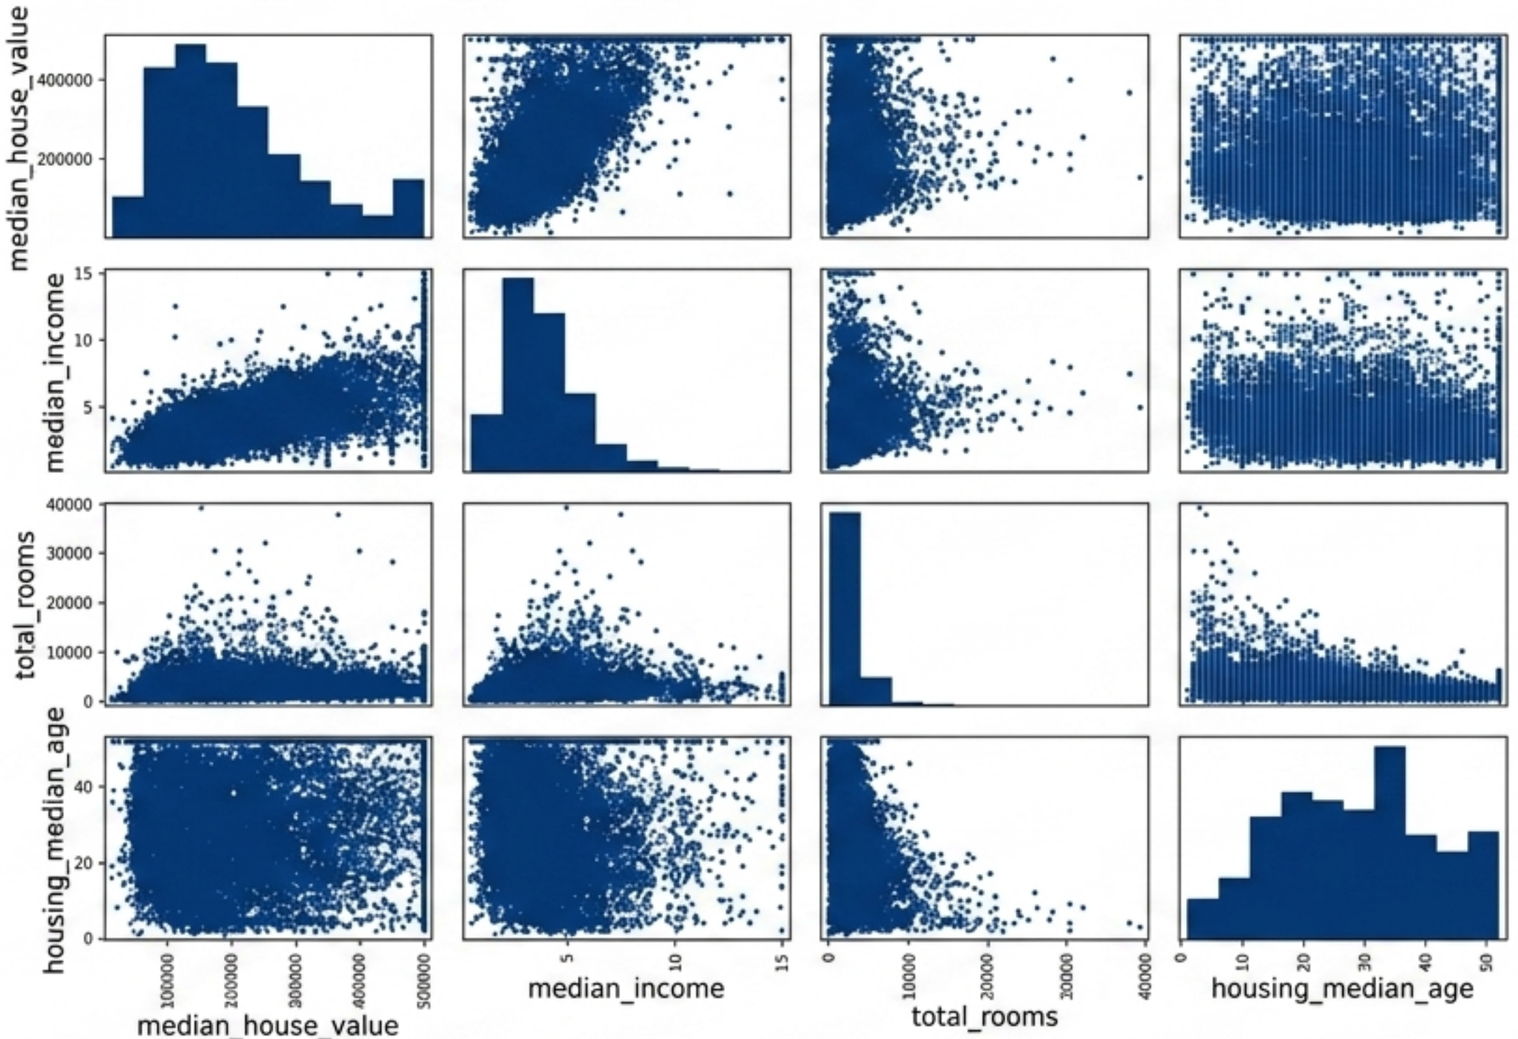

Hình 2-14. Ma trận phân tán hiển thị tương quan giữa các đặc trưng

Gemini Notebook

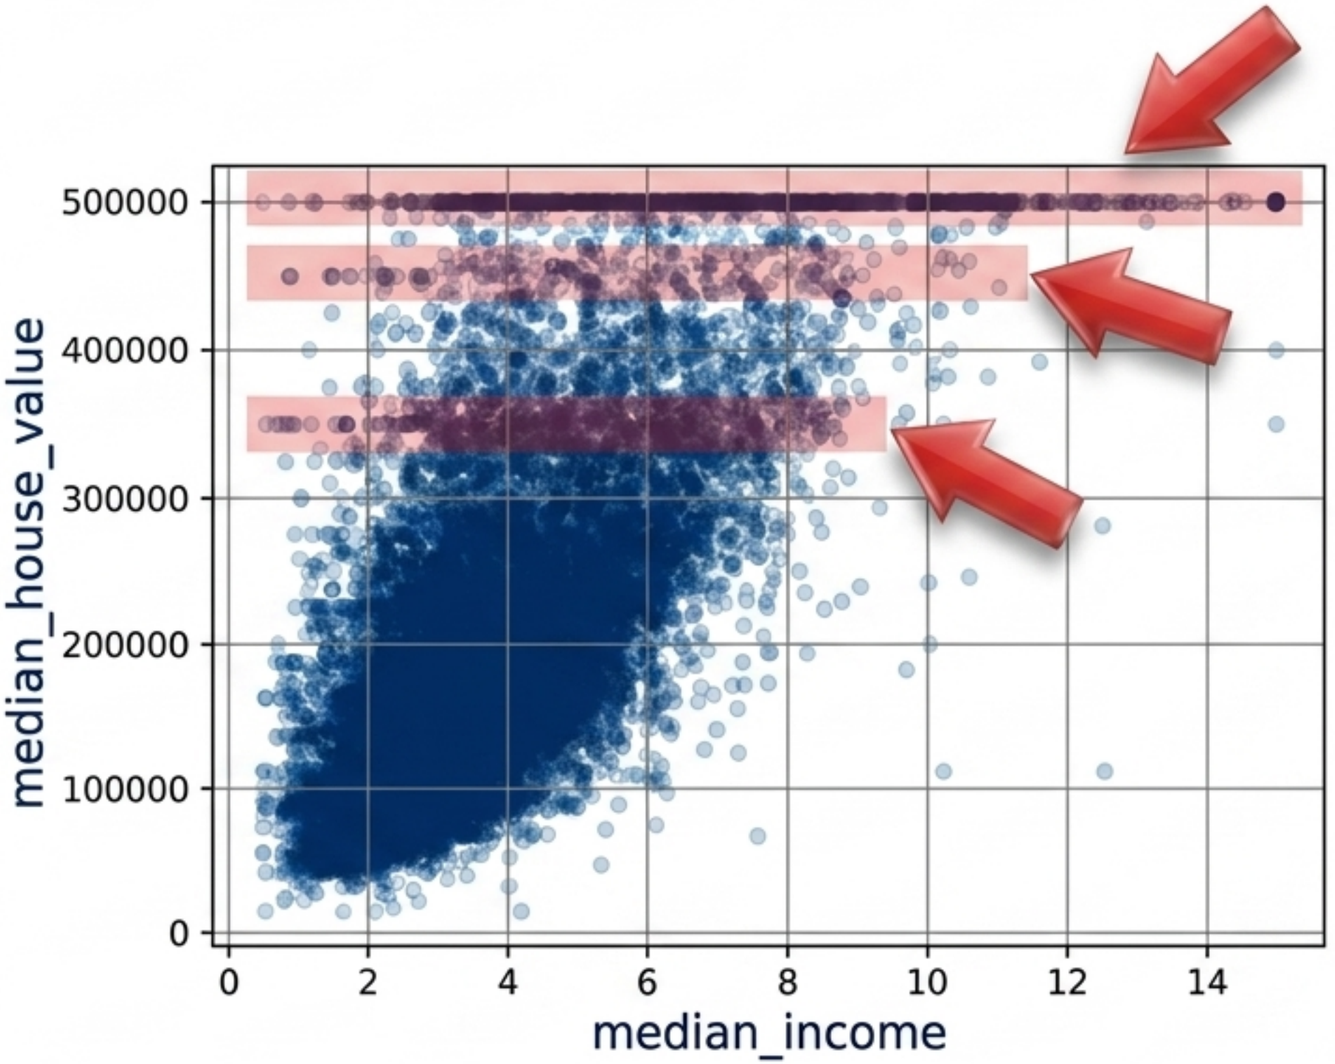

Hình 2-15. Thu nhập so với giá trị nhà

Thu nhập trung bình vs Giá nhà trung bình

Thu nhập trung bình là thuộc tính có tương quan mạnh nhất với giá nhà.

Anomaly Detected

Trên biểu đồ xuất hiện một số "đường ngang" (trần giá) ở mức $500k, $450k, và $350k.

Có thể cần phải loại bỏ các điểm dữ liệu này để thuật toán không học những mô hình sai lệch này.

Gemini Notebook

Phân phối và độ lệch chuẩn của dữ liệu

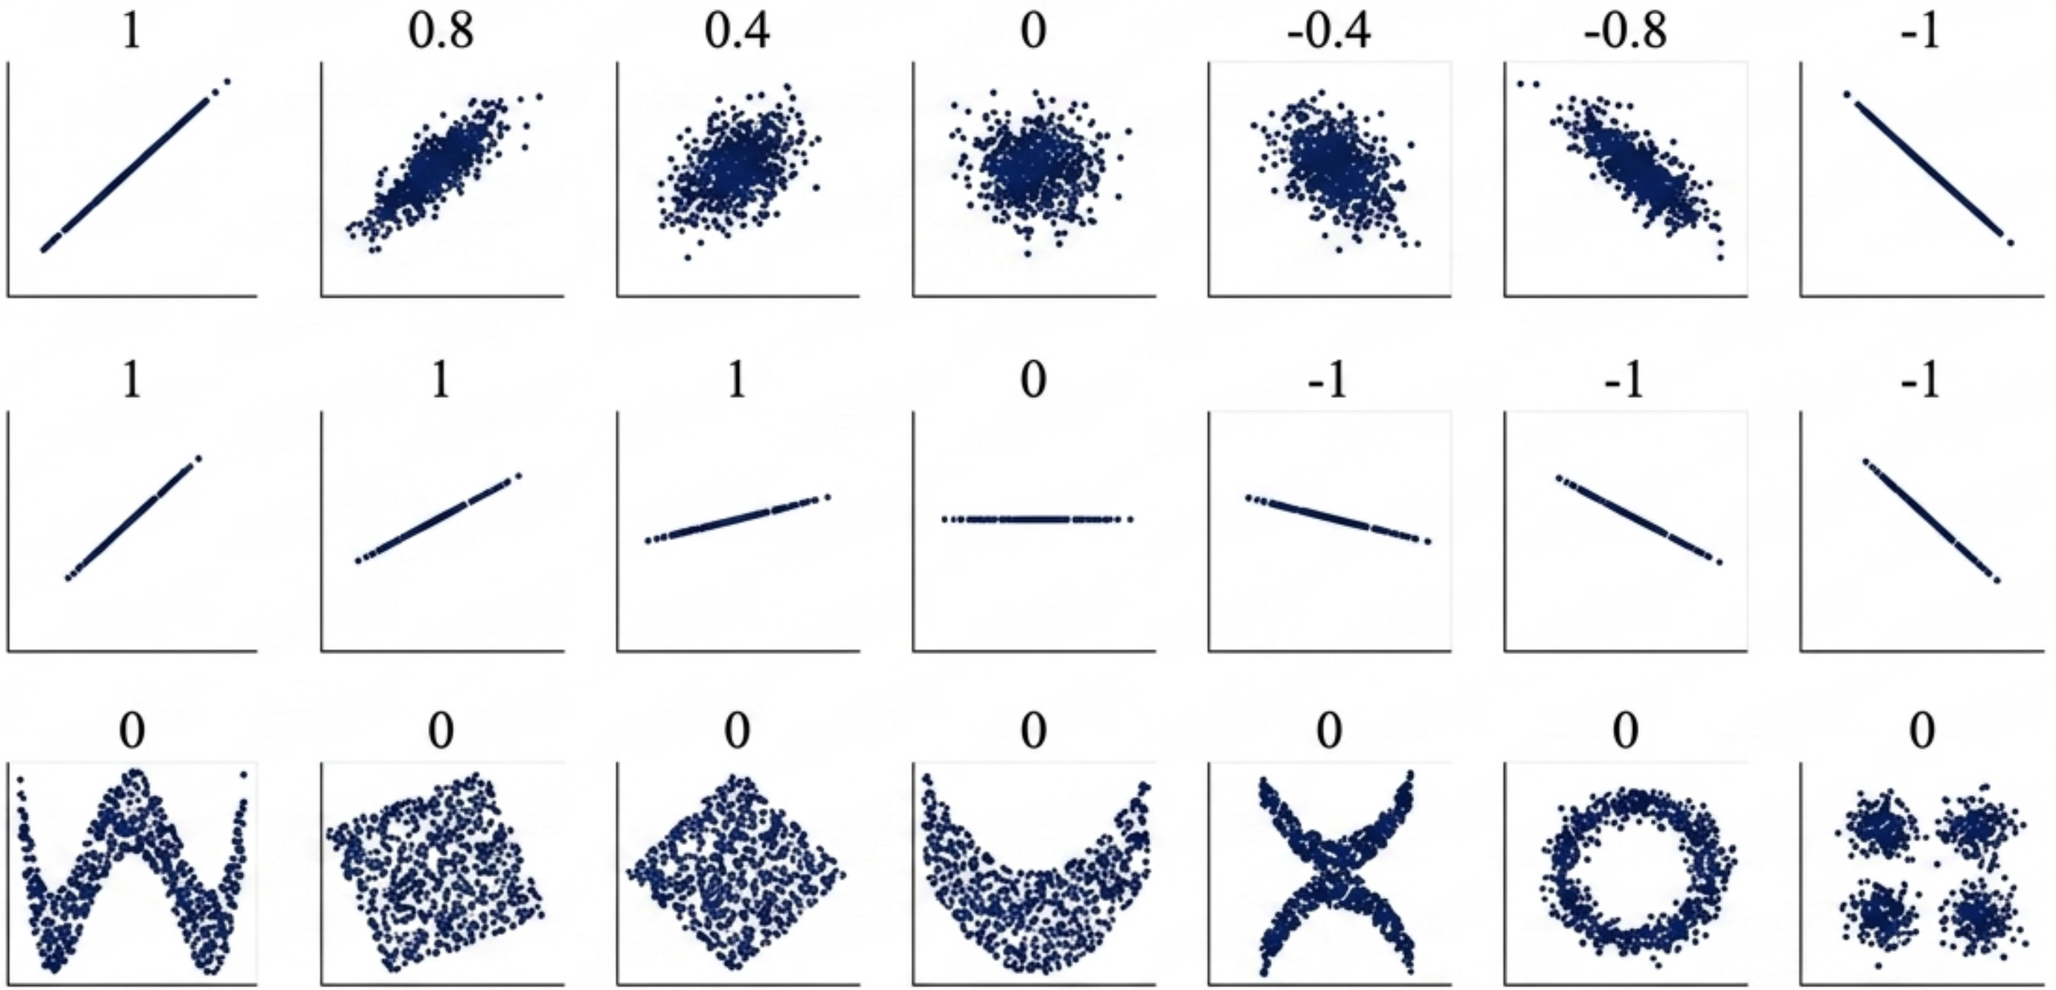

Hình 2-16. Độ lệch chuẩn của các tập dữ liệu khác nhau

Gemini Notebook

Thử nghiệm với các kết hợp đặc trưng

Đôi khi, kết hợp các đặc trưng hiện có sẽ tạo ra đặc trưng mới ý nghĩa hơn.

Vấn đề:
Số lượng phòng trong một quận không hữu ích nếu không biết số hộ gia đình.

Giải pháp:
Thay vào đó, tạo đặc trưng Số phòng trên mỗi hộ.

Các kết hợp khác:
Số lượng phòng ngủ trên tổng số phòng.
Dân số trên mỗi hộ.

Gemini Notebook

Gemini Notebook

Làm sạch dữ liệu (Data Cleaning)

Các thuật toán học máy không thể hoạt động với các giá trị bị thiếu (Missing Values).

1. Loại bỏ các mẫu tương ứng (xóa hàng).

2. Loại bỏ toàn bộ thuộc tính đó (xóa cột).

3. Điền vào các giá trị bị thiếu bằng một giá trị nào đó (0, trung bình, trung vị...).

Sử dụng **SimpleImputer** của Scikit-Learn.

Gemini Notebook

Xử lý các thuộc tính văn bản và phân loại

Hầu hết các thuật toán ML thích làm việc với con số. Cần chuyển đổi văn bản sang số.
Đặc trưng ”ocean_proximity” là văn bản.

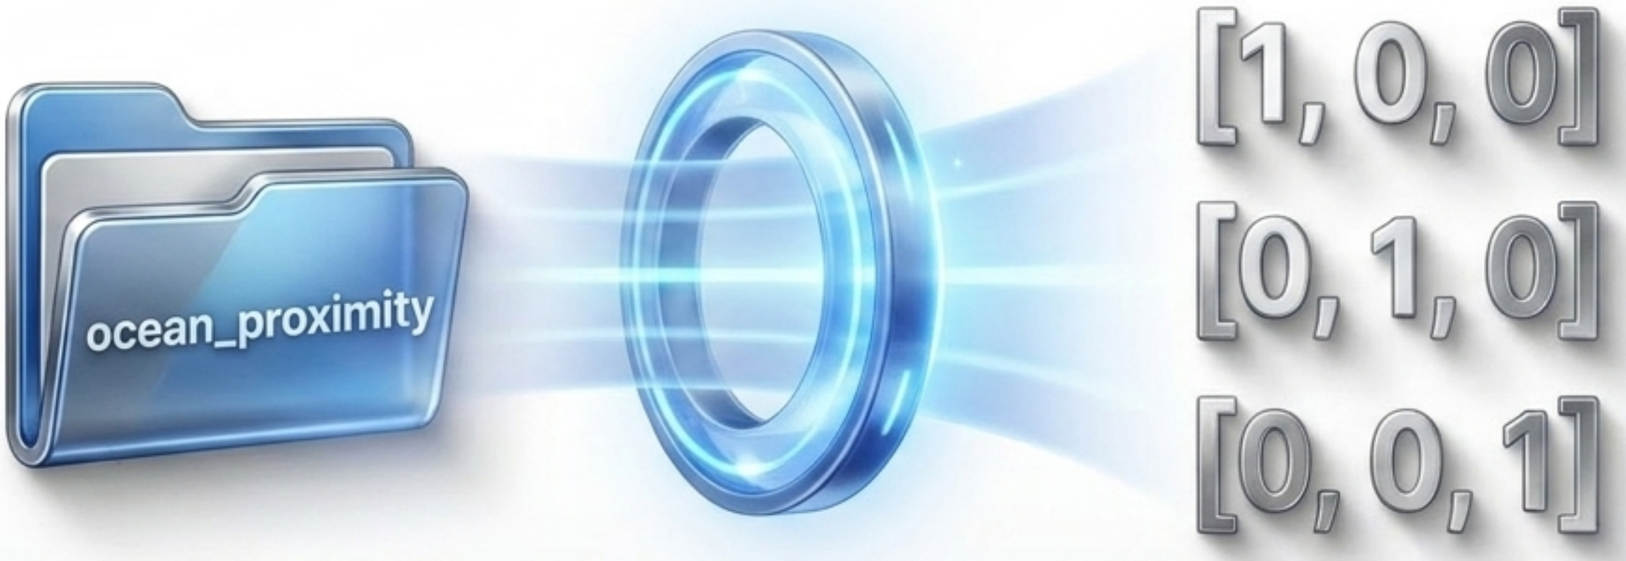

Phương pháp One-Hot Encoding:
Tạo một cột nhị phân cho mỗi danh mục.

Tránh việc thuật toán hiểu sai rằng danh mục ”1” thì gần danh mục ”2” hơn danh mục ”4”.

Gemini Notebook

Co giãn Đặc trưng (Feature Scaling)

Các thuật toán hoạt động không tốt khi các đặc trưng có thang đo rất khác nhau (ví dụ: dân số từ vài nghìn, nhưng thu nhập chỉ từ 0 - 15).

Min-Max Scaling (Chuẩn hóa Normalization)
(Chuẩn hóa Normalization)

Giá trị được chuyển về khoảng từ 0 đến 1.

Standardization (Chuẩn hóa Standardization)
(chuẩn hóa Standardization)

Trừ đi giá trị trung bình và chia cho độ lệch chuẩn. Không bị ảnh hưởng nhiều bởi ngoại lai.
Không bị ảnh hưởng nhiều bởi ngoại lai.

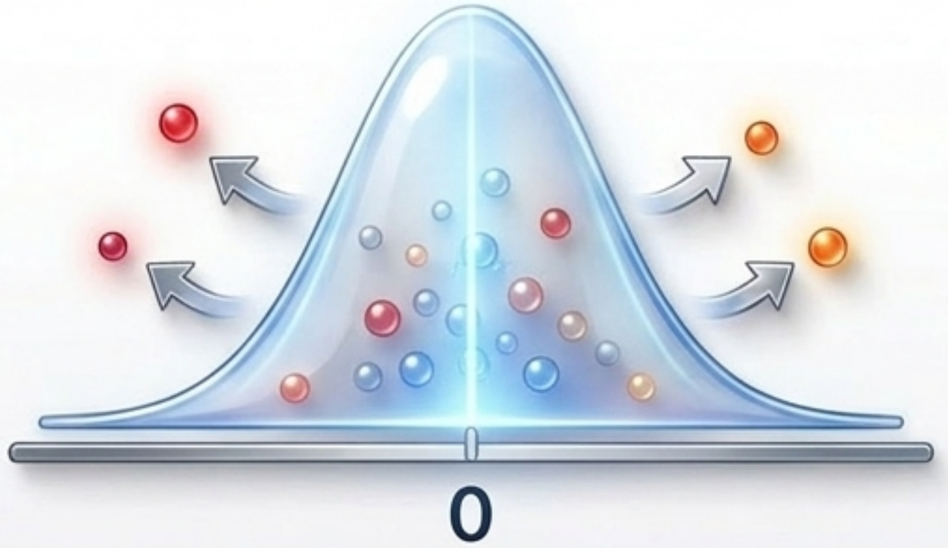

Gemini Notebook

Đưa dữ liệu về dạng phân phối Gaussian

Nhiều biểu đồ tần suất bị ”nặng đuôi” (tail-heavy). Sử dụng các phép tính logarit (Log) hoặc logarit căn bản để biến đổi dữ liệu về dạng giống cái chuông (bell-shaped Gaussian).

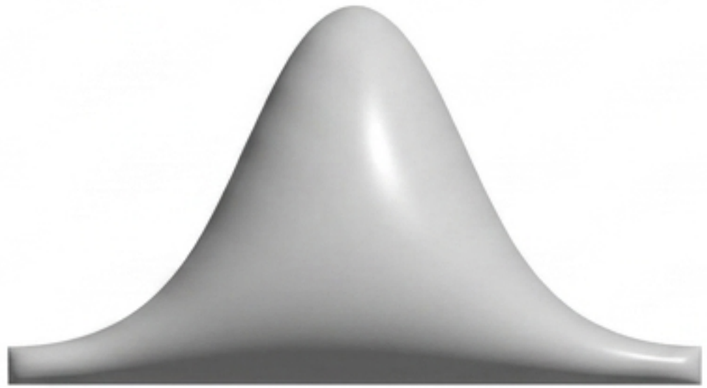

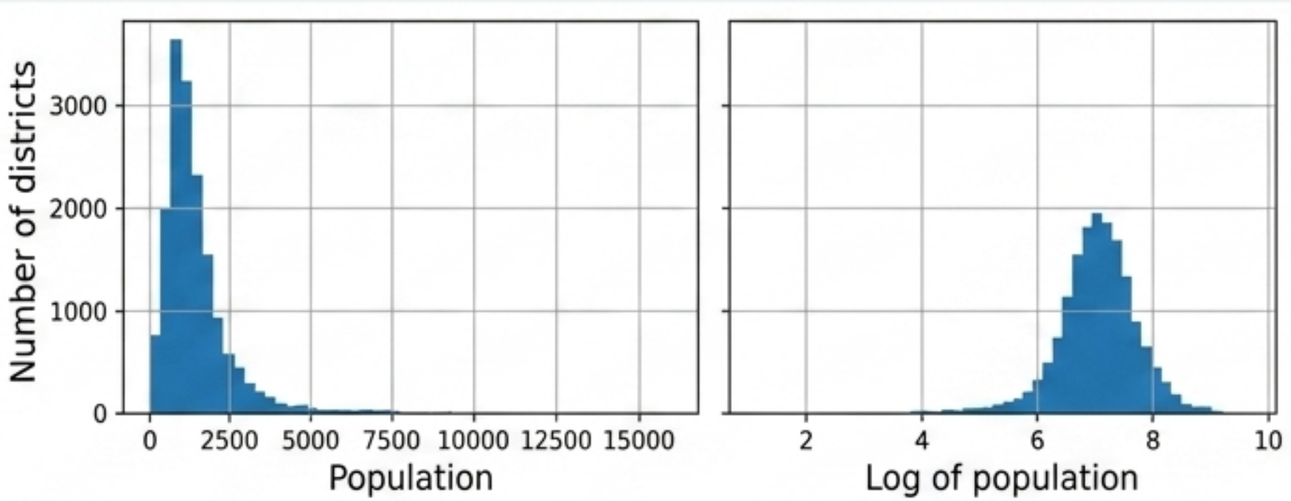

Hình 2-17. *Biến đổi đặc trưng nặng đuôi*

Gemini Notebook

Đo lường sự tương đồng tới các đỉnh bằng hàm RBF

- Áp dụng cho phân phối có nhiều đỉnh (multimodal).
- Sử dụng **Radial Basis Function (RBF)** - Hàm cơ sở xuyên tâm.
- Phương pháp này đo khoảng cách (sự tương đồng) giữa một giá trị và một "đỉnh" (landmark) cố định.

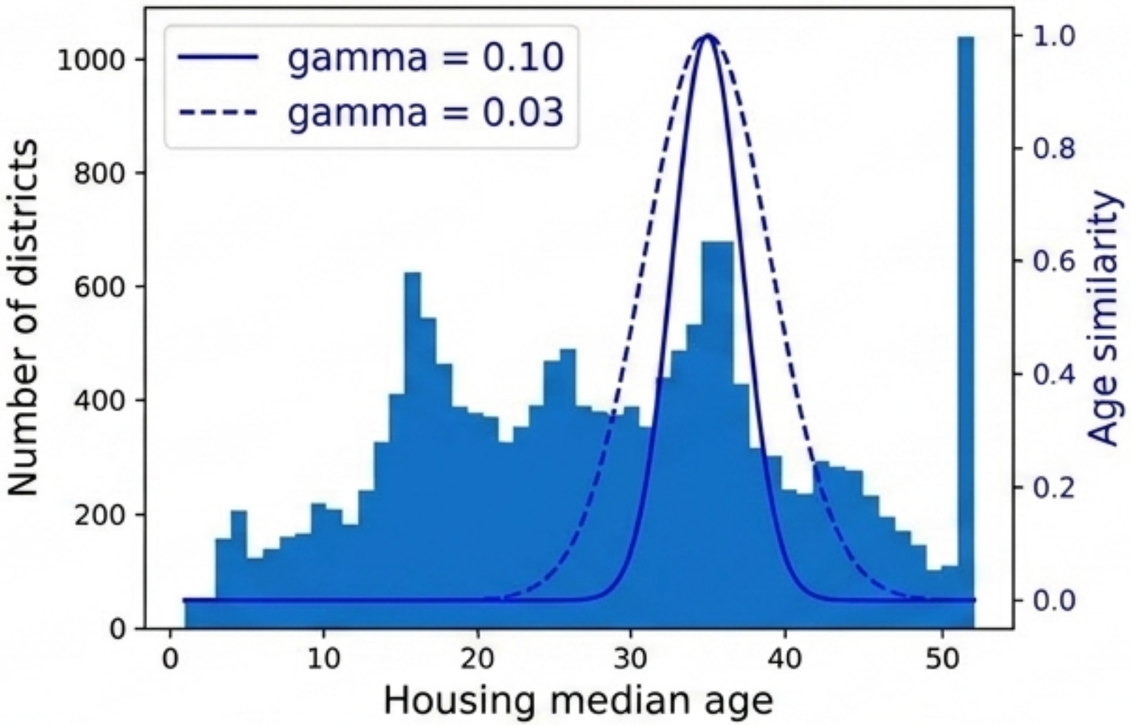

Hình 2-18. *Đặc trưng RBF (Đo khoảng cách tới 35)*

Gemini Notebook

Trích xuất đặc trưng từ phân cụm K-Means

Kết hợp thuật toán phân cụm K-Means để tự động xác định các tâm cụm, từ đó tạo ra các đặc trưng RBF mới phản ánh cấu trúc không gian của dữ liệu.

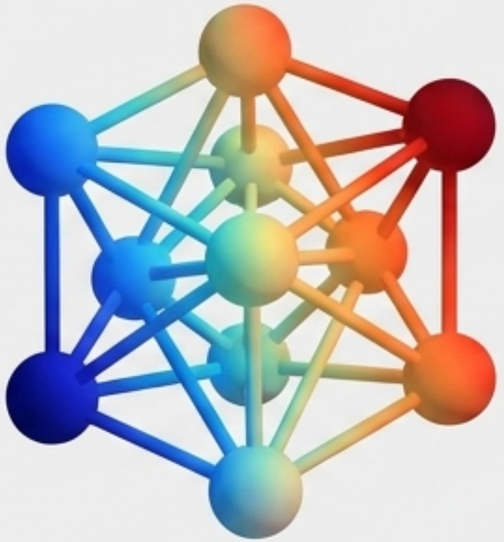

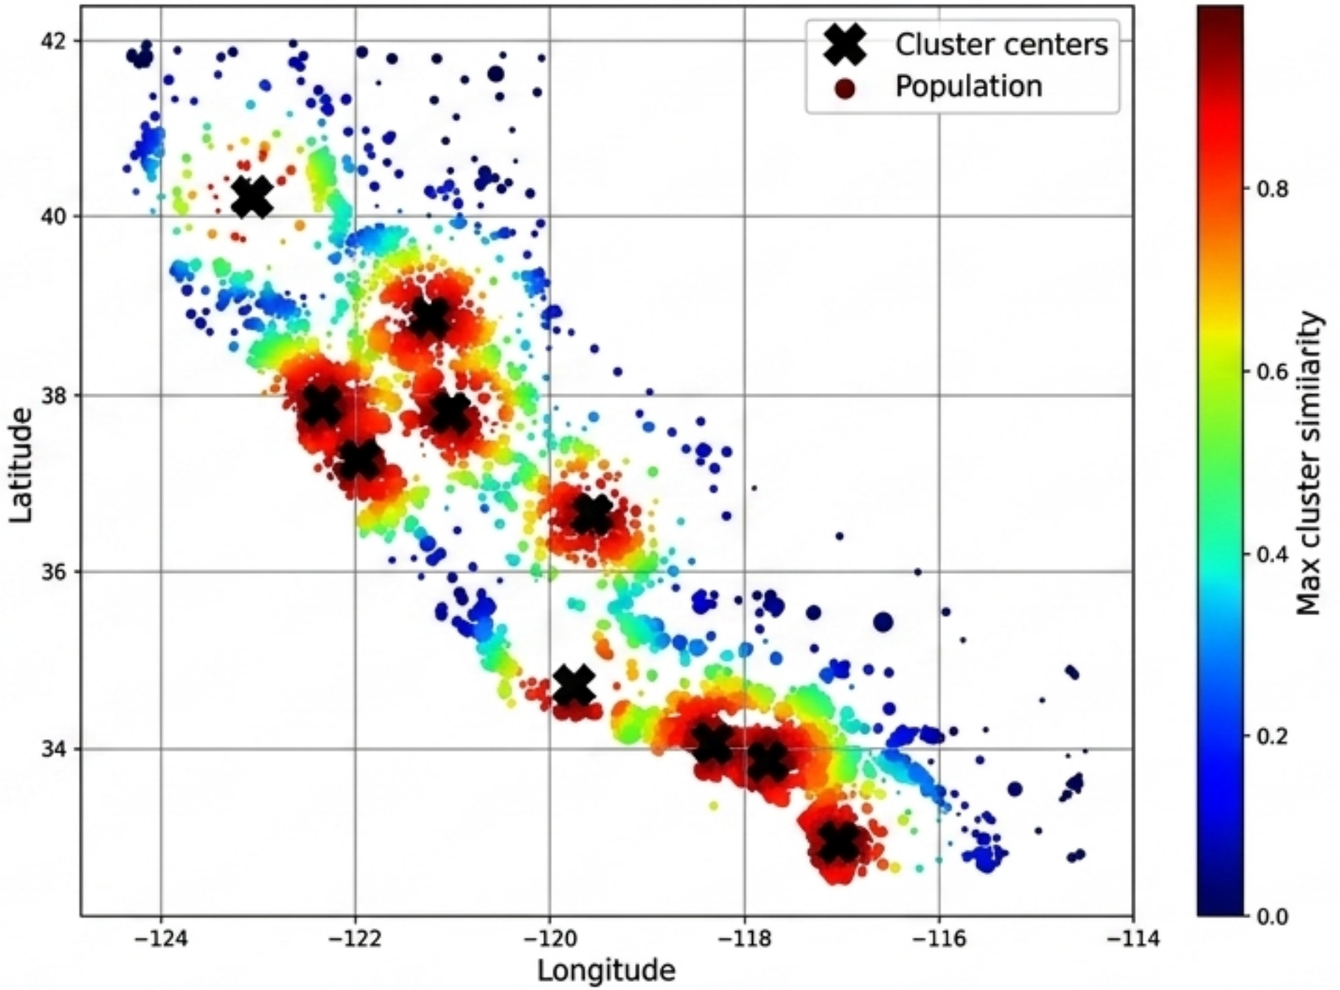

Hình 2-19. Đặc trưng RBF với tâm cụm từ K-Means

Gemini Notebook

Xây dựng các bộ biến đổi tùy chỉnh (Custom Transformers)

- **Vấn đề:**
  - Cần thực hiện logic riêng không có sẵn (ví dụ: tính số phòng trên mỗi hộ).
- **Giải pháp:**
  - Tạo các lớp (Class) tùy chỉnh tuân theo API của Scikit-Learn.
- **Kế thừa từ:**

Gemini Notebook

Liên kết các bước xử lý với Transformation Pipelines

Quá trình biến đổi dữ liệu yêu cầu thực hiện nhiều bước theo đúng thứ tự. `Pipeline` liên kết các bước thành một luồng duy nhất.

`ColumnTransformer` áp dụng các luồng xử lý khác nhau cho các loại cột khác nhau.

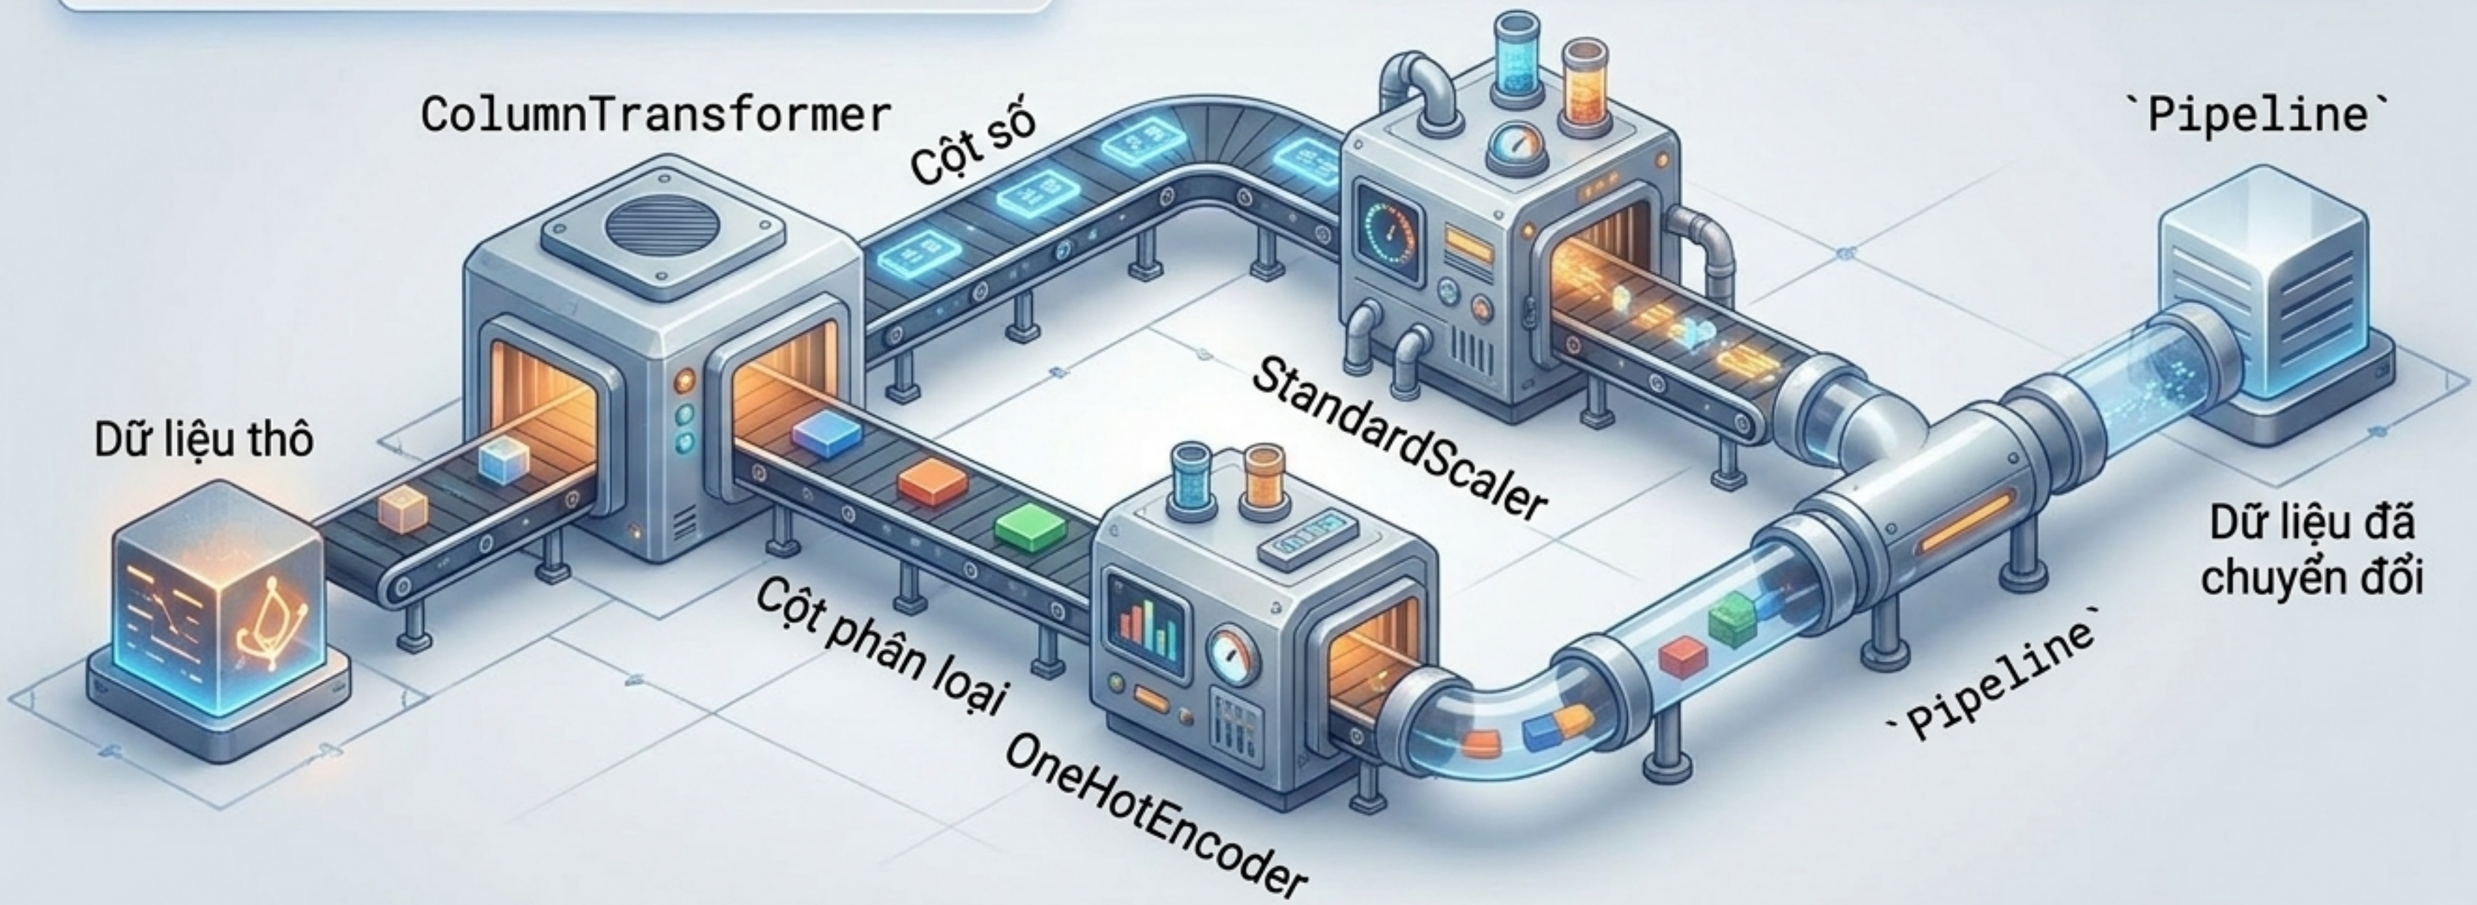

Gemini Notebook

3. Chọn, Huấn luyện, Tinh chỉnh & Triển khai

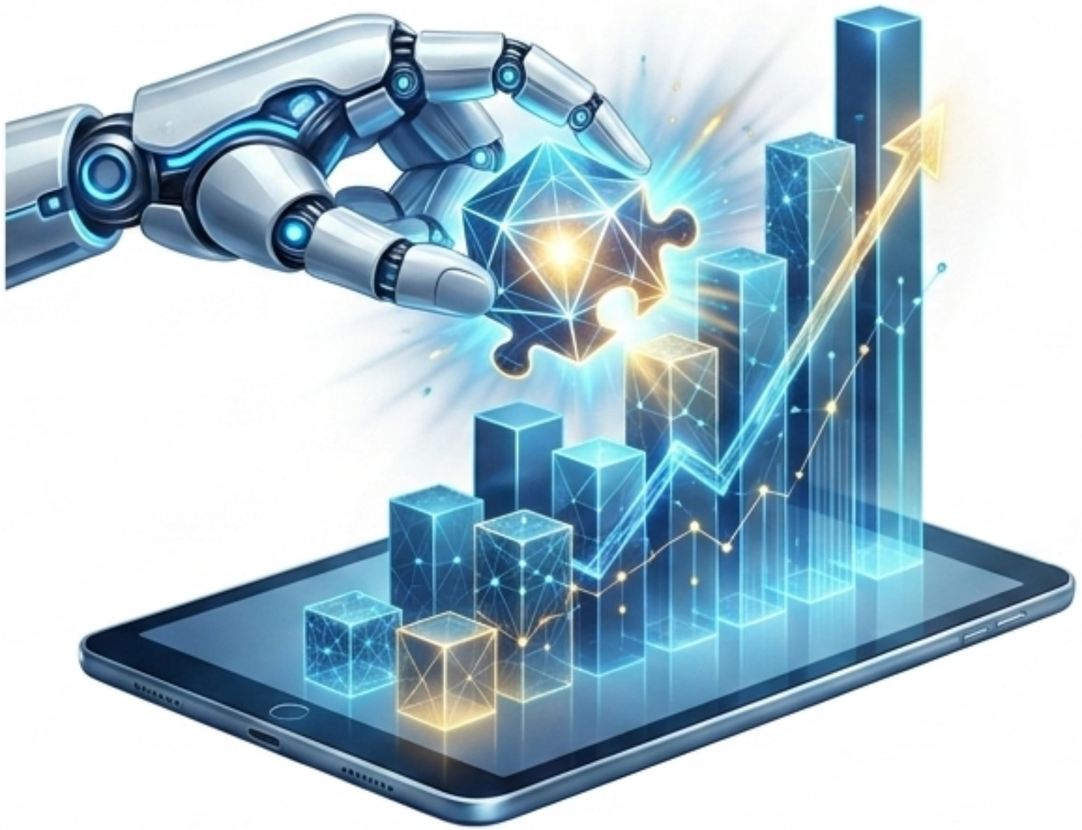

Gemini Notebook

Bắt đầu từ mô hình đơn giản đến phức tạp

Hồi quy tuyến tính (Linear Regression)

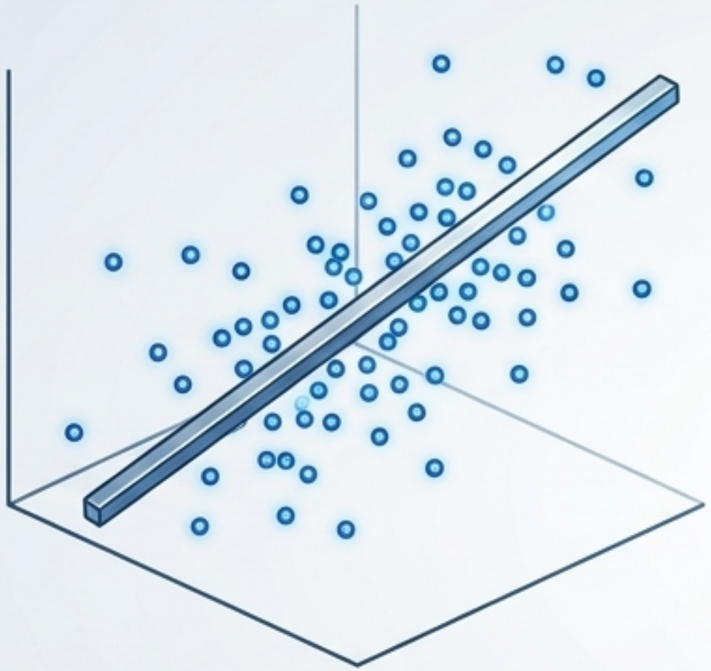

⚠ Nếu RMSE quá cao (ví dụ sai số 68,000 USD) -> Mô hình bị **Underfitting** (chưa khớp).

Cây quyết định (Decision Tree Regressor)

✓ Mô hình mạnh mẽ, có khả năng tìm ra các mối quan hệ phi tuyến tính phức tạp.

Gemini Notebook

Đánh giá tổng quát hóa bằng K-fold Cross-Validation

- Chia ngẫu nhiên tập huấn luyện thành K tập con (fold) khác biệt.
- Huấn luyện và đánh giá mô hình K lần: mỗi lần chọn một fold khác nhau để đánh giá và K-1 fold còn lại để huấn luyện.

⚠ Giúp biết chính xác mô hình tổng quát hóa tốt như thế nào mà không cần chạm vào tập kiểm thử thực (Test set).

Gemini Notebook

Vượt trội với Học tập hợp từ Rừng ngẫu nhiên

Rừng ngẫu nhiên (Random Forest) là một mô hình **Học tập hợp (Ensemble Learning)**.

Xây dựng nhiều Cây quyết định trên các tập hợp con ngẫu nhiên của các đặc trưng, sau đó lấy trung bình dự đoán của chúng.

Thường cho kết quả **vượt trội** và là một trong những mô hình máy học mạnh nhất.

Gemini Notebook

Tinh chỉnh mô hình

Tinh chỉnh mô hình: Tìm kiếm theo lưới (Grid Search)

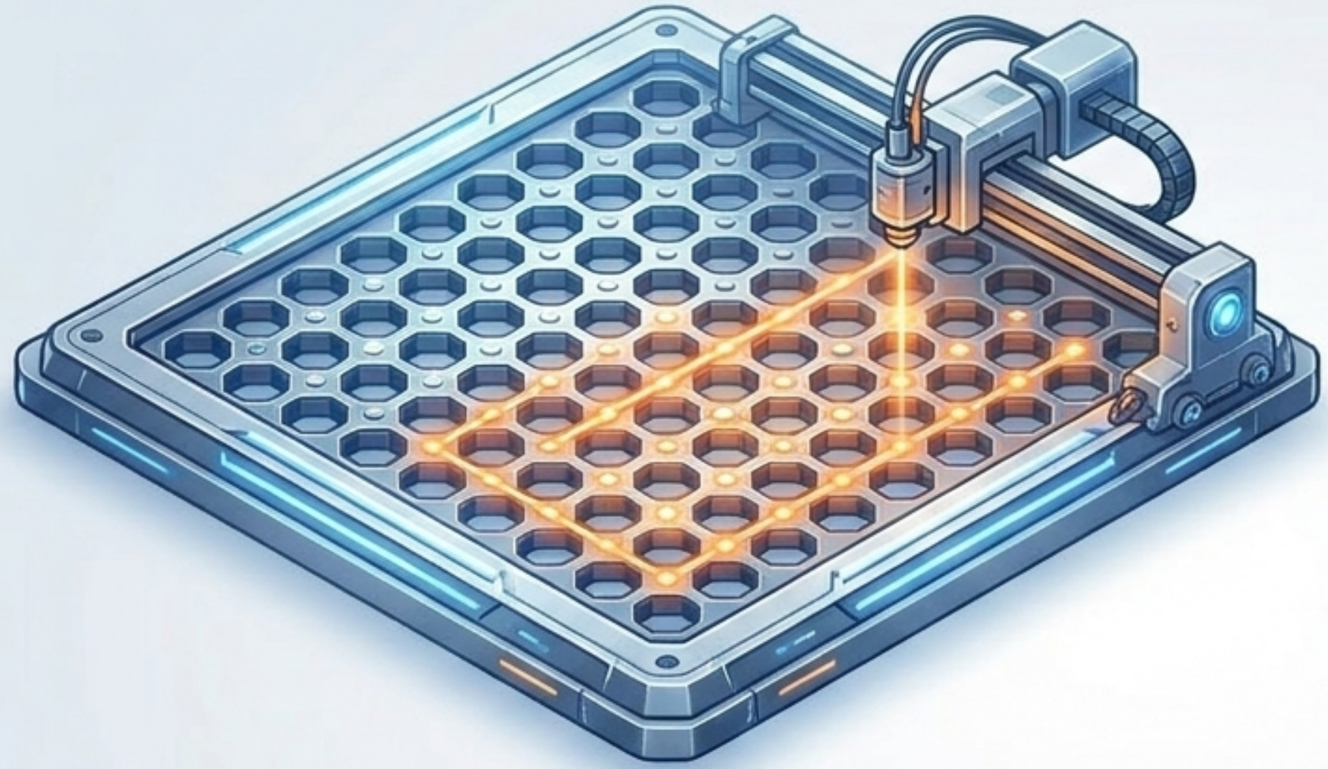

Sử dụng `**GridSearchCV**` của Scikit-Learn để tự động thử nghiệm **tất cả** các tổ hợp có **thể** có của các siêu tham số.

⚠ Rất hữu ích khi khám phá một vài kết hợp, nhưng **cực kỳ tốn thời gian tính toán** nếu không gian tìm kiếm lớn.

Gemini Notebook

Tinh chỉnh mô hình: Tìm kiếm ngẫu nhiên (Random Search)

Dùng **`RandomizedSearchCV`**: thay vì thử nghiệm tất cả, thuật toán sẽ đánh giá một số lượng ngẫu nhiên nhất định các kết hợp.

✓ Cho phép điều chỉnh siêu tham số với hiệu suất tính toán **tốt hơn rất nhiều** nếu không gian tìm kiếm quá lớn.

Gemini Notebook

Tối ưu hóa bằng các Phương pháp Tập hợp

Cố gắng kết hợp các mô hình hoạt động tốt nhất (**Ensemble Methods**). Một nhóm thường sẽ hoạt động tốt hơn so với mô hình cá nhân tốt nhất.

Giống như quyết định của một hội đồng thường tốt hơn một cá nhân.

Gemini Notebook

Phân tích mô hình tốt nhất để loại bỏ nhiễu

Kiểm tra các mô hình tốt nhất để có cái nhìn sâu sắc. Mô hình `**RandomForest**` có thể cho biết mức độ quan trọng tương đối (relative importance) của từng đặc trưng.

→ Dựa vào thông tin này, tiến hành cân nhắc **loại bỏ một số đặc trưng ít hữu ích nhất** để tối ưu hệ thống.

Gemini Notebook

Chốt hạ: Đánh giá hệ thống trên Tập kiểm thử

Chạy tập kiểm thử qua `full_pipeline` để chuyển đổi dữ liệu.

Chỉ gọi `transform()`

Tuyệt đối **KHÔNG** gọi `fit()`

- Hiệu suất thường sẽ hơi tệ hơn so với trên tập xác thực (do mô hình đã được tinh chỉnh riêng cho tập xác thực).
- Đừng cố tình điều chỉnh siêu tham số nữa sau bước này!

Gemini Notebook

Triển khai, Giám sát và Bảo trì hệ thống

Chu trình cuối của Ứng dụng Học máy

Gemini Notebook

Triển khai mô hình (Model Deployment)

1. Lưu trữ Mô hình

Lưu trữ mô hình đã huấn luyện bằng cách sử dụng các thư viện chuyên dụng như joblib.

2. Tải lên Production

Đưa mô hình lên môi trường sản xuất (Production) để sẵn sàng phục vụ thực tế.

3. Đóng gói & Đưa lên Cloud

Đóng gói mô hình bằng Container (ví dụ: Docker) và triển khai lên hạ tầng Điện toán đám mây (Cloud).

Gemini Notebook

Kiến trúc Triển khai (Ví dụ)

Hình 2-20. Triển khai mô hình học máy thành dịch vụ web (Web API)

Gemini Notebook

Giám sát hệ thống (Monitoring)

The Problem

Vấn đề: Sự suy giảm hiệu suất

Theo thời gian, dữ liệu thực tế thay đổi dẫn đến Model Rot hoặc Data Drift. Cần liên tục theo dõi sự chênh lệch giữa dự đoán của hệ thống và dữ liệu thực tế mới nhất.

The Solution

Giải pháp: Thiết lập cảnh báo

Cài đặt hệ thống cảnh báo tự động để đội ngũ xử lý ngay lập tức khi độ chính xác của mô hình giảm xuống dưới một ngưỡng nhất định.

Gemini Notebook

Tự động hóa quá trình bảo trì và cập nhật

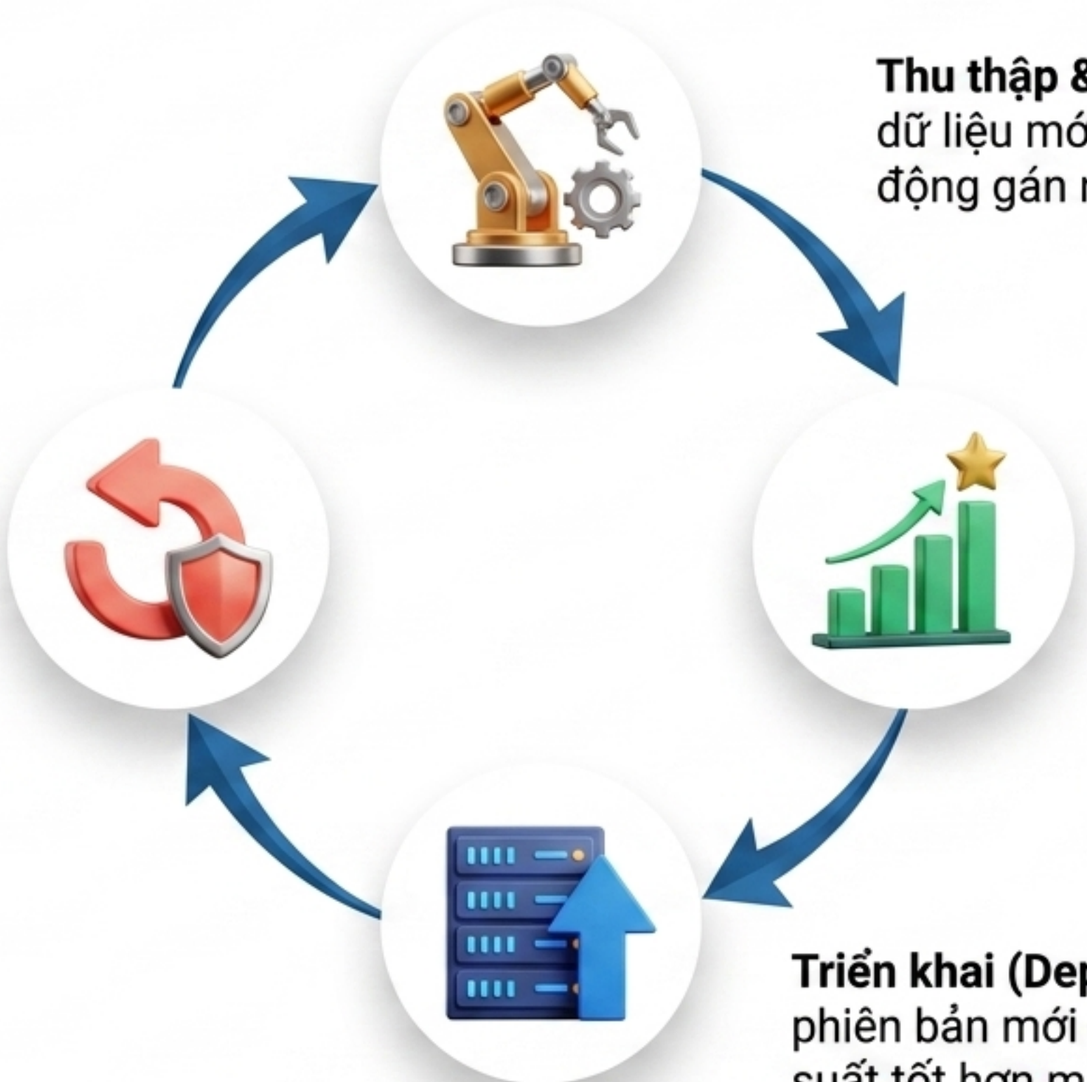

Thu thập & Gán nhãn: Thu thập dữ liệu mới thường xuyên và tự động gán nhãn (nếu có thể).

Đánh giá mô hình: Tự động đánh giá hiệu suất của các mô hình mới.

Triển khai (Deploy): Tự động đẩy phiên bản mới lên máy chủ nếu hiệu suất tốt hơn mô hình cũ.

Phòng ngừa (Rollback): Giữ lại bản sao lưu để quay lại phiên bản trước nhanh chóng nếu có lỗi nghiêm trọng.

Gemini Notebook

Tổng kết Chương 2

Quá trình xây dựng ứng dụng học máy là một chu trình khép kín (End-to-End):

Dữ liệu thô → Phân tích & Chuẩn bị → Huấn luyện → Triển khai → Bảo trì

Chìa khóa thành công

Hầu hết công sức của chuyên gia dữ liệu nằm ở khâu **Chuẩn bị dữ liệu** và **hiểu bài toán**, thay vì chọn các thuật toán tinh vi. Một pipeline dữ liệu vững chắc là chìa khóa thành công.

Gemini Notebook