DỰ ÁN HỌC MÁY TỪ ĐẦU ĐẾN CUỐI

Chương 3 - Phân loại (Classification)

TS. Trần Thành Thắng
Đại học Đông Á

August 11, 2026

Gemini Notebook

Nội dung Chương trình

1. Giới thiệu Phân loại, MNIST & Đánh giá Hiệu suất cơ bản

2. Sự đánh đổi Hiệu suất & Phân loại Đa lớp

3. Phân tích lỗi, Đa nhãn & Đa đầu ra

Gemini Notebook

Mục tiêu bài học

- Nắm vững khái niệm Phân loại (Classification) trong Học máy.
- Hiểu rõ và thực hành với bộ dữ liệu MNIST ("Hello World" của học máy).
- Đánh giá mô hình bằng các thước đo hiệu suất (Ma trận nhầm lẫn, Precision, Recall, F1-score, ROC AUC).
- Phân biệt và thực hiện Phân loại Đa lớp (Multiclass), Đa nhãn (Multilabel) và Đa đầu ra (Multioutput).
- Kỹ năng phân tích lỗi để cải thiện hiệu suất mô hình.

Gemini Notebook

1. Giới thiệu Phân loại, MNIST & Đánh giá Hiệu suất cơ bản

Gemini Notebook

Giới thiệu Bộ dữ liệu MNIST

Các tác vụ học có giám sát phổ biến nhất là Hồi quy (Regression) và Phân loại (Classification). Chúng ta sẽ sử dụng bộ dữ liệu MNIST, gồm 70.000 hình ảnh nhỏ của các chữ số viết tay bởi học sinh và nhân viên Cục Thống kê Hoa Kỳ.

MNIST được nghiên cứu nhiều đến mức nó được gọi là ”Hello World” của học máy.

Mục tiêu: Phân loại (nhận dạng) chữ số trong từng bức ảnh.

Gemini Notebook

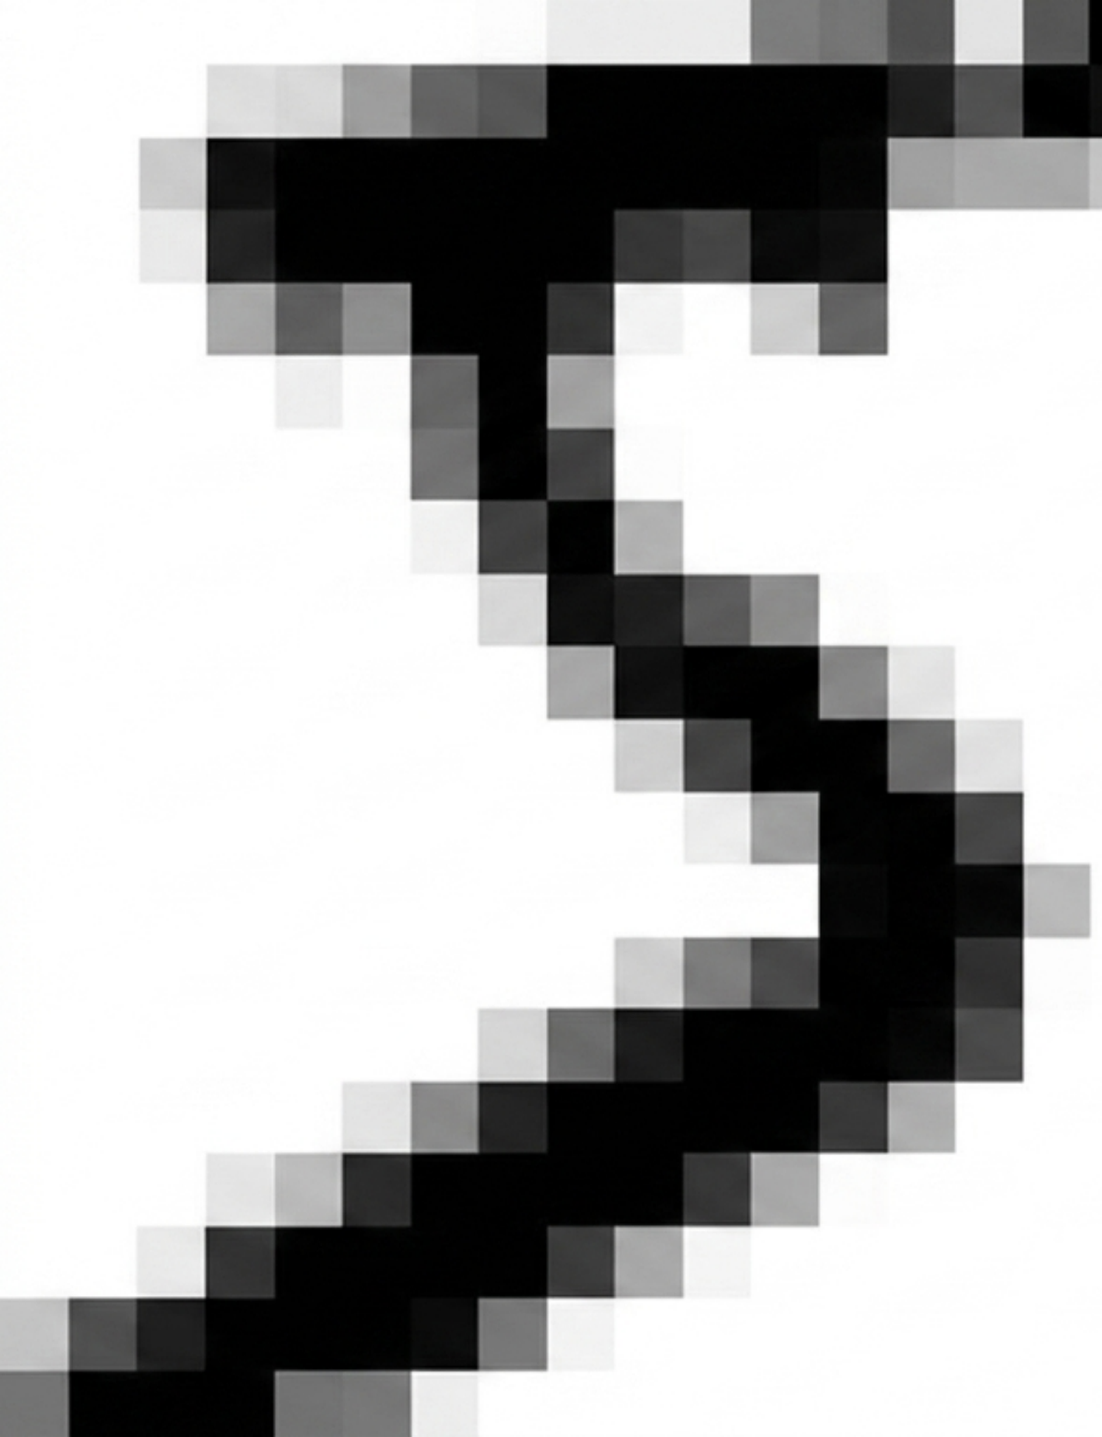

Hình ảnh chữ số MNIST

Mỗi hình ảnh có kích thước 28x28 pixel, tương đương 784 đặc trưng (pixels). Mỗi pixel đại diện cho cường độ xám, từ **0 (trắng)** đến **255 (đen)**. Trong ảnh là một ví dụ **trực quan** hóa một chữ số 5 từ bộ dữ liệu.

Hình 3-1. Ví dụ về hình ảnh MNIST

Gemini Notebook

Hình 3-2. Các chữ số từ bộ dữ liệu MNIST

Sự đa dạng của chữ số MNIST

Các chữ số được viết với nhiều phong cách, nét thanh, nét đậm khác nhau. Để minh họa độ phức tạp của bài toán phân loại, hình bên cạnh liệt kê một số chữ số mẫu từ tập dữ liệu.

Gemini Notebook

Phân chia tập huấn luyện và tập kiểm thử

Nguyên tắc vàng: Luôn tạo một tập kiểm thử (**Test set**) và tách biệt nó trước khi kiểm tra kỹ lưỡng dữ liệu. May mắn là tập dữ liệu MNIST tải từ OpenML đã được chia sẵn:

- Tập huấn luyện (Train set): 60.000 hình ảnh đầu tiên.
- Tập kiểm thử (Test set): 10.000 hình ảnh cuối cùng.

Tập huấn luyện đã được xáo trộn (shuffled), đảm bảo các thuật toán học (đặc biệt là các thuật toán học tuần tự) không bị nhận nhiều trường hợp giống nhau liên tiếp.

Gemini Notebook

Huấn luyện bộ phân loại nhị phân (Binary Classification)

Gemini Notebook

Bài toán: Bộ phát hiện chữ số 5

Hãy đơn giản hóa bài toán: Chúng quy chỉ cần phát hiện xem một chữ số có phải là ”5” hay không.

Đây là ví dụ về Phân loại Nhị phân (Binary Classification): Phân biệt giữa 2 lớp (5 và không-phải-5).

Mục tiêu (Label) mới: True (nếu là số 5), False (nếu là số khác).

Gemini Notebook

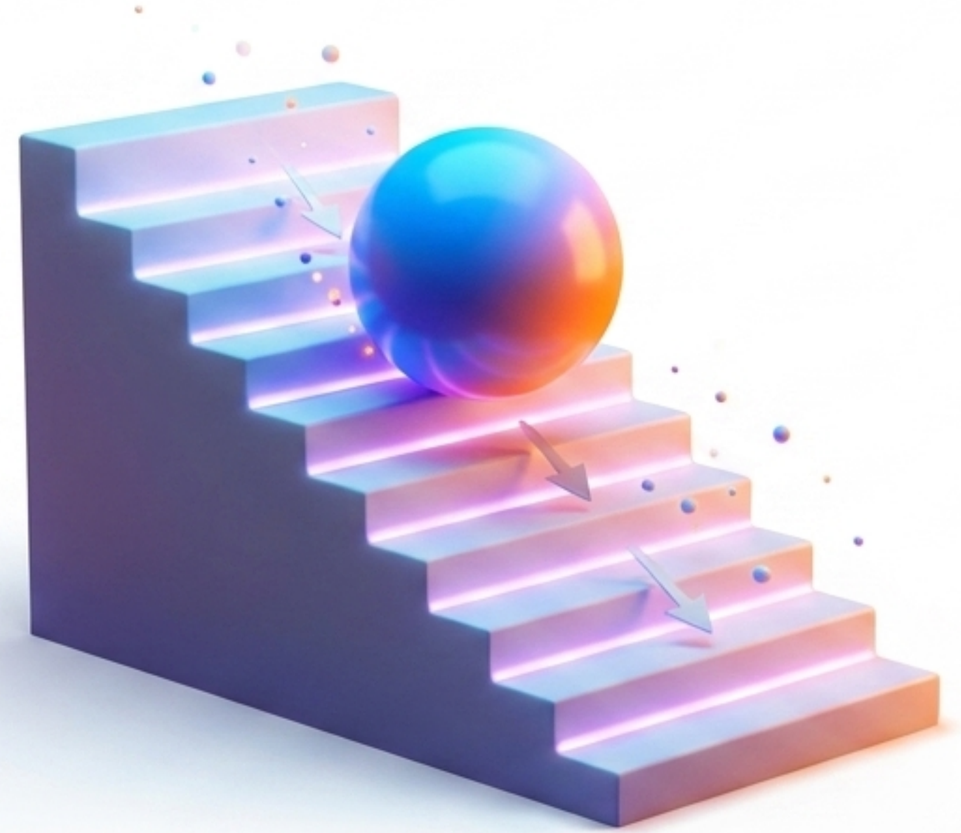

Thuật toán Stochastic Gradient Descent (SGD)

SGD (Xuống dốc ngẫu nhiên) là một thuật toán tối ưu rất hiệu quả để xử lý các tập dữ liệu lớn.

SGD xử lý các trường hợp huấn luyện độc lập, từng trường hợp một (phù hợp với học trực tuyến - online learning).

Lớp SGDClassifier trong Scikit-Learn giúp ta dễ dàng huấn luyện mô hình này.

Gemini Notebook

Các thước đo hiệu suất

Gemini Notebook

Đo độ chính xác bằng kiểm định chéo

Giống như hồi quy, ta có thể dùng kiểm định chéo (Cross-Validation) để đánh giá mô hình phân loại.

Kết quả: SGDClassifier đạt **độ chính xác (Accuracy) trên 95% cho mọi fold!** Nghe có vẻ tuyệt vời, nhưng hãy xem xét cẩn thận hơn.

Gemini Notebook

Sự đánh lừa của Độ chính xác (Accuracy)

Nếu ta tạo một "bộ phân loại ngốc nghếch" (Dummy Classifier) luôn đoán "không-phải-5", thì độ chính xác của nó cũng trên 90%!

Tại sao? Vì chỉ có 10% chữ số trong tập dữ liệu là số 5.

Kết luận: Độ chính xác (Accuracy) **không phải là thước đo tốt cho các tập dữ liệu bị lệch** (skewed datasets).

Gemini Notebook

Ma trận nhầm lẫn (Confusion Matrix)

Ma trận nhầm lẫn (CM) là một cách tốt hơn nhiều để đánh giá hiệu suất.

Ý tưởng chung: Đếm số lần các trường hợp của lớp A bị phân loại nhầm thành lớp B.

Mỗi hàng là một lớp thực tế, mỗi cột là một lớp được dự đoán.

Gemini Notebook

Ma trận nhầm lẫn (Confusion Matrix)

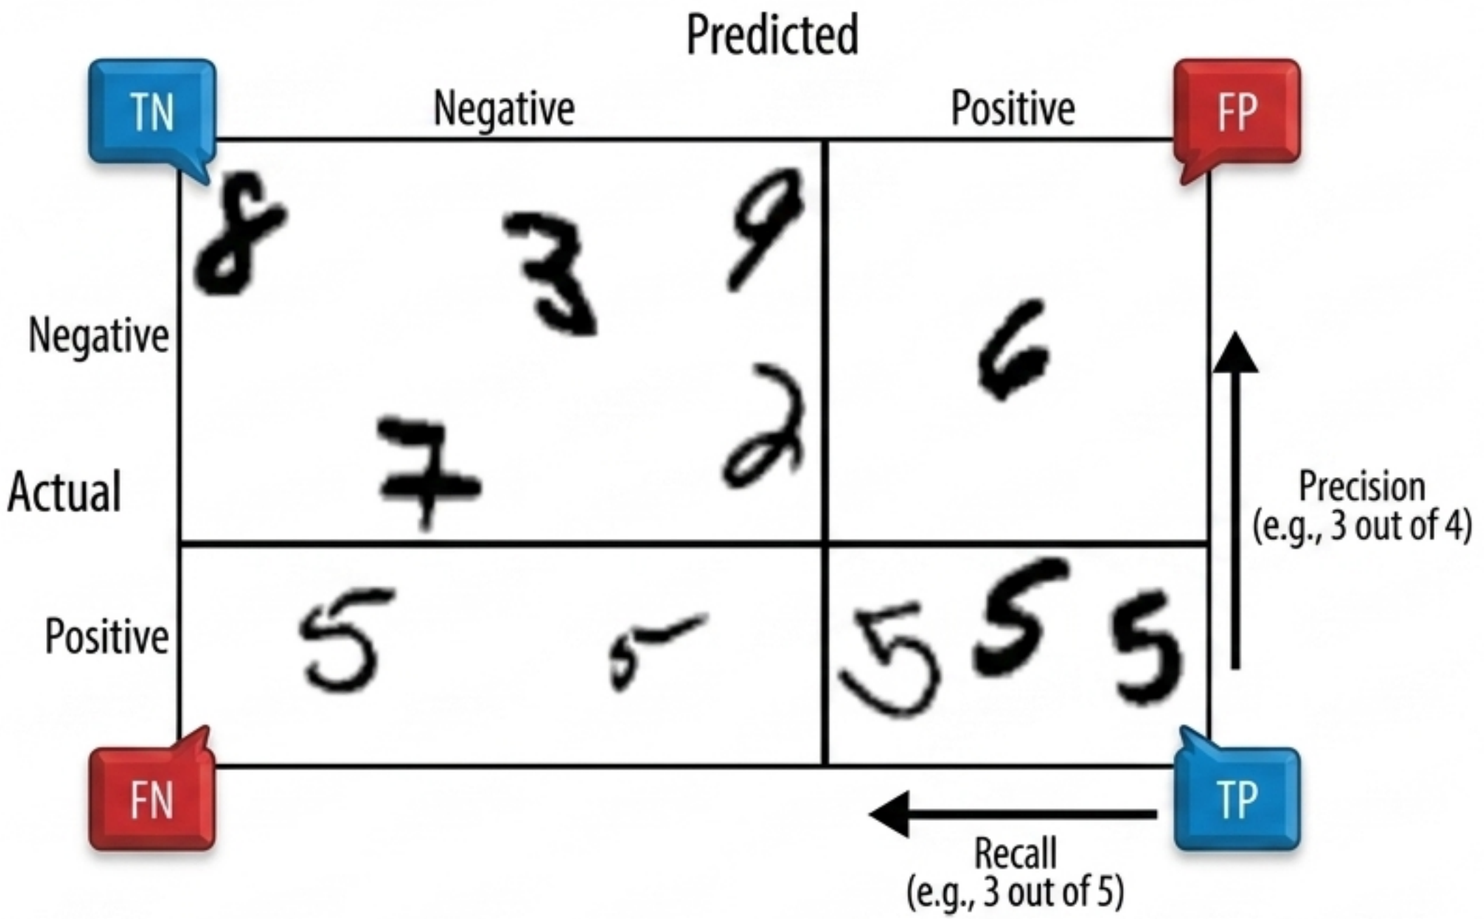

Hình 3-3. Ma trận nhầm lẫn minh họa

True Negative (TN):
Âm tính thật.

False Positive (FP):
Dương tính giả (Lỗi loại I).

False Negative (FN):
Âm tính giả (Lỗi loại II).

True Positive (TP):
Dương tính thật.

Gemini Notebook

Precision vs. Recall: Hai góc nhìn của dự đoán

Độ chính xác (Precision)

Độ chính xác của lớp Dương tính. Trong số các trường hợp mô hình dự đoán là Tích cực, có bao nhiêu phần trăm là đúng?

$$\text{Precision} = \frac{TP}{TP + FP}$$

Độ nhạy (Recall)

Tỷ lệ dương tính đúng. Trong số các trường hợp Tích cực thực sự, mô hình đã phát hiện được bao nhiêu phần trăm?

$$\text{Recall} = \frac{TP}{TP + FN}$$

Gemini Notebook

Điểm F1 (F1 Score): Sự kết hợp hoàn hảo

Precision
Độ chính xác

Recall
Độ nhạy

Điểm F1 là trung bình điều hòa (Harmonic Mean) của Precision và Recall.

⚠ Điểm F1 chỉ cao khi CẢ Precision và Recall đều cao. Nó ưu tiên các bộ phân loại có hai chỉ số này tương tự nhau.

$$\mathrm{F1} = \frac{2}{(1/\mathrm{Precision}) + (1/\mathrm{Recall})} = 2 \times \frac{(\mathrm{Precision} \times \mathrm{Recall})}{\mathrm{Precision} + \mathrm{Recall}}$$

Gemini Notebook

Cơ chế hoạt động: Ngưỡng quyết định (Decision Threshold)

Làm sao mô hình quyết định một mẫu là Tích cực hay Tiêu cực?

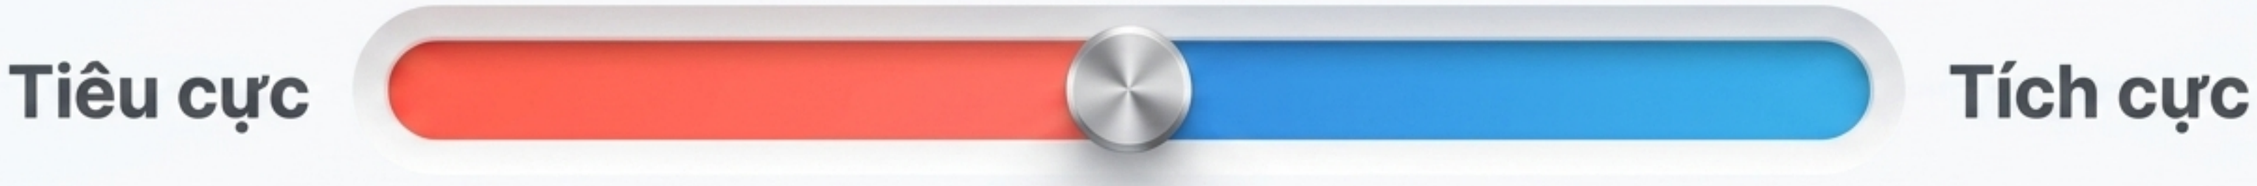

Mô hình tính toán một điểm số quyết định (decision score).

→

Nếu điểm số > Ngưỡng -> Tích cực

Nếu điểm số < Ngưỡng -> Tiêu cực

Gemini Notebook

Cơ chế hoạt động: Ngưỡng quyết định (Decision Threshold)

Làm sao mô hình quyết định một mẫu là Tích cực hay Tiêu cực?

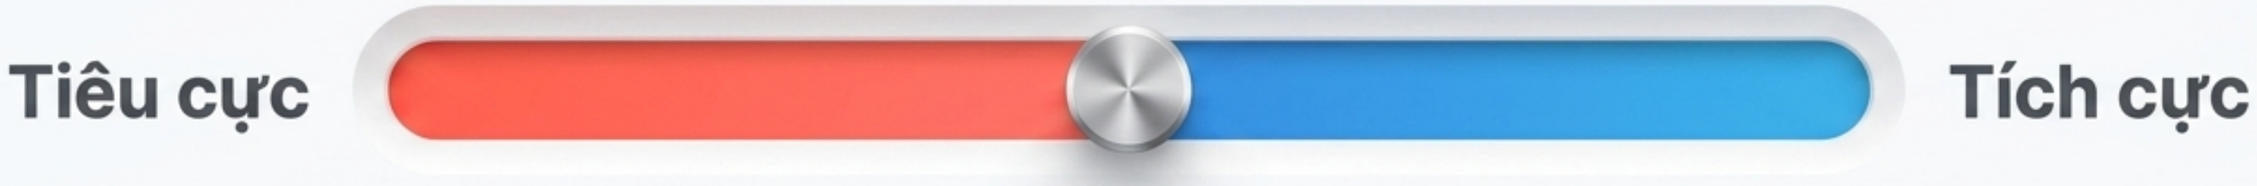

Mô hình tính toán một điểm số quyết định (decision score).

→

Nếu điểm số > Ngưỡng -> Tích cực

Nếu điểm số < Ngưỡng -> Tiêu cực

Gemini Notebook

Trực quan hóa sự đánh đổi (Trade-off)

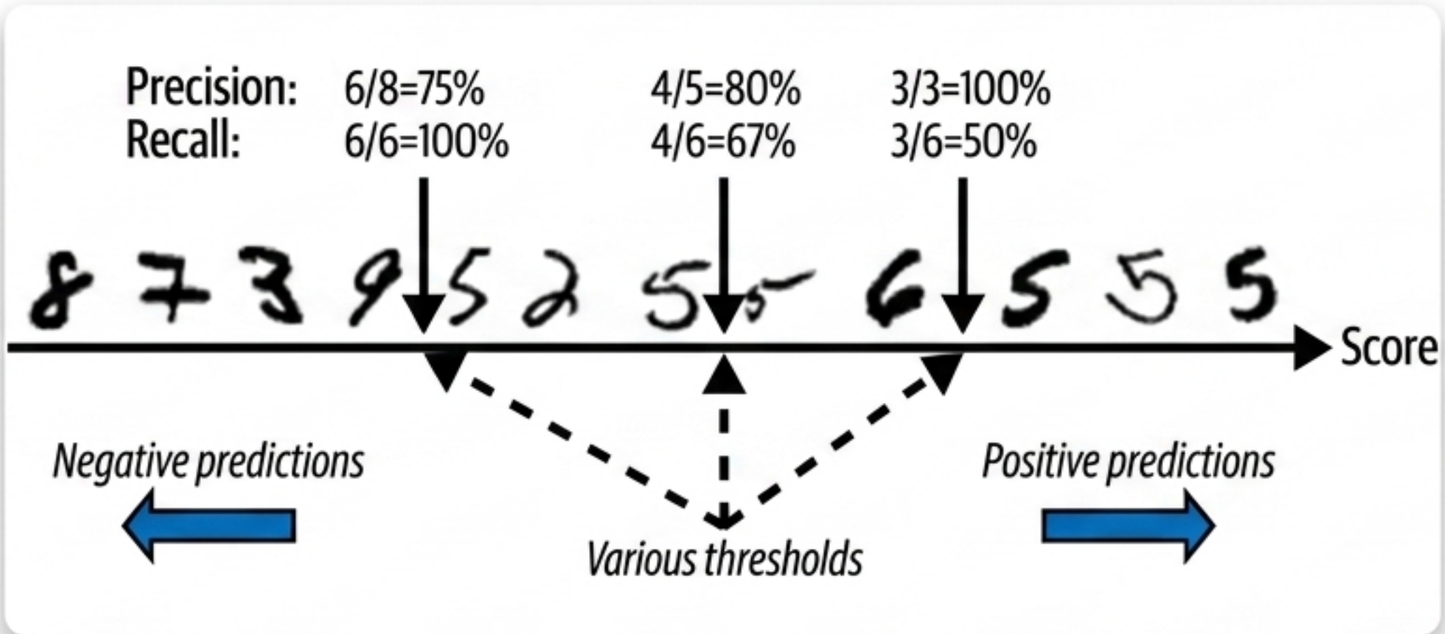

Hình 3-4. Sự đánh đổi độ chính xác/độ nhạy theo ngưỡng quyết định

Tăng ngưỡng:

Giảm False Positive (Precision ↑), nhưng tăng False Negative (Recall ↓).

Giảm ngưỡng:

Giảm False Negative (Recall ↑), nhưng tăng False Positive (Precision ↓).

Gemini Notebook

Chiến lược phân tích biểu đồ

Mục tiêu là chọn được một **Threshold phù hợp nhất với bài toán thực tế**.

Chiến lược 1:
Vẽ Precision và Recall theo từng giá trị ngưỡng (Threshold).
(Giống Hình 3-4)

Chiến lược 2:
Vẽ trực tiếp Precision theo Recall để xem đường tiệm cận.

Điểm vàng: Nên chọn điểm ngưỡng ngay trước khi Precision bị sụt giảm quá mạnh (ví dụ: ở Recall khoảng **60%-80%**).

Gemini Notebook

Phân tích: Precision so với Recall

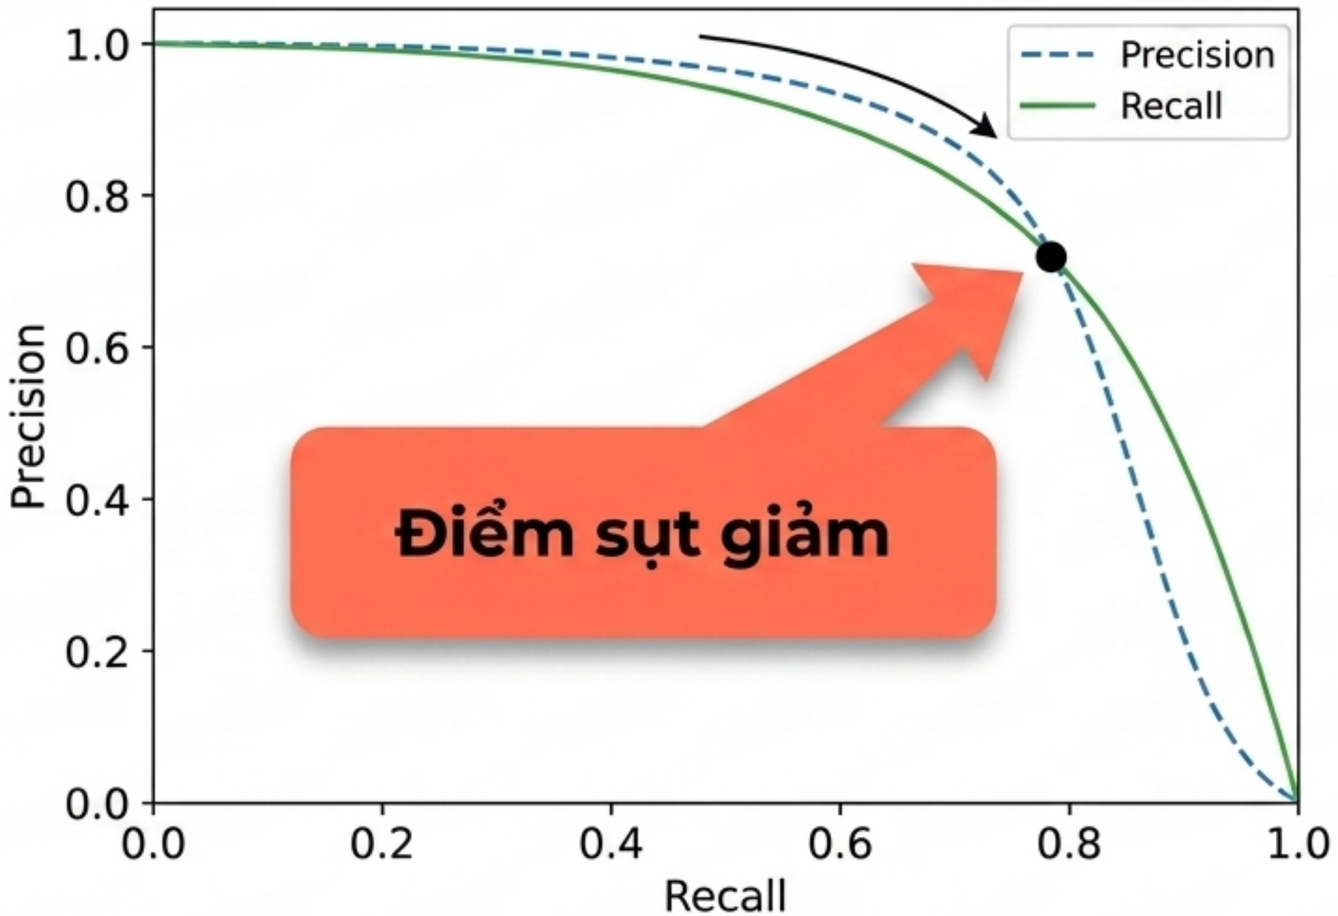

Hình 3-5. Precision và Recall so với Threshold
Hình 3-6. Precision so với Recall

- Đường cong cho thấy Precision bắt đầu giảm mạnh khi Recall vượt mốc ~80%.
- Lựa chọn ngưỡng (**Threshold**) tối ưu nằm ngay trước khúc cua sụt giảm này để cân bằng hiệu suất.

Gemini Notebook

Đường cong ROC (Receiver Operating Characteristic)

Rất phổ biến trong việc đánh giá các bộ phân loại nhị phân.

Trục Y: Tỷ lệ dương tính đúng (TPR / Recall). Độ nhạy của mô hình.

Trục Y

Trục X

Tỷ lệ dương tính giả (FPR FPR / Fall-out). Tỷ lệ các mẫu Âm tính bị nhận diện sai là Dương tính.

Sự đánh đổi cốt lõi: TPR càng cao (mô hình càng nhạy), thì FPR càng cao (càng nhiều báo động giả).

Gemini Notebook

Minh họa Đường cong ROC

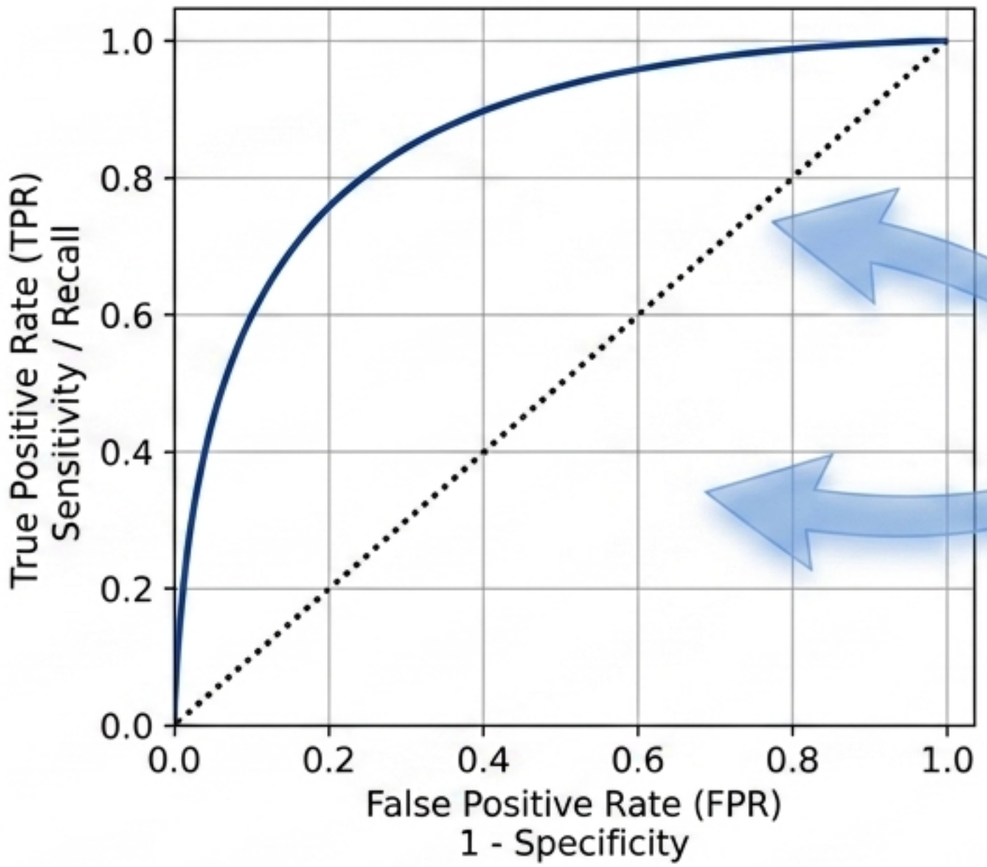

Hình dạng đường cong mô tả trực quan mức độ hiệu quả của mô hình so với một bộ phân loại ngẫu nhiên.

Minh họa: Đường cong ROC

Gemini Notebook

So sánh mô hình bằng ROC AUC

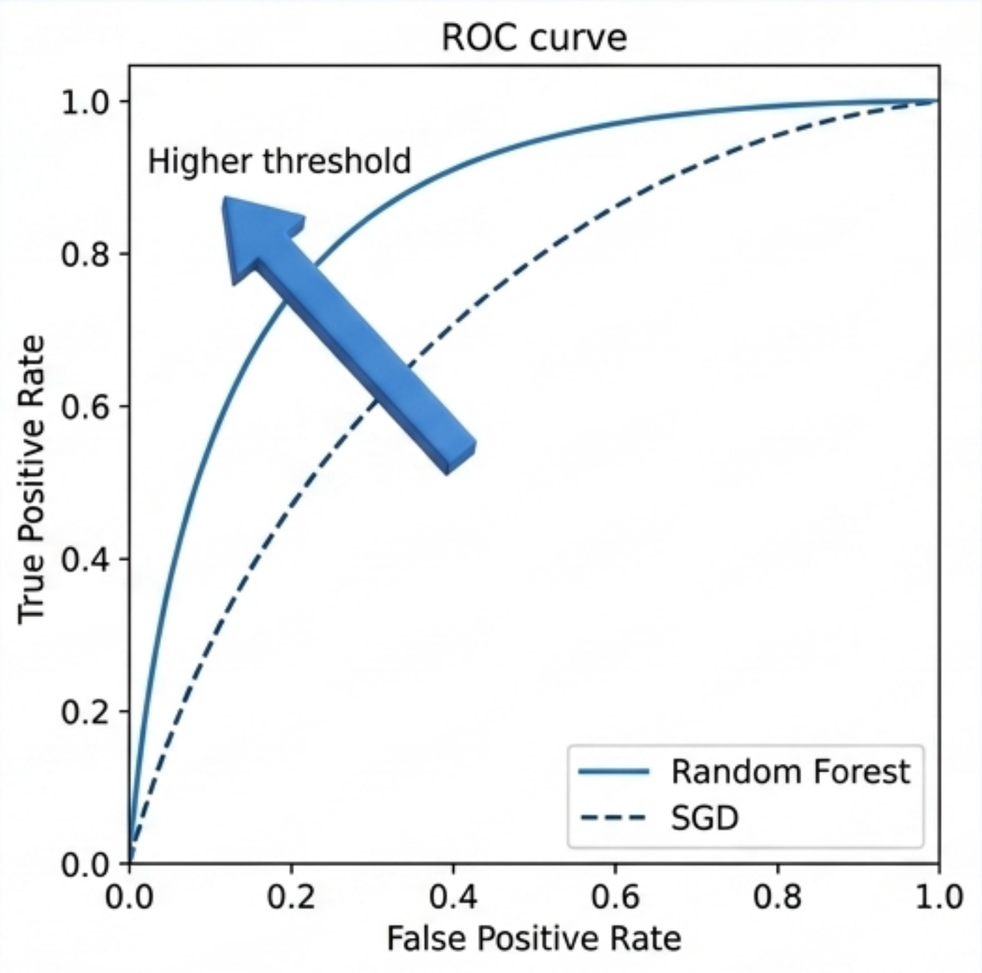

Hình 3-7. Đường cong ROC của mô hình SGD
Hình 3-8. So sánh ROC: SGD vs Random Forest

Versus

Đánh giá Biểu đồ

Observation

- Đường cong của Random Forest (nét liền) đẩy gần về góc trên bên trái hơn so với SGD (nét đứt).

Conclusion

- Random Forest có diện tích dưới đường cong (AUC) lớn hơn, chứng tỏ hiệu suất phân loại ưu việt hơn SGD trong bài toán này.

Gemini Notebook

Mở rộng bài toán: Phân loại đa lớp (Multiclass)

Khái niệm vượt ra ngoài phân loại nhị phân (chỉ có Tích cực/Tiêu cực).

Thách thức: Phân biệt giữa nhiều hơn hai lớp cùng một lúc (Ví dụ: Nhận diện chữ số viết tay từ 0 đến 9).

Gemini Notebook

Chiến lược Một-đối-phần-còn-lại (OvR / OvA)

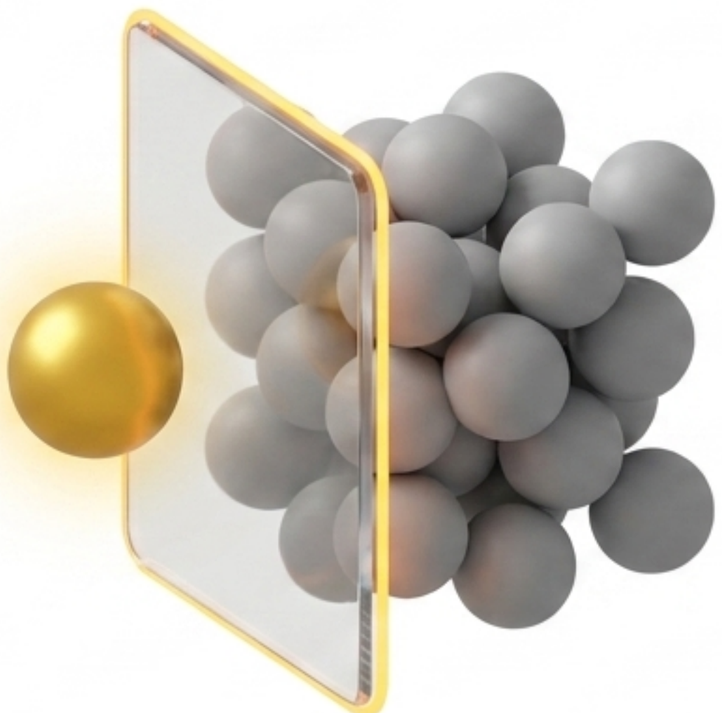

OvR (One-vs-Rest): Huấn luyện nhiều bộ phân loại nhị phân độc lập.

Để nhận diện số từ 0-9:
- Huấn luyện 10 mô hình.
- Mô hình "0": Số 0 vs. Các số còn lại.

Khi phân loại, **lấy điểm quyết định từ cả 10 mô hình và chọn lớp có điểm cao nhất.**

Gemini Notebook

Chiến lược Một-đối-một (OvO)

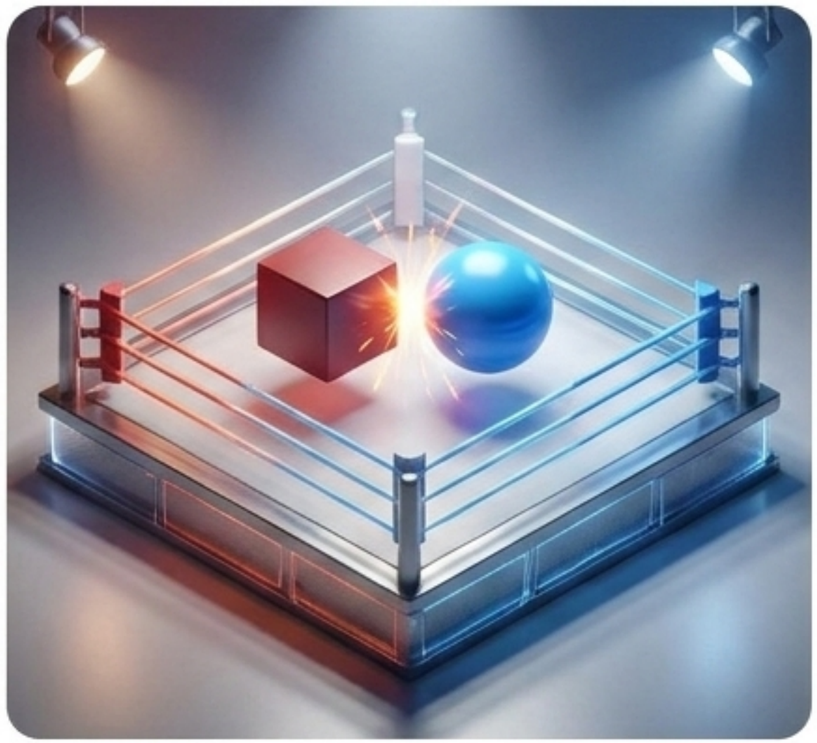

OvO (One-vs-One): Huấn luyện một bộ phân loại nhị phân cho MỖI CẶP nhãn. Ví dụ: 0 vs 1, 0 vs 2, 1 vs 2...

Tổng số mô hình cần huấn luyện:

N × (N - 1) / 2

(Ví dụ: 10 chữ số = 45 bộ phân loại!)

Phù hợp cho các thuật toán khó mở rộng với lượng dữ liệu lớn (như Support Vector Machine - SVC).

Gemini Notebook

Tự động hóa thông minh với Scikit-Learn

Scikit-Learn tự động phát hiện khi ta dùng mô hình nhị phân cho dữ liệu đa lớp.

Thư viện tự động chọn chiến lược OvO hoặc OvR tùy thuộc vào đặc tính của thuật toán.

Ví dụ: Truyền toàn bộ các nhãn y_train (từ 0-9) vào mô hình Support Vector Machine (SVC), hệ thống sẽ tự động huấn luyện bằng phương pháp OvO tối ưu.

Gemini Notebook

Phân loại đa lớp với thuật toán gốc

Một số mô hình sinh ra đã hỗ trợ Phân loại đa lớp. Trong trường hợp này, Scikit-Learn không cần phải tạo ra các thuật toán nhị phân giả lập (OvO/OvR).

`RandomForestClassifier`

`SGDClassifier`

`GaussianNB`

Gemini Notebook

Điểm số quyết định cho dự đoán đa lớp

INPUT

Gọi hàm `decision_function()` cho mô hình đa lớp.

PROCESSING

Mô hình trả về 1 mảng điểm tương ứng với mọi lớp có thể.

OUTPUT

Điểm cao nhất nằm ở vị trí (index) nào thì mô hình sẽ dự đoán ảnh thuộc về lớp đó.

Danh sách các lớp mục tiêu được lưu trong thuộc tính `classes_`.

Gemini Notebook

Đánh giá bộ phân loại đa lớp

Đánh giá

Ta vẫn có thể sử dụng hàm `cross_val_score` để đánh giá độ chính xác như phân loại nhị phân.

Chuẩn bị Dữ liệu

Để cải thiện kết quả, cần kết hợp với các các bước Chuẩn bị Dữ liệu ở Chương 2.

Ví dụ: Chuẩn hóa tỉ lệ các đặc trưng (Feature Scaling) bằng `StandardScaler`.

Gemini Notebook

3. Phân tích Lỗi & Các bài toán nâng cao

Trực quan hóa Ma trận nhầm lẫn đa lớp

1.

Đối với bài toán phân loại đa lớp (10 lớp), **ma trận nhầm lẫn** sẽ có kích thước 10 × 10. Rất khó để nhìn bằng mắt thường.

2.

Cách tốt nhất là trực quan hóa nó bằng **biểu đồ màu (heat map)**. Ở biểu đồ chuẩn, phần lớn dữ liệu hội tụ trên đường chéo (nghĩa là dự đoán đúng).

3.

Để xem phần **LỖI** rõ hơn, ta **tập trung trọng số** vào các ô '**dự đoán sai**'.

Gemini Notebook

Minh họa: Phân tích Ma trận nhầm lẫn

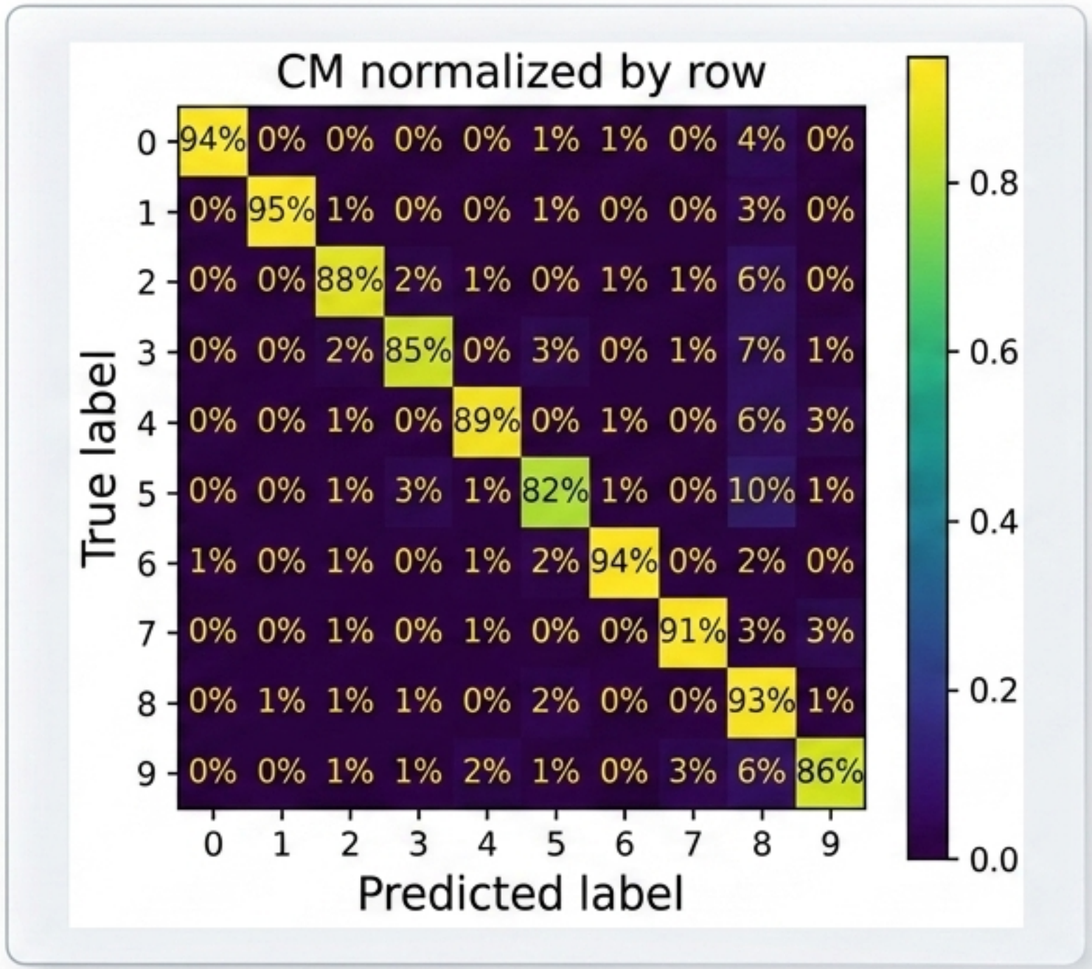

Hình 3-9. Ma trận nhầm lẫn được chuẩn hóa

Gemini Notebook

⚠️ Minh họa: Phân tích Ma trận nhầm lẫn

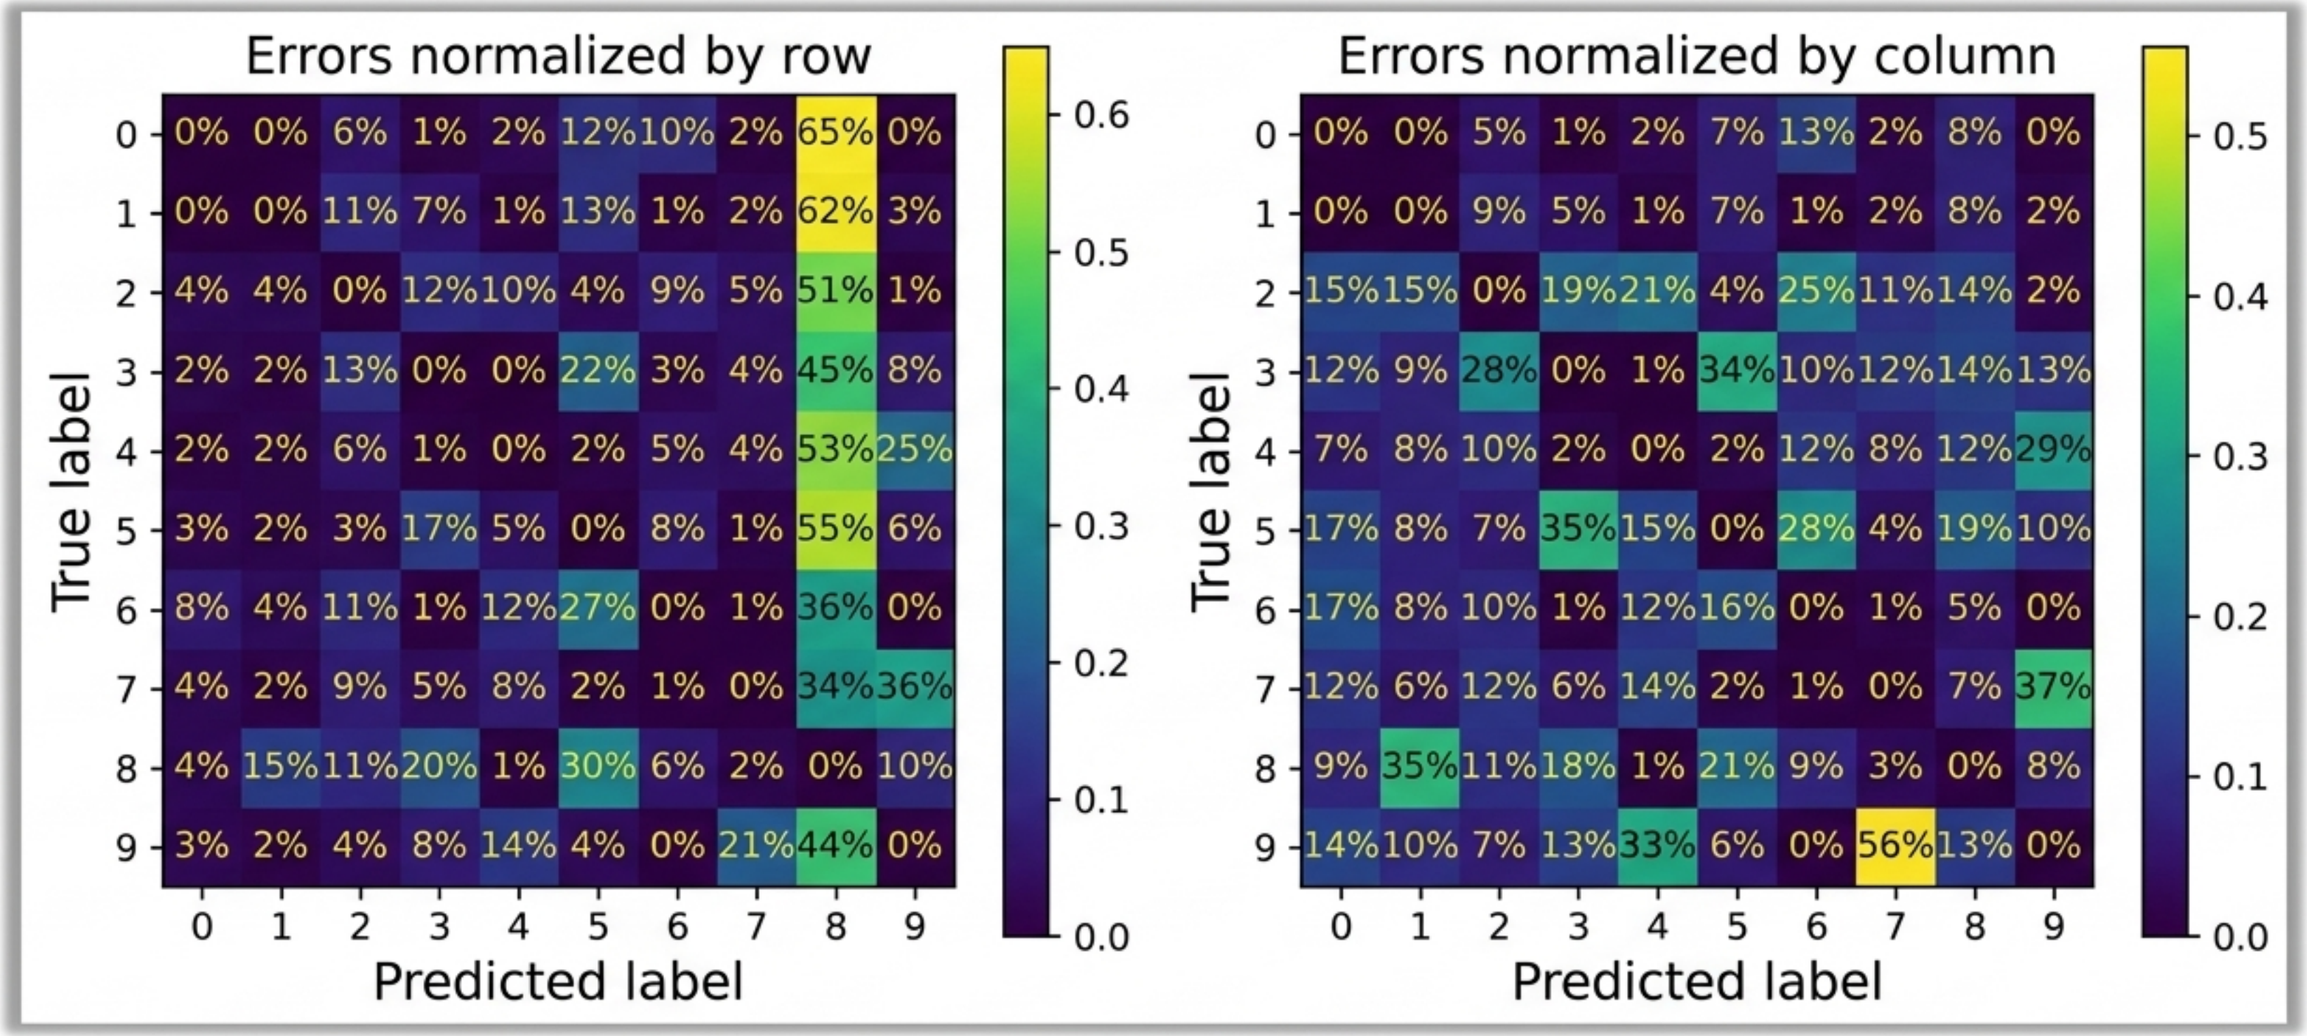

Hình 3-10. Ma trận nhầm lẫn chỉ hiển thị Lỗi

Gemini Notebook

Phân tích lỗi riêng lẻ và cách khắc phục

Problem → Solution

Vấn đề

Nhìn vào biểu đồ lỗi, ta có thể thấy số 8 thường bị nhầm lẫn nhiều nhất.

Cách khắc phục

- Thu thập thêm dữ liệu số 8 để mô hình học rõ hơn.
- Viết thuật toán tạo đặc trưng (ví dụ: đếm số vòng kín của số 8).
- Tiền xử lý hình ảnh, tăng độ tương phản...

Gemini Notebook

So sánh lỗi giữa số 3 và 5

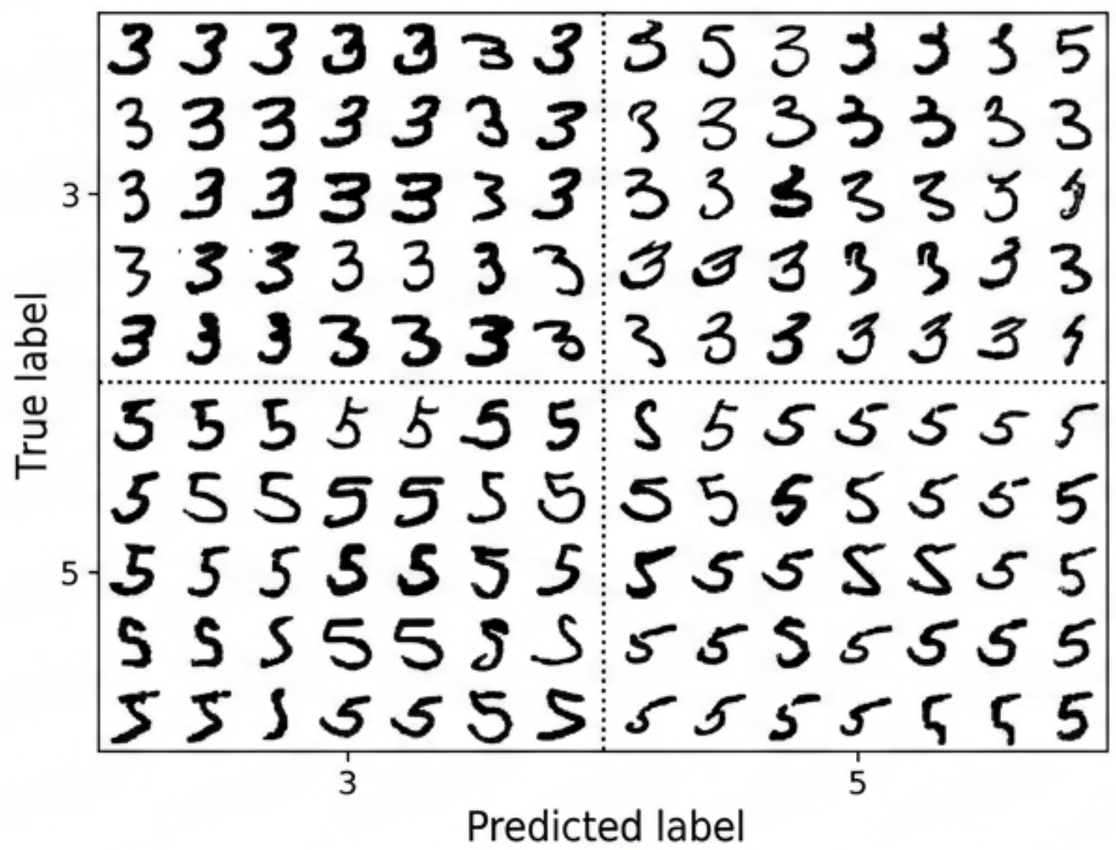

Hình 3-11. Sự nhầm lẫn giữa chữ số 3 và 5

Gemini Notebook

Tăng cường dữ liệu (Data Augmentation)

Mô hình máy học rất nhạy cảm với việc hình ảnh bị lệch (shift) hoặc xoay (rotate).
Giải pháp hiệu quả: Tăng cường dữ liệu (Data Augmentation).

Lấy các bức ảnh huấn luyện gốc.

Biến đổi nhẹ (dịch trái, dịch phải 1 pixel...)

Thêm vào tập huấn luyện, giúp mô hình có khả năng chịu đựng sai số (robust) tốt hơn!

Gemini Notebook

Phân loại Đa nhãn (Multilabel Classification)

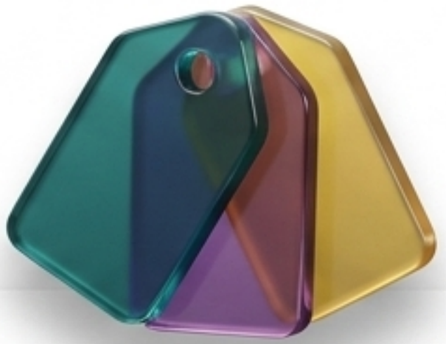

Phân loại Đa nhãn (Multilabel) là gì?

Một mẫu (instance) duy nhất nhưng thuộc về nhiều lớp cùng lúc.

Input

Ví dụ: Nhận diện khuôn mặt. Một bức ảnh có chứa cả Alice và Charlie, nhưng không có Bob.

Output

Đầu ra: Sẽ là một chuỗi cờ Nhị phân (Binary Tags).

`[True]` `[False]` `[True]`

Gemini Notebook

Phân loại Đa nhãn (Multilabel Classification)

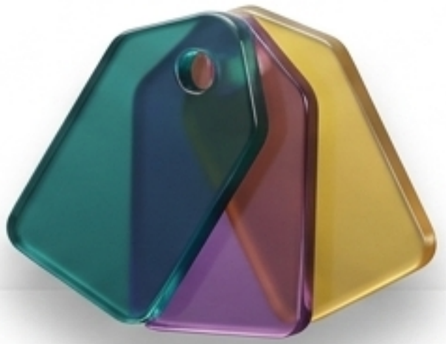

Phân loại Đa nhãn (Multilabel) là gì?

Một mẫu (instance) duy nhất nhưng thuộc về nhiều lớp cùng lúc.

Input

Ví dụ: Nhận diện khuôn mặt. Một bức ảnh có chứa cả Alice và Charlie, nhưng không có Bob.

Output

Đầu ra: Sẽ là một chuỗi cờ Nhị phân (Binary Tags).

`[True]` `[False]` `[True]`

Gemini Notebook

Ví dụ về hệ thống đa nhãn

Áp dụng vào MNIST, đánh giá 2 tiêu chí cùng lúc:

Chữ số đó có lớn không? (7, 8, 9)
→ `y_large`

Chữ số đó có phải là số lẻ không? (1, 3, 5, 7, 9)
→ `y_odd`

Kết hợp 2 nhãn này lại: `y_multilabel`.

Mô hình `KNeighborsClassifier` hỗ trợ xử lý việc này một cách tự nhiên.

Gemini Notebook

Đánh giá hệ thống phân loại đa nhãn

Tính `F1-score` cho từng nhãn (từng tiêu chí) riêng biệt, sau đó lấy trung bình của tất cả các nhãn.

Tùy chọn `average="macro"`

Giả định mọi nhãn quan trọng như nhau.

Tùy chọn `average="weighted"`

Sẽ đánh trọng số dựa trên số lượng mẫu thực tế của từng nhãn (nếu tập dữ liệu bị mất cân bằng).

Gemini Notebook

Phân loại đa nhãn với ClassifierChain

Nếu dùng mô hình như `SVC` (không hỗ trợ multilabel tự nhiên), ta có thể huấn luyện 1 mô hình cho mỗi nhãn. Tuy nhiên, các nhãn có thể phụ thuộc nhau (Ví dụ: số lớn > 7 thì có tỷ lệ số chẵn cao hơn).

Lớp `ClassifierChain` giải quyết bằng cách tổ chức mô hình thành một chuỗi (chain).

Gemini Notebook

Phân loại Đa đầu ra (Multioutput Classification)

Phân loại Đa đầu ra là gì?

Khái quát hóa của Phân loại đa nhãn.

- Đầu ra chứa nhiều nhãn.
- Mỗi nhãn có thể là đa lớp (nhận nhiều giá trị khác nhau).

Gemini Notebook

Ứng dụng: Khử nhiễu hình ảnh (Noise removal)

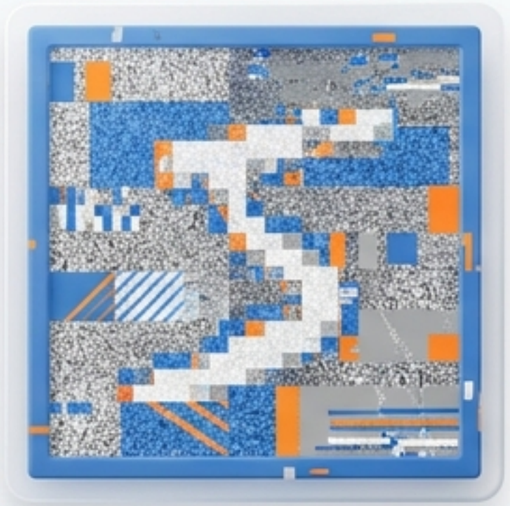

1 bức ảnh MNIST bị làm nhiễu pixel.

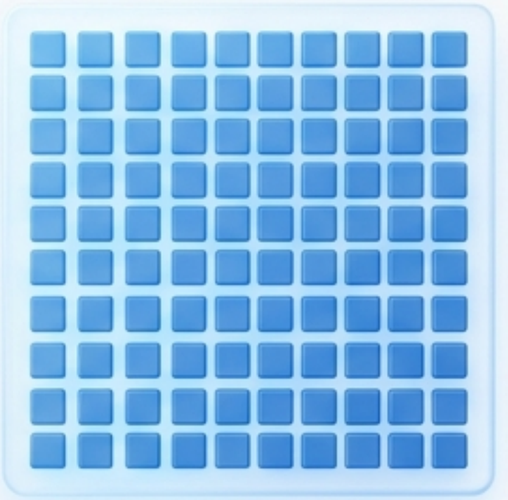

784 pixels. Mỗi pixel (là 1 nhãn) nhận một giá trị từ 0 đến 255 (Đa lớp).

Gemini Notebook

Bài toán khử nhiễu hình ảnh: Phương pháp

Chuẩn bị dữ liệu

Ta cố tình thêm nhiễu (noise) ngẫu nhiên vào dữ liệu huấn luyện.

Xác định mục tiêu

Mục tiêu mong muốn chính là hình ảnh MNIST ban đầu chưa nhiễu.

Huấn luyện mô hình

Mô hình KNeighborsClassifier sẽ học cách so khớp bức ảnh nhiễu và tìm lại bức ảnh gần gốc nhất.

Xem minh họa quá trình thực hiện ở Slide tiếp theo.

Gemini Notebook

Minh họa: Quá trình khử nhiễu

Hình 3-12. Ảnh bị nhiễu và Ảnh mục tiêu

Hình 3-13. Ảnh đã được mô hình làm sạch

Gemini Notebook

Tổng kết Chương 3

Hiểu rõ các chỉ số đánh giá cho Bài toán Phân loại (Precision, Recall, F1, ROC).

Kiểm soát và điều chỉnh được sự đánh đổi Precision/Recall bằng Threshold.

Nắm được quy trình Phân tích lỗi (Error Analysis) qua Ma trận nhầm lẫn.

Áp dụng các kỹ thuật Phân loại Đa lớp (OvR/OvO), Đa nhãn và Đa đầu ra cho các bài toán phức tạp.

Gemini Notebook