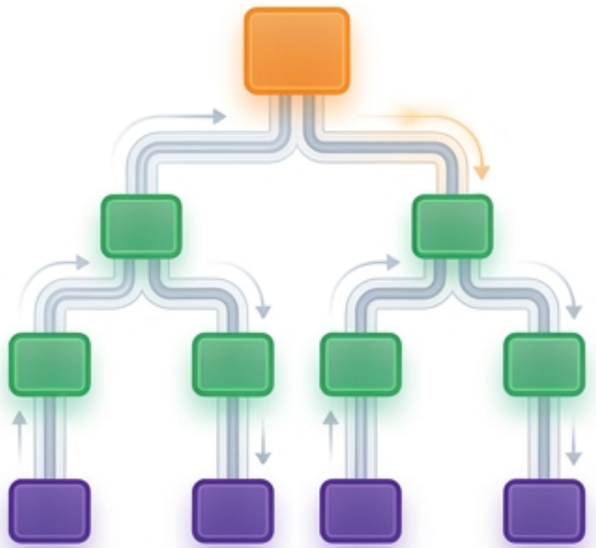

Chương 6: Cây Quyết định (Decision Trees)

Đại học Đông Á

Giảng viên

August 11, 2026

Gemini Notebook

Mục tiêu của Chương

Hiểu thuật toán Cây Quyết định & khả năng dự đoán (Phân loại & Hồi quy).

Nắm bắt thuật toán CART (Classification and Regression Tree) dùng để huấn luyện.

Tìm hiểu về độ vẩn đục: Gini Impurity và Entropy.

Các kỹ thuật **Chính quy hóa** (Regularization) bằng siêu tham số.

Điểm yếu: Phương sai cao (High Variance).

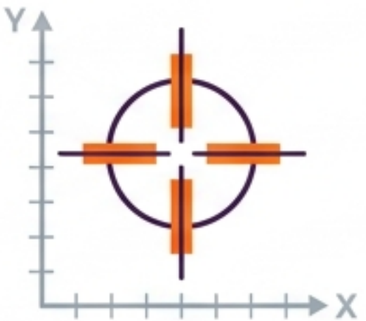

Điểm yếu: Nhạy cảm với hướng trục.

Gemini Notebook

Mục lục

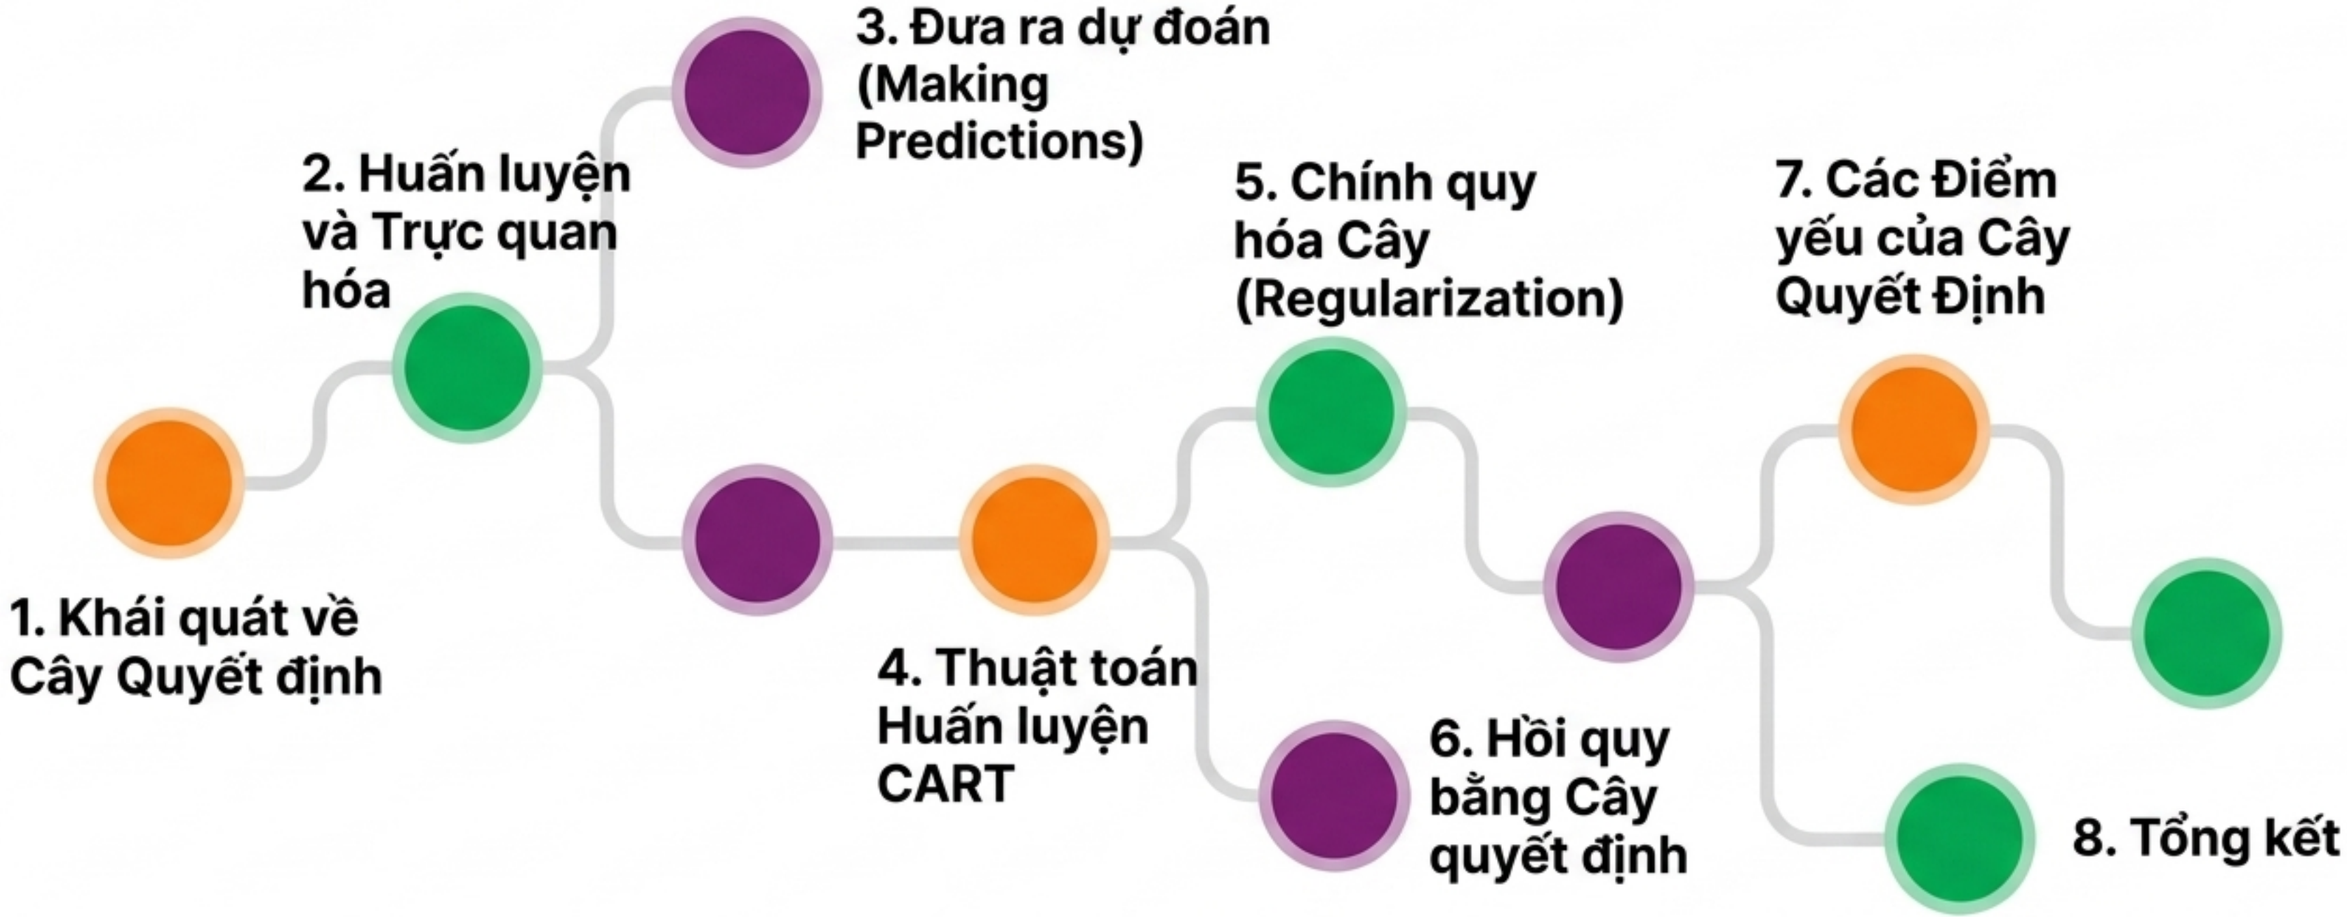

Gemini Notebook

1.1 Sức mạnh của Decision Trees

Đa năng.

Có thể thực hiện cả Phân loại (Classification), Hồi quy (Regression), và học nhiều đầu ra (Multioutput).

Khớp dữ liệu phức tạp.

Xử lý xuất sắc các tập dữ liệu cực kỳ phức tạp (Non-linear datasets).

Thành phần cơ bản (Building block).

Là nền tảng cho các thuật toán cực mạnh.

Nâng cấp.

Ứng dụng trực tiếp vào Random Forest và Gradient Boosting.

Gemini Notebook

1.2 Mô hình Hộp Trắng (White Box Model)

Mô hình Hộp Trắng (Decision Trees)

Điểm sáng giá nhất: Tính dễ diễn giải (Interpretability).

Có thể theo dõi chính xác cách mô hình đi đến kết luận.

Y tế, Tài chính - Nơi cần giải trình quyết định.

Mô hình Hộp Đen

Mạng nơ-ron hay Random Forest.

Rất khó giải thích tại sao mô hình lại đưa ra dự đoán đó.

Gemini Notebook

2.1 Code: Huấn luyện cây quyết định

Sử dụng bộ dữ liệu kinh điển Iris. Chỉ sử dụng 2 đặc trưng: petal length (chiều dài) và petal width (chiều rộng).

```python
from sklearn.datasets import load_iris
from sklearn.tree import DecisionTreeClassifier

iris = load_iris(as_frame=True)
X_iris = iris.data[['petal length (cm)', 'petal width (cm)']].values
y_iris = iris.target

tree_clf = DecisionTreeClassifier(max_depth=2, random_state=42)
tree_clf.fit(X_iris, y_iris)
```

Chỉ lấy 2 features.

Giới hạn độ sâu của cây.

Gemini Notebook

2.2 Code: Xuất biểu đồ cây

Scikit-Learn cung cấp **export_graphviz** để vẽ cây thành file .dot. Dùng Graphviz để chuyển thành ảnh PNG/PDF.

```python
from sklearn.tree import export_graphviz

export_graphviz(tree_clf,
    out_file='iris_tree.dot',
    feature_names=['petal length (cm)',
                   'petal width (cm)'],
    class_names=iris.target_names,
    rounded=True,
    filled=True)
```

```
dot -Tpng iris_tree.dot -o iris_tree.png
```

Gemini Notebook

2.3 Trực quan hóa Cây Iris

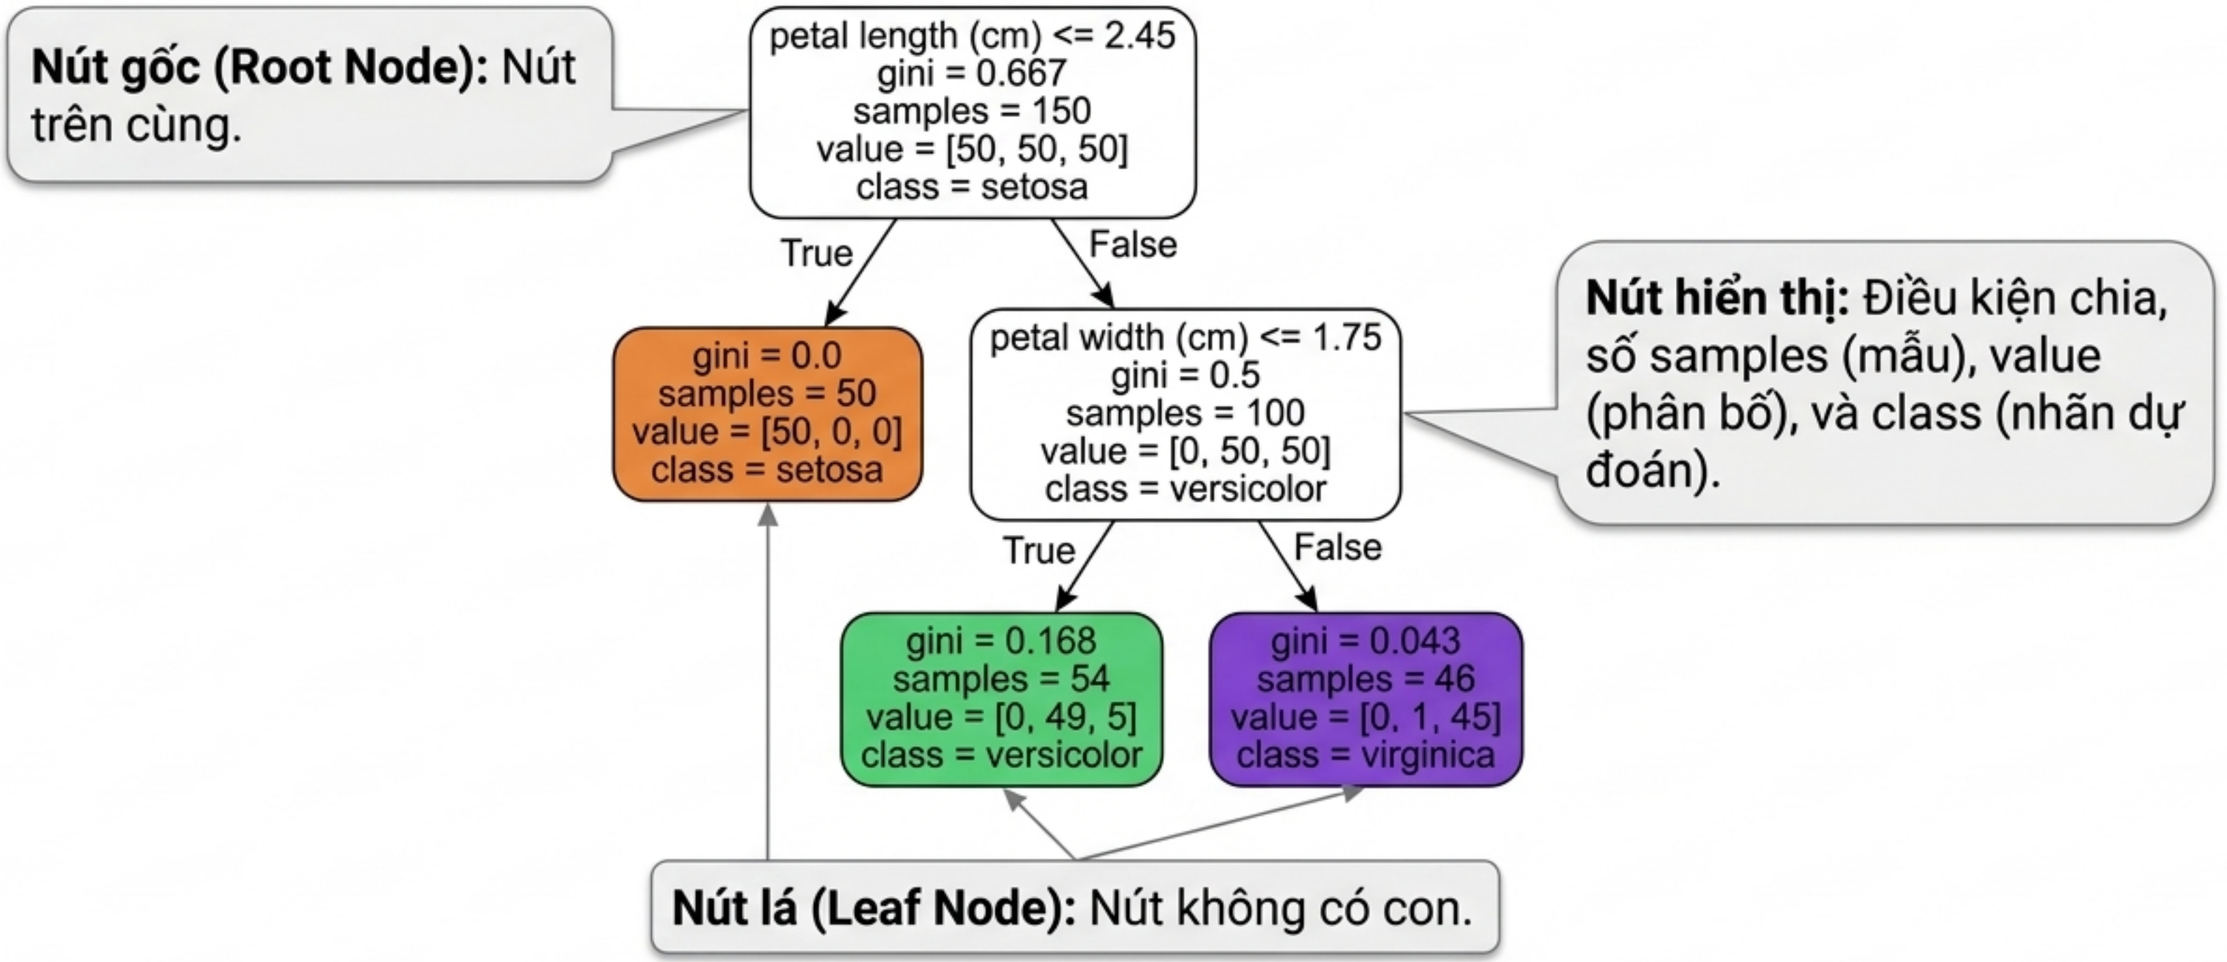

Hình 6-1: Cây Quyết định bộ dữ liệu Iris

Gemini Notebook

3.1 Quá trình đưa ra dự đoán

Bắt đầu duyệt từ **Nút gốc**.

Kiểm tra điều kiện
(VD: petal_length ≤ 2.45 cm).

Nếu **Đúng** (True), đi sang nhánh bên Trái.

Nếu **Sai** (False), đi sang nhánh bên Phải.

Lặp lại đến khi gặp **Nút lá**.

Lớp có số lượng mẫu đông nhất trong nút lá đó sẽ là dự đoán cuối cùng.

Gemini Notebook

3.2 Hiểu về Gini Impurity (Độ vẩn đục Gini)

Tham số gini ở mỗi nút đo lường độ vẩn đục (impurity) của nó. Một nút được gọi là "**thuần khiết**" (pure) nếu gini = 0, nghĩa là mọi mẫu trong nút đó đều thuộc về cùng một lớp.

$$G_i = 1 - \underbrace{\sum (p_{i,k})^2}$$

Trong đó: $p_{i,k}$ là tỷ lệ phần trăm mẫu thuộc lớp k nằm trong nút i.

Gemini Notebook

3.3 Ví dụ tính toán Gini Impurity

gini = 0.168
samples = 54
value = [0, 49, 5]
class = versicolor

Tỷ lệ (p)

p(versicolor) = 49/54

p(virginica) = 5/54

Áp dụng công thức

$$G_i = 1 - \left[\left(\frac{0}{54}\right)^2 + \left(\frac{49}{54}\right)^2 + \left(\frac{5}{54}\right)^2\right]$$

$$G_i \approx 1 - (0 + 0.823 + 0.008)$$

Kết quả

Gi ≈ 0.168 (Trùng khớp với biểu đồ Hình 6-1!)

Gemini Notebook

3.4 Ranh giới Quyết định (Decision Boundaries)

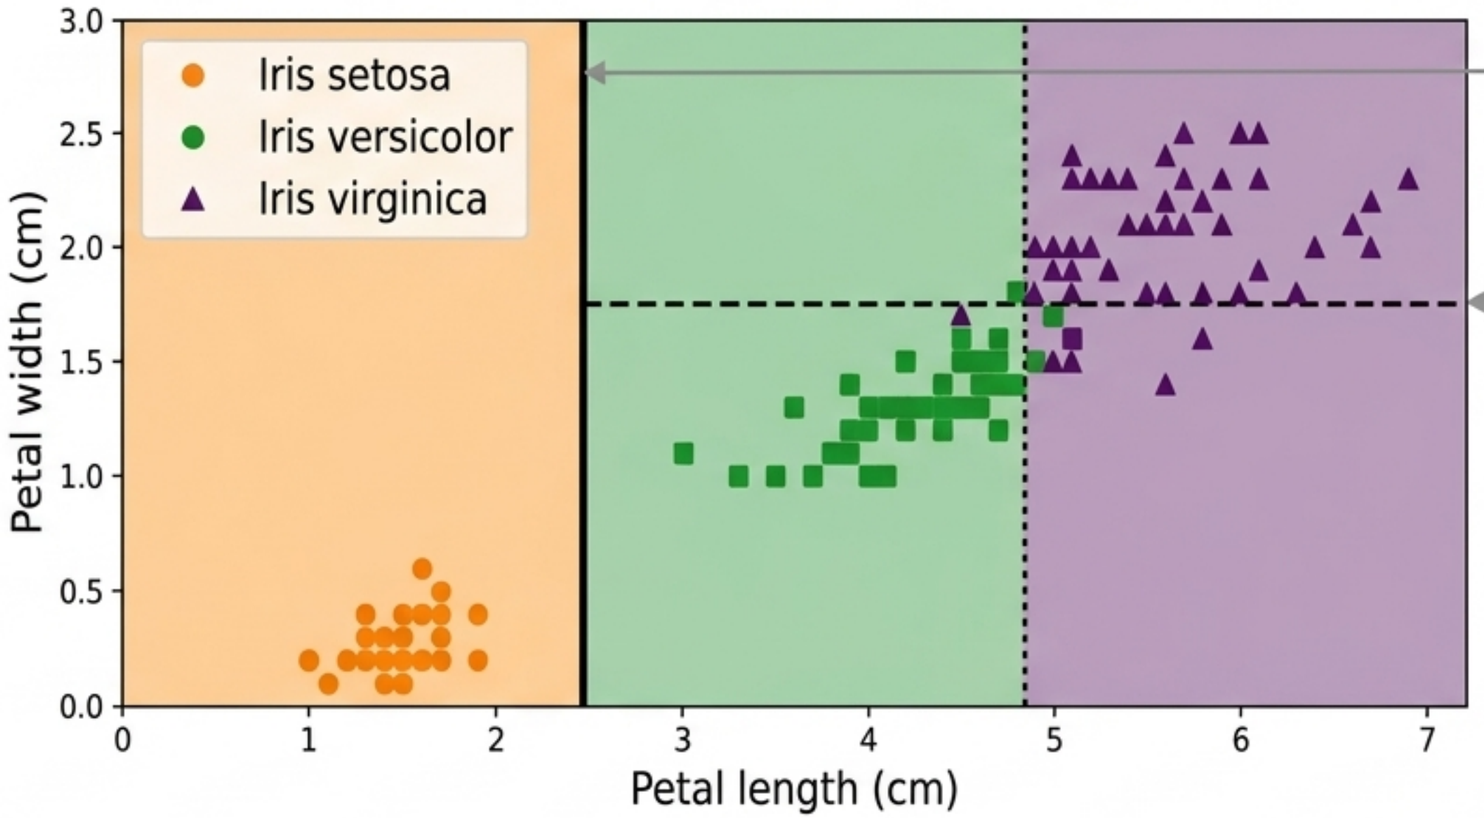

Đường nét đậm ở 2.45 cm (Trục tung) là ranh giới từ nút gốc (Depth=0).

Đường đứt nét ở 1.75 cm (Trục hoành) là ranh giới chia nhánh thứ hai (Depth=1).

Cây luôn tạo ra các đường ranh giới vuông góc với trục tọa độ.

Hình 6-2: Ranh giới quyết định của Cây

Gemini Notebook

3.5 Không cần Chuẩn hóa (Scaling) dữ liệu!

Việc một đặc trưng chạy từ 0-1 còn đặc trưng khác chạy từ 0-1000 không hề ảnh hưởng đến việc phân chia nhánh.

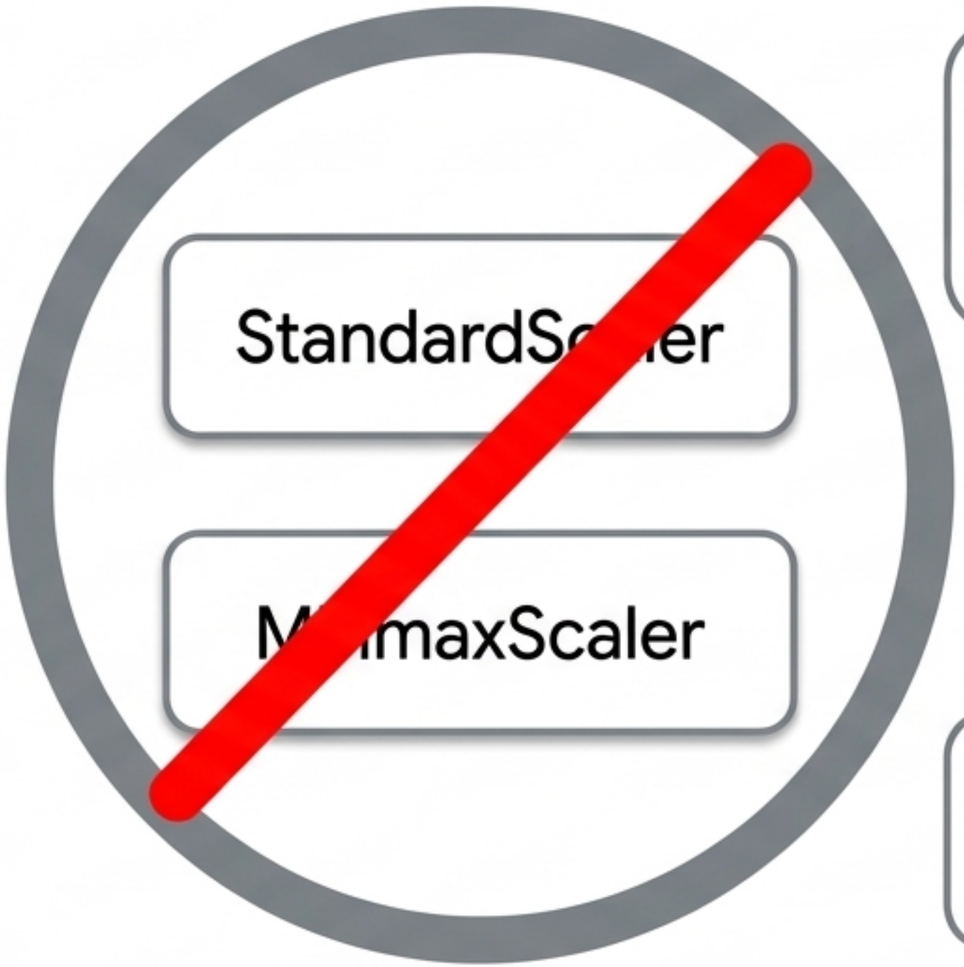

Một ưu điểm tuyệt vời: Nó gần như không yêu cầu tiền xử lý dữ liệu!

Thuật toán chỉ tìm điểm ngưỡng cắt tk.

Gemini Notebook

3.6 Ước tính Xác suất Lớp (Class Probabilities)

Mẫu mới nhập vào
(VD: Bông hoa dài 5cm, rộng 1.5cm).

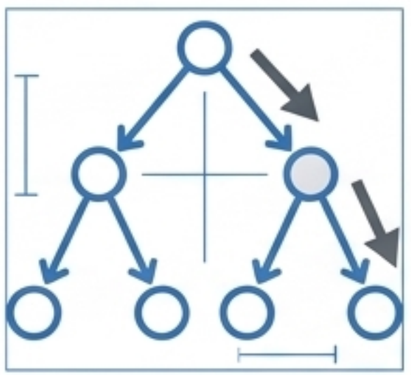

Duyệt từ gốc xuống nút lá tương ứng.

Rơi vào nút lá màu xanh lục (**49** Versicolor, **5** Virginica).

Xác suất: 49/54 ≈ 90.7% cho Versicolor.

Key Takeaway: Xác suất của lớp **k** chính là tỉ lệ mẫu của lớp **k** trên tổng số mẫu tại nút lá đó.

Gemini Notebook

3.7 Code: Dự đoán Xác suất

```
# Du doan xac suat cho 1 bong hoa (petal_length = 5.0, petal_width = 1.5)
probabilities = tree_clf.predict_proba([[5, 1.5]])
print('Xac suat (Setosa, Versi, Virgi):'', probabilities)
# Output: [[0. 0.90740741 0.09259259]]

# Du doan lop (argmax cua xac suat)
pred_class = tree_clf.predict([[5, 1.5]])
print('Lop du doan:', pred_class)
# Output: [1] (tuc la Versicolor)
```

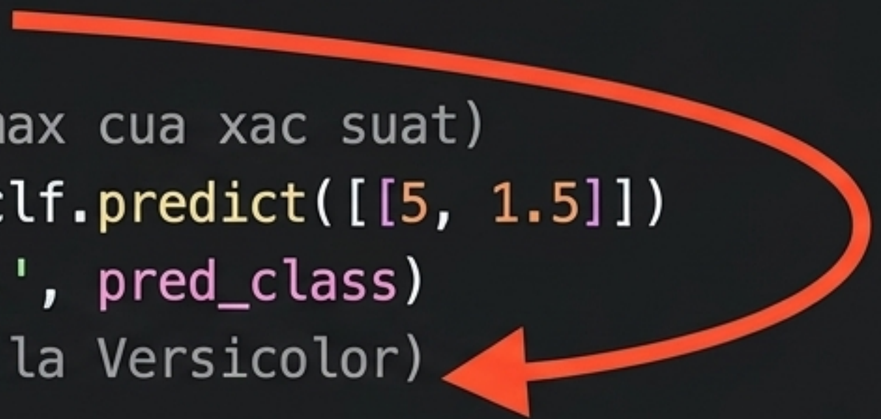

Gemini Notebook

Thuật toán CART là gì?

Bước 1

Phân chia tập huấn luyện thành 2 tập con sử dụng 1 đặc trưng k và ngưỡng t_k.

Bước 2

Chọn k và t_k sao cho tạo ra 2 tập con thuần khiết nhất (Gini Impurity nhỏ nhất).

Bước 3

Lặp lại đệ quy quá trình trên với từng tập con.

Bước 4

Dừng lại khi đạt đến max_depth hoặc không thể giảm thêm độ vẩn đục.

Gemini Notebook

Hàm Chi phí của CART (Phân loại)

$$J(k, t_k) = \frac{m_{left}}{m} G_{left} + \frac{m_{right}}{m} G_{right}$$

G_{left}, G_{right}: Độ vẩn đục Gini của tập con bên trái/phải.

m_{left}, m_{right}: Số lượng mẫu của tập con.

G_{left}, G_{right}: Độ vẩn đục Gini của tập con bên trái/phải.

m: Tổng số lượng mẫu tại nút đang xét.

Thuật toán Tham lam (Greedy Algorithm):
Chỉ tìm kiếm mức phân tách tốt nhất tại hiện tại, không nhìn về tương lai. Không bảo đảm tối ưu cục bộ.

Gemini Notebook

Gini Impurity hay Information Entropy?

Khái niệm

- Mặc định, CART dùng Gini Impurity (criterion="gini"). Có thể đổi sang dùng Entropy (criterion="entropy").
- Trạng thái thuần khiết: Entropy = 0 khi tập hợp hoàn toàn thuần khiết (chỉ chứa 1 lớp).

Công thức Shannon's Entropy:

$$H_i = -\sum_{k=1, p_{i,k} \neq 0}^{n} p_{i,k} \log_2(p_{i,k})$$

Gemini Notebook

So sánh: Gini vs. Entropy

Gini Impurity
(Lựa chọn Mặc định tốt)

- Tính toán nhanh hơn một chút (không chứa phép Logarit).
- Xu hướng: Thường cắt ra nhánh lớn nhất.

Information Entropy

- Tính toán chậm hơn.
- Xu hướng: Tạo ra các cây cân bằng hơn (balanced trees).

Kết luận: Trong hầu hết mọi trường hợp, Gini và Entropy tạo ra những cây rất giống nhau.

Gemini Notebook

Độ phức tạp Thời gian (Time Complexity)

Quá trình Suy luận (Dự đoán) - Cực Nhanh

- Phải duyệt từ gốc đến lá.
- Độ sâu cây: $O(\log_2(m))$
- Phức tạp dự đoán: $O(\log_2(m))$
  (Độc lập với số lượng đặc trưng!)

Quá trình Huấn luyện - Rất Chậm (với dữ liệu lớn)

- Thuật toán so sánh mọi đặc trưng trên mọi ngưỡng.
- Phức tạp thời gian:
  $O(n \times m \log_2(m))$
- Rất chậm đối với các tập dữ liệu có m lớn (Hàng triệu dòng).

Gemini Notebook

Tại sao phải Chính quy hóa?

Bản chất (Mô hình Non-parametric):
Số lượng tham số không được ấn định trước.
Mô hình phát triển tự do theo dữ liệu.

↓

Hậu quả (Không có giới hạn):
Cây cố phân nhánh đến khi mỗi chiếc lá
chỉ có 1 điểm duy nhất.

↓

Thực tế:
Tương đương việc ghi nhớ học vẹt bộ dữ liệu.

↓

Kết quả cuối cùng:
Gây ra hiện tượng Overfitting cực kỳ nghiêm trọng.

Gemini Notebook

Các Siêu tham số Chính quy hóa

max_depth

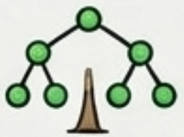

Độ sâu tối đa của cây (Default: None).

← Giảm để hạn chế Overfitting.

min_samples_split

Số lượng mẫu tối thiểu một nút phải có trước khi được phân chia.

min_samples_leaf

Số mẫu tối thiểu một nút lá phải có.

max_features

Số lượng đặc trưng tối đa được xem xét tại mỗi lần chia.

max_leaf_nodes

Số lượng nút lá tối đa.

Gemini Notebook

Hiệu ứng của Chính quy hóa

Cây không giới hạn

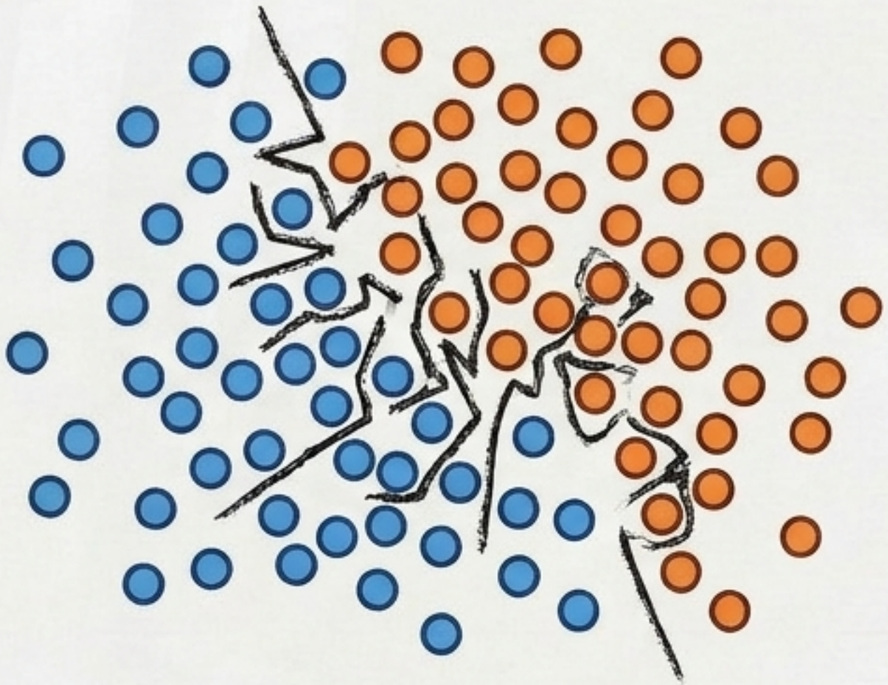

min_samples_leaf=1

→ Ranh giới ngoằn ngoèo, Overfitting nghiêm trọng.

Cây bị ràng buộc

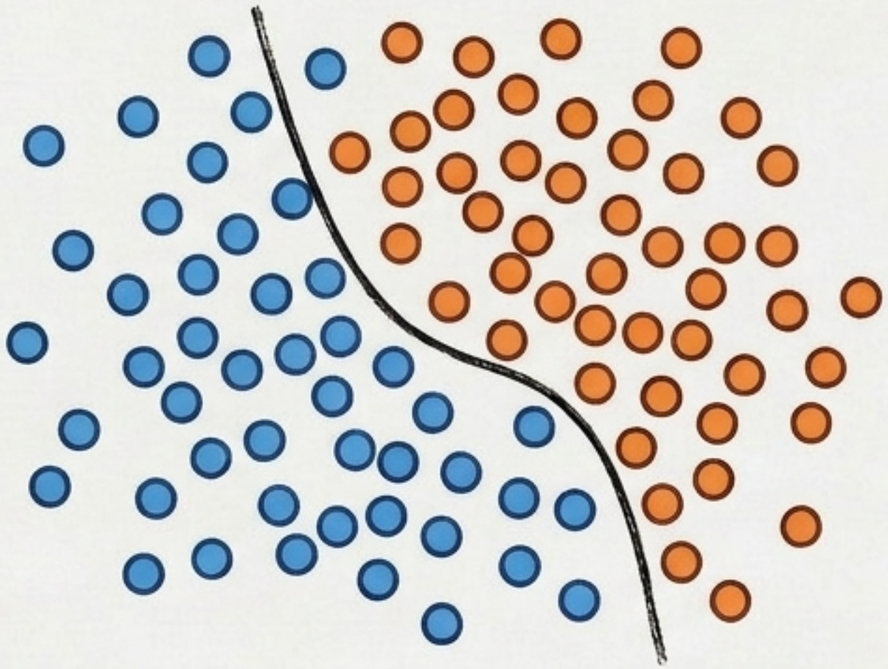

min_samples_leaf=4

→ Ranh giới mượt mà hơn, khả năng tổng quát hóa (Generalization) tốt hơn trên dữ liệu mới.

Hình 6-3: Cây không chính quy (trái) vs Chính quy hóa (phải).

Gemini Notebook

Lớp DecisionTreeRegressor (Hồi quy)

Cây quyết định cũng giải quyết xuất sắc các bài toán Hồi quy.

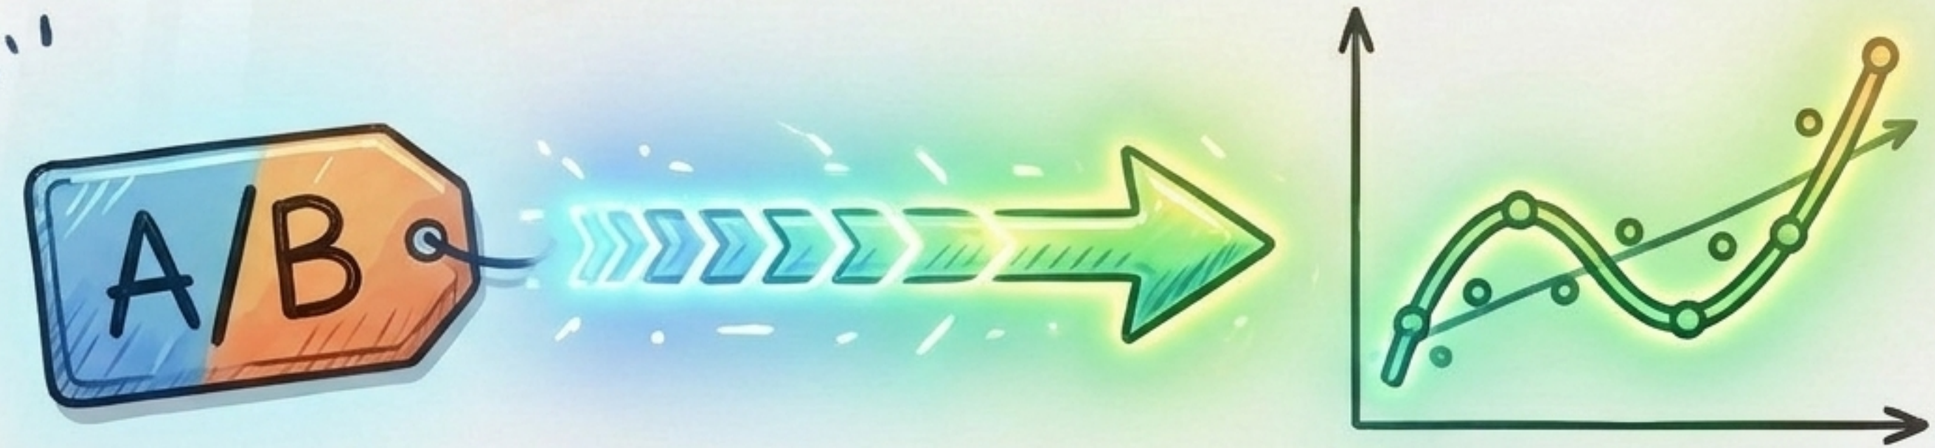

Sự khác biệt cốt lõi:

- Thay vì dự đoán một nhãn lớp...
- Nút lá dự đoán một giá trị liên tục(Trung bình cộng của tất cả các mẫu nằm trong lá đó).

Hàm mục tiêu:

Sử dụng MSE (Mean Squared Error) để tối ưu.

Gemini Notebook

Code Python: Hồi quy dữ liệu Quadratic

```python
import numpy as np
from sklearn.tree import DecisionTreeRegressor

# Tạo du lieu mỡ phong y = x^2 + nhiều
np.random.seed(42)
X_quad = np.random.rand(200, 1) - 0.5
y_quad = X_quad ** 2 + 0.025 * np.random.randn(200, 1)

# Huấn luyện cay họi quy (Giỏi hạn max_depth)
tree_reg = DecisionTreeRegressor(max_depth=2, random_state=42)
tree_reg.fit(X_quad, y_quad)
```

Gemini Notebook

Trực quan hóa Cây Hồi quy

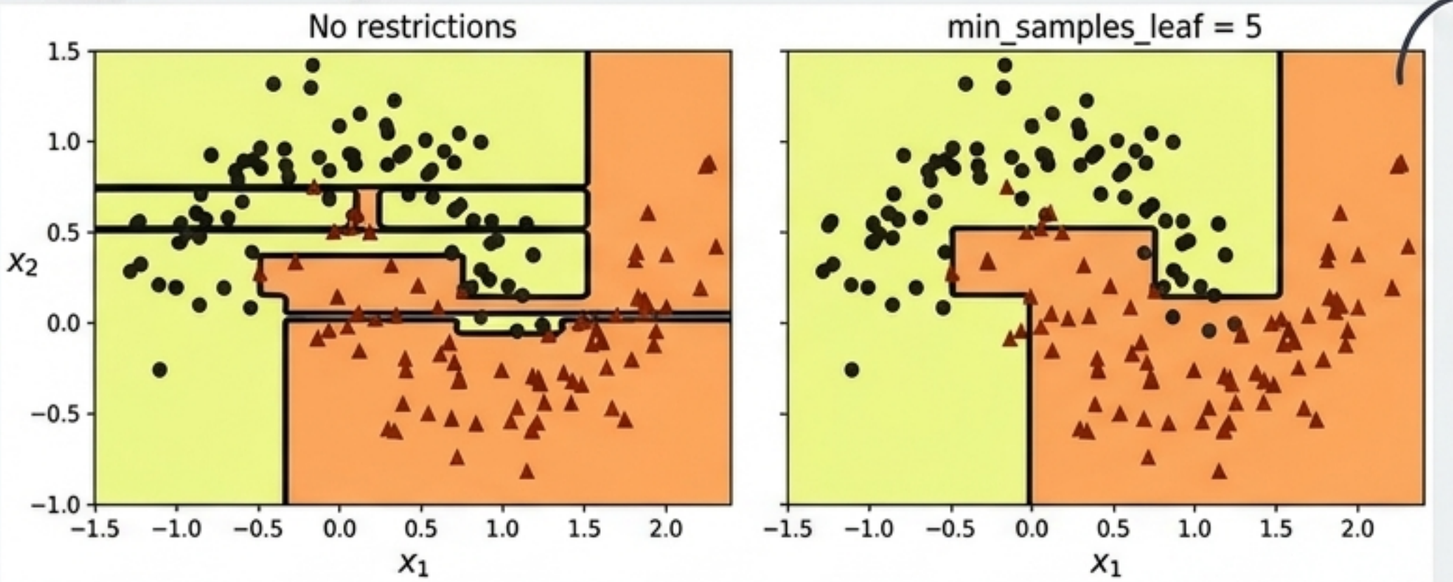

Hình 6-4: Sơ đồ Decision Tree Regression

Giải nghĩa Nút lá:

value: Chính là y trung bình của các mẫu rơi vào lá đó.

mse: Mean Squared Error (sai số tại nút đó).

Bản chất Dự đoán:

Mang dạng các bậc thang (step-wise) vì trong cùng 1 khoảng chia, mọi giá trị x đều trả ra cùng 1 mức y.

Gemini Notebook

Các Ranh giới Hồi quy (Bậc thang)

Bản chất: Cây phân chia không gian thành các mảng và dự đoán y là đường thẳng hằng số trên từng mảng.

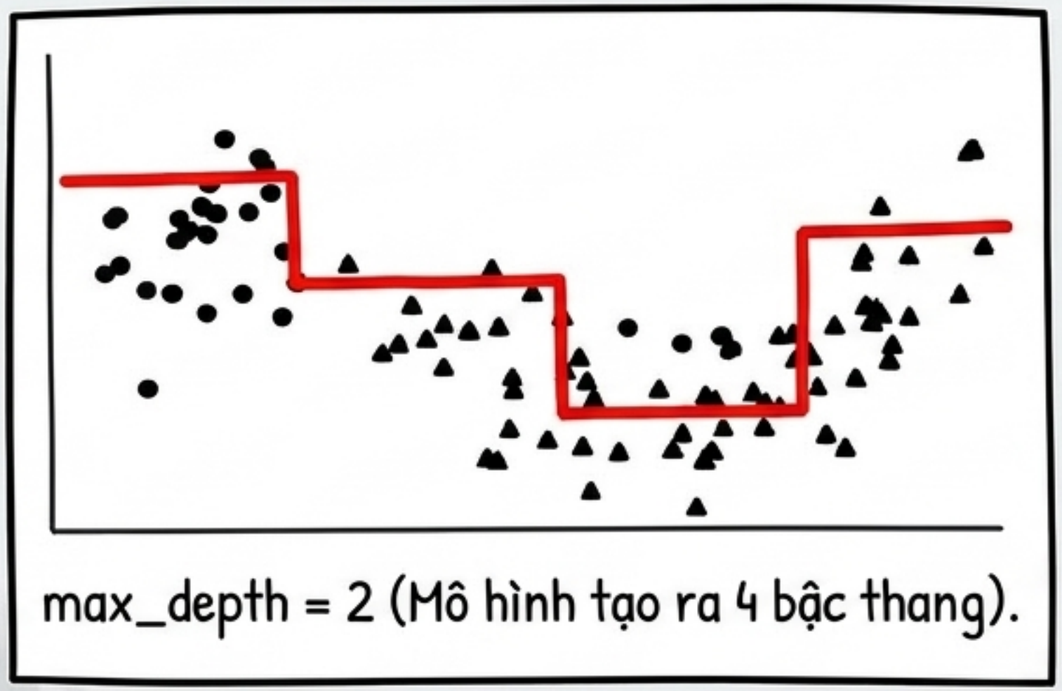

max_depth = 2 (Mô hình tạo ra 4 bậc thang).

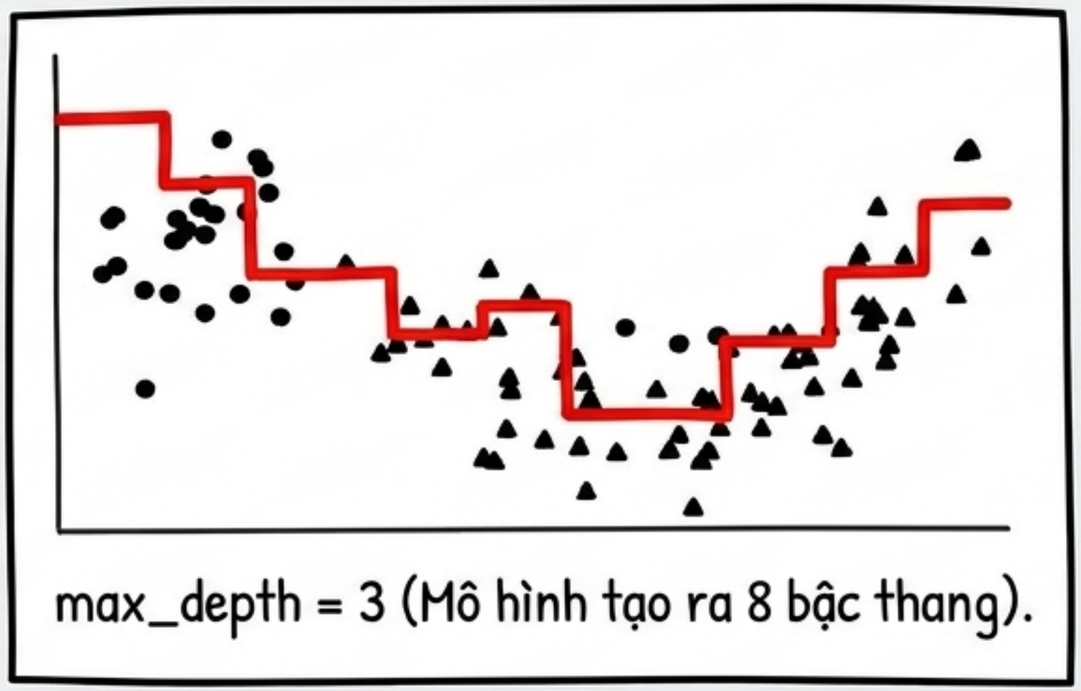

max_depth = 3 (Mô hình tạo ra 8 bậc thang).

Hình 6-5: Hàm dự đoán của Cây Hồi quy.

Gemini Notebook

Overfitting trong Hồi quy

Vấn đề (Overfitting):

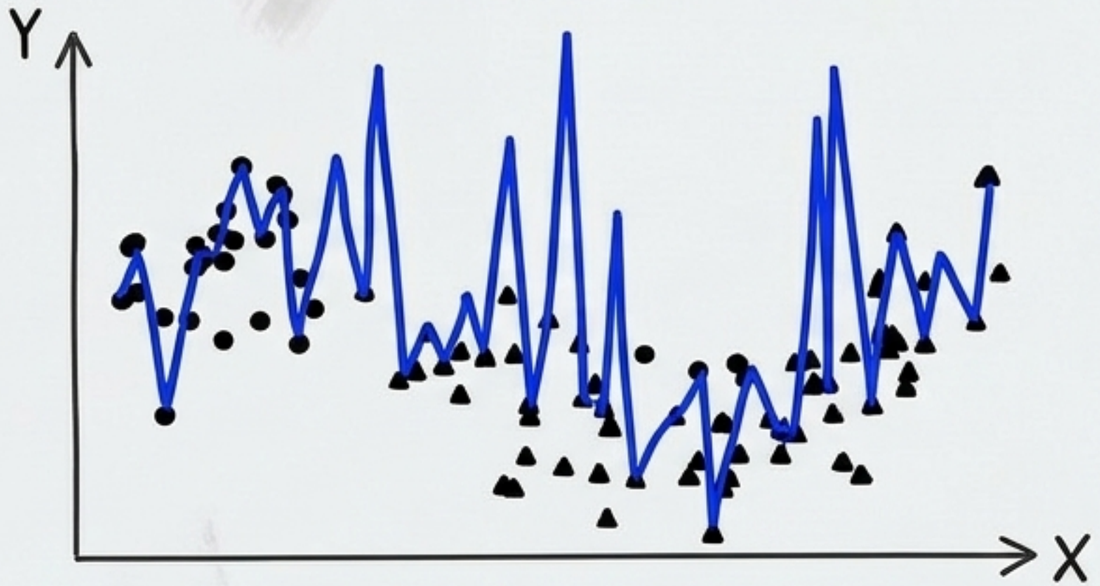

Cây Hồi quy rất dễ bị Overfitting nếu không ràng buộc. Cây sẽ uốn éo đứt đoạn để đi qua toàn bộ các nhiễu dữ liệu.

Khắc phục (Regularization):

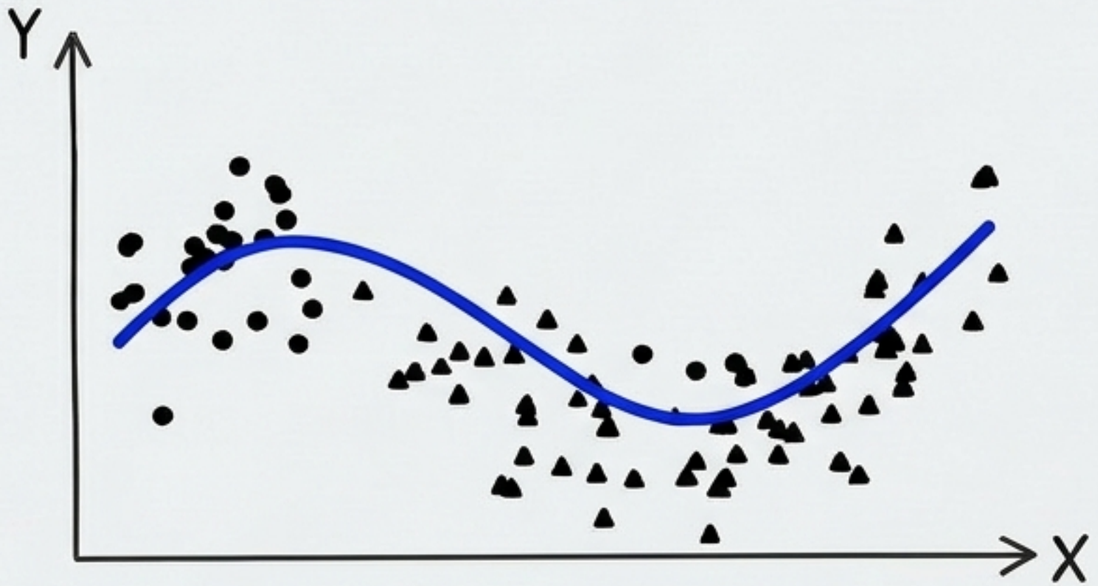

Dùng min_samples_leaf=10 để ép mô hình mượt mà hơn.

Gemini Notebook

Hàm Chi phí CART cho Hồi quy

Thuật toán CART tối thiểu hóa sai số MSE (thay vì Gini Impurity):

$$J(k, t_k) = \frac{m_{left}}{m} MSE_{left} + \frac{m_{right}}{m} MSE_{right}$$

Trong đó:

$$MSE_{node} = \frac{1}{m_{node}} \sum_{i \in node} (\hat{y}_{node} - y^{(i)})^2$$

Ghi chú: $\hat{y}_{node}$ luôn là Trung bình cộng của các mẫu trong lá.

Gemini Notebook

Hạn chế: Trục chia vuông góc

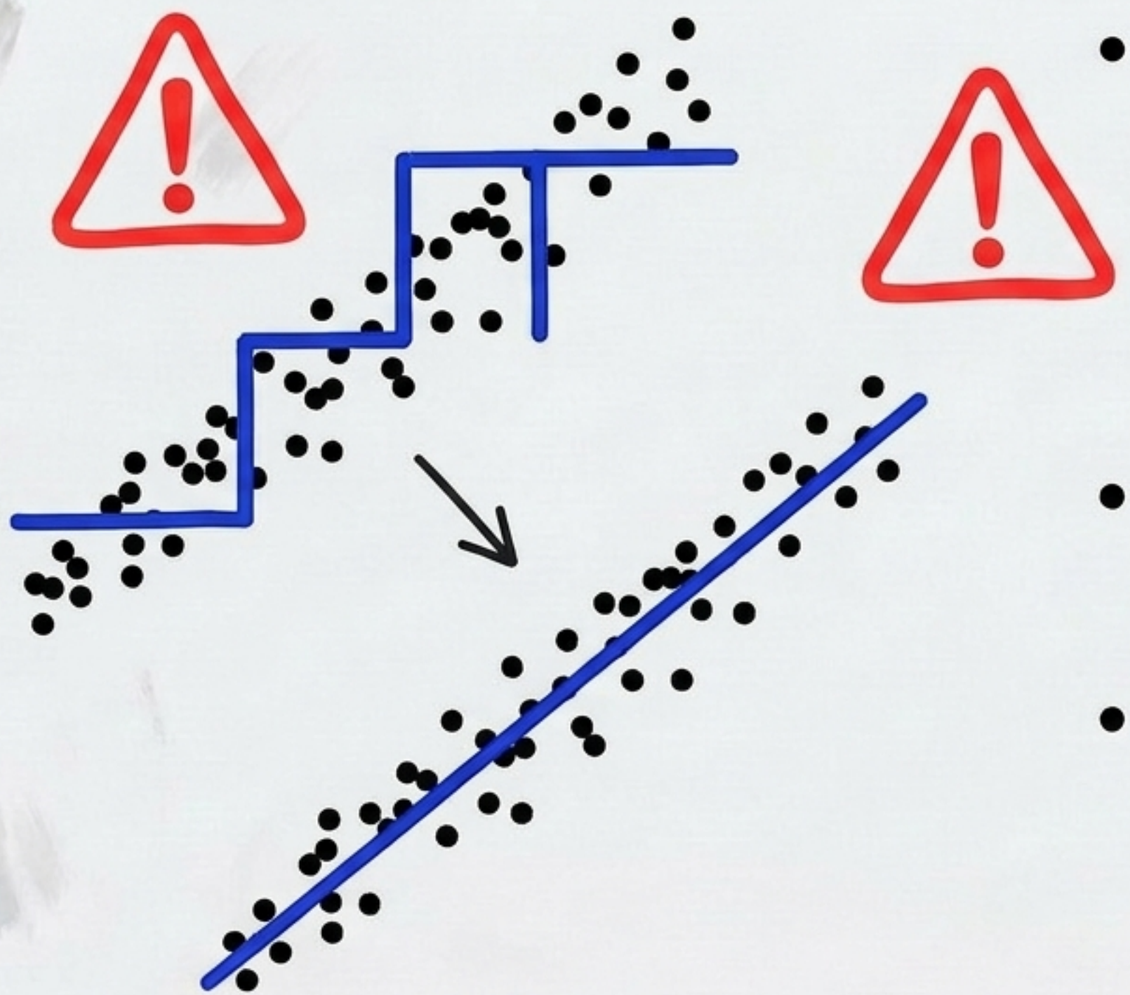

- **Orthogonal splits:** Cây quyết định yêu yêu thích sự đơn giản luôn phân chia tập dữ liệu bằng các đường song song hoặc vuông góc với trục tọa độ.
- **Hạn chế:** Không thể vẽ đường chéo hay đường cong!
- **Hệ quả:** Dẫn đến sự nhạy cảm cực độ đối với Hướng Xoay của Dữ liệu (Axis Orientation).

Gemini Notebook

Máy học đại học - Chương 6 (Phần 3)

Phân tích Chuyên sâu Cây Quyết Định & Khu Rừng Ngẫu Nhiên (Random Forest)

Gemini Notebook

Nhạy cảm với Xoay trục tọa độ

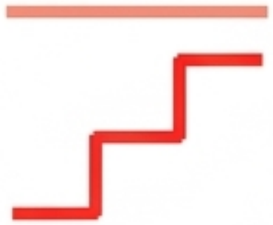

Hình Trái: Dữ liệu phân tách tuyệt đẹp bằng 1 đường thẳng ngang (Cây sâu 1 tầng).

Hình Phải: Cùng bộ dữ liệu nhưng xoay 45 độ. Cây buộc phải chia cắt thành vô vàn đường cầu thang ziczac dốc để xấp xỉ một đường chéo.

Kết quả: Cây rườm rà, tổng quát hóa kém.

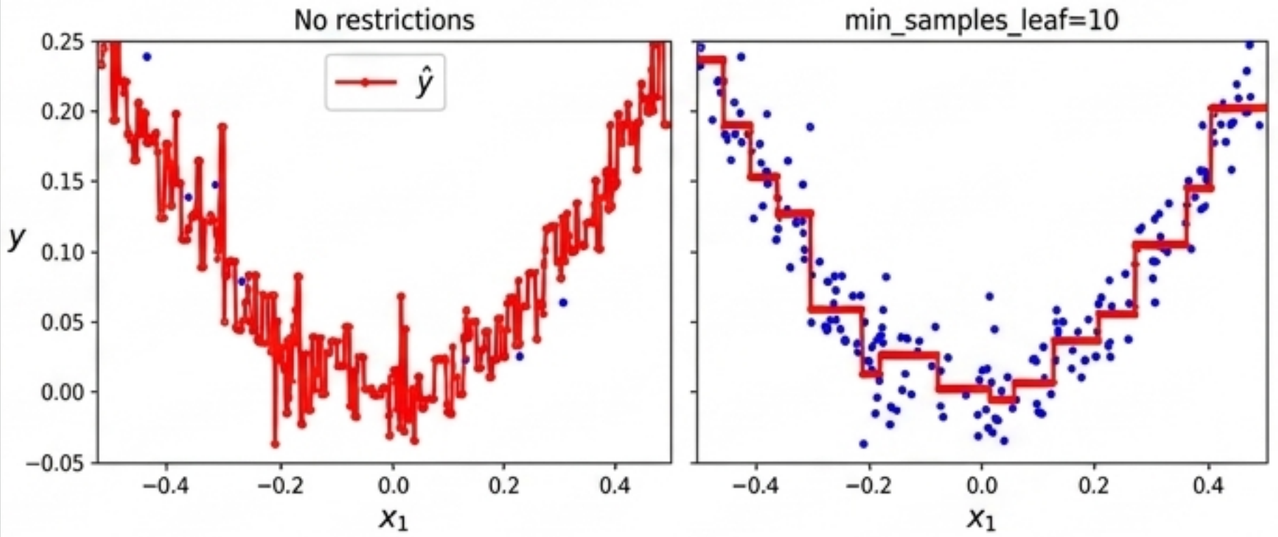

Hình 6-6: Độ nhạy cảm với trục xoay dữ liệu

Gemini Notebook

Khắc phục Bằng PCA (Phân tích Thành phần Chính)

Bước 1: Tiền xử lý dữ liệu bằng PCA.

Bước 2: Xoay tập dữ liệu về trạng thái phương sai lớn nhất trên các trục tọa độ.

Bước 3: Giới hạn khả năng cây bị bóp méo thành đường cầu thang.

(Tham chiếu: Hình 6-7: Cây phân loại sau khi xoay bằng PCA)

Gemini Notebook

Vấn đề Cốt lõi: Phương sai cao (High Variance)

Tính không ổn định cực cao: Vấn đề lớn nhất của Cây Quyết định.

(Nhiễu loạn siêu nhỏ)

(Thay đổi toàn cục)

Bản chất Tham lam: Vì là thuật toán tham lam (không kiểm tra lại toàn bộ tương lai), một thay đổi vô cùng nhỏ trong tập huấn luyện có thể tạo ra một cây hoàn toàn khác biệt.

Hiệu ứng Dây chuyền: Một nhiễu loạn ngẫu nhiên nhỏ xíu ở nút gốc sẽ làm toàn bộ các nút con thay đổi.

Gemini Notebook

Ví dụ Thực tế về High Variance (Dữ liệu Iris)

Hành động: Xóa đúng 1 bông hoa Versicolor to nhất (Dài 4.8cm, rộng 1.8cm).

Hậu quả: Cây mới học được đã chia cắt dữ liệu theo ranh giới khác hoàn toàn so với cây ban đầu (Hình 6-2).

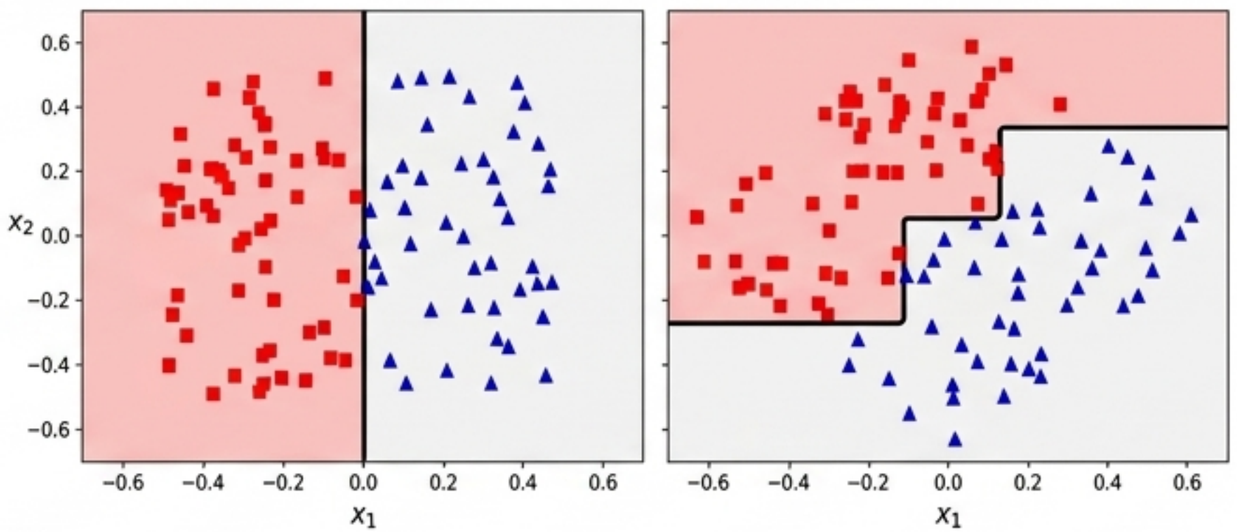

Hình 6-8: Cây bị méo mó chỉ sau khi xóa 1 điểm

Gemini Notebook

Ngẫu nhiên tính trong Huấn luyện

Cơ chế của Scikit-Learn: Ngay cả khi không xóa dữ liệu, Scikit-Learn vẫn chọn đặc trưng ngẫu nhiên để tăng tốc độ phân chia. Huấn luyện cùng 1 tập dữ liệu 2 lần có thể ra 2 kết quả khác nhau (Nếu không set random_state=42).

Nhận định:

Sự ngẫu nhiên và Phương sai cao này thoạt nghe có vẻ là điểm yếu chí mạng...

Gemini Notebook

Từ Điểm yếu trở thành Siêu Vị Thần

+

Hàng nghìn cây phương sai cao & độc lập = **Khu rừng ổn định** (Random Forest)

Thay vì dùng 1 cái cây không ổn định, ta trung bình hóa dự đoán của một Khu Rừng (Forest). Kết quả là một trong những thuật toán ML vĩ đại nhất lịch sử ra đời!

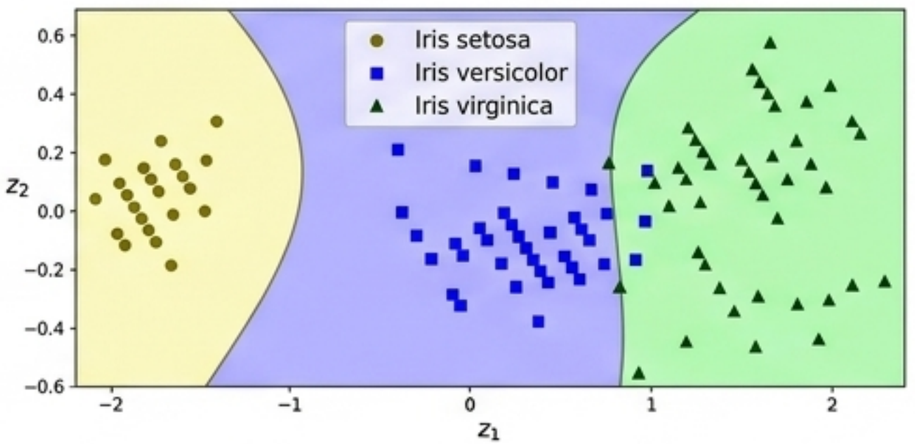

Hình 6-9: Khu rừng Random Forest (Chương 7)

Gemini Notebook

Tổng kết: Ưu điểm của Cây Quyết Định

Dễ hiểu, Dễ giải thích: Có thể xuất ra dạng quy tắc (If-Else) hoặc sơ đồ luồng.

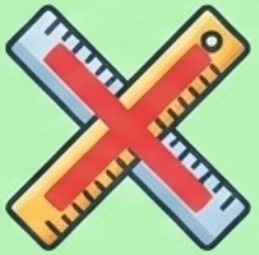

Không yêu cầu Chuẩn hóa: Hoạt động tốt ngay cả khi các biến khác đơn vị, hoặc lẫn lộn chữ và số.

Xử lý Phi tuyến tính: Cắt xẻ không gian tọa độ cực tốt, khớp với ranh giới phức tạp.

Nhanh ở khâu Dự đoán: Suy luận với tốc độ Logarit O(log2 m).

Gemini Notebook

Tổng kết: Nhược điểm của Cây Quyết Định

Overfitting nặng nề: Thích ôm chặt lấy dữ liệu huấn luyện nếu không bị kìm hãm bằng Regularization.

Giải pháp: Kìm hãm bằng Regularization

Nhạy cảm với Xoay trục: Bị trói buộc vào các ranh giới song song trục tọa độ.

Giải pháp: Khắc phục bằng PCA

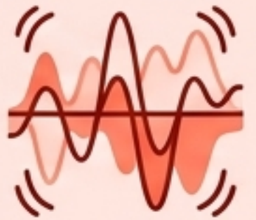

Bất ổn (Variance Cao): Rung lắc mạnh khi dữ liệu chỉ đổi một tẹo.

Giải pháp: Khắc phục bằng Ensemble Learning

Gemini Notebook

Thực hành - Bài tập 1: Phân loại Moons

Bước 1: Khởi tạo Dữ liệu

Tạo 10.000 điểm bằng make_moons(n_samples=10000, noise=0.4).

Bước 2: Phân chia

Tách thành Train/Test bằng train_test_split.

Bước 3: Dò tìm Tham số

Dùng GridSearchCV với DecisionTreeClassifier tìm max_leaf_nodes tốt nhất.

Bước 4: Đánh giá

Huấn luyện mô hình và tính Accuracy Score.

Gemini Notebook

Thực hành - Bài tập 2:
Tự xây dựng Khu rừng (Forest)

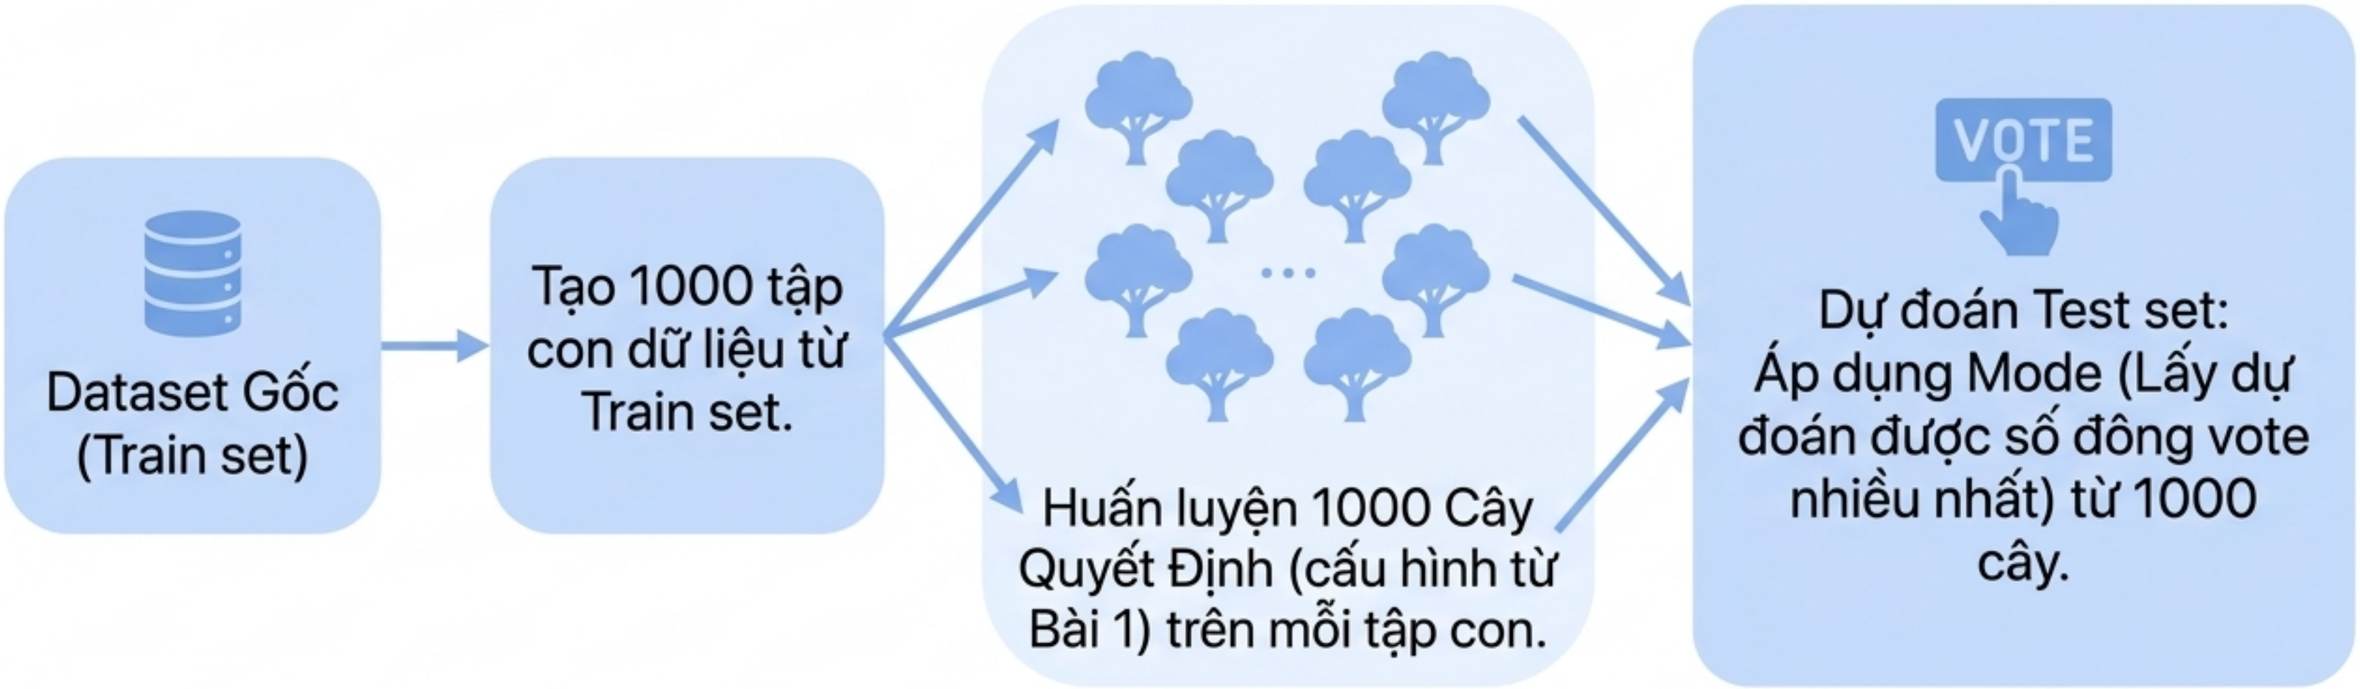

Kết quả: Độ chính xác tăng hơn ít nhất 0.5 – 1.5% so với 1 cây.