Chương 11: luyện lyện Mạng Nơ-ron Sâu

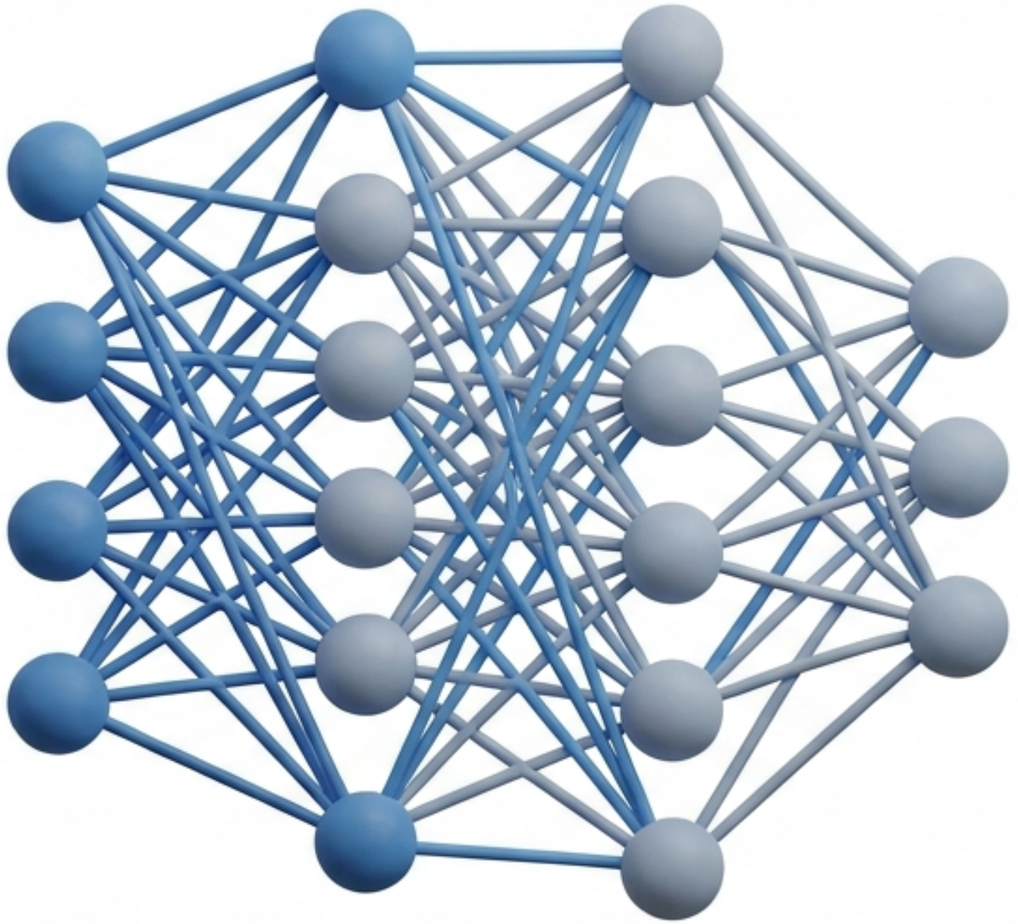

Giảng viên: [Tên Giảng Viên]

Đại Học Đông Á

Ngày 11 tháng 8 năm 2026

Gemini Notebook

Nội dung Chương 11

1. Vấn Đề Gradient Biến Mất / Bùng Nổ
2. Các Hàm Kích Hoạt Nâng Cao
3. Batch Normalization và Gradient Clipping
4. Tái Sử Dụng Các Lớp (Transfer Learning)
5. Các Trình Tối Ưu Hóa Tốc Độ Học (Fast Optimizers)
6. Lịch Trình Tốc Độ Học (Learning Rate Scheduling)
7. Kỹ Thuật Chính Quy Hóa (Regularization)

Gemini Notebook

Vấn đề Vanishing và Exploding Gradients

Thuật toán **backpropagation** cập nhật trọng số bằng cách truyền đạo hàm (gradient) từ lớp đầu ra ngược về lớp đầu vào.

Vanishing Gradients

Càng truyền ngược về các lớp sâu hơn (lower layers), **gradient** thường càng trở nên **nhỏ dần**.

Hậu quả: Trọng số của các lớp dưới cùng không thay đổi, mạng nơ-ron sâu không thể hội tụ.

Exploding Gradients

Gradient có thể **tăng lên** theo **cấp số nhân**.

Hậu quả: Trọng số lớn đến mức tràn bộ nhớ (thường gặp trong mạng RNN).

Gemini Notebook

Thủ phạm: Sự Bão Hòa Của Hàm Kích Hoạt Sigmoid

Năm 2010, Glorot và Bengio phát hiện thủ phạm chính: **hàm kích hoạt Sigmoid + khởi tạo trọng số ngẫu nhiên** ban đầu.

Nguyên nhân

Phương sai đầu ra > Phương sai đầu vào. Các giá trị ở lớp trên cùng trở nên rất lớn (hoặc rất âm).

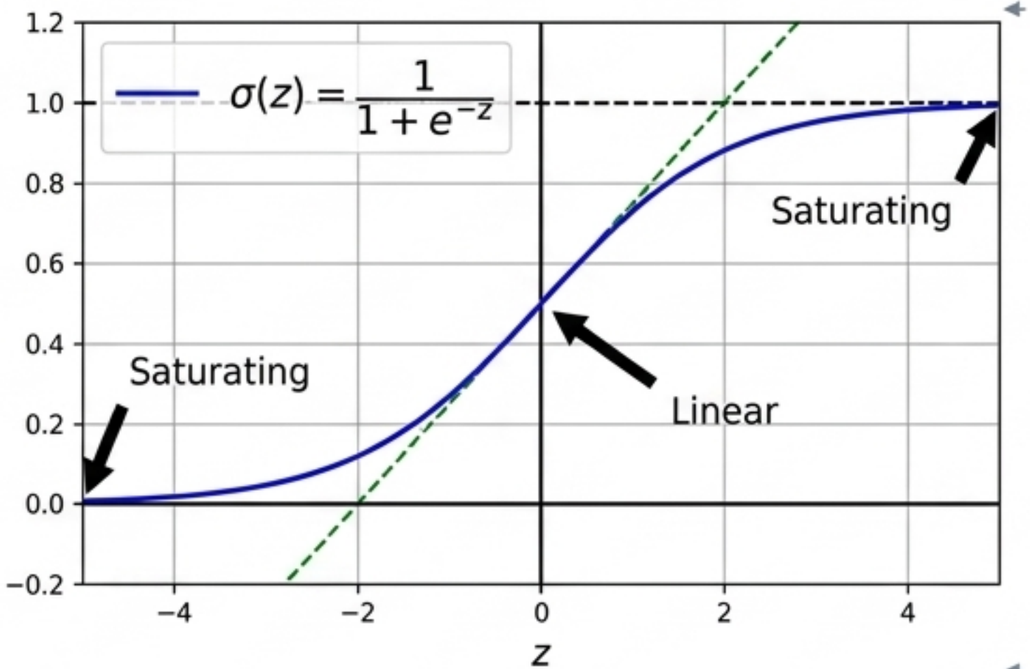

Cơ chế bão hòa

Khi giá trị tuyệt đối lớn, đạo hàm của hàm Sigmoid tiến về. Trọng số ngừng cập nhật.

Hình 11-1: Hàm kích hoạt sigmoid bão hòa ở hai đầu

Gemini Notebook

Giải pháp: Khởi tạo Trọng số Glorot / He (Initialization)

Nguyên tắc cốt lõi: Để tín hiệu chảy bình thường (xuôi & ngược), phương sai của đầu ra và đầu vào ở mỗi lớp phải bằng nhau.

Xavier Glorot

Đề xuất khởi tạo trọng số ngẫu nhiên (phân phối chuẩn) với phương sai:

$$\sigma^2 = \frac{1}{fan_avg}$$

Kaiming He

Đối với hàm ReLU, đề xuất khởi tạo He initialization:

$$\sigma^2 = \frac{2}{fan_in}$$

Gemini Notebook

Thực hành: Code Khởi Tạo Trọng Số trong Keras

Ghi chú: Mặc định, Keras dùng khởi tạo Glorot (phân phối đều).

```python
import tensorflow as tf
from tensorflow import keras

# Sụ dung He initialization (thuơng ket hợp voi ReLU)
dense = keras.layers.Dense(50, activation="relu",
                           kernel_initializer="he_normal")

# Hoac sụ dung phuong sai do LeCun de xuat (ket hợp voi SELU)
dense_lecun = keras.layers.Dense(50, activation="selu",
                                 kernel_initializer="lecun_normal")
```

Gemini Notebook

Điểm mù của ReLU: Vấn đề "Dying ReLU"

Dù hàm ReLU (`Rectified Linear Unit`) là tiêu chuẩn vàng, nó có một vấn đề nghiêm trọng gọi là **Dying ReLU**.

Nguyên nhân

Trọng số cập nhật sao cho tổng tĩnh $z < 0$.

Cơ chế

Hàm luôn trả về 0. Đồng thời, đạo hàm khi $z < 0$ cũng bằng 0.

Hậu quả

Nơ-ron "chết" vĩnh viễn và không bao giờ học lại được nữa.

Gemini Notebook

Khắc phục: Hàm Leaky ReLU

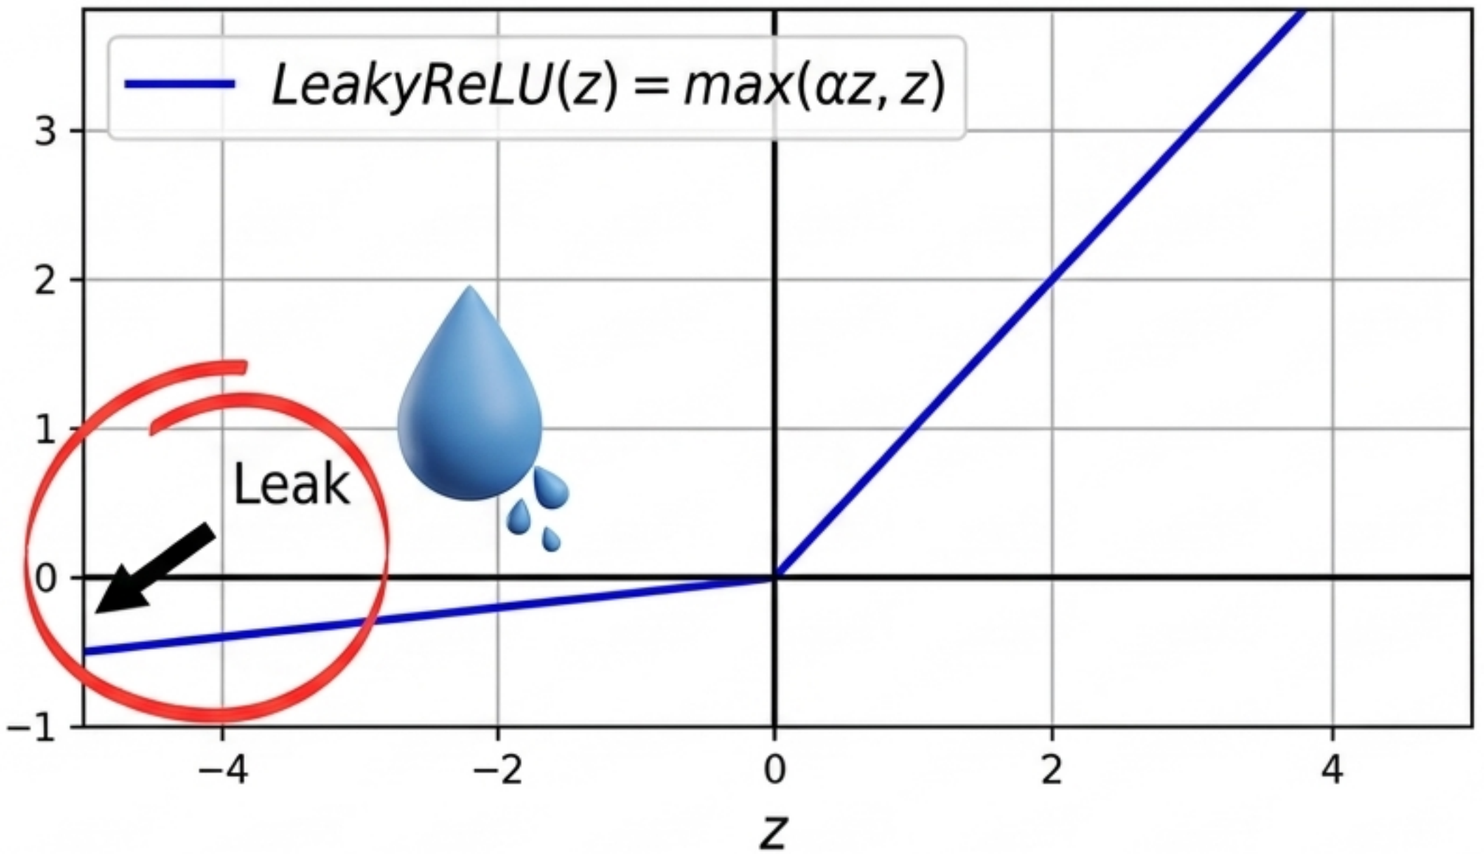

Hình 11-2: Hàm kích hoạt Leaky ReLU

Công thức:
$LeakyReLU_\alpha(z) = \max(\alpha z, z)$

Giải thích tham số: α (thường là 0.01) xác định độ dốc của hàm với các giá trị âm.

Tác dụng: "Độ rò rỉ" (leak) này giúp giữ nơ-ron không bị chết hoàn toàn, tạo cơ hội cho gradient được truyền ngược trở lại.

Gemini Notebook

Biến thể Nâng cao: ELU và SELU

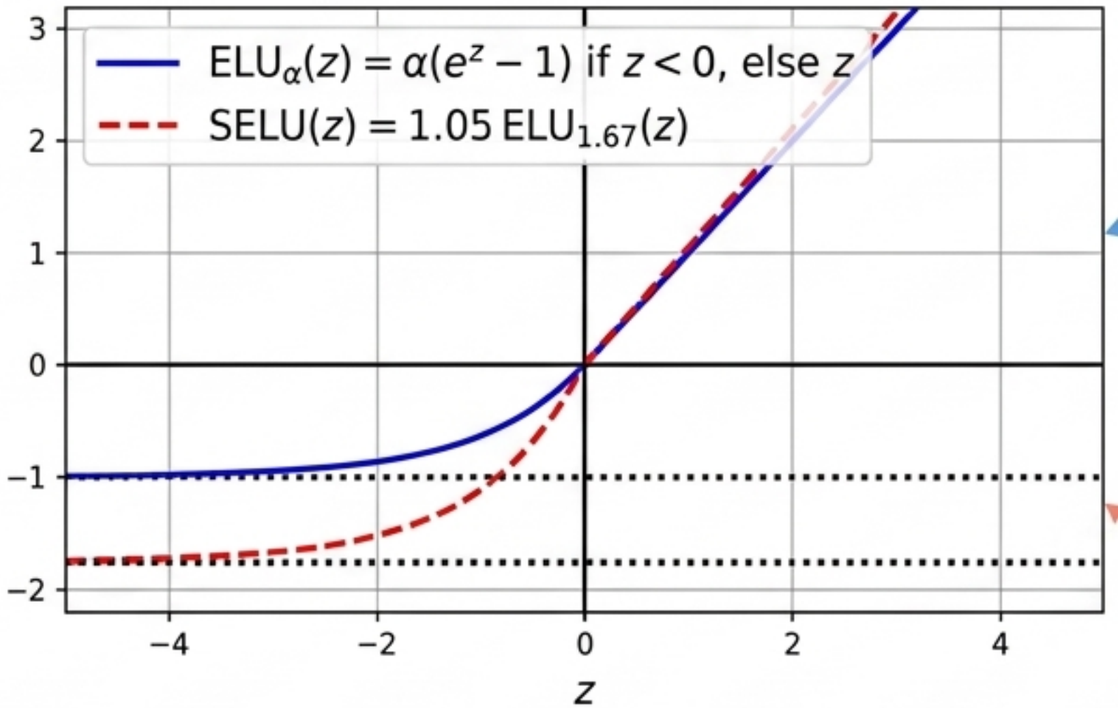

Hình 11-3: Các hàm kích hoạt ELU và SELU

ELU (Exponential Linear Unit)

- Mượt mà ở khắp mọi nơi (đạo hàm liên tục tại z = 0).
- Cải thiện tốc độ học tập.

SELU (Scaled ELU)

- Nếu tất cả các lớp dày đặc sử dụng SELU, mạng sẽ tự chuẩn hóa (self-normalize).
- Giải quyết vấn đề vanishing gradient triệt để.

Gemini Notebook

Các Hàm Hiện Đại: GELU, Swish, và Mish

Đặc điểm chung: Đây là các hàm phức tạp, mượt mà và không đơn điệu (non-monotonic).

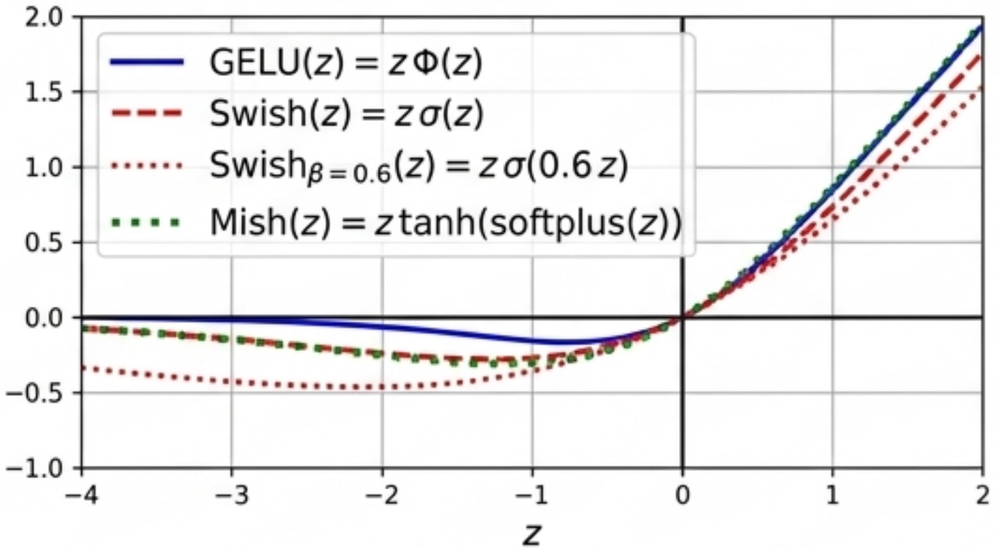

Hình 11-4: Các hàm kích hoạt GELU, Swish, và Mish

GELU: Vượt trội trong các mạng NLP (như BERT).

Swish: Do Google Brain đề xuất, tối ưu hơn trong các bài toán Image Recognition sâu.

Mish: Một hàm mới với đồ thị gần tương tự nhưng có công thức khác.

Gemini Notebook

Chuẩn hóa Hàng loạt (Batch Normalization)

Bối cảnh: Khởi tạo He và ELU có thể giảm thiểu Vanishing Gradient ở đầu khóa huấn luyện, nhưng không đảm bảo không xuất hiện trong quá trình.

Giải pháp: Sergey Ioffe và Christian Szegedy (2015) giới thiệu Batch Normalization (BN).

1. Tính **trung bình** và **độ lệch chuẩn** của đầu vào tại mỗi lô (**mini-batch**) độc lập.

2. Áp dụng **thay đổi tỷ lệ (scale)** γ

3. Áp dụng **độ dịch chuyển (shift)** β được học qua backpropagation.

Gemini Notebook

Thực hành: Thêm Batch Normalization trong Keras

Kinh nghiệm thực tế: Lớp BN thường được thêm trước hoặc sau Hàm kích hoạt. Đặt nó **TRƯỚC** hàm kích hoạt sẽ hoạt động tốt nhất.

```
model = keras.models.Sequential([
    keras.layers.Flatten(input_shape=[28, 28]),
    keras.layers.BatchNormalization(),
    keras.layers.Dense(300, use_bias=False), # khong can bias vi BN co thuoc tinh dich chuyen(beta)
    keras.layers.BatchNormalization(),
    keras.layers.Activation("relu"),
    keras.layers.Dense(100, use_bias=False),
    keras.layers.BatchNormalization(),
    keras.layers.Activation("relu"),
    keras.layers. Dense(10, activation= "softmax")
 ])
```

Không cần bias khi sử dụng BN vì BN đã có tham số dịch chuyển (beta)

Vị trí đặt các lớp Batch Normalization: Thường trước lớp Dense hoặc Activation để ổn định phân phối.

Gemini Notebook

Hoạt động của BN lúc Inference (Dự đoán)

Lúc Huấn luyện	Lúc Dự đoán (Inference)
Thách thức: BN tính mean, variance của một mini-batch.	**Thách thức:** Dữ liệu đến từng cái một, làm sao tính mean và variance?

Giải pháp (Keras xử lý tự động)

- BN theo dõi moving average (trung bình động) của mean và variance trên toàn bộ tập huấn luyện.
- Keras sẽ tự động sử dụng giá trị này khi bạn gọi `model.predict()`.

Gemini Notebook

Kìm hãm sự bùng nổ: Gradient Clipping

Khái niệm: Kỹ thuật phổ biến để giảm bớt vấn đề Exploding Gradients. Thường được dùng mạnh mẽ trong Mạng Nơ-ron Hồi quy (RNN).

Cơ chế: Cắt (clip) các gradient để chúng không bao giờ vượt quá một ngưỡng (Threshold).

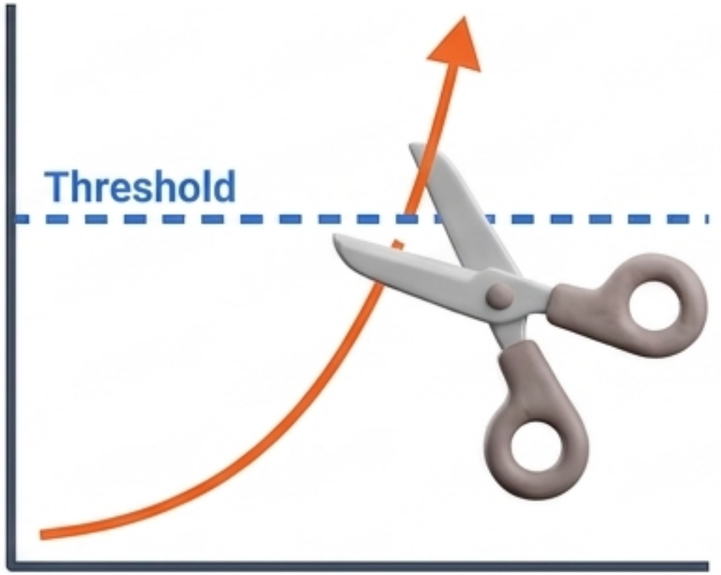


```
# Cat gradient theo gia tri tuyet doi (-1.0 den 1.0)
optimizer = keras.optimizers.SGD(clipvalue=1.0)
model.compile(loss="mse", optimizer=optimizer)

# Hoac cat theo chuan (Norm) de khong thay doi huong cua vector
optimizer = keras.optimizers.SGD(clipnorm=1.0)
```

Gemini Notebook

Chiến lược: Học Chuyển Giao (Transfer Learning)

Vấn đề: Sẽ rất lãng phí nếu đào tạo mạng CNN siêu lớn từ con số 0.

Chiến lược "Tái sử dụng":

1. Tìm một Mạng Nơ-ron hiện có thực hiện nhiệm vụ tương tự.
2. Giữ lại các lớp dưới (Lower layers) / Đóng băng (Freeze).
3. Chỉ thay đổi lớp trên cùng (Output layers).

Kết luận: Tái sử dụng các lớp giúp tăng tốc độ huấn luyện đáng kể.

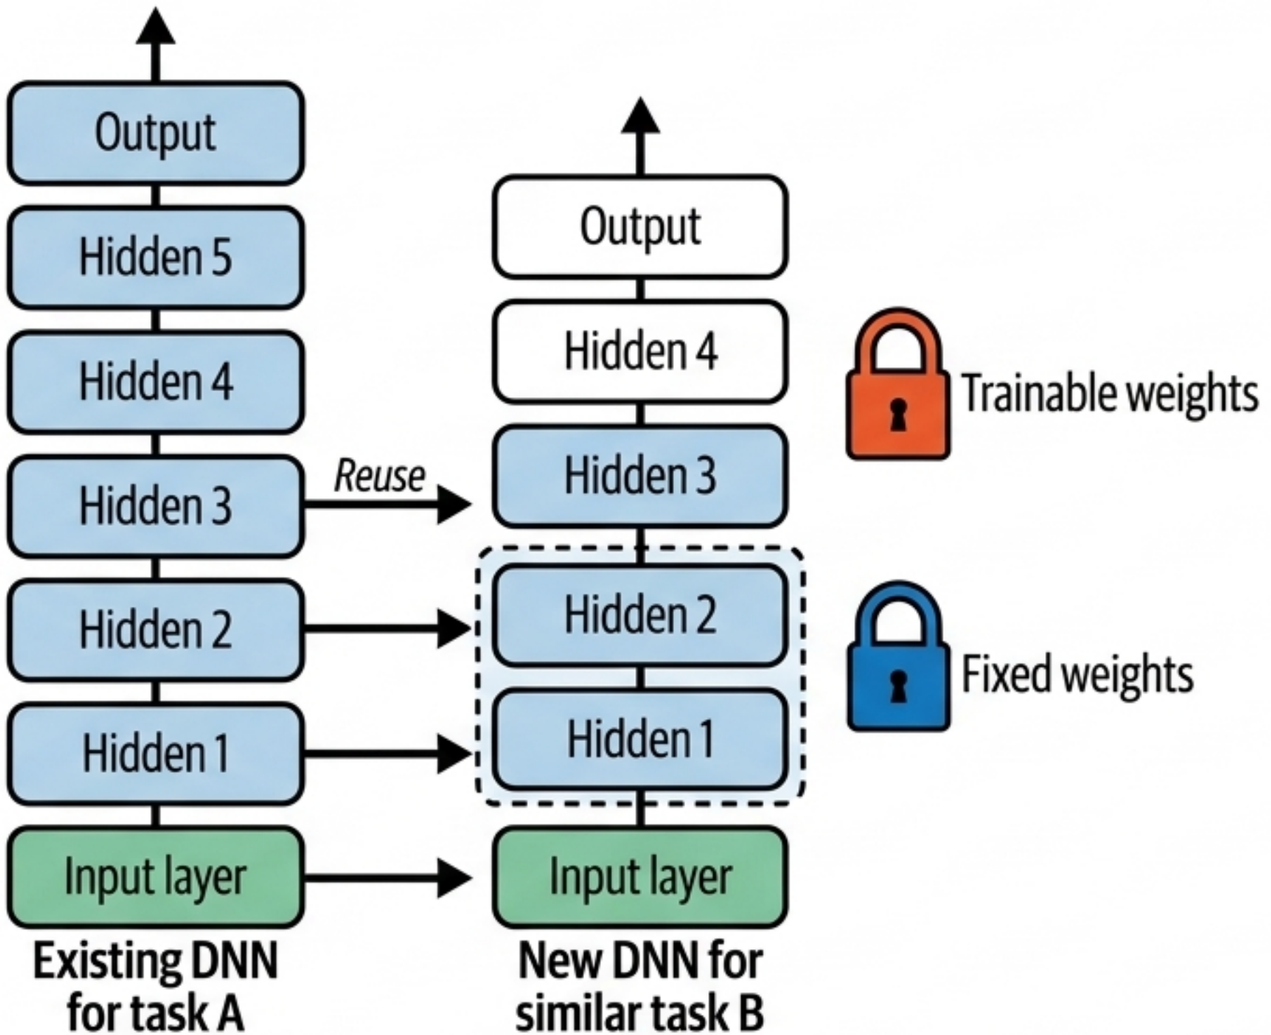

Hình 11-5: *Tái sử dụng các lớp đã được huấn luyện trước*

Gemini Notebook

Tái sử dụng mô hình trong Keras

```
# Tai mot mo hình da huan luyen (Model A)
model_A = keras.models.load_model("my_model_A.h5")

# Tao Model B dưa tren cac lop cua Model A (tru lop cuoi)
model_B_on_A = keras.models.Sequential(model_A.layers[:-1])
model_B_on_A.add(keras.layers.Dense(1, activation="sigmoid"))

# Dong bang (Freeze) cac lop cu
for layer in model_B_on_A.layers[:-1]:
    layer.trainable = False

# Huan luyen vai epoch de cap nhat lop cuoi
model_B_on_A.compile(loss="binary_crossentropy", optimizer="sgd")
model_B_on_A.fit(X_train_B , y_train_B , epochs=4)
```

Gemini Notebook

Huấn Luyện Không Giám Sát (Unsupervised Pretraining)

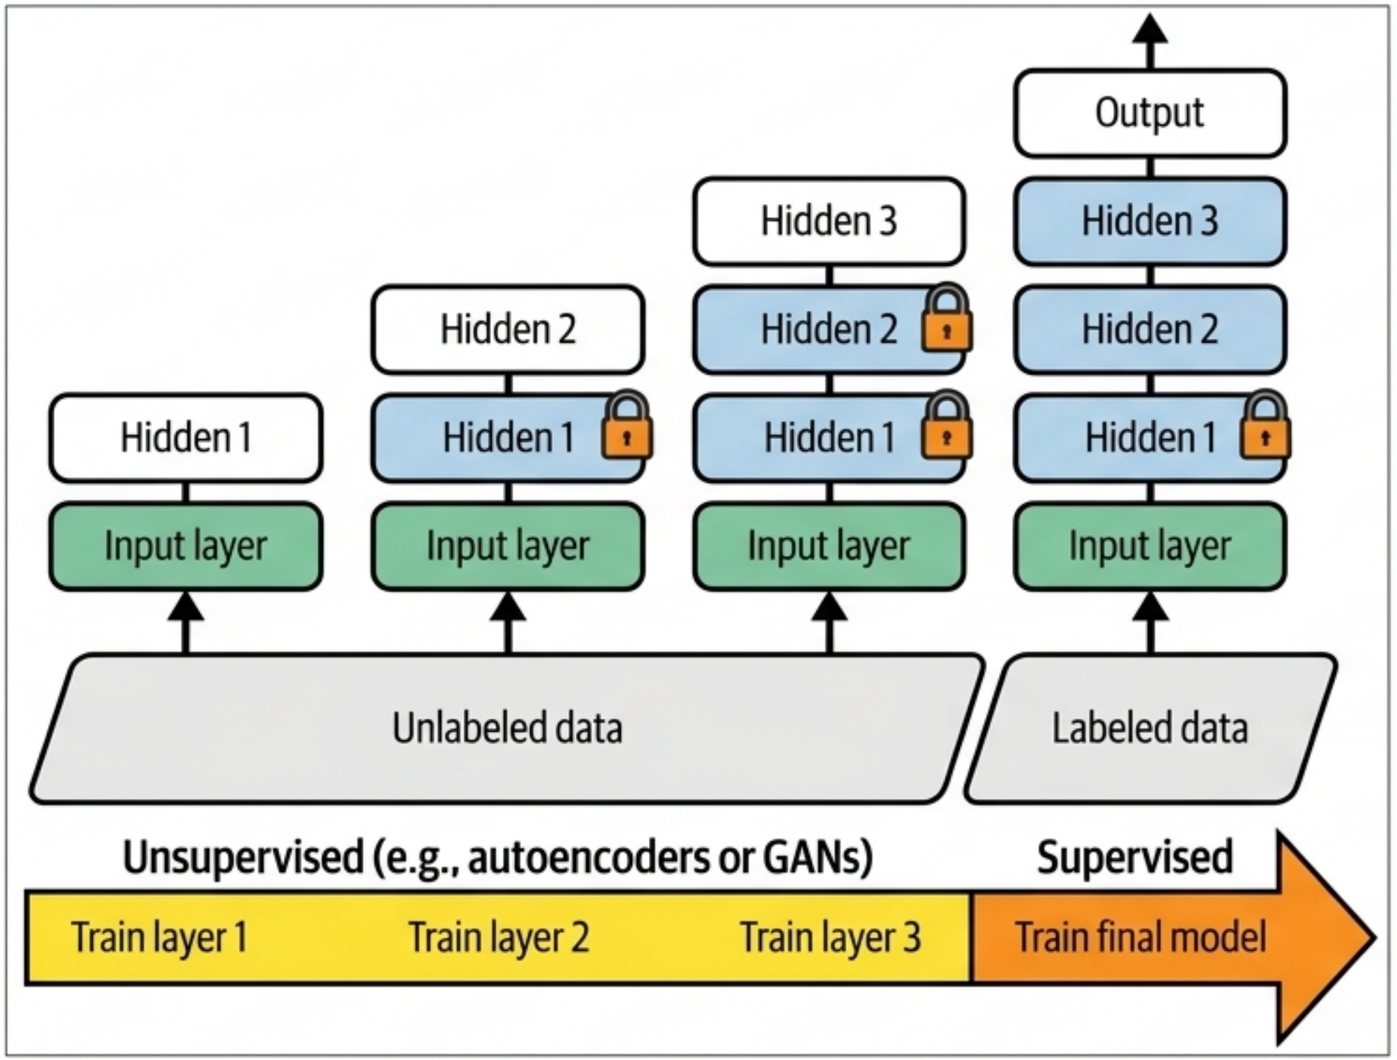

Hình 11-6: Học chuyển giao từ huấn luyện không giám sát

Điều gì xảy ra nếu bạn có quá ít dữ liệu gắn nhãn (Labeled data)? Bạn có thể đào tạo trước bằng **Học không giám sát** (như **Autoencorders** hoặc **RBMs**). Sau đó chèn thêm lớp phân loại và huấn luyện có giám sát.

Hình 11-6: Các mô hình **NLP** ngôn ngữ lớn như **GPT** và **BERT** cũng là một dạng **Unsupervised Pretraining** khổng lồ!

Gemini Notebook

Giới thiệu các Optimizer (Trình tối ưu hóa)

SGD (Stochastic Gradient Descent) cơ bản hoạt động ổn định nhưng **cực kỳ chậm**. Các nhà khoa học đã phát triển ra các thuật toán Tối ưu hóa có khả năng chạy nhanh gấp 10-100 lần. Các Optimizer nổi tiếng:

1. Momentum Optimization
2. Nesterov Accelerated Gradient (NAG)
3. AdaGrad
4. RMSProp
5. Adam / Nadam

Gemini Notebook

Tối ưu hóa Bằng Động Lượng (Momentum)

SGD cập nhật trọng số dựa hoàn toàn trên **gradient tại thời điểm hiện tại**. Nó giống như đi xuống núi nhưng rẽ ngoặt theo góc dốc ngay dưới chân.

Momentum quan tâm đến **các gradient trước đó**. Giống như thả một quả bóng bowling xuống bề mặt trơn: quả bóng sẽ liên tục **tăng tốc** (động lượng lớn). Cập nhật công thức:

$$\boldsymbol{m} \leftarrow \beta \boldsymbol{m} - \eta \nabla_\theta J(\boldsymbol{\theta})$$
$$\boldsymbol{\theta} \leftarrow \boldsymbol{\theta} + \boldsymbol{m}$$

```
Keras: keras.optimizers.SGD(learning_rate=0.001, momentum=0.9)
```

Gemini Notebook

Nesterov Accelerated Gradient (NAG)

Biến thể của Momentum. Thay vì tính đạo hàm tại vị trí hiện tại θ, NAG tính đạo hàm **ở bước tiến tới (Look-ahead)** một khoảng **βm**.

Điều này giúp thuật toán "đạp phanh" kịp thời khi đến gần đáy lũng. Hình 11-7 so sánh Momentum thông thường (màu xanh lam) và NAG (màu đỏ).

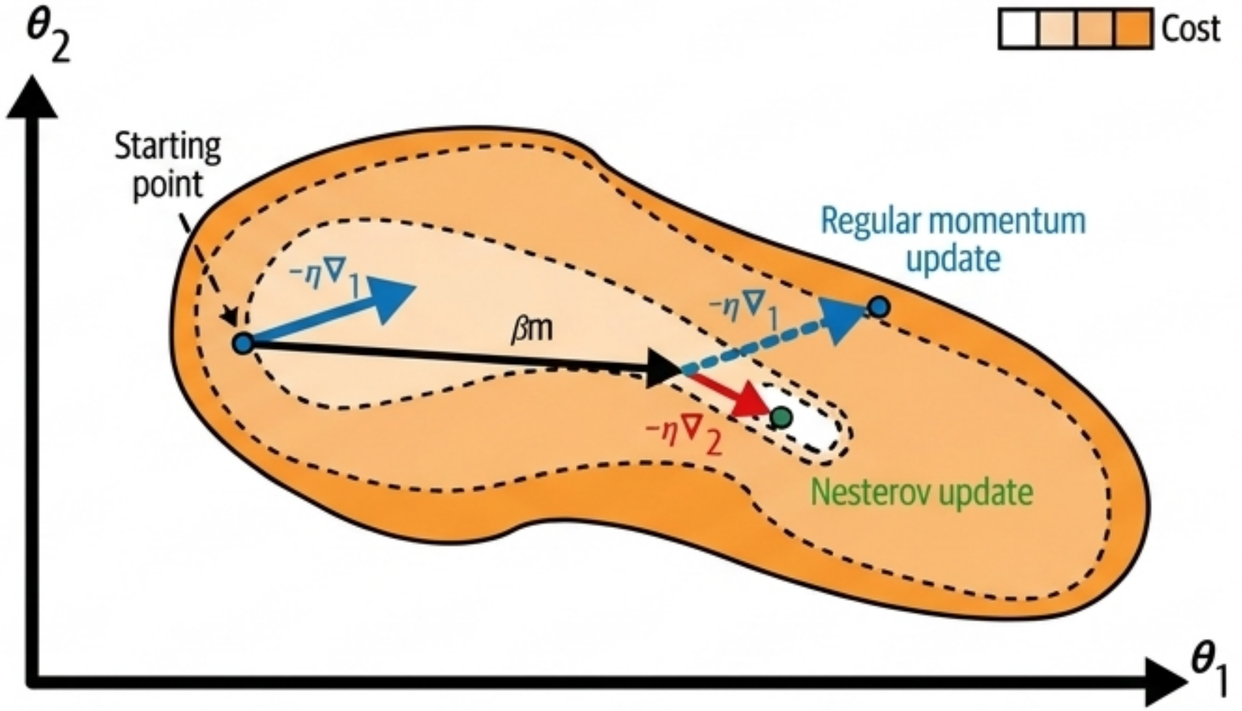

Hình 11-7: So sánh Momentum thông thường và Nesterov

Gemini Notebook

AdaGrad

Trong các bài toán có nhiều chiều (dimensions) bị thon dài (elongated bowl). Thuật toán AdaGrad tự động **làm giảm tốc độ học** dọc theo các chiều có độ dốc quá cao (steep dimensions).

Hình 11-8: AdaGrad đi thẳng tới đích rành mạch hơn thay vì "ngoằn ngoèo" như SGD.

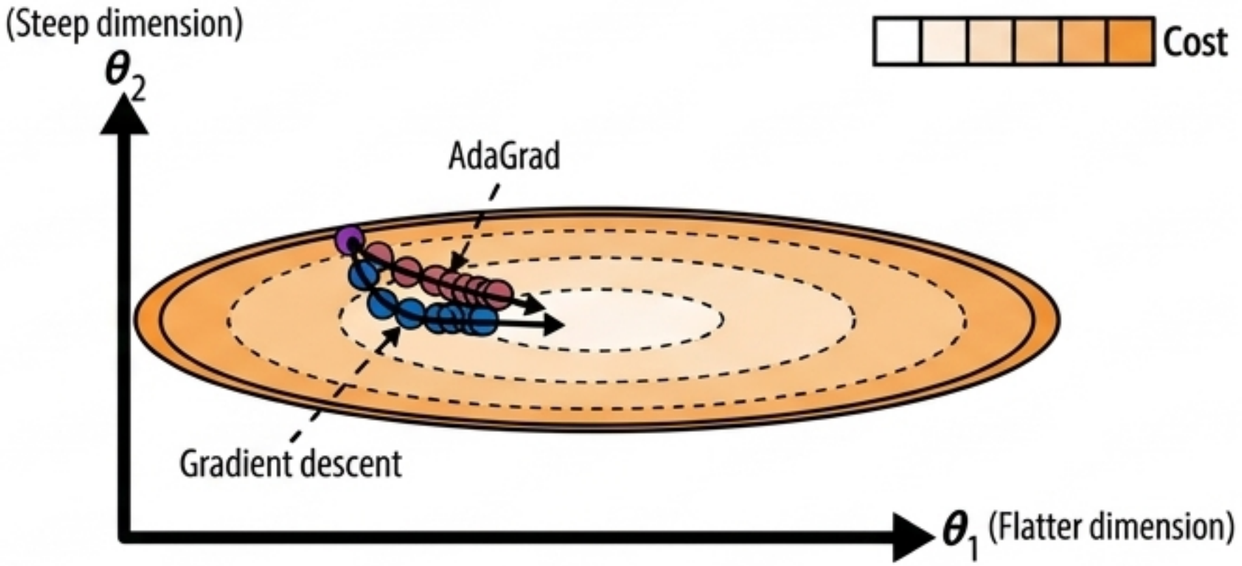

Hình 11-8: So sánh AdaGrad và Gradient Descent

Lưu ý: AdaGrad bị dừng quá sớm khi dùng cho Neural Networks, do vậy chỉ dùng trong hồi quy tuyến tính.

Gemini Notebook

RMSProp và Adam

RMSProp: Sửa chữa nhược điểm của AdaGrad bằng cách chỉ xem xét các gradient gần đây (thay vì tích lũy từ đầu). Rất phổ biến trước khi Adam ra đời.

Adam (Adaptive Moment Estimation): Kết hợp tính chất tuyệt vời của Momentum (tích lũy gradient) và RMSProp (tích lũy bình phương gradient). Adam là Optimizer "mặc định" và thành công vang dội nhất hiện nay cho Mạng Nơ-ron.

```
# Hien tai Optimizer xin so va de dung nhat la Adam
optimizer = keras.optimizers.Adam(learning_rate=0.001, beta_1=0.9, beta_2=0.999)
```

Gemini Notebook

Vấn đề của Tốc Độ Học Cố Định

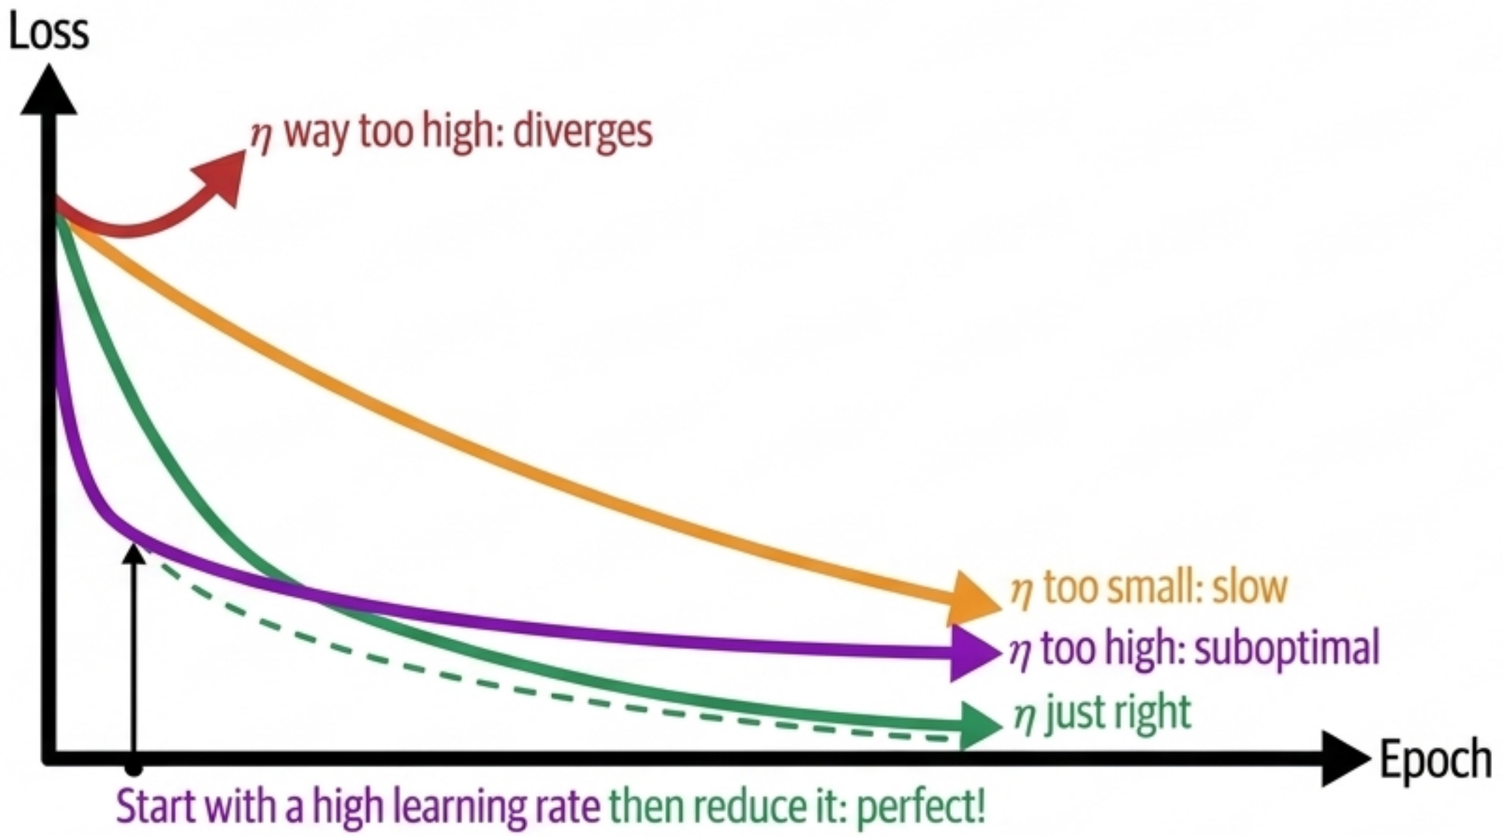

Hình 11-9: Lịch trình tốc độ học

Tốc độ học (Learning Rate - η) là siêu tham số quan trọng nhất.

- Quá lớn: mô hình phân kỳ.
- Quá nhỏ: mất quá nhiều thời gian hội tụ.

Hình 11-9: Nếu ta bắt đầu lớn (để tiến nhanh), sau đó giảm dần (để hội tụ chính xác), ta sẽ đạt kết quả tối ưu nhất trong thời gian ngắn nhất!

Gemini Notebook

Code: Power Scheduling trong Keras

Lập lịch theo hàm lũy thừa: $\eta(t) = \frac{\eta_0}{(1 + t/s)^c}$. Keras thực hiện cực kì dễ thông qua tham số 'decay' (Keras phiên bản cũ) hoặc 'InverseTimeDecay'.

```
lr_schedule = keras.optimizers.schedules.InverseTimeDecay(
    initial_learning_rate=0.01,
    decay_steps=10000,
    decay_rate=1.0)

optimizer = keras.optimizers.SGD(learning_rate=lr_schedule)
```

Gemini Notebook

Code: Performance Scheduling

Giảm tốc độ học một nửa khi hàm lỗi (validation error) ngưng giảm.
Trong Keras, sử dụng Callback ReduceLROnPlateau.

```
lr_scheduler = keras.callbacks.ReduceLROnPlateau( \
    factor=0.5, # giam mot nua
    patience=5) # neu sau 5 epoch khong giam loi, thi giam LR

model.fit(X_train , y_train , epochs=50, \
    validation_data=(X_valid , y_valid), \
    callbacks=[lr_scheduler])
```

Gemini Notebook

Tổng Quan Các Phương Pháp Chính Quy Hóa

‘Với hàng tỷ trọng số tự do, mạng nơ-ron sâu có thể học rất tốt, thậm chí nhớ luôn cả nhiễu trong dữ liệu." Đây chính là **Overfitting** (Quá khớp). Các kỹ thuật phổ biến để khắc phục:

1. L1 và L2 Regularization (Kìm hãm trọng số lớn)

2. Dropout (Loại bỏ ngẫu nhiên)

3. Max-Norm (Giới hạn chuẩn vector trọng số)

4. Data Augmentation (Tăng cường dữ liệu bằng biến đổi hình ảnh/âm thanh)

Gemini Notebook

L1 và L2 Regularization

Cộng thêm hình phạt (**penalty**) bằng độ lớn của trọng số (**Weights**) vào hàm Mất Mát (**Loss Function**). Có thể thiết lập dễ dàng trong Keras layers:

```
# Ap dung l2 regularization voi he so 0.01
layer = keras.layers.Dense(100, activation="elu",
     kernel_initializer="he_normal",
     kernel_regularizer=keras.regularizers.l2(0.01))
```

Pro-tip: Để mã sạch hơn (do lặp lại nhiều lần), bạn có thể dùng tính năng ‘`functools.partial`‘.

Gemini Notebook

Dropout - "Liều Thuốc Mê" Cho Nơ-ron

G. E. Hinton (2012) giới thiệu thuật toán đơn giản một cách vô lý nhưng cực kỳ thành công: **Dropout**.

Tại mỗi lượt huấn luyện, mỗi nơ-ron có xác suất p (thường từ 10% đến 50%) bị "ngắt" tạm thời. Các nơ-ron không thể phụ thuộc vào đồng nghiệp kế bên mà tự thân vận động trích xuất các đặc trưng hữu ích nhất.

Hình 11-10: Minh họa mạng áp dụng kỹ thuật Dropout.

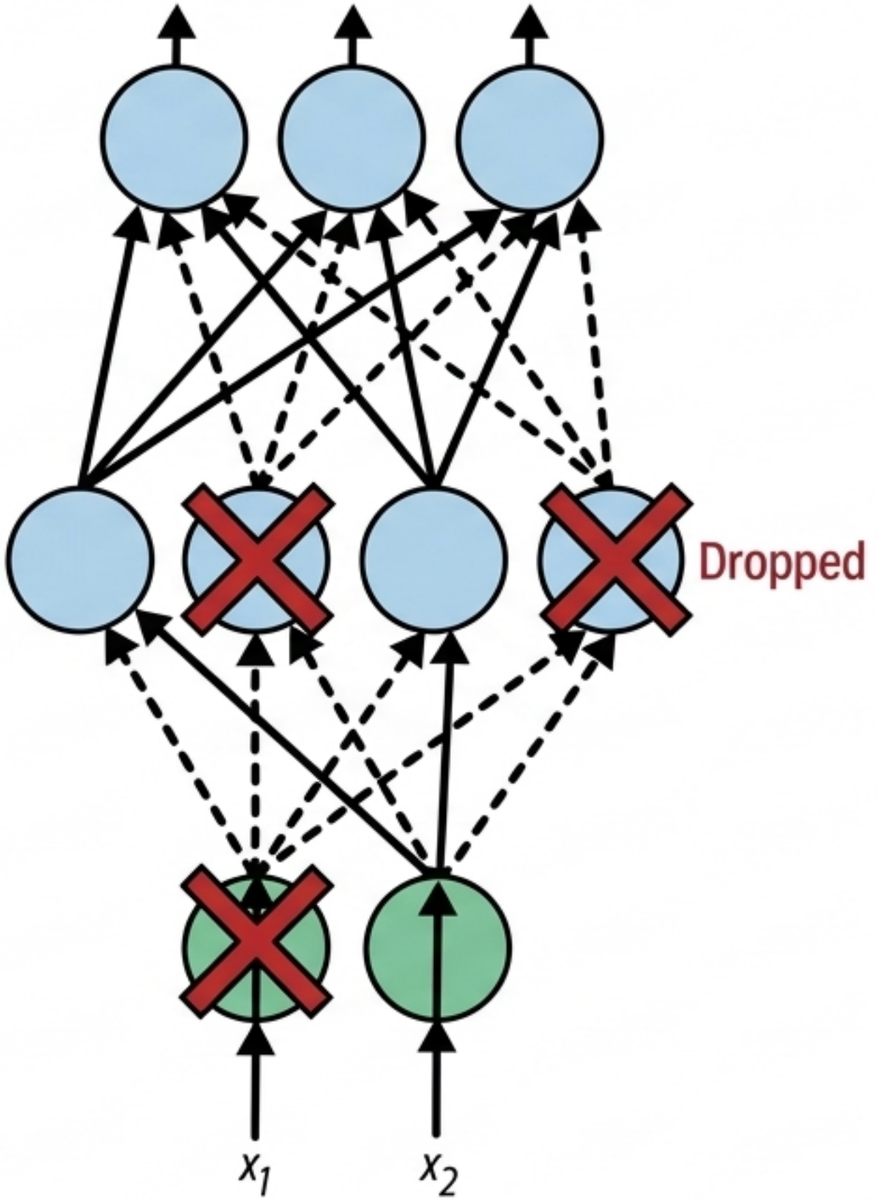

Hình 11-10: Với chính quy hóa dropout, một số nơ-ron bị tắt ngẫu nhiên

Gemini Notebook

Sử dụng Dropout trong Keras

Quan trọng: Khi Dropout huấn luyện, chỉ còn khoảng một nửa số nơ-ron tham gia dự đoán. Vì vậy, trong giai đoạn **Test/Inference**, ta **PHẢI** nhân giá trị với xác suất giữ lại để cân bằng. (Keras tự động xử lý việc này).

```
model = keras.models.Sequential([
    keras.layers.Flatten(input_shape=[28, 28]),
    keras.layers.Dropout(rate=0.2), # ngat 20% no-ron
    keras.layers.Dense(300, activation="elu", kernel_initializer="he_normal"),
    keras.layers.Dropout(rate=0.2),
    keras.layers.Dense(100, activation="elu", kernel_initializer="he_normal"),
    keras.layers.Dropout(rate=0.2),
    keras.layers.Dense(10, activation="softmax")
])
```

Gemini Notebook

Monte Carlo
Monte Carlo (MC) Dropout

Y. Gal và Z. Ghahramani (2016) chỉ ra rằng mạng nơ-ron sử dụng Dropout tương đương toán học với quá trình xấp xỉ suy luận Bayes (Bayesian inference).

Cụ thể, **MC Dropout** bật Dropout ngay cả trong giai đoạn Inference (Dự đoán).

Khi ta thực hiện dự đoán 100 lần trên cùng 1 mẫu, ta sẽ nhận được 100 kết quả dự đoán (xác suất) khác nhau do mỗi lần mạng lại tắt đi một số nơ-ron ngẫu nhiên. Tính **trung bình** và phương sai **của các dự đoán đó sẽ cho ta một độ tin cậy vô cùng chính xác!**

Gemini Notebook

Thực Hiện MC Dropout Bằng Keras

Tính toán giá trị trung bình và độ bất định của dự đoán bằng kỹ thuật Monte Carlo.

```python
import numpy as np

# Bat tinh nang Training = True ben trong lop Dropout ke cá khi du doan
y_probas = np.stack([model(X_test_scaled , training=True)
                     for sample in range(100)])
y_proba = y_probas.mean(axis=0)
y_std = y_probas.std(axis=0) # Do bat dinh (Uncertainty)
```

Bật tính năng Training = True bên trong lớp Dropout kể cả khi dự đoán.

Gemini Notebook

Alpha Dropout

Nếu bạn sử dụng hàm kích hoạt **SELU** để mạng tự chuẩn hóa (self-normalize). Thì sử dụng Dropout thông thường sẽ phá hủy sự tự chuẩn hóa đó!

Hãy sử dụng **AlphaDropout** - một biến thể của Dropout bảo toàn được giá trị trung bình và phương sai.

```
model.add(keras.layers.AlphaDropout(rate=0.2))
```

Gemini Notebook

Max-Norm Regularization

Hạn chế (clamp) không cho chuẩn l2 (Norm 2) của vector trọng số của mỗi nơ-ron vượt quá một giá trị lớn nhất r.

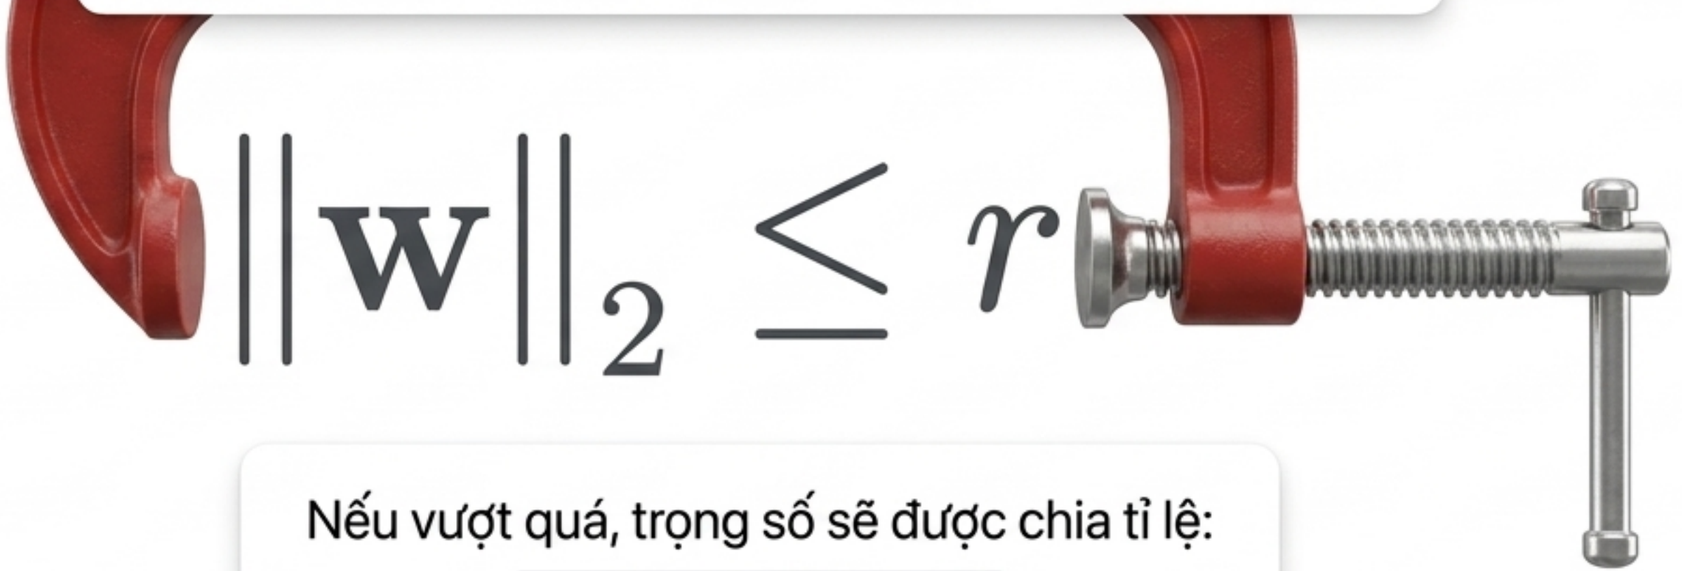

$$\|\mathbf{w}\|_2 \leq r$$

Nếu vượt quá, trọng số sẽ được chia tỉ lệ:

$$\mathbf{w} \leftarrow \mathbf{w}\,(r \,/\, \|\mathbf{w}\|_2)$$

Max-norm kết hợp rất tốt với Dropout để kìm hãm sự tăng trưởng vô hạn của các trọng số.

Gemini Notebook

Code: Max-Norm Trong Keras

```
dense = keras.layers.Dense(100, activation="elu",
                           kernel_initializer ="he_normal",
                           kernel_constraint=keras.constraints.max_norm(1.))
```

Tương đương với việc thiết lập giá trị lớn nhất r = 1. trong công thức kìm hãm trọng số.

Gemini Notebook

Tối ưu hóa RMSProp

AdaGrad - The Flaw

AdaGrad đôi khi giảm tốc độ học quá mức và **dừng sớm** trước khi đến mục tiêu cực trị toàn cục (global optimum).

RMSProp - The Fix

RMSProp là phiên bản nâng cấp của AdaGrad, giải quyết việc dừng sớm bằng cách:

- Chỉ tích lũy bình phương của các gradient **gần đây nhất** thay vì tất cả gradient từ đầu thuật toán.
- Thuật toán này sử dụng tốc độ **phân rã lũy thừa β** (exponential decay).

Gemini Notebook

Code: Tối Ưu Hóa RMSProp Keras

```
# Tinh chinh toc do doc bang RMSprop
optimizer = keras.optimizers.RMSprop(learning_rate=0.001, rho=0.9)
```

Tham số 'rho' tương ứng với β trong công thức lý thuyết (thường đặt là 0.9).

Ngoại trừ những kiến trúc cực kỳ phức tạp, RMSProp gần như luôn hoạt động tốt hơn hẳn so với AdaGrad.

Gemini Notebook

Adam, Nadam & AdamW

Adam

Kết hợp **Momentum** (theo dõi động lượng) và **RMSProp** (theo dõi bình phương gradient).

Nadam

Là Adam cộng **với kỹ thuật Nesterov Accelerated Gradient (NAG)**, cho tốc độ hội tụ nhanh hơn một chút.

AdamW

Là Adam kết hợp với kỹ thuật điều chuẩn phân rã trọng số (**weight decay regularization**) thực thụ, thường dùng cho mạng biến áp (Transformers).

Gemini Notebook

Tóm Tắt Lựa Chọn Các Kỹ Thuật (Phần 1)

Thành phần	Lựa chọn mặc định
Cấu hình khởi tạo (Init)	Khởi tạo He (He initialization)
Hàm kích hoạt (Activation)	ELU hoặc GELU (hoặc Swish)
Chuẩn hóa (Normalization)	Mạng nông/sâu: Batch Normalization (BN)
Chống quá khớp (Regularize)	Early Stopping + Dropout
Trình tối ưu hóa (Optimizer)	Nadam hoặc AdamW (kèm Warmup)
Lịch trình tốc độ học	Performance Scheduling (hoặc One Cycle)

Gemini Notebook

Tóm Tắt Lựa Chọn Nếu Tự Chuẩn Hóa (Phần 2)

Nếu bạn xây dựng Mạng dày đặc (Dense) và muốn nó tự chuẩn hóa (Self-Normalizing):

Thành phần	Cấu hình Mạng Tự Chuẩn Hóa
Cấu hình khởi tạo (Init)	Khởi tạo LeCun
Hàm kích hoạt (Activation)	SELU
Chuẩn hóa (Normalization)	Không cần (tự thân chuẩn hóa)
Chống quá khớp (Regularize)	Alpha Dropout
Lịch trình tốc độ học	Performance Scheduling (hoặc One Cycle)

Gemini Notebook

Các Vấn Đề Thực Tế Khác

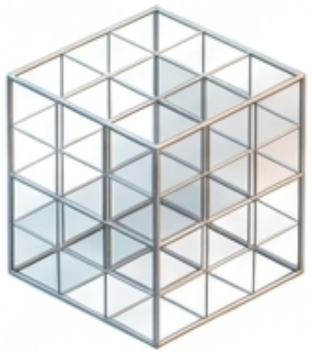

Nếu bạn làm việc trên các mô hình Thưa (Sparse models), hãy dùng L1 Regularization.

Nếu thiết bị của bạn cần tốc độ phản hồi cực nhanh (low latency) khi ứng dụng thực tế (Inference), hãy loại bỏ Batch Normalization bằng cách hợp nhất (fuse) các tham số vào lớp trước đó, và dùng Leaky ReLU.

Luôn tận dụng tài nguyên có sẵn: Đừng quên Transfer Learning!

Gemini Notebook

Tổng Kết Chương 11

Chúng ta đã giải quyết rốt ráo việc **Huấn Luyện Các Mạng Khổng Lồ** mà không để rơi vào tình trạng Vanishing Gradient.

Khởi tạo He kết hợp hàm **ELU / GELU** là lựa chọn tiêu chuẩn.

Củng cố bằng **Batch Normalization**.

Sử dụng **Adam Optimizer** với Lịch trình Học Tập (Learning Rate Schedule).

Và đương nhiên, chống Overfitting hiệu quả bằng **Dropout**.

Gemini Notebook